

7 Der Globus-Versuch



Bayes:Start!

7.1 Lernsteuerung

In diesem Kapitel übersetzen wir eine Problemstellung (Forschungsfrage) in ein (mathematisches) Modell, das uns dann mithilfe der Bayes-Formel Antworten auf die Problemstellung gibt.

Nach Absolvieren dieses Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- Unterschiede zwischen Modellen und der Realität erläutern
- die Binomialverteilung heranziehen, um geeignete (einfache) Modelle zu erstellen (für binomial verteilte Zufallsvariablen)
- die weite Einsetzbarkeit anhand mehrerer Beispiele exemplifizieren
- das Bayes-Modell anhand bekannter Formeln herleiten
- Post-Wahrscheinlichkeiten anhand der Bayesbox berechnen

Der Stoff dieses Kapitels deckt einen Teil aus McElreath (2020), Kap. 2, ab. McElreath (2020) stellt das Globusmodell mit mehr Erläuterung und etwas mehr theoretischem Hintergrund vor, als es in diesem Kapitel der Fall ist.

Lesen Sie zur Vorbereitung in [Statistik 1 das Kapitel “Daten Einlesen”](#). Das Video [Globusversuch](#) ist hilfreich.

Folgende R-Pakete werden in diesem Kapitel benötigt:

```
library(tidyverse)
library(ggpubr) # komfortable Visualisierung
```

Hinweis

Die Folien zu diesem Kapitel finden Sie [hier](#).

7.2 Von Welten und Golems

7.2.1 Kleine Welt, große Welt

Bekanntlich segelte Kolumbus 1492 los, und entdeckte Amerika¹. Das war aber ein glücklicher Zufall, denn auf seinem Globus existierte Amerika gar nicht. Vielleicht sah sein Globus so aus wie der von Behaim, s. Abb [Abbildung 7.1](#).




Abbildung 7.1: Behaims Globus: Kein Amerika

Quelle: Ernst Ravenstein, Wikimedia, Public Domain

Die *kleine Welt* des Modells entsprach hier nicht der *großen Welt*, der echten Erdkugel.

Das ist ein Beispiel, das zeigt, wie Modellieren schiefgehen kann. Es ist aber auch ein Beispiel für, sagen wir, die Komplexität wissenschaftlicher (und sonstiger) Erkenntnis. Einfach gesagt: Glück gehört halt auch dazu.

Hinweis

Behaims Globus ist nicht gleich der Erde. Die kleine Welt von Behaims Globus ist nicht die große Welt, ist nicht die Erde.

Was in der kleinen Welt funktioniert, muss nicht in der großen Welt funktionieren. Modelle zeigen immer nur die kleine Welt: Vorsicht vor schnellen Schlüssen und vermeintlicher Gewissheit.

Übungsaufgabe 7.1 🏆 Nennen Sie ein Beispiel, in dem ein Modell nicht (exakt) der Wirklichkeit entspricht! ☐


7.2.2 Der Golem von Prag



Abbildung 7.2: Der Golem von Prag

Der Golem von Prag, die Legende einer vom Menschen geschaffenen Kreatur mit gewaltiger Kraft, die Befehle wörtlich ausführt, s. Abbildung 7.2. Die Geschichte besagt, dass ein Rabbi mit Zauberkraften den Golem aus Lehm erschuf, um die jüdische Bevölkerung der Stadt zu schützen. Bei kluger Führung kann ein Golem Nützliches vollbringen. Bei unüberlegter Verwendung wird er jedoch großen Schaden anrichten.

7.2.3 Wissenschaftliche Modelle sind wie Golems



“Yeah, ich bin ein Golem!” - Bildquelle: Klara Schaumann

Golem

Eigenschaften des *Golems*:

- Besteht aus Lehm
- Belebt durch “Wahrheit”
- Mächtig
- dumm
- Führt Befehle wörtlich aus
- Missbrauch leicht möglich
- Märchen

Modell

Eigenschaften eines *Modells*:

- Besteht aus ~~Lehm~~ Silikon
- Belebt durch Wahrheit (?)
- Manchmal mächtig
- simpler als die Realität
- Führt Befehle wörtlich aus
- Missbrauch leicht möglich
- Nicht einmal falsch

Hinweis

Wir bauen Golems.

Abbildung 2.7 stellt ein Sinnbild von Modellen dar.

Vergleichen wir die kleine Welt unseres Modells (Tabelle 7.1), wie z.B. Behaims Globus, mit der Großen Welt, die Kolumbus und wir befahren.

Tabelle 7.1: Kleine Welt vs. große Welt

Kleine Welt	Große Welt
Die Welt, wie sie der Golem sieht	Die Welt, wie sie in Wirklichkeit ist
ist das Modell, aber nicht (zwangsläufig) die Wirklichkeit	entspricht nicht (zwangsläufig) dem Modell
Verwenden wir beim Modellieren	Ist das, was wir modellieren

Beispiel 7.1 (Die Bayes-Formel und Lernen) 🤖 Bayes-Inferenz ähnelt dem Lernen von Menschen. Geben Sie ein Beispiel von Lernen bei Menschen, das oben dargestelltem Prozess ähnelt! ☐

Beispiel 7.2 (Ein Regressionsmodell stammt aus der kleinen Welt) Ein wissenschaftliches Modell, etwa auf Basis eines Regressionsmodells ist Teil der *kleinen* Welt. Man muss sich bei der Interpretation eines Regressionsmodells vor Augen halten: “Die Ergebnisse des Modells sind nur richtig unter der Annahme, dass sich der Zusammenhang X und Y durch eine Gerade beschreiben lassen und unter der Annahme, dass meine Daten repräsentativ sind.” ☐

7.3 Ein erster Versuch: Wir werfen den Globus

7.3.1 Das Bayes-Update

Beispiel 7.3 (Wasseranteil auf der Erdoberfläche) Unsere Forschungsfrage lautet, mit welchem Anteil die Erde wohl mit Wasser bedeckt ist ([Abbildung 7.3](#))? Um möglichst wenig schreiben zu müssen, schreiben wir für “angenommener Wasseranteil auf der Erdoberfläche” kurz p oder π (p wie proportion, Anteil). ☐



Abbildung 7.3: Die Erde. Schön! Und mit viel Wasser, ca. 70% der Erdoberfläche sind mit Wasser bedeckt. [Quelle](#), Lizenz: CC 4.0 BY-NC

Analog können wir uns vorstellen, 11 Wissenschaftler haben jeweils eine andere Hypothese zum Wasseranteil, π , der Erde. Die erste Person hat die Hypothese $\pi_1 = 0$, die zweite Person geht von $\pi_2 = 0.1$ aus ... die 11. Person von $\pi_{11} = 1$.

Um die Forschungsfrage zu beantworten, werfen Sie einen Globus-Ball in die Luft und fangen ihn wieder auf. Sie notieren dann, ob die Stelle unter Ihrem Zeigefinger Wasser zeigt (W) oder Land (L). Den Versuch wiederholen Sie, bis Sie den Globusball insgesamt 9 Mal geworfen haben.²

So sah *mein*³ Ergebnis aus:

W L W W W L W L W

Also $W = 6$ (Wasser, d.h. “Treffer”) und $L = 3$ (Land, “Niete”) ($n = 9$ Versuche).

Übungsaufgabe 7.2 (Der Globusversuch) 🤖 Besorgen Sie sich einen Globus (zur Not eine Münze) und stellen Sie den Versuch nach! ☐

Beispiel 7.4 (Wir schießen Sonden ins Weltall) Eine alternative Geschichte für den Globusversuch: Es ist das Jahr 2345536. Sie arbeiten für eine Weltraumbehörde. Gestern haben Sie einen Planeten entdeckt, weit draußen im All. Jetzt geht es um die Frage, wie viel Wasser es auf der Oberfläche dieses Planeten gibt. Dazu schießen Sie (bzw. Ihre Behörde) eine Reihe von Sonden auf den Planeten. Wir gehen davon aus, dass die Landeplätze dieser Sonden voneinander unabhängig sind. Sagen wir, es werden $n = 9$ Sonden hochgeschossen, und davon landen $W = 6$ im Wasser. ☐

7.3.2 Bayes-Updates

Der Bayes-Golem denkt eigentlich ganz vernünftig: Zuerst (“Apriori”) hat er ein Vorwissen zum Wasseranteil, die dazugehörige Wahrscheinlichkeitsverteilung nennt man *Apriori-Verteilung* (s. [Definition 7.1](#)). In unserem Beispiel ist das Vorwissen recht bescheiden: Jeder Wasseranteil ist ihm gleich plausibel. Als nächstes beschaut sich der Golem die Daten und überlegt, wie wahrscheinlich die Daten sind, wenn man von einer bestimmten Hypothese ausgeht, z.B. dass der Wasseranteil 50% beträgt. Die zugehörige Wahrscheinlichkeit der Daten unter Annahme einer Hypothese nennt man die⁴ *Likelihood*⁵, s. [Definition 7.2](#). Als Letztes bildet sich der Golem eine abschließende Meinung zur Wahrscheinlichkeit jeder Hypothese. Diese Wahrscheinlichkeitsverteilung nennt man *Aposteriori-Verteilung*, s. [Definition 7.3](#). Sie berechnet sich als Gewichtung des Vorwissens mit den neuen Daten, die durch die Likelihood repräsentiert werden. Anders gesagt: Das Vorwissen wird anhand der Erkenntnisse (der Daten) aktualisiert: das Bayes-Update, s. [Abbildung 7.4](#).



Abbildung 7.4: Updating mit Bayes

Definition 7.1 (Apriori-Verteilung) Für jede Hypothese haben wir ein Vorab-Wissen, das die jeweilige Plausibilität der Hypothese angibt: *Apriori-Verteilung*⁶. □

Definition 7.2 (Likelihood) Für jede Hypothese (d.h. jeden *Parameterwert* π) möchten wir wissen, wie wahrscheinlich die Daten sind (unter der Annahme, dass die Hypothese richtig ist). Anders gesagt: Die *Likelihood* sagt uns, wie gut die Daten zu einer bestimmten Hypothese passen. □

Definition 7.3 (Aposteriori-Verteilung) Dann gewichten wir den Likelihood mit dem Vorabwissen, so dass wir die *Aposteriori-Verteilung*⁷ (kurz: “Post-Verteilung”) bekommen. Sie quantifiziert unser Wissen zu den Parameterwerten *nach* Kenntnis der Daten und aufbauend auf unserem Vorwissen. Man bezeichnet sie kurz mit $Pr(H|D)$, lies: “Die Wahrscheinlichkeit der Hypothese H gegeben der Daten D .” □

Übungsaufgabe 7.3 (Wie gut passen die Daten zur Hypothese, dass die Erde komplett trocken ist?) Wir haben in unseren Versuch $W = 6$ und $L = 3$ erzielt. Diese Daten passen *überhaupt nicht* zur Hypothese, dass die Erdoberfläche komplett trocken ist. Die *Likelihood*, L für $\pi = 0$ ist also Null. Analog ist die Likelihood für $\pi = 1$ auch Null. □

7.3.3 Berechnung der Likelihood im Globusversuch

Wie wahrscheinlich ist es, ein bestimmtes Ergebnis, z.B. $W = 6$ Treffer (bei 9 Würfeln), zu erhalten, wenn man eine bestimmte Hypothese (einen bestimmten Wasseranteil, z.B. 90%) annimmt? Diese Wahrscheinlichkeit nennt man die *Likelihood*, $L = Pr(W = 6, n = 9 | \pi = .9)$.

Wenn wir eine Binomialverteilung für die Globuswürfe annehmen, dann gehen wir davon aus, dass die Daten unabhängig voneinander entstehen und sich der Parameterwert nicht zwischenzeitlich ändert.⁸ Der Wasseranteil der Erde bleibt während des Versuchs gleich (durchaus plausibel).

Berechnen wir also die Likelihood für verschiedene Hypothesen (Wasseranteile, π), für $\pi = 0, 0.1, 0.2, \dots, 1$, s. [Listing 7.1](#). Wir halten also die Daten fest (6 Treffer bei 9 Würfeln) und berechnen die Wahrscheinlichkeit dieser Daten für verschiedene Hypothesen (Wasseranteile, π).

Listing 7.1: Likelihood-Funktion für $x=6$ Treffer, bei $n=9$ Würfeln, für eine binomialverteilte Zufallsvariable: Wir halten die Daten fest und variieren den Parameterwert.


```
dbinom(x = 6, size = 9, prob = .1)
dbinom(x = 6, size = 9, prob = .2)
dbinom(x = 6, size = 9, prob = .3)
dbinom(x = 6, size = 9, prob = .4)
dbinom(x = 6, size = 9, prob = .5)
dbinom(x = 6, size = 9, prob = .6)
dbinom(x = 6, size = 9, prob = .7)
dbinom(x = 6, size = 9, prob = .8)
dbinom(x = 6, size = 9, prob = .9)
## [1] 6.1e-05
## [1] 0.0028
## [1] 0.021
## [1] 0.074
## [1] 0.16
## [1] 0.25
## [1] 0.27
## [1] 0.18
## [1] 0.045
```

[Abbildung 7.5](#) visualisiert die Likelihood-Funktion für unser Beispiel (6 Wasser bei 9 Würfeln) für verschiedene Hypothesen (Wasseranteile, π). Man sieht, dass die Likelihood um $\pi = 0.7$ herum am höchsten ist.




Abbildung 7.5: Die Likelihood-Funktion für $x=6$ Treffer, bei $n=9$ Würfeln, für eine binomialverteilte Zufallsvariable (mit 11 Parameterwerten: 0, 0.1, 0.2, ..., 1): Die Parameterwerte um 0.7 herum sind am plausibelsten.

Oder von Hand gerechnet für $\pi = 1/2$, s. [Gleichung 7.1](#):

$$\begin{aligned}
 Pr(\pi = 1/2 | x = 6, n = 9) &= \\
 &= \binom{9}{6} \cdot (1/2)^6 \cdot (1/2)^3 = \\
 &= \frac{9!}{6!3!} \cdot (1/2)^9 = \\
 &= 84 \cdot 1/512 = 21/128 = 0.16
 \end{aligned}
 \tag{7.1}$$

Mithilfe von R als Taschenrechner gerechnet:

```
anz_pfade <- choose(9, 6)
wskt_pro_pfad <- (1/2)^6 * (1/2)^3
gesamt_wskt <- anz_pfade * wskt_pro_pfad
gesamt_wskt
## [1] 0.16
```

Für so viele Würfe ($n = 9$) würde ein Baumdiagramm unübersichtlich werden, s. [Abbildung 7.6](#). Visualisierungen wie Baumdiagramme sind eine praktische Hilfe zum Verständnis, kommen aber bei größeren Daten schnell an ihre Grenze.




Abbildung 7.6: Wir werfen den Globus (oder eine Münze) 9 Mal, es resultieren 512 Endknoten. Nicht gerade übersichtlich.

Jetzt folgen einige Beispiele.

Beispiel 7.5 (Likelihood für $W = 6, n = 9, \pi = .7$) Was ist die Likelihood von $W = 6$ bei $n = 9$ gegeben $\pi = .7$ bei unserem Globusversuch?

```
dbinom(x = 6, size = 9, prob = .7)
## [1] 0.27
```

Oder, synonym, wenn man einen Taschenrechner (oder R als Taschenrechner) benutzt:

```
choose(9, 6) * (.7)^6 * (.3)^3
## [1] 0.27
```

Noch “händischer” gerechnet:

```
factorial(9)/(factorial(6)*factorial(3)) * (.7)^6 * (.3)^3
## [1] 0.27
```

Die Daten passen gut zur Hypothese $\pi = .7$. $\square$

Zur Erinnerung: Die Funktion `dbinom` gibt uns die Wahrscheinlichkeit von `x` Treffern, bei `size` Versuchen zurück, wobei eine Binomialverteilung angenommen wird mit der Trefferwahrscheinlichkeit `prob`.

Beispiel 7.6 (Likelihood für $W = 6, n = 9, \pi = 1/3$) Was ist die Likelihood von $W = 6$ bei $n = 9$ gegeben $\pi = 1/3$ bei unserem Globusversuch?

```
dbinom(x = 6, size = 9, prob = 1/3)
## [1] 0.034
```

Offenbar ist $\pi = 1/3$ eine schlechte Hypothese, um die Daten zu erklären: Die Daten passen nicht gut zu ihr. $\square$

Beispiel 7.7 (Likelihood für $\pi = 0$) Was ist die Likelihood von $W = 6$ bei $n = 9$ gegeben $\pi = 0$ bei unserem Globusversuch?

```
dbinom(x = 6, size = 9, prob = 0)
## [1] 0
```

$\pi = 0$ ist offenbar eine sehr schlechte Hypothese, um die Daten zu erklären: Die Daten sind unmöglich unter dieser Hypothese. $\square$

(Fast) von Hand gerechnet:

```
factorial(9)/(factorial(6)*factorial(3)) * (.7)^6 * (.3)^3
## [1] 0.27
```

Als Formel, s. [Gleichung 7.2](#):

$$\begin{aligned} Pr(W = 6 | \pi = .7, n = 9) &= \\ \binom{9}{6} \cdot (.7)^6 \cdot (.3)^3 &= \\ \frac{9!}{6!3!} \cdot (.7)^6 \cdot (.3)^3 &= \\ 84 \cdot .003 &= .27. \end{aligned} \tag{7.2}$$

$\square$

Es gibt Taschenrechner(-Apps), die die Binomialverteilung oder den Binomialkoeffizienten berechnen können.⁹

Übungsaufgabe 7.4 (Peer Instruction: Welcher Parameterwert ist am plausibelsten?) Wir führen wieder den Globusversuch durch (oder werfen eine Münze) und erhalten folgendes Ergebnis: 7 Mal Wasser und 2 Mal Land (also $W = 7$ und $L = 2$).

Welcher Wasseranteil, π ist am plausibelsten?

- A. 0 Wasser (0%)
- B. 1/9 Wasser (ca. 11%)
- C. 3/9 Wasser (ca. 33%)
- D. 7/9 Wasser (ca. 78%)
- E. 9 Wasser (100%) $\square$

7.3.4 Unser Modell ist geboren

Ein Modell (in der Bayes-Statistik) besteht aus mind. drei Komponenten:

1. Die *Likelihood* (die Wahrscheinlichkeit der Daten unter Annahme der Hypothese), s. [Gleichung 7.1](#)
2. Die *Apriori-Verteilung(en)* (die Wahrscheinlichkeit der Hypothese vor den Daten), s. [Gleichung 7.3](#)
3. Die *Aposteriori-Verteilung* (die Wahrscheinlichkeit der Hypothese nach den Daten), s. [Abbildung 7.10](#)

7.3.5 Apriori-Verteilung

Unser Vorab- bzw. *Apriori*-Wissen zu π sei, dass uns alle Werte gleich (“uniform”) plausibel erscheinen, s. [Gleichung 7.3](#).

$$\pi \sim \text{Unif}(0, 1). \quad (7.3)$$

Lies: “ π ist gleich (uniform) verteilt mit der Untergrenze 0 und der Obergrenze 1”.

Man könnte auch sagen: Wir haben praktisch kein Vorwissen, wir sind erstmal (apriori) indifferent; jeder Parameterwert erscheint uns erstmal gleich wahrscheinlich, s. [Abbildung 7.7](#).




Abbildung 7.7: Gleichverteilung mit Parametern min=0 und max=1

7.3.6 Aposteriori-Verteilung

Wie in [Definition 7.3](#) eingeführt, quantifiziert die Aposteriori-Verteilung (kurz: “Post-Verteilung”) unser Wissen zu den Parameterwerten *nach* Kenntnis der Daten und aufbauend auf unserem Vorwissen (Apriori-Wissen). Sie ist das Ergebnis des Bayes-Updates; man bezeichnet sie kurz mit $Pr(H|D)$. Lies: “Die Wahrscheinlichkeit der Hypothese H gegeben der Daten D .”

Dabei nimmt man stillschweigend an, dass die Daten anhand eines gewissen Modells generiert wurden, z.B. der Binomialverteilung, sodass die Likelihood $Pr(D|H)$ berechnet werden kann. [Abbildung 7.10](#) zeigt die Post-Verteilung für unser Globusbeispiel (6 Wasser bei 9 Würfeln).

7.4 Bayes’ Theorem

7.4.1 Wozu wird Bayes in der Praxis genutzt?

In der Praxis nutzt man Bayes häufig, wenn man Daten D gesammelt hat, und wissen möchte, wie wahrscheinlich eine Hypothese H ist, im Lichte dieser gesammelten Daten, s. [Theorem 7.1](#). Anders gesagt: Die Likelihood ist relativ einfach zu bestimmen, $Pr(D|H)$, aber nicht so interessant. Die Aposteriori-Wahrscheinlichkeit, $Pr(H|D)$, ist schwerer zu bestimmen, aber interessanter. Man könnte also sinnbildlich

sagen, das Bayes-Theorem ist eine “Maschine”, die die Apriori-Wahrscheinlichkeit zusammen mit der Likelihood zur Aposteriori-Wahrscheinlichkeit “umbaut”.

$$Pr(H|D) = \frac{Pr(H) \cdot Pr(D|H)}{Pr(D)} \quad (7.4)$$

Theorem 7.1 (Bayes’ Theorem)

$$Pr(H|D) = \frac{Pr(H) \cdot Pr(D|H)}{Pr(D)} = \frac{\text{Apriori} \cdot \text{Likelihood}}{\text{Evidenz}} \quad \square$$

Bayes’ Theorem ([Theorem 7.1](#)) fragt nach $Pr(H|D)$:

Was ist die Wahrscheinlichkeit der Hypothese H , jetzt wo wir die Daten kennen?

Und antwortet so ([Gleichung 7.4](#)):

Diese Wahrscheinlichkeit entspricht der Apriori-Wahrscheinlichkeit der Hypothese mal der Plausibilität (Likelihood) der Daten unter Annahme (gegeben) der Hypothese. Aus Standardisierungsgründen dividiert man noch die totale Wahrscheinlichkeit der Daten über alle Hypothesen (durch die sog. *Evidenz*).

Für unser Globusbeispiel:

Wie wahrscheinlich ist denn jetzt ein bestimmter Wasseranteil auf der Erde, π , (gegeben den Daten, $W = 6$ und $L = 3$) und wenn wir jede Hypothese apriori für gleich wahrscheinlich halten? Also, wie wahrscheinlich ist z.B. ein Wasseranteil von 70% oder von 50%?

7.4.2 Die Evidenz zur Standardisierung

Die Aufgabe der Evidenz ist nur dafür zu sorgen, dass der Wert von $Pr(H|D)$ insgesamt nur Werte zwischen 0 und 1 annehmen kann, also eine brave, normale Wahrscheinlichkeit ist. Würde man in [Theorem 7.1](#) nicht durch die Evidenz teilen, so wäre die Aposteriori-Wahrscheinlichkeit nicht normiert, d.h. sie könnte Werte >1 annehmen, was ja nicht sein darf.

Definition 7.4 (Evidenz) $Pr(D)$ nennt man die *Evidenz*.

Die Evidenz berechnet sich als Summe der Likelihoods für alle Parameterwerte H_i , d.h. als die totale Wahrscheinlichkeit von D , s. [Theorem 7.2](#), vgl. [Definition 5.8](#). $\square$

Theorem 7.2 (Evidenz)

$$Pr(D) = \sum_{i=1}^n Pr(D|H_i) \cdot Pr(H_i) \quad \square$$

Die verschiedenen Parameterwerte kann man auch als die verschiedenen Hypothesen H_i auffassen. Falls es nur zwei Hypothesen bzw. Parameterwerte gibt, vereinfacht sich [Theorem 7.2](#) zu [Theorem 7.3](#).

Theorem 7.3 (Evidenz bei zwei Hypothesen)

$$Pr(D) = Pr(D|H_1) \cdot Pr(H_1) + Pr(D|H_2) \cdot Pr(H_2) \quad \square$$

Beispiel 7.8 In [Beispiel 7.10](#) betrug der Wert der Evidenz $0.03 + 0.002 + 0.012 = 0.044$, also ca. 4%. $\square$

Schauen wir uns die Bestandteile von Bayes' Theorem ([Theorem 7.1](#)) noch etwas näher an:

- (standardisierte) Aposteriori-Wahrscheinlichkeit: $Pr_{Post} := Pr(H|D)$
- Likelihood: $L := Pr(D|H)$
- Apriori-Wahrscheinlichkeit: $Pr_{Apriori} := Pr(H)$
- Evidenz: $E := Pr(D)$
- unstandardisierte Aposteriori-Wahrscheinlichkeit: $Pr_{unPost} = Pr_{Apriori} \cdot L$

Bayes' Theorem gibt die Pr_{Post} an, wenn man die Gleichung mit der $Pr_{Apriori}$ und dem L füttert. Bayes' Theorem wird verwendet, um die Pr_{Post} zu quantifizieren. Die Pr_{Post} ist proportional zu $Pr_{unPost} = L \times Pr_{Apriori}$.

7.4.3 Posteriori als Produkt von Priori und Likelihood

Die *unstandardisierte* Post-Wahrscheinlichkeit Pr_{unPost} ist einfach das Produkt von Likelihood und Priori, s. [Gleichung 7.5](#).

$$Pr_{unPost} = L \times \text{Priori} \quad (7.5)$$

Abb. [Abbildung 7.8](#) visualisiert, dass die Post-Verteilung eine Gewichtung von Apriori und Likelihood ist (das gilt sowohl für die unstandardisierte als auch für die standardisierte Post-Verteilung). Mathematisch gesprochen beruht diese Gewichtung auf einer einfachen Multiplikation der beiden genannten Terme.




Abbildung 7.8: Prior mal Likelihood = Post

Standardisiert man die unstandardisierte Post-Verteilung, so erhält man die standardisierte Post-Verteilung. Das Standardisieren dient nur dazu, einen Wert zwischen 0 und 1 zu erhalten. Dies erreichen wir, indem wir durch die Summe aller Post-Wahrscheinlichkeiten dividieren. Die Summe der Post-Wahrscheinlichkeiten bezeichnet man (auch) als Evidenz, vgl. Gleichung [Gleichung 7.6](#).

$$\text{Posteriori} = \frac{\text{Likelihood} \times \text{Priori}}{\text{Evidenz}} \quad (7.6)$$

7.4.4 Wissen updaten: Wir füttern Daten in das Modell

Golems können lernen?! [Abbildung 7.9](#) zeigt die Post-Verteilung, nach $n = 1, 2, \dots, n = 9$ Datenpunkten, d.h. Würfeln mit dem Globusball. Man sieht: Am Anfang, apriori, also bevor wir die Daten kennen, vor dem ersten Wurf also, ist jeder Parameterwert gleich wahrscheinlich für den Golem (das Modell). Je nach Ergebnis des Wurfes verändert sich die Wahrscheinlichkeit der Parameterwerte, kurz gesagt, die Post-Verteilung verändert sich in Abhängigkeit von den Daten.




Abbildung 7.9: Unser Golem lernt

Insofern kann man sagen: Unser Golem (das Modell) lernt. Ob das Modell nützlich ist (präzise Vorhersagen liefert), steht auf einem anderen Blatt.

7.5 Die Post berechnen mit der Bayesbox

Wir erstellen uns eine kleine Tabelle, die man “Bayesbox” nennen könnte.¹⁰ Unser Ziel ist es, die Posteriori-Wahrscheinlichkeit für verschiedene Parameterwerte zu berechnen, also die Wahrscheinlichkeit, dass ein bestimmter Wasseranteil π vorliegt, gegeben die Daten (6 Wasser bei 9 Würfeln). Dazu gehen wir so vor:

7.5.1 Die Idee der Bayesbox

1. Teile den Wertebereich des Parameters in ein “Gitter” auf, z.B. 0.1, 0.2, $\dots$, 0.9, 1.

2. Wähle die Apriori-Wahrscheinlichkeit für jeden Parameterwert, z.B. $1/11$ bei einer diskreten Gleichverteilung von 0 bis 1.
3. Berechne die Likelihood für jeden Parameterwert.
4. Berechne den unstandardisierten Aposteriori-Wert für jeden Parameterwert (Produkt von Apriori und Likelihood).
5. Standardisiere den Aposteriori-Wert durch Teilen anhand der Summe aller unstandardisierten Aposteriori-Wahrscheinlichkeiten.

Für jeden Parameterwert berechnen wir eine (Post-)Wahrscheinlichkeit.¹¹ Häufig entspricht eine Hypothese einem Parameterwert, etwa wenn man sagt: “Ich glaube, die Münze ist fair”, was auf einen Parameterwert von 50% herausläuft. Dazu geben wir an, für wie wahrscheinlich wir apriori¹² – also bevor wir irgendwelche Daten erheben – jeden einzelnen Parameterwert halten. Wir machen es uns hier einfach und halten jeden Parameterwert für gleich wahrscheinlich.

Tatsächlich ist der konkrete Wert hier egal, solange wir allen Parameterwerten denselben Wert geben, wird sich die standardisierte Aposteriori-Wahrscheinlichkeit nicht ändern.

Entscheidend ist das Verhältnis der Apriori-Werte zueinander: Geben wir einem Parameterwerten den Wert 2, aber einem anderen den Wert 1, so halten wir Ersteren für (apriori) doppelt so plausibel wie Letztere. Die Post-Wahrscheinlichkeit für den Ersteren wird dann auch doppelt so groß sein wie die für Letztere (alles andere konstant gehalten).

Die “End-Wahrscheinlichkeit”, die unstandardisierte Post-Wahrscheinlichkeit, die “hinten rauskommt” ist das Produkt von Apriori-Wert und Likelihood. Anschaulich gesprochen: Die Apriori-Werte werden mit den Likelihoodwerten gewichtet¹³. Da wir letztlich eine Wahrscheinlichkeitsverteilung bekommen möchten, teilen wir jeden Aposteriori-Wert durch die Summe aller Aposteriori-Werte. Dadurch ist garantiert, dass sich die Aposteriori-Werte zu eins aufaddieren. Damit haben wir dann die Ansprüche an eine Wahrscheinlichkeitsverteilung erfüllt (vgl. [Kapitel 4.3.3](#)).

7.5.2 Bayesbox in R berechnen

Legen wir uns ein Gitter mit Parameterwerten (π) an, um deren Aposteriori-Wahrscheinlichkeit zu berechnen. Konkret gesprochen: Wir listen jeden für uns interessanten Wasseranteil (π) auf, also $\pi = 0, 0.1, 0.2, \dots, 1$. Diese Parameterwerte sind die Hypothesen, die wir testen wollen, s. [Listing 7.2](#).

Listing 7.2: Parameterwerte (Gitter) für Wasseranteile: 0, 0.1, 0.2, ..., 1

```
wasseranteile <- seq(from = 0, to = 1, by = 0.1) # Parameterwerte
wasseranteile
## [1] 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
```

Dann berechnen wir schon mal die Wahrscheinlichkeit der Daten (6 W bei 9 Würfeln) gegeben jeweils eines Wasseranteils.

```
Likelihood <- dbinom(6, size = 9, prob = wasseranteile)
Likelihood
## [1] 0.0e+00 6.1e-05 2.8e-03 2.1e-02 7.4e-02 1.6e-01 2.5e-01 2.7e-01 1.8e-01
## [10] 4.5e-02 0.0e+00
```

Schließlich packen wir das alles in eine Tabelle, die “Bayesbox”, s. [Tabelle 7.2](#) und [Listing 7.3](#).

```

bayesbox_globusversuch <-
  tibble(
    # definiere die Hypothesen (die Parameterwerte, p):
    p = wasseranteile,
    # Lege den Apriori-Wert für alle Parameterwerte auf 1/11 fest:
    Apriori = 1/11) |>
  mutate(
    # berechne Likelihood für jeden Wasseranteil (Parameterwert):
    Likelihood = Likelihood,
    # berechne unstand. Aposteriori-Werte:
    unstd_Post = Likelihood * Apriori,
    # berechne Evidenz, d.i. die Summe aller unstand. Post-Werte:
    Evidenz = sum(unstd_Post),
    # berechne stand. Aposteriori-Werte (summiert zu 1):
    Post = unstd_Post / Evidenz)

```

Die Bayesbox ([Tabelle 7.2](#)) zeigt, wie sich die Post-Verteilung berechnet.

Tabelle 7.2: Die Bayesbox für den Globusversuch, k=6 Treffer, n=9 Versuche, Apriori-Wahrscheinlichkeit $Pr(H)=9\%$, und Wasseranteile p von 0 bis 1

id	p	Apriori	Likelihood	unstd_Post	Evidenz	Post
1	0.0	0.091	0.000	0.000	0.091	0.000
2	0.1	0.091	0.000	0.000	0.091	0.000
3	0.2	0.091	0.003	0.000	0.091	0.003
4	0.3	0.091	0.021	0.002	0.091	0.021
5	0.4	0.091	0.074	0.007	0.091	0.074
6	0.5	0.091	0.164	0.015	0.091	0.164
7	0.6	0.091	0.251	0.023	0.091	0.251
8	0.7	0.091	0.267	0.024	0.091	0.267
9	0.8	0.091	0.176	0.016	0.091	0.176
10	0.9	0.091	0.045	0.004	0.091	0.045
11	1.0	0.091	0.000	0.000	0.091	0.000

Für jede Hypothese (Spalte **id**) berechnen wir die *unstandardisierte* Aposteriori-Wahrscheinlichkeit als Produkt von Apriori und Likelihood.

Um zur *standardisierten* Aposteriori-Wahrscheinlichkeit zu gelangen, teilen wir in jeder Zeile der Bayesbox (also für jede Hypothese) die unstandardisierte Post-Wahrscheinlichkeit durch die Summe der unstandardisierten Post-Wahrscheinlichkeiten, s. [Gleichung 7.7](#).

$$\text{Post} = \frac{\text{Post}_{\text{unstand}}}{\text{Evidenz}} = \frac{Pr(H) \cdot Pr(H|D)}{Pr(D)} \quad (7.7)$$

Dabei haben wir die Apriori-Wahrscheinlichkeit für alle Parameterwerte als gleich angenommen, da wir keinerlei Vorwissen hatten, $Pr(H_i) = 1/11$. Die Evidenz berechnet sich als Summe der unstandardisierten

Post-Wahrscheinlichkeiten, $Pr(D) = \sum Pr_{unstandPost} = 0.09$.

Wenn die Apriori-Wahrscheinlichkeit für alle Hypothesen gleich ist, dann ist die standardisierte Aposteriori-Wahrscheinlichkeit identisch mit der Likelihood. Denn die Post-Wahrscheinlichkeit ist die um die Priori-Wahrscheinlichkeit gewichtete Likelihood. Sind die Apriori-Wahrscheinlichkeiten alle gleich, so ist die Gewichtung der Likelihood für alle Hypothesen gleich.

Beispiel 7.9 (Post-Wahrscheinlichkeit im Globusversuch für $p=.7$) In [Beispiel 7.5](#) haben wir die Wahrscheinlichkeit für 6 Treffer bei 9 Würfeln gegeben einer Trefferwahrscheinlichkeit von $\pi = .7$ berechnet. Damit haben wir die Likelihood $L = Pr(D|H) = .27$ berechnet.

Auf dieser Basis können wir die Aposteriori-Wahrscheinlichkeit Pr_{Post} berechnen, zunächst die unstandardisierte. Dazu haben wir die Apriori-Wahrscheinlichkeit mit der Likelihood multipliziert, s.

[Gleichung 7.8](#):

$$Post_{unstand} = Pr(H) \cdot Pr(D|H) = 1/11 \cdot 0.2668 = 0.024 \quad (7.8)$$

Jetzt standardisieren wir die unstandardisierte Post-Wahrscheinlichkeit, indem wir durch die Evidenz dividieren, s. [Gleichung 7.9](#).

$$Post = \frac{Post_{unstand}}{Evidenz} = \frac{0.024}{0.09} = 0.267 \quad (7.9)$$

Fazit: Nach dem Versuch, d.h. nachdem wir die Daten in Betracht gezogen haben, hat sich unsere Meinung über den Wasseranteil von $\pi = .7$ aktualisiert von 0.09 auf 0.27 – das ist eine Verdreifachung. Wir sind uns drei Mal so sicher wie vor dem Versuch, dass der Wasseranteil bei 70% liegt. $\square$

Übungsaufgabe 7.5 🤖 Was wohl mit *Post* passiert, wenn wir *Apriori* ändern? $\square$

[Abbildung 7.10](#) zeigt eine Visualisierung der Post-Verteilung mit Hilfe der Funktion `ggline(x, y)` aus dem Paket `ggpubr`. Wie man sieht, ist die Post-Wahrscheinlichkeit am höchsten bei $\pi = 0.7$. Wobei der Bereich von 0.6 bis 0.8 auch recht wahrscheinlich ist.




Abbildung 7.10: Die Post-Verteilung visualisiert. Die Post-Wahrscheinlichkeit ist am höchsten bei $p=0.7$

7.5.3 Was sagt die Post?


Die Aposteriori-Verteilung (Kurz: “Post-Verteilung”, oder “Post”), Pr_{Post} , sagt, wie plausibel wir jeden Wert von p halten, jetzt, nachdem wir die Daten des Versuchs kennen. Die Post-Wahrscheinlichkeit updatet unser Apriori-Wissen mit dem Wissen, das wir durch die Daten erhalten haben.

[Abbildung 7.11](#) zeigt die Post-Wahrscheinlichkeit für 5, 10 und 20 Parameterwerte. Das mittlere Teilbild mit 10 Parameterwerten entspricht unserer Tabelle oben. Man sieht: Je mehr Parameterwerte, desto “glatter” wird die Verteilung.

Posterior-Verteilung bei unterschiedlicher Gitterfeinheit


6 Erfolge bei 9 Versuchen, uniforme Prior-Verteilung

Unendlich viele Parameterwerte




pi

10 Parameterwerte




pi

5 Parameterwerte



pi

20 Parameterwerte



pi

Abbildung 7.11: Die Post-Verteilung zunehmend mehr Parameterwerte in der Bayesbox. Je mehr Parameterwerte, desto ‘glatter’ wird die Verteilung.

Die Post-Verteilung ist sowas wie das Ziel all Ihrer Träume (falls Sie es noch nicht gewusst haben): Aus der Post-Verteilung können Sie ablesen, wie wahrscheinlich Ihre Hypothese (Ihr Lieblings-Parameterwert) ist. Und noch einiges mehr, aber das ist Thema des nächsten Kapitels. □

Übungsaufgabe 7.6 (Peer Instruction: Schlüsse ziehen mit dem Bayes-Modell) Auf einer Party: Unterhalten sich fünf Studis über das Bayesmodell. Einer hat Unrecht, die anderen Recht. Aber wer?

- A. Wenn eine Hypothese A apriori doppelt so wahrscheinlich ist wie die anderen und die Likelihoods für alle Hypothesen gleich ist, dann ist A aposteriori auch doppelt so wahrscheinlich wie die anderen Hypothesen.
- B. Sind alle Hypothesen apriori gleich wahrscheinlich, dann hat die Hypothese mit dem höchsten Likelihood aposteriori auch die höchste Post-Wahrscheinlichkeit.

- C. Hat eine Hypothese apriori die Wahrscheinlichkeit Null, so hat sie automatisch aposteriori auch die Wahrscheinlichkeit Null, unabhängig von ihrer Likelihood.
- D. Die unstandardisierte Aposteriori-Wahrscheinlichkeit ist gleich der standardisierten mal einen Faktor k .
- E. Hat eine Hypothese die höchste Likelihood, so hat sie automatisch auch die höchste Wahrscheinlichkeit aposteriori. ☐

7.6 Abschluss

7.6.1 Zusammenfassung

[Übung zum Globusversuch](#)

- In unserem Modell haben wir Annahmen zu Pr_{Priori} und L getroffen.
- Auf dieser Basis hat der Golem sein Wissen geupdated zu Pr_{Post} .
- Mit der Bayesbox haben wir viele Hypothesen (Parameterwerte) untersucht und jeweils die Pr_{Post} berechnet.
- Unser Modell bildet die kleine Welt ab; ob es in der großen Welt nützlich ist, steht auf einem anderen Blatt.

Tipp

 Wenn Sie auf einen Prozentwert für W tippen müssten, welchen würden Sie nehmen, laut dem Modell (und gegeben der Daten)? ☐

7.6.2 Der Globusversuch als Modell für zweiwertige Zufallsversuche

Der Globusversuch ist kein prototypisches Beispiel für Statistik in der Praxis, zumindest nicht auf den ersten Blick. Er hat aber den Vorteil, dass es ein einfaches, gut greifbares Beispiel ist, und damit zum Lernen gut geeignet ist. Bei näherer Betrachtung ist der Globusversuch prototypisch für ganz viele Fragestellungen:

- Von einem neuen Produkt wurden von n Exemplaren k verkauft. Auf welchen Wert p kann die Akzeptanzrate dieses Produkts geschätzt werden?
- Ein Chat-Bot hat von n Fragen k richtig beantwortet. Wie hoch kann die Verständnisrate p dieses Programms geschätzt werden?
- Eine neue Krebstherapie hat von n "austherapierten" Patientis k geheilt. Auf wie hoch kann die Erfolgsrate dieser Therapie geschätzt werden?

Kurz: Der Globusversuch ist ein Muster für zweiwertige Zufallsversuche. Und solche sind häufig im Leben, im Business und in der Wissenschaft.

7.7 Vertiefung

7.7.1 Bayes-Video von 3b1b

Das "[Bayes-Paradox-Video](#)" von 3b1b präsentiert eine gut verständliche Darstellung des Bayes-Theorems aus einer zwar nicht gleichen, aber ähnlichen Darstellung wie in diesem Kapitel.

7.7.2 Bayes als Baum

Bayes' Theorem kann man sich als Baumdiagramm vor Augen führen, [Abbildung 7.12](#).

Gesucht sei $Pr(M_1|A)$, also: die Wahrscheinlichkeit, dass das Teil von Maschine 1 produziert wurde, gegeben, dass es Ausschuss ist. Gegeben sind die Wahrscheinlichkeiten, dass Maschine i das Teil produziert hat, $Pr(M_i)$. Außerdem sind die Wahrscheinlichkeiten, dass das Teil Ausschuss ist, $Pr(A|M_i)$, bekannt.

Das Diagramm löst die Aufgabe für uns; es zeigt damit die Anwendung von Bayes' Theorem auf.

Um $Pr(M_1|A)$ zu erhalten, setzt man die Wahrscheinlichkeit des *günstigen* Asts ins Verhältnis zur Wahrscheinlichkeit *aller relevanten* Äste, $Pr(A)$.

Beispiel 7.10 (Maschine produziert Ausschuss) Die drei Maschinen M_1, M_2, M_3 produzieren den gleichen Artikel. Ihr jeweiliger Anteil an der Produktion liegt bei 60%, 10% bzw. 30%. Die jeweilige Ausschussquote liegt bei 5, 2, bzw. 4%, s. [Abbildung 7.12](#).

Aufgabe: Wie groß ist die Wahrscheinlichkeit, dass ein defektes Teil von Maschine 1 produziert wurde? Berechnen Sie diese Wahrscheinlichkeit. ☐

Der günstige (gesuchte) Ast, $Pr(M_1 \cap A)$, ist hier fett gedruckt, s. [Abbildung 7.12](#). In [Abbildung 7.12](#) zeigen die runden Kästchen am Ende der Pfade die Wahrscheinlichkeiten des jeweiligen Pfades an.




Abbildung 7.12: Günstige Pfade

$$Pr(M_1|A) = \frac{Pr(M_1 \cap A)}{Pr(A)} = \frac{0.6 \cdot 0.05}{0.03 + 0.002 + 0.012} = \frac{0.03}{0.044} \approx 0.68$$

$Pr(M_1|A)$ beträgt also ca. 68%.

Zur Erinnerung: $Pr(A)$ ist die totale Wahrscheinlichkeit (dass ein produziertes Teil Ausschuss ist).

7.7.3 Bayes als bedingte Wahrscheinlichkeit

Bayes' Theorem wird verwendet, um die *Wahrscheinlichkeit* einer *Hypothese*, *gegeben einer bestimmten Datenlage* und basierend auf einer *Apriori-Wahrscheinlichkeit* dieser *Hypothese* zu berechnen. Man berechnet also $Pr(H|D)$. Bayes' Theorem ist nichts anderes als eine normale bedingte Wahrscheinlichkeit.

$Pr(H|D)$ kann man umformen (vgl. [Theorem 5.3](#) und [Definition 5.6](#)), dann erhält man Bayes' Theorem, s. [Theorem 7.4](#).

Theorem 7.4 (Bayes' Theorem als bedingte Wahrscheinlichkeit)

$$\begin{aligned} Pr(H|D) &= \frac{\overbrace{Pr(H \cap D)}^{\text{umformen}}}{Pr(D)} \\ &= \frac{\underbrace{Pr(H)}_{\text{Apriori-Wahrscheinlichkeit}} \cdot \underbrace{Pr(D|H)}_{\text{Likelihood}}}{\underbrace{Pr(D)}_{\text{Evidenz}}} \quad \square \end{aligned}$$

7.7.4 Weitere Herleitung der Bayes-Formel

Man kann sich Bayes' Theorem auch wie folgt herleiten:

$$Pr(D \cap H) = Pr(H \cap D) = Pr(D) \cdot Pr(H|D) = Pr(H) \cdot Pr(D|H)$$

Dann lösen wir nach $Pr(H|D)$ auf, s. [Gleichung 7.10](#).

$$Pr(H|D) = \frac{\underbrace{Pr(H)}_{\text{Apriori-Wahrscheinlichkeit}} \cdot \underbrace{Pr(D|H)}_{\text{Likelihood}}}{\underbrace{Pr(D)}_{\text{Evidenz}}} \quad (7.10)$$

7.7.5 Zusammengesetzte Hypothesen

Das ist vielleicht ein bisschen fancy, aber man kann Bayes' Theorem auch nutzen, um die Wahrscheinlichkeit einer *zusammengesetzten Hypothese* zu berechnen: $H = H_1 \cap H_2$. Ein Beispiel wäre: "Was ist die Wahrscheinlichkeit, dass es Regen (R) und Blitzeis (B) gibt, wenn es kalt (K) ist?".

Das sieht dann so aus, [Gleichung 7.11](#):

$$\begin{aligned} Pr(R \cap B|K) &= \frac{Pr(R \cap B) \cdot Pr(K|R \cap B)}{Pr(D)} \\ &= \frac{Pr(R) \cdot Pr(B) \cdot Pr(K|R \cap B)}{Pr(D)} \end{aligned} \quad (7.11)$$

Hier haben wir $Pr(R \cap B)$ aufgelöst in $Pr(R) \cdot Pr(B)$, das ist nur zulässig, wenn R und B unabhängig sind.

7.8 Aufgaben

Einige der folgenden Aufgaben sind in englischer Sprache. Wenn Ihnen eine andere Sprache (z.B. Deutsch) lieber ist, nutzen Sie einfach die Übersetzungsfunktion Ihres Browsers. Das sind meist nur zwei Klicks. ☐

7.8.1 Papier-und-Bleistift-Aufgaben

1. [Verteilungen-Quiz-01](#)
2. [globus1](#)
3. [globus2](#)
4. [globus3](#)
5. [globus-bin](#)
6. [globus-bin2](#)
7. [Krebs1](#)
8. [kekse01](#)
9. [kekse03](#)
10. [bayes2](#)
11. [Bayes-Theorem1](#)
12. [bayes-ziel1](#)
13. [totale-wskt1](#)
14. [wskt-quiz13](#)
15. [wskt-quiz12](#)
16. [wskt-quiz15](#)
17. [qm2-quiz-globos](#)

7.8.2 Aufgaben, für die man einen Computer braucht

2. [Rethink2m1](#)
3. [Rethink2m2](#)
4. [Rethink2m3](#)
5. [kekse02](#)
6. [euro-bayes](#)
7. [bath42](#)
8. [Kaefer2](#)
9. [rethink3m1](#)
10. [Lose-Nieten-Binomial-Grid](#)

7.8.3 Quiz-Aufgaben

Hier finden Sie Single-Choice-Aufgaben zu diesem Kapitel. Wählen Sie eine Antwort aus und klicken Sie auf das Häkchen, um sie zu überprüfen; über das Fragezeichen erhalten Sie die ausführliche Lösung.

Welche der folgenden Aussagen zum Konzept “kleine Welt vs. große Welt” im Kontext wissenschaftlicher Modelle (z.B. Behaims Globus) ist korrekt?

- ☐ Die “große Welt” bezieht sich auf besonders umfangreiche bzw. komplexe Modelle.
- ☐ Die Unterscheidung zwischen kleiner und großer Welt ist nur bei Bayes-Modellen relevant, nicht bei anderen statistischen Modellen wie der Regression.
- ☐ Ein gutes Modell macht die kleine und die große Welt vollständig identisch.
- ☐ Die kleine Welt ist das Modell, die große Welt ist die Realität, die das Modell abzubilden versucht.

☐ Wenn ein Modell in der kleinen Welt funktioniert (also intern konsistent ist), muss es zwangsläufig auch in der großen Welt (der Realität) zuverlässig funktionieren.



Welche der folgenden Zuordnungen zu den drei zentralen Bestandteilen eines Bayes-Modells ist korrekt?

- ☐ Likelihood = Wahrscheinlichkeit der Hypothese gegeben der Daten, $Pr(H|D)$.
- ☐ Aposteriori-Verteilung = Wahrscheinlichkeit der Daten, unabhängig von jeder Hypothese.
- ☐ Apriori- und Aposteriori-Verteilung sind stets identisch, unabhängig von den beobachteten Daten.
- ☐ Likelihood = Wahrscheinlichkeit der Daten gegeben einer bestimmten Hypothese, $Pr(D|H)$.
- ☐ Apriori-Verteilung = Wahrscheinlichkeit der Hypothese, *nachdem* man die Daten gesehen hat.



Bei einem Globusversuch werden $n = 10$ Würfe durchgeführt, davon zeigt $W = 7$ Mal der Zeigefinger auf Wasser. Wie groß ist die Likelihood für die Hypothese $\pi = 0,6$, also $Pr(W = 7, n = 10 | \pi = 0,6)$?

- ☐ $Pr(W = 7, n = 10 | \pi = 0,6) = \binom{10}{7} \cdot 0,4^7 \cdot 0,6^3 \approx 0,042$
- ☐ $Pr(W = 6, n = 10 | \pi = 0,6) \approx 0,251$
- ☐ $Pr(W \leq 7, n = 10 | \pi = 0,6) \approx 0,833$
- ☐ $Pr(W = 7, n = 10 | \pi = 0,6) = \binom{10}{7} \cdot 0,6^7 \approx 3,359$
- ☐ $Pr(W = 7, n = 10 | \pi = 0,6) = \binom{10}{7} \cdot 0,6^7 \cdot 0,4^3 \approx 0,215$



In einer Bayesbox berechnet man für eine Hypothese H_i den unstandardisierten Aposteriori-Wert $\text{Post}_{\text{unstand}} = Pr(H_i) \cdot L_i = 0,05$. Die Summe aller unstandardisierten Post-Werte über sämtliche Hypothesen (die Evidenz) beträgt 0,2. Wie groß ist die *standardisierte* Aposteriori-Wahrscheinlichkeit für H_i ?

- ☐ $\text{Post} = 0,05 \cdot 0,2 = 0,01$
- ☐ $\text{Post} = 1 - 0,05 = 0,95$
- ☐ $\text{Post} = \frac{0,2}{0,05} = 4$
- ☐ $\text{Post} = 0,05$ (keine Standardisierung nötig)
- ☐ $\text{Post} = \frac{0,05}{0,2} = 0,25$



Drei Maschinen M_1, M_2, M_3 produzieren denselben Artikel, mit Produktionsanteilen von 50%, 30% bzw. 20%. Ihre jeweiligen Ausschussquoten betragen 3%, 6% bzw. 10%. Wie groß ist die Evidenz $Pr(A)$, also die

totale Wahrscheinlichkeit, dass ein zufällig ausgewähltes Teil Ausschuss (A) ist?

- ☐ $Pr(A) = 0,03 + 0,06 + 0,10 = 0,19$
- ☐ $Pr(A) = 0,5 \cdot 0,03 + 0,3 \cdot 0,06 + 0,2 \cdot 0,10 = 0,053$
- ☐ $Pr(A) = 0,5 \cdot 0,03 = 0,015$
- ☐ $Pr(A) = 0,2 \cdot 0,03 + 0,3 \cdot 0,06 + 0,5 \cdot 0,10 = 0,074$
- ☐ $Pr(A) = \frac{0,03 + 0,06 + 0,10}{3} \approx 0,063$



Drei Maschinen M_1, M_2, M_3 produzieren denselben Artikel, mit Produktionsanteilen von 50%, 30% bzw. 20%. Ihre jeweiligen Ausschussquoten betragen 3%, 6% bzw. 10% (Evidenz $Pr(A) = 0,053$, s. vorherige Aufgabe). Ein zufällig ausgewähltes Teil ist Ausschuss. Wie groß ist die Wahrscheinlichkeit, dass es von Maschine 2 stammt, $Pr(M_2 | A)$?

- ☐ $Pr(M_2 | A) = \frac{0,5 \cdot 0,03}{0,053} \approx 0,283$
- ☐ $Pr(M_2 | A) = 0,3 \cdot 0,06 = 0,018$
- ☐ $Pr(M_2 | A) = Pr(M_2) = 0,3$
- ☐ $Pr(M_2 | A) = \frac{0,053}{0,3 \cdot 0,06} \approx 2,944$
- ☐ $Pr(M_2 | A) = \frac{0,3 \cdot 0,06}{0,053} \approx 0,340$



Welche Funktion hat die Evidenz $Pr(D)$ in der Bayes-Formel $Pr(H|D) = \frac{Pr(H) \cdot Pr(D|H)}{Pr(D)}$?

- ☐ Sie muss bekannt sein, *bevor* man die Likelihood einer einzelnen Hypothese berechnen kann.
- ☐ Sie verändert die Rangfolge der Hypothesen, also welche Hypothese am plausibelsten ist.
- ☐ Sie normiert die Aposteriori-Werte, sodass sich diese über alle Hypothesen zu 1 aufsummieren.
- ☐ Sie ist stets identisch mit der Likelihood der plausibelsten Hypothese.
- ☐ Sie gibt an, wie plausibel die beste Hypothese im Vergleich zu allen anderen Hypothesen ist.



Auf einer Party diskutieren fünf Studierende über das Bayes-Modell. Nur eine der folgenden Aussagen ist richtig, die anderen vier sind falsch (bzw. gelten nur unter zusätzlichen, hier nicht genannten Voraussetzungen). Welche Aussage ist richtig?

- ☐ Die unstandardisierte und die standardisierte Aposteriori-Wahrscheinlichkeit sind grundsätzlich identisch, unabhängig vom Wert der Evidenz.

- ☐ Sind alle Hypothesen apriori gleich wahrscheinlich, hat trotzdem nicht zwangsläufig die Hypothese mit der höchsten Likelihood auch aposteriori die höchste Wahrscheinlichkeit.
- ☐ Hat eine Hypothese die höchste Likelihood, so hat sie nicht zwangsläufig auch die höchste Aposteriori-Wahrscheinlichkeit – das hängt auch von der jeweiligen Apriori-Wahrscheinlichkeit ab.
- ☐ Wenn eine Hypothese apriori doppelt so wahrscheinlich ist wie eine andere und beide dieselbe Likelihood haben, sind sie aposteriori gleich wahrscheinlich.
- ☐ Hat eine Hypothese apriori die Wahrscheinlichkeit Null, so kann ihre Aposteriori-Wahrscheinlichkeit trotzdem größer als Null sein, wenn nur ihre Likelihood hoch genug ist.



Angenommen, in einer Bayesbox haben alle betrachteten Hypothesen dieselbe Apriori-Wahrscheinlichkeit (uniforme Priori, wie beim ursprünglichen Globusversuch). Welche Aussage zur *standardisierten* Aposteriori-Verteilung ist in diesem Fall korrekt?

- ☐ Die Aposteriori-Verteilung ist in diesem Fall für jede Hypothese gleich groß (uniform).
- ☐ Die Aposteriori-Verteilung hängt in diesem Fall überhaupt nicht mehr von den beobachteten Daten ab.
- ☐ Die Post-Wahrscheinlichkeiten summieren sich in diesem Fall nicht notwendigerweise zu 1.
- ☐ Man kann in diesem Fall komplett auf die Berechnung der Evidenz verzichten, da die Likelihood direkt schon eine gültige Wahrscheinlichkeitsverteilung ist.
- ☐ Die standardisierte Aposteriori-Verteilung ist dann identisch mit der (auf Summe 1 normierten) Likelihood-Funktion.



Für ein Experiment werden nur drei mögliche Hypothesen betrachtet: $\pi \in \{0,3, 0,5, 0,7\}$, jeweils mit identischer Apriori-Wahrscheinlichkeit $Pr(\pi) = 1/3$. Bei $n = 5$ Würfeln und $W = 4$ Treffern ergeben sich folgende Likelihoods: $L(\pi = 0,3) \approx 0,0284$, $L(\pi = 0,5) \approx 0,1563$, $L(\pi = 0,7) \approx 0,3602$. Wie groß ist die standardisierte Aposteriori-Wahrscheinlichkeit für die Hypothese $\pi = 0,7$?

- ☐ $Post(\pi = 0,7) = \frac{L(0,7)}{L(0,3) + L(0,5) + L(0,7)} \cdot \frac{1}{3} \approx 0,220$
- ☐ $Post(\pi = 0,7) = \frac{1/3}{3} \approx 0,111$
- ☐ $Post(\pi = 0,7) = \frac{L(0,7) \cdot 1/3}{\sum_i L(\pi_i) \cdot 1/3} \approx 0,661$
- ☐ $Post(\pi = 0,7) = L(0,7) = 0,3602$
- ☐ $Post(\pi = 0,7) = \frac{L(0,3) \cdot 1/3}{\sum_i L(\pi_i) \cdot 1/3} \approx 0,052$





1. wenn auch nicht als Erster ↩
2. Warum gerade 9 Mal? Tja, dann hat das Handy geklingelt... Auch in wissenschaftlichen Versuchen ist (leider?) nicht immer alles genau geregelt. ↩
3. *Ihr* Ergebnis kann anders aussehen, schließlich ist es ja Zufall. ↩
4. oder den? ↩
5. zu Deutsch etwa: “Mutmaßlichkeit” ↩
6. Anstatt von *Apriori-Verteilung* liest man auch *Priori-Verteilung* oder *Prior*. ↩
7. Anstatt von *Apriori* liest man auch *Prior* oder *Priori*; anstatt *Aposteriori* auch *Posterior* ↩
8. Die sog. “iid-Annahme”, *independently and identically distributed*: Jeder Wurf des Globusballes ist eine Realisation der gleichen Zufallsvariablen. Jeder Wurf ist unabhängig von allen anderen: Das Ergebnis eines Wurfes hat keinen (stochastischen) Einfluss auf ein Ergebnis anderer Würfe. Die Wahrscheinlichkeitsverteilung ist bei jedem Wurf identisch. ↩
9. <https://www.geogebra.org/scientific?lang=de> ↩
10. Auch Gitter-Methode oder Grid-Methode genannt. ↩
11. Ein Parameterwert ist eine mögliche Ausprägung des Parameters. ↩
12. synonym: *priori* ↩
13. synonym: Die Likelihoodwerte werden mit den Apriori-Werten gewichtet. ↩