

8 Die Post befragen



Bayes:Start!

8.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- die Post-Verteilung anhand einer Stichprobenverteilung auslesen
- Fragen nach Wahrscheinlichkeitsanteilen der Post-Verteilung anhand der Stichprobenverteilung beantworten
- Fragen nach Quantilen anhand der Stichprobenverteilung beantworten
- Die Post-Verteilung visualisieren mit R
- Schätzbereiche (Konfidenzintervalle) aus der Post-Verteilung bestimmen anhand von Perzentilintervallen und Highest Density Intervals (HDI)

Der Stoff dieses Kapitels orientiert sich an McElreath (2020), Kap. 3.1 und 3.2.

Lesen Sie folgende Kapitel zur Vorbereitung im Eigenstudium:

- [Statistik1, Kap. "Daten umformen"](#)
- [Statistik1, Kap. "Daten zusammenfassen"](#)
- [Statistik1, Kap. 6.4 "Quantile"](#)

Zusätzlich ist diese Playlist (bei YouTube) nützlich: [Playlist QM2](#).

Folgende R-Pakete werden in diesem Kapitel benötigt:

```
library(tidyverse)
library(easystats)
library(ggpubr) # optional, Visualisierung
library(prada)  # optional, bayesbox automatisiert
```

Hinweis

Die Folien zu diesem Kapitel finden Sie [hier](#).

8.2 Zur Erinnerung: Bayesbox in R berechnen

Berechnen wir mit der Bayesbox ("Gittermethode") die Postverteilung für den Globusversuch. Die Bayesbox ist ein Weg, die Posteriori-Verteilung zu berechnen. Die Posteriori-Verteilung birgt viele nützliche Informationen. Sie ist das zentrale Ergebnis einer Bayes-Analyse.

Beispiel 8.1 (Bayesbox für $W = 6$ Wasser bei $N = 9$ Würfeln) Betrachten wir wieder das Globusmodell mit folgendem Ergebnis: $W = 6$ Wasser, $N = 9$ Würfeln, bei Apriori-Indifferenz gegenüber den Parameterwerten. Und, sagen wir, $g = 11$ Gitterwerten¹ von 0 bis 1, in Schritten von 0.1, 0.1, 0.2, ..., 0.9, 1.0. □

Übungsaufgabe 8.1 (Welcher Parameterwert hat die höchste Posteriori-Wahrscheinlichkeit?)

Lösung

>

Listing 8.1: Bayesbox mit 6 Wasser bei 9 Versuchen (g=11 Gitterwerte)

```
n_success <- 6
n_trials  <- 9
p_grid <- seq(from = 0, to = 1, by = .1)
L <- dbinom(n_success, size = n_trials, prob = p_grid)

bayesbox_6w_9v <-
  tibble(p_grid = p_grid, prior = 1) %>%
  mutate(likelihood = L) %>%
  mutate(unstand_post = (likelihood * prior),
         post = unstand_post / sum(unstand_post))
```

Abb. [Abbildung 8.1](#) zeigt die resultierende Bayesbox; vor allem ist die Post-Verteilung wichtig. Voilà, die Post-Verteilung zu [Beispiel 8.1](#) als Tabelle, die “Bayesbox”: s. [Tabelle 8.1](#).




Abbildung 8.1: Die Postverteilung für W=6, N=9; der wahrscheinlichste Parameterwert ist farblich hervorgehoben

Tabelle 8.1: Postverteilung mit der Bayesbox berechnet

p_grid	prior	likelihood	unstand_post	post
0.0	1	0.00	0.00	0.00
0.1	1	0.00	0.00	0.00
0.2	1	0.00	0.00	0.00
0.3	1	0.02	0.02	0.02
0.4	1	0.07	0.07	0.07
0.5	1	0.16	0.16	0.16
0.6	1	0.25	0.25	0.25
0.7	1	0.27	0.27	0.27
0.8	1	0.18	0.18	0.18
0.9	1	0.04	0.04	0.04
1.0	1	0.00	0.00	0.00



8.2.1 Bayesbox automatisiert

Übrigens kann man die Berechnung der Bayesbox auch automatisieren, s. [Tabelle 8.2](#) und [Listing 8.2](#). Entweder importiert (“sourced”) man die Funktion `bayesbox` direkt von Github:

```
source("https://raw.githubusercontent.com/sebastiansauer/prada/master/R/NAME_bayesbox.R")
bayesbox(hyps = p_grid, priors = 1, liks = L)
```

Mit `source` importiert man eine R-Skriptdatei. In diesem Fall steht dort der Code für die Funktion `bayesbox`.

Oder Sie starten das R-Paket `prada` (mit `library(prada)`), wo die Funktion wohnt:

Tabelle 8.2: Eine Bayesbox ‘automatisiert’ erstellt, mit Hilfe der Funktion `bayesbox`

Listing 8.2: Funktion `bayesbox`, auch im Paket `prada` erhältlich

```
library(prada)
bayesbox(hyps = p_grid, priors = 1, liks = L)
```

8.2.2 Bayesbox geht nur für einfache Modelle

Bisher, für einfache Fragestellungen, hat unsere Bayesbox gut funktioniert. Allerdings: Funktioniert sie auch bei komplexeren Modellen? Schließlich wollen wir ja auch irgendwann Regressionsmodelle berechnen.

Angenommen, wir haben ein Regressionsmodell mit 1 Prädiktor, dann haben wir folgende drei Parameter zu schätzen: β_0, β_1, σ . Hört sich gar nicht so viel an. Aber Moment, wir müssten dann z.B. die Frage beantworten, wie wahrscheinlich die Daten aposteriori sind, wenn z.B. $\beta_0 = -3.14$ und $\beta_1 = 2.71$ und $\sigma = 0.70$. Wie viele Zeilen brauchen wir dann in der Bayesbox? Wenn wir für die drei Parameter jeweils 10 Ausprägungen annehmen, was wenig ist, kämen wir $10 \cdot 10 \cdot 10 = 1000 = 10^3$ Zeilen in der Bayesbox. Bei 100 Ausprägungen und 3 Parametern wären es schon $100^3 = 10^6$ Zeilen. Das wäre doch eine recht lange Tabelle.² Bei einer multiplen Regression mit sagen wir 10 Parametern mit jeweils 100 Ausprägungen rechnet das arme R bis zum jüngsten Tag, denn das sind 10^{100} Variationen, also Zeilen in der Bayesbox.



Bitte tue mir das nicht an!



Schon gut, das können wir R nicht zumuten. Wir brauchen eine andere Lösung!

8.3 Mit Stichproben die Post-Verteilung zusammenfassen

8.3.1 Wir arbeiten jetzt mit Häufigkeit, nicht mit Wahrscheinlichkeit

Kurz gesagt: Komplexere Bayes-Modelle können nicht mehr “einfach mal eben” ausgerechnet werden; die Mathematik wird zu rechenintensiv. Glücklicherweise gibt es einen Trick, der die Sache nicht nur rechnerisch, sondern auch konzeptionell viel einfacher macht. Dieser Trick lautet: Wir arbeiten nicht mehr mit Wahrscheinlichkeiten, sondern mit *Häufigkeiten*. Praktischerweise werden wir in Kürze einen R-Golem kennenlernen, der das für uns erledigt (er heißt *Stan* und kommt aus dem Paket `rstanarm`). Dieser Golem liefert uns *Stichproben* aus der Post-Verteilung zurück. Lernen wir jetzt also, wie man mit solchen Stichproben umgeht.

Die Bayesbox-Methode³ ist bei größeren Datensätzen (oder größeren Modellen) zu unpraktisch. In der Praxis werden daher andere, schnellere Verfahren verwendet, sog. Monte-Carlo-Markov-Ketten (MCMC). Wie diese Verfahren funktionieren sind aber nicht mehr Gegenstand dieses Kurses. Wir wenden Sie einfach an, freuen uns und lassen es damit gut sein.⁴

8.3.2 Häufigkeiten sind einfacher als Wahrscheinlichkeiten

Wie gesagt, typische R-Werkzeuge (“R-Golems”, wie Stan) liefern uns die Post-Verteilung in Stichprobenform zurück. Bevor wir uns aber mit diesen R-Werkzeugen beschäftigen, sollten wir uns vertraut machen mit einer Post-Verteilung in Stichprobenform. Erstellen wir uns also eine Tabelle mit Stichprobendaten aus der Posteriori-Verteilung (s. Dataframe `bayesbox_6w_9v`), s. [Listing 8.3](#).

Listing 8.3: Wir stellen eine Tabelle mit Stichproben aus der Post-Verteilung

```
samples_6w_9v <-  
  bayesbox_6w_9v %>% # nimm die Tabelle mit Posteriori-Daten,  
  slice_sample( # Ziehe daraus eine Stichprobe,  
    n = 1e4, # mit insgesamt n=10000 Zeilen,  
    weight_by = post, # Gewichte nach Post-Wskt.,  
    replace = T) %>% # Ziehe mit Zurücklegen  
  select(p_grid)
```

Die Wahrscheinlichkeit, einen bestimmten Parameterwert (d.h. aus der Spalte `p_grid`) aus Tabelle `bayesbox_6w_9v` zu ziehen, ist proportional zur Posteriori-Wahrscheinlichkeit (`post`) dieses Werts. Ziehen mit Zurücklegen hält die Wahrscheinlichkeiten während des Ziehens konstant. Das Argument `weight_by` legt die Wahrscheinlichkeit fest, mit der eine Zeile gezogen wird. Wir begnügen uns mit der Spalte mit den Wasseranteilswerten (Parameterwerten), `p_grid`, die anderen Spalten brauchen wir nicht.

Wenn Sie jetzt denken: “Warum machen wir das jetzt? Brauchen wir doch gar nicht!” – Dann haben Sie Recht, für dieses Kapitel. Ab dem nächsten Kapitel werden wir aber, wenn wir mit komplexeren Modellen zu tun haben, nur noch mit Post-Verteilungen auf Stichprobenbasis arbeiten, weil wir Regressionsmodelle nicht mehr mit der Bayesbox berechnen können. Die Anzahl der Zeilen wäre einfach zu groß.

Hier erstmal die ersten 100 gesampelten Parameterwerte (`p_grid`) aus `samples_6w_9v`:

```
## [1] 0.5 0.9 0.7 0.6 0.9 0.3 0.7 0.6 0.8 0.4 0.7 0.3 0.9 0.7 0.6 0.6 0.4 0.6  
## [19] 0.5 0.5 0.5 0.6 0.8 0.7 0.5 0.7 0.7 0.4 0.8 0.6 0.6 0.7 0.9 0.6 0.9 0.4  
## [37] 0.8 0.9 0.8 0.6 0.6 0.6 0.5 0.7 0.5 0.8 0.7 0.7 0.6 0.8 0.3 0.5 0.8 0.5  
## [55] 0.7 0.6 0.5 0.8 0.7 0.7 0.7 0.7 0.6 0.7 0.5 0.7 0.6 0.6 0.7 0.8 0.7 0.6  
## [73] 0.8 0.5 0.8 0.7 0.7 0.7 0.6 0.8 0.7 0.7 0.9 0.4 0.5 0.6 0.6 0.5 0.8 0.8  
## [91] 0.7 0.7 0.6 0.9 0.9 0.5 0.5 0.8 0.7 0.8
```

So sieht unsere “Stichproben-Bayesbox” als Balkendiagramm aus, s. [Abbildung 8.2](#).

Syntax

Output

```
samples_6w_9v |>  
  count(p_grid) |>
```

```
ggbarplot(x = "p_grid", y = "n") # aus ggpubr
```

Aus [Abbildung 8.2](#) können wir einfach auslesen, wie wahrscheinlich gewisse Parameterwerte sind. So sehen wir, dass das Modell Parameterwerte (Wasseranteil, π) zwischen ca. 50% und 70% am wahrscheinlichsten hält. Aber auch kleine Anteile wie 25% sind nicht auszuschließen (auf Basis der Daten und der Modellannahmen).

Vergleichen Sie [Abbildung 8.2](#) mit [Abbildung 7.11](#): beide sind sehr ähnlich! Das Stichprobenziehen ([Abbildung 8.2](#)) nähert sich recht gut an die exakte Berechnung an ([Abbildung 7.11](#)).

Es ist hilfreich, sich die Stichproben-Posterior-Verteilung einmal anzuschauen, um ein Gefühl dafür zu bekommen, wie die Post-Verteilung aussieht.


[↓ DOWNLOAD SAMPLES_6W_9V.XLSX](#)[↓ DOWNLOAD SAMPLES_6W_9V.CSV](#)

8.3.3 Visualisierung der Stichprobendaten mit $g = 100$ Gitterwerten

$g = 10$ Gitterwerte ist ein grobes Raster. Drehen wir mal die Auflösung auf $g = 100$ Gitterwerte (Ausprägungen) nach oben.

```
g <- 100
n_success <- 6
n_trials <- 9

bayesbox_g100 <-
  tibble(p_grid = seq(from = 0,
                       to = 1,
                       length.out = g+1),
         prior = 1) %>%
  mutate(likelihood = dbinom(n_success,
                             size = n_trials,
                             prob = p_grid)) %>%
  mutate(unstand_post = (likelihood * prior),
         post = unstand_post / sum(unstand_post))
```



bayesbox_g100 ist eine Bayesbox mit $W = 6$, $N = 9$, $g = 101$; sie ist in [Tabelle 8.3](#) dargestellt.

Tabelle 8.3: Bayesbox mit $g=101$ Gitterwerten für $W=6$ Wasser bei $N=9$ Würfeln

[↓ DOWNLOAD BAYESBOX_G100.XLSX](#)[↓ DOWNLOAD BAYESBOX_G100.CSV](#)

Und daraus ziehen wir uns $n = 1000 = 10^3$ Stichproben:

```
samples_g100 <-
  bayesbox_g100 %>% # nimmt die Tabelle mit Posteriori-Daten,
  slice_sample( # Ziehe daraus eine Stichprobe,
    n = 1000, # mit insgesamt n=1000 Elementen,
    weight_by = post, # Gewichte nach Spalte mit Post-Wskt.,
    replace = T) # Ziehe mit Zurücklegen
```

[Abbildung 8.3](#) zeigt sowohl die exakte Post-Verteilung (farbige, gepunktete Linie) als auch die Post-Verteilung auf Basis von Stichproben (Histogramm). In beiden Fällen erkennt man gut die zentrale Tendenz: ein Wasseranteil von ca. 70% scheint der “typische” Wert des Modells zu sein. Außerdem erkennt man, dass das Modell durchaus einige Streuung in der Schätzung des Wasseranteils bereithält. Das Modell ist sich nicht sehr sicher, könnte man sagen.




Abbildung 8.3: Post-Verteilung mit 100 Gitterwerten, exakt vs. auf Basis von Stichproben

Die Stichprobendaten nähern sich der “echten” Posteriori-Verteilung an: Die Stichproben-Post-Verteilung ist ähnlich zur echten, exakten Post-Verteilung. Das Stichproben-Verfahren zur Berechnung der Post-Verteilung funktioniert also! Das ist gut, denn wir werden in Zukunft nur noch mit dem Stichproben-Verfahren (zur Erstellung der Post-Verteilung) arbeiten.

Hinweis

Mehr Stichproben und mehr Gitterwerte glätten die Stichproben-Post-Verteilung.

Jetzt die Post-Verteilung noch mal mit mehr Stichproben: $n = 10^6$ Stichproben bei $g = 101$ Gitterwerten aus der Posteriori-Verteilung, s. [Abbildung 8.4](#).




Abbildung 8.4: Post-Verteilung mit einer Million Stichproben und 100 Parameterwerten (Gitterwerten): schön 'glatt'. Mittelwert (MW), Modus und Median (Md) liegen eng nebeneinander, da die Verteilung recht symmetrisch ist.

Übungsaufgabe 8.2 (Erstellen Sie Ihre eigene Stichproben-Post-Verteilung) Erstellen Sie eine Stichproben-Post-Verteilung auf Basis der Bayesbox `bayesbox_6w_9v`. Ziehen Sie $n = 100$ Stichproben. Tun Sie das *per Hand*: Übertragen Sie die Werte der Spalte `p_grid` auf kleine Zettel. Dabei soll der Anteil der Zettel pro Wert von `p_grid` der Posteriori-Wahrscheinlichkeit (`post`) entsprechen (gerundet auf zwei Dezimalstellen). Beispiel: Wenn der Parameterwert 0.6 eine Posteriori-Wahrscheinlichkeit von 0.27 hat, dann schreiben Sie 27 Zettel (von 100) mit dem Wert 0.6. □

8.4 Die Post-Verteilung befragen

So, jetzt befragen wir die Post-Verteilung.

 [Die Post-Verteilung auslesen](#)

! Wichtig

Die Post-Verteilung ist das zentrale Ergebnis einer Bayes-Analyse. Wir können viele nützliche Fragen an sie stellen.

Es gibt zwei Arten von Fragen:

A. nach Wahrscheinlichkeiten (p) B. nach Parameterwerten (Quantilen, q)

Beispiel 8.2 (Beispiele für Fragen an die Post-Verteilung) A. Fragen nach Wahrscheinlichkeiten (p):

- Mit welcher Wahrscheinlichkeit liegt der Parameter unter einem bestimmten Wert?
- Mit welcher Wahrscheinlichkeit liegt der Parameter über einem bestimmten Wert?
- Mit welcher Wahrscheinlichkeit liegt der Parameter zwischen zwei bestimmten Werten?

B. Fragen nach Parameterwerten (Quantilen, q):


- Welcher Wert wird mit 95% Wahrscheinlichkeit nicht überschritten?

- Mit 5% Wahrscheinlichkeit liegt der Parameterwert nicht unter welchem Wert?
- Welcher Parameterwert hat die höchste Wahrscheinlichkeit?
- Wie ungewiss ist das Modell über die Parameterwerte?

etc. ☐


Der Unterschied zwischen beiden Arten von Fragen ist in [Abbildung 8.5](#) schematisch illustriert.

Welcher Wasseranteil wird mit 50% Wahrscheinlichkeit nicht übertroffen?



(a) Fragen nach Parameterwerten (q)

Was ist die Wahrscheinlichkeit eines Wasseranteils von höchstens 50%?



(b) Fragen nach Parameterwerten (q)

Abbildung 8.5: Unterschied zwischen Fragen nach Wahrscheinlichkeiten (p) und Fragen nach Parameterwerten (q)

Im *linken* Teildiagramm von [Abbildung 8.5](#) fragen wir: “Welcher Wasseranteil wird mit einer gegebenen Wahrscheinlichkeit p nicht überschritten?” – Wir suchen also einen Parameterwert (Quantil, q). Im *rechten* Teildiagramm fragen wir: “Wie wahrscheinlich ist ein Wasseranteil von höchstens q ?” – Wir suchen also eine Wahrscheinlichkeit (p).

8.4.1 Fragen nach Wahrscheinlichkeiten (p)

Sagen wir, dass sei unsere Forschungsfrage: *Wie groß ist die Wahrscheinlichkeit, dass der Wasseranteil unter 50% liegt?* Um diese Frage zu beantworten, zählen wir einfach, wie viele Stichproben die Bedingung erfüllen, und summieren die Wahrscheinlichkeiten dieser Stichproben. Wir zählen (`count`) also die Stichproben, die sich für einen Wasseranteil (`p_grid`) von weniger als 50% aussprechen.

```
samples_6w_9v %>%  
  count(p_grid < .5)
```

Wenn wir insgesamt 10000 (1e4) Stichproben gezogen haben, können wir noch durch diese Zahl teilen, um einen Anteil zu bekommen. Dieser Anteil ist die Antwort auf die Forschungsfrage: Wie wahrscheinlich ist (laut Modell) ein Wasseranteil kleiner als 50%? In unseren Daten ist die Wahrscheinlichkeit ca. 10%.

Übungsaufgabe 8.3 (Was macht die Funktion `count`?) Zur Erinnerung: Der Befehl `count` macht Folgendes: Er gruppiert die Stichprobe nach dem Prüfkriterium (hier: `p_grid < .5`, d.h. Wasseranteil höchstens 50%). Dann zählt er in jeder der beiden Teiltabellen die Zeilen und liefert diese zwei Zahlen dann zurück. □

Wir zählen, wie oft der Wasseranteil weniger als 50% beträgt.

Natürlich gibt es verschiedene Wege, die gleiche Frage zu beantworten.

```
samples_6w_9v %>%  
  count(p_grid < .5)
```

```
bayesbox_6w_9v %>%  
  filter(p_grid < .5) %>%  
  summarise(sum = sum(post))
```

Beispiel 8.3 (Wasseranteil zwischen 50 und 75%?) Noch eine Forschungsfrage: *Mit welcher Wahrscheinlichkeit liegt der Parameter (Wasseranteil) zwischen 0.5 und 0.75?*

Wir zählen die Stichproben, die diesen Kriterien entsprechen.

```
samples_6w_9v %>%  
  count(p_grid > .5 & p_grid < .75)
```

 Ich würde empfehlen, die Anzahl noch in Anteile umzurechnen. Die kann man dann als Wahrscheinlichkeiten auffassen.

 Das wollte ich auch gerade sagen...

```
samples_6w_9v %>%  
  count(p_grid > .5 & p_grid < .75) %>%  
  mutate(Anteil = n / 1e4,  
         Prozent = 100 * n / 1e4) # In Prozent
```

Anstelle von `count()` könnte man, wenn man möchte, auch `filter()` verwenden.

```
samples_6w_9v %>%  
  filter(p_grid > .5 & p_grid < .75) %>%  
  summarise(sum = n() / 1e4,  
            anteil = 100 * n() / 1e4) # In Prozent
```

Fertig 😊 ☐

Beispiel 8.4 (Wasseranteil zwischen 90% und 100%?) Noch ein Beispiel für eine Forschungsfrage: *Mit welcher Wahrscheinlichkeit liegt der Parameter zwischen 0.9 und 1?*

Syntax

Output

```
samples_6w_9v %>%  
  count(p_grid >= .9 & p_grid <= 1) %>%  
  mutate(prop = 100 * n / 1e4) # prop wie "proportion", Anteil
```

Laut unserem Modell ist es also sehr unwahrscheinlich, dass der Wasseranteil der Erde mind. 90% beträgt. ☐

Übungsaufgabe 8.4 (Wasseranteil höchstens 50%?)



Mit welcher Wahrscheinlichkeit ist der Planet höchstens zur Hälfte mit Wasser bedeckt?

Lösung



Wir können auch fragen, welcher Parameterwert am wahrscheinlichsten ist; dieser Wert entspricht dem “Gipfel” des Berges, s. [Abbildung 8.4](#).

Für unsere Stichproben-Postverteilung, `samples_6w_9v`, s. [Abbildung 8.2](#), lässt sich der Modus so berechnen:

```
map_estimate(samples_6w_9v$p_grid)
```

Dabei steht `map` für [Maximum A posteriori](#), also das Maximum der Post-Verteilung.

Übungsaufgabe 8.5 Bei der Gelegenheit könnten wir folgende, ähnliche Fragen stellen:

- Was ist der mittlere Schätzwert (Mittelwert) zum Wasseranteil laut Post-Verteilung?
- Was ist der mediane Schätzwert (Median)?

Lösung



8.4.2 Fragen nach Parameterwerten

! Wichtig

Schätzbereiche von Parameterwerten nennt man auch *Konfidenz- oder Vertrauensintervalle*⁵.

Welcher Parameterwert wird mit 90% Wahrscheinlichkeit nicht überschritten, laut unserem Modell? (Gesucht sind also die unteren 90% der Posteriori-Wahrscheinlichkeit.) Wir möchten also ziemlich sicher sein, was die Obergrenze an Wasser auf diesem Planeten ist. Diese Frage können wir mit dem Befehl `quantile` beantworten.

```
samples_6w_9v %>%  
  summarise(quantile90 = quantile(p_grid, p = .9))
```

Laut unserem Modell können wir zu 90% sicher sein, dass der Wasseranteil kleiner ist als ca. 78%.

Es hilft vielleicht, sich die Post-Verteilung noch einmal vor Augen zu führen, s. [Abbildung 8.4](#).

Was ist das *mittlere* Intervall, das mit 90% Wahrscheinlichkeit den Parameterwert enthält, laut dem Modell?

Dafür “schneiden” wir links und rechts die 5% der Stichproben mit den extremsten Werten ab und schauen, bei welchen Parameterwerten wir als Grenzwerte landen:

```
samples_6w_9v %>%  
  summarise(  
    quant_05 = quantile(p_grid, 0.05),  
    quant_95 = quantile(p_grid, 0.95))
```

Solche Fragen lassen sich also mit Hilfe von *Quantilen* beantworten.

Übungsaufgabe 8.6 (Welcher Parameterwert ist der wahrscheinlich größte?) Übersetzen wir “wahrscheinlich” größte in “mit einer Wahrscheinlichkeit von 99% gibt es keinen größeren”.

Lösung



Übungsaufgabe 8.7 (Welcher Parameterwert ist der wahrscheinlich kleinste?) Übersetzen wir “wahrscheinlich” kleinste in “mit einer Wahrscheinlichkeit von 99% gibt es keinen kleineren”.

Lösung



Übungsaufgabe 8.8 (Welcher Parameterwert ist der “vermutlich” kleinste?) In der “wirklichen” Welt sind Aussagen nicht immer präzise. Sagen wir, die Chefin der Weltraumbehörde hat in einem Presse-Statement von der “vermutlichen Untergrenze” hinsichtlich des Wasseranteils gesprochen.

Übersetzen wir “vermutlich” kleinste in “mit einer Wahrscheinlichkeit von 90% gibt es keinen kleineren”.

Lösung



8.5 Visualisierung der Verteilungen

8.5.1 Perzentilintervalle

Definition 8.1 (Perzentilintervall (PI)) Intervalle (Bereiche), die die “abzuschneidende” Wahrscheinlichkeitsmasse hälftig auf die beiden Ränder aufteilen, nennen wir *Perzentilintervalle* (PI) oder (synonym) *Equal-Tails-Intervalle* (ETI), s. Abb. [Abbildung 8.6](#).⁶ □

80%-ETI: Die mittleren 80% der Wahrscheinlichkeit liegen zwischen 0.45 und 0.81




Abbildung 8.6: Perzentilintervalle: Das Intervall umfasst die mittleren 80% der Wahrscheinlichkeit

Die 10%-, 20%-, ..., 100%-Quantile⁷ (auf Basis von `bayesbox_g100_samples`) sind in [Abbildung 8.7](#) illustriert.




Abbildung 8.7: Quantile in 10%-Schritten durch die Verteilung von `bayesbox_g100_samples`

8.5.2 Schiefe Posteriori-Verteilungen sind möglich

Beispiel 8.5 (Globusversuch: 3 Würfe, 3 Treffer) Noch einmal zum Globusversuch: Gehen wir von 3 Würfeln mit 3 Mal Wasser (Treffer) aus; auf welche Wasseranteile (Parameterwerte) werden wir jetzt schließen? ☐

Erstellen wir uns dazu mal eine Post-Verteilung (3 Treffer, 3 Würfe), s. [Listing 8.4](#) mit dem Objekt `bayesbox_3w_3v`.

Listing 8.4: Schiefe Post-Verteilung in einer Bayesbox

```
bayesbox_3w_3v <-  
  tibble(p_grid = seq(0,1, by = .01),  
         prior = 1) %>%  
  mutate(likelihood = dbinom(3, size = 3, prob = p_grid)) %>%  
  mutate(unstand_post = likelihood * prior) %>%  
  mutate(post_33 = unstand_post / sum(unstand_post))  
  
samples_3w_3v <-  
  bayesbox_3w_3v %>%  
    slice_sample(n = 1e6,  
               weight_by = post_33,  
               replace = T)
```


So sehen die ersten paar Zeilen der Post-Verteilung, `samples_3w_3v`, aus.

p_grid	prior	likelihood	unstand_post
0.86	1	0.64	0.64
0.88	1	0.68	0.68


p_grid	prior	likelihood	unstand_post
0.62	1	0.24	0.24
0.96	1	0.88	0.88
0.84	1	0.59	0.59
0.88	1	0.68	0.68

Mit dieser “schiefen” Post-Verteilung können wir gut die Auswirkungen auf das Perzentil- und das Höchste-Dichte-Intervall vergleichen.

Hier z.B. ein 50%-Perzentilintervall, s. Abb. [Abbildung 8.8](#), (a).



(a) Perzentilintervall (PI)



(b) Höchste-Dichte-Intervall (HDI)

Abbildung 8.8: Schiefe Intervalle: Das PI enthält den wahrscheinlichsten Parameterwert nicht, das HDI schon.

Ein *Perzentilintervall* kann bei schiefen Verteilungen den wahrscheinlichsten Parameterwert nicht enthalten, diesen plausiblen Wert also zurückweisen. Das macht keinen Sinn.

Ein *Highest-Density-Intervall* (HDI⁸) ist schmaler als das Perzentilintervall und enthält immer den wahrscheinlichsten Parameterwert.

Die Grenzwerte dieses ETI (oder jedes beliebig breiten) kann man sich z.B. mit dem Befehl `eti` ausgeben lassen.

```
samples_3w_3v %>%
  select(p_grid) %>%
  eti(ci = .5) # Paket `easystats`
```

Der wahrscheinlichste Parameterwert (1) ist *nicht* im Intervall enthalten. Das ist ein Nachteil der ETI.

8.5.3 Intervalle höchster Dichte

Definition 8.2 (Intervalle höchster Dichte (Highest Density Intervals)) Intervalle höchster Dichte (Highest Density Intervals, HDI oder HDPI) sind definiert als das *schmälste* Intervall, das den gesuchten Parameter enthält (in Bezug auf ein gegebenes Modell). □

Der wahrscheinlichste Parameterwert (1) *ist* im Intervall enthalten, was Sinn macht, s. [Abbildung 8.8](#). Bei einem HDI sind die abgeschnittenen Ränder nicht mehr gleich groß, im Sinne davon, dass sie nicht (zwangsläufig) die gleiche Wahrscheinlichkeitsmasse enthalten. Beim PI ist die Wahrscheinlichkeitsmasse in diesen Rändern hingegen gleich groß.

Je unsymmetrischer die Verteilung, desto weiter liegen die Punktschätzer auseinander (und umgekehrt), s. Abb. [Abbildung 8.9](#).




Abbildung 8.9: Visualisierung der Punktschätzer bei einer schiefen Post-Verteilung (auf Basis von `samples_3w_3v`)

Mit dem Befehl `hdi` kann man sich die Grenzwerte eines HDI, z.B. eines 50%-HDI, ausgeben lassen, s. [Tabelle 8.4](#).

```
samples_6w_9v %>%
  select(p_grid) %>%
  hdi(ci = .5) # aus dem Paket `{easystats}`
```

Tabelle 8.4: 50%-HDI für unser Globusmodell (`samples_6w_9v`)

Das Modell ist sich also zu 50% sicher, dass der gesuchte Parameter (der Wasseranteil der Erdoberfläche) sich im Bereich von ca. .67 bis .78 befindet (auf Basis eines HDI).

8.6 Fazit

- Bei symmetrischer Posteriori-Verteilung sind beide Intervalle ähnlich oder identisch
- Perzentilintervalle sind verbreiteter
- *Intervalle höchster Dichte* (Highest Density Interval, HDI) sind bei schiefen Post-Verteilungen zu bevorzugen
- Intervalle höchster Dichte sind die *schmalsten* Intervalle für eine gegebene Wahrscheinlichkeitsmasse

Fassen wir zentrale Punkte an einem Beispiel zusammen.

Wir greifen dazu wieder auf den Globusversuch zurück, Datensatz `samples_6w_9v`, s. [Listing 8.3](#). Sagen wir, wir haben 6 Treffer bei 9 Würfeln erzielt.

Lageparameter: Welchen mittleren Wasseranteil kann man erwarten?

```
samples_6w_9v %>%
  summarise(
    mean = mean(p_grid),
    median = median(p_grid))
```

Streuungsparameter: Wie unsicher sind wir in der Schätzung des Wasseranteils?


```
samples_6w_9v %>%  
  summarise(  
    p_sd    = sd(p_grid),  
    p_iqr   = IQR(p_grid),  
    p_mad   = mad(p_grid)) # Mean Absolute Deviation, Mittlerer Absolutfehler
```

Anstelle von Streuungsparametern ist es aber üblicher, ein HDI oder PI für den gesuchten Parameter anzugeben.

! Wichtig

Alles Wasser oder was? Im Beispiel dieses Kapitels haben wir uns gefragt, was wohl der Wasseranteil auf dem Planeten Erde ist. Halten Sie sich klar vor Augen: Der Wasseranteil ist ein Beispiel für einen *Parameter*, einer unbekannten GröÙes eines Modells.

8.7 Aufgaben

8.7.1 Papier-und-Bleistift-Aufgaben

1. [kekse03](#)
2. [bfi10](#)
3. [Kaefer2](#)
4. [mtcars-post2a](#)
5. [rethink3e1-7-paper](#)
6. [mtcars-post3a](#)
7. [mtcars-post3a](#)
8. [mtcars-post_paper](#)
9. [fattails1](#)
10. [fattails2](#)
11. [eti-hdi](#)

8.7.2 Aufgaben, bei denen man einen Computer benötigt

1. [iq01](#)
2. [iq02](#)
3. [iq03](#)
4. [iq04](#)
5. [iq05](#)
6. [iq06](#)
7. [iq07](#)
8. [iq08](#)
9. [iq10](#)
10. [ReThink3e1-7](#)
11. [Weinhaendler](#)
12. [Rethink3m1](#)
13. [Rethink3m2](#)
14. [groesse2](#)
15. [groesse1](#)

16. [Anteil-Apple](#)
17. [Kung-height](#)
18. [zweilichter-dozent-bayes](#)

8.7.3 Quiz-Aufgaben

Hier finden Sie Single-Choice-Aufgaben zu diesem Kapitel. Wählen Sie eine Antwort aus und klicken Sie auf das Häkchen, um sie zu überprüfen; über das Fragezeichen erhalten Sie die ausführliche Lösung.

Bei einem Regressionsmodell mit 4 zu schätzenden Parametern nimmt man für jeden Parameter 50 mögliche Ausprägungen (Gitterwerte) an. Wie viele Zeilen hätte eine vollständige Bayesbox (Gittermethode) für dieses Modell?

- ☐ $50 \cdot 4 = 200$
- ☐ $4 \cdot 50^2 = 10\,000$
- ☐ $50^3 = 125\,000$
- ☐ $50^4/4 = 1\,562\,500$
- ☐ $50^4 = 6\,250\,000$



Beim Befragen der Post-Verteilung unterscheidet man Fragen nach Wahrscheinlichkeiten (p) und Fragen nach Parameterwerten (Quantilen, q). Welche der folgenden Fragen ist eine Frage vom Typ “ q ” (Frage nach einem Parameterwert)?

- ☐ “Wie hoch ist der Anteil der Stichproben mit einem Wasseranteil kleiner als 0,5?”
- ☐ “Mit welcher Wahrscheinlichkeit liegt der Wasseranteil unter 50%?”
- ☐ “Mit welcher Wahrscheinlichkeit liegt der Wasseranteil zwischen 0,5 und 0,75?”
- ☐ “Welcher Wasseranteil wird mit 95% Wahrscheinlichkeit nicht überschritten?”
- ☐ “Mit welcher Wahrscheinlichkeit liegt der Wasseranteil über 90%?”



Eine Bayesbox enthält folgende (standardisierte) Post-Wahrscheinlichkeiten für ein Gitter von 5 Parameterwerten:

p (Parameterwert)	0	0,25	0,5	0,75	1
Post-Wahrscheinlichkeit	0,05	0,20	0,30	0,30	0,15

Wie hoch ist laut dieser Bayesbox die Wahrscheinlichkeit, dass der Parameter p *kleiner als* 0,5 ist, also $Pr(p < 0,5)$?

- ☐ $Pr(p < 0,5) = 0,20$
- ☐ $Pr(p < 0,5) = 0,05 + 0,20 + 0,30 = 0,55$
- ☐ $Pr(p < 0,5) = 0,05 + 0,20 = 0,25$

☐ $Pr(p < 0,5) = 0,05 + 0,20 + 0,30 + 0,30 + 0,15 = 1$

☐ $Pr(p < 0,5) = 1 - 0,25 = 0,75$



Eine Bayesbox enthält folgende (standardisierte) Post-Wahrscheinlichkeiten für ein Gitter von 5 Parameterwerten:

p (Parameterwert)	0	0,25	0,5	0,75	1
Post-Wahrscheinlichkeit	0,05	0,20	0,30	0,30	0,15

Wie hoch ist laut dieser Bayesbox die Wahrscheinlichkeit, dass der Parameter p zwischen (einschließlich) 0,25 und 0,75 liegt, also $Pr(0,25 \leq p \leq 0,75)$?

☐ $Pr(0,25 \leq p \leq 0,75) = 0,20 + 0,30 + 0,30 = 0,80$

☐ $Pr(0,25 \leq p \leq 0,75) = 0,05 + 0,20 + 0,30 + 0,30 + 0,15 = 1$

☐ $Pr(0,25 \leq p \leq 0,75) = 1 - 0,80 = 0,20$

☐ $Pr(0,25 \leq p \leq 0,75) = 0,30$

☐ $Pr(0,25 \leq p \leq 0,75) = 0,20 + 0,30 + 0,30 + 0,15 = 0,95$



Bei einem Globusversuch mit 3 Würfeln und 3 Treffern (also $W = 3$, $N = 3$) ist die resultierende Post-Verteilung stark schief: Der wahrscheinlichste Parameterwert liegt bei $\pi = 1$, direkt am Rand des möglichen Wertebereichs. Welche Aussage zum Vergleich von Perzentilintervall (PI) und Intervall höchster Dichte (HDI) in diesem Fall ist korrekt?

☐ Ein 50%-PI kann bei dieser schiefen Verteilung den wahrscheinlichsten Parameterwert ($\pi = 1$) ausschließen, ein 50%-HDI hingegen nicht.

☐ PI und HDI schließen bei schiefen Verteilungen grundsätzlich immer denselben Wertebereich ein.

☐ Ein PI schneidet an beiden Rändern unterschiedlich viel Wahrscheinlichkeitsmasse ab, ein HDI immer exakt gleich viel.

☐ Ein HDI ist per Definition stets breiter als ein PI derselben Wahrscheinlichkeitsmasse.

☐ Bei symmetrischen Post-Verteilungen unterscheiden sich PI und HDI stark voneinander, bei schiefen Verteilungen sind sie hingegen identisch.



Für die Stichproben-Post-Verteilung eines Globusversuchs liefert der Befehl `quantile(p_grid, p = .9)` den Wert 0,78. Welche Interpretation dieses Ergebnisses ist korrekt?

☐ Der wahrscheinlichste Parameterwert (der Modus der Post-Verteilung) liegt bei 0,78.

☐ Der Mittelwert der Post-Verteilung liegt bei 0,78.

☐ Der tatsächliche Wasseranteil der Erde beträgt mit Sicherheit höchstens 78%.

- ☐ 90% der gezogenen Stichproben haben exakt den Wert 0,78.
- ☐ Laut dem Modell liegen 90% der Post-Wahrscheinlichkeitsmasse bei Parameterwerten kleiner oder gleich 0,78; nur 10% der Wahrscheinlichkeitsmasse entfallen auf Werte darüber.



Um aus einer Bayesbox eine Stichproben-Post-Verteilung zu erzeugen, verwendet man in R den Befehl `slice_sample(n = 1e4, weight_by = post, replace = TRUE)`. Welche Aussage zur Rolle der Argumente `weight_by` und `replace` ist korrekt?

- ☐ `weight_by = post` sorgt dafür, dass Parameterwerte mit höherer Post-Wahrscheinlichkeit häufiger gezogen werden; `replace = TRUE` erlaubt, denselben Parameterwert mehrfach zu ziehen, sodass die Ziehungswahrscheinlichkeiten während des gesamten Ziehungsprozesses konstant bleiben.
- ☐ Ohne `replace = TRUE` könnte man aus einer Bayesbox mit 11 Gitterwerten gar keine 10.000 Stichproben ziehen – mit `replace = TRUE` wird dieses Problem behoben, hat aber sonst keinen Einfluss auf die resultierende Verteilung.
- ☐ `weight_by` legt fest, wie viele Stichproben insgesamt gezogen werden.
- ☐ `replace = TRUE` bedeutet, dass jeder Parameterwert höchstens einmal gezogen werden darf.
- ☐ `weight_by = post` sorgt dafür, dass jeder Parameterwert exakt gleich oft gezogen wird, unabhängig von seiner Post-Wahrscheinlichkeit.



Bei der Post-Verteilung eines Globusversuchs mit $W = 3$ Treffern bei $N = 3$ Würfeln liegt der Modus (wahrscheinlichster Wert) bei $\pi = 1$, während Mittelwert und Median der Post-Verteilung deutlich darunter liegen. Welche Aussage zum Zusammenhang von Schiefe und den drei Lageparametern (Mittelwert, Median, Modus) ist korrekt?

- ☐ Bei einer schiefen Verteilung ist der Modus immer der kleinste der drei Lageparameter.
- ☐ Je unsymmetrischer (schiefer) eine Post-Verteilung ist, desto weiter liegen Mittelwert, Median und Modus tendenziell auseinander.
- ☐ Der Median reagiert bei schiefen Verteilungen genauso empfindlich auf extreme Randwerte wie der Mittelwert.
- ☐ Der Mittelwert ist bei schiefen Post-Verteilungen grundsätzlich der am besten geeignete Punktschätzer, da er alle Datenpunkte berücksichtigt.
- ☐ Mittelwert, Median und Modus sind bei jeder Post-Verteilung – unabhängig von deren Form – stets identisch.



Was ist per Definition das entscheidende Kennzeichen eines Intervalls höchster Dichte (Highest Density Interval, HDI)?

- ☐ Es existiert per Definition nur bei symmetrischen, eingipfligen Post-Verteilungen.
- ☐ Es ist – bezogen auf eine gegebene Wahrscheinlichkeitsmasse (z.B. 50%) – das schmalste mögliche Intervall, das diese Wahrscheinlichkeitsmasse enthält.
- ☐ Es ist per Definition immer symmetrisch um den Mittelwert der Verteilung angeordnet.
- ☐ Es enthält per Definition niemals den wahrscheinlichsten Parameterwert (den Modus) der Verteilung.
- ☐ Es schneidet an beiden Rändern der Verteilung stets exakt gleich viel Wahrscheinlichkeitsmasse ab.




Um die Ungewissheit einer Post-Verteilung zu beschreiben, könnte man klassische Streuungsmaße wie Standardabweichung (SD), Interquartilsabstand (IQR) oder mittlere absolute Abweichung (MAD) berechnen. In der Bayes-Statistik werden stattdessen aber meist Intervalle wie das HDI oder PI berichtet. Welche Aussage dazu ist am ehesten zutreffend?

- ☐ HDI und PI sind nur alternative Namen für dieselbe Größe wie die Standardabweichung.
- ☐ Ein Interquartilsabstand (IQR) kann keine sinnvolle Information zur Ungewissheit einer Post-Verteilung liefern.
- ☐ Streuungsmaße wie die Standardabweichung lassen sich bei einer Post-Verteilung grundsätzlich nicht berechnen.
- ☐ Intervalle wie HDI oder PI geben zusätzlich zur reinen Streuungsgröße auch konkrete, inhaltlich interpretierbare Grenzwerte des Parameters an (z.B. “zwischen 0,67 und 0,78”), während ein einzelner Streuungswert (z.B. $SD = 0,15$) diese Information nicht direkt liefert.
- ☐ Die Angabe eines Intervalls (wie HDI oder PI) ist grundsätzlich informationsärmer als die Angabe eines einzelnen Streuungsmaßes wie der SD.



8.8 -



1. Die Anzahl g der Gitterwerte ist nicht Teil des Modells; die Anzahl der Gitterwerte entscheiden nur über die Genauigkeit der Post-Verteilung. ↩
2. Vorsicht beim Ausdrucken. ↩
3. auch Grid-Methode genannt ↩

4. Eine gute Einführung in die Hintergründe findet sich bei McElreath (2020). [↩](#)
5. Tatsächlich gibt es eine Vielzahl an Begriffen, die in der Literatur nicht immer konsistent verwendet werden, etwa Kompatibilitätsintervall, Ungewissheitsintervall, Passungsbereich. [↩](#)
6. Hier auf Basis der Post-Verteilung `samples_6w_9v`. [↩](#)
7. d.h. die *Dezile* [↩](#)
8. Auch als *Highest Density Posterior Interval* (HDPI) bezeichnet. [↩](#)