

9 Gauss-Modelle



Bayes:Start!

9.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- ein Gaußmodell spezifizieren und in R berechnen
- an Beispielen verdeutlichen, wie sich eine vage bzw. eine informationsreiche Priori-Verteilung auf die Posteriori-Verteilung auswirkt

Der Stoff dieses Kapitels orientiert sich an McElreath (2020), Kap. 4.1 bis 4.3. Im YouTube-Kanal des Autors finden sich passende Videos wie  [Teil 1](#) und  [Teil 2](#).

Lesen Sie zur Vorbereitung folgende Kapitel im Eigenstudium:

- [Statistik1, Kap. "Modellgüte"](#)
- [Statistik1, Kap. "Punktmodelle 2"](#)
- [Statistik1, Abschnitt "Normalverteilung"](#)

In diesem Kapitel werden die folgenden R-Pakete benötigt:


Hinweis

Software, und das sind R-Pakete, müssen Sie nur einmalig installieren. Aber bei jedem Start von R bzw. RStudio müssen Sie die (benötigten!) Pakete starten.

```
library(tidyverse) # Datenjudo
library(rstanarm)  # Bayes-Modelle berechnen
library(easystats) # Statistik-Komfort
library(DataExplorer) # Daten verbildlichen
library(ggpubr)    # Daten verbildlichen
library(hexbin)    # stat_bin_hex ggplot2
```

Wichtig

Ab diesem Kapitel benötigen Sie *Stan*, das ist das R-Paket `rstanarm`. ☐



Hallo, Leute! Ich bin Stan! Ich mache hier die Schwerarbeit.

Wir benötigen den Datensatz *!Kung* aus der Datei `Howell1a.csv`. Quelle der Daten ist McElreath (2020) mit Bezug auf Howell.

```
Kung_path <-  
  "https://raw.githubusercontent.com/sebastiansauer/Lehre/main/data/Howell1a.csv"  
  
kung <- read.csv(Kung_path)  
  
head(kung, n = 5)
```

[Datenquelle](#)

[↓ DOWNLOAD CSV](#)[↓ DOWNLOAD XLSX](#)

i Hinweis

Die Folien zu diesem Kapitel finden Sie [hier](#).

9.2 Einstieg

Beispiel 9.1 (Was war noch mal eine Normalverteilung?) In diesem Kapitel benötigen Sie ein gutes Verständnis der Normalverteilung (die auch als Gauss-Verteilung bezeichnet wird). Fassen Sie daher die wesentlichen Aspekte der Normalverteilung (soweit im Unterricht behandelt) zusammen! ☐

Beispiel 9.2 (Was war noch mal eine Posteriori-Verteilung?) In diesem Kapitel befragen wir die Post-Verteilung für eine normalverteilte Zufallsvariable, nämlich die Körpergröße der *!Kung* San. Was war noch mal eine Post-Verteilung und wozu ist sie gut? ☐

9.3 Wie groß sind die *!Kung* San?

Dieser Abschnitt basiert auf McElreath (2020), Kap. 4.3.

9.3.1 *!Kung* San

In diesem Abschnitt untersuchen wir eine Forschungsfrage in Zusammenhang mit dem Volk der *!Kung*.

The !Kung are one of the San peoples who live mostly on the western edge of the Kalahari desert, Ovamboland (northern Namibia and southern Angola), and Botswana. The names !Kung (!Xun) and Ju are variant words for ‘people’, preferred by different !Kung groups. This band level society used traditional methods of hunting and gathering for subsistence up until the 1970s. Today, the great majority of !Kung people live in the villages of Bantu pastoralists and European ranchers.

Quelle

Wir interessieren uns für die Größe der erwachsenen !Kung, also filtern wir die Daten entsprechend und speichern die neue Tabelle als `kung_erwachsen`.

```
kung_erwachsen <- kung %>%  
  filter(age >= 18)  
  
nrow(kung_erwachsen)  
## [1] 352
```

$N = 352$.

Lassen wir uns einige typische deskriptive Statistiken zum Datensatz ausgeben. `{easystats}` macht das tatsächlich recht easy, s. [Tabelle 9.1](#).

```
describe_distribution(kung_erwachsen)
```

Tabelle 9.1: Statistiken der metrischen Variablen im Kung-Datensatz

Variable	Mean	SD	IQR	Min	Max	Skewness	Kurtosis	n	n_Missing
height	154.60	7.74	12.06	136.53	179.07	0.15	-0.48	352.00	0
weight	44.99	6.46	9.19	31.07	62.99	0.13	-0.51	352.00	0
age	41.14	15.97	23.00	18.00	88.00	0.67	-0.21	352.00	0
male	0.47	0.50	1.00	0.00	1.00	0.13	-2.00	352.00	0

Die Verteilungen lassen sich mit `plot_density` (aus `{DataExplorer}`), s. [Abbildung 9.1](#).

```
plot_density(kung_erwachsen)
```




Abbildung 9.1: Verteilungen der Variablen im Kung-Datensatz. Größe und Gewicht sind recht symmetrisch bzw. normalverteilt; Alter ist rechtsschief.

9.3.2 Wir gehen apriori von normalverteilter Größe der !Kung aus

Forschungsfrage: Wie groß sind die erwachsenen !Kung im *Durchschnitt*?

Wir interessieren uns also für den Mittelwert der Körpergröße einer erwachsenen !Kung-Person, μ . Der Einfachheit halber gehen wir davon aus, dass Frauen und Männer im Schnitt gleich groß sind.



Mensch, [Wikimedia Commons](#)¹

9.4 Unser Gauss-Modell der !Kung

9.4.1 Normalverteilung als Grundlage des Modells

Hier gehen wir von einer Normalverteilung (synonym: “Gauss-Verteilung”) des Populationsmittelwert, μ , sowie der tatsächlichen Körpergrößen der einzelnen Personen, h_i (h wie *height*) aus.

Zur Erinnerung: Die (unstandardisierte) Post-Verteilung ist das Produkt von Apriori und Likelihood, s. [Abbildung 9.2](#). Im Folgenden gehen wir diese Bestimmungsstücke der Reihe nach durch, in gewohnter Manier.



Abbildung 9.2: Apriori mal Likelihood ist gleich der unstandardisierten Post-Verteilung

Nur dass wir dieses Mal die Bayesbox nicht von Hand berechnen, sondern Stan die Arbeit überlassen. Stan liefert uns brav eine Stichproben-Post-Verteilung zurück.



Ich berechne dir die Stichproben-Postverteilung, ganz ohne Bayesbox!



Toll, dann hab ich ja nix zu tun!

9.4.2 Apriori-Verteilungen

Wir haben zwei Apriori-Größen (Parameter):

1. Den *Mittelwert* der Körpergrößen in der Population, μ . Dieser Parameter beantwortet die Frage: “Wie groß sind die erwachsenen !Kung im Durchschnitt?”
2. Die *Streuung* der tatsächlichen Körpergrößen um den Mittelwert der Population herum, σ . Dieser Parameter beantwortet die Frage: “Wie unterschiedlich groß sind die erwachsenen !Kung?”

Apriori-Verteilung für μ : Der Mittelwert der Körpergröße, μ , sei *normalverteilt* mit $\mu = 178$ und $\sigma = 20$:

$$\mu \sim \mathcal{N}(178, 20) \quad \text{Prior}$$

Apriori-Verteilung für σ : Die Streuung der Größen, σ , sei *exponentialverteilt* (da notwendig positiv) mit $\lambda = 1/8$


.

$$\sigma \sim \mathcal{E}(1/8) \quad \text{Prior}$$

Warum gerade $\lambda = 1/8$? Das ist einfach ein grobes Abschätzen mit Blick auf [Abbildung 6.9](#): Bei $\lambda = 1/8$ liegt der Median bei ca. 5 cm. Eine Streuung von ca. 5 cm um den Mittelwert herum erscheint nicht ganz falsch. Dann kann man folgern: $95\%KI(\mu) : 178 \pm 40$. In Worten: 95% der erwachsenen !Kung sind zwischen 138 cm und 218 cm groß - laut unserem Modell (unserer Apriori-Verteilung). Das ist ein ausreichend großer Bereich, um Überraschungen zuzulassen, aber eng genug, um biologisch unmögliche Werte auszuschließen.


In [Abbildung 9.3](#) sind unsere Priori-Verteilungen visualisiert.

`mu ~ dnorm(178, 20)`



(a) Priori der mittleren Körpergröße

$\sigma \sim \text{dexp}(0.1)$



Streuung der Körpergrößen, σ

(b) Priori der Schätzungenauigkeit

Abbildung 9.3: Prioris unseres (ersten) Kung-Modells (`m_kung`)

Hinweis

Dieses Modell hat zwei Parameter, μ und σ . ☐

Warum 178 cm? Kein besonderer Grund. Hier wollen wir den Effekt verschiedener Priori-Werte untersuchen.² In einer echten Untersuchung sollte man einen inhaltlichen Grund für einen Priori-Wert haben. Oder man wählt “schwach informative” Prioris, wie das `{rstanarm}` im Standard tut: Damit lässt man kaum Vorab-Information in das Modell einfließen, aber man verhindert extreme Prioris, die meistens unsinnig sind (so wie eine SD von 100 Metern bei der Körpergröße).

Hinweis

Wir haben zwar vorab nicht viel Wissen, aber auch nicht gar keines: Eine Gleichverteilung der Körpergrößen kommt nicht in Frage und ein vages Wissen zum Mittelwert haben wir auch. Darüber hinaus ist eine Normalverteilung für Körpergröße biologisch nicht unplausibel und spiegelt sich in den Daten wider, s. [Abbildung 9.1](#).

9.4.3 Likelihood

Für viele Ausprägungen von μ und σ müssen wir (bzw. Stan) die jeweilige Likelihood berechnen. Z.B. ist zu fragen, wie groß die Wahrscheinlichkeit ist, dass wir einen !Kung finden mit Körpergröße 190 bis 191 cm ($h_i = [190, 191]$), gegeben der Hypothesen (Parameterwerte), dass der Populationsmittelwert $\mu = 170$ cm und der Streuung der Körpergrößen $\sigma = 10$ cm beträgt. Nehmen wir an, dass die Körpergrößen, h_i normalverteilt sind, dann können wir die Likelihood anhand der Quantile der Normalverteilung berechnen. Etwa so:

$$L = \text{Pr}(h_i = [190; 191] \mid \mu = 180, \sigma = 10)$$

Aber da wir das Rechnen an Stan geben, begnügen wir uns mit einer Kurz-Schreibweise

$$h_i \sim \mathcal{N}(\mu, \sigma) \quad \text{Likelihood}$$

Lies: “Die Körpergröße ist normalverteilt mit Mittelwert μ und Streuung σ .” Stan weiß dann, was er zu tun hat. Für die Post-Verteilung muss Stan für alle plausiblen Kombinationen von μ und σ die Likelihoods berechnen, s. [Abbildung 9.4](#).




Abbildung 9.4: Die Verteilung der Körpergrößen, h_i setzt sich aus zwei Verteilungen zusammen: Dem Mittelwert μ und der exponentialverteilten Streuung σ

Jetzt haben wir unser Modell (`m_kung`) definiert!

Weil es so schön ist, schreiben/zeichnen wir es hier noch einmal auf, [Gleichung 9.1](#).

$$\begin{array}{ll}
 \mu \sim \mathcal{N}(M = 178, S = 20) & \text{Prior} \\
 \sigma \sim \mathcal{E}(1/8) & \text{Prior} \\
 h_i \sim \mathcal{N}(\mu, \sigma) & \text{Likelihood}
 \end{array} \tag{9.1}$$

9.4.4 Post-Verteilung berechnen mit Stan

Zur Berechnung von `m_kung` nutzen wir jetzt dieses Mal aber *nicht* die Bayesbox, sondern lassen Stan (in R) die Arbeit verrichten.

Okay, Stan, du Golem unseres Vertrauens! An die Arbeit! Berechne uns das Kung-Modell!

```
# library(rstanarm) # nicht vergessen, das Paket zu starten
m_kung <-
  stan_glm(height ~ 1,
    prior_intercept = normal(178, 20),
    prior_aux = exponential(1/8),
    refresh = 0,
    data = kung_erwachsen)

m_kung_post <- as_tibble(m_kung)
names(m_kung_post) <- c("mu", "sigma")
```



Mit `stan_glm` rufen wir Stan zur Arbeit. `stan_glm`³ ist eine Funktion, mit der man Regressionsmodelle berechnen kann. Nun haben wir in diesem Fall kein “richtiges” Regressionsmodell. Man könnte sagen, wir haben eine AV (Körpergröße), aber keine UV (keine Prädiktoren). Glücklicherweise können wir auch solche “armen” Regressionsmodelle formulieren: `av ~ 1` bzw. in unserem Beispiel `height ~ 1` bedeutet, dass man nur die Verteilung der AV berechnen möchte, aber keine Prädiktoren hat (das soll die `1` symbolisieren).

Betrachten wir die Post-Verteilungen von μ und von σ , s. [Abbildung 9.5](#).




Abbildung 9.5: Die beiden Randverteilungen der Post-Verteilungen, d.h. die Verteilungen für μ und für σ

Plotten wir mal die *gemeinsame* Post-Verteilung von `m_kung`, s. [Abbildung 9.6](#), also die Kombinationen, die “Pärchen” der Werte von Mittelwert und Streuung.

Fliesendiagramm

Streudiagramm

Histogramm

Gemeinsame Post-Verteilung von Mittelwert, μ und Streuung, σ

```
m_kung_post %>%
  ggplot() +
  aes(x = mu, y = sigma) %>%
  geom_hex() +
  scale_fill_viridis_c()
```




Abbildung 9.6: Die gemeinsame Post-Verteilung von Mittelwert und Streuung von `m_kung_neue_prioris`

Da das Modell *zwei* Parameter hat, können wir auch beide gleichzeitig plotten. Wie man sieht, sind die beiden Parameter unkorreliert. In anderen Modellen können die Parameter korreliert sein. [Abbildung 9.6](#) erlaubt uns, für *jede Kombination von Mittelwert und Streuung* zu fragen, wie wahrscheinlich diese bestimmte Kombination ist.

Fassen wir die Ergebnisse dieses Modells zusammen:

- Wir bekommen eine Wahrscheinlichkeitsverteilung für μ und eine für σ (bzw. eine zweidimensionale Verteilung, für die μ, σ -Paare).
- Trotz des eher vagen Priors ist die Streuung der Posteriori-Werte für μ und σ klein: Die große Stichprobe hat die Priori-Werte überstimmt.
- Ziehen wir Stichproben aus der Posteriori-Verteilung, so können wir interessante Fragen stellen.

9.5 Hallo, Posteriori-Verteilung

... wir hätten da mal ein paar Fragen an Sie. 🧐

1. Mit welcher Wahrscheinlichkeit ist die *mittlere* !Kung-Person größer als 1,55m?
2. Welche mittlere Körpergröße wird mit 95% Wahrscheinlichkeit nicht überschritten, laut dem Modell?
3. In welchem 90%-PI liegt μ vermutlich?
4. Mit welcher Unsicherheit ist die Schätzung der mittleren Körpergröße behaftet?
5. Was ist der mediane Schätzwert der mittleren Körpergröße, sozusagen der “Best Guess”?

Antworten folgen etwas weiter unten.

9.5.1 Posteriori-Stichproben von `stan_glm()` berechnen lassen

Mit `stan_glm()` können wir komfortabel die Posteriori-Verteilung berechnen. Die Gittermethode wird nicht verwendet, aber die Ergebnisse sind - für unsere Fälle - ähnlich. Es werden aber auch viele Stichproben simuliert (sog. MCMC-Methode).

Grob gesagt berechnen wir die Post-Verteilung mit `stan_glm` so: `stan_glm(AV ~ UV, data = meine_daten)`.

Wir können, wie wir es oben getan haben, uns die Stichproben der Post-Verteilung ausgeben lassen, und diese z.B. plotten.

Wir können es aber auch komfortabler haben ... Mit dem Befehl `parameters` kann man sich die geschätzten Parameterwerte einfach ausgeben lassen (s. [Abbildung 9.6](#)).

```
parameters(m_kung) # aus Paket `easystats`
```

Parameter	Median	95% CI	pd	Rhat	ESS (tail)	Prior
(Intercept)	154.61	(153.81, 155.43)	100%	1.000	2129	Normal (178 +- 20)

Das Wesentliche: Unser Golem schätzt den Größenmittelwert der Kung auf ca. 155cm bzw. auf einen Bereich von etwa 153.81 bis 155.43 (95%-ETI in der Voreinstellung⁴). Informativ ist vielleicht noch, dass wir den `Prior` erfahren, der im Modell verwendet wurde. Dazu später mehr.

Hinweis

In dieser Ausgabe sind ein paar Angaben, die wir nicht verstehen, wie `pd`, `Rhat` und `ESS`. Kein Problem: Einfach ignorieren 😊 Wer Näheres wissen will, findet [hier](#) einen Anfang. Außerdem sei an McElreath (2020) und Gelman et al. (2021) verwiesen. □

9.6 Wie tickt `stan_glm()`?



Stan

[Quelle](#)



Hallo Leute!

Mehr findet sich in der [Dokumentation von RstanArm](#).

Hier ein paar Kerninfos zu `stan_glm`:

- *Stan* ist eine Software zur Berechnung von Bayesmodellen; das Paket `rstanarm` stellt Stan für uns bereit.
- `stan_glm()` ist für die Berechnung von Regressionsmodellen ausgelegt.
- Will man nur die Verteilung einer einzelnen Variablen (wie `heights`) schätzen, so hat man ... eine Regression ohne Prädiktor.
- Eine Regression ohne Prädiktor schreibt man auf Errisch so: `y ~ 1`. Die `1` steht also für die nicht vorhandene UV; `y` meint die AV (`height`).
- `(Intercept)` (Achsenabschnitt) gibt den Mittelwert an.

9.6.1 Schätzwerte zu den Modellparameter

Die Parameter eines Modells sind die Größen, für die wir eine Priori-Verteilung annehmen. Außerdem wählen wir die Normalverteilung als Likelihood-Verteilung, so dass wir die Likelihood berechnen können. Auf dieser Basis schätzen wir dann die Post-Verteilung. Ich sage *schätzen*, um hervorzuheben, dass wir die wahren Werte nicht kennen, sondern nur eine Vermutung haben, unsere Ungewissheit vorab also (wie immer) in der Priori-Verteilung festnageln und unsere Ungewissheit nach Kenntnis der Daten in der Posteriori-Verteilung quantifizieren. Wie gerade gesehen, lassen sich die Modellparameter (bzw. genauer gesagt deren Schätzungen) einfach mit `parameters(modellname)` auslesen.

9.6.2 Stichproben aus der Posteriori-Verteilung ziehen

Wie wir es vom Globusversuch gewohnt sind, können wir aber auch Stichproben aus der Post-Verteilung ziehen.

Hier die ersten paar Zeilen von `m_kung_post`:

```
head(m_kung_post)
```

In einer Regression ohne Prädiktoren entspricht der Achsenabschnitt dem Mittelwert der AV, daher gibt uns die Spalte `(Intercept)` Aufschluss über unsere Schätzwerte zu μ (der Körpergröße).

Übungsaufgabe 9.1 (Mit welcher Wahrscheinlichkeit ist $\mu > 155$?)

Lösung



Übungsaufgabe 9.2 (Mit welcher Wahrscheinlichkeit ist $\mu > 165$?)

Lösung



Beispiel 9.3 (Welche mittlere Körpergröße wird mit 95% Wahrscheinlichkeit nicht überschritten, laut dem Modell `m_kung`?)

Lösung



Übungsaufgabe 9.3 (In welchem 90%-PI liegt μ vermutlich?)

Lösung



Übungsaufgabe 9.4 (Mit welcher Unsicherheit ist die Schätzung der mittleren Körpergröße behaftet?)

Lösung



Übungsaufgabe 9.5 (Was ist der mediane Schätzwert der mittleren Körpergröße, sozusagen der “Best Guess”?)

Lösung



🤖 Ähnliche Fragen bleiben als Übung für die Lesis. 😊

9.6.3 Standard-Prioriwerte bei `stan_glm()`

Man kann `stan_glm()` auch ohne Priori-Werte aufrufen. In dem Fall bestimmt Stan die Priori-Werte selber. Welche das sind, kann man sich so anzeigen lassen:

```
prior_summary(m_kung)
## Priors for model 'm_kung'
## -----
## Intercept (after predictors centered)
## ~ normal(location = 178, scale = 20)
##
## Auxiliary (sigma)
## ~ exponential(rate = 0.12)
## -----
## See help('prior_summary.stanreg') for more details
```

Aber welche Priori-Werte verwendet Stan? Ganz einfach: Stan zieht die Stichproben-Daten als Prioris heran. Strenggenommen ist das nicht “pures Bayes”, weil die Priori-Werte ja *vorab*, also vor Kenntnis der Daten bestimmt werden sollen.

Man sollte diese Standardwerte als (komfortablen) Minimalvorschlag sehen. Kennt man sich im Sachgebiet aus, kann man meist bessere Prioris finden. Die Voreinstellung ist nicht zwingend; andere Werte wären auch

denkbar.

Standardwerte von `stan_glm`

- **Intercept** : μ , der Mittelwert der Verteilung Y
 - $\mu \sim \mathcal{N}(\bar{Y}, sd(Y) \cdot 2.5)$
 - als Streuung von μ wird die 2.5-fache Streuung der Stichprobe (für Y) angenommen.
- **Auxiliary (sigma)** : σ , die Streuung der Verteilung Y
 - $\sigma \sim \mathcal{E}(\lambda = 1/sd(Y))$
 - als “Streuung”, d.h. λ von h_i wird $\frac{1}{sd(Y)}$ angenommen. $\square$

Eine sinnvolle Strategie ist, einen Prior so zu wählen, dass man nicht übergewiss ist, also nicht zu sicher Dinge behauptet, die dann vielleicht doch passieren (also die Ungewissheit zu gering spezifiziert), andererseits sollte man extreme, unplausible Werte ausschließen.

Wichtig

Bei der Wahl der Prioris gibt es nicht die eine, richtige Wahl. Die beste Entscheidung ist auf transparente Art den Stand der Forschung einfließen zu lassen und eigene Entscheidungen zu begründen. Häufig sind mehrere Entscheidungen möglich. Möchte man lieber vorsichtig sein, weil man wenig über den Gegenstand weiß, dann könnte man z.B. auf die Voreinstellung von `rstanarm` vertrauen, die “schwachinformativ” ist, also nur wenig Priori-Information in das Modell einfließen lässt.

9.6.4 Wenn es schnell gehen muss

`stan_glm()` ist deutlich langsamer als z.B. der befreundete Golem `lm()`. Der Grund für Stans Langsamkeit ist, dass er viele Stichproben zieht, also viel zu zählen hat. Außerdem wiederholt er das Stichprobenziehen (im Standard) 4 Mal, damit sein Meister prüfen kann, ob er (Stan) die Arbeit auch immer richtig gemacht hat. Die Idee dabei ist: Wenn alle vier Durchführungen (auch “Ketten”, engl. “chains”, genannt) zum etwa gleichen Ergebnis kommen, dann wird schon alles mit rechten Dingen zugegangen sein. Weichen die Ergebnisse der 4 Ketten voneinander ab, so ist Stan ein Fehler unterlaufen, oder irgendetwas ist “dumm gelaufen”. An dieser Stelle schauen wir uns die Ketten nicht näher an, aber es sei notiert, dass man die Anzahl der Ketten mit dem Argument `chains` steuern kann. Möchte man, dass Stan sich beeilt, so kann man `chains = 1` setzen, das spart Zeit, s. `m_kung_1kette`.

```
m_kung_1kette <- stan_glm(height ~ 1,
  data = kung_erwachsen,
  chains = 1, # nur 1 Kette, anstelle von 4 im Default, spart Zeit
  refresh = 0)

parameters(m_kung_1kette)
```

9.7 Modell `m_kung_neue_priors` : Standard-Priori-Werte

Im Modell `m_kung` haben wir unsere eigenen Priori-Werte einfließen lassen. Jetzt vertrauen wir die Wahl der Prioris Stan an. Betrachten Sie dazu unser zweites Kung-Modell, `m_kung_neue_priors`.

```
m_kung_neue_priors <-
  stan_glm(height ~ 1,
    refresh = FALSE, # bitte nicht so viel Ausgabe drucken
```



```
data = kung_erwachsen)
parameters(m_kung_neue_priors)
```

Tabelle 9.2: Parameter von m_kung_neue_priors mit Standard-prioriwerten

Parameter	Median	95% CI	pd	Rhat	ESS (tail)	Prior
(Intercept)	154.60	(153.78, 155.42)	100%	1.001	2239	Normal (154.60 +- 19.36)

Wir haben noch nicht alle Informationen kennengelernt, die in [Tabelle 9.2](#) ausgegeben werden. Im Zweifel: Einfach ignorieren. Wichtige Fähigkeit im Studium. 🤓

❗ Wichtig

Vergleichen Sie die Parameterwerte von `m_kung` und `m_kung_neue_priors`! Was fällt Ihnen auf? Nichts? Gut! Tatsächlich liefern beide Modelle sehr ähnliche Parameterwerte. Die Prioriwerte waren nicht so wichtig, weil wir genug Daten haben. Hat man einigermaßen viele Daten, so fallen Prioriwerte nicht mehr ins Gewicht, zumindest wenn sie moderat gewählt waren.

9.7.1 Posteriori-Verteilung und Parameter plotten

Leider liefert der Stan-Golem keinen braven Tibble (Tabelle) zurück.

👤 Mensch, Stan, streng dich mal ein bisschen an!

🤖 Mach's halt selber, wenn du es besser kannst!

Daher müssen wir die Ausgabe des Stan-Golems erst in eine schöne Tabelle umwandeln:

```
m_kung_neue_priors_tibble <-
  as_tibble(m_kung_neue_priors)


head(m_kung_neue_priors_tibble)
```

Außerdem ist der Name der ersten Spalte eigentlich unzulässig, da Spaltennamen in R nicht mit Sonderzeichen anfangen dürfen (sondern mit Buchstaben). Daher müssen wir den Namen mit "Samthandschuhen" anpacken. Auf Errisch sind das die Backticks, die wir um den Namen rumwickeln müssen, s. die folgende Syntax.

Mit {ggpubr}

Mit {ggplot}

```
m_kung_neue_priors_tibble |>
  gghistogram(x = "`(Intercept)`") # Aus dem Paket "ggpubr"
```



Als Ausblick: Ein Vergleich mehrerer Priori-Werte wäre auch nützlich, um ein skeptisches Publikum von der Wahl (bzw. der Indifferenz) der gewählten Priori-Werte zu überzeugen.

9.7.2 Welche Körpergrößen erwartet unser Modell

Bisher haben wir untersucht, wie die Verteilung der *mittleren* Körpergrößen, μ , laut unserem Modell aussehen könnte; wir haben uns also mit der Post-Verteilung von μ beschäftigt. Wir könnten aber auch an der Frage der Verteilung der *tatsächlichen* Körpergrößen, h_i , laut Modell, interessiert sein: Wie groß sind sie denn, die !Kung, laut unserem Modell?


Wie wir wissen, liefert unser Stan-Golem eine *Stichproben-Postverteilung*. Wenn wir das Ergebnisobjekt unserer Analyse, `m_kung`, in eine Tabelle (Tibble) umwandeln und (die ersten paar Zeilen) betrachten, sehen wir diese Stichproben:

```
m_kung |> as_tibble() |> head()
```


Laut unserem Modell sind die Körpergrößen, h_i , normalverteilt mit μ und σ . μ wird von Stan, der in Begriffen der Regressionsanalyse denkt, schnöde als `(Intercept)` bezeichnet. Wir könnten jetzt also für jede Zeile eine Normalverteilung berechnen. Und daraus zufällig eine Zahl ziehen. Damit hätten wir dann unsere Verteilung von Körpergrößen laut Modell. Diese Verteilung nennt man auch *Posterior-Prädiktiv-Verteilung*. Prädiktiv daher, weil sie die Werte der Körpergrößen “vorhersagt”.

Wir können uns diese Verteilung auch komfortabel von R ausgeben lassen, s. [Abbildung 9.10](#).

```
pp_check(m_kung)
pp_check(m_kung, "stat")
```



(a) Die dunkle, dicke Dichtekurve zeigt die tatsächliche Verteilung der Körpergrößen im Datensatz. Die hellen, leichten Dichtekurven zeigen die Verteilungen laut der Post-Verteilung unseres Modells.



(b) Der wahre Wert einer Test-Statistik (T), hier der Mittelwert der Körpergrößen, wird mit der Verteilung der Körpergrößen in Bezug gesetzt.


Abbildung 9.10: Die Posterior-Prädiktiv-Verteilung: Die Verteilung der tatsächlichen Körpergrößen auf Basis der Post-Verteilung. Unser Modell stellt die tatsächliche Verteilung ganz gut nach.

9.8 Fazit

9.8.1 Zusammenfassung

Wir haben die Posteriori-Verteilung für ein Gauss-Modell berechnet. Dabei hatten wir ein einfaches Modell mit metrischer Zielvariablen, ohne Prädiktoren, betrachtet. Die Zielvariable, Körpergröße (**height**), haben wir als normalverteilt mit den Parametern μ und σ angenommen. Für μ und σ haben wir jeweils keinen einzelnen (fixen) Wert angenommen, sondern eine Wahrscheinlichkeitsverteilung, der mit der Priori-Verteilung für μ bzw. σ festgelegt ist.

9.8.2 Botschaft von einem Statistiker



♥ Bleiben Sie dran!

! Wichtig

Kontinuierliches Lernen ist der Schlüssel zum Erfolg.

9.9 Vertiefung: Wahl der Priori-Werte

📖 Dieser Abschnitt ist eine VERTIEFUNG und nicht prüfungsrelevant. 📖

9.9.1 Welche Beobachtungen sind auf Basis unseres Modells zu erwarten?

```
n <- 1e4

sim <- tibble(sample_mu =
  rnorm(n,
    mean = 178,
    sd = 20),
  sample_sigma =
    rexp(n,
      rate = 0.1)) %>%
  mutate(height =
    rnorm(n,
```

```

    mean = sample_mu,
    sd    = sample_sigma))

height_sim_sd <-
  sd(sim$height) %>% round()
height_sim_mean <-
  mean(sim$height) %>% round()

```

Was denkt der Golem (`m_kung`) *a priori* von der Größe der !Kung?

Ziehen wir mal ein paar Stichproben auf Basis des Modells. Voilà:


```

p3 <-
  sim %>%
  ggplot(aes(x = height)) +
  geom_density(fill = "grey33") +
  scale_x_continuous(breaks = c(0, 178-3*height_sim_sd, 178, 178+3*height_sim_sd)) +
  scale_y_continuous(NULL, breaks = NULL) +
  labs(title = "height ~ dnorm(mu, sigma)",
       caption = "X-Achse zeigt MW±3SD",
       x = "Größe") +
  theme(panel.grid = element_blank())

```

p3

height ~ dnorm(mu, sigma)



X-Achse zeigt MW±3SD

[Quellcode](#)

9.9.2 Priori-Werte prüfen mit der Priori-Prädiktiv-Verteilung


- Die Priori-Prädiktiv-Verteilung (`sim`) simuliert Beobachtungen (nur) auf Basis der Priori-Annahmen:

$$h_i \sim \mathcal{N}(\mu, \sigma), \mu \sim \mathcal{N}(178, 20), \sigma \sim \mathcal{E}(0.1)$$
- So können wir prüfen, ob die Priori-Werte vernünftig sind.

Die Priori-Prädiktiv-Verteilung zeigt, dass unsere Priori-Werte ziemlich vage sind, also einen zu breiten Bereich an Größenwerten zulassen:

p3

height ~ dnorm(mu, sigma)



X-Achse zeigt MW±3SD

Anteil $h_i > 200$:


```
anteil_großer_kung <-  
sim %>%  
  count( height > 200) %>%  
  mutate(prop = n/sum(n))  
anteil_großer_kung
```

🤔 Sehr große Buschleute? 17 Prozent sind größer als 2 Meter. Das ist diskutabel, muss aber nicht zwangsläufig ein schlechter Prior sein.


9.9.3 Vorhersagen der Priori-Werte

$\mu \sim \text{dnorm}(178, 20)$

$\sigma \sim \text{dexp}(0.1)$




Mittelwert der Körpergröße, μ



Streuung der Körpergrößen, σ



$\text{height} \sim \text{dnorm}(\mu, \sigma)$




Größe

X-Achse zeigt $\text{MW} \pm 3\text{SD}$

9.9.4 Extrem vage Priori-Verteilung für die Streuung?

$\sigma \sim \mathcal{E}(\lambda = 0.01)$

$\text{height} \sim \text{dnorm}(\mu, \sigma)$
 $\mu \sim \text{dnorm}(178, 100)$
 $\sigma \sim \mathcal{E}(0.01)$



Größe


X-Achse zeigt $\text{MW} \pm 3\text{SD}$

Die Streuung der Größen ist weit:

```
d <-  
  tibble(x = seq(0, 75, by = .01),  
         y = dexp(x, rate = .01))
```

```
d %>%
```

```
ggplot(aes(x,y)) +  
geom_line()
```



😞 Das Modell geht apriori von ein paar Prozent Menschen mit *negativer* Größe aus. Ein Haufen Riesen 🐉 werden bei den !Kung auch erwartet.

🤖 Vage (flache, informationslose, “neutrale”, “objektive”) Priori-Werte machen oft keinen Sinn, weil sie extreme, unplausible Werte zulassen.

9.10 Aufgaben

9.10.1 Papier-und-Bleistift-Aufgaben

1. [exp-tab](#)
2. [exp-tab2](#)
3. [norms-sd](#)
4. [small-wide-normal](#)
5. [exp1](#)
6. [distros](#)
7. [mtcars-post_paper](#)
8. [groesse03](#)
9. [pupil-size2](#)
10. [groesse04](#)
11. [ReThink4e2](#)
12. [Priorwahl1](#)

9.10.2 Aufgaben, für die man einen Computer benötigt

1. [stan_glm01](#)
2. [ReThink4e1](#)

3. [ReThink4e3](#)
4. [Kung-height](#)
5. [Pupil-size](#)
6. [IQ-Studentis](#)
7. [Priori-Streuung](#)

9.10.3 Quiz-Aufgaben

Hier finden Sie Single-Choice-Aufgaben zu diesem Kapitel. Wählen Sie eine Antwort aus und klicken Sie auf das Häkchen, um sie zu überprüfen; über das Fragezeichen erhalten Sie die ausführliche Lösung.

Das Kung-Modell aus dem Kapitel ist wie folgt spezifiziert:

$\mu \sim \mathcal{N}(178, 20)$	Prior
$\sigma \sim \mathcal{E}(1/8)$	Prior
$h_i \sim \mathcal{N}(\mu, \sigma)$	Likelihood

Welche Interpretation dieses Modells ist korrekt?

- ☐ μ und σ sind feste, bekannte Zahlen, die im Modell direkt vorgegeben werden, nur h_i ist unsicher.
- ☐ Da σ apriori als exponentialverteilt angenommen wird, kann σ auch negative Werte annehmen.
- ☐ Der *Populationsmittelwert* der Körpergröße, μ , wird apriori als normalverteilt angenommen; die *Streuung* der Körpergrößen, σ , wird apriori als exponentialverteilt angenommen; die *einzelnen Körpergrößen* h_i werden als normalverteilt um μ mit Streuung σ angenommen.
- ☐ Die dritte Zeile besagt, dass jede einzelne Körpergröße h_i exakt dem Wert μ entspricht.
- ☐ Die erste Zeile ($\mu \sim \mathcal{N}(178, 20)$) beschreibt die Verteilung der einzelnen beobachteten Körpergrößen im Datensatz.



Im Kung-Modell wird für den Mittelwert μ eine Normalverteilung, für die Streuung σ hingegen eine Exponentialverteilung als Apriori-Verteilung gewählt. Warum eignet sich die Normalverteilung *nicht* auch für σ ?

- ☐ Weil eine Normalverteilung immer schief ist als eine Exponentialverteilung.
- ☐ Weil sich die Exponentialverteilung inhaltlich besser für Körpergrößen eignet als für Streuungsmaße.
- ☐ Weil die Normalverteilung nur für ganzzahlige Werte definiert ist, σ aber reellwertig sein kann.
- ☐ Weil μ und σ laut Modell exakt denselben Wertebereich haben müssen.
- ☐ Weil σ als Streuungsmaß per Definition nicht negativ werden darf, eine Normalverteilung aber auch negative Werte zulassen würde; die Exponentialverteilung ist hingegen nur für positive Werte definiert.



Im Kapitel wird das Kung-Modell u.a. mit `stan_glm(height ~ 1, ...)` berechnet. Welche Aussage zur Bedeutung von `height ~ 1` und dem resultierenden `(Intercept)` ist korrekt?

- ☐ `height ~ 1` spezifiziert eine Regression ohne Prädiktor (die `1` symbolisiert die fehlende UV); der geschätzte (**Intercept**) entspricht in diesem Sonderfall direkt dem Populationsmittelwert μ der Körpergröße.
- ☐ Die `1` in `height ~ 1` steht für die Anzahl der Post-Verteilungs-Stichproben, die gezogen werden sollen.
- ☐ `stan_glm()` benötigt zwingend mindestens einen Prädiktor; ein Modell ganz ohne UV wie `height ~ 1` ist nicht möglich.
- ☐ Der (**Intercept**) gibt in diesem Modell die Streuung σ der Körpergrößen an, nicht den Mittelwert.
- ☐ `height ~ 1` bedeutet, dass alle Körpergrößen im Modell auf den Wert 1 gesetzt werden.



Im Kapitel werden zwei Kung-Modelle verglichen: `m_kung` (mit selbst gewählten, informativen Priori-Werten $\mu \sim \mathcal{N}(178, 20)$) und `m_kung_neue_prioris` (mit den schwach-informativen Standard-Priori-Werten von `rstanarm`). Beide liefern nahezu identische Ergebnisse für μ und σ . Welche Erklärung dafür ist im Kapitel korrekt?

- ☐ `stan_glm()` ignoriert per Voreinstellung immer die vom Nutzer angegebenen Priori-Werte und verwendet stattdessen automatisch die Standardwerte.
- ☐ Die Ähnlichkeit der Ergebnisse ist ein Zufall und lässt sich nicht systematisch erklären.
- ☐ Bei einer ausreichend großen Stichprobe dominiert die Likelihood (die Daten) die Post-Verteilung so stark, dass unterschiedliche (moderate) Priori-Werte kaum noch ins Gewicht fallen.
- ☐ Die Wahl der Priori-Verteilung hat grundsätzlich, unabhängig von der Stichprobengröße, niemals einen Einfluss auf die Post-Verteilung.
- ☐ Beide Modelle verwenden tatsächlich exakt dieselben Priori-Werte, nur mit unterschiedlichen Namen.



Ruft man `stan_glm()` ohne eigene Priori-Angaben auf, verwendet `rstanarm` als Standard-Priori für die Streuung σ eine Exponentialverteilung mit Rate $\lambda = 1/sd(Y)$. Angenommen, die Standardabweichung der Körpergrößen in der Stichprobe beträgt $sd(Y) = 6,25$ cm. Welchen Ratenparameter λ und welchen Erwartungswert hat die resultierende Standard-Priori für σ ?

- ☐ $\lambda = 2,5 \cdot 6,25 = 15,625$; Erwartungswert $= 1/\lambda \approx 0,064$
- ☐ $\lambda = 1/6,25 = 0,16$; Erwartungswert $= sd(Y)^2 = 39,0625$
- ☐ $\lambda = 1/6,25 = 0,16$; Erwartungswert $= 1/\lambda = 6,25$
- ☐ $\lambda = 1/6,25 = 0,16$; Erwartungswert $= \lambda = 0,16$
- ☐ $\lambda = 6,25$; Erwartungswert $= 1/\lambda = 0,16$



Im Kapitel werden sowohl eine *Priori-Prädiktiv-Verteilung* als auch eine *Posterior-Prädiktiv-Verteilung* (PPV, mit `pp_check()`) verwendet. Worin unterscheiden sich beide?

- ☐ Die Priori-Prädiktiv-Verteilung dient zur Prüfung der Post-Verteilung, die Posterior-Prädiktiv-Verteilung zur Prüfung der Priori-Werte.
- ☐ Die Priori-Prädiktiv-Verteilung simuliert mögliche Beobachtungen ausschließlich auf Basis der Priori-Annahmen, *bevor* die Daten berücksichtigt wurden; die Posterior-Prädiktiv-Verteilung simuliert Beobachtungen auf Basis der Post-Verteilung, also *nach* Einbeziehung der Daten.
- ☐ Die Priori-Prädiktiv-Verteilung wird aus den beobachteten Daten berechnet, die Posterior-Prädiktiv-Verteilung hingegen ganz ohne Bezug zu den Daten.
- ☐ Nur die Posterior-Prädiktiv-Verteilung lässt sich in R überhaupt berechnen, die Priori-Prädiktiv-Verteilung ist rein theoretisch und nicht simulierbar.
- ☐ Beide Verteilungen sind identisch und unterscheiden sich nur im Namen.



Im Vertiefungsabschnitt wird eine besonders vage Priori für die Streuung getestet, $\sigma \sim \mathcal{E}(\lambda = 0,01)$, kombiniert mit $\mu \sim \mathcal{N}(178, 100)$. Die resultierende Priori-Prädiktiv-Verteilung zeigt, dass ein spürbarer Anteil simulierter Körpergrößen negativ ist und auch unrealistisch riesige Werte vorkommen. Welche Schlussfolgerung zieht das Kapitel daraus?

- ☐ Sehr vage ("flache", informationslose) Priori-Verteilungen sind oft problematisch, weil sie unplausible, teils unmögliche Werte (wie negative Körpergrößen) zulassen – eine gewisse inhaltlich begründete Einschränkung der Priori ist meist sinnvoller.
- ☐ Je vager die Priori-Verteilung, desto genauer wird zwangsläufig die resultierende Post-Verteilung.
- ☐ Das Auftreten negativer Werte in der Priori-Prädiktiv-Verteilung zeigt, dass die Likelihood-Verteilung (Normalverteilung) für Körpergrößen grundsätzlich ungeeignet ist.
- ☐ Negative simulierte Körpergrößen in der Priori-Prädiktiv-Verteilung sind unproblematisch, da sie ohnehin nie in der Post-Verteilung auftauchen können.
- ☐ Vage Priori-Verteilungen sind grundsätzlich immer die beste Wahl, da sie am wenigsten subjektive Annahmen einbringen.



Im Modell `m_kung` wird für σ die Priori-Verteilung $\sigma \sim \mathcal{E}(\lambda = 1/8)$ angenommen. Welchen Wert hat das 95%-Quantil dieser Priori-Verteilung, also `qexp(p = .95, rate = 1/8)`?

- ☐ $Q_{95} = \frac{-\log_{10}(0,05)}{1/8} \approx 10,41$
- ☐ $Q_{95} = \lambda \cdot (-\ln(0,05)) = \frac{1}{8} \cdot (-\ln(0,05)) \approx 0,37$
- ☐ $Q_{95} = \frac{\ln(2)}{1/8} = 8 \cdot \ln(2) \approx 5,55$ (das ist der *Median*, nicht das 95%-Quantil)
- ☐ $Q_{95} = 1/\lambda = 8$ (das ist der *Erwartungswert*, nicht das 95%-Quantil)
- ☐ $Q_{95} = \frac{-\ln(0,05)}{1/8} = 8 \cdot (-\ln(0,05)) \approx 23,97$



`stan_glm()` zieht standardmäßig die Post-Stichproben in 4 unabhängigen “Ketten” (`chains`). Welche Aussage zum Zweck dieser mehrfachen Ketten ist korrekt?

- ☐ Ketten sind nur bei der Bayesbox-Methode relevant, nicht bei der MCMC-Berechnung mit Stan.
- ☐ Die Anzahl der Ketten bestimmt direkt die Anzahl der Beobachtungen im verwendeten Datensatz.
- ☐ Jede zusätzliche Kette berechnet ein anderes, inhaltlich verschiedenes Modell mit unterschiedlichen Priori-Werten.
- ☐ Mehrere unabhängige Ketten dienen als Kontrolle: Kommen alle Ketten zu einem etwa gleichen Ergebnis, spricht das dafür, dass die Berechnung zuverlässig funktioniert hat; weichen die Ketten stark voneinander ab, deutet das auf ein Problem bei der Berechnung hin.
- ☐ Mehr Ketten führen automatisch zu einer anderen (systematisch verzerrten) Post-Verteilung als eine einzelne Kette.



Das Kung-Modell hat zwei Parameter, μ und σ . Neben den beiden einzelnen (Rand-)Verteilungen für μ und σ zeigt das Kapitel auch die *gemeinsame* Post-Verteilung beider Parameter (z.B. als Streudiagramm oder Fliesendiagramm von μ gegen σ). Welche Aussage dazu ist korrekt?

- ☐ Die gemeinsame Post-Verteilung erlaubt es, für jede *Kombination* von μ - und σ -Werten die zugehörige Wahrscheinlichkeit abzulesen; im Kung-Beispiel sind μ und σ dabei unkorreliert.
- ☐ Die Randverteilungen (nur für μ bzw. nur für σ) und die gemeinsame Post-Verteilung enthalten exakt dieselbe Information, nur in unterschiedlicher Formatierung.
- ☐ Da μ und σ im Kung-Beispiel unkorreliert sind, kann man daraus schließen, dass Parameter in Bayes-Modellen grundsätzlich niemals korreliert sein können.
- ☐ Eine gemeinsame Post-Verteilung von zwei Parametern lässt sich grundsätzlich nicht visualisieren, sondern nur einzeln für jeden Parameter getrennt.
- ☐ Die gemeinsame Post-Verteilung zeigt zusätzlich noch einen dritten Parameter, der im Modell gar nicht spezifiziert wurde.





1. Bildquelle: Own alterations and File:SVG_Human_With_All_Organs.svg by Madhero88, CC BY-SA, 3.0 [↩](#)
2. Der Autor des zugrundeliegenden Lehrbuchs, Richard McElreath, gibt 178cm als seine Körpergröße an. [↩](#)
3. aus dem R-Paket `rstanarm`, das zuvor installiert und gestartet sein muss, bevor Sie den Befehl nutzen können. [↩](#)
4. https://easystats.github.io/parameters/reference/model_parameters.brmsfit.html [↩](#)