

10 Einfache lineare Modelle

10.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- Das Zusammenspiel von Apriori-Verteilungen und linearem Modell zur Berechnung der Likelihood erläutern
- die Post-Verteilung für einfache lineare Modelle in R berechnen
- zentrale Informationen zu Modellparametern des Regressionsmodells – wie Lage- oder Streuungsmaße und auch Schätzintervalle - aus der Post-Verteilung herauslesen

Der Stoff dieses Kapitels orientiert sich an McElreath (2020), Kap. 4.4.

Lesen Sie zur Vorbereitung folgende Kapitel im Eigenstudium:

- [Statistik1, Kap. “Geradenmodelle 1”](#)
- [Statistik1, Abschnitt “z-Transformation”](#)

In diesem Kapitel benötigen Sie folgende R-Pakete:

```
library(tidyverse)
library(easystats)
library(rstanarm) # Bayes-Golem
library(ggpubr)   # Datenvisualisierung
```

Da wir in diesem Kapitel immer mal wieder eine Funktion aus dem R-Paket `{easystats}` verwenden: [Hier](#) finden Sie eine Übersicht aller Funktionen des Pakets.¹

In diesem Kapitel benötigen wir den Datensatz zu den !Kung-Leuten, aus der Datei `Howell1a.csv`, McElreath (2020).

DOWNLOAD CSV

DOWNLOAD XLSX

```
Kung_path <- "https://raw.githubusercontent.com/sebastiansauer/Lehre/main/data/Howe ①
kung <- read.csv(Kung_path) ②
kung_erwachsen <- kung %>% filter(age > 18) ③
```

Hinweis

Die Folien zu diesem Kapitel finden Sie [hier](#).

10.2 Einstieg

Übungsaufgabe 10.1 (Grundkonzepte der linearen Regression) Fassen Sie die Grundkonzepte der linearen Regression kurz zusammen! □

Übungsaufgabe 10.2 (Was ist eine Post-Verteilung und wozu ist sie gut?) Erklären Sie kurz, was eine Post-Verteilung ist – insbesondere im Zusammenhang mit den Koeffizienten einer einfachen Regression – und wozu sie gut ist. □

Dieses Kapitel stellt ein einfaches Regressionsmodell vor, bei dem die Körpergröße auf das Gewicht zurückgeführt wird; also ein sehr eingängiges Modell. Neu (im Vergleich zu einer Frequentistischen Regression mit `lm`) ist dabei lediglich, dass die drei Parameter des Modells – β_0 , β_1 , σ – jetzt über eine Post-Verteilung verfügen. Die Post-Verteilung ist der Zusatznutzen der Bayes-Statistik. Die “normale” Regression hat uns nur einzelne Werte für die Modellparameter geliefert (“Punktschätzer”). Mit Bayes haben wir eine ganze Verteilung pro Parameter; das ist informationsreicher als mit der Frequentistischen Regressionsanalyse.

10.3 Den Datensatz verstehen

10.3.1 Statistiken zum !Kung-Datensatz

[Tabelle 10.1](#) zeigt die zentralen deskriptiven Statistiken zum !Kung-Datensatz.

```
Kung_path <- "data/Howell1a.csv"
kung <- read_csv(Kung_path)

kung_erwachsen <- kung %>% filter(age > 18)

describe_distribution(kung_erwachsen)
```

Tabelle 10.1: Verteilung der (metrischen) Variablen im !Kung-Datensatz

Variable	Mean	SD	IQR	Range	Skewness	Kurtosis	n	n_Missing
height	154.64	7.77	12.06	(136.53, 179.07)	0.14	-0.50	346	0
weight	45.05	6.46	9.14	(31.52, 62.99)	0.14	-0.53	346	0
age	41.54	15.81	22.00	(19.00, 88.00)	0.68	-0.20	346	0
male	0.47	0.50	1.00	(0.00, 1.00)	0.10	-2.00	346	0

Wie aus [Tabelle 10.1](#) abzulesen ist, liegt das mittlere Körpergewicht (`weight`) bei ca. 45 kg (SD ca. 7 kg).

Wir brauchen explorative Datenanalyse (EDA) nicht wirklich, um einfache Bayes-Regressionen zu verstehen. Aber EDA hilft, die Daten zu verstehen, was essenziell ist, wenn man Erkenntnisse aus den Daten gewinnen will. Das Paket `DataExplorer` hat ein paar nette Hilfen zur explorativen Datenanalyse.

```
library(DataExplorer)
```

Was man im Rahmen einer EDA stets prüfen sollte, sind fehlende Werte. Gibt es in diesem Datensatz fehlende Werte? Nein, s. Abb. [Abbildung 10.1](#).

```
kung_erwachsen %>% plot_missing()
```




Abbildung 10.1: Fehlende Werte - fehlen.

Betrachten wir als Nächstes die Verteilung der *numerischen* Variablen des Datensatzes, s. [Abbildung 10.2](#).

```
kung_erwachsen %>% plot_histogram()
```




Abbildung 10.2: Verteilung (als Histogramme dargestellt) der numerischen Variablen des Datensatzes

Wie man in [Abbildung 10.2](#) sieht, ist Alter (`age`) rechtsschief verteilt, wohingegen Größe (`height`) und Gewicht (`weight`) deutlich symmetrischer oder sogar normalverteilt sind. `height` ist bimodal (zweigipflig), vermutlich auf Grund der Vermischung der Verteilung der beiden Geschlechter.

Betrachten wir nun die Verteilung der *kategorialen* Variablen des Datensatzes, s. [Abbildung 10.3](#). Es gibt etwas mehr Männer als Frauen im Datensatz.

```
kung_erwachsen |>  
  count(male) |>  
  mutate(Anteil_maenner = n / sum(n))
```

```
kung_erwachsen %>% plot_bar()
```




Abbildung 10.3: Verteilung (als Balkendiagramme dargestellt) der kategorialen Variablen des Datensatzes

Korrelationen sind, ähnlich wie Regressionen, eine Methode, um Zusammenhänge zwischen Variablen darzustellen. Allerdings sind Korrelationen nur zwischen zwei Variablen definiert; Regressionsanalysen können komfortabel mehrere Variablen berücksichtigen. Die Korrelationen der (numerischen) Variablen sind in [Abbildung 10.4](#) dargestellt.

```
kung_erwachsen %>% plot_correlation()
```




Abbildung 10.4: Korrelationsmatrix

Starke Zusammenhänge finden sich (wenig überraschend) zwischen Größe und Gewicht sowie zwischen Geschlecht und Größe/Gewicht.

Übungsaufgabe 10.3 (Vertiefung: EDA-Bericht) Probieren Sie mal die folgende Funktion aus, die Ihnen einen Bericht zur EDA erstellt: `create_report(kung_erwachsen)`. ☐

10.3.2 Der Zusammenhang von Gewicht und Größe

Die (einfache) Regression prüft, inwieweit zwei Variablen, Y und X linear zusammenhängen. Je mehr sie zusammenhängen, desto besser kann man X nutzen, um Y vorherzusagen (und umgekehrt). Hängen X und Y zusammen, heißt das nicht (unbedingt), dass es einen *kausalen* Zusammenhang zwischen X und Y gibt. *Linear* ist ein Zusammenhang, wenn der Zuwachs in Y relativ zu X konstant ist: wenn X um eine Einheit steigt, steigt Y immer um b Einheiten (nicht kausal, sondern deskriptiv gemeint).²

Laden wir die !Kung-Daten und visualisieren wir uns den Zusammenhang zwischen *Gewicht* (X , UV) und *Größe* (Y , AV), [Abbildung 10.5](#).

Mit `ggplot2`

Mit `ggpubr`

```
kung_erwachsen %>%
  ggplot(
    aes(x = weight, y = height)) +
  geom_point(alpha = .7) +
  geom_smooth(method = "lm")
```




Abbildung 10.5: Der Zusammenhang zwischen Gewicht (X) und Größe (Y)

Wie man sieht in [Abbildung 10.5](#), gibt es einen deutlichen linearen Zusammenhang zwischen Gewicht und Größe: Je schwerer (je höher das Gewicht einer Person), desto größer (desto höher ihr Wert in der Körpergröße).

10.3.3 Prädiktor zentrieren

i Hinweis

Wenn Sie mit der z-Transformation nicht vertraut sind, macht es Sinn, das Thema (jetzt) zu lernen, s. [hier](#). □

Zieht man von jedem Gewichtswert den Mittelwert ab, so bekommt man die Abweichung des Gewichts vom Mittelwert; der Prädiktor ist dann *zentriert* (engl. to center). Wenn man den Prädiktor *Gewicht* (`weight`) zentriert hat, ist der Achsenabschnitt, β_0 , einfacher zu verstehen: In einem Modell mit zentriertem Prädiktor (`weight`) gibt der Achsenabschnitt die Größe einer Person mit durchschnittlichem Gewicht an. Würde man `weight` nicht zentrieren, gibt der Achsenabschnitt die Größe einer Person mit `weight=0` an, was nicht wirklich sinnvoll zu interpretieren ist; vgl. Gelman et al. (2021), Kap. 10.4, 12.2. Man zentriert eine Variable X , indem man von x_i den Mittelwert $\bar{x}$ abzieht: $x_i - \bar{x}$. Im Folgenden zentrieren wir *Gewicht* (`weight`); die resultierende Variable nennen wir `weight_c` (c wie “centered”).

```
kung_zentriert <-
  kung_erwachsen %>%
  mutate(weight_c = weight - mean(weight))
```

Mit Hilfe der Funktion `center()` aus `{easystats}` kann man sich das Zentrieren erleichtern.

```
kung_zentriert <-
  kung_erwachsen %>%
  mutate(weight_c = as.numeric(center(weight)))
```

Tabelle 10.2: Gewicht (`weight`) und zentriertes Gewicht (`weight_c`): Zentrierte Gewichtswerte zeigen, wie viele Kilogramm eine Person vom Mittelwert entfernt ist. So ist die Person mit der ID 1 drei Kilogramm schwerer als der Mittelwert von 45 kg.

id	weight	weight_c	height	age	male
1	48	3	152	63	1
2	36	-9	140	63	0
3	32	-13	137	65	0

Wie man sieht, wird die Verteilung von `weight` durch die Zentrierung “zur Seite geschoben”: Der Mittelwert von `weight_c` (das zentrierte Gewicht) liegt jetzt bei 0, s. [Abbildung 10.6](#).




Abbildung 10.6: Das Zentrieren ändert die Verteilungsform nicht, sondern “schiebt” die Verteilung nur zur Seite. Der resultierende Mittelwert ist dann Null. Die zentrierten Werte zeigen, wie weit ein Messwert vom Mittelwert entfernt ist (hier in der Einheit kg).

Das Schwierigste ist dabei nur, nicht zu vergessen, dass `kung_zentriert` die Tabelle mit zentriertem Prädiktor ist, nicht `kung_erwachsen`.

10.4 Modell `m_kung_gewicht_c`: zentrierter Prädiktor

[Prädiktoren zentrieren](#)

Erstellen wir nun ein Regressionsmodell mit dem zentrierten Prädiktor, Gewicht. Die Forschungsfrage lautet: “Wie stark ist der lineare Zusammenhang von Größe und Gewicht?”. Anders formuliert: “Um wie viele Zentimeter Körpergröße unterscheiden sich zwei erwachsene Kung, wobei die eine Person um 1 kg leichter ist als die andere?”.

Einige Regressionskoeffizienten, wie der Achsenabschnitt (engl. intercept) sind schwer zu interpretieren: Bei einem (erwachsenen) Menschen mit *Gewicht 0*, was wäre wohl die Körpergröße? Hm, Philosophie steht heute nicht auf der Tagesordnung. Da wäre es schön, wenn wir die Daten so umformen könnten, dass der Achsenabschnitt eine sinnvolle Aussage macht. Zum Glück geht das leicht: Wir zentrieren den Prädiktor (Gewicht)!

Zuerst stellen wir die Modelldefinition von `m_kung_gewicht_c` auf.

Für jede Ausprägung des Prädiktors *Gewicht zentriert* (`weight_centered`), wc_i , wird eine Post-Verteilung für die abhängige Variable *Größe* (`height`, h_i) berechnet. Der Mittelwert μ für jede Post-Verteilung ergibt sich aus dem linearen Modell (unserer Regressionsformel). Die Post-Verteilung berechnet sich auf Basis der Priori-Werte und des Likelihoods (Bayes-Formel). Wir brauchen Priori-Werte für die Steigung β_1 und den Achsenabschnitt β_0 der Regressionsgeraden. Außerdem brauchen wir einen Priori-Wert, der die Streuung σ der Größe (`height`) angibt; dieser Wert wird als exponentialverteilt angenommen. Der Likelihood gibt an, wie wahrscheinlich ein bestimmter Wert `height` ist, gegeben μ und σ . [Theorem 10.1](#) stellt die Modelldefinition dar. [Abbildung 10.7](#) zeigt, wie die drei Parameter zusammen die Likelihood definieren.




Abbildung 10.7

[Theorem 10.1](#) stellt [Abbildung 10.7](#) als Modellgleichung dar. [Abbildung 10.8](#) zeigt anhand der Regressionsgerade, wie die vorhergesagten Körpergrößen zustande kommen: μ (vorhergesagte Körpergröße) beruht auf dem jeweiligen X -Wert (d.h. Gewicht, UV); zusammen mit der Streuung der Körpergrößen um den Mittelwert (σ) ergibt sich dann die Normalverteilung der Körpergrößen, y_i (AV).




Abbildung 10.8: Die Körpergrößen, Y (AV) sind abhängig vom Wert des Körpergewichts, X , (UV)

Theorem 10.1 (Modelldefinition `m_kung_gewicht_c`)

$\text{height}_i \sim \text{Normal}(\mu_i, \sigma)$	Likelihood
$\mu_i = \beta_0 + \beta_1 \cdot \text{weightcentered}_i$	Lineares Modell, Regressionsformel
$\beta_0 \sim \text{Normal}(178, 20)$	Priori
$\beta_1 \sim \text{Normal}(0, 10)$	Priori
$\sigma \sim \text{Exp}(0.1)$	Priori
$\text{height}_i \sim \text{Normal}(\mu_i, \sigma)$	Likelihood

Der Likelihood von `m_kung_gewicht_c` ist ähnlich zu den vorherigen Modellen (`m_kung`). Nur gibt es jetzt ein kleines “Index- i ” am μ und am h (h wie `heights`). Es gibt jetzt nicht mehr nur einen Mittelwert μ , wie in `m_kung`, sondern für jede Beobachtung (Zeile) einen Mittelwert μ_i . Lies etwa so:

“Die Wahrscheinlichkeit, eine bestimmte Größe h bei Person i zu beobachten, gegeben μ und σ ist normalverteilt (mit Mittelwert μ und Streuung σ)”.

Betrachten wir als nächstes die Regressionsformel, `m_kung_gewicht_c`:

$$\mu_i = \beta_0 + \beta_1 \cdot \text{weightcentered}_i \quad \text{Lineares Modell}$$

μ ist jetzt *nicht* mehr ein Parameter, der (stochastisch) geschätzt werden muss (wie in `m_kung`). μ wird jetzt (deterministisch) *berechnet*. Gegeben β_0 und β_1 ist μ also ohne Ungewissheit bekannt. weight_i ist der Gewichtswert (`weight`) der i ten Beobachtung, also einer !Kung-Person (Zeile i im Datensatz). Lies etwa so:

“Der vorhergesagte mittlere Wert der Körpergröße, μ_i , der i ten Person berechnet sich als Summe von β_0 und β_1 mal weight_i ”.

μ_i ist eine lineare Funktion von `weight`. β_1 gibt den Unterschied in `height` zweier Beobachtung an, die sich um eine Einheit in `weight` unterscheiden (Steigung der Regressionsgeraden). β_0 gibt an, wie groß μ ist, wenn `weight` Null ist (Achsenabschnitt, engl. intercept).

Was sind unsere Priori-Verteilung des Modells `m_kung_gewicht_c`? Sie gleichen denen von `m_kung`, allerdings haben wir jetzt zusätzlich β_1 . Dieser Parameter gibt die Steigung der Regressionsgeraden an (auch als “Regressionsgewicht” bezeichnet). Damit wird die Stärke des (linearen) Zusammenhangs zwischen UV (X) und AV (Y) festgelegt. Hier definieren wir den Zusammenhang als normalverteilt mit Mittelwert 0 und Streuung 10 cm. Damit liegt der Bereich plausibler Werte für den Zusammenhang von Gewicht und Größe zwischen -20 cm bis +20 cm Unterschied in der Körpergröße pro Kilogramm Unterschied im Körpergewicht. Das ist ein recht informationsarmer Wert: Viele Werte sind möglich, auch unerwartete. Man kann argumentieren, dass diese Apriori-Verteilung biologisch nicht realistisch ist. Dazu später mehr.

$\beta_0 \sim \text{Normal}(178, 20)$	Priori Achsenabschnitt
$\beta_1 \sim \text{Normal}(0, 10)$	Priori Regressionsgewicht
$\sigma \sim \text{Exp}(0.1)$	Priori Sigma

Parameter sind hypothetische Kreaturen: Man kann sie nicht beobachten, sie existieren nicht wirklich. Ihre Verteilungen nennt man Priori-Verteilungen. β_0 wurde in `m_kung` als μ bezeichnet, da wir dort eine “Regression ohne Prädiktoren” berechnet haben. σ ist uns schon als Parameter bekannt und behält seine Bedeutung aus dem letzten Kapitel. Da `height` nicht zentriert ist, liegt der Mittelwert von β_0 bei 178 und nicht bei 0. β_1 fasst unser Vorwissen, ob und wie sehr der Zusammenhang zwischen Gewicht und Größe positiv (gleichsinnig) ist. β_1 ist hier schwach informativ: Im Schnitt behauptet diese Apriori-Verteilung, sei der Zusammenhang gleich Null. Aber die Apriori-Verteilung akzeptiert auch recht starke positive und negative (!) Werte. Diese Wahl an Apriori-Werten ist nicht unbedingt ideal. Wir sollten uns künftig noch andere (bessere) Parameter für die Apriori-Verteilung von β_1 überlegen. Die Anzahl der Prioris entspricht übrigens der Anzahl der Parameter des Modells.

Jetzt sind wir bereit, das Model bzw. die Post-Verteilung zu berechnen. Erinnern wir uns: “Prioris plus Daten gleich Post”. Los, Stan, an die Arbeit! Berechne uns die Post-Verteilung. Nennen wir das Modell `m_kung_gewicht_c`.

```
m_kung_gewicht_c <-
  stan_glm(
    height ~ weight_c, # Regressionsformel
    prior = normal(0, 10), # Regressionsgewicht (beta 1)
    prior_intercept = normal(178, 20), # beta 0
    prior_aux = exponential(0.1), # sigma
    refresh = 0, # zeig mir keine Details
    data = kung_zentriert)

parameters(m_kung_gewicht_c)
```

```
parameters(m_kung_gewicht_c) |> display()
```

Tabelle 10.3: Parameter von `m_kung_gewicht_c`

Parameter	Median	95% CI	pd	Rhat	ESS (tail)	Prior
(Intercept)	154.65	(154.11, 155.19)	100%	1.000	3048	Normal (178 +- 20)

Parameter	Median	95% CI	pd	Rhat	ESS (tail)	Prior
weight_c	0.91	(0.83, 0.99)	100%	1.001	2725	Normal (0 +- 10)

Wie man in [Tabelle 10.3](#) sieht, wird der Zusammenhang von Gewicht und Größe, d.h. β_1 , die Steigung der Regressionsgeraden, auf einen Wert zwischen ca. 0.8 bis 1.0 kg Unterschied in der Körpergröße geschätzt (wenn sich die Personen um 1 kg Körpergewicht unterscheiden). Es gibt also einen Zusammenhang zwischen Gewicht und Größe (laut unserem Modell). Danke, Stan!

Übungsaufgabe 10.4 (Peer-Instruction: Wie leitet sich der Wert der Körpergrößen h_i her?) Welche Aussage zur Herleitung der Körpergrößen, h_i , ist korrekt?

- Die Körpergrößen sind gleich mit dem um das Regressionsgewicht gewichteten Wert des jeweiligen Körpergewichts (d.h. $h_i = \beta_1 \cdot wc_i$).
- Die Körpergrößen sind apriori normalverteilt mit dem Mittelwert 178 cm (in diesem Modell).
- Die Körpergrößen sind apriori normalverteilt mit dem Mittelwert, der sich aus dem Regressionsmodell ergibt für jede Beobachtung i .
- Die Körpergrößen sind das Resultat zweier Parameter: Der mittleren Körpergröße, μ , sowie der Streuung in der Population, σ . ☐

10.5 Die Post-Verteilung befragen

 [Post-Verteilung auslesen 1](#)

 [Post-Verteilung auslesen 2](#)

10.5.1 m_kung_starkes_beta1

Mit der Apriori-Verteilung von β_1 in `m_kung_gewicht_c` sind wir nicht zufrieden. Sagen wir stattdessen, auf Basis gut geprüfter Evidenz haben wir folgendes Modell festgelegt: `height ~ weight_c`, s. [Gleichung 10.1](#). Dabei haben wir folgende Apriori-Verteilungen gewählt:

$$\beta_1 \sim N(5, 3); \beta_0 \sim N(178, 20); \sigma \sim E(0.1) \quad (10.1)$$

Dieses Mal haben wir für β_1 durchaus “meinungsstarke” Werte ausgewählt. Im Schnitt gehen wir von einem Zusammenhang aus, so dass es einen Unterschied von 5 cm in der AV (Größe) gibt, wenn sich die UV (Gewicht) um 1 Einheit (1 kg) unterscheidet zwischen zwei Personen. Wir nennen das Modell `m_kung_starkes_beta1`³, s. [Listing 10.1](#).

Listing 10.1: Modelldefinition von `m_kung_starkes_beta1` in R

```
m_kung_starkes_beta1 <-
  stan_glm(
    height ~ weight_c, # Regressionsformel
    prior = normal(5, 3), # Regressionsgewicht (beta 1)
    prior_intercept = normal(178, 20), # beta 0
    prior_aux = exponential(0.1), # sigma
    refresh = 0, # zeig mir keine Details
    data = kung_zentriert)
```

Hinweis

Mit `seed` kann man die Zufallszahlen fixieren, so dass jedes Mal die gleichen Werte resultieren. So ist die Nachprüfbarkeit der Ergebnisse (“Reproduzierbarkeit”) sichergestellt⁴. Welcher Wert für `seed` man verwendet, ist egal, solange alle den gleichen verwenden. Der Autor verwendet z.B. oft den Wert 42. Zur Erinnerung: Der Golem zieht Zufallszahlen, damit erstellt er Stichproben, die die Postverteilung schätzen. Das Argument `seed` ist nur relevant, wenn man die Ergebnisse von Stan zwischen zwei Durchläufen vergleichen möchte. Ansonsten hat es keine Bedeutung.

10.5.2 Mittelwerte von β_0 und β_1 aus der Post-Verteilung

Betrachten wir die ersten paar Zeilen aus der Post-Verteilung, s. [Tabelle 10.4](#). Dazu wandeln wir das Ergebnis-Objekt von `stan_glm`, d.h. `m_kung_starkes_beta1` in eine Tabelle (einen “Tibble”) um.

Listing 10.2: Die Post-Verteilung bekommen wir, indem wir das Ergebnisobjekt von `stan_glm` in einen Tibble (Dataframe) umwandeln.

```
m_kung_starkes_beta1_post <-  
m_kung_starkes_beta1 %>%  
  as_tibble() %>%  
  head()
```

Tabelle 10.4: Die ersten paar Zeilen der Post-Verteilung von `m_kung_starkes_beta1`

	id (Intercept)	weight_c	sigma
1	155.1	0.9	5.0
2	155.5	0.8	5.1
3	155.5	0.9	5.1

[Tabelle 10.5](#) zeigt die Zusammenfassung der Stichproben aus der Post-Verteilung; komfortabel zu erhalten mit dem Befehl `parameters(m_kung_starkes_beta1)`.

Tabelle 10.5: Parameter von `m_kung_starkes_beta1`

Parameter	Median	95% CI	pd	Rhat	ESS (tail)	Prior
(Intercept)	154.65	(154.14, 155.19)	100%	0.999	2862	Normal (178 +- 20)
weight_c	0.91	(0.82, 0.99)	100%	1.001	2688	Normal (5 +- 3)

Definition 10.1 (Effektwahrscheinlichkeit) Die Kennzahl `pd` (propability of direction) gibt die *Effektwahrscheinlichkeit* an: Die Wahrscheinlichkeit, dass der Effekt positiv (also größer als Null) oder negativ ist (je nachdem ob der Median des Effekts positiv oder negativ ist). `pd` gibt aber nicht an, wie stark der Effekt ist, nur ob er klar auf einer Seite der Null liegt. Damit ist er so etwas (grob!) Ähnliches wie der p-Wert in der Frequentistischen Statistik ([Makowski et al., 2019](#)). □

Am besten das Diagramm zur Effektwahrscheinlichkeit (`pd`) anschauen, s. [Abbildung 10.9](#). `Rhat` und `ESS` sind Kennzahlen, die untersuchen, ob mit der Stichprobenziehung im Bayes-Modell alles gut funktioniert hat. Bei einfachen Modellen (die wir hier berechnen) sollte da in der Regel alles in Ordnung sein. `Rhat` sollte nicht (viel) größer als 1 oder 1,01 sein. `ESS` (effective sample size) gibt die Anzahl der effektiv nutzbaren Stichproben an

(im Standard werden 4000 berechnet). Die Zahl sollte nicht deutlich geringer sein. Wir werden uns aber mit diesen beiden Kennwerten nicht weiter beschäftigen in diesem Kurs.

```
plot(p_direction(m_kung_starkes_beta1))
```




Abbildung 10.9: Diagramm zur Probability of Direction, Modell `m_kung_starkes_beta1`

10.5.3 Visualisieren der “mittleren” Regressionsgeraden

Zur Erinnerung: Die Bayes-Analyse liefert uns viele Stichproben zu den gesuchten Parametern, hier β_0 , β_1 und σ . Überzeugen wir uns mit einem Blick in die Post-Verteilung von `m_kung_starkes_beta1`, s. [Tabelle 10.4](#). Wir können z.B. ein Lagemaß wie den Median hernehmen, um die “mittlere” Regressionsgerade zu betrachten, s. [Abbildung 10.10](#).

```
kung_zentriert %>%
  ggplot() +
  aes(x = weight_c, y = height) +
  geom_point() +
  geom_abline(
    slope = 0.9, # Median beta 1
    intercept = 154, # Median beta 0
    color = "blue")
```




Abbildung 10.10: Die mittlere Regressionsgerade, unser 'Best-Guess' zum Zusammenhang von Gewicht und Größe

10.5.4 Zentrale Statistiken zu den Parametern

In diesem Modell gibt es drei Parameter: β_0 , β_1 , σ .⁵ Hier folgen einige Beispiele an Fragen, die wir an unser Modell bzw. die Post-Verteilung stellen können.

10.5.4.1 Lagemaße zu den Parametern

- Was ist die mittlere Größe der erwachsenen Kung? (Das war die Forschungsfrage des letzten Kapitels; β_0)
- Was ist der Schätzwert für den Zusammenhang von Gewicht und Größe? (β_1)
- Was ist der Schätzwert für Ungewissheit in der Schätzung der Größe? (σ)
- Was ist der wahrscheinlichste und der mediane Wert für β_1 ?

Eine nützliche Zusammenfassung der Post-Verteilung bekommt man mit `parameters(modell)`, s.

[Tabelle 10.5](#). Wandelt man das Ausgabe-Objekt der Bayes-Regression, d.h. `m_kung_starkes_beta1`, mit `as_tibble()` in eine Tabelle um, so bekommt man eine Tabelle mit den Stichproben der Post-Verteilung, s.

[Tabelle 10.4](#).

Wie wir gesehen haben, nutzen wir diese Tabelle der Post-Verteilung immer wieder. Daher haben wir sie uns als ein Objekt abgespeichert, `m_kung_starkes_beta1_post`, s. [Listing 10.2](#). Jetzt haben wir wieder eine schöne Tabelle mit Stichproben aus der Post-Verteilung, die wir wie gewohnt befragen können. Oder man erstellt selber ein Diagramm mit `ggplot` oder `ggpubr`, s. [Abbildung 10.11](#), um einen Überblick über Lage- und Streuungsmaße der Post-Verteilung zu bekommen.

```
m_kung_starkes_beta1_post %>%
  ggplot(aes(x = weight_c)) +
  geom_density(fill = "orange")
```




Abbildung 10.11: Die Postverteilung für den Parameter Gewicht (zentriert); die plausiblen Werte liegen zwischen 0.8 und 1.0 cm pro Kilogramm Gewicht

[Abbildung 10.11](#) zeigt, dass Mittelwert, Median und Modus eng zusammenliegen. Zur Erinnerung: Der Modus gibt den häufigsten, d.h. hier also den wahrscheinlichsten, Wert an. Der Modus wird hier auch *Maximum a Posteriori* (MAP) genannt, daher:

```
m_kung_starkes_beta1_post %>%
  summarise(map_b1 = map_estimate(weight_c))
```

Hier ist die Verteilung von σ visualisiert, s. [Abbildung 10.12](#). Interessanterweise ist die *Post*-Verteilung von σ *normalverteilt* und *nicht* mehr *exponentialverteilt*, wie in der *Apriori*-Verteilung: Die Daten haben die *Apriori*-Verteilung “überstimmt”.

```
m_kung_starkes_beta1_post %>%
  ggplot(aes(x = sigma)) +
  geom_density(fill = "orange")
```




Abbildung 10.12: Die Post-Verteilung für den Parameter sigma, m_kung_starkes_beta1; die plausiblen Werte liegen zwischen 4.7 cm und 5.5 cm.

Alternativ kann man sich die Verteilung eines Parameters auch so ausgeben lassen, gleich mit Intervallgrenzen, z.B. 95%, s. [Abbildung 10.13](#).

```
m_kung_starkes_beta1_hdi <-
  m_kung_starkes_beta1_post |>
  select(weight_c) |> # analog für `select(sigma)`
  hdi() # analog mit eti()

plot(m_kung_starkes_beta1_hdi, data = m_kung_starkes_beta1_post)
```

Highest Density Interval (HDI)




Abbildung 10.13: Die Parameter Gewicht (zentriert) Modells m_kung_starkes_beta1

Ergänzt man bei `plot()` noch `show_intercept = TRUE` wird auch der Achsenabschnitt angezeigt. Den Parameter der Vorhersage-Genauigkeit, σ bekommt man mit `get_sigma`:

```
get_sigma(m_kung_starkes_beta1)
## [1] 5.1
## attr(,"class")
## [1] "insight_aux" "numeric"
```

10.5.5 Streuungsmaße zu den Parametern

- Wie unsicher sind wir uns in den Schätzungen der Parameter?

Diese Frage wird durch die Ungewissheitsintervalle in der Ausgabe beantwortet.

i Hinweis

An einigen Stellen wird empfohlen, anstelle eines (gebräuchlichen) 95%-Intervalls auf ein 90%- oder 89%-Intervall auszuweichen, aufgrund der besseren numerischen Stabilität.

10.5.6 Ungewissheit von β_0 und β_1 aus der Post-Verteilung visualisiert

[Abbildung 10.14](#) stellt die Ungewissheit der Post-Verteilung dar, in dem einige Stichproben aus der Post-Verteilung visualisiert werden.

10

100

1000

1000000

Die ersten 10 Stichproben:

```
kung_zentriert %>%
  ggplot(aes(x = weight_c,
             y = height)) +
  geom_point() +
  geom_abline(
    data = m_kung_starkes_beta1_post %>%
      slice_head(n = 10),
    aes(slope = weight_c,
        intercept = `(Intercept)`),
    alpha = .3)
```




Abbildung 10.14

Einfacher ist die Visualisierung mit `estimate_expectation`, s. [Abbildung 10.15](#).

```
estimate_expectation(m_kung_starkes_beta1, by = "weight_c") %>% # Regressionsgerade
  plot() +
  geom_point(data = kung_zentriert, aes(x = weight_c, y = height)) # Punkte
```




Abbildung 10.15: Schätzbereich für die bedingten mittleren Körpergröße, also die Regressionsgerade mit Unsicherheitsintervall

10.5.7 Fragen zu Quantilen des Achsenabschnitts

Hinweis

Zur Erinnerung: Bei einem zentrierten Prädiktor misst der Achsenabschnitt die mittlere Größe⁸.

- Welche mittlere Größe wird mit einer Wahrscheinlichkeit von 50%, 90% bzw. 95% Wahrscheinlichkeit nicht überschritten?
- Welche mittlere Größe wird mit einer Wahrscheinlichkeit von 95% nicht unterschritten?
- Von wo bis wo reicht der innere 50%-Schätzbereich (ETI) der mittleren Körpergröße?

Quantile:

```
m_kung_starkes_beta1_post %>%  
  summarise(  
    q_50 = quantile(`(Intercept)`, prob = .5),  
    q_90 = quantile(`(Intercept)`, prob = .9),  
    q_05 = quantile(`(Intercept)`, prob = .95))
```

50%-ETI:

```
m_kung_starkes_beta1 %>%  
  eti(ci = .5)
```

10.5.8 Fragen zu Wahrscheinlichkeitsmassen des Achsenabschnitts

Wie wahrscheinlich ist es, dass die mittlere Größe bei mind. 155 cm liegt?

```
m_kung_starkes_beta1_post %>%  
  count(gross = `(Intercept)` >= 155) %>%  
  mutate(prop = n / sum(n))
```

Die Wahrscheinlichkeit beträgt 0.1.

Wie wahrscheinlich ist es, dass die mittlere Größe höchstens 154.5 cm beträgt?

```
m_kung_starkes_beta1_post %>%  
  count(klein = `(Intercept)` <= 154.5) %>%  
  mutate(prop = n / sum(n))
```

Die Wahrscheinlichkeit beträgt 0.29.

Beispiel 10.1 (Typischer Bayes-Nutzer in Aktion)



Typischer Bayes-Nutzer, der ein Ungewissheitsintervall berechnet. Bildquelle: Easystats, bayestestR

[Quelle](#) ☐

10.6 Post-Verteilung bedingt auf einen Prädiktorwert

10.6.1 Bei jedem Prädiktorwert eine Post-Verteilung für μ

Komfort pur: Unser Modell erlaubt uns für jeden beliebigen Wert des Prädiktors eine Post-Verteilung (von μ) zu berechnen. Hier am Beispiel von `m_kung_post`, s. [Abbildung 10.16](#).




Abbildung 10.16: Für jeden beliebigen Prädiktorwert kann man eine Post-Verteilung bekommen. A: Regressionsmodell mit einigen ausgewählten Gewichtswerten. Es ist jeweils die Wahrscheinlichkeitsverteilung für den vorhergesagten Y-Wert dargestellt (hier sind die Verteilungen zu groß dargestellt zur besseren Sichtbarkeit). B: Für jeden beliebigen Gewichtswert (Y) bekommt man eine (auf den jeweiligen X-Wert bedingten) Post-Verteilung.

10.6.2 Visualisierung

Was ist wohl die Wahrscheinlichkeit der Körpergröße bei einem bestimmten Gewicht? Angenommen wir wissen, dass das Gewicht bei, sagen wir 45 kg liegt. Welche Körpergröße ist (im Schnitt) zu erwarten? Wie unsicher sind wir uns über diesen Mittelwert? Etwas formaler ausgedrückt: $\mu | \text{weight} = 45$

45 kg entspricht genau dem Mittelwert von `weight`. Geht man von zentrierten Prädiktorwerten aus, gilt in dem Fall `weight_c = 0`. Erstellen wir uns dazu eine Tabelle und plotten diese, s. [Abbildung 10.17](#).

```
mu_at_45 <-
  m_kung_gewicht_c_post %>%
  mutate(mu_at_45 = `(Intercept)`)
```

```
mu_at_45 %>%
  ggplot(aes(x = mu_at_45)) +
  geom_density()
```





Abbildung 10.17: Post-Verteilung der Größe (laut unserem Modell) bei einem Gewicht von 45kg

Analog können wir fragen, wie groß wohl eine Person mit 50 kg im Mittelwert sein wird und wie (un)gewiss wir uns über diesen Mittelwert sind. 50 kg, das sind 5 über dem Mittelwert, in zentrierten Einheiten ausgedrückt also $\text{weight_c} = 5$. Auch dazu erstellen wir uns eine Tabelle, s. [Tabelle 10.6](#). Die Verteilung der mittleren Größe bei einem Gewicht von 50kg ist weiter “rechts” (Richtung höhere Größe) lokalisiert, s. [Abbildung 10.18](#). Dazu addieren wir zum Wert des Achsenabschnitts (intercept) das Fünffache des Regressionsgewichts, β_1

(weight_c): `mu_at_50 = (Intercept) + 5 * weight_c`. Das Diagramm erhält man mit `ggplot(mu_at_50, aes(x = mu_at_50)) + geom_density()`.

```
mu_at_50 <-  
  mu_at_45 %>%  
  mutate(mu_at_50 = `(Intercept)` + 5 * weight_c)  
  
head(mu_at_50)
```

Tabelle 10.6: Die Verteilung von mu bedingt auf ein Gewicht von 50kg.




Abbildung 10.18: Post-Verteilung der mittleren Größe (laut unserem Modell) bedingt auf ein Gewicht von 50 kg

10.6.3 Lagemaße und Streuungen

Befragen wir die *bedingte* Post-Verteilung. Eine erste Frage zielt nach den typischen deskriptiven Statistiken, also nach Lage und Streuung der Verteilung der Körpergröße.

Was ist das 90% ETI für $\mu|w = 50$? Man erhält es mit dem Befehl `mu_at_50 %>% eti(ci = .9)`

```
#|echo: false  
mu_at_50 %>%  
  eti(ci = .9)
```

Die mittlere Größe – gegeben $w = 50$ – liegt mit 90% Wahrscheinlichkeit zwischen den beiden Werten (ca.) 159 cm und 160 cm.

Welche mittlere Größe wird mit 95% Wahrscheinlichkeit nicht überschritten, wenn die Person 45kg wiegt? Dazu berechnen wir das gefragte Quantil (also bei 95%).

```
mu_at_45 %>%  
  summarise(q_95 = quantile(mu_at_45, prob = .95))
```

10.7 Fazit

10.7.1 Ausstieg

Beispiel 10.2 (Fassen Sie das Wesentliche zusammen!) Schreiben Sie 5-10 Sätze zum Wesentlichen Stoff dieses Kapitels und reichen Sie bei der von Lehrkraft vorgegebenen Stelle ein! ☐

10.7.2 Vertiefung

McElreath (2020) bietet eine tiefere Darstellung von linearen Modellen auf Basis der Bayes-Statistik, insbesondere Kapitel 4 daraus vertieft die Themen dieses Kapitels. Kurz (2021) greift die R-Inhalte von McElreath (2020) auf und setzt sie mit Tidyverse-Methoden um; ein interessanter Blickwinkel, wenn man tiefer in die R-Umsetzung einsteigen möchte. Gelman et al. (2021) bieten ebenfalls viele erhellende Einblicke in das Thema Regressionsanalyse, sowohl aus einer frequentistischen als auch aus einer Bayes-Perspektive.

10.8 Aufgaben

10.8.1 Papier-und-Bleistift-Aufgaben

1. [Bayes-Ziel1](#)
2. [Bayesmod-bestimmen01](#)
3. [mtcars-post2a](#)
4. [Bed-Post-Wskt1](#)
5. [mtcars-post3a](#)
6. [regression1a](#)
7. [regression1b](#)
8. [Regression2](#)
9. [Priorwahl1](#)
10. [Bayesmod-bestimmen02](#)
11. [Aussagen-einfache-Regr](#)
12. [Likelihood-identifizieren](#)
13. [Priorwahl2](#)
14. [Likelihood2](#)
15. [interpret-koeff](#)
16. [bed-post-wskt1](#)

10.8.2 Computer-Aufgaben

1. [Post-befragen1](#)
2. [penguins-stan-01](#)

10.8.3 Quiz-Aufgaben

Hier finden Sie Single-Choice-Aufgaben zu diesem Kapitel. Wählen Sie eine Antwort aus und klicken Sie auf das Häkchen, um sie zu überprüfen; über das Fragezeichen erhalten Sie die ausführliche Lösung.

Warum wird der Prädiktor *Gewicht* im Kung-Regressionsmodell zentriert (d.h. `weight_c = weight - mean(weight)` gebildet), bevor das Modell berechnet wird?

- ☐ Zentrieren dient dazu, negative Gewichtswerte aus dem Datensatz zu entfernen.
- ☐ Durch das Zentrieren ändert sich die Steigung der Regressionsgeraden (β_1), wodurch der Zusammenhang zwischen Gewicht und Größe stärker erscheint.
- ☐ Ohne Zentrierung könnte man mit `stan_glm()` gar kein Regressionsmodell mit dieser Variablen berechnen.
- ☐ Durch die Zentrierung entspricht der Achsenabschnitt β_0 der (mittleren) Körpergröße bei *durchschnittlichem* Gewicht – ohne Zentrierung würde β_0 die (unrealistische) Körpergröße bei einem Gewicht von 0 kg angeben.
- ☐ Zentrieren ist nötig, damit das Regressionsgewicht β_1 überhaupt berechnet werden kann.



Das Modell `m_kung_gewicht_c` ist wie folgt spezifiziert:

$height_i \sim \text{Normal}(\mu_i, \sigma)$	Likelihood
$\mu_i = \beta_0 + \beta_1 \cdot \text{weightcentered}_i$	Lineares Modell
$\beta_0 \sim \text{Normal}(178, 20)$	Prior
$\beta_1 \sim \text{Normal}(0, 10)$	Prior
$\sigma \sim \text{Exp}(0,1)$	Prior

Welche Aussage zu diesem Modell ist korrekt?

- ☐ μ_i wird *deterministisch* aus β_0 , β_1 und dem Gewicht der i -ten Person berechnet – es hat also (gegeben β_0 und β_1) selbst keine eigene Apriori-Verteilung, im Unterschied zum reinen Modell `m_kung` ohne Prädiktor.
- ☐ Das Modell hat insgesamt nur zwei zu schätzende Parameter: β_0 und β_1 .
- ☐ μ_i hat, genau wie β_0 und β_1 , eine eigene, separat geschätzte Apriori-Verteilung.
- ☐ Die Likelihood-Zeile besagt, dass jede Person exakt die Körpergröße μ_i hat, ohne jede Streuung.
- ☐ β_1 gibt an, wie groß die mittlere Körpergröße bei einem Gewicht von exakt 0 kg (zentriert) ist.



Im Kung-Regressionsmodell (`height ~ weight_c`) wird für β_1 (das “Regressionsgewicht”) ein Schätzwert von etwa 0,9 berichtet. Wie ist dieser Wert korrekt zu interpretieren?

- ☐ Die durchschnittliche Körpergröße aller erwachsenen !Kung beträgt 0,9 cm.
- ☐ Zwei erwachsene !Kung, die sich um 1 kg im (zentrierten) Gewicht unterscheiden, unterscheiden sich laut Modell im Schnitt um etwa 0,9 cm in der Körpergröße.
- ☐ $\beta_1 = 0,9$ bedeutet, dass 90% der !Kung größer als der Mittelwert sind.
- ☐ $\beta_1 = 0,9$ gibt die Korrelation zwischen Gewicht und Größe an, die hier bei $r = 0,9$ liegt.
- ☐ Eine Person mit einem (zentrierten) Gewicht von 0 hat laut Modell eine Körpergröße von 0,9 cm.



Für ein Kung-Regressionsmodell mit zentriertem Gewicht als Prädiktor liegen die (medianen) Post-Schätzwerte bei $\beta_0 = 154$ (Achsenabschnitt, mittlere Größe bei Durchschnittsgewicht) und $\beta_1 = 0,9$ (Regressionsgewicht pro kg). Wie groß ist die vorhergesagte mittlere Körpergröße μ für eine Person mit einem zentrierten Gewicht von $\text{weight_c} = 8$ (also 8 kg über dem Stichprobenmittelwert)?

- ☐ $\mu = \beta_0 - \beta_1 \cdot \text{weight_c} = 154 - 0,9 \cdot 8 = 146,8$
- ☐ $\mu = \beta_1 + \beta_0 \cdot \text{weight_c} = 0,9 + 154 \cdot 8 = 1232,9$
- ☐ $\mu = \beta_1 \cdot \text{weight_c} = 0,9 \cdot 8 = 7,2$
- ☐ $\mu = \beta_0 + \beta_1 \cdot \text{weight_c} = 154 + 0,9 \cdot 8 = 161,2$
- ☐ $\mu = \beta_0 + \beta_1 + \text{weight_c} = 154 + 0,9 + 8 = 162,9$



Im Kapitel wird die Kennzahl **pd** (probability of direction, Effektwahrscheinlichkeit) eingeführt. Welche Aussage zu **pd** ist korrekt?

- ☐ **pd** gibt an, wie viele Prozent der ursprünglichen Priori-Verteilung durch die Daten “überstimmt” wurden.
- ☐ **pd** kann nur Werte zwischen -1 und 1 annehmen, wie ein Korrelationskoeffizient.
- ☐ **pd** gibt die Wahrscheinlichkeit an, dass ein Effekt (z.B. β_1) klar auf einer Seite von Null liegt (also eindeutig positiv oder eindeutig negativ ist) – sie sagt aber nichts über die *Stärke* des Effekts aus.
- ☐ **pd** ist identisch mit dem Median der Post-Verteilung eines Parameters.
- ☐ **pd** gibt die exakte Stärke (Effektgröße) eines Zusammenhangs an, z.B. in Zentimetern pro Kilogramm.



Das Kapitel stellt fest, dass Gewicht und Größe der !Kung linear zusammenhängen. Welche Aussage zum Verhältnis von (linearem) Zusammenhang und Kausalität ist korrekt?

- ☐ Ein linearer (statistischer) Zusammenhang zwischen zwei Variablen bedeutet nicht automatisch, dass zwischen ihnen ein kausaler Zusammenhang besteht.
- ☐ Ein linearer Zusammenhang zwischen zwei Variablen beweist immer, dass die eine Variable die andere kausal beeinflusst.
- ☐ Ein linearer Zusammenhang bedeutet, dass eine Verdopplung von X auch eine Verdopplung von Y zur Folge hat.
- ☐ Wenn kein linearer Zusammenhang zwischen zwei Variablen vorliegt, kann zwischen ihnen mit Sicherheit auch kein kausaler Zusammenhang bestehen.
- ☐ Regressionsanalysen können – im Gegensatz zu Korrelationen – grundsätzlich nur kausale Zusammenhänge abbilden, niemals rein deskriptive.



Eine Post-Stichprobe des Achsenabschnitts (der mittleren Körpergröße) besteht aus 4000 Werten. Der Befehl `count(Intercept >= 155)` liefert folgendes Ergebnis: `FALSE: 3800`, `TRUE: 200`. Wie hoch ist die geschätzte Wahrscheinlichkeit $Pr(\beta_0 \geq 155)$?

- ☐ $Pr(\beta_0 \geq 155) = \frac{200}{4000} = 0,05$
- ☐ $Pr(\beta_0 \geq 155) = 200$
- ☐ $Pr(\beta_0 \geq 155) = \frac{200}{3800} \approx 0,053$
- ☐ $Pr(\beta_0 \geq 155) = \frac{4000}{200} = 20$
- ☐ $Pr(\beta_0 \geq 155) = \frac{3800}{4000} = 0,95$



Das Kapitel vergleicht zwei Modelle: `m_kung_gewicht_c` mit einer eher schwach informativen Priori für β_1 ($\beta_1 \sim \mathcal{N}(0, 10)$) und `m_kung_starkes_beta1` mit einer meinungsstärkeren Priori ($\beta_1 \sim \mathcal{N}(5, 3)$). Welche Aussage zum Effekt dieser unterschiedlichen Priori-Wahl ist am ehesten zutreffend?

- ☐ Die schwach informative Priori bedeutet, dass das Modell β_1 überhaupt nicht schätzen kann.
- ☐ Die schwach informative Priori für β_1 lässt vorab auch negative Zusammenhänge (also einen negativen Effekt von Gewicht auf Größe) als plausibel zu, während die meinungsstärkere Priori vorab bereits einen klar positiven Zusammenhang um 5 herum favorisiert.
- ☐ Beide Prioris führen zwangsläufig zu exakt identischen Post-Verteilungen für β_1 , unabhängig von der Datenmenge.
- ☐ Eine meinungsstärkere Priori für β_1 macht die Berechnung mit `stan_glm()` unmöglich.
- ☐ Der Unterschied zwischen den beiden Prioris betrifft nur β_0 , nicht β_1 .



Das Kapitel visualisiert die Ungewissheit der Regressionsgeraden, indem viele einzelne Geraden aus den Post-Stichproben (z.B. die ersten 10, 100 oder 1000 Kombinationen von β_0 und β_1) übereinander geplottet werden. Welche Aussage zu dieser Visualisierung ist korrekt?

- ☐ Je mehr Geraden aus der Post-Verteilung eingezeichnet werden, desto deutlicher wird sichtbar, wie viel Ungewissheit im Modell bezüglich der genauen Lage der Regressionsgeraden besteht – die “Wolke” der Geraden zeigt den plausiblen Bereich.
- ☐ Nur eine einzige Gerade aus der Post-Verteilung ist tatsächlich “richtig”, alle anderen sind reine Rechenfehler.
- ☐ Alle aus der Post-Verteilung gezogenen Geraden sind exakt identisch, da β_0 und β_1 feste Werte sind.
- ☐ Diese Visualisierung zeigt ausschließlich die Unsicherheit von σ , nicht die von β_0 und β_1 .

☐ Je mehr Geraden eingezeichnet werden, desto größer wird die tatsächliche Unsicherheit des Modells.



Das Kapitel visualisiert mit `estimate_expectation(modell, by = "weight_c")` eine Regressionsgerade mit einem Schätzbereich (Unsicherheitsband) und legt zusätzlich die einzelnen beobachteten Datenpunkte darüber. Welche Aussage zur Interpretation dieser Grafik ist korrekt?

- ☐ Das Unsicherheitsband zeigt, mit welcher Wahrscheinlichkeit eine *einzelne neue Person* exakt auf der Regressionsgeraden liegen wird.
- ☐ Das Unsicherheitsband und die Streuung der einzelnen Datenpunkte um die Gerade sind exakt gleich breit.
- ☐ Je breiter das Unsicherheitsband, desto besser passt das Modell zu den Daten.
- ☐ Alle beobachteten Datenpunkte müssen zwangsläufig innerhalb des Unsicherheitsbands der mittleren Vorhersage liegen, sonst ist das Modell fehlerhaft.
- ☐ Das Unsicherheitsband zeigt die Ungewissheit über den *mittleren* vorhergesagten Wert μ bei jedem Gewichtswert; die einzelnen Datenpunkte streuen typischerweise stärker um die Gerade als dieses (schmalere) Band, da zusätzlich die Streuung σ einzelner Beobachtungen um μ hinzukommt.



10.9 —



1. Da es viele Funktionen sind, bietet es sich an mit *Strg-F* auf der Webseite nach Ihrem Lieblingsbefehl zu suchen. [↵](#)
2. [Datenquelle](#), McElreath (2020). [↵](#)
3. Wer ist hier für die Namensgebung zuständig? Besoffen oder was? [↵](#)
4. oder zumindest *besser* sichergestellt [↵](#)
5. In manchen Lehrbüchern wird β_0 auch als α bezeichnet. [↵](#)
6. 1e6 [↵](#)
7. Im Standard beschert uns `stan_glm()` 4000 Stichproben. [↵](#)

