

11 Schätzen vs. Testen

11.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können...

- den Unterschied zwischen dem *Schätzen* von Modellparametern und dem *Testen* von Hypothesen erläutern
- Vor- und Nachteile des Schätzens und Testens diskutieren
- Das ROPE-Konzept erläutern und anwenden
- Die Güte von Regressionsmodellen einschätzen und berechnen

Der Stoff dieses Kapitels orientiert sich an ([Kruschke, 2018](#)).

Lesen Sie zur Vorbereitung folgende Literatur:

- [Statistik1, Kap. "Geradenmodelle 2"](#)

In diesem Kapitel werden folgende R-Pakete benötigt:

```
library(rstanarm) # Bayes-Modelle
library(tidyverse)
library(easystats)
library(palmerpenguins) # Datensatz "penguins"
```

Wir benötigen den Datensatz `palmerpenguins`.




Abbildung 11.1: Possierlich: Die Pinguine ([Horst, 2024](#))

Übungsaufgabe 11.1 (Machen Sie sich mit den Pinguinen vertraut) Machen Sie sich zunächst mit dem Pinguin-Datensatz vertraut. Sie finden den Datensatz `penguins` im R-Paket `palmerpenguins`, das Sie auf gewohnte Art installieren können. Im Internet findet man den Datensatz auch als CSV-Datei; s. unten. Importieren Sie den Datensatz und verschaffen Sie sich einen Überblick über die Verteilungen jeder Variablen des Datensatzes.

Sie können den Datensatz `penguins` entweder über den Pfad importieren:

```
penguins_url <- "https://vincentarelbundock.github.io/Rdatasets/csv/palmerpenguins/peng  
penguins <- read.csv(penguins_url)
```

↓ **DOWNLOAD**

Oder über das zugehörige R-Paket:

```
data("penguins", package = "palmerpenguins")
```

Beide Möglichkeiten des Datenimports sind okay. ☐

Hinweis

Die Folien zu diesem Kapitel finden Sie [hier](#).

11.2 Einstieg

Betrachten Sie die zwei folgenden Aussagen, die jeweils ein Forschungsziel angeben:

1. “Lernen für die Klausur bringt etwas!”
2. “Wie viel bringt Lernen für die Klausur?”

Beispiel 11.1 Diskutieren Sie die epistemologische Ausrichtung sowie mögliches Für und Wider der beiden Ausrichtungen! Einmal Behauptung, einmal Frage – was macht das für einen Unterschied? ☐

11.3 Was ist Testen? Was ist Schätzen?

Forschungsfragen kann man, allgemein gesprochen, auf zwei Arten beantworten:

1. *Hypothesen testen*: “Die Daten widerlegen die Hypothese (nicht)”
2. *Parameter schätzen*: “Der Effekt von X auf Y liegt zwischen A und B”.

11.3.1 Hypothesen testen

Hypothesen testende Analysen kommen zu einer Ja-Nein-Entscheidung bzgl. einer Hypothese. Genauer muss man sagen: Im besten Fall kommen sie zu einer Ja-Nein-Aussage. Es kann natürlich sein, dass die Datenlage so nebelig oder das Problem so knifflig ist, dass man ehrlicherweise zugeben muss, dass man sich nicht sicher ist oder sogar komplett im Dunkeln tappt.

Beispiel 11.2 (“Lernen erhöht den Prüfungserfolg!”) Die Hypothese *Lernen erhöht den Prüfungserfolg* kann durch eine Studie und eine entsprechende Analyse grundsätzlich folgende drei Ergebnisse finden. 1) Die Daten widersprechen der Hypothese: Lernen bringt offenbar doch nichts für den Klausurerfolg. 2) Die Daten unterstützen die Hypothese: Lernen erhöht den Prüfungserfolg. 3) Die Daten sind uneindeutig, es ist keine Aussage zum Einfluss von Lernen auf den Prüfungserfolg möglich. ☐

Das Testen einer Hypothese kann zu drei Arten von Ergebnissen führen. Die ersten beiden sind informationsreich, die dritte ist informationsarm.

1.  Die Daten *widersprechen* der Hypothese: Auf Basis der Daten (und des Modells) muss man die Hypothese ablehnen (verwerfen, sagt man), also als falsch (falsifiziert) betrachten oder zumindest hat die Glaubwürdigkeit der Hypothese gelitten.
2.  Die Daten *unterstützen* die Hypothese: Auf Basis der Daten (und des Modells) muss man die Hypothese annehmen (oder kann die Gegenthese zumindest nicht verwerfen). Oder zumindest hat die Hypothese an Glaubwürdigkeit gewonnen.
3.  Die Datenlage ist *unklar*; zum Teil unterstützen die Daten die Hypothese, zum Teil widersprechen sie ihr. Man kann keine oder kaum Schlüsse aus den Daten ziehen. In diesem Fall gibt es keinen (nennenswerten) Erkenntnisgewinn.

Hypothesen prüfen ist *binär* in dem Sinne, dass sie zu “Schwarz-Weiß-Ergebnissen” führen (sofern die Datenlage stark genug ist).

Wichtig

Eine gängige Variante des Hypothesentestens¹ ist das Testen der Hypothese “Es liegt kein (null) Effekt vor” (Null Effekt). Man geht also davon aus, dass es keinen Zusammenhang zwischen UV und AV gibt und spricht vom *Nullhypothesen testen*, H_0 . □

11.3.2 Beispiele für Nullhypothesen

- “Lernen bringt nichts”
- “Frauen und Männer parken gleich schnell ein”
- “Es gibt keinen Zusammenhang von Babies und Störchen”
- “Früher war es auch nicht besser (sondern gleich gut)”
- “Bei Frauen ist der Anteil, derer, die Statistik mögen gleich hoch wie bei Männern” (Null Unterschied zwischen den Geschlechtern) □

Vorteil des Hypothesen testen ist das klare, einfache Ergebnis – die Hypothese ist abgelehnt, angenommen, oder die Datenlage ist unklar. Das unterstützt die Entscheidungsfindung, da es die Komplexität reduziert.

Man kann Hypothesen nicht bestätigen

Karl Poppers These, dass man Hypothesen nicht bestätigen (verifizieren) kann, hatte großen Einfluss auf die Wissenschaftstheorie (und Epistemologie allgemein) ausgeübt (Popper, 2013). Schlagend ist das Beispiel zur Hypothese H “Alle Schwäne sind weiß”. Auch eine große Stichprobe an weißen Schwänen kann die Wahrheit der Hypothese nicht beweisen. Schließlich ist es möglich, dass wir den schwarzen Schwan einfach noch nicht gefunden haben.² Umgekehrt reicht die (zuverlässige) Beobachtung eines einzelnen schwarzen Schwans, um die Hypothese H zu widerlegen (falsifizieren). □

Wirklich nicht?

In der Wissenschaftspraxis werden die meisten Hypothesen probabilistisch untersucht. Komplette sichere Belege, wie in Poppers Beispiel mit dem schwarzen Schwan, gibt es nicht. Das bedeutet, dass Evidenz im bestätigenden wie im widerlegenden Sinne tendenziell (d.h. probabilistisch) zu betrachten ist. Auf dieser Basis und der Basis zuverlässiger, repräsentativer Daten erscheint plausibel, dass Hypothesen sowohl bestätigt als auch widerlegt werden können (Kruschke, 2018; Morey & Rouder, 2011). □

11.3.3 Parameter schätzen

Beim Schätzen von Parametern untersucht man, *wie groß* ein Effekt ist, etwa der Zusammenhang zwischen X und Y. Es geht also um eine Skalierung, um ein *wieviel* und nicht um ein “ja/nein”, was beim Hypothesen testen der Fall ist.

Beim Parameter schätzen gibt es zwei Varianten:

-  **Punktschätzung:** Das Schätzen eines einzelnen Parameterwerts, sozusagen ein “Best Guess”
-  **Bereichsschätzung:** Das Schätzen eines Bereichs plausibler oder wahrscheinlicher Parameterwerte

Allerdings kann man das Parameter schätzen auch wie einen Hypothesentest nutzen: Ist ein bestimmter Wert, etwa die Null, nicht im Schätzbereich enthalten, so kann man die Hypothese verwerfen, dass der Parameter gleich diesem Wert (etwa Null) ist. Das Hypothesen testen ist daher (implizit) im Parameter schätzen enthalten.

Beispiel 11.3 Wie groß ist der Schätzbereich für den Effekt des Parameters “Geschlecht” auf das mittlere Gewicht von Pinguinen? Hat die UV *Geschlecht* einen großen Einfluss auf das mittlere Gewicht dieser Tiere? Anders gefragt: Um welchen Wert sind männliche Tiere im Schnitt schwerer als weibliche Tiere? [Tabelle 11.1](#) gibt uns die Antwort.

```
data(penguins, package = "palmerpenguins")
penguins_nona <-
  penguins |> drop_na(sex, body_mass_g) # keine fehlenden Werte

m_penguins_sex <-
  stan_glm(body_mass_g ~ sex, data = penguins_nona)
```

Tabelle 11.1: Parameterschätzung des Modells m_penguins; der Gewichtsunterschied zwischen den Mittelwerten der Geschlechter beträgt etwa 700 g.

Parameter	Median	95% CI	pd	Rhat	ESS (tail)	Prior
(Intercept)	3863.18	(3754.31, 3971.56)	100%	1.000	2735	Normal (4207.06 +- 2013.04)
sexmale	681.11	(528.74, 843.76)	100%	1.000	2642	Normal (0.00 +- 4020.19)

Grob gesagt sind männliche Tiere ca. 500 g bis 800 g schwerer als weibliche Tiere im Schnitt (95%-ETI), laut unserem Modell; der Punktschätzer liegt bei einem Gewichtsunterschied von ca. 681 g. □

Beispiel 11.4 (Parameterschätzen als Nullhypothesentest)

Forschungsfrage: Sind männliche Pinguine im Schnitt schwerer als weibliche Tiere?

[Gleichung 11.1](#) formalisiert diese Forschungsfrage als statistische Hypothese H .

$$H : \mu_M \geq \mu_F \rightarrow d = \mu_M - \mu_F \geq 0 \quad (11.1)$$

Beim Testen einer Nullhypothese prüft man, ob ein gleich Null ist.

Theorem 11.1 (Nullhypothesentest)

$$H : \mu_M \geq \mu_F \leftrightarrow d = \mu_M - \mu_F \geq 0 \quad \square$$

Der Unterschied zwischen zwei Mittelwerten, d , ist genau dann Null, wenn $\beta_1 = 0$ in unserem Regressionsmodell [m1](#), s. [Theorem 11.1](#). Entsprechend gilt $d \neq 0$ wenn $\beta_1 \neq 0$.

Um die Forschungsfrage zu beantworten, zählen wir wie gewohnt den Anteil der Stichproben in der Post-Verteilung für die UV `sexmale`, die einen Wert größer Null aufweisen:

```
m_penguins_sex_post <-  
  m_penguins_sex |>  
  as_tibble()  
  
m_penguins_sex_post |>  
  count(sexmale > 0)
```

100% (4000 von 4000) Stichproben finden einen Wert größer Null für `sexmale`; das heißt, weibliche Tiere sind leichter bzw. männliche Tiere schwerer (im Durchschnitt). Entsprechend finden 0% der Stichproben einen Wert, der für das Gegenteil spricht (das weibliche Tiere schwerer wären). Damit resümieren wir, dass unser Modell 100% Wahrscheinlichkeit für die Hypothese einräumt: $p_H = 1$. Achtung: Die 100%-ige Sicherheit für die Hypothese stammt aus der kleinen Welt, nicht unbedingt aus der großen Welt.

Einfacher zeigt uns `parameters(m_penguins_sex)`, wie groß die Wahrscheinlichkeit für $\beta_1 > 0$ ist, nämlich anhand des Koeffizienten `pd`, s. [Tabelle 11.1](#).

Aber das Auslesen der Post-Verteilung erlaubt uns auch, andere Hypothesen zu prüfen, etwa die Wahrscheinlichkeit der Hypothese, dass der Gewichtsunterschied zwischen den Geschlechtern mehr als 500 g beträgt.

Vorteil der Parameterschätzung (gegenüber dem Testen von Hypothesen) ist die Nuanciertheit des Ergebnisses, die der Komplexität echter Systeme besser Rechnung trägt.

Übungsaufgabe 11.2 (Interpretation beim Hypothesen testen) Ein Forschungsteam untersucht die Hypothese, dass hohe Bildschirmzeit mit verringerter Intelligenz bei Kindern einhergeht. Dazu vergleichen Sie Kinder, die sehr viel Zeit am Tag am Bildschirm verbringen, mit Kindern, die sehr wenig Zeit am Tag am Bildschirm verbringen (und die im übrigen vergleichbar sind). Sie finden in ihrer Studie einen Effekt von $95\%KI[-4; -2]$ IQ-Punkten, zuungunsten der Kinder mit hoher Bildschirmzeit.

Welche Aussage dazu ist korrekt bzw. passt am besten?

- A. Die H_0 ist als sicher falsch zu verwerfen.
- B. Die H_0 ist als sicher richtig anzunehmen.
- C. Die H_0 ist mit 95% Wahrscheinlichkeit richtig.
- D. Die H_0 ist mit 95% Wahrscheinlichkeit falsch.
- E. Die Datenlage ist unklar, es ist keine Entscheidung möglich. ☐

11.4 ROPE: Bereich von “praktisch Null”

Teil 2

Nullhypothesen sind fast immer falsch, s. [Abbildung 11.2](#).



Abbildung 11.2: Du testest EXAKTE Nullhypothesen?

[Quelle: Imgflip Meme Generator](#)

We do not generally use null hypothesis significance testing in our own work. In the fields in which we work, we do not generally think null hypotheses can be true: in social science and public health, just about every treatment one might consider will have *some* effect, and no comparison or regression coefficient of interest will be exactly zero. We do not find it particularly helpful to formulate and test null hypothesis that we knowe ahead of time cannot be true. (Gelman et al., 2021)

11.4.1 Alternativen zu Nullhypothesen

Nullhypothesen, H_0 , sind z.B.: $\rho = 0$, $\rho_1 = \rho_2$, $\mu_1 = \mu_2$, $\mu = 0$, $\beta_1 = 0$. Nullhypothesen zu testen, ist sehr verbreitet. Ein Grund ist, dass in der Frequentistischen Statistik keine andere Art von Hypothesentest (einfach) möglich ist.³ Ein anderer Grund ist vermutlich, ... wir haben es schon immer so gemacht. 🙄 Alternativen zum Testen von Nullhypothesen sind:

- Posteriori-Intervalle (ETI oder HDI) berichten
- Rope-Konzept (Kruschke, 2018)
- Wahrscheinlichkeit von inhaltlich bedeutsamen Hypothesen quantifizieren (z.B. dass $\beta_1 > 0.42$)
- Wahrscheinlichkeit quantifizieren, dass der Effekt ein positives bzw. ein negatives Vorzeichen hat (*probability of direction*, *pd*)

11.4.2 “Praktisch kein Unterschied”: Das Rope-Konzept

Beispiel 11.5 (Beispiele für ROPE)

- Sagen wir, wenn sich zwei Preismittelwerte um höchstens $d = 100\text{€}$ unterscheiden, gilt dieser Unterschied für einen Marketingmanager als “praktisch gleich”, “praktisch kein Unterschied”, “nicht substanziell”, “unbedeutend” bzw. “vernachlässigbar gering”
- Bei Pinguinarten definiert eine Biologin nach umfangreichem Studium der Literatur, dass ein Unterschied von max. 100 g Körpergewicht “vernachlässigbar wenig” ist.
- Eine findige Geschäftsfrau entscheidet für ihre Firma, dass ein Umsatzunterschied von 100k Euro “praktisch irrelevant” sei. $\square$

Definition 11.1 (ROPE) ROPE (Region of Practical Equivalence) ist ein Bereich um den Nullwert, der als praktisch äquivalent zu Null angesehen wird. $\square$

Wie legt man den Grenzwert d fest, bis zu dem ein Unterschied (Differenz) gerade noch bzw. gerade nicht mehr unbedeutend ist? Die Wahl von d ist *subjektiv* in dem Sinne als sie von inhaltlichen Überlegungen geleitet sein sollte. Diesen Bereich bezeichnen wir den *Indifferenzbereich* (Äquivalenzzone, Bereich eines vernachlässigbaren Unterschieds oder *Region of practical equivalence*, Rope).

Jetzt prüfen wir, ob ein “Großteil” der Posteriori-Stichproben im Rope liegt. Unter “Großteil” wird häufig das 95%-HDI verstanden (das ist auch der Standard der R-Funktion `rope()`, die wir hier nutzen).

Entscheidungsregel nach Kruschke (2018):

- Großteil der Post-Verteilung liegt *innerhalb* von Rope $\rightarrow$ *Annahme* der ROPE-Nullhypothese “praktisch kein Effekt”, H_0
- Großteil der Post-Verteilung liegt *außerhalb* von Rope $\rightarrow$ *Ablehnung* der ROPE-Nullhypothese “praktisch kein Effekt”, H_0
- Ansonsten $\rightarrow$ keine Entscheidung – die Datenlage ist uneindeutig

Mit “Großteil” meinen wir (per Default) das 95%-KI (der Posteriori-Verteilung).

11.4.3 Vernachlässigbarer Regressionseffekt

Kruschke (2018) schlägt vor, einen Regressionskoeffizienten unter folgenden Umständen als “praktisch Null” zu bezeichnen:

Wenn eine Veränderung über “praktisch den ganzen Wertebereich” von X (UV) nur einen vernachlässigbaren Effekt auf Y (AV) hat. Ein vernachlässigbarer Effekt ist dabei $\hat{\gamma} = \pm 0.1 sd_y$. Das impliziert Rope-Grenzen von $\beta_x = \pm 0.1$ für z-standardisierte UV und AV. Einfach gesprochen: Eine vernünftige Voreinstellung für die Rope-Grenzen bei Regressionskoeffizienten sind $\pm 10\%$ der SD der AV.

ROPE-Defaults

Im der Voreinstellung umfasst die Größe des ROPE $\pm 10\%$ der SD der AV. $\square$

11.4.4 HDI-Rope-Entscheidungsregel visualisiert




Abbildung 11.3: Die Entscheidungsregeln zum ROPE illustriert (Kruschke, 2018); A: Verwerfen der ROPE-Hypothese; B und C: Akzeptieren; D-F: Unklare Datenlage, keine Entscheidung zur ROPE-Hypothese

Abbildung 11.3 illustriert die Entscheidungsregel zum ROPE für die drei Situationen *Verwerfen* der ROPE-Hypothese, *Beibehalten* und *unklare Datenlage* (Kruschke, 2018, Abb. 1, S. 272).

11.4.5 Rope berechnen

Hier ist das Modell, das Gewicht als Funktion der Pinguinart erklärt (`m_penguins_species`).

```
m_penguins_species <- stan_glm(body_mass_g ~ species,
  data = penguins,
  refresh = 0, # unterdrückt Ausgabe der Posteriori-Stichproben
  seed = 42 # zur Reproduzierbarkeit
)
```

Den Rope berechnet man mit `rope(model)`, s. [Tabelle 11.2](#).

Tabelle 11.2: Der Rope-Bereich für die Stufen der UV (Arten von Pinguinen)

Die Faktorstufe `Chinstrap` der UV `species` hat doch einen beträchtlichen Teil ihrer Wahrscheinlichkeitsmasse der Posteriori-Verteilung im ROPE. Wir können daher für diese Gruppe das ROPE *nicht* verwerfen. Die Datenlage ist *unklar*. Es ist keine abschließende Entscheidung über die Hypothese möglich.

Aber: `Gentoo` liegt zu 0% im Rope. Für die Gruppe *Gentoo* können wir die ROPE-Hypothese *verwerfen*. Der Effekt von *Gentoo* ist größer als vernachlässigbar. Anders gesagt: Tiere der Art *Gentoo* sind im Schnitt substantiell schwerer als Tiere der Referenzgruppe (*Adelie*). Der ROPE-Grenzwert wurde hier per Voreinstellung auf 80 g Unterschied festgelegt (10% der SD der AV).


Hinweis

Die angegebenen Prozentwerte beziehen sich nicht auf die 100% der Post-Verteilung, sondern (in der Voreinstellung) auf das 95%-ETI. Dabei werden 10% der Streuung der AV als Intervallgrenzen des ROPE angenommen, s. `help(rope)`.


Das hört sich abstrakt an? Dann lassen Sie uns das lieber visualisieren. 🎨

11.4.6 Visualisierung unserer Rope-Werte, `m_penguins_species`

Ein Großteil der Posteriori-Masse von `m_penguins_species` liegt *nicht* innerhalb des Rope. Aber können wir umgekehrt sagen, dass ein Großteil außerhalb liegt? Das erkennt man optisch ganz gut, s. [Abbildung 11.4](#).



(a) Diagramm mit `rope(m_penguins_species) %>% plot()`



(b) Diagramm mit `parameters(m_penguins_species) %>% plot()`

Abbildung 11.4: Rope und HDI überlappen bei Chinstrap, aber nicht bei Gentoo. Im ersten Fall nehmen wir die Rope-Null-Hypothese an, im zweiten Fall verwerfen wir sie.

Das ROPE durchkreuzt die “Berge” der Posteriori-Verteilung für *Chinstrap* deutlich. Aber: Das 95%-HDI liegt nicht komplett innerhalb des Rope. Wir können das Nullhypothese für Chinstrap *nicht verwerfen*, aber auch *nicht bestätigen* – eine unklare Datenlage.

Gentoo hingegen wird vom Rope nicht durchkreuzt, es ist weit entfernt vom “blauen vertikalen Band” des Rope: *Gentoo* liegt außerhalb des Rope. Es gibt einen “substanziellen” Unterschied zwischen dem Mittelwert der AV in Gruppe *Gentoo* und in der Referenzgruppe *Adelie*.

Wir verwerfen die ROPE-Hypothese, die “Praktisch-Null-Hypothese”, in diesem Fall.

11.4.7 Finetuning des Rope

Wir können festlegen, was wir unter “praktischer Äquivalenz” verstehen, also die Grenzen des Ropes verändern. Sagen wir, 200 Gramm sind unsere Grenze für einen vernachlässigbaren Effekt, s. [Abbildung 11.5](#).

```
plot(rope(m_penguins_species, range = c(-200, 200))) +  
  scale_fill_okabeito() # schönes Farbschema
```

Region of Practical Equivalence (ROPE)




Abbildung 11.5: ROPE mit selber eingestellter Grenze von ± 200 (Gramm)

In der Voreinstellung werden 95%-ETI berichtet, das kann man wie folgt ändern, wenn man möchte. Die ROPE-Grenzen sind in [Tabelle 11.3](#) zu sehen.

```
rope(m_penguins_species, range = c(-500, 500), ci = .89, ci_method = "HDI")
```

Tabelle 11.3: ROPE-Grenzen für das Modell `m_penguins_species` mit ROPE-Grenzen von 500 g.

Jetzt wird berichtet, welcher Teil eines 89%-CI⁴ sich im Rope befindet.

Übungsaufgabe 11.3 (Peer-Instruction: Interpretation des ROPE-Anteils) In einer Hochschule wird der Effekt eines “Robo-Professors” auf die Lernleistung der Studierenden untersucht, im Fach Statistik. Der “Robo-Professor” ist ein Computerprogramm auf Basis künstlicher Intelligenz, das den Studierenden den Stoff vermittelt. Dazu wird eine Gruppe von Studierenden von einem menschlichen Dozenten unterrichtet, die andere Gruppe von einem “Robo-Professor”. Nach dem Kurs wird die Lernleistung der Studierenden in einer Prüfung gemessen. Das Regressionsmodell `m_robo` liefert einen Rope-Anteil von 10% für den Koeffizienten `robo_professor`. Welche Aussage dazu ist korrekt?

- A. Der Robo-Professor hat einen Einfluss von 10% auf die Lernleistung der Studierenden.
- B. Der Einfluss des Robo-Professors auf die Lernleistung der Studierenden ist substanziell.
- C. Es gibt keinen Einfluss des Robo-Professors auf die Lernleistung der Studierenden.
- D. Es ist nicht auszuschließen, dass der Robo-Professor keinen substanziellen Einfluss auf die Lernleistung der Studierenden hat.
- E. Der Einfluss des Robo-Professors auf die Lernleistung der Studierenden ist vernachlässigbar. ☐

11.4.8 Beantwortung der Forschungsfrage

Für die Spezeis *Gentoo* wurde ein substanzieller Gewichtsunterschied zur Referenzgruppe, *Adelie*, vom Modell entdeckt. Für *Chinstrap* hingegen ist keine klare inferenzstatistische Aussage hinsichtlich eines Indifferenzbereichs möglich: Es ist plausibel, laut dem Modell, dass es einen praktisch bedeutsamen Unterschied gibt, aber es ist auch plausibel, dass es keinen praktisch bedeutsamen Unterschied gibt.

11.5 Modellgüte

11.5.1 Wozu Modellgüte?

Hat man ein Modell aufgestellt und geprüft und Ergebnisse erhalten, möchte man wissen, wie belastbar diese Ergebnisse sind. Eine Abschätzung zur Belastbarkeit der Modellergebnisse liefern Kennwerte der Modellgüte. Diese Kennwerte zielen z.B. darauf ab, wie *präzise* die Aussagen des Modells sind. Je präziser die Aussagen eines Modells, desto nützlicher ist es natürlich. Bei einer Parameterschätzung erhält man auch Informationen zur Präzision der Schätzung: Ist der Schätzbereich schmal, so ist die Schätzung präzise (und vice versa). Allerdings könnte ein Modell aus mehreren Parameterschätzungen bestehen, die unterschiedlich präzise sind. Da kann es helfen, eine zusammenfassende Beurteilung zur Präzision, oder allgemeiner zur Güte des Modells, zu erhalten. Im Folgenden wird eine von mehreren gebräuchlichen und sinnvollen Kennzahlen vorgestellt, R^2 .

11.5.2 Modellgüte mit R^2 bestimmen

R^2 gibt den Anteil der Gesamtvarianz (der AV) an, den das Modell erklärt. - Höhere Werte von R^2 bedeuten, dass das Modell die Daten besser erklärt. R^2 wird normalerweise auf Basis eines Punktschätzers definiert. Solch eine Definition lässt aber viel Information - über die Ungewissheit der Schätzung - außen vor. Daher ist es wünschenswert, diese Information in R^2 einfließen zu lassen: *Bayes-R-Quadrat*.

Die Post-Verteilung von R^2 kann man sich wie folgt ausgeben lassen, s. [Abbildung 11.6](#).

```
m_penguins_species_r2 <-  
  m_penguins_species %>%  
  r2_posterior() %>%  
  as_tibble()
```

```
hdi(m_penguins_species_r2) %>% # Intervallgrenzen der Post-Verteilung von R2
plot() # visualisieren
```

Highest Density Interval (HDI)




Abbildung 11.6: Die Verteilung von R-Quadrat im Modell `m_penguins_species`

R^2 und σ sind negativ assoziiert: In einem Datensatz mit hohem R^2 ist σ gering und umgekehrt. Beide Koeffizienten berechnen sich auf Basis von σ und haben den gleichen Zweck: die Abschätzung der Güte eines Modells. Im Unterschied zum Frequentistischen R-Quadrat erhält man in der Bayes-Statistik nicht nur einen Punktschätzer für R^2 , sondern wie auch sonst eine Post-Verteilung, so dass man z.B. einen Schätzbereich angeben kann.

Schneller bekommt man den Punkt- und den Intervallschätzer für R^2 mit `r2(m_penguins_species)`.

```
## # Bayesian R2 with Compatibility Interval
##
## Conditional R2: 0.667 (95% CI [0.620, 0.711])
```

11.6 Fazit

Obwohl das Testen von Hypothesen im Moment verbreiteter ist, spricht einiges zugunsten der Vorzüge der Parameterschätzung. Möchte man aber, um sich bestimmter bestehender Forschung anzunähern, einen Hypothesentest, speziell den Test einer Nullhypothese verwenden, so bietet sich das ROPE-Verfahren an.

Übungsaufgabe 11.4 (Zeit für einen Rückblick: Welche Fragen haben Sie im Moment?) Mittlerweile haben wir einen Großteil des Stoffs absolviert. Welche Punkte sind Ihnen offen geblieben? Wo haben Sie noch Fragen?

Die Lehrkraft stellt Ihnen eine (anonyme) Plattform für Ihre Fragen bereit, so dass Sie in Ruhe Ihre offenen Fragen und diejenigen Ihrer Kommilitoninnen und Kommilitonen überdenken können. □

11.7 Aufgaben

1. [Wskt-Schluckspecht](#)
2. [wskt-mtcars-1l](#)
3. [rope-regr](#)
4. [rope1](#)
5. [rope2](#)
6. [rope3](#)

11.7.1 Quiz-Aufgaben

Hier finden Sie Single-Choice-Aufgaben zu diesem Kapitel. Wählen Sie eine Antwort aus und klicken Sie auf das Häkchen, um sie zu überprüfen; über das Fragezeichen erhalten Sie die ausführliche Lösung.

Welche Aussage beschreibt den zentralen Unterschied zwischen dem *Testen von Hypothesen* und dem *Schätzen von Parametern* korrekt?

- ☐ Hypothesentests zielen auf eine (im besten Fall) binäre Ja-Nein-Entscheidung ab ("Die Daten widersprechen der Hypothese oder nicht"); das Schätzen von Parametern liefert stattdessen eine nuanciertere Aussage über die *Größe* eines Effekts (z.B. einen Schätzbereich).
- ☐ Hypothesentests und Parameterschätzungen liefern immer exakt dieselbe Information, nur in unterschiedlicher Darstellung.
- ☐ Ein Hypothesentest kann niemals implizit im Schätzen eines Parameters enthalten sein.
- ☐ Beim Schätzen von Parametern erhält man ausschließlich eine Ja-Nein-Antwort, beim Testen von Hypothesen hingegen einen Wertebereich.
- ☐ Parameter schätzen ist nur in der frequentistischen Statistik möglich, Hypothesen testen nur in der Bayes-Statistik.



Das Kapitel greift Karl Poppers Beispiel der Hypothese "Alle Schwäne sind weiß" auf. Welche Aussage zu diesem Beispiel und seiner Bedeutung für das Testen von Hypothesen ist korrekt?

- ☐ Laut Popper sind Bestätigung und Widerlegung einer Hypothese logisch gleich einfach zu erreichen.
- ☐ Auch eine sehr große Stichprobe weißer Schwäne kann die Hypothese "Alle Schwäne sind weiß" nicht beweisen (verifizieren); die zuverlässige Beobachtung eines einzigen schwarzen Schwans reicht hingegen aus, um sie zu widerlegen (falsifizieren) – Bestätigung und Widerlegung sind also nicht symmetrisch.
- ☐ Popper zeigt, dass man mit ausreichend vielen weißen Schwänen die Hypothese sicher beweisen kann.
- ☐ Das Kapitel schließt aus Poppers Beispiel, dass in der Wissenschaftspraxis überhaupt keine Evidenz für oder gegen Hypothesen gesammelt werden kann.
- ☐ Poppers Beispiel zeigt, dass Hypothesentests in der Bayes-Statistik grundsätzlich unmöglich sind.



Nach der Entscheidungsregel für das ROPE-Verfahren (Kruschke (2018)) gibt es drei mögliche Ergebnisse, je nachdem wie sich die Post-Verteilung eines Effekts zum ROPE-Bereich (Region of Practical Equivalence) verhält. Welche Zuordnung ist korrekt?

- ☐ Liegt der Großteil der Post-Verteilung außerhalb des ROPE, wird die Praktisch-Null-Hypothese angenommen.
- ☐ Liegt auch nur ein einziger Wert der Post-Verteilung im ROPE, wird die Praktisch-Null-Hypothese immer sofort verworfen.
- ☐ Liegt der Großteil (z.B. 95%) der Post-Verteilung *innerhalb* des ROPE, wird die “Praktisch-Null-Hypothese” angenommen; liegt der Großteil *außerhalb*, wird sie verworfen; überlappen sich Post-Verteilung und ROPE nur teilweise, ist keine Entscheidung möglich.
- ☐ Die ROPE-Entscheidungsregel bezieht sich immer auf 100% der Post-Verteilung, niemals auf ein Teilintervall wie das 95%-HDI.
- ☐ Das ROPE-Verfahren liefert grundsätzlich immer eine eindeutige Ja-Nein-Entscheidung, eine unklare Datenlage ist beim ROPE-Verfahren nicht vorgesehen.



Die Standardabweichung der AV (Körpergewicht) in einem Pinguin-Datensatz betrage $sd_y = 800$ g. Nach der im Kapitel beschriebenen Voreinstellung für Regressionskoeffizienten umfasst das ROPE $\pm 10\%$ der SD der AV. Wie groß ist die ROPE-Grenze für einen Regressionskoeffizienten in diesem Fall?

- ☐ $\pm 0,01 \cdot 800 = \pm 8$ g
- ☐ $800 + 10 = 810$ g
- ☐ $\pm 0,10 \cdot 800 = \pm 80$ g
- ☐ ± 800 g
- ☐ $\pm 0,50 \cdot 800 = \pm 400$ g



Im Modell `m_penguins_species` (Referenzgruppe: *Adelie*) liegt ein beträchtlicher Teil der Post-Verteilung für *Chinstrap* innerhalb des ROPE, während *Gentoo* zu 0% im ROPE liegt. Welche Schlussfolgerung zieht das Kapitel daraus?

- ☐ Für *Gentoo* wird die Praktisch-Null-Hypothese verworfen (substanzieller Gewichtsunterschied zur Referenzgruppe); für *Chinstrap* ist die Datenlage hingegen uneindeutig – weder Annahme noch Ablehnung der Praktisch-Null-Hypothese ist gerechtfertigt.
- ☐ Für *Gentoo* ist die Datenlage uneindeutig, für *Chinstrap* wird ein substanzieller Unterschied festgestellt.
- ☐ Beide Ergebnisse (*Chinstrap* und *Gentoo*) erlauben dieselbe eindeutige Schlussfolgerung: kein substanzieller Unterschied zur Referenzgruppe.
- ☐ Für beide Arten, *Chinstrap* und *Gentoo*, wird die Praktisch-Null-Hypothese in gleicher Weise verworfen.
- ☐ Da *Chinstrap* teilweise im ROPE liegt, bedeutet das automatisch, dass es *überhaupt keinen* Unterschied zwischen *Chinstrap* und der Referenzgruppe gibt.



An einer Hochschule wird der Effekt eines “Robo-Professors” (KI-gestützte Lehre) auf die Lernleistung im Fach Statistik untersucht. Das Regressionsmodell m_{robo} liefert für den Koeffizienten robo_professor einen ROPE-Anteil von 10% (d.h. 10% der relevanten Post-Verteilung liegen innerhalb des ROPE, 90% außerhalb). Welche Aussage dazu ist korrekt?

- ☐ Ein ROPE-Anteil von 10% bedeutet automatisch, dass der Effekt vernachlässigbar (praktisch Null) ist.
- ☐ Der Einfluss des Robo-Professors ist eindeutig als substantiell zu bezeichnen, da 90% der Post-Verteilung außerhalb des ROPE liegen.
- ☐ Der Robo-Professor hat einen Einfluss von exakt 10% auf die Lernleistung der Studierenden.
- ☐ Es ist nicht auszuschließen, dass der Robo-Professor keinen substantiellen Einfluss auf die Lernleistung hat – ein ROPE-Anteil von 10% reicht (je nach gewählter Entscheidungsschwelle) meist nicht aus, um die Praktisch-Null-Hypothese eindeutig zu verwerfen.
- ☐ Es gibt definitiv keinen Einfluss des Robo-Professors auf die Lernleistung.



Welcher Unterschied besteht laut Kapitel zwischen dem klassischen (frequentistischen) R^2 und dem Bayes- R^2 zur Beurteilung der Modellgüte?

- ☐ Bayes- R^2 und σ (die Streuung der Vorhersagefehler) sind völlig unabhängig voneinander und stehen in keinem systematischen Verhältnis.
- ☐ Ein hohes Bayes- R^2 bedeutet automatisch, dass ein gefundener Zusammenhang auch kausal ist.
- ☐ Frequentistisches und Bayes- R^2 sind exakt dieselbe Zahl, nur mit unterschiedlichem Namen.
- ☐ R^2 kann in der Bayes-Statistik grundsätzlich nicht berechnet werden.
- ☐ Das frequentistische R^2 ist üblicherweise nur ein Punktschätzer; das Bayes- R^2 liegt hingegen als vollständige Post-Verteilung vor, sodass man zusätzlich einen Schätzbereich für die Modellgüte angeben kann.



Was ist laut Kapitel der zentrale Vorteil der Parameterschätzung gegenüber dem reinen Testen von Hypothesen?

- ☐ Die Parameterschätzung ist immer schneller zu berechnen als ein Hypothesentest.
- ☐ Die Parameterschätzung liefert automatisch Aussagen über Kausalität, während Hypothesentests das nicht können.
- ☐ Die Parameterschätzung liefert ein nuancierteres Ergebnis (z.B. einen Schätzbereich für die Effektgröße), das der Komplexität realer Systeme besser gerecht wird als eine reine Ja-Nein-Entscheidung.
- ☐ Die Parameterschätzung benötigt grundsätzlich keine Daten, nur Vorwissen.
- ☐ Die Parameterschätzung eliminiert jegliche Ungewissheit aus der Analyse.



Die Post-Stichprobe `m_penguins_sex_post` enthält 4000 Werte für den Koeffizienten `sexmale`. Der Befehl `count(sexmale > 0)` liefert: 3980 Werte sind größer als 0, 20 Werte sind kleiner oder gleich 0. Wie hoch ist die Effektwahrscheinlichkeit `pd` (probability of direction) für diesen Effekt?

- ☐ $pd = \frac{3980}{4000} = 0,995$, also 99,5%
- ☐ $pd = \frac{4000}{3980} \approx 1,005$
- ☐ $pd = 3980$
- ☐ $pd = \frac{3980}{20} = 199$
- ☐ $pd = \frac{20}{4000} = 0,005$, also 0,5%



Das Kapitel zitiert Gelman & Kollegen mit der Aussage, dass man exakte Nullhypothesen (z.B. $\beta_1 = 0$) in den Sozial- und Gesundheitswissenschaften kaum je für “wirklich wahr” hält. Welche Schlussfolgerung zieht das Kapitel daraus für die Praxis?

- ☐ Statt exakte Nullhypothesen zu testen, sind Alternativen wie das Berichten von Post-Intervallen, das ROPE-Konzept, die Quantifizierung inhaltlich bedeutsamer Hypothesen oder die probability of direction (`pd`) oft sinnvoller.
- ☐ Da Nullhypothesen fast nie exakt wahr sind, sollte man in der Praxis komplett auf jegliche statistische Auswertung verzichten.
- ☐ Nullhypothesentests sind in der frequentistischen Statistik grundsätzlich verboten und dürfen nicht mehr verwendet werden.
- ☐ Weil exakte Nullhypothesen fast immer falsch sind, kann man in der Bayes-Statistik grundsätzlich keine Hypothesen mehr formulieren.
- ☐ Die Kritik an exakten Nullhypothesen betrifft ausschließlich die Bayes-Statistik, nicht die frequentistische Statistik.



1. vor allem in der Frequentistischen Statistik ↩
2. Tatsächlich gibt es schwarze Schwäne, aber nicht in Europa: https://en.wikipedia.org/wiki/Black_swan ↩
3. Mittlerweile gibt es neue Frequentistische Ansätze für ein Verfahren ähnlich dem ROPE-Ansatz, der weiter unten vorgestellt wird. ↩
4. 89 ist die nächst kleinste Primzahl unter 95; und 95 wird gemeinhin als Grenzwert für Schätzbereiche verwendet. Damit ist 95 hier eine “magic number”, ein Defacto-Standard ohne hinreichende Begründung. Um darauf hinzuweisen, benutzen einige Forscherinnen und Forscher mit – ähem – subtilem Humor lieber die 89 als die 95. 🙄 ↩

