

13 Konfundierung

13.1 Lernsteuerung

Für dieses Kapitel benötigen Sie folgende R-Pakete:

```
library(dagitty) # DAGs zeichnen
library(tidyverse)
library(rstanarm)
library(easystats)
```

13.2 Datensatz

In diesem Kapitel nutzen wir den Datensatz [Saratoga County](#); s. [Tabelle 13.3](#). Hier gibt es eine [Beschreibung des Datensatzes](#).

DOWNLOAD

Sie können ihn entweder über die Webseite herunterladen:

```
SaratogaHouses_path <- "https://vincentarelbundock.github.io/Rdatasets/csv/mosaicData/SaratogaHouses.csv"
d <- read.csv(SaratogaHouses_path)
```

Oder aber über das Paket `mosaic` importieren:

```
data("SaratogaHouses", package = "mosaicData")
d <- SaratogaHouses # kürzerer Name, das ist leichter zu tippen
```

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- erklären, was eine Konfundierung ist
- DAGs lesen und zeichnen
- Konfundierung in einem DAG erkennen

Dieses Kapitel vermittelt die Grundlagen der Kausalinferenz mittels graphischer Modelle. Ähnliche Darstellungen wie in diesem Kapitel finden sich bei Rohrer (2018).

Hinweis

Die Folien zu diesem Kapitel finden Sie [hier](#).

13.3 Einstieg

In diesem Kapitel steigen wir ein in das Themengebiet *Kausalanalyse* (oder synonym Kausalinferenz). Wir beschäftigen uns also mit der für die Wissenschaft (und den Rest des Universums) zentralen Frage, was die Ursache eines Phänomens ist. In diesem ersten Kapitel zu dem Thema geht es um einen häufigen Fall von “Scheinkorrelation”, also eines Zusammenhangs zwischen UV und AV, der aber gar kein echter kausaler ist, sondern nur Schein. Bei diesem Scheinzusammenhang handelt es sich um die Konfundierung. Im nächsten Kapitel schauen wir uns die verbleibenden Grundbausteine der Kausalinferenz an.

13.3.1 Von Störchen und Babies

Kennen Sie die Geschichte von Störchen und Babies? Ich meine nicht die aus dem Biologieunterricht in der fünften Klasse, sondern in einem statistischen Zusammenhang. Was war da noch mal die Moral von der Geschichte?¹ ☐

13.3.2 Erlaubt eine Regressionsanalyse Kausalschlüsse?

Findet man in einer Regressionsanalyse einen “Effekt”, also ein Regressionsgewicht ungleich Null, heißt das dann, dass die UV die Ursache der AV ist?² Erklären Sie diesen Sachverhalt genauer. ☐

13.4 Statistik, was soll ich tun?

13.4.1 Studie A: Östrogen

13.4.1.1 Medikament einnehmen?

Mit Blick auf [Tabelle 13.1](#): Was raten Sie dem Arzt? Medikament einnehmen, ja oder nein?

Tabelle 13.1: Daten zur Studie A

Gruppe	Mit Medikament	Ohne Medikament
Männer	81/87 überlebt (93%)	234/270 überlebt (87%)
Frauen	192/263 überlebt (73%)	55/80 überlebt (69%)
Gesamt	273/350 überlebt (78%)	289/350 überlebt (83%)

Die Daten stammen aus einer (fiktiven) klinischen Studie, $n = 700$, hoher Qualität (Beobachtungsstudie). Bei Männern scheint das Medikament zu helfen; bei Frauen auch. Aber *insgesamt* (Summe von Frauen und Männern) *nicht*?! Was sollen wir den Arzt raten? Soll er das Medikament verschreiben? Vielleicht nur dann, wenn er das Geschlecht kennt ([Pearl et al., 2016](#))?

13.4.1.2 Kausalmodell zur Studie A

In Wahrheit sieht die kausale Struktur so aus: Das Geschlecht (Östrogen) hat einen Einfluss (+) auf Einnahme des Medikaments und auf Heilung (-). Das Medikament hat einen Einfluss (+) auf Heilung. Betrachtet man die

Gesamt-Daten zur Heilung, so ist der Effekt von Geschlecht (Östrogen) und Medikament *vermengt* (konfundiert, confounded). Die kausale Struktur, also welche Variable beeinflusst bzw. nicht, ist in [Abbildung 13.1](#) dargestellt.




Abbildung 13.1: Zwei direkte Effekte (gender, drug) und ein indirekter Effekt (gender über drug) auf recovery

Betrachtung der Gesamtdaten zeigt in diesem Fall einen *konfundierten* Effekt: Geschlecht konfundiert den Zusammenhang von Medikament und Heilung.

! Wichtig

Betrachtung der Teildaten (d.h. stratifiziert pro Gruppe) zeigt in diesem Fall den wahren, kausalen Effekt. Stratifizieren ist also in diesem Fall der korrekte, richtige Weg. Achtung: Das Stratifizieren ist nicht immer und nicht automatisch die richtige Lösung. Stratifizieren bedeutet, den Gesamtdatensatz in Gruppen oder “Schichten” (“Strata”).

13.4.2 Studie B: Blutdruck

13.4.2.1 Medikament einnehmen?

Mit Blick auf [Tabelle 13.2](#): Was raten Sie dem Arzt? Medikament einnehmen, ja oder nein?

Tabelle 13.2: Daten zur Wirksamkeit eines Medikaments (Studie B)

Gruppe	Ohne Medikament	Mit Medikament
geringer Blutdruck	81/87 überlebt (93%)	234/270 überlebt (87%)
hoher Blutdruck	192/263 überlebt (73%)	55/80 überlebt (69%)
Gesamt	273/350 überlebt (78%)	289/350 überlebt (83%)

Die Daten stammen aus einer (fiktiven) klinischen Studie, $n = 700$, hoher Qualität (Beobachtungsstudie). Bei geringem Blutdruck scheint das Medikament zu schaden. Bei hohem Blutdruck scheint das Medikament auch zu schaden. Aber *insgesamt* (Summe über beide Gruppen) *nicht*, da scheint es zu nutzen?! Was sollen wir den Arzt raten? Soll er das Medikament verschreiben? Vielleicht nur dann, wenn er den Blutdruck nicht kennt ([Pearl et al., 2016](#))?

13.4.2.2 Kausalmodell zur Studie B

Das Medikament hat einen (absenkenden) Einfluss auf den Blutdruck. Gleichzeitig hat das Medikament einen (toxischen) Effekt auf die Heilung. Verringerter Blutdruck hat einen positiven Einfluss auf die Heilung. Sucht man innerhalb der Leute mit gesenktem Blutdruck nach Effekten, findet man nur den toxischen Effekt: Gegeben diesen Blutdruck ist das Medikament schädlich aufgrund des toxischen Effekts. Der positive Effekt der Blutdruck-Senkung ist auf diese Art nicht zu sehen.

Das Kausalmodell von Studie B ist in [Abbildung 13.2](#) dargestellt.




Abbildung 13.2: Drug hat keinen direkten, aber zwei indirekte Effekt auf recovery, einer davon ist heilsam, einer schädlich. Betrachtung der Teildaten zeigt nur den toxischen Effekt des Medikaments, nicht den nützlichen (Reduktion des Blutdrucks).

! Wichtig

Betrachtung der Gesamtdaten zeigt in diesem Fall den wahren, kausalen Effekt. Stratifizieren wäre falsch, da dann nur der toxische Effekt, aber nicht der heilsame Effekt sichtbar wäre.

13.4.3 Studie A und B: Gleiche Daten, unterschiedliches Kausalmodell

Vergleichen Sie die DAGs [Abbildung 13.1](#) und [Abbildung 13.2](#), die die *Kausalmodelle* der Studien A und B darstellen: Sie sind *unterschiedlich*. Aber: Die *Daten* sind *identisch*.

Kausale Interpretation - und damit Entscheidungen für Handlungen - ist nur möglich, da das Kausalmodell bekannt ist. Die Daten alleine reichen nicht. Gut merken.

13.4.4 Sorry, Statistik: Du allein schaffst es nicht

Datenanalyse alleine reicht nicht für Kausalschlüsse. 🤖

Datenanalyse plus Kausalinferenz erlaubt Kausalschlüsse. 📚 + 📊 = 😊

! Wichtig

Für Entscheidungen ("Was soll ich tun?") braucht man kausales Wissen. Kausales Wissen basiert auf einer Theorie (Kausalmodell) plus Daten.

13.4.5 Vertiefung³

13.4.5.1 Studie C: Nierensteine


Nehmen wir an, es gibt zwei Behandlungsvarianten bei Nierensteinen, Behandlung A und B. Ärzte tendieren zu Behandlung A bei großen Steinen (die einen schwereren Verlauf haben); bei kleineren Steinen tendieren die Ärzte zu Behandlung B.

Sollte ein Patient, der nicht weiß, ob sein Nierenstein groß oder klein ist, die Wirksamkeit in der Gesamtpopulation (Gesamtdaten) oder in den stratifizierten Daten (Teildaten nach Steingröße) betrachten, um zu entscheiden, welche Behandlungsvariante er (oder sie) wählt?

Die Größe der Nierensteine hat einen Einfluss auf die Behandlungsmethode. Die Behandlung hat einen Einfluss auf die Heilung. Damit gibt es eine Mediation ("Kette") von Größe → Behandlung → Heilung. Darüber hinaus gibt es noch einen Einfluss von Größe der Nierensteine auf die Heilung.

Das Kausalmodell ist in [Abbildung 13.3](#) dargestellt; [Abbildung 13.4](#) visualisiert alternativ. Beide Varianten zeigen das Gleiche. Sie können sich einen aussuchen. Hier sind beide Varianten gezeigt, damit Sie wissen, dass verschiedene Darstellungsformen möglich sind.

Sollte man hier **size** kontrollieren, wenn man den Kausaleffekt von **treatment** schätzen möchte? Oder lieber nicht kontrollieren?



Ja: In diesem Fall sollte man **size** kontrollieren, denn man ist am Effekt des **treatments** interessiert. Würde man nicht **size** kontrollieren, bekäme man den "vermengten" Effekt von **size** und **treatment**, also keine (belastbare) Aussage über den Effekt der Behandlung.

13.4.5.2 Mehr Beispiele

Beispiel 13.1 Studien zeigen, dass Einkommen und Heiraten (bzw. verheiratet sein) hoch korrelieren. Daher wird sich dein Einkommen erhöhen, wenn du heiratest. ☐

Beispiel 13.2 Studien zeigen, dass Leute, die sich beeilen, zu spät zu ihrer Besprechung kommen. Daher lieber nicht beeilen, oder du kommst zu spät zu deiner Besprechung. ☐

13.4.6 Zwischenfazit

Bei *Beobachtungsstudien* ist aus den Daten alleine nicht herauszulesen, ob eine Intervention wirksam ist, ob es also einen kausalen Effekt von der Intervention (angenommen Ursache) auf eine AV (Wirkung) gibt. Damit ist auch nicht zu erkennen, welche Entscheidung zu treffen ist. Nur Kenntnis des Kausalmodells zusätzlich zu den Daten erlaubt, eine Entscheidung sinnvoll zu treffen.

Bei *experimentellen Daten* ist die Kenntnis des Kausalmodells nicht nötig (wenn das Experiment handwerklich gut gestaltet ist): Das Randomisieren der Versuchspersonen zu Gruppen und das Kontrollieren der Versuchsbedingungen sorgen dafür, dass es keine Konfundierung gibt.

13.5 Konfundierung

13.5.1 Die Geschichte von Angie und Don



Don, Immobilienmogul,
Auftraggeber



Angie, Data Scientistin.



Wolfie, Post-Nerd, kommt in
dieser Geschichte aber nicht vor

 [Don und Angie](#)

13.5.2 Datensatz ‘Hauspreise im Saratoga County’

Importieren Sie den Datensatz `SaratogaHouses`, s. [Kapitel 13.2](#).

Tabelle 13.3: Saratoga-County-Datensatz

13.5.3 Immobilienpreise in einer schicken Wohngegend vorhersagen

“Finden Sie den Wert meiner Immobilie heraus! Die Immobilie muss viel wert sein!”

 Das ist Don, Immobilienmogul, Auftraggeber.

Das finde ich heraus. Ich mach das wissenschaftlich.

  Das ist Angie, Data Scientistin.

13.5.4 Modell 1: Preis als Funktion der Anzahl der Zimmer

“Hey Don! Mehr Zimmer, mehr Kohle!”  

Modell 1 (`m1`) modelliert den Hauspreis als Funktion der Zimmerzahl, s. [Abbildung 13.5](#).




Abbildung 13.5: Modell m1

“Jedes Zimmer mehr ist knapp 50 Tausend wert. Dein Haus hat einen Wert von etwa 150 Tausend Dollar, Don.”



Zu wenig! 🤔



Berechnen wir das Modell `m1`; der Punktschätzer des Parameters `bedroom` steht in [Tabelle 13.4](#).

```
m1 <- stan_glm(price ~ bedrooms,
  refresh = 0,
  seed = 42,
  data = d)
```

```
point_estimate(m1)
```

Tabelle 13.4: Parameter für m1

`point_estimates(modell)` gibt die Punktschätzer der Parameter eines Modells zurück, aber nicht die Schätzbereiche. Möchten Sie beides, können Sie die Funktion `parameters(modell)` nutzen.⁴

Mit `estimate_predictions` können wir Vorhersagen berechnen (bzw. schätzen; die Vorhersagen sind ja mit Ungewissheit verbunden, daher ist “schätzen” vielleicht das treffendere Wort). [Tabelle 13.5](#) zeigt den laut `m1` vorhergesagten Hauspreis für ein Haus mit 2 Zimmern.

```
dons_house <- tibble(bedrooms = 2)
estimate_prediction(m1, data = dons_house)
```

Tabelle 13.5: Vorhersage des Hauspreises für ein Haus mit 2 Zimmern

Model-based Predictions

bedrooms	Predicted	SE	95% CI
2	1.55e+05	91197.19	(-17709.68, 3.33e+05)

Variable predicted: price

13.5.5 Don hat eine Idee

“Ich bau eine Mauer! Genial! An die Arbeit, Angie!” 🧑

Don hofft, durch Verdopplung der Zimmerzahl den doppelten Verkaufspreis zu erzielen. Ob das klappt?

“Das ist keine gute Idee, Don.”



Berechnen wir die Vorhersagen für Dons neues Haus (mit den durch Mauern halbierten Zimmern), s.

[Tabelle 13.6](#).⁵

```
dons_new_house <- tibble(bedrooms = 4)
estimate_prediction(m1, dons_new_house)
predict(m1, newdata = dons_new_house)
```

Tabelle 13.6: Vorhergesagter Hauspreis laut m1 für ein Haus mit 4 Zimmern

Model-based Predictions

bedrooms	Predicted	SE	95% CI
4	2.53e+05	92475.66	(74347.84, 4.36e+05)

Variable predicted: price

Mit 4 statt 2 Schlafzimmer steigt der Wert auf 250k, laut `m1`, s. [Abbildung 13.5](#).

“Volltreffer! Jetzt verdiene ich 100 Tausend mehr! 💰 Ich bin der Größte!” 🧑

Hinweis

Zur Erinnerung: “4e+05” ist die Kurzform der wissenschaftlichen Schreibweise und bedeutet:
 $4 \cdot 100000 = 4 \cdot 10^5 = 400000$

13.5.6 R-Funktionen, um Beobachtungen vorhersagen

`predict(m1, dons_new_house)` oder `point_estimate(m1, dons_new_house)` sagt einen *einzelnen Wert* vorher (den sog. Punktschätzer der Vorhersage).⁶ Ein Intervall wird *nicht* ausgegeben.

`estimate_prediction(m1, dons_new_house)` erstellt *Vorhersageintervalle*, berücksichtigt also zwei Quellen von Ungewissheit:

- Ungewissheiten in den Parametern (Modellkoeffizienten, $\beta_0, \beta_1, \dots$)
- Ungewissheit im “Strukturmodell”: Wenn also z.B. in unserem Modell ein wichtiger Prädiktor fehlt, so können die Vorhersagen nicht präzise sein. Fehler im Strukturmodell schlagen sich in breiten Schätzintervallen (bedingt durch ein großes σ) nieder.

`estimate_expectation(m1, dons_new_house)` erstellt *Konfidenzintervalle* und berücksichtigt also nur eine Quelle von Ungewissheit:

- Ungewissheiten in den Parametern (Modellkoeffizienten)

Die Schätzbereiche sind in dem Fall deutlich kleiner, s. [Tabelle 13.7](#).

```
estimate_expectation(m1, dons_new_house)
```

Tabelle 13.7: Ungewissheit für die Parameter, also die Regressionsgerade, nicht die Beobachtungen

Model-based Predictions			
bedrooms	Predicted	SE	95% CI
4	2.53e+05	3168.87	(2.47e+05, 2.59e+05)

Variable predicted: price

13.5.7 Modell 2

Berechnen wir das Modell `m2: price ~ bedrooms + livingArea`. [Tabelle 13.8](#) gibt den Punktschätzer für die Koeffizienten wider.

```
m2 <- stan_glm(price ~ bedrooms + livingArea,  
  data = d,  
  seed = 42,  
  refresh = 0)  
  
point_estimate(m2, centrality = "median")
```

Tabelle 13.8: Parameter (Punktschätzer, keine Schätzung der Ungewissheit) von m2

Point Estimate	
Parameter	Median
(Intercept)	36533.15
bedrooms	-14138.79
livingArea	125.35

Was sind die Vorhersagen des Modells? [Tabelle 13.9](#) gibt Aufschluss für den laut `m2` vorhersagten Kaufpreis eines Hauses mit 4 Zimmern und 1200 Quadratfuß Wohnfläche; [Tabelle 13.10](#) gibt die Schätzung (laut `m2`) für

den Preis eines Hauses mit 2 Zimmern (und der gleichen Wohnfläche). Die Vorhersage erhält man mit dem Befehl `predict()`:

```
predict(m2, newdata = data.frame(bedrooms = 4, livingArea = 1200))  
##      1  
## 130464
```

Tabelle 13.9: Vorhersage von m2 für ein Haus mit 4 Zimmern und 1200 Einheiten Wohnfläche

Tabelle 13.10: Vorhersage von m2 für ein Haus mit 2 Zimmern und 1200 Einheiten Wohnfläche

Andere, aber ähnliche Frage: Wie viel kostet ein Haus mit sagen wir 4 Zimmern *gemittelt* über die verschiedenen Größen von `livingArea`? Stellen Sie sich alle Häuser mit 4 Zimmern vor (also mit verschiedenen Wohnflächen). Wir möchten nur wissen, was so ein Haus “im Mittel” kostet. Wir möchten also die Mittelwerte pro `bedroom` schätzen, gemittelt für jeden Wert von `bedroom` über `livingArea`. Die Ergebnisse stehen in [Tabelle 13.11](#) und sind in [Abbildung 13.6](#) visualisiert.

```
estimate_means(m2, by = "bedrooms", length = 7)
```

Tabelle 13.11: Vorhersagen des Preises von Häusern mit verschiedener Zimmerzahl gemittelt über die verschiedenen Werte der Wohnfläche; basierend auf m2.




Abbildung 13.6: Hauspreis als Funktion der Zimmerzahl, laut m2

“Die Zimmer zu halbieren, hat den Wert des Hauses *verringert*, Don!”



“Verringert!? Weniger Geld?! Oh nein!”



13.5.8 Die Zimmerzahl ist negativ mit dem Preis korreliert

... wenn man die Wohnfläche (Quadratmeter) kontrolliert, s. [Abbildung 13.7](#).

“Ne-Ga-Tiv!”



Hauspreis als Funktion von Zimmerzahl und Quadratmeter




Abbildung 13.7: Hauspreis stratifizieren

Quellcode

i Hinweis

Aussagen, gleich ob sie statistischer, wissenschaftlicher oder sonstiger Couleur sind, können immer nur dann richtig sein, wenn ihre Annahmen richtig sind. Behauptet etwa ein Modell, dass der Wert einer Immobilie steigt, wenn man mehr Zimmer hat, so ist das kein Naturgesetz, sondern eine Aussage, die nur richtig sein kann, wenn das zugrundeliegende Modell richtig ist. □

13.5.9 Kontrollieren von Variablen



Durch das Aufnehmen von Prädiktoren in die multiple Regression werden die Prädiktoren *kontrolliert* (adjustiert, konditioniert):

Die Koeffizienten einer multiplen Regression zeigen den Zusammenhang β des einen Prädiktors mit y , wenn man den (oder die) anderen Prädiktoren statistisch *konstant hält*.

Man nennt die Koeffizienten einer multiplen Regression daher auch *parziale Regressionskoeffizienten*. Manchmal spricht man, eher umgangssprachlich, auch vom “Netto-Effekt” eines Prädiktors, oder davon, dass ein Prädiktor “bereinigt” wurde vom (linearen) Einfluss der anderen Prädiktoren auf y .

Damit kann man die Regressionskoeffizienten so interpretieren, dass Sie den Effekt des Prädiktors x_1 auf y anzeigen *unabhängig* vom Effekt der anderen Prädiktoren, $x_2, x_3, \dots$ auf y .

Man kann sich dieses Konstanthalten vorstellen als eine Aufteilung in Gruppen: Der Effekt eines Prädiktors x_1 wird für jede Ausprägung (Gruppe) des Prädiktors x_2 berechnet.

! Wichtig

Das Hinzufügen von Prädiktoren kann die Gewichte der übrigen Prädiktoren ändern. □

Aber welche und wie viele Prädiktoren soll ich denn jetzt in mein Modell aufnehmen?! Und welches Modell ist jetzt richtig?!



Leider kann die Statistik keine Antwort darauf geben.



Wozu ist sie dann gut?!



! Wichtig

In Beobachtungsstudien hilft nur ein (korrektes) Kausalmodell. Ohne Kausalmodell ist es *nutzlos*, die Regressionskoeffizienten (oder eine andere Statistik) zur Erklärung der Ursachen heranzuziehen: Die Regressionskoeffizienten können sich wild ändern, wenn man Prädiktoren hinzufügt oder weglässt. Es können sich sogar die *Vorzeichen der Regressionsgewichte ändern*; in dem Fall spricht man von einem Simpson-Paradox.

13.5.10 Welches Modell richtig ist, kann die Statistik nicht sagen

Often people want statistical modeling to do things that statistical modeling cannot do. For example, we'd like to know whether an effect is “real” or rather spurious. Unfortunately, modeling merely quantifies uncertainty in the precise way that the model understands the problem. Usually answers to large world questions about truth and causation depend upon information not included in the model. For example, any observed correlation between an outcome and predictor could be eliminated or reversed once another predictor is added to the model. But if we cannot think of the right variable, we might never notice. Therefore all statistical models are vulnerable to and demand critique, regardless of the precision of their estimates and apparent accuracy of their predictions. Rounds of model criticism and revision embody the real tests of scientific hypotheses. A true hypothesis will pass and fail many statistical “tests” on its way to acceptance.

– McElreath (2020), S. 139

13.5.11 Kausalmodell für Konfundierung, km1

Das Kausalmodell km1 ist in [Abbildung 13.8](#) dargestellt; vgl. [Abbildung 13.7](#).




Abbildung 13.8: Kausalmodell km1 - Eine Erklärung (von mehreren) für m1 bzw. die Daten, die m1 zugrunde liegen

Wenn dieses Kausalmodell stimmt, findet man eine *Scheinkorrelation* zwischen **price** und **bedrooms**. Eine Scheinkorrelation ist ein Zusammenhang, der *nicht* auf einem kausalen Einfluss beruht. **d_connected** heißt, dass die betreffenden Variablen “verbunden” sind durch einen gerichteten (**d** wie directed) Pfad, durch den die Assoziation (Korrelation) wie durch einen Fluss fließt 🌊. **d_separated** heißt, dass sie *nicht* **d_connected** sind.

13.5.12 m2 kontrolliert die Konfundierungsvariable **livingArea**

Beispiel 13.3 In [Abbildung 13.8](#) ist **living area** eine Konfundierungsvariable für den Zusammenhang von **bedrooms** und **price**. □

Definition 13.1 (Konfundierungsvariable) Eine Konfundierungsvariable (Konfundierer) ist eine Variable, die den Zusammenhang zwischen UV und AV verzerrt, wenn sie nicht kontrolliert wird ([VanderWeele & Shpitser, 2013](#)). □

Wenn das Kausalmodell stimmt, dann zeigt **m2** den kausalen Effekt von **livingArea**.

Was tun wir jetzt bloß?! Oh jeh!



Wir müssen die Konfundierungsvariable kontrollieren.



[Abbildung 13.9](#) zeigt, dass **bedrooms** und **price** *unkorreliert* werden (**d_separated**), wenn man **living area** kontrolliert.




Abbildung 13.9: Durch Kontrolle von living area wird die Assoziation von price und bedrooms aufgehoben.

Durch das Kontrollieren (“adjustieren”), sind **bedrooms** und **price** nicht mehr korreliert, nicht mehr **d_connected**, sondern jetzt **d_separated**.


Definition 13.2 (Blockieren) Das Kontrollieren eines Konfundierers (wie **living_area**) “blockt” den betreffenden Pfad, führt also dazu, dass über diesen Pfad keine Assoziation (z.B. Korrelation) zwischen UV (**bedrooms**) und AV (**price**) mehr vorhanden ist. UV und AV sind dann **d_separated** (“getrennt”). □

13.5.13 Konfundierer kontrollieren


Gehen wir in diesem Abschnitt davon aus, dass **km1** richtig ist.

Ohne Kontrollieren der Konfundierungsvariablen: Regressionsmodell $y \sim x$, [Abbildung 13.10](#), links: Es wird (fälschlich) eine Korrelation zwischen **x** und **y** angezeigt: Scheinkorrelation. *Mit* Kontrollieren der Konfundierungsvariablen: Regressionsmodell $y \sim x + \text{group}$, [Abbildung 13.10](#), rechts.

Ohne Kontrolle der Konfundierungsvariablen



(a) Ohne Kontrolle der Konfundierungsvariablen: Konfundierung tritt auf.



(b) Mit Kontrolle der Konfundierungsvariablen: Konfundierung tritt nicht auf.

Abbildung 13.10: Konfundierung von y und x!

Abbildung 13.10, rechts, zeigt korrekt, dass es keine Korrelation zwischen x und y gibt, wenn $group$ kontrolliert wird. Außerdem sieht man im rechten Teildiagramm, dass es ein Kontrollieren der Variable $group$ durch Aufnahme als Prädiktor in die Regressionsgleichung einem Stratifizieren entspricht (getrennte Berechnung der Regressionsgerade pro Gruppe).

! Wichtig

Kontrollieren Sie Konfundierer. ☐

13.5.14 $m1$ und $m2$ passen nicht zu den Daten, wenn $km1$ stimmt

Laut $km1$ dürfte es keine Assoziation (Korrelation) zwischen $bedrooms$ und $price$ geben, wenn man $livingArea$ kontrolliert, wie in [Abbildung 13.8](#) dargestellt. Es gibt aber noch eine Assoziation zwischen $bedrooms$ und $price$, wenn man $livingArea$ kontrolliert. Daher sind sowohl $m1$ als auch $m2$ nicht mit dem Kausalmodell $km1$ vereinbar.

13.5.15 Kausalmodell 2, $km2$

Unser Modell $m2$ sagt uns, dass beide Prädiktoren jeweils einen eigenen Beitrag zur Erklärung der AV haben.

Daher könnte das folgende Kausalmodell, $km2$, besser passen.

In diesem Modell gibt es eine Wirkkette: $a \rightarrow b \rightarrow p$.

Insgesamt gibt es zwei Kausaleinflüsse von a auf p : $- a \rightarrow p - a \rightarrow b \rightarrow p$

Man nennt die mittlere Variable einer Wirkkette auch einen *Mediator* und den Pfad von der UV (a) über den Mediator (b) zur AV (p) auch *Mediation*, s. [Abbildung 13.11](#).



Abbildung 13.11: Der Effekt von livingArea wird über den Mediator bedrooms auf price vermittelt.

13.5.16 Dons Kausalmodell, km3

So sieht Dons Kausalmodell aus, s. [Abbildung 13.12](#).




Abbildung 13.12: Dons Kausalmodell

“Ich glaube aber an mein Kausalmodell. Mein Kausalmodell ist das größte! Alle anderen Kausalmodelle sind ein Disaster!”



“Don, nach deinem Kausalmodell müssten **bedrooms** und **livingArea** unkorreliert sein. Sind sie aber nicht.”



Rechne doch selber die Korrelation aus, Don:

“Äh, wie ging das nochmal?”



So könntest du das rechnen, Don: `correlation(d, select = c("bedrooms", "livingArea"))`. Oder z.B. so:

```
dons_r <- d %>%
  summarise(cor(bedrooms, livingArea))
```

Die Korrelation liegt also bei 0.66

“Bitte, gerne hab ich dir geholfen, Don.”



13.5.17 Unabhängigkeiten laut der Kausalmodelle

km1: **b**: bedrooms, **p**: price, **a** area (living area), s. [Abbildung 13.8](#).

Das Kausalmodell **km1** behauptet: $b \perp\!\!\!\perp p \mid a$: **bedrooms** sind unabhängig von **price**, wenn man **livingArea** kontrolliert.

Kontrollieren einer Variable Z erreicht man auf einfache Art, indem man sie zusätzlich zur vermuteten Ursache X in die Regressionsgleichung mit aufnimmt, also $y \sim x + z$.

Aber diese behauptete Unabhängigkeit findet sich *nicht* in den Daten wieder, s. [Tabelle 13.8](#). Also: 🌩️ Passt nicht zu den Daten!

km2 **b**: bedrooms, **p**: price, **a** area (living area), s. [Abbildung 13.11](#).

Das Kausalmodell **km2** postuliert *keine* Unabhängigkeiten: Laut **km2** sind alle Variablen des Modells miteinander assoziiert (korreliert).

Hinweis

Ein Modell, in dem alle Variablen miteinander korreliert sind, nennt man auch *saturiert* oder saturiertes Modell. So ein Modell ist empirisch *schwach*. Denn: Behauptet ein Modell, dass die Korrelation zwischen zwei Variablen irgendeinen Wert zwischen -1 und +1 beträgt (nur nicht exakt Null), so ist das eine sehr schwache Aussage (und kaum zu falsifizieren). So ein Modell ist wissenschaftlich wenig wert. Das ist so ähnlich wie ein Modell, das voraussagt, dass es morgen irgendeine Temperatur hat zwischen -30 und +30 Grad (nur nicht exakt Null). Trifft diese Temperaturvorhersage ein, so werden wir nicht gerade beeindruckt sein. 🙄

Fazit: **km2** passt zu den Daten, aber wir sind nicht gerade beeindruckt vom Modell.

km3: **b**: bedrooms, **p**: price, **a** area (living area), s. [Abbildung 13.12](#).

$b \perp\!\!\!\perp a$: **bedrooms** sind unabhängig von **livingArea** (**a**)

🌩️ **km3** passt nicht zu den Daten/zum Modell!

13.6 DAGs: Directed Acyclic Graphs

Was sind DAGs? Wir haben in diesem Kapitel schon viele Beispiele gesehen, z.B. [Abbildung 13.12](#).

Definition 13.3 (DAG) DAGs sind eine bestimmte Art von Graphen zur Analyse von Kausalstrukturen. Ein *Graph* besteht aus Knoten (Variablen) und Kanten (Linien), die die Knoten verbinden. DAGs sind *gerichtet*; die Pfeile zeigen immer in eine Richtung (und zwar von Ursache zu Wirkung). DAGs sind *azyklisch*; die Wirkung eines Knoten darf nicht wieder auf ihn zurückführen. □

Definition 13.4 (Pfad) Ein *Pfad* ist ein Weg durch den DAG, von Knoten zu Knoten über die Kanten, unabhängig von der Pfeilrichtung. □

Der DAG von **km1** ist in [Abbildung 13.8](#) zu sehen.

13.6.1 Leider passen potenziell viele DAGs zu einer Datenlage

Auf Basis der in Dons Modell dargestellten (Un-)Abhängigkeiten der Variablen sind noch weitere Kausalmodelle möglich.

In [Abbildung 13.13](#) sind diese weiteren, möglichen Kausalmodelle für Dons Modell dargestellt. Dabei sind folgende Abkürzungen verwendet: **b**: bedrooms, **p**: price, **a**: area (living area).

Ja, der Job der Wissenschaft ist kein Zuckerschlecken. Aber wenn es einfach wäre, die Kausalstruktur der Phänomene zu entdecken, wären sie längst erkannt, und alle Probleme der Menschheit gelöst.




Abbildung 13.13: Kausalmodelle, die potenziell geeignet sind für Dons Fragestellung

Alle diese DAGs in [Abbildung 13.13](#) haben die *gleichen* Implikationen hinsichtlich der (Un-)Abhängigkeiten zwischen den Variablen. Wir können also leider empirisch nicht bestimmen, welcher der DAGs der richtige ist. Um den richtigen DAG zu identifizieren, bräuchten wir z.B. einen reichhaltigeren DAG, also mit mehr Variablen.

13.6.2 Was ist eigentlich eine Ursache?

Etwas verursachen kann man auch (hochtrabend) als “Kausation” bezeichnen.

i Hinweis

Weiß man, was die Wirkung W einer Handlung H (Intervention) ist, so hat man H als Ursache von W erkannt (McElreath, 2020). □

Definition 13.5 (Kausale Abhängigkeit) Ist X die Ursache von Y , so hängt Y von X ab: Y ist (kausal) abhängig von X . $\square$

Viele Menschen denken - fälschlich - dass Korrelation Kausation bedeuten muss, s. [Abbildung 13.14](#).




Abbildung 13.14: xkcd zum Thema Kausation

[Quelle](#) und [Erklärung](#)

Beispiel 13.4 (Der Schoki-DAG) Der “Schoki-DAG” in [Abbildung 13.15](#) zeigt den DAG für das Schokoladen-Nobelpreis-Modell. $\square$




Abbildung 13.15: Macht Schokolade Nobelpreise?

13.7 Fazit

13.7.1 Zusammenfassung

Sind zwei Variablen korreliert (abhängig, assoziiert), so kann es dafür zwei Gründe geben:

1. Kausaler (“echter”) Zusammenhang
2. Nichtkausaler Zusammenhang (“Scheinkorrelation”)

Man ist daran interessiert, echten (also kausalen) Zusammenhang aufzudecken⁷ und Scheinkorrelation auszuschließen.

Eine von zwei möglichen Ursachen einer Scheinkorrelation ist Konfundierung.⁸

Konfundierung kann man aufdecken, indem man die angenommene Konfundierungsvariable kontrolliert (adjustiert), z.B. indem man sie als Prädiktor in eine Regression aufnimmt.

Ist die Annahme einer Konfundierung korrekt, so löst sich der Scheinzusammenhang nach dem Adjustieren auf.

Löst sich der Scheinzusammenhang nicht auf, sondern drehen sich die Vorzeichen der Zusammenhänge nach Adjustieren um, so spricht man von einem *Simpson-Paradox*.

Die *Daten alleine* können *nie* sagen, welches Kausalmodell der Fall ist in einer Beobachtungsstudie. Fachwissen (inhaltliches wissenschaftliches Wissen) ist nötig, um DAGs auszuschließen.

13.7.2 Ausstieg

Beispiel 13.5 (Schoki macht Nobelpreis!?) Eine Studie fand eine starke Korrelation, $r = 0.79$ zwischen der Höhe des Schokoladenkonsums eines Landes und der Anzahl der Nobelpreise eines Landes (Messerli, 2012), s.

[Abbildung 13.16](#).




Abbildung 13.16: Je mehr Schoki, desto mehr Nobelpreise

! Wichtig

Korrelation ungleich Kausation! Korrelation *kann* bedeuten, dass eine Kausation vorliegt, aber es muss auch nicht sein, dass Kausation vorliegt. Liegt Korrelation ohne Kausation vor, so spricht man von einer *Scheinkorrelation*. Um Scheinkorrelation von echter Assoziation (auf Basis von Kausation) abzugrenzen, muss man die Kausalmodelle überprüfen, so wie wir das hier tun.

13.7.3 Vertiefung

Es gibt viel Literatur zu dem Thema Kausalinferenz. Ein Artikel, der einen vertieften Einblick in das Thema Konfundierung liefert z.B. Tennant et al. (2020) oder Suttrop et al. (2015). Allerdings sollte man neben Konfundierung noch die drei anderen “Atome” der Kausalinferenz - Kollision, Mediation (und Nachfahre) - kennen, um gängige Fragen der Kausalinferenz bearbeiten zu können.

13.8 Aufgaben

- [Sammlung "kausal"](#)

13.8.1 Quiz-Aufgaben

Hier finden Sie Single-Choice-Aufgaben zu diesem Kapitel. Wählen Sie eine Antwort aus und klicken Sie auf das Häkchen, um sie zu überprüfen; über das Fragezeichen erhalten Sie die ausführliche Lösung.

Was ist laut Definition im Kapitel eine Konfundierungsvariable (ein Konfundierer)?

- ☐ Eine Variable, die per Definition niemals mit der AV korreliert sein kann.
- ☐ Eine Variable, die den Zusammenhang zwischen UV und AV vermittelt (also auf dem kausalen Pfad von UV zu AV liegt).
- ☐ Eine Variable, die ausschließlich von der AV beeinflusst wird, aber selbst keinen Einfluss auf irgendetwas hat.
- ☐ Jede beliebige zusätzliche Variable, die man in ein Regressionsmodell aufnimmt, unabhängig von ihrer kausalen Rolle.
- ☐ Eine Variable, die den (beobachteten) Zusammenhang zwischen UV und AV verzerrt, wenn sie nicht kontrolliert wird – z.B. weil sie sowohl auf die UV als auch auf die AV kausal wirkt.



In Studie A (Östrogen-Medikament) hilft das Medikament sowohl bei Männern als auch bei Frauen jeweils innerhalb der Gruppe, aber in den *Gesamtdaten* (über beide Geschlechter summiert) scheint es zu schaden. Das Kausalmodell zeigt: Geschlecht beeinflusst sowohl die Einnahme des Medikaments als auch die Heilung direkt. Was ist laut Kapitel die korrekte Handlungsempfehlung?

- ☐ Da sich Gesamt- und Teildaten widersprechen, kann man aus diesen Daten überhaupt keine Aussage ableiten, unabhängig vom Kausalmodell.
- ☐ Man sollte die *stratifizierten* (nach Geschlecht getrennten) Daten betrachten, da Geschlecht hier ein Konfundierer ist, der den Gesamteffekt verzerrt; die Teildaten zeigen den wahren kausalen Effekt.
- ☐ Man sollte ausschließlich die *Gesamtdaten* betrachten, da diese immer den zuverlässigeren Schluss erlauben.
- ☐ Die Entscheidung zwischen Gesamt- und Teildaten ist in diesem Fall komplett beliebig und macht keinen inhaltlichen Unterschied.
- ☐ Stratifizieren ist in diesem Fall grundsätzlich falsch, weil es prinzipiell nie korrekt sein kann, Daten in Untergruppen aufzuteilen.



In Studie B (Blutdruck-Medikament) senkt das Medikament den Blutdruck (was der Heilung nützt), hat aber gleichzeitig einen toxischen Effekt auf die Heilung. Innerhalb jeder Blutdruck-Gruppe (stratifiziert) scheint das Medikament zu schaden, aber in den *Gesamtdaten* scheint es zu nutzen. Warum ist es in diesem Fall – anders als in Studie A – richtig, die *Gesamtdaten* zu betrachten statt zu stratifizieren?

- ☐ Weil in Studie B per Zufall randomisiert wurde, spielt die Wahl zwischen Gesamt- und Teildaten überhaupt keine Rolle.
- ☐ Weil die Stichprobengröße in Studie B größer ist als in Studie A, sind Gesamtdaten hier automatisch vertrauenswürdiger.
- ☐ Blutdruck ist hier ein *Mediator* (liegt auf dem kausalen Pfad Medikament → Blutdruck → Heilung); stratifiziert man nach diesem Mediator, blockiert man den heilsamen Effekt Pfad und sieht nur noch den toxischen Effekt – die Gesamtdaten zeigen hingegen den Nettoeffekt aus beiden Pfaden.
- ☐ Blutdruck ist in diesem Modell ein Konfundierer, daher muss man wie in Studie A stratifizieren.
- ☐ Es gibt grundsätzlich keinen Unterschied zwischen Studie A und Studie B – in beiden Fällen ist die gleiche Vorgehensweise korrekt.



In der Nierenstein-Studie C beeinflusst die Größe des Nierensteins sowohl, welche Behandlung (A oder B) ein Arzt wählt, als auch direkt die Heilungschance. Man ist am *kausalen Effekt der Behandlung* auf die Heilung interessiert. Sollte man die Steingröße (**size**) statistisch kontrollieren?

- ☐ Es spielt keine Rolle, ob man **size** kontrolliert, da es laut Kausalmodell keinen Einfluss auf **recovery** hat.
- ☐ Ja: **size** ist ein Konfundierer für den Zusammenhang von **treatment** und **recovery** (da **size** sowohl **treatment** als auch **recovery** beeinflusst); ohne Kontrolle von **size** erhält man einen mit dem Effekt von **size** vermengten, nicht belastbaren Effekt von **treatment** .
- ☐ Nein, man sollte **size** niemals in ein Modell zur Schätzung des Behandlungseffekts aufnehmen.
- ☐ Da **size** nur **treatment** , aber nicht **recovery** direkt beeinflusst, ist eine Kontrolle unnötig.
- ☐ Man sollte stattdessen **treatment** kontrollieren, wenn man den Effekt von **size** auf **recovery** schätzen möchte, aber **size** selbst braucht bei der Frage nach dem **treatment** -Effekt keine Beachtung.



Im Kausalmodell **km1** (bedrooms ← livingArea → price, sowie bedrooms → price) wird **livingArea** als Konfundierer identifiziert. Kontrolliert man **livingArea** (nimmt sie als Prädiktor ins Regressionsmodell auf), werden **bedrooms** und **price** “d-separiert” statt “d-verbunden”. Was bedeutet das Konzept des “Blockierens” in diesem Zusammenhang?

- ☐ Das Kontrollieren des Konfundierers **livingArea** unterbricht (“blockt”) den Pfad, über den eine Scheinassoziation zwischen **bedrooms** und **price** fließen konnte – nach dem Blockieren sind **bedrooms** und **price** statistisch nicht mehr assoziiert, wenn **km1** korrekt ist.
- ☐ Blockieren führt immer dazu, dass eine bestehende *kausale* Verbindung zwischen zwei Variablen unsichtbar gemacht wird, unabhängig vom zugrundeliegenden DAG.
- ☐ Blockieren ist nur bei experimentellen, niemals bei Beobachtungsdaten anwendbar.
- ☐ “Blockieren” bedeutet, dass man eine Variable komplett aus dem Datensatz löscht, statt sie zu kontrollieren.
- ☐ “d-verbunden” (d-connected) bedeutet, dass zwei Variablen niemals assoziiert sein können.



Das Kausalmodell **km2** (mit einer Wirkkette **livingArea** → **bedrooms** → **price** sowie einem direkten Pfeil **livingArea** → **price**) postuliert keine einzige Unabhängigkeit zwischen den Variablen – alle sind miteinander assoziiert. Warum bezeichnet das Kapitel ein solches “saturiertes” Modell als “empirisch schwach”?

- ☐ Ein saturiertes Modell ist schwach, weil es in R technisch nicht berechnet werden kann.
- ☐ Saturierte Modelle sind grundsätzlich falsch und sollten niemals verwendet werden.
- ☐ Ein saturiertes Modell behauptet lediglich, dass irgendeine Korrelation zwischen den Variablen besteht (irgendein Wert zwischen -1 und $+1$, nur nicht exakt Null) – eine derart unspezifische Behauptung lässt sich kaum durch Daten widerlegen (falsifizieren) und ist daher wissenschaftlich wenig aussagekräftig.
- ☐ Ein saturiertes Modell ist deshalb schwach, weil es weniger Parameter enthält als andere Modelle.
- ☐ Ein saturiertes Modell ist empirisch schwach, weil es niemals zu den Daten passt.



Das Kapitel erwähnt, dass sich beim Adjustieren (Kontrollieren) von Prädiktoren manchmal sogar die *Vorzeichen* der Regressionsgewichte umkehren können (z.B. wird der Effekt von **bedrooms** auf **price** negativ, sobald man **livingArea** kontrolliert). Wie wird dieses Phänomen im Kapitel bezeichnet, und was unterscheidet es vom “normalen” Verschwinden einer Scheinkorrelation durch Konfundierung?

- ☐ Ein Simpson-Paradox tritt ausschließlich bei experimentellen (randomisierten) Studien auf, niemals bei Beobachtungsstudien.
- ☐ Man spricht von einem *Simpson-Paradox*: Anders als beim “normalen” Auflösen einer Scheinkorrelation (bei der der Effekt beim Adjustieren einfach auf ungefähr Null schrumpft) dreht sich hier das Vorzeichen des Effekts komplett um.
- ☐ Man spricht von einem Simpson-Paradox, wenn sich beim Adjustieren gar nichts an den Koeffizienten ändert.
- ☐ Ein Simpson-Paradox liegt vor, wenn ein Modell schlicht nicht konvergiert.
- ☐ Ein Simpson-Paradox bedeutet, dass die Stichprobengröße zu klein für eine verlässliche Schätzung war.



Das Kapitel zeigt, dass es zu Dons Datenlage (Zusammenhänge zwischen **bedrooms**, **livingArea**, **price**) mehrere unterschiedliche DAGs gibt, die *alle* dieselben (Un-)Abhängigkeitsimplikationen haben. Was folgt daraus für die Kausalanalyse?

- ☐ Wenn mehrere DAGs zu denselben Daten passen, ist automatisch der DAG mit den meisten Pfeilen korrekt.
- ☐ Existieren mehrere passende DAGs, bedeutet das, dass Kausalanalyse in diesem Fall grundsätzlich unmöglich und sinnlos ist.

- ☐ Die Daten allein können unter mehreren, empirisch äquivalenten DAGs nicht entscheiden, welcher der “richtige” ist; um den korrekten DAG zu identifizieren, braucht man zusätzliches Fachwissen bzw. einen reichhaltigeren DAG mit mehr Variablen.
- ☐ Man kann das Problem lösen, indem man einfach mehr Beobachtungen (eine größere Stichprobe) derselben Variablen sammelt.
- ☐ Empirisch äquivalente DAGs unterscheiden sich immer in der Anzahl der beteiligten Variablen.



Warum betont das Kapitel, dass man bei *experimentellen* Daten (im Gegensatz zu Beobachtungsdaten) das Kausalmodell nicht unbedingt kennen muss, um Kausalschlüsse zu ziehen?

- ☐ Randomisierung sorgt dafür, dass die UV keinen Effekt mehr auf die AV haben kann.
- ☐ Eine handwerklich gute Randomisierung der Versuchspersonen zu Gruppen sorgt dafür, dass mögliche Konfundierer gleichmäßig auf die Gruppen verteilt werden und damit systematisch keinen Unterschied mehr zwischen den Gruppen erklären können – Konfundierung wird dadurch verhindert.
- ☐ Bei Experimenten gibt es per Definition überhaupt keine weiteren Variablen außer UV und AV.
- ☐ Experimentelle Daten sind grundsätzlich größer (mehr Beobachtungen) als Beobachtungsdaten, weshalb Konfundierung automatisch unwahrscheinlicher wird.
- ☐ Auch bei Experimenten braucht man zwingend ein vollständiges Kausalmodell mit allen Konfundierern, genau wie bei Beobachtungsstudien.



Modell `m1` (`price ~ bedrooms`) sagt für ein Haus mit 2 Zimmern einen Preis von 150 (Tausend Dollar) und für ein Haus mit 4 Zimmern einen Preis von 250 (Tausend Dollar) voraus. Welche Werte ergeben sich für den Achsenabschnitt (β_0) und die Steigung (β_1) des linearen Modells $\text{price} = \beta_0 + \beta_1 \cdot \text{bedrooms}$?

- ☐ $\beta_1 = 50; \beta_0 = 150$ (der vorhergesagte Preis bei 2 Zimmern selbst)
- ☐ $\beta_1 = 250 - 150 = 100; \beta_0 = 0$
- ☐ $\beta_1 = \frac{250 - 150}{4 - 2} = 50; \beta_0 = 150 + 50 \cdot 2 = 250$
- ☐ $\beta_1 = \frac{250 - 150}{4} = 25; \beta_0 = 150$
- ☐ $\beta_1 = \frac{250 - 150}{4 - 2} = 50; \beta_0 = 150 - 50 \cdot 2 = 50$





1. Nur weil die Variablen `Anzahl_Stoerche` und `Anzahl_Babies` korreliert sind, heißt das nicht, dass das eine die Ursache des anderen sein muss. ↩
2. Nein ↩
3. Dieser Abschnitt ist prüfungsrelevant, birgt aber nichts Neues. ↩
4. In aller Regel macht es mehr Sinn, die Schätzbereiche der Punktschätzer auch zu betrachten. Nur die Punktschätzer zu betrachten vernachlässigt wesentliche Information. ↩
5. Anstelle von `estimate_relation()` kann man auch (einfacher vielleicht) `predict()` verwenden: `predict(m1, newdata = dons_new_house)`. Allerdings gibt `predict()` nur den vorhergesagten Wert aus. `estimate_prediction()` gibt noch zusätzlich das *Vorhersageintervall* aus, berücksichtigt also die (doppelte) Ungewissheit der Vorhersage. Mit anderen Worten: `estimate_prediction` gibt die PPV aus. ↩
6. Bei `predict` ist dieser Wert der Median der Post-Verteilung; bei `point_estimate` kann man sich aussuchen, ob der Median, der Mittelwert oder der wahrscheinlichste Wert der Post-Verteilung als Schätzwert verwendet wird. ↩
7. zu “identifizieren” ↩
8. Die andere Ursache ist die Kollisionsverzerrung, s. [Kapitel 13](#). ↩