

14 Die Atome der Kausalität

14.1 Lernsteuerung

Für dieses Kapitel benötigen Sie folgende R-Pakete:

```
library(tidyverse)
library(rstanarm)
library(easystats)
```

Wir nutzen wieder den Datensatz [Saratoga County](#); s. [Tabelle 13.3](#). Hier gibt es eine [Beschreibung des Datensatzes](#).

Sie können ihn entweder über die Webseite herunterladen:

```
SaratogaHouses_path <- "https://vincentarelbundock.github.io/Rdatasets/csv/mosaicData/SaratogaHouses.csv"
d <- read.csv(SaratogaHouses_path)
```

Oder aber über das Paket `mosaic` importieren:

```
data("SaratogaHouses", package = "mosaicData")
d <- SaratogaHouses # kürzerer Name, das ist leichter zu tippen
```

Alternativ können Sie ihn hier herunterladen:

DOWNLOAD

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- erklären, wann eine Kausalaussage gegeben eines DAGs berechtigt ist
- erklären, warum ein statistisches Modell ohne Kausalmodell zumeist keine Kausalaussagen treffen kann
- die “Atome” der Kausalität eines DAGs benennen
- “kausale Hintertüren” schließen

Dieses Kapitel vermittelt die Grundlagen der Kausalinferenz mittels graphischer Modelle. Ähnliche Darstellungen wie in diesem Kapitel finden sich bei Rohrer (2018).

Hinweis

Die Folien zu diesem Kapitel finden Sie [hier](#).

14.2 Kollision

14.2.1 Kein Zusammenhang von Intelligenz und Schönheit (?)

Gott ist gerecht (?)

Zumindest findet sich in folgenden Daten kein Zusammenhang von Intelligenz (**talent**) und Schönheit (**looks**), wie [Abbildung 14.1](#) illustriert. Für geringe Intelligenzwerte gibt es ein breites Spektrum von Schönheitswerten und für hohe Intelligenzwerte sieht es genauso aus.




Abbildung 14.1: Kein Zusammenhang von Schlauheit und Schönheit in den Daten

14.2.2 Aber Ihre Dates sind entweder schlau oder schön

Seltsamerweise beobachten Sie, dass die Menschen, die Sie daten (Ihre Dates), entweder schön sind oder schlau - aber selten beides gleichzeitig (schade), s. [Abbildung 14.2](#).




Abbildung 14.2: Ihre Datingpartner sind komischerweise entweder schlau oder schön (aber nicht beides), zumindest in der Tendenz.

Wie kann das sein?

14.2.3 DAG zur Rettung



Der DAG in [Abbildung 14.3](#) bietet eine rettende Erklärung.




Abbildung 14.3: Date als gemeinsame Wirkung von Schönheit und Intelligenz. Stratifiziert man die gemeinsame Wirkung (dates), so kommt es zu einer Scheinkorrelation zwischen Schönheit und Intelligenz.

Eine ähnliche Visualisierung des gleichen Sachverhalts zeigt [Abbildung 14.4](#).




Abbildung 14.4: Durch Kontrolle der gemeinsamen Wirkung entsteht eine Scheinkorrelation zwischen den Ursachen

14.2.4 Was ist eine Kollision?

Definition 14.1 (Kollision) Als *Kollision* (Kollisionsverzerrung, Auswahlverzerrung, engl. collider) bezeichnet man einen DAG, bei dem eine Wirkung zwei Ursachen hat (eine gemeinsame Wirkung zweier Ursachen) (Pearl et al., 2016, p. 40). □

Kontrolliert man die *Wirkung* **m**, so entsteht eine *Scheinkorrelation* zwischen den Ursachen **x** und **y**. Kontrolliert man die Wirkung *nicht*, so entsteht *keine Scheinkorrelation* zwischen den Ursachen, s. [Abbildung 14.3](#), vgl. Rohrer (2018).

! Wichtig

Man kann also zu viele oder falsche Prädiktoren einer Regression hinzufügen, so dass die Koeffizienten nicht die kausalen Effekte zeigen, sondern durch Scheinkorrelation verzerrte Werte.

💡 Tipp

14.2.5 Einfaches Beispiel zur Kollision

In der Zeitung *Glitzer* werden nur folgende Menschen gezeigt:

- Schöne Menschen 🧚
- Reiche Menschen 💰

Gehen wir davon aus, dass Schönheit und Reichtum unabhängig voneinander sind.

Übungsaufgabe 14.1 Wenn ich Ihnen sage, dass Don nicht schön ist, aber in der *Glitzer* häufig auftaucht, was lernen wir dann über seine finanzielle Situation?¹ ☐

“Ich bin schön, unglaublich schön, und groß, großartig, tolle Gene!!!” 🧑

14.2.6 Noch ein einfaches Beispiel zur Kollision

“So langsam check ich’s!” 🧑²

Sei $Z = X + Y$, wobei X und Y unabhängig sind.

Wenn ich Ihnen sage, $X = 3$, lernen Sie nichts über Y , da die beiden Variablen unabhängig sind. Aber: Wenn ich Ihnen zuerst sage, $Z = 10$, und dann sage, $X = 3$, wissen Sie sofort, was Y ist ($Y = 7$).

Also: X und Y sind abhängig, gegeben Z : $X \not\perp Y \mid Z$.³

14.2.7 Durch Kontrollieren entsteht eine Verzerrung bei der Kollision

[Abbildung 14.3](#) zeigt: Durch Kontrollieren entsteht eine Kollision, eine Scheinkorrelation zwischen den Ursachen.

Kontrollieren kann z.B. bedeuten:

- *Stratifizieren*: Aufteilen von **date** in zwei Gruppen und dann Analyse des Zusammenhangs von **talent** und **looks** in jeder Teilgruppe von **date**
- *Kontrollieren mit Regression*: Durch Aufnahme von **date** als Prädiktor in eine Regression zusätzlich zu **looks** mit **talent** als Prädiktor

Ohne Kontrolle von **date** entsteht *keine* Scheinkorrelation zwischen **Looks** und **Talent**. Der Pfad (“Fluss”) von **Looks** über **date** nach **Talent** ist blockiert.

Kontrolliert man **date**, so *öffnet* sich der Pfad **Looks** -> **date** -> **talent** und die Scheinkorrelation entsteht: Der Pfad ist nicht mehr “blockiert”, die Korrelation kann “fließen” - was sie hier nicht soll, denn es handelt sich um Scheinkorrelation.

Das Kontrollieren von **date** erfolgt zumeist durch das Bilden einer Teilgruppe (Auswahl).

14.2.8 IQ, Fleiss und Eignung fürs Studium

Sagen wir, über die *Eignung* für ein Studium würden nur (die individuellen Ausprägungen) von Intelligenz (IQ) und Fleiss entscheiden, s. den DAG in [Abbildung 14.5](#).




Abbildung 14.5: Kollisionsstruktur im Dag zur Studiumseignung

Bei positiver `eignung` wird ein Studium aufgenommen (`studium = 1`), ansonsten nicht (`studium = 0`).

[Quelle](#)

`eignung` (fürs Studium) sei definiert als die Summe von `iq` und `fleiss`, plus etwas Glück, s. [Listing 14.1](#).

Listing 14.1: Eignung ist die Summe von Fleiss und Intelligenz, plus ein Quentchen Glück

```
set.seed(42) # Reproduzierbarkeit
N <- 1e03

d_eignung <-
tibble(
  iq = rnorm(N), # normalverteilt mit MW=0, sd=1
  fleiss = rnorm(N),
  glueck = rnorm(N, mean = 0, sd = .1),
  eignung = 1/2 * iq + 1/2 * fleiss + glueck,
  # nur wer geeignet ist, studiert (in unserem Modell):
  studium = ifelse(eignung > 0, 1, 0)
)
```

Laut unserem Modell setzt sich Eignung zur Hälfte aus Intelligenz und zur Hälfte aus Fleiss zusammen, plus etwas Glück.

14.2.9 Schlagzeile “Fleiß macht blöd!”

Eine Studie untersucht den Zusammenhang von Intelligenz (iq) und Fleiß (f) bei Studentis (s). Ergebnis: Ein *negativer* Zusammenhang!?

Berechnen wir das “Eignungsmodell”, aber nur mit Studis (`studium == 1`, also ohne Nicht-Studis), s. [Tabelle 14.1](#).

```
m_eignung <-  
  stan_glm(iq ~ fleiss, data = d_eignung %>% filter(studium == 1), refresh = 0)  
  
hdi(m_eignung)
```

Tabelle 14.1: Zum Zusammenhang von Fleiss und Talent

Highest Density Interval	
Parameter	95% HDI
(Intercept)	[0.70, 0.86]
fleiss	[-0.53, -0.36]

[Abbildung 14.6](#) zeigt das Modell und die Daten.

Negativer Zusammenhang von Fleiss und IQ bei Studentis




Abbildung 14.6: Der Zusammenhang von Fleiss und IQ

IQ ist *nicht* unabhängig von Fleiß in unseren Daten, sondern abhängig. Nichtwissenschaftliche Berichte, etwa in einigen Medien, greifen gerne Befunde über Zusammenhänge auf und interpretieren die Zusammenhänge – oft vorschnell – als kausal.⁴

14.2.10 Kollisionsverzerrung nur bei Stratifizierung

Definition 14.2 (Stratifizieren) Durch Stratifizieren wird eine Stichprobe in (homogene) Untergruppen unterteilt (sog. *Strata*). □

Nur durch das Stratifizieren (Aufteilen in Subgruppen, Kontrollieren, Adjustieren) tritt die Scheinkorrelation auf, s. [Abbildung 14.7](#).

i Hinweis

Ohne Stratifizierung tritt *keine* Scheinkorrelation auf. Mit Stratifizierung tritt Scheinkorrelation auf.

Kein Stratifizierung, keine Scheinkorrelation




Abbildung 14.7: Stratifizierung und Scheinkorrelation. A: Keine Stratifizierung und keine Scheinkorrelation. B: Stratifizierung und Scheinkorrelation

Wildes Kontrollieren einer Variablen - Aufnehmen in die Regression - kann genauso gut schaden wie nützen.

Nur Kenntnis des DAGs verrät die richtige Entscheidung: ob man eine Variable kontrolliert oder nicht.

i Hinweis

Nimmt man eine Variable als zweiten Prädiktor auf, so “kontrolliert” man diese Variable. Das Regressionsgewicht des ersten Prädiktors wird “bereinigt” um den Einfluss des zweiten Prädiktors; insofern ist der zweite Prädiktor dann “kontrolliert”.

14.2.11 Einfluss von Großeltern und Eltern auf Kinder

Wir wollen hier den (kausalen) Einfluss der Eltern **E** und Großeltern **G** auf den *Bildungserfolg* der Kinder **K** untersuchen.

Wir nehmen folgende Effekte an:

- indirekter Effekt von **G** auf **K**: $G \rightarrow E \rightarrow K$
- direkter Effekt von **E** auf **K**: $E \rightarrow K$
- direkter Effekt von **G** auf **K**: $G \rightarrow K$

Wir sind v.a. interessiert an $G \rightarrow K$, dem *direkten kausalen* Effekt von Großeltern auf ihre Enkel, s.

[Abbildung 14.8](#).




Abbildung 14.8: Der kausale Effekt von Großeltern auf Enkel. Ein verlorener Fall, zumindest was den DAG betrifft

Aber was ist, wenn wir vielleicht eine *unbekannte Variable* übersehen haben? (S. nächster Abschnitt). 🤖

14.2.12 Der Gespenster-DAG

🤖 Es gibt “unheilbare” DAGs, nennen wir sie “Gespenster-DAGs”, in denen es nicht möglich ist, einen (unverzerrten) Kausaleffekt zu bestimmen, s. [Abbildung 14.9](#). Letztlich sagt uns der DAG bzw. unsere Analyse zum DAG: “Deine Theorie ist nicht gut, zurück an den Schreibtisch und denk noch mal gut nach. Oder sammle mehr Daten.”




Abbildung 14.9: Der Gespenster-DAG: Eine Identifikation der Kausaleffekt ist nicht (vollständig) möglich.

U könnte ein ungemessener Einfluss sein, der auf E und K wirkt, etwa *Nachbarschaft*. Die Großeltern wohnen woanders (in Spanien), daher wirkt die Nachbarschaft der Eltern und Kinder nicht auf sie. E ist sowohl für G als auch für U eine Wirkung, also eine Kollisionsvariable auf diesem Pfad. Wenn wir E kontrollieren, wird es den Pfad $G \rightarrow K$ verzerren, auch wenn wir niemals U messen.

Die Sache ist in diesem Fall chancenlos. Wir müssen diesen DAG verloren geben, McElreath (2020), S. 180; ein Gespenster-DAG. 🤖

14.3 Die Hintertür schließen

Definition 14.3 (Hintertür) Eine “Hintertür” ist ein nicht-kausaler Pfad zwischen einer UV und einer AV. Ein Hintertürpfad entsteht, wenn es eine alternative Route über eine oder mehrere Variable gibt, die UV mit der AV verbindet. Dieser Pfad verzerrt die Schätzwerte des kausalen Einflusses, wenn er nicht kontrolliert wird. $\square$

14.3.1 Zur Erinnerung: Konfundierung

Forschungsfrage: Wie groß ist der (kausale) Einfluss der Schlafzimmerzahl auf den Verkaufspreis des Hauses?

a: livingArea, **b**: bedrooms, **p**: price

UV: **b**, AV: **p**

Das Kausalmodell ist in [Abbildung 14.10](#) dargestellt.




Abbildung 14.10: Der Preis wird sowohl von der Zimmerzahl als auch der Wohnfläche beeinflusst

Im Regressionsmodell $p \sim b$ wird der kausale Effekt durch die Konfundierung mit **a** verzerrt sein. Der Grund für die Konfundierung sind die zwei Pfade zwischen **b** und **p**:

1. $b \rightarrow p$
2. $b \leftarrow a \rightarrow p$

Beide Pfade erzeugen (statistische) Assoziation zwischen **b** und **p**. Aber nur der erste Pfad ist kausal; der zweite ist nichtkausal. Gäbe es nur den zweiten Pfad und wir würden **b** ändern, so würde sich **p** *nicht* ändern.

14.3.2 Gute Experimente zeigen den echten kausalen Effekt

[Abbildung 14.11](#) zeigt eine erfreuliche Situation: Die “Hintertür” zu unserer UV (Zimmerzahl) ist geschlossen!

Ist die Hintertür geschlossen - führen also keine Pfeile in unserer UV - so kann eine Konfundierung ausgeschlossen werden.




Abbildung 14.11: Unverzerrte Schätzung des kausalen Effekts unserer UV (Zimmerzahl). Das Regressionsgewicht ist hier der unverzerrte Kausaleffekt. Es spielt keine Rolle, ob der andere Prädiktor im Modell enthalten ist. Da die beiden Prädiktoren unkorreliert sind, hat die Aufnahme des einen Prädiktors keinen Einfluss auf das Regressionsgewicht des anderen.

Die “Hintertür” der UV (**b**) ist jetzt zu! Der einzig verbleibende, erste Pfad ist der kausale Pfad und die Assoziation zwischen **b** und **p** ist jetzt komplett kausal.

Eine berühmte Lösung, den kausalen Pfad zu isolieren, ist ein (randomisiertes, kontrolliertes⁵) Experiment. Wenn wir den Häusern zufällig (randomisiert) eine Anzahl von Schlafzimmern (**b**) zuweisen könnten (unabhängig von ihrer Quadratmeterzahl, **a**), würde sich der Graph so ändern. Das Experiment *entfernt* den Einfluss von **a** auf **b**. Wenn wir selber die Werte von **b** einstellen im Rahmen des Experiments, so kann **a** keine Wirkung auf **b** haben. Damit wird der zweite Pfad, $b \leftarrow a \rightarrow p$ geschlossen (“blockiert”).

! Wichtig

Die Stärke von (gut gemachten) Experimente ist, dass sie kausale Hintertüren schließen. Damit erlauben sie (korrekte) Kausalaussagen. □

14.3.3 Hintertür schließen auch ohne Experimente

Konfundierende Pfade zu blockieren zwischen der UV und der AV nennt man auch *die Hintertür schließen* (backdoor criterion). Wir wollen die Hintertüre schließen, da wir sonst nicht den wahren, kausalen Effekt bestimmen können.

Zum Glück gibt es neben Experimenten noch andere Wege, die Hintertür zu schließen, wie die Konfundierungsvariable **a** in eine Regression mit aufzunehmen.

💡 Tipp

Kontrollieren Sie Konfundierer, um kausale Hintertüren zu schließen. □

Warum blockt das Kontrollieren von **a** den Pfad $b \leftarrow a \rightarrow p$? Stellen Sie sich den Pfad als eigenen Modell vor. Sobald Sie **a** kennen, bringt Ihnen Kenntnis über **b** kein zusätzliches Wissen über **p**. Wissen Sie hingegen nichts über **a**, lernen Sie bei Kenntnis von **b** auch etwas über **p**. Konditionieren ist wie “gegeben, dass Sie **a** schon kennen...”.

$$b \perp\!\!\!\perp p \mid a$$

14.4 Die vier Atome der Kausalanalyse

[Abbildung 14.12](#) stellt die vier “Atome” der Kausalinferenz dar. Mehr gibt es nicht! Kennen Sie diese vier Grundbausteine, so können Sie jedes beliebige Kausalsystem (DAG) entschlüsseln.




Abbildung 14.12: Die vier Atome der Kausalinferenz

14.4.1 Mediation

Definition 14.4 (Mediator) Einen Pfad mit drei Knoten (Variablen), die über insgesamt zwei Kanten verbunden sind, wobei die Pfeile von UV zu Mediator und von Mediator zur AV zeigen, nennt man *Mediation*. Der *Mediator* ist die Variable zwischen UV und AV ([Pearl et al., 2016](#), p. 38). $\square$

Die *Mediation* (synonym: Wirkkette, Rohr, Kette, chain) beschreibt Pfade, in der die Kanten (eines Pfades) die gleiche Wirkrichtung haben: $x \rightarrow m \rightarrow y$. Anders gesagt: Eine Mediation ist eine Kausalabfolge der Art $x \rightarrow m \rightarrow y$, s. [Abbildung 14.13](#). Die Variable in der Mitte m der Kette wird auch *Mediator* genannt, weil sie die Wirkung von X auf Y “vermittelt” oder überträgt. Die Erforschung von Mediation spielt eine recht wichtige Rolle in einigen Wissenschaften, wie der Psychologie.

Die Mediation




Abbildung 14.13: Das Kausalmodell der Mediation mit x als UV, m als Mediator und Y als AV.

Beispiel 14.1 (Mediator kontrollieren?) Sollte man den Mediator **m** in [Abbildung 14.13](#) kontrollieren, wenn man den Kausaleffekt von **x** auf **y** schätzen möchte?⁶ ☐

Ohne Kontrollieren ist der Pfad offen: Die Assoziation “fließt” den Pfad entlang (in beide Richtungen). Kontrollieren blockt (schließt) die Kette (genau wie bei der Gabel).

Tipp

Kontrollieren Sie den Mediator *nicht*. Der Pfad über den Mediator ist ein “echter” Kausalpfad, keine Scheinkorrelation. ☐

Wichtig

Das Kontrollieren eines Mediators ist ein Fehler, wenn man am gesamten (totalen) Kausaleffekt von UV zu AV interessiert ist. ☐

Es kann auch angenommen werden, dass der Mediator nicht der einzige Weg von X zu Y ist, s. [Abbildung 14.14](#). In [Abbildung 14.14](#) gibt es zwei kausale Pfade von X zu Y: $x \rightarrow m \rightarrow y$ und $x \rightarrow y$.

Definition 14.5 (Kausaleffekt) Gibt es eine (von (praktisch) Null verschiedene) kausale Assoziation der UV auf die AV, so hängt die AV von der UV (kausal) ab. Man spricht von einem Kausaleffekt (der UV auf die AV). ☐

Definition 14.6 (Totaler Effekt) Die Summe der Effekte aller (kausalen) Pfade von UV zu AV nennt man den *totalen (kausalen) Effekt*. ☐

Definition 14.7 (Indirekter Effekt) Den (kausalen) Effekt über den Mediatorpfad (von X über M zu Y) nennt man den *indirekten (kausalen) Effekt*. ☐

Definition 14.8 (Direkter Effekt) Ein Effekt, der nur aus dem Pfad $x \rightarrow y$ besteht, also ohne Zwischenglieder, nennt man in Abgrenzung zum indirekten Effekt, *direkten (kausalen) Effekt*. ☐




Abbildung 14.14: Partielle Mediation: Es gibt einen direkten Effekt ($X \rightarrow Y$) und einen indirekten Effekt ($X \rightarrow M \rightarrow Y$).

14.4.2 Der Nachfahre

Definition 14.9 (Nachfahre) Ein *Nachfahre* (engl. descendent) ist eine Variable, die von einer anderen Variable beeinflusst⁷ wird, s. [Abbildung 14.15](#). $\square$

Kontrolliert man einen Nachfahren d , so kontrolliert man damit zum Teil den Vorfahren (die Ursache), m . Der Grund ist, dass d Information beinhaltet über m . Hier wird das Kontrollieren von d den Pfad von x nach y teilweise öffnen, da m eine Kollisionsvariable ist.




Abbildung 14.15: Ein Nachfahre verhält sich ähnlich wie sein Vorfahre...

14.4.3 Kochrezept zur Analyse von DAGs 🍳

Wie kompliziert ein DAG auch aussehen mag, er ist immer aus diesen vier Atomen aufgebaut.

Hier ist ein Rezept, das Ihnen zeigt, welche Variablen Sie kontrollieren sollten und welche nicht:

1. Listen Sie alle Pfade von UV (X) zu AV (Y) auf.

2. Beurteilen Sie jeden Pfad, ob er gerade geschlossen oder geöffnet ist.
3. Beurteilen Sie für jeden Pfad, ob er ein Hintertürpfad ist (Hintertürpfade haben einen Pfeil, der zur UV führt).
4. Wenn es geöffnete Hintertürpfade gibt, prüfen Sie, welche Variablen man kontrollieren muss, um den Pfad zu schließen (falls möglich).

14.5 Schließen Sie die Hintertür (wenn möglich)!

[Hintertür schließen](#)

14.5.1 Hintertür: ja oder nein?

14.5.1.1 Fall 1: $x \rightarrow$

$$\boxed{X \rightarrow}$$

Alle Pfade, die von der UV (x) *wegführen*, sind entweder “gute” Kausalpfade oder automatisch geblockte Nicht-Kausal-Pfade. In diesem Fall müssen wir nichts tun.⁸

14.5.1.2 Fall 2: $\rightarrow x$

$$\boxed{\rightarrow X}$$

Alle Pfade, die zur UV *hinführen*, sind immer Nicht-Kausal-Pfade, *Hintertüren*. Diese Pfade können offen sein, dann müssen wir sie schließen. Sie können auch geschlossen sein, dann müssen wir nichts tun.

Tipp

Schließen Sie immer offene Hintertüren, um Verzerrungen der Kausaleffekte zu verhindern. ☐

14.5.2 bsp1

UV: X , AV: Y , drei Kovariaten (A, B, C) und ein ungemessene Variable, U




Abbildung 14.16: Puh, ein schon recht komplizierter DAG

Es gibt zwei Hintertürpfade in [Abbildung 14.16](#):

1. $X \leftarrow U \leftarrow A \rightarrow C \rightarrow Y$, offen

2. $X \leftarrow U \rightarrow B \leftarrow C \rightarrow Y$, geschlossen

Kontrollieren von A oder (auch) C schließt die offene Hintertür.

McElreath (2020), Kurz (2021), s. S. 186.

14.5.3 Schließen Sie die Hintertür (wenn möglich)!, bsp2

S. DAG in [Abbildung 14.17](#): UV: W , AV: D




Abbildung 14.17: Welche Variablen muss man kontrollieren, um den Effekt von W auf D zu bestimmen?

Kontrollieren Sie diese Variablen, um die offenen Hintertüren zu schließen:

- entweder A und M
- oder S

[Mehr Infos](#)

Details finden sich bei McElreath (2020) oder Kurz (2021), S. 188.

14.5.4 Implizierte bedingte Unabhängigkeiten von bsp2

Auch wenn die Daten nicht sagen können, welcher DAG der richtige ist, können wir zumindest lernen, welcher DAG falsch ist. Die vom Modell implizierten bedingten Unabhängigkeiten geben uns Möglichkeiten, zu prüfen, ob wir einen DAG verwerfen (ausschließen) können. Bedingte Unabhängigkeit zwischen zwei Variablen sind Variablen, die nicht assoziiert (also stochastisch unabhängig) sind, wenn wir eine bestimmte Menge an Drittvariablen kontrollieren.

bsp2 impliziert folgende bedingte Unabhängigkeiten:

```
## A _| _ W | S
## D _| _ S | A, M, W
## M _| _ W | S
```

14.6 Fazit

14.6.1 Ausstieg

Beispiel 14.2 (PMI zum heutigen Stoff) Der Kreativitätsforscher Edward de Bono hat verschiedene “Denkmethoden” vorgestellt, die helfen sollen, Probleme besser zu lösen. Eine Methode ist die “PMI-Methode”. PMI steht für *Plus*, *Minus*, *Interessant*. Bei Plus und Minus soll man eine Bewertung von Positiven bzw. Negativen bzgl. eines Sachverhaltes anführen. Bei *Interessant* verzichtet man aber explizit auf eine Bewertung (im Sinne von “gut” oder “schlecht”) und fokussiert sich auf Interessantes, Überraschendes, Bemerkenswertes.

Führen Sie die PMI-Methode zum heutigen Stoff durch!

1. *Plus*: Was fanden Sie am heutigen Stoff gut, sinnvoll, nützlich? Warum?
2. *Minus*: Was finden Sie am heutigen Stoff nicht gut, sinnvoll, nützlich? Warum?
3. *Interessant*: Was finden Sie am heutigen Stoff bemerkenswert, interessant, nachdenkenswert? Warum?

Reichen Sie die Antworten an der von der Lehrkraft angezeigten Stelle ein! ☐

14.6.2 Zusammenfassung

Wie (und sogar ob) Sie statistische Ergebnisse (z.B. eines Regressionsmodells) interpretieren können, hängt von der *epistemologischen Zielrichtung* der Forschungsfrage ab:

- Bei *deskriptiven* Forschungsfragen können die Ergebnisse (z.B. Regressionskoeffizienten) direkt interpretiert werden. Z.B. “Der Unterschied zwischen beiden Gruppen beträgt etwa ...”. Allerdings ist eine kausale Interpretation nicht zulässig.
- Bei *prognostischen* Fragestellungen (Vorhersagen) spielen die Modellkoeffizienten keine Rolle, stattdessen geht es um vorhergesagten Werte, $\hat{y}_i$, z.B. auf Basis der PPV. Kausalaussagen sind zwar nicht möglich, aber auch nicht von Interesse.
- Bei *kausalen* Forschungsfragen dürfen die Modellkoeffizienten nur auf Basis eines Kausalmodells (DAG) oder eines (gut gemachten) Experiments interpretiert werden.

Modellkoeffizienten ändern sich (oft), wenn man Prädiktoren zum Modell hinzufügt oder wegnimmt. Entgegen der verbreiteten Annahme ist es falsch, möglichst viele Prädiktoren in das Modell aufzunehmen, wenn das Ziel eine Kausalaussage ist. Kenntnis der “kausalen Atome” ist Voraussetzung zur Ableitung von Kausalschlüssen in Beobachtungsstudien.

14.6.3 Vertiefung

An weiterführender Literatur sei z.B. Cumiskey et al. (2020), Lübke et al. (2020), Pearl et al. (2016) und Dablander (2020) empfohlen. Ein gutes Lehrbuch, das auf Kausalinferenz eingeht, ist Huntington-Klein (2022). Praktischerweise ist es [öffentlich lesbar](#). Das Web-Buch [Causal Inference for the Brave and True](#) sieht auch vielversprechend aus. Es gibt viel Literatur zu dem Thema; relevante Google-Suchterme sind z.B. “DAG”, “causal” oder “causal inference”.

14.7 Aufgaben

- [Sammlung “kausal”](#)

14.7.1 Quiz-Aufgaben

Hier finden Sie Single-Choice-Aufgaben zu diesem Kapitel. Wählen Sie eine Antwort aus und klicken Sie auf das Häkchen, um sie zu überprüfen; über das Fragezeichen erhalten Sie die ausführliche Lösung.

Eine Kollision (Collider) liegt vor, wenn eine Variable die gemeinsame Wirkung zweier Ursachen ist (z.B. `date` als gemeinsame Wirkung von `Schönheit` und `Talent`). Welche Aussage zum Umgang mit einer solchen Kollisionsvariable ist korrekt?

- ☐ Kollision und Konfundierung erfordern exakt dieselbe Handlungsempfehlung: In beiden Fällen sollte man die betreffende Variable kontrollieren.
- ☐ Man sollte Kollisionsvariablen immer kontrollieren, um Scheinkorrelationen zu vermeiden.
- ☐ Kontrolliert man die Kollisionsvariable, verschwindet jede eventuell vorhandene Scheinkorrelation zwischen den Ursachen.
- ☐ Kontrolliert man die Kollisionsvariable (z.B. durch Stratifizieren oder Aufnahme als Prädiktor), entsteht dadurch eine Scheinkorrelation zwischen den beiden (eigentlich unabhängigen) Ursachen; man sollte Kollisionsvariablen daher grundsätzlich *nicht* kontrollieren.
- ☐ Eine Kollisionsvariable erzeugt eine Scheinkorrelation zwischen den Ursachen, unabhängig davon, ob man sie kontrolliert oder nicht.



Im Kapitel wird ein simuliertes Beispiel gezeigt, in dem IQ und Fleiß in der Gesamtpopulation unabhängig voneinander sind (`eignung = 1/2*iq + 1/2*fleiss + glueck`, `studium = 1` falls `eignung > 0`). Betrachtet man aber nur die Studierenden (`studium == 1`), findet man einen *negativen* Zusammenhang zwischen IQ und Fleiß ("Fleiß macht blöd"). Wie erklärt das Kapitel diesen Befund?

- ☐ `studium` ist ein Konfundierer für den Zusammenhang von `iq` und `fleiss`, daher muss man unbedingt danach kontrollieren, um den wahren Zusammenhang zu sehen.
- ☐ IQ und Fleiß sind in Wirklichkeit immer negativ korreliert, unabhängig von der betrachteten Teilgruppe.
- ☐ Der negative Zusammenhang zeigt, dass Fleiß tatsächlich kausal die Intelligenz verringert.
- ☐ Der negative Zusammenhang entsteht durch einen Fehler in der Simulation und hat keine inhaltliche Erklärung.
- ☐ `studium` ist eine Kollisionsvariable (gemeinsame Wirkung von `iq` und `fleiss`); indem man die Stichprobe auf `studium == 1` beschränkt, kontrolliert (stratifiziert) man implizit nach dieser Kollisionsvariable, wodurch eine Scheinkorrelation zwischen `iq` und `fleiss` entsteht.



Gegeben sei eine Mediationsstruktur $x \rightarrow m \rightarrow y$, wobei m der Mediator ist. Man ist am *totalen* kausalen Effekt von x auf y interessiert. Sollte man den Mediator m in der Regression kontrollieren?

- ☐ Es spielt für den geschätzten totalen Effekt keine Rolle, ob man den Mediator kontrolliert oder nicht.
- ☐ Nur wenn der Mediator eine nominale (kategoriale) Variable ist, sollte man ihn nicht kontrollieren; bei metrischen Mediatoren ist Kontrollieren hingegen unproblematisch.

- ☐ Ja, man sollte den Mediator immer kontrollieren, um Scheinkorrelationen zu vermeiden.
- ☐ Nein: Kontrolliert man den Mediator, wird der (echte, kausale) Pfad von x über m zu y blockiert – man verliert dann gerade den Effekt, an dem man eigentlich interessiert ist.
- ☐ Der Mediator muss kontrolliert werden, weil er sonst als Konfundierer wirkt.



Ein *Nachfahre* ist eine Variable, die kausal von einer anderen Variable im DAG beeinflusst wird (z.B. wenn eine Kollisionsvariable m ihrerseits eine Wirkung d hat: $x \rightarrow m \leftarrow y, m \rightarrow d$). Welche Aussage zum Kontrollieren eines Nachfahren d ist korrekt?

- ☐ Das Kontrollieren eines Nachfahren betrifft ausschließlich die Variable selbst, niemals irgendwelche anderen Pfade im DAG.
- ☐ Nachfahren sollte man immer kontrollieren, unabhängig von der übrigen Struktur des DAGs.
- ☐ Kontrolliert man einen Nachfahren d eines Kolliders m , kontrolliert man dadurch teilweise auch m selbst (da d Information über m enthält) – das kann denselben verzerrenden Effekt haben wie das direkte Kontrollieren des Kolliders.
- ☐ Ein Nachfahre ist dasselbe wie ein Mediator und sollte daher genauso behandelt werden.
- ☐ Das Kontrollieren eines Nachfahren hat grundsätzlich überhaupt keinen Effekt auf die Analyse, da Nachfahren per Definition keine Information über ihre Vorfahren enthalten.



Das Kapitel benennt vier “Atome” der Kausalanalyse, aus denen sich jeder beliebige DAG zusammensetzt. Welche Zuordnung von Atom und der zugehörigen Handlungsempfehlung (kontrollieren oder nicht) ist korrekt?

- ☐ Konfundierung: kontrollieren, um Scheinkorrelation aufzulösen. Kollision: nicht kontrollieren, sonst entsteht Scheinkorrelation. Mediation: nicht kontrollieren, wenn der totale Effekt gesucht ist. Nachfahre: Wirkung hängt von der Rolle des zugehörigen Vorfahren ab.
- ☐ Mediation bedeutet dasselbe wie Konfundierung, nur mit anderer Bezeichnung.
- ☐ Es gibt laut Kapitel nur zwei relevante Atome der Kausalanalyse, nicht vier.
- ☐ Alle vier Atome (Konfundierung, Kollision, Mediation, Nachfahre) erfordern exakt dieselbe Handlungsempfehlung: immer kontrollieren.
- ☐ Konfundierung und Kollision erfordern beide “nicht kontrollieren”, Mediation und Nachfahre erfordern beide “immer kontrollieren”.



Was versteht das Kapitel unter einer “Hintertür” (backdoor) zwischen UV und AV, und welche Rolle spielt die Pfeilrichtung dabei?

- ☐ Hintertüren treten ausschließlich bei experimentellen Studien auf, niemals bei Beobachtungsstudien.

- ☐ Eine Hintertür ist ein Pfad, der immer automatisch blockiert (geschlossen) ist und daher nie zusätzliche Aufmerksamkeit erfordert.
- ☐ Eine Hintertür entsteht nur, wenn die AV direkt auf die UV wirkt.
- ☐ Eine Hintertür ist ein nicht-kausaler Pfad zwischen UV und AV; solche Pfade sind daran erkennbar, dass ein Pfeil *in die UV hineinführt* (also $\rightarrow X$) statt von ihr wegzuführen – Pfade, die nur von der UV *wegführen* ($X \rightarrow$), sind hingegen entweder echte Kausalfade oder automatisch blockiert.
- ☐ Eine Hintertür ist jeder beliebige Pfad zwischen UV und AV, unabhängig von der Pfeilrichtung.



Im “Gespenster-DAG” (Großeltern G , Eltern E , Kinder K , plus eine ungemessene Variable U , z.B. Nachbarschaft, mit $U \rightarrow E$ und $U \rightarrow K$) ist E eine Kollisionsvariable auf dem Pfad zwischen G und U . Warum bezeichnet das Kapitel diesen DAG als “unheilbar”?

- ☐ Der DAG ist unheilbar, weil G und K nicht direkt durch einen Pfeil verbunden sind.
- ☐ Der DAG ist unheilbar, weil er azyklisch ist.
- ☐ Man könnte das Problem einfach lösen, indem man U zusätzlich in die Regression aufnimmt.
- ☐ Der DAG ist unheilbar, weil zu wenige Beobachtungen im Datensatz vorhanden sind.
- ☐ Da E eine Kollisionsvariable ist, würde das Kontrollieren von E (nötig, um den Konfundierungspfad über E zu blockieren) gleichzeitig eine Scheinkorrelation über U öffnen – da U aber unbeobachtet (ungemessen) ist, kann man diese neu geöffnete Verzerrung nicht mehr durch weiteres Kontrollieren beheben.



Im DAG-Beispiel **bsp1** (UV: X , AV: Y , Kovariaten A, B, C , ungemessene Variable U ; mit $C \rightarrow B, U \rightarrow B, A \rightarrow C, A \rightarrow U, U \rightarrow X, C \rightarrow Y, X \rightarrow Y$) gibt es zwei Hintertürpfade: $X \leftarrow U \leftarrow A \rightarrow C \rightarrow Y$ (offen) und $X \leftarrow U \rightarrow B \leftarrow C \rightarrow Y$ (bereits geschlossen, da B eine Kollisionsvariable auf diesem Pfad ist). Welche Variable(n) muss man kontrollieren, um die offene Hintertür zu schließen?

- ☐ B , da B auf einem der beiden Hintertürpfade liegt.
- ☐ Keine Variable muss kontrolliert werden, da beide Hintertürpfade automatisch geschlossen sind.
- ☐ Man muss X selbst kontrollieren, um die Hintertür zu schließen.
- ☐ A (oder alternativ C) – beide liegen auf dem offenen Hintertürpfad und sind keine Kollisionsvariablen, ihre Kontrolle blockiert den Pfad.
- ☐ U , da U die ungemessene Variable ist und daher unbedingt kontrolliert werden muss.



Im DAG-Beispiel **bsp2** (UV: W , AV: D) gelten folgende Kausalpfeile: $S \rightarrow A, S \rightarrow M, S \rightarrow W, A \rightarrow D, A \rightarrow M, M \rightarrow D, W \rightarrow D$. Welche Variable(n) muss man mindestens kontrollieren, um alle offenen Hintertüren zwischen W und D zu schließen?

- ☐ Entweder kontrolliert man S allein, oder alternativ A und M gemeinsam – beide Mengen blockieren alle Hintertürpfade von W nach D , da jeder dieser Pfade bei S beginnt ($W \leftarrow S \rightarrow \dots \rightarrow D$) und über A und/oder M zu D weiterläuft.
- ☐ Man muss zwingend alle vier Variablen A , M , S und D gleichzeitig kontrollieren, sonst bleibt immer mindestens eine Hintertür offen.
- ☐ Man darf hier gar keine Variable kontrollieren, da jede Kontrolle automatisch eine neue Scheinkorrelation zwischen W und D erzeugt.
- ☐ Es genügt, D zu kontrollieren, da D die AV ist und dadurch alle Pfade zu ihr automatisch geschlossen werden.
- ☐ Es genügt, nur A zu kontrollieren, da alle Hintertürpfade zwangsläufig über A verlaufen.



Das Kapitel unterscheidet drei “epistemologische Zielrichtungen” einer Forschungsfrage: deskriptiv, prognostisch und kausal. Welche Zuordnung ist korrekt?

- ☐ Prognostische Fragestellungen erfordern zwingend ein vollständiges Kausalmodell, deskriptive Fragestellungen hingegen nicht.
- ☐ Kausale Forschungsfragen benötigen niemals ein Kausalmodell, da die Statistik allein ausreicht, um Kausaleffekte zu identifizieren.
- ☐ Deskriptive Forschungsfragen sind grundsätzlich unwissenschaftlich und sollten vermieden werden.
- ☐ Bei allen drei Zielrichtungen (deskriptiv, prognostisch, kausal) sind Regressionskoeffizienten immer automatisch kausal zu interpretieren.
- ☐ Bei deskriptiven Fragen können Regressionskoeffizienten direkt (aber nicht-kausal) interpretiert werden; bei prognostischen Fragen sind die vorhergesagten Werte relevant, nicht die Koeffizienten; bei kausalen Fragen dürfen die Koeffizienten nur auf Basis eines Kausalmodells (DAG) oder eines guten Experiments interpretiert werden.



Ein DAG (z.B. [bsp2](#)) impliziert bestimmte bedingte Unabhängigkeiten zwischen Variablen, die man z.B. mit `impliedConditionalIndependencies()` aus dem R-Paket `dagitty` auflisten kann. Wozu ist das nützlich, wenn man doch (laut Kapitel) allein aus den Daten nicht bestimmen kann, welcher DAG der “richtige” ist?

- ☐ Implizierte Unabhängigkeiten sind rein theoretische Spielerei ohne jeden praktischen Nutzen für die Datenanalyse.
- ☐ Die implizierten Unabhängigkeiten eines DAGs ändern sich bei jeder neuen Stichprobe, sie sind keine feste Eigenschaft des DAGs.
- ☐ Implizierte Unabhängigkeiten sagen nur etwas über kausale Pfeile aus, niemals über beobachtbare statistische Zusammenhänge.
- ☐ Auch wenn man aus den Daten nicht direkt beweisen kann, welcher DAG richtig ist, kann man prüfen, ob die vom DAG implizierten (bedingten) Unabhängigkeiten mit den beobachteten Daten übereinstimmen – widersprechen die Daten einer implizierten Unabhängigkeit, kann man den betreffenden DAG verwerfen.

☐ Man kann mit implizierten Unabhängigkeiten stets beweisen, dass ein DAG der einzig korrekte ist.



14.8 —



1. Don muss reich sein. [↩](#)
2. Super, Don! [↩](#)
3. Der horizontale Balken “|” bedeutet “gegeben, dass”. Ein Beispiel lautet $Pr(A|B)$: “Die Wahrscheinlichkeit von A, gegeben dass B der Fall ist.” [↩](#)
4. Ehrlicherweise muss man zugeben, dass auch wissenschaftliche Berichte Daten über Zusammenhänge gerne kausal interpretieren, oft vorschnell. [↩](#)
5. engl. randomized, controlled trial, RCT [↩](#)
6. Nein, durch das Kontrollieren von **m** wird der Kausalfad von **x** zu **y** geschlossen. Es kann keine kausale Assoziation von **x** auf **y** mehr “fließen”. [↩](#)
7. beeinflussen ist grundsätzlich kausal zu verstehen [↩](#)
8. Denken Sie daran, dass Sie keine Nachkommen der UV kontrollieren dürfen, da das den Kausalfad von der UV zur AV blockieren könnte. [↩](#)