

15 Abschluss

15.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- erläutern, wie Sie eine typische, sozialwissenschaftliche Forschungsfrage (quantitativ) untersuchen
- typische “Lieblingsfehler” benennen und Wege aufzeigen, um die Fehler zu umgehen
- zwischen den Grundkonzepten der Frequentistischen Statistik und der Bayes-Statistik übersetzen
- die Grundideen der Bayes-Statistik in einen Gesamtzusammenhang einordnen

In diesem Kapitel benötigen Sie folgende R-Pakete.

```
library(tidyverse)
library(easystats)
library(rstanarm)
```

Nutzen Sie nach Bedarf folgende Begleitvideos:

- [Fragestunde QM2](#)
- [Playlist QM2](#)
- [Lieblingsfehler](#)

Hinweis

Die Folien zu diesem Kapitel finden Sie [hier](#).

15.2 Probeklausur

Diese Liste ist im Aufbau. Bitte konsultieren Sie für weitere Aufgaben selbständig alle relevanten Aufgaben, die in den Kapiteln vorgestellt wurden.

15.2.1 2025

Hier finden Sie Single-Choice-Aufgaben zu einer Probeklausur aus dem Jahr 2025. Wählen Sie eine Antwort aus und klicken Sie auf das Häkchen, um sie zu überprüfen; über das Fragezeichen erhalten Sie die ausführliche Lösung.

Die Varianzanalyse (ANOVA) ist ein inferenzstatistisches Verfahren des Frequentismus. Welches Skalenniveau passt zu diesem Verfahren?

- ☐ UV: nominal (mehrstufig), AV: metrisch
- ☐ UV: nominal (zweistufig), AV: nominal (zweistufig)
- ☐ UV: metrisch, AV: metrisch

- ☐ UV: nominal (mehrstufig), AV: nominal (mehrstufig)
- ☐ UV: metrisch, AV: nominal (zweistufig)



Wie viele Parameter sieht die folgende Definition eines Bayes-Modells vor?

$$\begin{aligned} y_i &\sim \mathcal{N}(\mu_i, \sigma) \\ \mu_i &= \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} \\ \beta_0, \beta_1, \beta_2 &\sim \mathcal{N}(0, 2.5) \\ \sigma &\sim \mathcal{E}(1) \end{aligned}$$

- ☐ 5
- ☐ 3
- ☐ 6
- ☐ 2
- ☐ 4



Die Inferenzstatistik ergänzt die deskriptive Statistik.

Welche Aussage zur Inferenzstatistik ist *FALSCH*?

- ☐ Grund für die Schwankungen der Modellparameter zwischen den (zufällig gezogenen) Stichproben ist die Zufälligkeit des Stichprobenziehens.
- ☐ Die Inferenzstatistik verallgemeinert die Stichprobendaten auf eine Population.
- ☐ Kennzahlen einer Population nennt man auch Parameter.
- ☐ Man kann die Zielarten der Statistik in drei Gruppen fassen: Beschreiben, Vorhersagen und Zusammenfassen.
- ☐ Ein inferenzstatistisches Modells besitzt die folgenden zwei Arten von Ungewissheit: 1) Ungewissheit zu den Koeffizienten und 2) Ungewissheit zur Modellspezifikation.



Welche der folgenden Formeln stellt das Bayes-Theorem korrekt dar?

- ☐ $Pr(H|D) = \frac{Pr(H) \times Pr(D)}{Pr(D|H)}$
- ☐ $Pr(H|D) = \frac{Pr(D|H)}{Pr(H) \times Pr(D)}$
- ☐ $Pr(H|D) = Pr(D|H) \times Pr(H) \times Pr(D)$
- ☐ $Pr(H|D) = Pr(H) + Pr(D|H) - Pr(D)$

☐ $Pr(H|D) = \frac{Pr(D|H) \times Pr(H)}{Pr(D)}$



Die Exponentialverteilung ist eine häufig verwendete Verteilung in der Statistik. Sie kann verwendet werden, um Streuungen zu modellieren.

Welche der folgenden Aussagen zur Exponentialverteilung ist **nicht** korrekt?

- ☐ Die Exponentialverteilung hat nur einen Parameter.
- ☐ Die Exponentialverteilung ist streng monoton fallend.
- ☐ Die Exponentialverteilung ist symmetrisch.
- ☐ Die Exponentialverteilung ist eine stetige Verteilung.
- ☐ Die Exponentialverteilung ist nur für nicht-negative Werte definiert.



Welche Definition von Statistik passt am besten?

- ☐ Statistik fasst Daten zusammen.
- ☐ Statistik fasst Daten zusammen, um wesentliche Informationen den Daten zu entnehmen.
- ☐ Statistik vervielfacht Daten.
- ☐ Keine der genannten.
- ☐ Statistik fasst Daten zusammen, um wesentliche Informationen den Daten zu entnehmen und beschreibt die Ungewissheit unserer Schlüsse.



Behauptung: *Ist Null nicht im Konfidenzintervall enthalten, so liegt ein statistisch signifikantes Ergebnis vor.*

Beziehen Sie sich auf die Lehrmeinung, wie im Skript dargestellt.

Wählen Sie die korrekte Antwort!

- ☐ Die Behauptung ist richtig für die Bayes-Statistik, aber nicht für die Frequentistische Statistik.
- ☐ Die Behauptung ist richtig für die Frequentistische Statistik, aber nicht für die Bayes-Statistik.
- ☐ Die Behauptung ist nicht definiert.
- ☐ Die Behauptung ist richtig sowohl für die Bayes-Statistik als auch für die Frequentistische Statistik.
- ☐ Die Behauptung ist falsch für die Bayes-Statistik und für die Frequentistische Statistik.



Sei $X \sim \text{Exp}(1)$.

Welche der Aussagen ist richtig?

- ☐ Die Verteilung hat keinen Mittelwert.
- ☐ Keine der genannten Antworten ist richtig.
- ☐ Je größer lambda, desto größer der Mittelwert der Verteilung.
- ☐ Je größer lambda, desto kleiner der Mittelwert der Verteilung.
- ☐ Lambda ist unabhängig vom Mittelwert der Verteilung.



Gegeben sei

$x \sim \text{Exp}(1)$.

Gesucht ist folgendes Quantil: 95 %.

Nutzen Sie die Tabelle der Exponentialverteilung, um das Quantil zu bestimmen.


rate	2.5 %	5 %	50 %	95 %	97.5 %
1.00	0.03	0.05	0.69	3.00	3.69
2.00	0.01	0.03	0.35	1.50	1.84
4.00	0.01	0.01	0.17	0.75	0.92
8.00	0.00	0.01	0.09	0.37	0.46
0.50	0.05	0.10	1.39	5.99	7.38
0.25	0.10	0.21	2.77	11.98	14.76
0.12	0.20	0.41	5.55	23.97	29.51

- ☐ 1.50
- ☐ 3.00
- ☐ 3.69
- ☐ 5.99
- ☐ 0.69



Prof. Süß-Sauer untersucht eine seiner Lieblingsfragen: Wie viel bringt das Lernen auf eine Klausur? Dabei konzentriert er sich auf das Fach Statistik (es gefällt ihm gut). In einer aktuellen Untersuchung hat er $n = 70$ Studierende untersucht (s. Tabelle und Diagramm) und jeweils erfasst, ob die Person die Klausur bestanden (B) hat oder durchgefallen ($\neg B$) ist. Im Hinblick auf das Lernen, L (wie viel die Person gelernt hat) hat er zwei Gruppen unterschieden: Die “Viel-Lerner” (VL) und die “Wenig-Lerner” (WL).

Das folgende Diagramm zeigt die Häufigkeiten pro Gruppe:



Hier ist die Kontingenztafel mit den Häufigkeiten pro Gruppe:

Lerntyp	Bestehen	Durchfallen
Weniglerner	10	25
Viellerner	21	14

Berechnen Sie die folgende gemeinsame Wahrscheinlichkeit: $p(\text{Bestehen UND Weniglerner})$. Wählen Sie die richtige Antwortoption.

- ☐ 0.86
- ☐ 0.36
- ☐ 0.14
- ☐ 0.29
- ☐ 0.3



Ein renommiertes Unternehmen sucht einen Kandidaten für eine (hoch dotierte) Führungsposition. Ein Managementberatungsunternehmen führt ein Assessmentcenter durch, welches pro Kandidat/in eine positive bzw. negative Empfehlung ergibt. Aus früheren Erfahrungen heraus wissen die Berater, dass die tatsächlich geeigneten Kandidaten (Ereignis E wie *eligible*) mit 60% eine positive Empfehlung für die Stelle ausgesprochen bekommen (Ereignis R wie *recommendation*). Weiterhin bekommen von den *nicht* geeigneten Kandidaten 72% eine negative Empfehlung. Insgesamt wissen die Berater, dass 10% der Bewerber/innen tatsächlich geeignet sind.

Aufgabe: Was ist die entsprechende Häufigkeitstabelle? Wählen Sie die Antwortoption, die alle vier gemeinsamen Wahrscheinlichkeiten (in Prozent) korrekt angibt.

Hinweis: Das Gegenereignis vom Ereignis A wird als Komplementärereignis oder kurz als Komplement bezeichnet und mit A^C oder $\bar{A}$ abgekürzt. Im vorliegenden Fall meint $\bar{R} = R^C$ das Ereignis, dass ein Kandidat *keine* Empfehlung ausgesprochen bekommt.

- ☐ $P(E \cap R) = 4.00\%, P(\bar{E} \cap R) = 64.80\%, P(E \cap \bar{R}) = 6.00\%, P(\bar{E} \cap \bar{R}) = 25.20\%$
- ☐ $P(E \cap R) = 6.00\%, P(\bar{E} \cap R) = 25.20\%, P(E \cap \bar{R}) = 4.00\%, P(\bar{E} \cap \bar{R}) = 64.80\%$
- ☐ $P(E \cap R) = 25.20\%, P(\bar{E} \cap R) = 6.00\%, P(E \cap \bar{R}) = 64.80\%, P(\bar{E} \cap \bar{R}) = 4.00\%$
- ☐ $P(E \cap R) = 64.80\%, P(\bar{E} \cap R) = 4.00\%, P(E \cap \bar{R}) = 25.20\%, P(\bar{E} \cap \bar{R}) = 6.00\%$
- ☐ 0



Betrachten wir das Zufallsexperiment, bei dem ein Würfel geworfen wird. Wir haben keinen Grund zu glauben, dass eine bestimmte Augenzahl bevorzugt wird, und nehmen daher an, dass alle Augenzahlen gleich wahrscheinlich sind.

Sei A das Ereignis, dass eine gerade Zahl geworfen wird. Sei B das Ereignis, dass eine Zahl größer als 3 geworfen wird.

Was ist die Wahrscheinlichkeit für das Ereignis $A \cap B$, also das gemeinsame Eintreten von A und B ?

- ☐ $\frac{1}{3}$
- ☐ $\frac{1}{2}$
- ☐ $\frac{1}{6}$
- ☐ $\frac{2}{3}$
- ☐ $\frac{1}{4}$



Wissenschaft! Vielleicht das wichtigste Projekt der Menschheit, geht es doch um die Loslösung von “Du musst das glauben, weil ich es sage” hin zu “Ich glaube das, weil ich es verstehe”.

Sei 1% aller Studien der Wissenschaft “genial”. Ein Gutachter prüft eine wissenschaftliche Studie und erkennt 90% der genialen Studien als solche. Allerdings stuft der Gutachter auch 10% der nicht-genialen Studien fälschlich als genial ein. Nach der Prüfung der Studie ist der Gutachter überzeugt, dass die Studie genial ist.

Aufgabe: Berechnen Sie die Wahrscheinlichkeit, dass die Studie wirklich genial ist.

- ☐ 0.08
- ☐ 0.1
- ☐ 0.9
- ☐ 0.01
- ☐ 0.92



Wir werfen einen Globus $n = 9$ Mal und erzielen $W = 9$ mal das Ereignis "Wasser".

Was ist die Wahrscheinlichkeit dieses Ereignisses, wenn wir von einer Wasseranteil, d.h. Wahrscheinlichkeit, von $\pi = .7$ ausgehen?

- ☐ 0.04
- ☐ 0.96
- ☐ 0
- ☐ .14
- ☐ 0.7



Für Statistiken (Stichprobe) verwendet man meist lateinische Buchstaben; für Parameter (Population) verwendet man meist (die entsprechenden) griechischen Buchstaben.

Kennwert	Statistik	Parameter
Mittelwert	$\bar{X}$	NA
Mittelwertsdifferenz	$\bar{X}_1 - \bar{X}_2$	NA
Streuung	sd	NA
Anteil	p	NA
Korrelation	r	NA
Regressionsgewicht	b	NA

Welche Antwortoption vervollständigt folgende Tabelle korrekt?

- ☐ Mittelwert: σ , Mittelwertsdifferenz: $\mu_1 - \mu_2$, Streuung: μ , Anteil: π , Korrelation: β , Regressionsgewicht: ρ
- ☐ Mittelwert: μ , Mittelwertsdifferenz: $\mu_1 - \mu_2$, Streuung: σ , Anteil: π , Korrelation: β , Regressionsgewicht: ρ
- ☐ Mittelwert: μ , Mittelwertsdifferenz: $\mu_1 - \mu_2$, Streuung: σ , Anteil: π , Korrelation: ρ , Regressionsgewicht: β
- ☐ Mittelwert: μ , Mittelwertsdifferenz: $\mu_1 - \mu_2$, Streuung: π , Anteil: σ , Korrelation: ρ , Regressionsgewicht: β
- ☐ Mittelwert: σ , Mittelwertsdifferenz: $\mu_1 - \mu_2$, Streuung: μ , Anteil: π , Korrelation: ρ , Regressionsgewicht: β



Übersetzen Sie folgende Forschungsfrage in die korrekte Regressionsformel!

Gibt es einen Interaktionseffekt zwischen Geschlecht und Schnabellänge auf das Gewicht eines Pinguins?
Liegen auch Haupteffekte vor?

Welche Regressionsformel ist korrekt?

- ☐ `body_mass_g ~ sex:bill_length_mm`
- ☐ `body_mass_g ~ sex * bill_length_mm * species`
- ☐ `body_mass_g ~ sex + bill_length_mm`
- ☐ `body_mass_g ~ sex + bill_length_mm + species:bill_length_mm`
- ☐ `body_mass_g ~ sex + bill_length_mm + sex:bill_length_mm`



Betrachten Sie folgende Forschungsformel:

Gibt es einen Interaktionseffekt zwischen Geschlecht und Schnabellänge auf das Gewicht eines Pinguins? Liegen auch Haupteffekte vor?

Auf Basis der folgenden Analyse ist folgende Frage zu untersuchen. Liegt ein Interaktionseffekt vor?

Zur besseren Interpretierbarkeit sind die metrischen UV standardisiert:

```
penguins_z <- standardize(penguins, select = c(bill_length_mm), append = TRUE)
```

Es werden verschiedene Modelle berechnet, die sich in ihrer Regressionsformel unterscheiden:

```
m1 <- stan_glm(body_mass_g ~ sex, data = penguins_z)
m2 <- stan_glm(body_mass_g ~ sex + bill_length_mm_z, data = penguins_z)
m3 <- stan_glm(body_mass_g ~ sex + bill_length_mm_z + sex:bill_length_mm_z,
               data = penguins_z)
m4 <- stan_glm(body_mass_g ~ sex:bill_length_mm_z, data = penguins_z)
m5 <- stan_glm(bill_length_mm_z ~ sex + body_mass_g + sex:body_mass_g, data =
penguins_z)
```

Hier sind die Modellparameter (Punktschätzer als Median sowie 95%-ETI):

Modell	Median	CI_low	CI_high
m1	3864	3753	3978
m2	4003	3907	4100
m3	4012	3908	4116
m4	4220	4144	4296
m5	26	22	30

Welches Modell ist korrekt spezifiziert, um die Forschungsfrage (Interaktionseffekt und Haupteffekte) zu beantworten?

- ☐ `m2: body_mass_g ~ sex + bill_length_mm_z`

- ☐ m5: `bill_length_mm_z ~ sex + body_mass_g + sex:body_mass_g`
- ☐ m1: `body_mass_g ~ sex`
- ☐ m3: `body_mass_g ~ sex + bill_length_mm_z + sex:bill_length_mm_z`
- ☐ m4: `body_mass_g ~ sex:bill_length_mm_z`



Beurteilen Sie folgende Aussagen: *Man kann die Forschungsfrage, ob sich zwei Gruppen (Populationen) hinsichtlich ihres Mittelwerts unterscheiden, mit einem t-Test oder einer Regressionsanalyse untersuchen.*

Wählen Sie die korrekte Antwortoption!

- ☐ Ja, beide Verfahren sind analog, aber die Regression hat Vorzüge.
- ☐ Nein, eine Regression setzt intervallskalierte Prädiktoren voraus, daher ist sie hier nicht anwendbar.
- ☐ Nein, eine Regression kann nur bei mehr als zwei Gruppen verwendet werden.
- ☐ Nein, man sollte die Regression generell nicht verwenden.
- ☐ Ja, aber die Regression ist numerisch instabil und sollte daher nicht verwendet werden.



Welche der folgenden Aussagen zur Interpretation eines Populationsparameters (z.B. μ) eines Konfidenzintervalls der Art 95% CI [182cm; 184cm] ist richtig bzw. passt am besten?

Mit 95% Wahrscheinlichkeit liegt der wahre Wert des zugrundeliegenden Parameters zwischen 182cm und 184cm.

- ☐ Bedeutet, dass 95% aller Messwerte der Population zwischen 182cm und 184cm liegen
- ☐ Passt weder zur Frequentistischen, noch zur Bayesianischen Statistik
- ☐ Passt nur zur Bayesianischen, nicht zur Frequentistischen Statistik
- ☐ Passt nur zur Frequentistischen, nicht zur Bayesianischen Statistik
- ☐ Passt sowohl zur Frequentistischen, als auch zur Bayesianischen Statistik



Betrachten Sie dieses Modell, das den Zusammenhang von PS-Zahl (`hp`: horse power) und Spritverbrauch (`mpg`: miles per Gallone) untersucht (Datensatz `mtcars`):

```
data(mtcars)
library(rstanarm)
library(easystats)
lm1 <- stan_glm(mpg ~ hp, data = mtcars,
               refresh = 0)
```

Parameter	Median	95% CI
(Intercept)	30.11	(26.89, 33.43)
hp	-0.07	(-0.09, -0.05)

Wie ist der Effekt von β_1 (hp) im Modell am besten zu interpretieren?

- ☐ Die Korrelation zwischen PS-Zahl und Spritverbrauch beträgt 0,1
- ☐ Der PS-Wert erklärt 0,1 % der Varianz im Spritverbrauch
- ☐ Ein Auto mit einem PS mehr verbraucht 0,1 Gallonen mehr Sprit pro gefahrener Meile
- ☐ Bei einem PS-Wert von 0 beträgt der geschätzte mittlere Spritverbrauch 0,1 Meilen pro Gallone
- ☐ Ein Auto mit einem PS mehr kommt im Mittel ca. 0,1 (0.07) Meilen weniger weit mit einer Gallone Sprit, laut diesem Modell



Weltsensation?! Der Insektenforscher Prof. Mügge ist der Meinung, eine bislang unbekannte Käferart entdeckt zu haben. Nach nur 18 Jahren Feldforschung im brasilianischen Regenwald gelang ihm dieser Durchbruch. Wenn es denn nun wirklich eine neue Art ist. Gerade untersucht er ein Exemplar unter dem Mikroskop. Hm, was ist das für ein Tier?

Drei Arten kommen in Frage, A_1 , A_2 , A_3 .

Dabei ist die Art A_1 sehr verbreitet und schon längst bekannt, A_2 ist die neue Art, Exemplare dieser Art sind selten und A_3 ist auch bekannt und eher häufig anzutreffen. Allerdings spricht das Aussehen am ehesten für A_2 , der seltenen Art.

Hier sind die genauen Vorkommenshäufigkeiten:

```
Pr_A1 <- .6
Pr_A2 <- .1
Pr_A3 <- .3
```

Und hier die genauen Wahrscheinlichkeiten, wie typisch das beobachtete Objekt für einen Vertreter der jeweiligen Art ist:

```
L_A1 <- .5
L_A2 <- .9
L_A3 <- .4
```

Wie groß ist die Wahrscheinlichkeit, dass Prof. Mügge wirklich einen großen Fang gemacht hat und einen unbekannten Käfer entdeckt hat? Berechnen Sie diese Wahrscheinlichkeit!

- ☐ 50 %
- ☐ 17,6 %
- ☐ 23,1 %
- ☐ 10 %
- ☐ 90 %



In *Think Bayes* stellt Allen Downey folgende Aufgabe:

“Angenommen, es gibt zwei Schüsseln mit Keksen.

Schüssel 1 enthält 30 Vanillekekse und 10 Schokoladenkekse.

Schüssel 2 enthält 20 Vanillekekse und 20 Schokoladenkekse.

Nehmen Sie nun an, Sie wählen zufällig eine der beiden Schüsseln aus und ziehen daraus, ohne hinzusehen, zufällig einen Keks.

Wenn der Keks Vanille ist, wie groß ist die Wahrscheinlichkeit, dass er aus Schüssel 1 stammt?”

Wählen Sie die korrekte Antwort!

- ☐ .33
- ☐ .40
- ☐ .75
- ☐ .50
- ☐ .60



Eine Studentin hat zwei Klausuren, A und B geschrieben. Sie schätzt ihre Chancen zu bestehen auf 35% bzw. auf 60%. Unterstellen Sie Unabhängigkeit der Ereignisse.

```
Pr_A <- .35  
Pr_B <- .6
```

Wie groß ist die Chance, mindestens eine der beiden Klausuren zu bestehen?

- ☐ 26 %
- ☐ 74 %
- ☐ 95 %
- ☐ 60 %
- ☐ 21 %



Ein Krebstest (T) hat die Wahrscheinlichkeit 0.9, einen vorhandenen Krebs (K) zu erkennen: $Pr(T+ | K+)$. Die Falsch-Positiv-Rate beträgt 0.05: $Pr(T+ | K-)$. Die Grundrate dieser Krebsart liegt bei 0.01: $Pr(K+)$.

Berechnen Sie die Wahrscheinlichkeit, dass ein Patient tatsächlich Krebs hat, wenn der Test positiv ist:
 $Pr(K + | T+)$.

- ☐ 0.17
- ☐ 0.18
- ☐ 0.01
- ☐ 0.85
- ☐ 0.15



15.2.2 2024

1. [ttest-als-regr](#)
2. [Additionssatz1](#)
3. [Nerd-gelockert](#)
4. [Urne1](#)
5. [corona-blutgruppe](#)
6. [voll-normal](#)
7. [alphafehler-inflation3](#)
8. [verteilungen-quiz-05](#)
9. [verteilungen-quiz-03](#)
10. [verteilungen-quiz-04](#)
11. [Kekse03](#)
12. [globus-bin2](#)
13. [globus2](#)
14. [iq01a](#)
15. [gem-wskt4](#)
16. [Rethink2m3](#)
17. [mtcars-post2a](#)
18. [groesse03](#)
19. [bath42](#)
20. [klausur-raten](#)
21. [bed-post-wskt1](#)
22. [mtcars-post3a](#)
23. [exp-tab](#)
24. [norms-sd](#)
25. [mtcars-post_paper](#)
26. [bfi10](#)
27. [rope-luecke](#)
28. [wskt-schluckspecht2a](#)
29. [penguins-stan-06](#)

15.2.3 2023

[Dieser Tag auf dem Datenwerk](#) stellt Fragen einer Probeprüfung (Version 2023) zusammen.

15.2.4 2022

[Dieser Tag auf dem Datenwerk](#) stellt Fragen einer Probeprüfung (Version 2022) zusammen.

15.3 Lieblinglingsfehler

Lieblinglingsfehler im Überblick 🙋:

1. Quantile und Verteilungsfunktion verwechseln
2. Prädiktoren nicht zentrieren, wenn es einen Interaktionsterm gibt
3. Interaktion falsch interpretieren
4. Regressionskoeffizienten kausal interpretieren, wenn es keine kausale Fundierung gibt

15.3.1 Post-Präd-Verteilung (PPV) und Post-Verteilung verwechseln 🙋

🔗 🔗 Vertiefung: Dieser Abschnitt ist nicht prüfungsrelevant. 🚫 🔗

Berechnen wir unser Standard-mtcars-Modell: `mpg ~ hp`.

```
m1 <- stan_glm(mpg ~ hp, data = mtcars, refresh = 0)
```

Die *Post-Verteilung* zeigt Stichproben zu den Parameterwerten, s. [Tabelle 15.1](#).

```
post_verteilung <- m1 %>%  
  as_tibble()  
head(post_verteilung)
```

Tabelle 15.1: Postverteilung in Stichprobenform (m1)

Diese Tabelle kann man hernehmen, um Fragen zu Post-Verteilung zu beantworten. Häufig ist es aber bequemer, z.B. mit `parameters(m1)` Post-Intervalle und Punktschätzer auszulesen.

Die *Posterior-Prädiktiv-Verteilung (PPV)* zeigt die Vorhersagen, also keine Parameterwerte, sondern Beobachtungen.

15.3.2 Quantile und Verteilungsfunktion verwechseln 🙋

15.3.2.1 Quantil für p

Ein p -Quantil teilt eine Verteilung in zwei Teile, und zwar so, dass mind. p kleiner oder gleich dem p -Quantil sind. s. [Abbildung 15.1](#).




Abbildung 15.1: 50%-Quantil

Das 50%-Quantil (.5-Quantil) beträgt $x = 0$. Mind ein Anteil $1 - p$ ist größer oder gleich dem p -Quantil.

15.3.2.2 Verteilungsfunktion F

$F(x)$ gibt die Wahrscheinlichkeit an der Stelle x an, dass X einen Wert kleiner oder gleich x annimmt, s. [Abbildung 15.2](#).




Abbildung 15.2: Verteilungsfunktion $F(x=0)=1/2$

$F(0) = 1/2$, die Wahrscheinlichkeit beträgt hier 50%, dass x nicht größer ist als 0.

15.3.3 Interaktion falsch interpretieren 🙋

Berechnen wir ein einfaches Interaktionsmodell: `mpg ~ hp*vs`.

Hinweis

Zur Erinnerung: `mpg ~ hp*vs` ist synonym zu (aber kürzer als) `mpg ~ hp + vs + hp:vs`.

```
m2 <- stan_glm(mpg ~ hp*vs, data = mtcars) # mit Interaktionseffekt
```

Modellkoeffizienten, s. [Tabelle 15.2](#).

```
parameters(m2)
```

Tabelle 15.2: Parameter von m2

Parameter	Median	95% CI	pd	Rhat	ESS (tail)	Prior
(Intercept)	24.58	(19.07, 29.94)	100%	1.001	2588	Normal (20.09 +- 15.07)
hp	-0.04	(-0.07, -0.01)	99.80%	1.001	2596	Normal (0.00 +- 0.22)
vs	14.22	(5.76, 23.58)	100%	1.002	1612	Normal (0.00 +- 29.89)
hp:vs	-0.11	(-0.20, -0.03)	99.85%	1.001	1738	Normal (0.00 +- 0.31)

[Tabelle 15.2](#) zeigt die Visualisierung der Parameter von m2.

```
plot(parameters(m2))
```




Abbildung 15.3: Parameter von m2 visualisiert

Falsch 🙈 Der Unterschied im Verbrauch zwischen den beiden Gruppen `vs=0` und `vs=1` beträgt ca. -0.11.

Richtig 🧐 Der Unterschied im Verbrauch zwischen den beiden Gruppen `vs=0` und `vs=1` beträgt ca. -0.11 – wenn `hp=0`.

Da $hp=0$ kein realistischer Wert ist, ist das Modell schwer zu interpretieren. Zentrierte Prädiktoren wären hier eine sinnvolle Lösung.

Gelman et al. (2021), Kap. 10, McElreath (2020), Kap. 8

15.4 Kochrezepte

15.4.1 Kochrezept: Forschungsfrage untersuchen

Theoretische Phase 1. Staunen über ein Phänomen, y , Kausalfrage finden 2. Literatur wälzen, um mögliche Ursachen x von y zu lernen 3. Forschungsfrage, Hypothese präzisieren 4. Modell präzisieren (DAG(s), Prioris)

Empirische Phase

- 5. Versuch planen
- 6. Daten erheben

Analytische Phase

- 7. Daten aufbereiten
- 8. Modell berechnen anhand eines oder mehrerer DAGs
- 9. Modell prüfen/kritisieren
- 10. Forschungsfrage beantworten

Yeah! Fertig.

15.4.2 Parameter schätzen vs. Hypothesen prüfen

Quantitative Studien haben oft einen von zwei (formalen) Zielen: Hypothesen testen oder Parameter schätzen.

Beispiel Hypothesenprüfung: "Frauen parken im Durchschnitt schneller ein als Männer". Beispiel

Parameterschätzung: "Wie groß ist der mittlere Unterschied in der Ausparkzeit zwischen Frauen und Männern?"

Je ausgereifter ein Forschungsfeld, desto *kühnere* Hypothesen lassen sich formulieren: - stark ausgereift: - Die nächste totale Sonnenfinsternis in Deutschland wird am 27.7.2082 um 14.47h stattfinden, [Quelle](#) - gering ausgereift: - Die nächste Sonnenfinsternis wird in den nächsten 100 Jahren stattfinden. - Lernen bringt mehr als Nicht-Lernen für den Klausurerfolg. Kühne Hypothesen sind wünschenswert 

15.4.3 Formalisierung von Forschungsfragen

Der Mittelwert in Gruppe A ist höher als in Gruppe B (der Unterschied, d , im Mittelwert ist größer als Null):

$$\mu_1 > \mu_2 \Leftrightarrow \mu_1 - \mu_2 > 0 \Leftrightarrow \mu_d > 0$$

15.5 Kerngedanken Bayes

 [Bayes in fünf Minuten](#)

 [Bayes in zehn Minuten](#)

15.5.1 Zentraler Kennwert der Bayes-Statistik: Post-Verteilung

Berechnen wir wieder ein einfaches¹ Modell: `mpg ~ hp`.

```
m3 <- stan_glm(mpg ~ hp, data = mtcars)
```

Und schauen wir uns die Post-Verteilung an, mit eingezeichnetem HDI, s. [Abbildung 15.4](#).




Abbildung 15.4: Post-Verteilung (HDI) von m3

Ein Zusammenfassen der Posterior-Verteilung (z.B. zu einem 95%-PI) ist möglich und oft sinnvoll. Verschiedene Arten des Zusammenfassens der Post-Verteilung sind möglich, z.B. zu Mittelwert oder SD oder einem HD-Intervall. Allerdings übermittelt nur die gesamte Post-Verteilung alle Informationen. Daher empfiehlt es sich (oft), die Post-Verteilung zu visualisieren.

15.5.2 Posteriori als Produkt von Priori und Likelihood

$$\text{Posteriori} = \frac{\text{Likelihood} \times \text{Priori}}{\text{Evidenz}}$$

15.6 Beispiele für Prüfungsaufgaben

15.6.1 Geben Sie den korrekten Begriff an!

👤 🚗 🧑 🧑 🔄 Hans 🧑 🔄 Anna 🧑 🔄 Lise

Puh, wie erstelle ich für alle Studis ein anderes Rätsel²?

15.6.2 DAG mit doppelter Konfundierung

Puh, jetzt kommt ein wilder DAG, s. [Abbildung 15.5](#).




Abbildung 15.5: Ein DAG mit doppelter Konfundierung. Ist hier noch zu helfen?

Definition 15.1 (Minimale Adjustierungsmenge) die Minimale Adjustierungsmenge für x und y gibt eine kleinstmögliche Menge an an Knoten eines DAGs an, die zu adjustieren sind, um den kausalen Effekt von x auf y zu bestimmen (zu “identifizieren”). $\square$

? Geben Sie die minimale Adjustierungsmenge (minimal adjustment set) an, um den totalen (gesamten) Effekt von E auf D zu bestimmen!

! Entweder ist die Menge $\{A, Z\}$ zu adjustieren oder die Menge $\{B, Z\}$.

Ja, dem DAG ist zu helfen.

15.6.3 DAG mit vielen Variablen

Je nach dem wie komplex Ihre Theorie ist, ist Ihr DAG auch komplex, s. [Abbildung 15.6](#).




Abbildung 15.6: Ein DAG mit vielen Variablen

Minimale Adjustierungsmenge, um den Effekt von E auf D zu identifizieren: $\{7\}, \{8\}$.

Trotz der vielen Variablen, ist der kausale Effekt von E auf D recht gut zu identifizieren.

15.6.4 Ein Kausalmodell der Schizophrenie, van Kampen (2014)

The SSQ model of schizophrenic prodromal unfolding revised:

An analysis of its causal chains based on the language of directed graphs

D. van Kampen

Lesen Sie [hier den Abstract](#).

Folgende Symptome der Schizophrenie wurden gemessen:

Social Anxiety (SAN), Active Isolation (AIS), Affective Flattening (AFF), Suspiciousness (SUS), Egocentrism (EGC), Living in a Fantasy World (FTW), Alienation (ALN), Apathy (APA), Hostility (HOS), Cognitive Derailment (CDR), Perceptual Aberrations (PER), and Delusional Thinking (DET)

van Kampen (2014)

UV: SUS, AV: EGC

Berechnen Sie die minimale Adjustierungsmenge, um den kausalen Effekt der UV auf die AV zu identifizieren!

[Abbildung 15.7](#) zeigt den DAG von van Kampen (2014) zu den Symptomen der Schizophrenie.




Abbildung 15.7: Ein DAG zu den Symptomen der Schizophrenie

Minimales Adjustment-Set für den totalen Kausaleffekt: {AIS, ALN}

15.6.5 Modelle berechnen

Stellen Sie sich auf Aufgaben ein, in denen Sie Modellparameter berechnen sollen. Orientieren Sie sich an den Aufgaben und Inhalten des Unterrichts.

Prüfungsfragen zu Modellen könnten z.B. sein:

- Geben Sie den Punktschätzer (Median) für den Prädiktor X im Modell Y an!
- Geben Sie ein 89%-HDI für den Parameter X im Modell Y an!
- Geben Sie R-Quadrat an.
- Formulieren Sie ein Interaktionsmodell!

- Welches Modell ist korrekt, um den kausalen Effekt zu modellieren?
- Formulieren Sie ein Modell mit folgenden Prioris ...
- Liegt der Effekt X noch im ROPE ?
- Unterscheidet sich die Breite des CI von der Breite des HDI für den Prädiktor X im Modell Y?
- Was verändert sich an den Parametern, wenn Sie die Prädiktoren zentrieren/z-standardisieren?
- ...

15.7 Aufgabensammlungen

Folgende Tags auf dem [Datenwerk](#) beinhalten relevante Aufgaben³:

- [bayes](#)
- [bayes-grid](#)
- [dag](#)
- [qm2](#)
- [probability](#)
- [post](#)
- [rope](#)

Besondere “Prüfungsnahe” könnten diese Sammlungen haben:

- [qm2-pruefung](#)
- [exam-22](#)
- [quiz1-qm2-ws23](#)
- [Verteilungen-Quiz](#)

15.7.1 Quiz-Aufgaben

Hier finden Sie Single-Choice-Aufgaben zu diesem Kapitel. Wählen Sie eine Antwort aus und klicken Sie auf das Häkchen, um sie zu überprüfen; über das Fragezeichen erhalten Sie die ausführliche Lösung.

Das Kapitel nennt das Verwechseln von Post-Verteilung und Posterior-Prädiktiv-Verteilung (PPV) als einen “Lieblingsfehler”. Für das Modell `m1: mpg ~ hp` liefert `m1 %>% as_tibble()` eine Tabelle mit Spalten wie `(Intercept)`, `hp` und `sigma`; `posterior_predict(m1)` liefert hingegen eine Tabelle mit vorhergesagten `mpg`-Werten. Welche Aussage zum Unterschied ist korrekt?

- ☐ Der Unterschied zwischen beiden Tabellen ist rein kosmetisch und für die Interpretation der Ergebnisse folgenlos.
- ☐ `as_tibble(m1)` liefert vorhergesagte `mpg`-Werte, `posterior_predict(m1)` liefert die Parameterwerte.
- ☐ Die PPV enthält ausschließlich Parameterwerte, niemals Beobachtungswerte.
- ☐ Beide Befehle liefern exakt dieselbe Information, nur mit unterschiedlichen Spaltennamen.
- ☐ `as_tibble(m1)` liefert Stichproben der *Post-Verteilung* (Werte der Modellparameter wie Achsenabschnitt, Steigung, Sigma); `posterior_predict(m1)` liefert Stichproben der *PPV* (vorhergesagte Beobachtungswerte der AV `mpg`) – beide Tabellen enthalten unterschiedliche Größen und dürfen nicht gleichgesetzt werden.



Für eine Standardnormalverteilung gilt sowohl: das 50%-Quantil beträgt $x = 0$, als auch: die Verteilungsfunktion an der Stelle $x = 0$ beträgt $F(0) = 0,5$. Beide Aussagen liefern hier scheinbar “die gleiche Information”. Welche Aussage zum konzeptionellen Unterschied zwischen Quantil und Verteilungsfunktion ist dennoch korrekt?

- ☐ Quantile sind nur für diskrete, die Verteilungsfunktion nur für stetige Verteilungen definiert.
- ☐ Ein Quantil liefert immer eine Wahrscheinlichkeit, niemals einen Wert auf der X-Achse.
- ☐ Ein p -Quantil ist ein *Wert auf der X-Achse* (gegeben eine Wahrscheinlichkeit p , gesucht ist der zugehörige Wert), während die Verteilungsfunktion $F(x)$ eine *Wahrscheinlichkeit* liefert (gegeben ein Wert x , gesucht ist die zugehörige kumulierte Wahrscheinlichkeit) – beide sind Umkehrfunktionen zueinander.
- ☐ Quantil und Verteilungsfunktion sind in jedem Fall identisch und können beliebig gegeneinander ausgetauscht werden.
- ☐ Die Verteilungsfunktion $F(x)$ liefert immer einen Wert auf der X-Achse, niemals eine Wahrscheinlichkeit.



Für das Interaktionsmodell `m2: mpg ~ hp*vs` (unzentrierte Prädiktoren) wird der Koeffizient für `vs` auf ca. $-0,11$ geschätzt. Welche Interpretation dieses Werts ist laut Kapitel korrekt?

- ☐ Der Unterschied im Verbrauch zwischen `vs=0` und `vs=1` beträgt ca. $-0,11$, und zwar unabhängig vom Wert von `hp`.
- ☐ Da `hp=0` ein realistischer, häufig vorkommender Wert im Datensatz `mtcars` ist, ist die Interpretation unproblematisch.
- ☐ Der Koeffizient $-0,11$ gibt den Interaktionseffekt selbst an, nicht den Haupteffekt von `vs`.
- ☐ Der Koeffizient für `vs` ist bei einem Interaktionsmodell immer bedeutungslos und sollte grundsätzlich ignoriert werden.
- ☐ Der Unterschied im Verbrauch zwischen `vs=0` und `vs=1` beträgt ca. $-0,11$ – aber nur unter der (meist unrealistischen) Bedingung, dass `hp=0` ist; bei unzentrierten Prädiktoren mit Interaktion bezieht sich der Haupteffekt-Koeffizient immer auf diesen Sonderfall.



Einer der “Lieblingsfehler” im Kapitel lautet: “Prädiktoren nicht zentrieren, wenn es einen Interaktionsterm gibt”. Warum ist das Fehlen der Zentrierung bei einem Interaktionsmodell besonders problematisch?

- ☐ Zentrieren ist nur bei Interaktionsmodellen mit ausschließlich nominalen Prädiktoren notwendig.
- ☐ Zentrieren ist bei Interaktionsmodellen zwar üblich, hat aber überhaupt keinen Effekt auf die Interpretierbarkeit der Koeffizienten.
- ☐ Ohne Zentrierung beziehen sich die Haupteffekt-Koeffizienten der beteiligten Prädiktoren jeweils auf den (oft unrealistischen) Fall, dass der jeweils andere Prädiktor den Wert 0 annimmt – das erschwert die

Interpretation erheblich und lädt zu Fehlinterpretationen ein (wie bei `mpg ~ hp*vs`).

- ☐ Nicht-zentrierte Prädiktoren führen bei Interaktionsmodellen automatisch zu falschen Vorhersagen des Modells.
- ☐ Ohne Zentrierung lässt sich ein Interaktionsmodell technisch überhaupt nicht mit `stan_glm()` berechnen.



Ein weiterer im Kapitel genannter “Lieblingsfehler” lautet: “Regressionskoeffizienten kausal interpretieren, wenn es keine kausale Fundierung gibt”. Was genau ist mit “kausaler Fundierung” hier gemeint, und wann ist eine kausale Interpretation eines Regressionskoeffizienten gerechtfertigt?

- ☐ Ein Regressionskoeffizient darf immer kausal interpretiert werden, sobald er statistisch (mit hoher Wahrscheinlichkeit) von Null verschieden ist.
- ☐ Eine kausale Interpretation ist immer dann gerechtfertigt, wenn möglichst viele Kontrollvariablen ins Modell aufgenommen wurden.
- ☐ Eine kausale Interpretation ist nur gerechtfertigt, wenn entweder ein sauber begründetes Kausalmodell (DAG) vorliegt, das die relevanten Konfundierer korrekt berücksichtigt, oder wenn die Daten aus einem gut durchgeführten (randomisierten) Experiment stammen.
- ☐ Kausale Fundierung bedeutet, dass die Stichprobe besonders groß sein muss ($n > 1000$).
- ☐ Ein Regressionskoeffizient ist automatisch kausal interpretierbar, sobald das zugehörige Modell einen hohen R^2 -Wert aufweist.



Ein DAG mit “doppelter Konfundierung” enthält folgende Pfeile: $A \rightarrow E$, $A \rightarrow Z$, $B \rightarrow D$, $B \rightarrow Z$, $E \rightarrow D$, $Z \rightarrow D$, $Z \rightarrow E$. Dabei ist E die UV (Exposure) und D die AV (Outcome). Welche der folgenden Mengen ist laut Kapitel eine korrekte *minimale Adjustierungsmenge*, um den totalen kausalen Effekt von E auf D zu bestimmen?

- ☐ $\{D\}$ – man muss die AV selbst kontrollieren.
- ☐ Die leere Menge $\{\}$ – man muss überhaupt nichts kontrollieren.
- ☐ $\{A, Z\}$ (oder alternativ $\{B, Z\}$)
- ☐ $\{A, B, Z\}$ – man muss immer alle Variablen des DAGs kontrollieren.
- ☐ $\{A, B\}$, ohne Z zu berücksichtigen.



Was ist laut Kapitel eine “minimale Adjustierungsmenge” (minimal adjustment set)?

- ☐ Die kleinstmögliche Menge an Knoten (Variablen) eines DAGs, die kontrolliert (adjustiert) werden müssen, um den kausalen Effekt der UV auf die AV zu identifizieren.
- ☐ Die Menge aller Variablen, die niemals kontrolliert werden dürfen, unabhängig vom DAG.

- ☐ Die minimale Anzahl an Beobachtungen (Stichprobengröße), die für eine verlässliche Kausalanalyse nötig ist.
- ☐ Eine beliebige, zufällig ausgewählte Teilmenge der im DAG enthaltenen Variablen.
- ☐ Die größtmögliche Menge an Variablen, die man in ein Regressionsmodell aufnehmen sollte, um möglichst viel Varianz zu erklären.



Das Kapitel vergleicht eine “stark ausgereifte” Hypothese (“Die nächste totale Sonnenfinsternis in Deutschland wird am 27.7.2082 um 14:47 Uhr stattfinden”) mit einer “gering ausgereiften” Hypothese (“Lernen bringt mehr als Nicht-Lernen für den Klausurerfolg”). Welche Aussage zum Zusammenhang zwischen Reifegrad eines Forschungsfeldes und der “Kühnheit” von Hypothesen ist korrekt?

- ☐ Je ausgereifter ein Forschungsfeld ist (je mehr gesichertes, präzises Wissen vorliegt), desto kühnere – d.h. präzisere und riskantere, leichter falsifizierbare – Hypothesen lassen sich formulieren.
- ☐ Eine “gering ausgereifte” Hypothese ist automatisch präziser als eine “stark ausgereifte”, weil in neuen Feldern mehr Unsicherheit herrscht, die durch präzisere Aussagen kompensiert werden muss.
- ☐ Die Präzision einer Hypothese hat nichts mit dem Reifegrad des zugrundeliegenden Forschungsfeldes zu tun.
- ☐ Kühne Hypothesen sind grundsätzlich unwissenschaftlich und sollten vermieden werden.
- ☐ Je weniger ausgereift ein Forschungsfeld ist, desto präzisere Hypothesen kann man formulieren, da noch wenig bekannt ist.



Das “Kochrezept” zur Untersuchung einer Forschungsfrage gliedert sich laut Kapitel in drei Phasen: theoretisch, empirisch, analytisch. Welche Zuordnung von Schritten zu Phasen ist korrekt?

- ☐ Die Datenerhebung gehört in die theoretische Phase, das Festlegen von Prioris in die analytische Phase.
- ☐ Alle Schritte (Literaturrecherche, Datenerhebung, Modellberechnung) gehören in ein und dieselbe Phase, eine Unterteilung in drei Phasen ist im Kapitel nicht vorgesehen.
- ☐ Modellkritik (Schritt “Modell prüfen/kritisieren”) ist laut Kapitel kein notwendiger Bestandteil des Forschungsprozesses.
- ☐ Theoretische Phase: Phänomen entdecken, Literatur wälzen, Forschungsfrage präzisieren, Modell (DAG, Prioris) festlegen. Empirische Phase: Versuch planen, Daten erheben. Analytische Phase: Daten aufbereiten, Modell berechnen, Modell prüfen, Forschungsfrage beantworten.
- ☐ Die analytische Phase kommt laut Kapitel vor der empirischen Phase: Man berechnet zuerst das Modell und erhebt danach erst die Daten.



Das Kapitel betont im Abschnitt zu den “Kerngedanken Bayes”, dass man eine Post-Verteilung zwar zu einzelnen Kennzahlen (z.B. Mittelwert, SD oder einem HD-Intervall) zusammenfassen kann, dies aber mit

einem gewissen Informationsverlust einhergeht. Welche Aussage dazu ist korrekt?


- ☐ Mittelwert und Standardabweichung der Post-Verteilung sind grundsätzlich nutzlose Kennzahlen und sollten nie berichtet werden.
- ☐ Die Visualisierung der Post-Verteilung ist laut Kapitel überflüssig, sobald man ein Schätzintervall berechnet hat.
- ☐ Eine zusammengefasste Kennzahl (wie ein Intervall) enthält grundsätzlich mehr Information als die vollständige Post-Verteilung selbst.
- ☐ Nur die *gesamte* Post-Verteilung übermittelt alle verfügbaren Informationen über die Ungewissheit eines Parameters; jede Zusammenfassung (z.B. ein einzelnes Intervall) reduziert diese Information notwendigerweise – deshalb ist es oft sinnvoll, die Post-Verteilung zusätzlich zu visualisieren.
- ☐ Ein 95%-HDI enthält immer exakt dieselbe Information wie die vollständige Post-Verteilung, ohne jeglichen Informationsverlust.



15.8 Viel Erfolg bei der Prüfung!



15.9 —



1. langweiliges [↔](#)
2. Fahr-Hier-Hans-Anna-Lise: Varianzanalyse [↔](#)
3. das ist keine vollständige Liste, sondern eine Anregung. Andere Tags könnten auch relevant sein [↔](#)

Impressum



Quellcode anzeigen

Problem melden