Start:Bayes!

Die drei Zielarten der Statistik

Sebastian Sauer



Die drei Zielarten in der Statistik

Wozu ist Statistik eigentlich da?

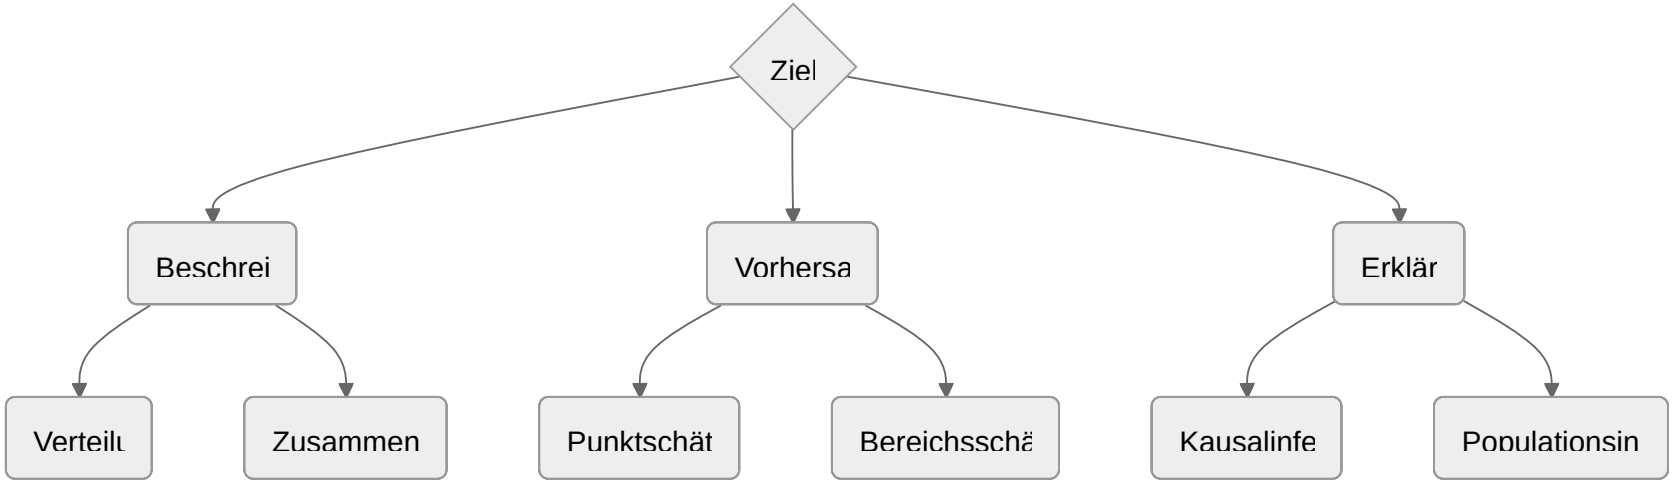
Nach Shmueli (2010) lassen sich drei Zielarten statistischer Analysen unterscheiden:

- **Beschreiben**
- **Vorhersagen**
- **Erklären**

Anhand der verwendeten Methode (z. B. Regression) allein erkennt man **nicht**, welches Ziel eine Studie verfolgt — das steht in der Forschungsfrage.

Die drei Zielarten in der Statistik

Übersicht der drei Zielarten



Beispiele für die drei Zielarten

- **Beschreiben:** Wie groß ist der Gender-Paygap in Branche X im Zeitraum Y?
- **Vorhersagen:** Wenn Mr. X 100 Stunden auf die Statistikklausur lernt, welche Note ist zu erwarten?
- **Erklären:** Wie viel *bringt* (mir) das Lernen auf die Klausur?

Zielart *Beschreiben*

Beschreiben im Überblick

- Ziel: Daten zu aussagekräftigen Kennzahlen zusammenfassen
- Synonym: **deskriptive Statistik**
- Typische Kennzahlen: Mittelwert, Korrelation, Regressionskoeffizienten
- **Kein** Anspruch, über die Daten hinauszugehen (keine Aussage über die Population)

Definition: Deskriptivstatistik

Deskriptivstatistik fasst Merkmale aus einer Stichprobe zu Kennzahlen (Statistiken) zusammen.

Beschreiben — Beispiel

- 100 Studis im Hörsaal schreiben ihre Körpergröße auf
- Dozentin berechnet den Mittelwert
- Fertig: **deskriptive Statistik!**



Beschreibende Statistik fasst eine oder mehrere Variablen zu einer Kennzahl zusammen.

Beschreibende Statistik fasst eine oder mehrere Variablen zu einer Kennzahl zusammen.



Zielart *Vorhersagen*

Vorhersagen im Überblick

- Ziel: gegeben Werten der UV den Wert der AV vorhersagen
- Synonym: **prädiktive / prognostische Analyse**
- Ergebnis: Punktschätzung oder Bereichsschätzung

Beispiel — Ali lernt für die Klausur: Ali lernt 42 Stunden. Vorhersage: 83 Punkte (Punktschätzung) bzw. 80–86 Punkte (Bereichsschätzung).

Vorhersagen — Regressionsmodell für Ali



Noten und Lernzeit: Rohdaten mit Regressionsgerade und Punkt-Vorhersage für Ali

Noten und Lernzeit: Rohdaten mit Regressionsgerade und Punkt-Vorhersage für Ali



Vorhersagen — mit Unsicherheitsbereich



Regressionsgerade mit Vorhersagebereich für Ali (herangezoomt)

Regressionsgerade mit Vorhersagebereich für Ali (herangezoomt)



Zielart *Erklären*

Erklären im Überblick

Synonym: **schließende Statistik / Inferenzstatistik**

Zwei Bedeutungen (vgl. Gelman et al., 2021):

1. **Populationsinferenz** — gilt der Stichproben-Befund auch in der Grundgesamtheit?
2. **Kausalinferenz** — welche Variable ist Ursache, welche Wirkung?

Erklären — Beispiele

Populationsinferenz:

- Wie groß ist b (Lernzeit → Note) in der Grundgesamtheit?
- Bevorzugen Kunden *allgemein* Webshop A oder B?

Kausalinferenz:

- Ist Größe eine Ursache von Gewicht?
- Wenn ich 100 h lerne, welche Note schreibe ich dann *deswegen*?

Kausalinferenz — Studie A: Östrogen

Fiktive klinische Studie, $n = 700$: Medikament vs. kein Medikament, getrennt nach Geschlecht.

- Bei Männern: Medikament hilft
- Bei Frauen: Medikament hilft
- **Gesamt: Medikament hilft NICHT?!**

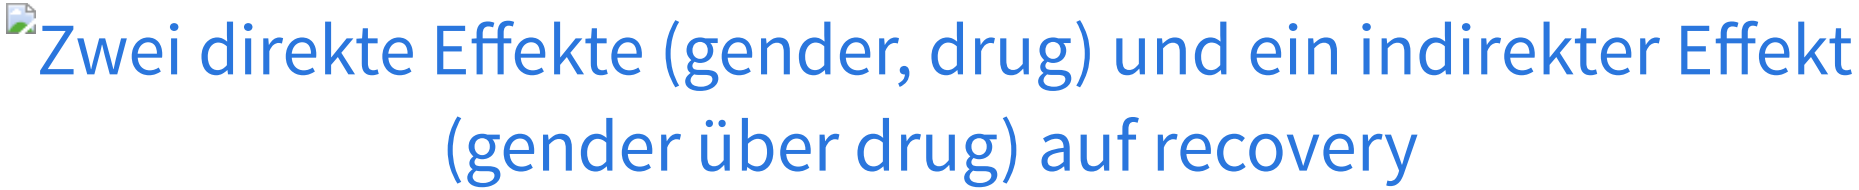
Wie kann das sein? Was raten wir dem Arzt?

Studie A — Daten im Bild



Daten zur Studie A im Balkendiagramm

Studie A — die kausale Struktur



Zwei direkte Effekte (gender, drug) und ein indirekter Effekt (gender über drug) auf recovery

Wichtig

Geschlecht **konfundiert** den Zusammenhang von Medikament und Heilung. Hier ist **Stratifizieren** (nach Geschlecht trennen) der richtige Weg.

Kausalinferenz — Studie B: Blutdruck

Gleiche Datenstruktur wie Studie A, aber:

- Bei geringem Blutdruck: Medikament schädlich
- Bei hohem Blutdruck: Medikament schädlich
- **Gesamt: Medikament scheint zu nützen?!**

Studie B — die kausale Struktur



Drug hat keinen direkten, aber zwei indirekte Effekte auf recovery — einer heilsam, einer schädlich

Drug hat keinen direkten, aber zwei indirekte Effekte auf recovery — einer heilsam, einer schädlich

> **Wichtig**
>
> Hier zeigt die **Gesamtbetrachtung** den wahren kausalen Effekt. Stratifizieren wäre hier **falsch** — man sähe nur den toxischen Effekt.



Studie A vs. B — die Pointe

- **Gleiche Daten-Struktur**, aber **unterschiedliches Kausalmodell**
- In A: Stratifizieren richtig
- In B: Stratifizieren falsch
- Ohne Kausalmodell ist aus den Daten allein **keine** Handlungsempfehlung ableitbar

Wichtig

Für Entscheidungen (“Was soll ich tun?”) braucht man kausales Wissen — basierend auf Theorie (Kausalmodell) **plus** Daten.

Populationsinferenz

- Schließt von der **Stichprobe** auf die **Grundgesamtheit**
- Nicht die Frage “was ist Ursache”, sondern: gilt der Befund auch allgemein — oder ist er nur Stichprobenrauschen?
- Werkzeuge: Konfidenzintervalle, Signifikanztests, **Bayes-Statistik** (Fokus dieses Buchs)

Wichtig

Populationsinferenz sagt **nichts** über Ursache und Wirkung aus — ein statistisch gesicherter Zusammenhang kann trotzdem konfundiert sein.

Populationsinferenz — Beispiele

- Zusammenhang Lernzeit–Note in der Stichprobe: $b = 0{,}8$. Wie groß ist b vermutlich in der Grundgesamtheit?
- Kunden bevorzugen in der Stichprobe Webshop A vor B. Gilt das für *alle* (zukünftigen) Kunden — oder ist das Zufall?

Populationsinferenz ist Thema des nächsten Kapitels.

Modellieren

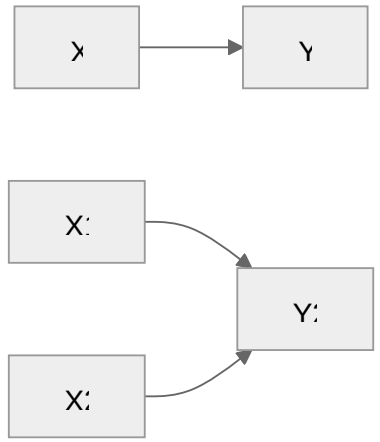
Modellieren — Grundraster des Erkennens

- Die Welt ist zu komplex, um jedes Detail zu erfassen
- Wir vereinfachen — aber behalten das Wesentliche

Definition: Modell

Ein Modell ist ein vereinfachtes Abbild der Wirklichkeit.

X und Y — das Sinnbild des statistischen Modells



Definition: Funktion

Eine mathematische Funktion f setzt zwei Größen in Beziehung: $f : X \to Y$ bzw. $y = f(x)$.

Definition: Effekt

Effekt bezeichnet die Größe des statistischen Zusammenhangs (oder der Differenz) zwischen UV und AV, die über den zufälligen Erwartungswert hinausgeht. Effekt ist nicht unbedingt kausal zu verstehen.

Alle drei Zielarten modellieren — aber unterschiedlich

- **Beschreiben:** Kennzahlen wie der Mittelwert, um sich “ein Bild zu machen”
- **Vorhersagen:** Modelle als Werkzeug für genaue Vorhersagen (ohne Erklärungsanspruch)
- **Erklären:** Modelle, um die Wirklichkeit möglichst korrekt darzustellen

Regression zum Modellieren



Eine Regression

> **Hinweis**
>
> Regression + Inferenz = 💖

Die Regression ist das “Schweizer Taschenmesser” der Statistik — (fast) immer einsetzbar, statt vieler verschiedener Spezialverfahren.

Regression statt Verfahrens-Wald



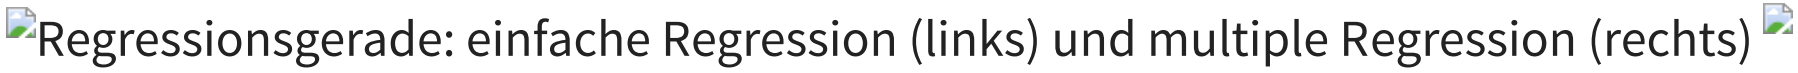
Wähle die Regression statt vieler Einzelverfahren

> **Hinweis**
>
> Viele klassische Verfahren (t-Test, ANOVA, Korrelation) sind **Spezialfälle** der Regression.

Spezialfälle der Regression

- **t-Test:** UV zweistufig nominal, AV metrisch
- **ANOVA:** UV mehrstufig nominal, AV metrisch
- **Korrelation:** = Regressionskoeffizient β_1, wenn UV und AV z-standardisiert sind

Die Regressionsgleichung



Satz: Lineares Modell (Regressionsgleichung)

$$y = \beta_0 + \beta_1 x_1 + \ldots + \beta_k x_k + \epsilon$$

β_0: Achsenabschnitt (Intercept); $\beta_1, \ldots, \beta_k$: Steigungen (Regressionsgewichte, Koeffizienten, Parameter) (Gelman et al., 2021).

Fazit

Fazit — Zusammenfassung

- Drei Zielarten: **Beschreiben**, **Vorhersagen**, **Erklären** (Populations- & Kausalinferenz)
- Alle drei modellieren — mit unterschiedlichem Anspruch
- Die **Regression** ist unser universelles Werkzeug für alle Zielarten
- Als Nächstes: Populationsinferenz vertiefen

> **Wichtig**
>
> Kontinuierliches Lernen ist der Schlüssel zum Erfolg.

Vielen Dank!

Fragen?

Gelman, A., Hill, J., & Vehtari, A. (2021). *Regression and Other Stories*. Cambridge University Press.

Shmueli, G. (2010). To Explain or to Predict? *Statistical Science*, *25*(3), 289–310. https://doi.org/10.1214/10-STS330

