Start:Bayes!

Einfache lineare Modelle

Sebastian Sauer



Einstieg

Lernziele

Nach diesem Kapitel können Sie …

- das Zusammenspiel von Apriori-Verteilungen und linearem Modell zur Berechnung der Likelihood erläutern
- die Post-Verteilung für einfache lineare Modelle in R berechnen
- zentrale Informationen (Lage-, Streuungsmaße, Schätzintervalle) aus der Post-Verteilung eines Regressionsmodells herauslesen

Orientiert an McElreath (2020), Kap. 4.4.



Überblick

- Modell: Körpergröße vorhergesagt durch Gewicht (!Kung-Datensatz)
- Neu ggü. Frequentistischer Regression (`lm`): Die drei Parameter β_0, β_1, σ haben jetzt eine **Post-Verteilung**
- Frequentistisch: nur Punktschätzer pro Parameter
- Bayes: eine ganze Verteilung pro Parameter — informationsreicher



Den Datensatz verstehen

Der Datensatz: !Kung-Leute

- Datei `Howell1a.csv` (McElreath, 2020)
- Nur Erwachsene (Alter > 18)
- Variablen u. a.: `height` (Größe), `weight` (Gewicht), `age`, `male`



Explorative Datenanalyse (EDA)

- Nicht zwingend nötig für die Bayes-Regression, aber hilfreich zum Datenverständnis
- Keine fehlenden Werte im Datensatz
- `age` rechtsschief; `height` und `weight` eher symmetrisch/normalverteilt
- `height` bimodal — vermutlich Mischung der Geschlechter
- Etwas mehr Männer als Frauen im Datensatz



Zusammenhänge in den Daten



Starke Zusammenhänge zwischen Größe und Gewicht sowie zwischen Geschlecht und Größe/Gewicht.

Gewicht und Größe: linearer Zusammenhang

- Regression prüft, inwieweit zwei Variablen Y und X **linear** zusammenhängen
- Je stärker der Zusammenhang, desto besser lässt sich X zur Vorhersage von Y nutzen
- Zusammenhang $\neq$ Kausalität
- *Linear*: Zuwachs in Y relativ zu X ist konstant — steigt X um 1 Einheit, steigt Y um b Einheiten



Gewicht (X) und Größe (Y)



Deutlicher linearer Zusammenhang: je schwerer, desto größer.

Prädiktor zentrieren

- Zentrieren: von jedem Wert den Mittelwert abziehen — $x_i - \bar{x}$
- Ergebnis: `weight_c` (*c* wie *centered*)

> **Warum zentrieren?**
>
> Mit zentriertem Prädiktor gibt der Achsenabschnitt β_0 die Größe einer Person mit **durchschnittlichem** Gewicht an — sonst wäre es die (unsinnige) Größe bei Gewicht = 0. Vgl. Gelman et al. (2021), Kap. 10.4, 12.2.

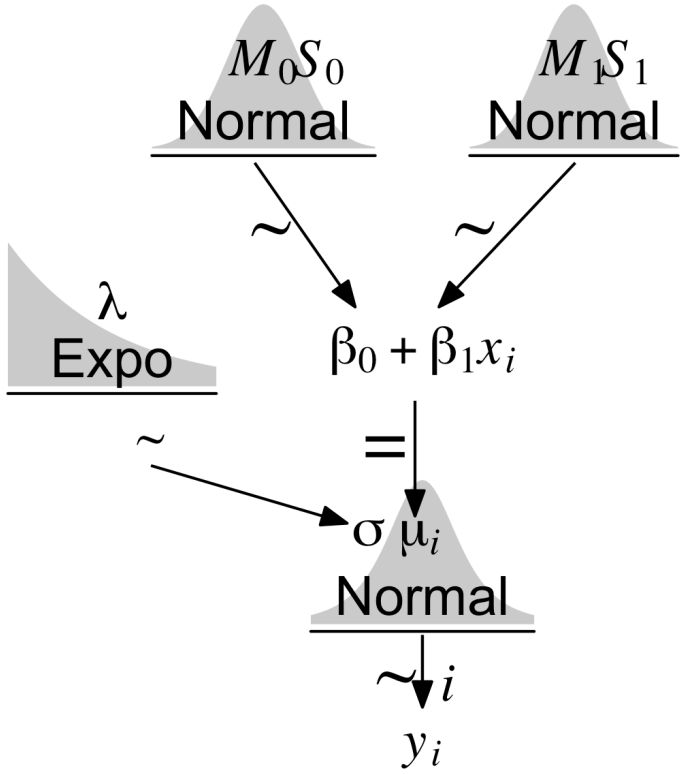
Zentrieren — visualisiert



Der Mittelwert von `weight_c` liegt danach bei 0.

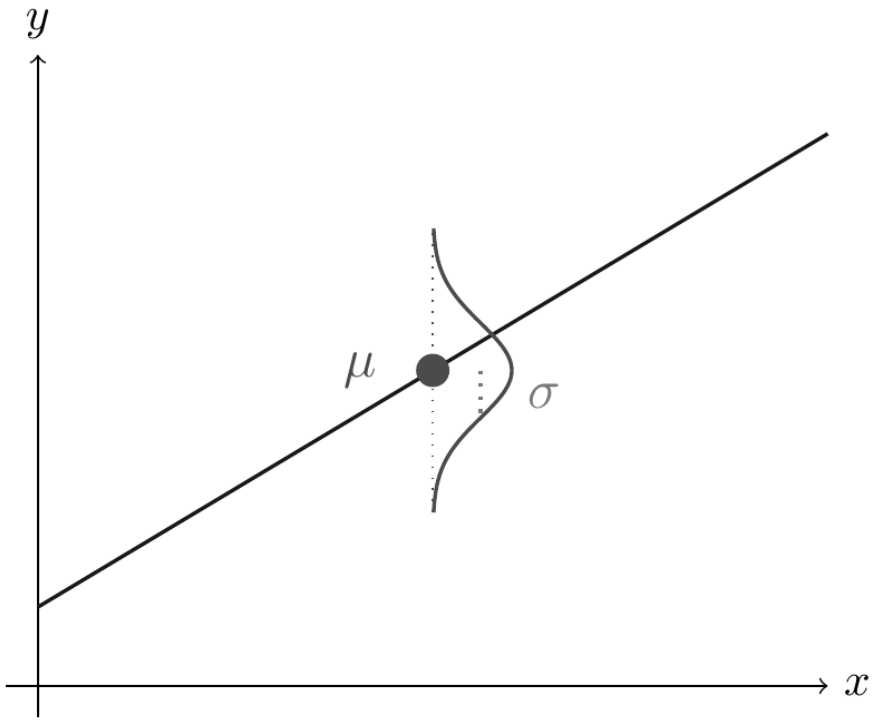
Modell m_kung_gewicht_c: zentrierter Prädiktor

Modellidee: drei Parameter zusammen



Modell m_kung_gewicht_c: zentrierter Prädiktor

Vorhergesagte Größen als Normalverteilungen



Modelldefinition `m_kung_gewicht_c`

Definition: Modelldefinition m_kung_gewicht_c

$$
\begin{aligned}
\text{height}_i &\sim \text{Normal}(\mu_i, \sigma) && \text{Likelihood} \\
\mu_i &= \beta_0 + \beta_1 \cdot \text{weightcentered}_i && \text{Lineares Modell} \\
\beta_0 &\sim \text{Normal}(178, 20) && \text{Priori} \\
\beta_1 &\sim \text{Normal}(0, 10) && \text{Priori} \\
\sigma &\sim \text{Exp}(0.1) && \text{Priori}
\end{aligned}
$$

□

Likelihood lesen

$$\text{height}_i \sim \text{Normal}(\mu_i, \sigma)$$

- Jetzt ein Index i an μ und h: nicht mehr **ein** Mittelwert, sondern **pro Beobachtung** ein μ_i

> "Die Wahrscheinlichkeit, eine bestimmte Größe h bei Person i zu beobachten, gegeben μ und σ, ist normalverteilt."



Das lineare Modell lesen

$$\mu_i = \beta_0 + \beta_1 \cdot \text{weightcentered}_i$$

- μ wird jetzt **deterministisch berechnet**, nicht geschätzt
- β_1: Unterschied in `height` bei einer Einheit Unterschied in `weight` (Steigung)
- β_0: Wert von μ, wenn `weight_c` = 0 (Achsenabschnitt)

> "Der vorhergesagte mittlere Wert der Körpergröße, μ_i, berechnet sich als Summe von β_0 und $\beta_1 \cdot \text{weight}_i$."



Priori-Verteilungen des Modells

$$\beta_0 \sim \text{Normal}(178, 20) \quad \text{Priori Achsenabschnitt}$$
$$\beta_1 \sim \text{Normal}(0, 10) \quad \text{Priori Regressionsgewicht}$$
$$\sigma \sim \text{Exp}(0.1) \quad \text{Priori Sigma}$$

- β_1: schwach informativ — im Schnitt kein Zusammenhang, aber auch starke positive/negative Werte plausibel
- Zahl der Prioris = Zahl der Modellparameter



Die Post-Verteilung befragen

Ein “meinungsstärkeres” Modell

- Modell `m_kung_starkes_beta1`: andere Priori für β_1

$$\beta_1 \sim N(5, 3); \quad \beta_0 \sim N(178, 20); \quad \sigma \sim E(0.1)$$

- Im Schnitt: 5 cm Unterschied in Größe pro 1 kg Unterschied im Gewicht — deutlich “meinungsstärker” als zuvor

> **Hinweis**
>
> `seed` fixiert die Zufallszahlen für reproduzierbare Ergebnisse (Konvention hier: 42).



Definition: Effektwahrscheinlichkeit (pd)

Definition: Effektwahrscheinlichkeit

Die Kennzahl pd (*probability of direction*) gibt an, mit welcher Wahrscheinlichkeit ein Effekt positiv bzw. negativ ist (je nachdem, ob der Median des Effekts positiv oder negativ ist). Sie sagt nichts über die Effektstärke aus — nur ob der Effekt klar auf einer Seite der Null liegt. Grob vergleichbar mit dem p-Wert der Frequentistischen Statistik (Makowski et al., 2019).

Effektwahrscheinlichkeit visualisiert



- `Rhat`, `ESS`: Diagnosekennzahlen der Stichprobenziehung — bei einfachen Modellen i. d. R. unproblematisch

Post-Verteilung befragen: die Bausteine

- Post-Verteilung = viele Stichproben zu β_0, β_1, σ
- `parameters(modell)`: Zusammenfassung der Post-Verteilung
- `as_tibble(modell)`: Rohe Stichproben als Tabelle
- Ergebnis für `m_kung_starkes_beta1`: β_1 (Steigung) liegt etwa zwischen 0.8 und 1.0 cm Größe pro kg Gewicht



Die “mittlere” Regressionsgerade



Regressionsgerade auf Basis der Post-Verteilung (Median von \beta_0, \beta_1)

Post-Verteilung des Regressionsgewichts



- Mittelwert, Median und Modus (MAP) liegen eng beieinander

Post-Verteilung von Sigma



- Interessant: Die *Post*-Verteilung von σ ist normalverteilt, obwohl die *Apriori*-Verteilung exponentialverteilt war — die Daten haben den Prior “überstimmt”

Ungewissheit sichtbar machen

- Regressionsgeraden aus einzelnen Stichproben der Post-Verteilung übereinandergelegt
- 10 Stichproben → breites Band; 1000 Stichproben → dichtes, informatives Band um die wahrscheinlichste Gerade



Erwartungswert mit Unsicherheitsband



Regressionsgerade mit Unsicherheitsintervall (estimate_expectation)

Fragen an die Post-Verteilung: Quantile

Typische Fragen an den (zentrierten) Achsenabschnitt:

- Welche mittlere Größe wird mit 50 %, 90 %, 95 % Wahrscheinlichkeit nicht überschritten?
- Welche mittlere Größe wird mit 95 % Wahrscheinlichkeit nicht unterschritten?
- Von wo bis wo reicht der innere 50 %-Schätzbereich (ETI)?

> **Hinweis**
>
> Statt eines 95 %-Intervalls wird teils ein 90 %- oder 89 %-Intervall empfohlen (bessere numerische Stabilität).

Fragen an die Post-Verteilung: Wahrscheinlichkeitsmassen

- Wie wahrscheinlich ist es, dass die mittlere Größe mindestens 155 cm beträgt?
- Wie wahrscheinlich ist es, dass die mittlere Größe höchstens 154.5 cm beträgt?

Beantwortbar durch einfaches Auszählen der Stichproben aus der Post-Verteilung (Anteil erfüllt Bedingung).



Post-Verteilung bedingt auf einen Prädiktorwert

Post-Verteilung für jeden Gewichtswert

- Für **jeden** beliebigen Wert des Prädiktors lässt sich eine eigene Post-Verteilung von μ berechnen
- Beispiel: Wie groß ist eine Person (im Mittel) bei Gewicht 45 kg? Bei 50 kg?



A: Ausgewählte Gewichtswerte im Modell. B: Bedingte Post-Verteilung für jeden Gewichtswert

Beispiel: μ bei Gewicht = 45 kg

- 45 kg entspricht dem Mittelwert von `weight` → `weight_c = 0`



Post-Verteilung bedingt auf einen Prädiktorwert

Beispiel: μ bei Gewicht = 50 kg

- 50 kg = 5 über dem Mittelwert → `weight_c = 5`
- `mu_at_50 = (Intercept) + 5 * weight_c`



Post-Verteilung der Größe bei einem Gewicht von 50 kg — weiter rechts als bei 45 kg

Lagemaße und Streuungen der bedingten Post-Verteilung

- 90 %-ETI für $\mu|w = 50$: ca. 159 cm bis 160 cm
- 95 %-Quantil für $\mu|w = 45$: welche Größe wird mit 95 % nicht überschritten?

Dieselben Werkzeuge (Quantile, ETI/HDI, Auszählen) funktionieren für jede bedingte Post-Verteilung.



Fazit



Zusammenfassung

- Lineares Modell + Priori-Verteilungen $\longrightarrow$ Post-Verteilung für β_0, β_1, σ
- Zentrieren des Prädiktors macht β_0 leichter interpretierbar
- Die Post-Verteilung lässt sich für **jeden** Prädiktorwert befragen: Lage, Streuung, Quantile, Wahrscheinlichkeitsmassen
- Mehr Information als Punktschätzer der Frequentistischen Regression



Vertiefende Literatur

- McElreath (2020), Kap. 4: vertiefte Darstellung linearer Bayes-Modelle
- Kurz (2021): Tidyverse-Umsetzung der Inhalte von McElreath (2020)
- Gelman et al. (2021): Regressionsanalyse frequentistisch und Bayes



Vielen Dank!

Fragen?

Gelman, A., Hill, J., & Vehtari, A. (2021). *Regression and Other Stories*. Cambridge University Press.

Kurz, S. (2021). *Statistical Rethinking with Brms, Ggplot2, and the Tidyverse: Second Edition*. https://bookdown.org/content/4857/

Makowski, D., Ben-Shachar, M. S., Chen, S. H. A., & Lüdecke, D. (2019). Indices of Effect Existence and Significance in the Bayesian Framework. *Frontiers in Psychology*, *10*. https://www.frontiersin.org/article/10.3389/fpsyg.2019.02767

McElreath, R. (2020). *Statistical Rethinking: A Bayesian Course with Examples in R and Stan* (2. Aufl.). Taylor and Francis, CRC Press.

