# Start:Bayes!

Fallbeispiele

Sebastian Sauer





# Taxonomie von Forschungsfragen

# Lernziele

Nach diesem Kapitel können Sie …

- typische, deskriptive Forschungsfragen als Regression spezifizieren
- Forschungsfragen in Regressionsterme übersetzen
- typische Forschungsfragen mit `stan_glm` auswerten

Orientiert an McElreath (2020) (Kap. 4.4) sowie Gelman et al. (2021) (Kap. 7, 10).





# Nomenklatur

Skalenniveaus der beteiligten Variablen:

- $y$: metrische AV
- $g$: Gruppierungsvariable (nominal, mehrstufig)
- $b$: binäre UV
- $x$: metrische UV
- $u$: ungemessene (unbekannte) Variable

Für jede Forschungsfrage: Beispiel, Modellformel, Kausalgraph, Auswertung.





# Datensätze

- `kidiq`: IQ von Kindern, Schulabschluss und IQ der Mutter (R-Paket `rstanarm`)
- `penguins`: Körpermaße dreier Pinguinarten (R-Paket `palmerpenguins`)

**Definition: Skalenniveaus**

Um Forschungsfragen zu klassifizieren, muss man wissen, welches Skalenniveau AV und UV(s) haben.

# Fallbeispiel 1: `y ~ b`

Binäre UV — Schulabschluss der Mutter

# Forschungsfrage

*Hintergrund:* Eine Schulpsychologin sucht “Risikofaktoren” für geringere Intelligenz von Kindern.

> Ist der mittlere IQ-Wert von Kindern, deren Mutter über einen Schulabschluss verfügt (`mom_hs = 1`), höher als bei Kindern ohne diesen Hintergrund (`mom_hs = 0`)? (ceteris paribus)

Modellformel: `kid_score ~ mom_hs`





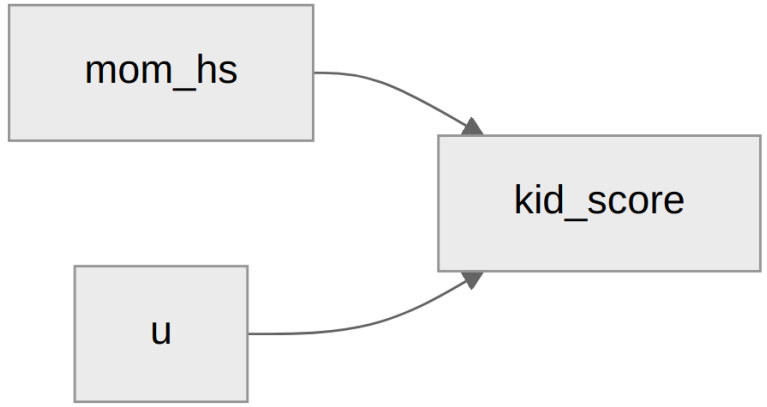
# Hypothesen

**Hypothese für ungleiche Mittelwerte**

$$H_A : \mu_{x=1} > \mu_{x=0}$$

- $H_0 : \mu_{x=1} = \mu_{x=0}$
- ROPE-Hypothese (5 IQ-Punkte als Bagatellgrenze): $H_{ROPE} : \mu_{x=1} > \mu_{x=0} + 5$

# Kausalgraph




y hat laut Modell zwei Ursachen: `mom_hs` und u (unbekannt/sonstige Einflüsse).

# Modell m10.1

```
stan_glm(kid_score ~ mom_hs, data = kidiq)
```

$$
\begin{aligned}
\text{kid score}_i &\sim \text{Normal}(\mu_i, \sigma) && \text{Likelihood} \\
\mu_i &= \beta_0 + \beta_1 \cdot \text{mom hs}_i && \text{Lineares Modell} \\
\beta_0 &\sim \text{Normal}(87, 51) && \text{Prior Achsenabschnitt} \\
\beta_1 &\sim \text{Normal}(0, 124) && \text{Prior Regressionsgewicht} \\
\sigma &\sim \text{Exp}(0.049) && \text{Prior Vorhersagegüte}
\end{aligned}
$$





# Ergebnis m10.1

`kid_score = 78 + 12*mom_hs + error`

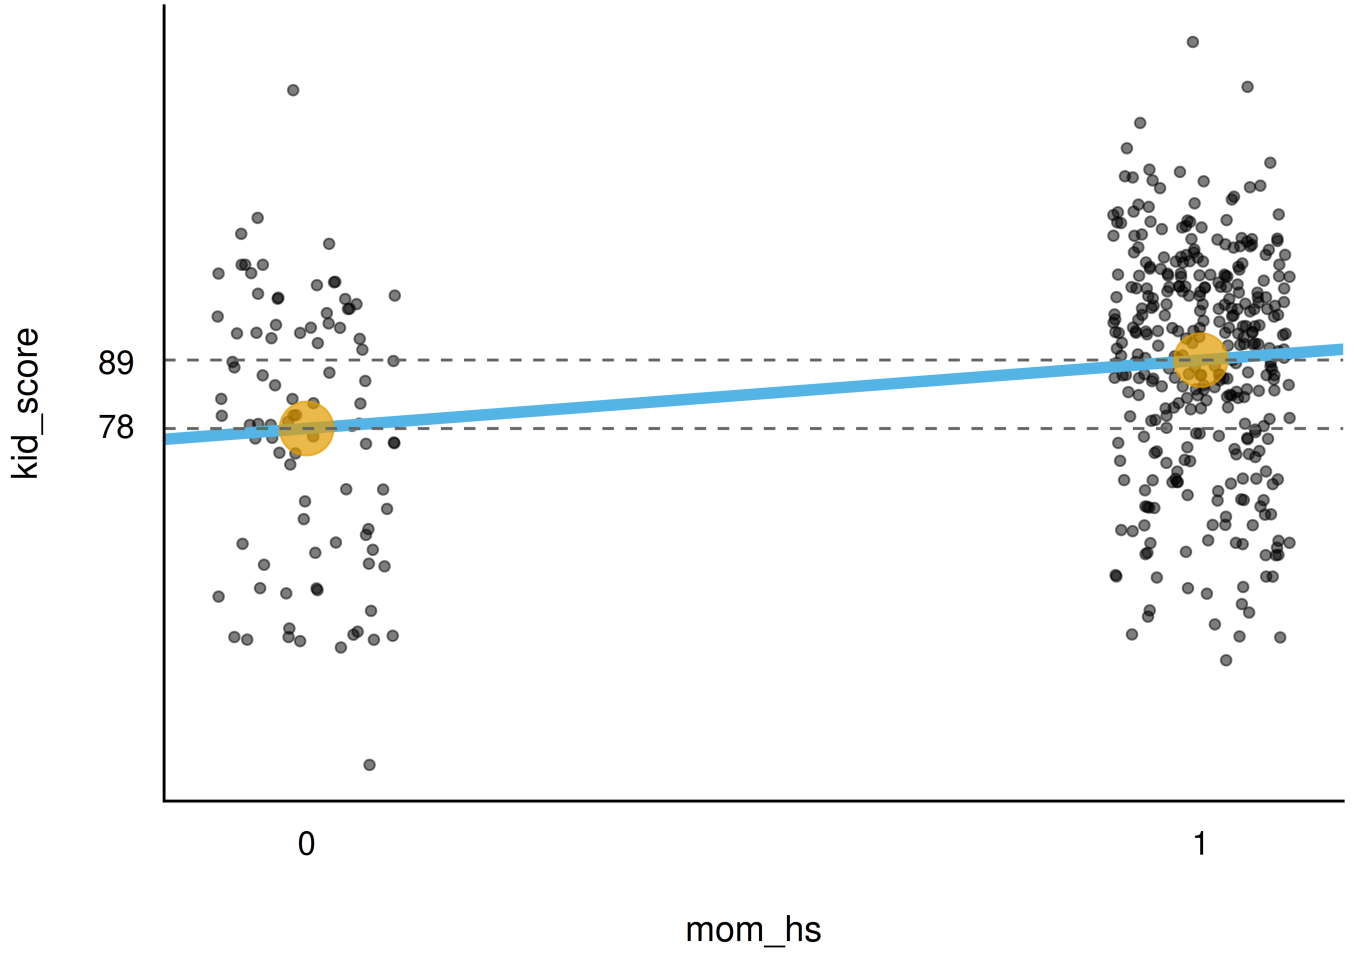
- *Achsenabschnitt* ($\beta_0 = 78$): geschätzter IQ bei `mom_hs = 0`
- *Regressionsgewicht* ($\beta_1 = 12$): Unterschied im IQ zwischen den Gruppen
- `error`: Vorhersagefehler ($y - \hat{y}$)

Gruppenmittelwerte unterscheiden sich um ca. 12 Punkte (89.4 vs. 77.6).





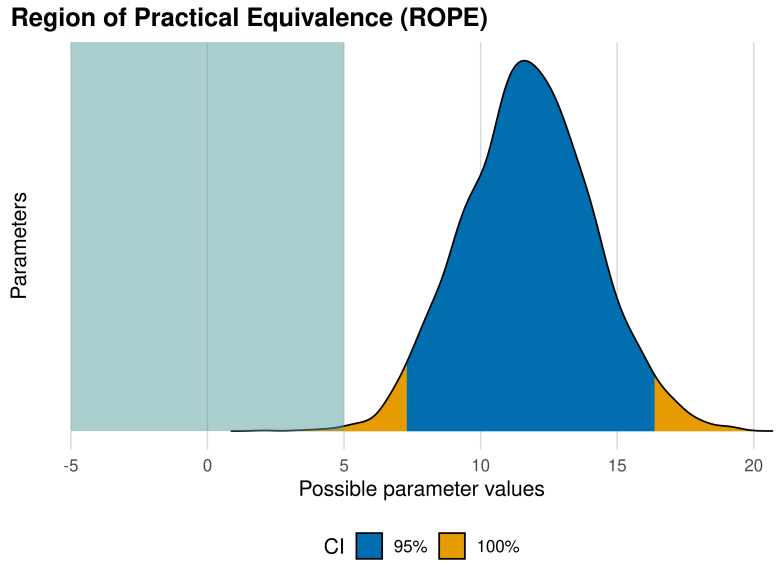
# Visualisierung



# ROPE-Verfahren

Prüfung mit `rope(m10.1, range = c(-5, 5))`: 0 % Überlappung von ROPE und 95 %-HDI.

**Fazit:** Praktisch-Null-Hypothese wird verworfen.



# 95 %-PI und Fazit

Mit 95 % Wahrscheinlichkeit liegt der Unterschied im mittleren IQ zwischen 7 und 16 Punkten: $95\%PI : [7, 16]$.

**Wichtig**

Korrelation ungleich Kausation. Ein Kausaleffekt braucht mehr Fundierung als eine einfache Assoziation — etwa Theorie oder bestehende Studien.

Alternative (frequentistisch): der *t*-Test — führt zu ähnlichem Ergebnis wie `y ~ b`.

# Fallbeispiel 2: y ~ x + b

Metrische und binäre UV gemeinsam

# Forschungsfrage

> Wie stark ist der statistische Effekt von Schulabschluss der Mutter (`mom_hs`) und IQ der Mutter (`mom_iq`) auf den IQ des Kindes?

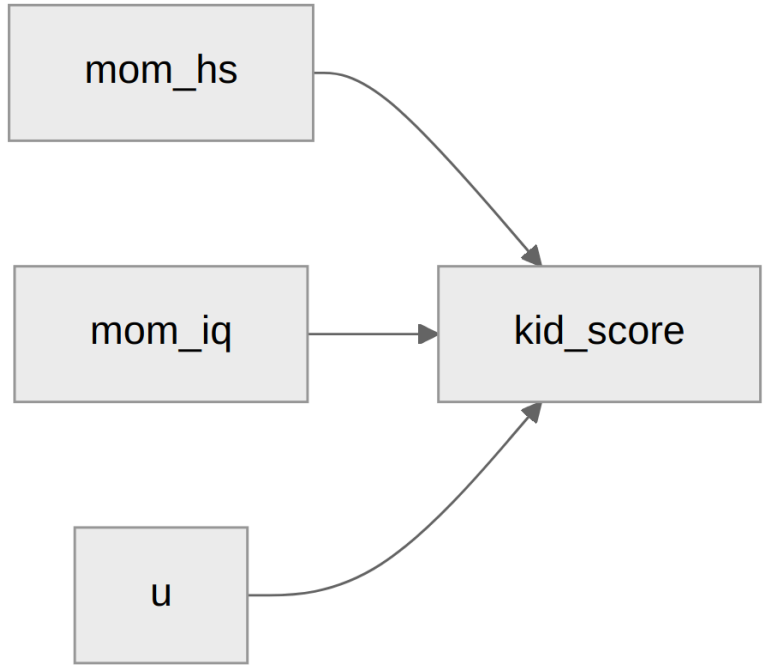
Modellformel: `kid_score ~ mom_iq + mom_hs`

Hypothesen: $\beta_{momhs} > 0$ und $\beta_{momiq} > 0$





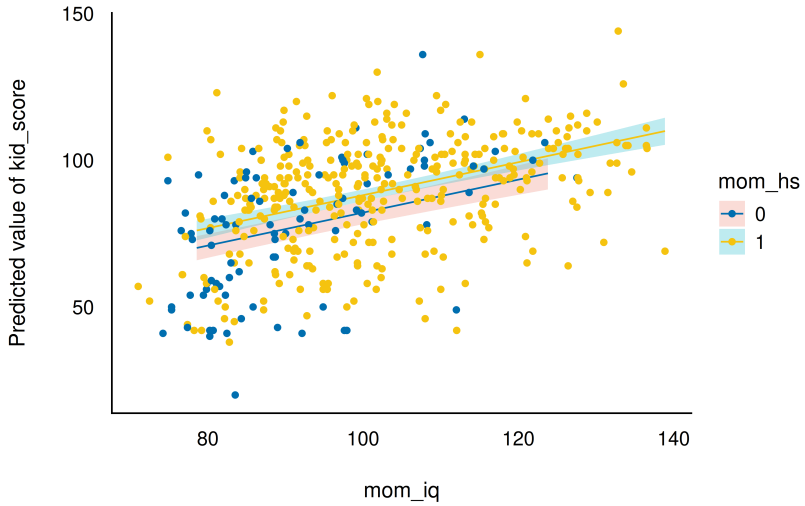
# Kausalgraph



# Modell m10.3

```
stan_glm(kid_score ~ mom_iq + mom_hs, data = kidiq)
```

```
kid_score = 26 + 0.6*mom_iq + 6*mom_hs + error
```



# Interpretation m10.3

- *Achsenabschnitt*: IQ-Schätzung für IQ-Mutter = 0, ohne Abschluss (26 — nicht sinnvoll interpretierbar)
- `mom_hs`: Unterschied von 6 Punkten bei gleichem mütterlichem IQ
- `mom_iq`: 0.6 Punkte Unterschied pro IQ-Punkt der Mutter, bei gleichem Schulabschluss

95 %-ETI schließt für beide UV die Null aus — Nulleffekt wird abgelehnt.





# Fallbeispiel 3: Interaktion

```
y ~ x + b + x:b
```

# Forschungsfrage

> Gibt es einen Interaktionseffekt zwischen mütterlichem Schulabschluss und mütterlichem IQ?

**Wichtig**

Liegt eine Interaktion vor, unterscheidet sich die Steigung der Geraden zwischen den Gruppen. Liegt keine Interaktion vor, sind die Geraden parallel.

Modell `m10.4`: `kid_score ~ mom_iq + mom_hs + mom_hs:mom_iq`





# Modellgleichung

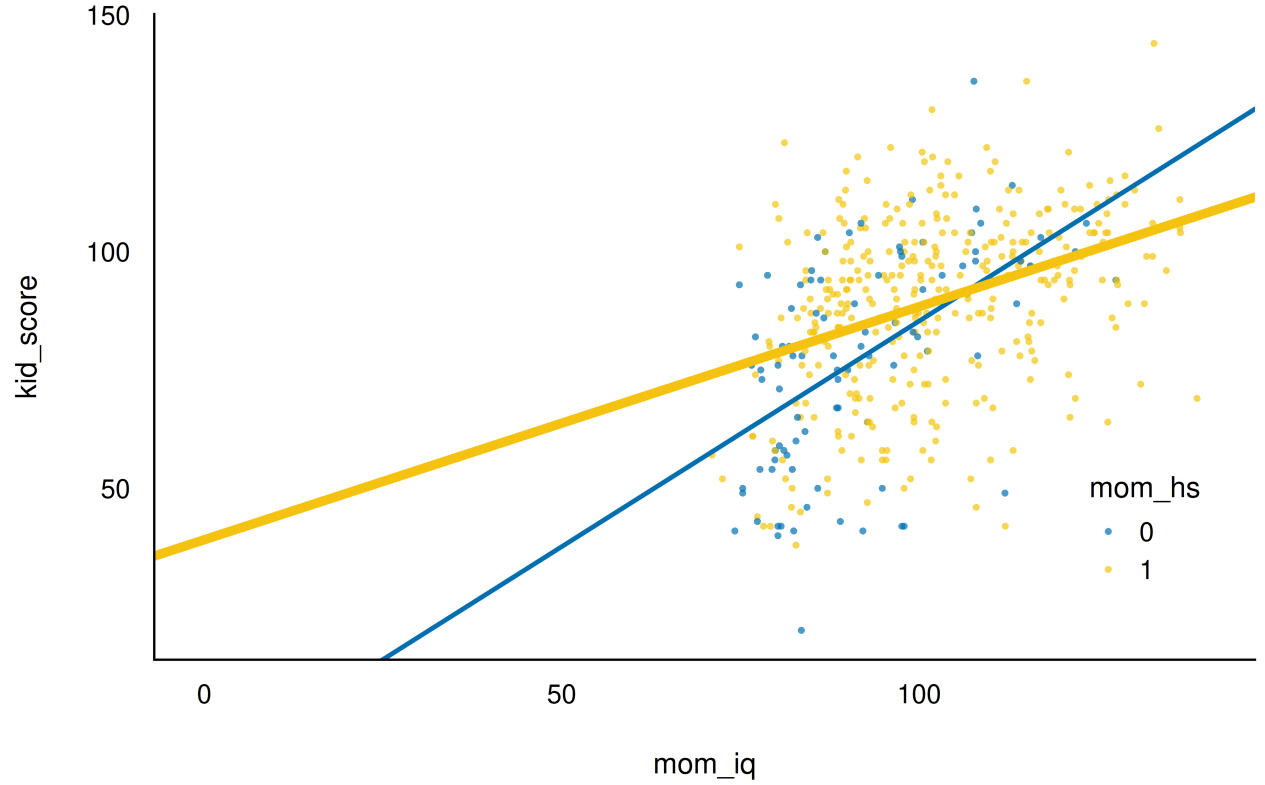
$$\text{kid score} = \beta_0 + \beta_1 \cdot \text{mom hs} + \beta_2 \cdot \text{mom iq} + \beta_3 \cdot \text{mom hs} \cdot \text{mom iq}$$

$\beta_3$ = Stärke des Interaktionseffekts (Unterschied der Steigungen).





# Visualisierung m10.4




Alle drei Effekte (IQ, Schulabschluss, Interaktion) schließen die Null aus.

# Fallbeispiel 4: Zentrierung

```
y ~ x_c + b + x_c:b
```

# Zentrieren

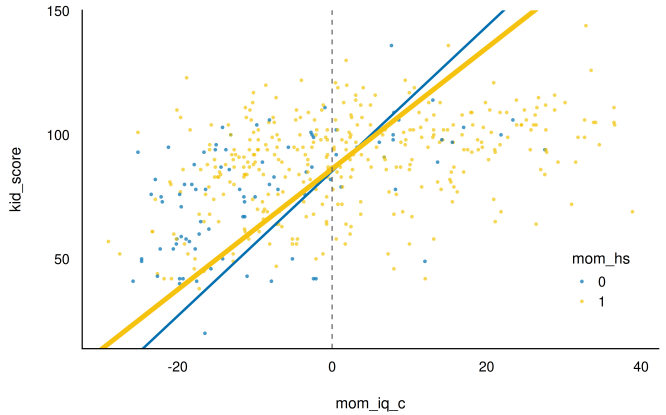
**Definition: Zentrieren**

Zentrieren (*centering*) bedeutet, die Differenz eines Messwerts zu seinem Mittelwert zu bilden: `mom_iq_c = mom_iq - mean(mom_iq)`. Zentrierte Werte machen den Achsenabschnitt einfacher interpretierbar.

Modell `m10.5`: `kid_score ~ mom_hs + mom_iq_c + mom_hs:mom_iq_c`

# Interpretation m10.5

- *Achsenabschnitt*: mittlerer IQ des Kindes bei Mutter *mittlerer* Intelligenz, *ohne* Abschluss
- `mom_hs`: Unterschied bei Müttern *mittlerer* Intelligenz, mit/ohne Abschluss
- `mom_iq_c`: Unterschied pro IQ-Punkt der Mutter, *ohne* Abschluss
- Interaktion: Unterschied im Koeffizienten von `mom_iq_c` zwischen den Gruppen



# Wichtig: Zentrieren ändert nichts an…

- den Vorhersagen des Modells
- der Streuung der Vorhersagen ($\sigma$)
- den Regressionskoeffizienten selbst

Es ändert nur die **Interpretierbarkeit** des Achsenabschnitts.

> **Wichtig**
>
> Kausalaussagen (z. B. im DAG postuliert) benötigen eine explizite Begründung aus der Literatur — sonst nicht haltbar.





# Fallbeispiel 5: y ~ g

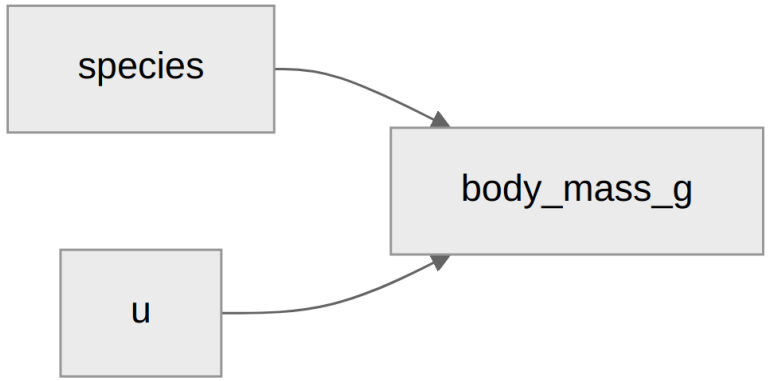
Nominale UV mit mehreren Stufen — Pinguine



# Forschungsfrage

> Unterscheiden sich die mittleren Körpergewichte der drei Pinguinarten (Adelie, Chinstrap, Gentoo)?

Modellformel: `body_mass_g ~ species`



# Von der Nullhypothese zur besseren Frage

$H_0 : \mu_1 = \mu_2 = \ldots = \mu_k$ — dass *alle* Mittelwerte exakt gleich sind, ist unplausibel.

Bessere Frage:

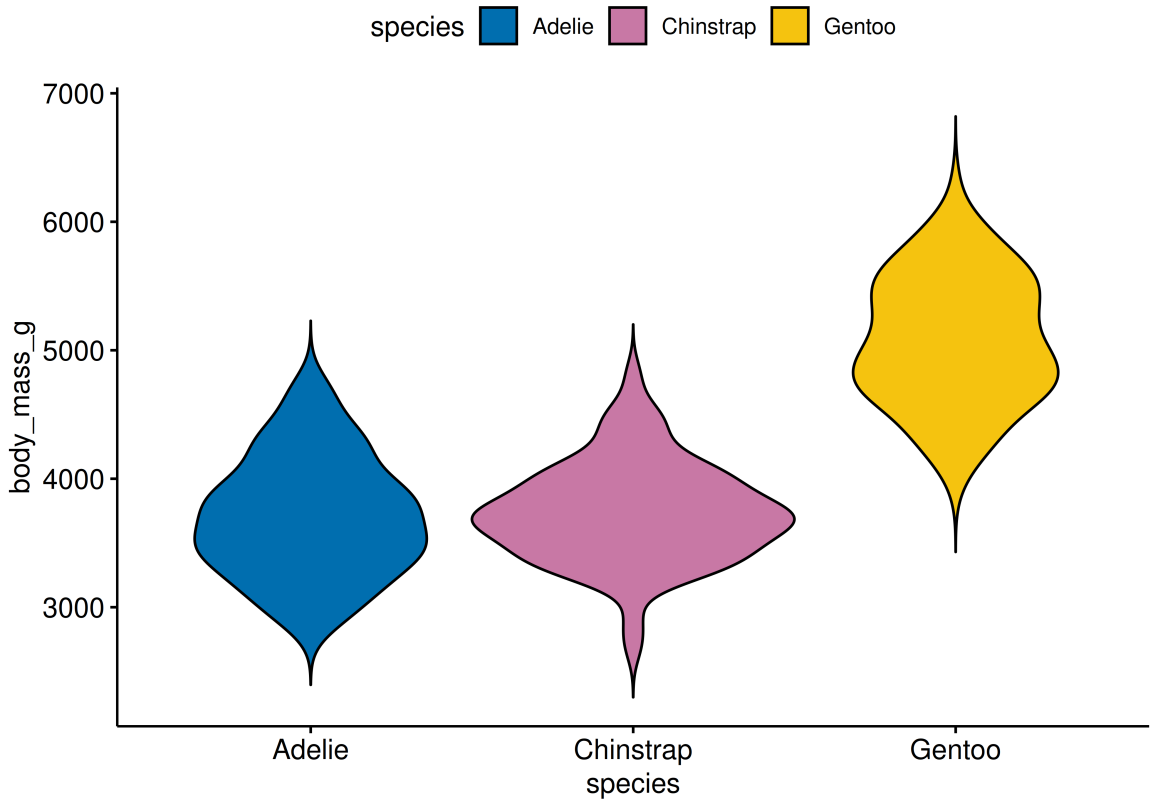
> *Wie sehr* unterscheiden sich die mittleren Körpergewichte zwischen den Pinguinarten?

(Frequentistisches Pendant: *Varianzanalyse*/ANOVA.
Bayesianisch: Post-Verteilung.)





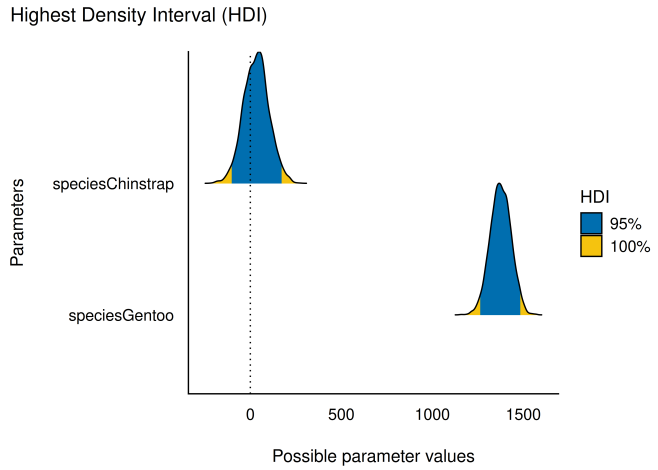
# Verteilung des Gewichts



# Modell m10.6

```
stan_glm(body_mass_g ~ species, data = penguins)
```

- Referenzkategorie (`Adelie`, im Achsenabschnitt): mittleres Gewicht ca. 3700 g
- Koeffizienten für `Chinstrap`/`Gentoo`: Unterschied zur Referenzgruppe



# Interpretation

- `Gentoo`: deutlich schwerer als `Adelie` (Intervall überlappt Null nicht)
- `Chinstrap`: ähnlich zu `Adelie` (Intervall überlappt deutlich mit Null)

**Fazit:** nicht alle Gruppen unterscheiden sich gleichermaßen — die exakte Nullhypothese wird dennoch verworfen.





# Vertiefung: Wechsel der Referenzkategorie

# Vertiefung: Referenzkategorie wechseln

- `species` sollte als `factor` kodiert werden
- Standard: alphabetische Sortierung der Stufen
- `fct_relevel(species, "Gentoo")` setzt neue Referenzkategorie

Der Wechsel der Referenzkategorie ändert **nichts Wesentliches** am Modell — nur welche Vergleiche direkt ablesbar sind.





# Fallbeispiel 6: `y ~ x1 + x2`

Zwei metrische UV

# Forschungsfrage

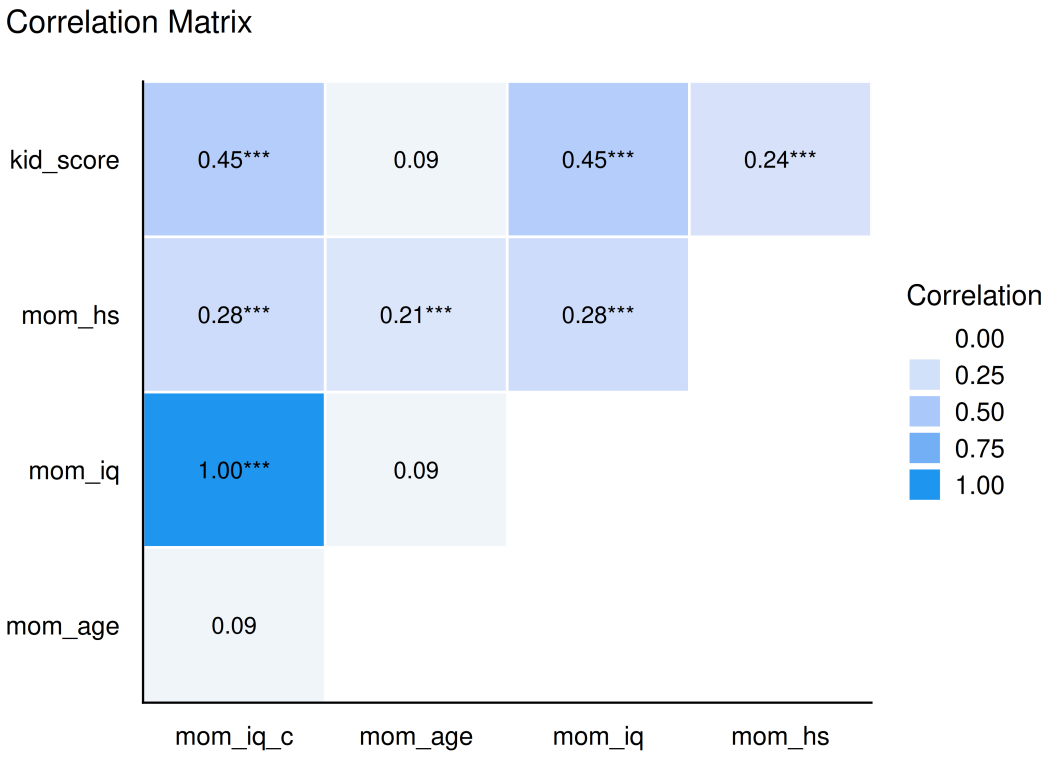
> Stehen sowohl der IQ der Mutter als auch, unabhängig davon, das Alter der Mutter im Zusammenhang mit dem IQ des Kindes?

**Deskriptive** Forschungsfrage — keine Kausalwirkung impliziert.

**Wichtig**

“Effekt” klingt nach Kausalzusammenhang. Eine Regression allein ist keine hinreichende Begründung für Kausalität.

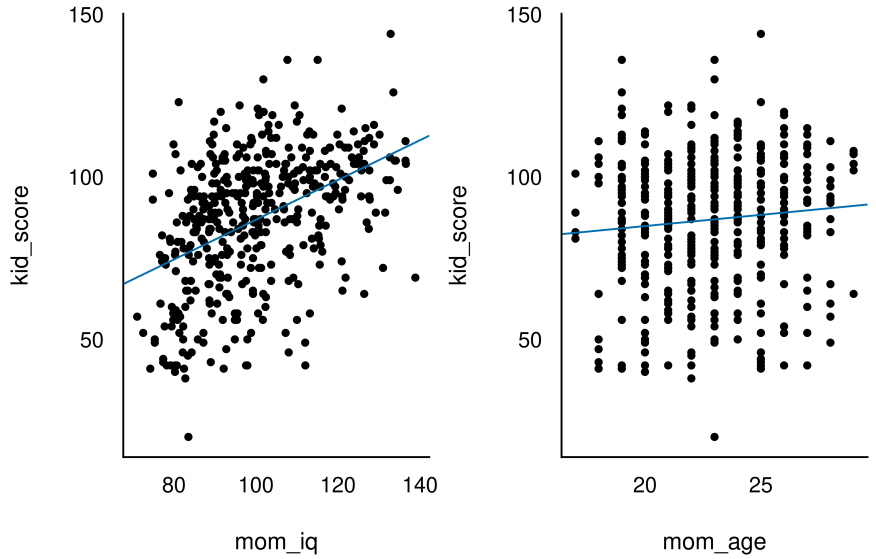
# Zusammenhänge explorieren



# Univariate vs. multiple Regression

Univariate Modelle: `kid_score ~ mom_iq` (m10.7), `kid_score ~ mom_age` (m10.8)

m10.7: Die univariate Regression mit dem Alter der Mutter als Prädiktor

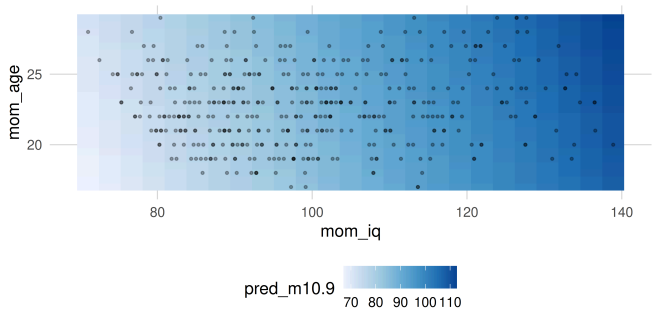


# Multiples Modell m10.9

`stan_glm(kid_score ~ mom_iq + mom_age, data = kidiq)`

**Wichtig**

Regressionsgewichte im multiplen Modell unterscheiden sich (potenziell) von den univariaten Modellen — sie sind “bereinigt” um den jeweils anderen Prädiktor.




`mom_iq` erklärt sichtbar mehr Variation als `mom_age`.

# Fallbeispiel 7: Standardisierung

`y ~ x1_z + x2_z` und `y_z ~ x1_z + x2_z`

# Warum standardisieren?

Welcher Prädiktor ist “wichtiger”? Das hängt auch von der **Skalierung** ab — `mom_iq` streut stärker als `mom_age`.

**Definition: z-Standardisierung**

$$z = \frac{x - \bar{x}}{sd(x)}$$

Ergebnis: Mittelwert 0, SD 1 — macht Effekte verschiedener Prädiktoren vergleichbar.

# Vorteile der z-Transformation

- Achsenabschnitt leichter interpretierbar (bezieht sich auf mittlere Ausprägung)
- Interaktionen leichter interpretierbar
- Prioris leichter zu definieren
- Effektgrößen verschiedener Prädiktoren vergleichbar
- numerisch stabiler für den Sampler

In R: `standardize()` aus `easystats` oder `scale()`.

```
y_z ~ x1_z + x2_z
```

# Modell m10.12 (AV und UV standardisiert)

```
stan_glm(kid_score_z ~ mom_iq_z + mom_age_z, data = kidiq_z)
```

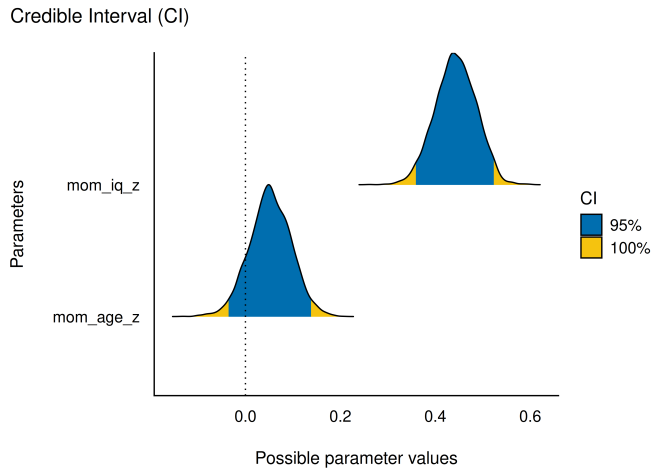
- Achsenabschnitt = Mittelwert der AV (da `kid_score_z = 0` = Mittelwert)
- Koeffizienten: Änderung der AV in SD-Einheiten pro SD-Einheit Änderung der UV

95 %PI `mom_iq_z`: [0.38, 0.51] — `mom_age_z`: [-0.02, 0.12]





# Ergebnisdarstellung




**Fazit:** Intelligenz der Mutter ist statistisch relevant, Alter der Mutter eher nicht. $R^2 \approx 0.2$.

**Wichtig**

“Statistischer Effekt” statt “Effekt” betonen — kausale Sprache nur mit Begründung (Theorie/Literatur/Experiment).

# Vertiefung



# Vertiefung: Regression = Korrelation bei z-Werten

**Theorem: Beta-r-Zusammenhang**

$$b = r\frac{sd_y}{sd_x}$$

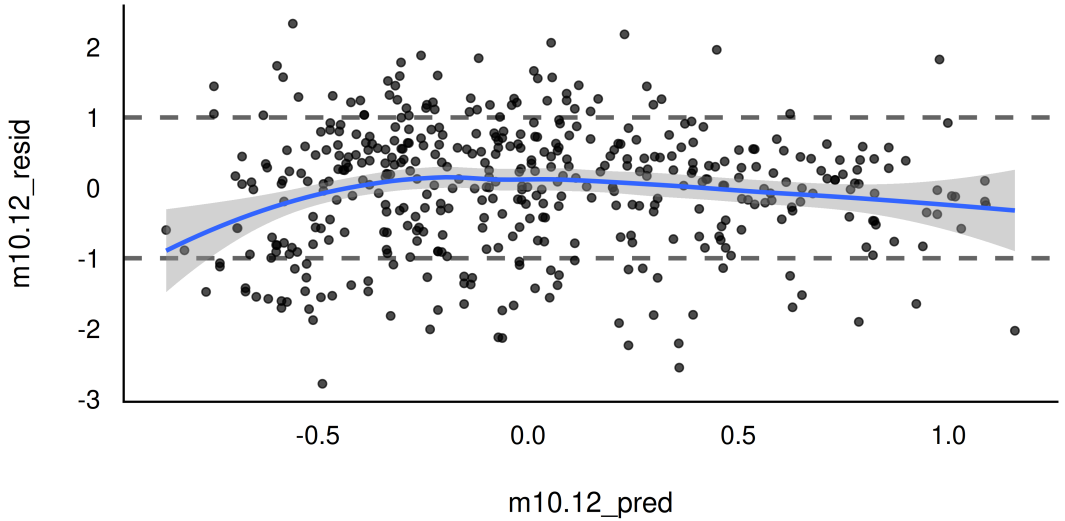
Sind X und Y z-standardisiert, sind Regressionskoeffizient und Korrelation identisch.

# Residualanalyse

Zentrale Annahme: AV ist *lineare* Funktion der Prädiktoren,

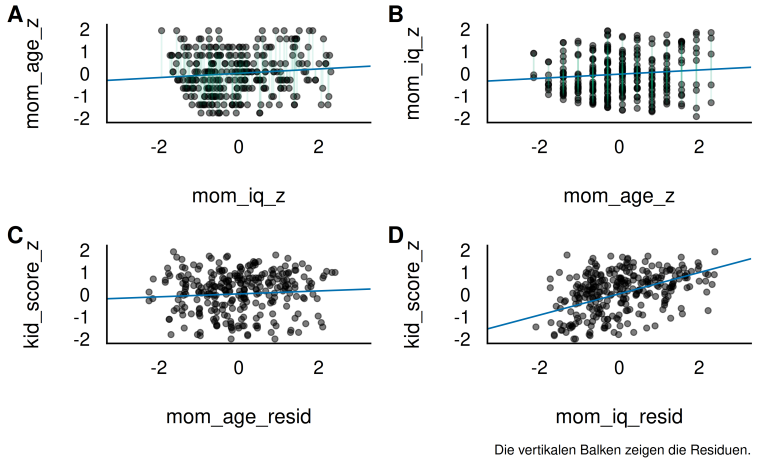
$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots$$

Residuum: $e_i = y_i - \hat{y}_i$



# Bereinigte Koeffizienten

Multiple Regressionskoeffizienten = Regression der **Residuen** eines Prädiktors (nach Herausrechnen des anderen) auf die AV.




`mom_iq`-Residuen sind stark mit der AV assoziiert, `mom_age`-Residuen kaum.

# Bayes vs. Frequentistisch

`stan_glm()` und `lm()` liefern bei schwach informativen Priors ähnliche Punktschätzer.

**Wichtig**

Numerisch ähnliche Ergebnisse, aber grundverschiedene Interpretation: Bayes-Modelle erlauben Wahrscheinlichkeitsaussagen zu Parametern, frequentistische nicht.





# Fazit



# Zusammenfassung und Ausblick

- Viele Forschungsfragen lassen sich einheitlich als Regression mit metrischer AV behandeln
- Bausteine: binäre/nominale/metrische UV, Interaktionen, Zentrierung, Standardisierung
- Bayesianische Auswertung: Post-Verteilung, PI/HDI, ROPE statt (nur) Signifikanztests
- Korrelation/Regression $\neq$ Kausation — kausale Aussagen brauchen Begründung

**Ausblick:** Regression mit binärer AV (nächstes Kapitel).

Gelman, A., Hill, J., & Vehtari, A. (2021). *Regression and Other Stories*. Cambridge University Press.

McElreath, R. (2020). *Statistical Rethinking: A Bayesian Course with Examples in R and Stan* (2. Aufl.). Taylor and Francis, CRC Press.



