Start:Bayes!

Konfundierung

Sebastian Sauer



Datensatz



Konfundierung

- Einstieg in die *Kausalanalyse* (Kausalinferenz)
- Zentrale Frage: Was ist die Ursache eines Phänomens?
- Heute: ein häufiger Fall von **Scheinkorrelation** — die *Konfundierung*

Lernziele

Sie können …

- erklären, was eine Konfundierung ist
- DAGs lesen und zeichnen
- Konfundierung in einem DAG erkennen

Einstieg

Von Störchen und Babies

- Klassisches Beispiel: `Anzahl_Stoerche` und `Anzahl_Babies` sind korreliert
- Moral der Geschichte: Nur weil zwei Variablen korrelieren, heißt das nicht, dass die eine die Ursache der anderen ist

Und: Ein Regressionsgewicht ungleich Null in einer Regressionsanalyse bedeutet **nicht automatisch**, dass die UV Ursache der AV ist.



Statistik, was soll ich tun?

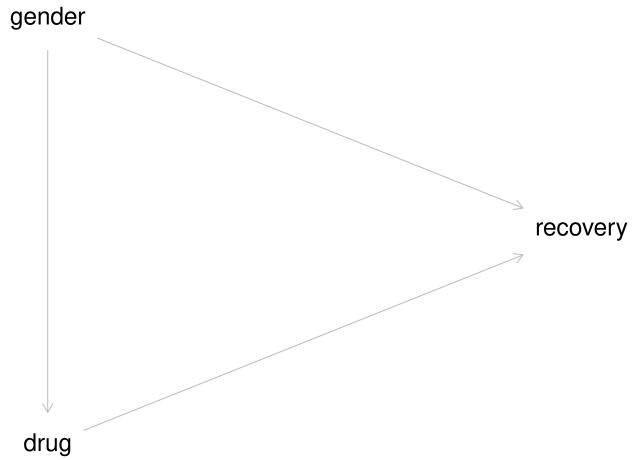


Studie A: Östrogen — Was raten Sie dem Arzt?

Gruppe	Mit Medikament	Ohne Medikament
Männer	81/87 (93 %)	234/270 (87 %)
Frauen	192/263 (73 %)	55/80 (69 %)
Gesamt	273/350 (78 %)	**289/350 (83 %)**

- Bei Männern *und* bei Frauen hilft das Medikament
- *Insgesamt* aber scheinbar nicht — Widerspruch?

Kausalmodell zur Studie A



- Geschlecht beeinflusst Medikamenteneinnahme *und* Heilung
- Effekt von Geschlecht und Medikament ist in den Gesamtdaten **vermengt** (konfundiert)

Wichtig

Hier zeigt die **Stratifizierung** (Betrachtung pro Gruppe) den wahren kausalen Effekt.

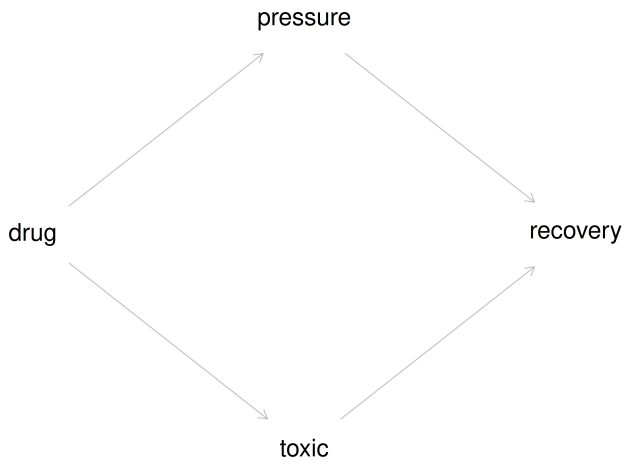
Studie B: Blutdruck — Was raten Sie dem Arzt?

Gruppe	Ohne Medikament	Mit Medikament
geringer Blutdruck	81/87 (93 %)	234/270 (87 %)
hoher Blutdruck	192/263 (73 %)	55/80 (69 %)
Gesamt	273/350 (78 %)	**289/350 (83 %)**

- Innerhalb jeder Blutdruckgruppe scheint das Medikament zu *schaden*
- *Insgesamt* scheint es zu *nutzen* — gleiche Zahlen wie Studie A, andere Geschichte!



Kausalmodell zur Studie B



- Medikament senkt Blutdruck (gut) **und** wirkt toxisch (schlecht)
- Blutdrucksenkung wirkt sich positiv auf Heilung aus

Wichtig

Hier zeigen die **Gesamtdaten** den wahren Effekt. Stratifizieren wäre hier *falsch* — man sähe nur den toxischen Teileffekt.

Gleiche Daten, unterschiedliches Kausalmodell

- Studie A und Studie B haben **identische** Zahlen
- Aber: **unterschiedliche Kausalmodelle** → unterschiedliche richtige Antworten
- Kausale Interpretation ist nur möglich, wenn das Kausalmodell bekannt ist
- Die Daten allein reichen **nicht**



Sorry, Statistik: Du allein schaffst es nicht

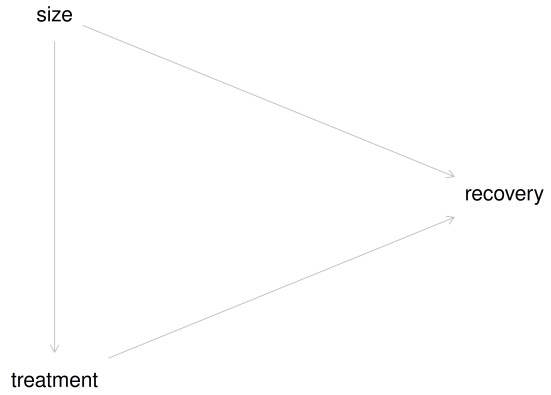
Wichtig

Für Entscheidungen (“Was soll ich tun?”) braucht man kausales Wissen. Kausales Wissen basiert auf einer **Theorie (Kausalmodell) plus Daten**.

- Datenanalyse allein reicht *nicht* für Kausalschlüsse
- Datenanalyse + Kausalinferenz erlaubt Kausalschlüsse

Vertiefung: Studie C — Nierensteine

- Ärzte wählen Behandlung A bei großen Steinen, Behandlung B bei kleinen
- Größe beeinflusst Behandlung **und** Heilung
- Kette: Größe → Behandlung → Heilung, plus direkter Effekt Größe → Heilung



Nierensteine: sollte man `size` kontrollieren?

- Ziel: Kausaleffekt von `treatment` schätzen
- **Ja** — `size` sollte kontrolliert werden
- Ohne Kontrolle: vermengter Effekt von `size` und `treatment`, keine belastbare Aussage über die Behandlung



Weitere Scheinkorrelationen

- “Einkommen und Heiraten korrelieren hoch — also erhöht Heiraten dein Einkommen.” Wirklich?
- “Wer sich beeilt, kommt zu spät zur Besprechung — also lieber nicht beeilen.” Wirklich?
- Beide Schlüsse sind voreilig: mögliche Drittvariablen im Spiel



Zwischenfazit

- **Beobachtungsstudien:** Aus den Daten allein ist nicht erkennbar, ob ein kausaler Effekt vorliegt — nur Kenntnis des Kausalmodells + Daten erlaubt eine Entscheidung
- **Experimentelle Daten:** Kausalmodell ist (bei gutem Design) nicht nötig — Randomisierung und Kontrolle verhindern Konfundierung



Konfundierung



Die Geschichte von Angie und Don

- 🧑 **Don**: Immobilienmogul, Auftraggeber
- 👩 **Angie**: Data Scientistin
- Datensatz: `SaratogaHouses` — Hauspreise im Saratoga County, USA
- Don will wissen: Was ist meine Immobilie wert?



Modell 1: Preis als Funktion der Zimmerzahl



- `m1: price ~ bedrooms`
- Jedes Zimmer mehr ist ca. 50.000 $ wert (laut `m1`)

Dons Idee: mehr Zimmer durch Wände einziehen

- Don verdoppelt die Zimmerzahl durch das Einziehen von Mauern
- Erwartung: doppelter Verkaufspreis
- **Aber:** Vorhersage laut `m1` mit 4 statt 2 Zimmern → Preis steigt trotzdem (von `m1` isoliert betrachtet)
- Das Problem: `m1` berücksichtigt nicht die Wohnfläche — künstlich mehr, aber kleinere Zimmer ändern real nichts am Wert



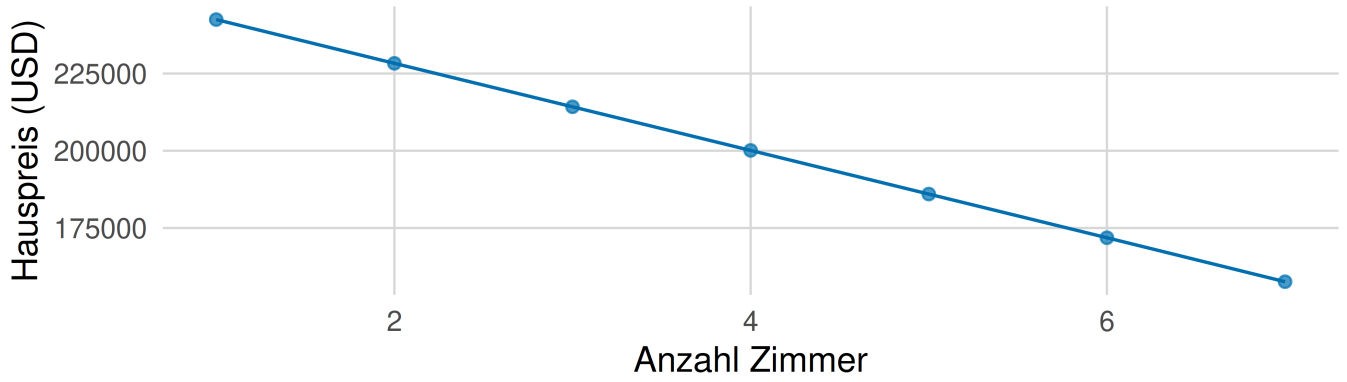
Punktschätzer vs. Schätzintervalle

- `predict()` / `point_estimate()`: nur ein **Punktschätzer**, kein Intervall
- `estimate_prediction()`: **Vorhersageintervall** — zwei Quellen der Ungewissheit (Parameter + Strukturmodell)
- `estimate_expectation()`: **Konfidenzintervall** — nur eine Quelle (Parameter)



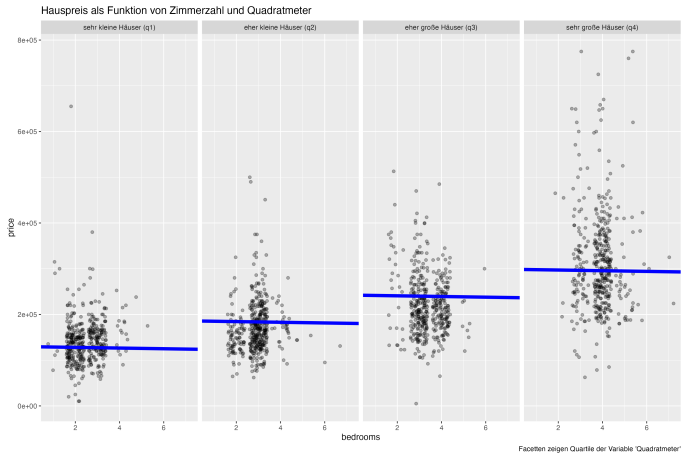
Modell 2: Zimmerzahl und Wohnfläche

- `m2: price ~ bedrooms + livingArea`
- Kontrolliert man `livingArea` mit, dreht sich das Bild



Die Zimmerzahl ist negativ mit dem Preis korreliert

… wenn man die Wohnfläche kontrolliert:



Hinweis

Eine Aussage kann nur dann richtig sein, wenn ihre Annahmen richtig sind. “Mehr Zimmer = mehr Wert” ist kein Naturgesetz, sondern hängt vom zugrundeliegenden Modell ab.

Kontrollieren von Variablen

- Prädiktoren in der multiplen Regression werden **kontrolliert** (adjustiert, konditioniert)
- Koeffizienten zeigen den Effekt eines Prädiktors, wenn die anderen *konstant gehalten* werden
- Man spricht auch von *parziellen Regressionskoeffizienten* oder dem “Netto-Effekt”

Wichtig

Das Hinzufügen von Prädiktoren kann die Gewichte der übrigen Prädiktoren ändern.

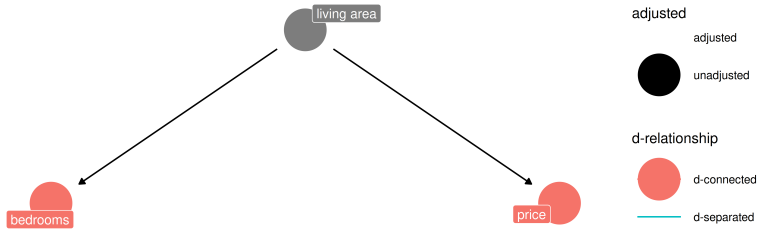
Welches Modell ist richtig?

Wichtig

In Beobachtungsstudien hilft nur ein **korrektes Kausalmodell**. Ohne Kausalmodell ist es nutzlos, Regressionskoeffizienten zur Erklärung von Ursachen heranzuziehen — die Koeffizienten können sich wild ändern, sogar das **Vorzeichen** (Simpson-Paradox).

> "… any observed correlation between an outcome and predictor could be eliminated or reversed once another predictor is added to the model." — McElreath (2020)

Kausalmodell `km1`



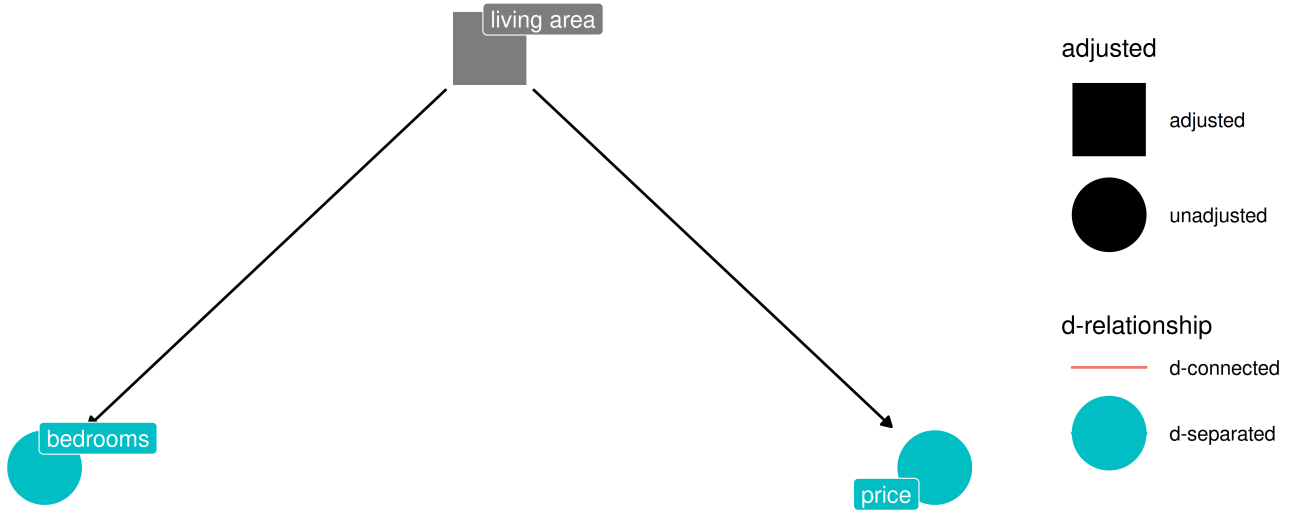
- Erklärung für `m1`/`m2`: `livingArea` beeinflusst sowohl `bedrooms` als auch `price`
- Wenn `km1` stimmt: **Scheinkorrelation** zwischen `bedrooms` und `price`
- d-connected: Variablen sind über einen gerichteten Pfad “verbunden”

Definition: Konfundierungsvariable

Definition: Konfundierungsvariable

Eine Konfundierungsvariable (Konfundierer) ist eine Variable, die den Zusammenhang zwischen UV und AV verzerrt, wenn sie nicht kontrolliert wird (VanderWeele & Shpitser, 2013).

`m2` kontrolliert den Konfundierer `livingArea`



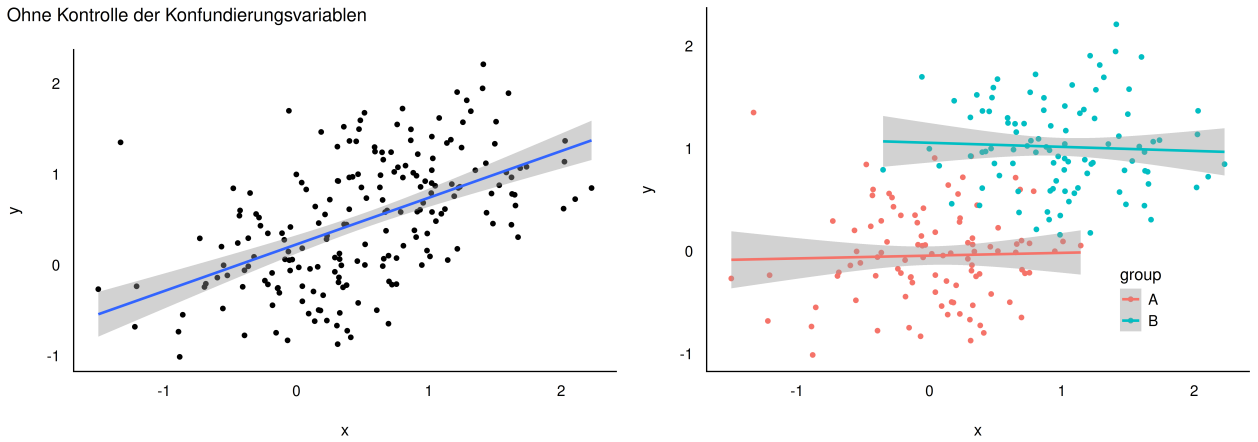
- Kontrolliert man `livingArea`, werden `bedrooms` und `price` **unkorreliert** (d-separated)

Definition: Blockieren

Definition: Blockieren

Das Kontrollieren eines Konfundierers “blockt” den betreffenden Pfad — es besteht dann über diesen Pfad keine Assoziation mehr zwischen UV und AV. UV und AV sind dann d-separated (“getrennt”).

Konfundierer kontrollieren — mit vs. ohne



- Links: **ohne** Kontrolle der Konfundierungsvariable → Scheinkorrelation
- Rechts: **mit** Kontrolle → keine Korrelation mehr

Wichtig

Kontrollieren Sie Konfundierer.

`m1`/`m2` passen nicht zu `km1`

- Laut `km1` dürfte es **keine** Assoziation zwischen `bedrooms` und `price` geben, wenn `livingArea` kontrolliert wird
- In den Daten gibt es aber noch eine Assoziation
- Also: `m1` und `m2` sind **nicht** mit `km1` vereinbar

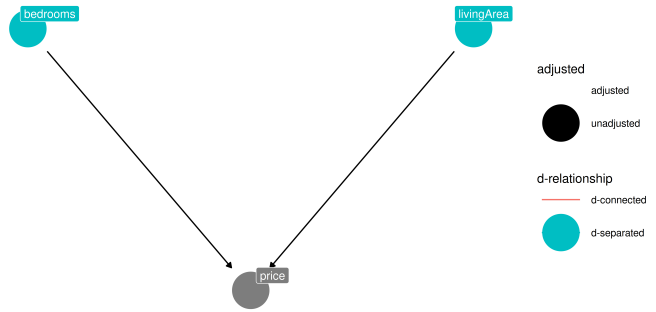


Kausalmodell `km2`: Mediation



- Wirkkette: `area` ⟶ `bedrooms` ⟶ `price`, plus direkter Effekt `area` ⟶ `price`
- Mittlere Variable = **Mediator**, der Pfad = **Mediation**

Dons Kausalmodell `km3`



- Don behauptet: `bedrooms` und `livingArea` sind unkorreliert
- Realität: Sie sind korreliert (Angie rechnet es nach)
- `km3` widerspricht also den Daten

Unabhängigkeiten laut den Kausalmodellen

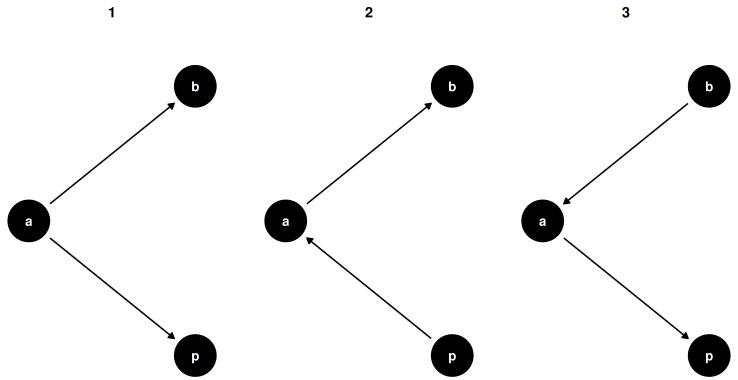
- `km1`: $b \backslash \text{indep} p \mid a$ (bedrooms unabhängig von price, gegeben area) — passt **nicht** zu den Daten
- `km2`: keine Unabhängigkeiten postuliert — passt formal zu den Daten, ist aber ein *saturiertes* (empirisch schwaches) Modell
- `km3`: $b \backslash \text{indep} a$ — passt **nicht** zu den Daten

> **Hinweis**
>
> Ein saturiertes Modell (alle Variablen korreliert) ist kaum falsifizierbar und daher wissenschaftlich wenig aussagekräftig.

DAGs: Directed Acyclic Graphs



Mehrere DAGs passen oft zu einer Datenlage



- Mehrere Kausalmodelle können die gleichen (Un-)Abhängigkeiten implizieren
- Empirisch nicht unterscheidbar — man bräuchte mehr/andere Variablen

Definition: DAG

Definition: DAG

DAGs sind eine Art von Graphen zur Analyse von Kausalstrukturen. Ein Graph besteht aus Knoten (Variablen) und Kanten (Linien). DAGs sind **gerichtet** (Pfeile von Ursache zu Wirkung) und **azyklisch** (keine Rückführung auf sich selbst).

Definition: Pfad

Ein Pfad ist ein Weg durch den DAG, von Knoten zu Knoten über die Kanten, unabhängig von der Pfeilrichtung.

Was ist eine Ursache?

Hinweis

Weiß man, was die Wirkung W einer Handlung H (Intervention) ist, so hat man H als Ursache von W erkannt (McElreath, 2020).

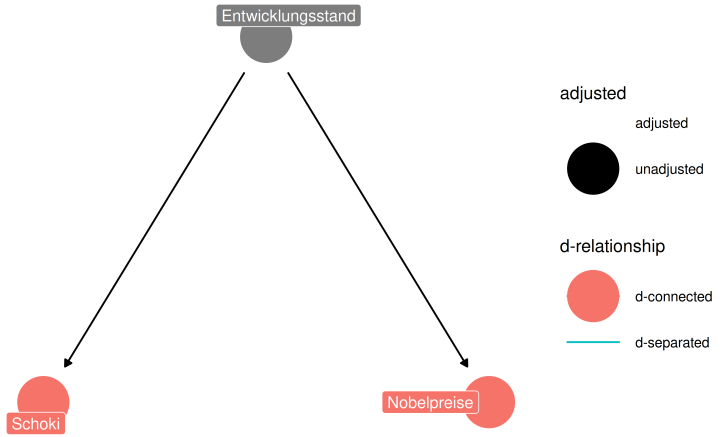
Definition: Kausale Abhängigkeit

Ist X die Ursache von Y, so hängt Y von X ab: Y ist (kausal) abhängig von X.

Viele Menschen denken fälschlich, dass Korrelation Kausation bedeuten muss.



Der Schoki-DAG



- Schokoladenkonsum und Nobelpreise korrelieren stark ($r = 0{,}79$)
- Möglicher Konfundierer: Entwicklungsstand eines Landes

Fazit



Zusammenfassung

- Zwei Variablen können korreliert sein durch:
  1. einen **kausalen** (“echten”) Zusammenhang
  2. einen **nichtkausalen** Zusammenhang (Scheinkorrelation)
- Konfundierung ist eine mögliche Ursache einer Scheinkorrelation
- Aufdecken: angenommenen Konfundierer kontrollieren (z. B. als Prädiktor in der Regression)
- Löst sich der Scheinzusammenhang dabei **nicht** auf, sondern dreht sich das Vorzeichen um: **Simpson-Paradox**



Fazit

Wichtig

Die Daten allein können nie sagen, welches Kausalmodell zutrifft. Fachwissen ist nötig, um DAGs auszuschließen.

- Korrelation $\neq$ Kausation
- Um Scheinkorrelation von echter Assoziation abzugrenzen: Kausalmodelle prüfen
- Konfundierung ist eines von vier “Atomen” der Kausalinferenz (neben Kollision, Mediation, Nachfahre)

Vielen Dank!

Fragen?

McElreath, R. (2020). *Statistical Rethinking: A Bayesian Course with Examples in R and Stan* (2. Aufl.). Taylor and Francis, CRC Press.

VanderWeele, T. J., & Shpitser, I. (2013). On the Definition of a Confounder. *Annals of statistics*, *41*(1), 196–220. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4276366/

