

START:BAYES!

Dieses Buch führt in die Grundlagen der Bayes-Statistik ein. Der Schwerpunkt liegt auf der Inferenz mit der Bayes-Methode. Es ist ein angewandtes Buch für Anfänger. Sie lernen, mit Hilfe der Programmiersprache R Bayes-Modelle zu erstellen und zu interpretieren.

START:BAYES!

Einführung in die Bayes-Statistik mit R

Sebastian Sauer

Start:Bayes!

Lizenz: CC-BY-NC-SA-4.0

Sebastian Sauer

2026

Für Laurenz und Martha

Vorwort

Willkommen bei Start:Bayes!

Dieses Buch führt in die Bayes-Statistik ein, mit Schwerpunkt auf Wahrscheinlichkeit, Inferenz und Kausalität. Es baut auf Statistik¹ auf: Wer die Grundlagen der Modellierung schon kennt, ist hier richtig. Sie lernen, statistische Unsicherheit zu beziffern – und zwar so, wie es die Bayes-Statistik erlaubt: einfach, direkt, nachvollziehbar (und ohne p -Werte).

Warum noch ein Statistikbuch, obwohl es schon viele gibt? Weil es (meines Wissens) in deutscher Sprache kein Buch gibt, das die Bayes-Statistik anwendungsnah, mit modernen Werkzeugen und mit Freude am Lernen vermittelt. Diese Lücke soll dieses Buch schließen.

Bayes-Statistik gilt vielen als schwierig, manchmal sogar als exotisch. Zu Unrecht, wie ich finde. Der Grundgedanke ist einfach: Wir starten mit einer Annahme, sammeln Daten und aktualisieren unsere Annahme entsprechend. Das ist näher am gesunden Menschenverstand als das Testen von Nullhypothesen. Die Mathematik dahinter kann anspruchsvoll sein, keine Frage. Aber die Idee ist es nicht. Dieses Buch setzt auf die Idee zuerst, die Formeln zweitrangig – und auf R als Werkzeug, um Wahrscheinlichkeit erfahrbar zu machen statt sie nur zu berechnen.

Der Aufbau folgt dieser Linie: Zuerst Wahrscheinlichkeit und Verteilungen, dann der Kern der Bayes-Statistik an einem einfachen Beispiel (der Globus-Versuch), danach lineare Modelle im Bayes-Gewand, zum Schluss Kausalität. Jedes Kapitel baut auf dem vorigen auf. Wie in Statistik1 gilt: Lieber am Anfang etwas grober erklären und dafür verstanden werden, als von Beginn an jede Nuance zu präzisieren. Wer die Grundidee einmal hat, findet sich in den Details leichter zurecht.

Dieses Buch ist ein Praxisbuch. Es will befähigen, Bayes-Modelle selbst zu rechnen und zu interpretieren, nicht in erster Linie mathematische Theorie vermitteln. Für alle, die tiefer einsteigen wollen, gibt es reichlich weiterführende Literatur; Hinweise dazu finden Sie im Buch.

¹<https://sebastiansauer.github.io/statistik1/>

Vorwort

Wenn Sie Fragen oder Feedback haben, bin ich für Ihre Hinweise dankbar. Stellen Sie sie gerne hier ein: <https://github.com/sebastiansauer/statistik1/issues>. Dieses Buches ist frei verfügbar und unter der CC-BY-NC-SA-4.0-Lizenz² publiziert.

Dieses Buch ist meinen Kindern Laurenz und Martha gewidmet. Und allen anderen Menschen, die noch viel lernen wollen. Die Fragen, Rückmeldungen und Anregungen meiner Studierenden sind der Grund für vieles, was ich gelernt habe; dafür bin ich dankbar. Dieses Buch spiegelt einen bestimmten Zwischenstand meiner eigenen Lernreise wider. Einiges habe ich schon lernen dürfen, aber so viel ist noch jenseits meines Verständnisses. Ich wünsche Ihnen, dass Ihnen dieses Buch hilft, um in Ihrer eigenen Lernreise mit Freude voranzukommen.

Ihr

Sebastian Sauer

²<https://creativecommons.org/licenses/by-nc-sa/4.0/>

Inhaltsverzeichnis

Vorwort	vii
1 Organisatorisches	1
1.1 Ihr Lernerfolg	1
1.2 Lernhilfen	4
1.3 Hinweise	4
I Grundlagen	5
2 Die drei Zielarten der Statistik	7
2.1 Lernsteuerung	7
2.2 Die drei Zielarten in der Statistik	8
2.3 Zielart <i>Beschreiben</i>	9
2.4 Zielart <i>Vorhersagen</i>	10
2.5 Zielart <i>Erklären</i>	11
2.6 Modellieren	17
3 Populationsinferenz	23
3.1 Lernsteuerung	23
3.2 Schließen von der Stichprobe auf die Grundgesamtheit	24
3.3 Was ist Populationsinferenz?	27
3.4 Frequentistische Inferenz vs. Bayes-Inferenz	34
3.5 Aufgaben	40
4 Hallo, Wahrscheinlichkeit	42
4.1 Lernsteuerung	42
4.2 Grundbegriffe	43
4.3 Was ist Wahrscheinlichkeit?	50
4.4 Relationen von Ereignissen	55
4.5 Zufallsvariable	62

Inhaltsverzeichnis

4.6	Aufgaben	73
5	Rechnen mit Wahrscheinlichkeit	75
5.1	Lernsteuerung	75
5.2	Additionssatz	75
5.3	Vereinigung von Ereignissen: Additionssatz	76
5.4	Bedingte Wahrscheinlichkeit	79
5.5	Stochastische (Un-)Abhängigkeit	83
5.6	Wahrscheinlichkeit gemeinsamer Ereignisse: Multiplikationssatz . . .	87
5.7	Totale Wahrscheinlichkeit	95
5.8	Vertiefung	98
5.9	Aufgaben	99
6	Verteilungen	101
6.1	Lernsteuerung	101
6.2	Wichtige Verteilungen	102
6.3	Gleichverteilung	103
6.4	Binomialverteilung	103
6.5	Die halbe Normalverteilung	117
6.6	Die Exponentialverteilung	118
6.7	Vertiefung	122
6.8	Aufgaben	122
II	Bayes	124
7	Der Globus-Versuch	126
7.1	Lernsteuerung	126
7.2	Von Welten und Golems	127
7.3	Ein erster Versuch: Wir werfen den Globus	130
7.4	Bayes' Theorem	139
7.5	Die Post berechnen mit der Bayesbox	143
7.6	Abschluss	150
7.7	Vertiefung	151
7.8	Aufgaben	154
8	Die Post befragen	156
8.1	Lernsteuerung	156
8.2	Zur Erinnerung: Bayesbox in R berechnen	157
8.3	Mit Stichproben die Post-Verteilung zusammenfassen	161

8.4	Die Post-Verteilung befragen	167
8.5	Visualisierung der Verteilungen	176
8.6	Fazit	180
8.7	Aufgaben	182
III	Lineare Modelle	184
9	Gauss-Modelle	186
9.1	Lernsteuerung	186
9.2	Einstieg	187
9.3	Wie groß sind die !Kung San?	188
9.4	Unser Gauss-Modell der !Kung	190
9.5	Hallo, Posteriori-Verteilung	199
9.6	Wie tickt <code>stan_glm()</code> ?	200
9.7	Modell <code>m_kung_neue_prioris</code> : Standard-Priori-Werte	207
9.8	Fazit	211
9.9	Aufgaben	212
10	Einfache lineare Modelle	213
10.1	Lernsteuerung	213
10.2	Einstieg	214
10.3	Den Datensatz verstehen	215
10.4	Modell <code>m_kung_gewicht_c</code> : zentrierter Prädiktor	221
10.5	Die Post-Verteilung befragen	226
10.6	Post-Verteilung bedingt auf einen Prädiktorwert	238
10.7	Fazit	243
10.8	Aufgaben	244
11	Schätzen vs. Testen	245
11.1	Lernsteuerung	245
11.2	Einstieg	246
11.3	Was ist Testen? Was ist Schätzen?	247
11.4	ROPE: Bereich von „praktisch Null“	252
11.5	Modellgüte	260
11.6	Fazit	262
11.7	Aufgaben	263
12	Fallbeispiele	264
12.1	Lernsteuerung	264

Inhaltsverzeichnis

12.2	Taxonomie von Forschungsfragen	266
12.3	$y \sim b$	266
12.4	Vertiefung: Toleranzbereich	274
12.5	$y \sim x + b$	276
12.6	$y \sim x + b + x:b$	283
12.7	$y \sim x_c + b + x_c:b$	286
12.8	$y \sim g$	290
12.9	Vertiefung: Wechsel der Referenzkategorie	298
12.10	$y \sim x_1 + x_2$	299
12.11	$y \sim x_{1_z} + x_{2_z}$	305
12.12	$y_z \sim x_{1_z} + x_{2_z}$	308
12.13	Vertiefung	313
12.14	Fazit	317
12.15	Aufgaben	320
IV	Kausalität	321
13	Konfundierung	323
13.1	Lernsteuerung	323
13.2	Datensatz	323
13.3	Einstieg	324
13.4	Statistik, was soll ich tun?	325
13.5	Konfundierung	331
13.6	DAGs: Directed Acyclic Graphs	346
13.7	Fazit	348
13.8	Aufgaben	350
14	Die Atome der Kausalität	351
14.1	Lernsteuerung	351
14.2	Kollision	352
14.3	Die Hintertür schließen	361
14.4	Die vier Atome der Kausalanalyse	364
14.5	Schließen Sie die Hintertür (wenn möglich)!	368
14.6	Fazit	371
14.7	Aufgaben	373
	Literaturverzeichnis	374

V	Anhang	377
15	Abschluss	379
15.1	Lernsteuerung	379
15.2	Lieblingsfehler	379
15.3	Kochrezepte	384
15.4	Kerngedanken Bayes	385
15.5	Beispiele für Prüfungsaufgaben	386
15.6	Aufgabensammlungen	390
16	Probeklausur	391
16.1	2025	391
16.2	2024	392
16.3	2023	393
16.4	2022	393
17	Definitionen	394
18	Theoreme	397

1 Organisatorisches

1.1 Ihr Lernerfolg

! Wichtig

Kontinuierliches Lernen¹ ist der Schlüssel zum Erfolg.

1.1.1 Lernziele

Nach diesem Kurs sollten Sie ...

- grundlegende Konzepte der Inferenzstatistik mit Bayes verstehen und mit R anwenden können
- gängige einschlägige Forschungsfragen in statistische Modelle übersetzen und mit R auswerten können
- kausale Forschungsfragen in statistische Modelle übersetzen und prüfen können
- die Güte und Grenze von statistischen Modellen einschätzen können

1.1.2 Was lerne ich hier und wozu ist das gut?

Kurz gesagt, warum soll ich das lernen?

Statistische Analysen sind die Grundlage für Entscheidungen: Nehmen wir zum Beispiel an, Sie haben 50 Frauen und Männer vor eine Einpark-Aufgabe gestellt (natürlich alles schön standardisiert und kontrolliert) – Die Aufgabe lautet: Wer am schnellsten ein Auto einparken kann. Das Ergebnis: Frauen können schneller einparken als Männer, im Durchschnitt. Das hätten wir also geklärt. Aber haben wir

¹<https://imgflip.com/i/77wn7m>

1 Organisatorisches

das ganz sicher geklärt? Mit welcher Sicherheit? Bekanntlich sind in dieser Welt nur Steuern und der Tod sicher; sonstige Aussagen leider nicht und damit unsere Einpark-Studie und sonstige statistische Analysen auch nicht. Ja, ich weiß, das ist jetzt ein harter Schlag für Sie... Aber die gute Nachricht ist: Wir können angeben, wie (un)sicher wir bei mit einer Aussage („Frauen parken schneller ein“) sind. Zum Beispiel könnten wir uns zu 99 % oder zu 51 % sicher sein – und *wie sicher* wir uns sind, macht schon einen Unterschied. Wenn Sie nächste Woche einen Fahrer für Ihren neuen Rolls Royce anheuern, müssen Sie ja wissen, ob es besser eine Frau oder ein Mann sein soll.

Kurz gesagt: In diesem Kurs lernen Sie, wie Sie die Unsicherheit eines statistischen Ergebnisses beziffern.

Warum ist das wichtig?

Da fast keine Aussage auf dieser Welt 100 % sicher ist, müssen wir wissen, wie sicher eine Aussage ist, wenn wir eine Entscheidung treffen wollen.

Wozu brauche ich das im Job?

Ihr Boss wird wissen wollen, wie sicher Sie sich sind, wenn Sie sagen „laut meiner Analyse sollten wir unser Werk in Ansbach/Peking/Timbuktu bauen“. Sind Sie sich zu 50 %, 90 % oder 99,9 % sicher, dass Ihre Aussage richtig ist? Wichtige Frage im echten Leben.

Wozu brauche ich das im weiteren Studium?

In Forschungsarbeiten (wie in empirischen Forschungsprojekten, etwa in der Abschlussarbeit) ist es üblich, statistische Ergebnisse hinsichtlich ihrer Unsicherheit zu beziffern.

Gibt es auch gute Jobs, wenn man sich mit Daten auskennt?

Das Forum (2020) berichtet zu den „Top 20 job roles in increasing and decreasing demand across industries“ (S. 30, Abb. 22):

1. Data Analysts und Scientists
2. AI and Machine Learning Specialists
3. Big Data Specialists

1.1.3 Modulüberblick

Abbildung 1.1 gibt einen Überblick zu den Inhalten des Kurses.




Abbildung 1.1: Modulverlauf im Überblick. Die einzelnen Schritte entsprechen in etwa den Kapiteln dieses Buchs.

1.1.4 Voraussetzungen

Für diesen Kurs wird folgendes Wissen vorausgesetzt:

- grundlegende Kenntnis im Umgang mit R, möglichst auch mit dem tidyverse
- grundlegende Kenntnis der deskriptiven Statistik
- grundlegende Kenntnis der Regressionsanalyse

Dieses Wissen wird z. B. im Online-Buch „Statistik1“² vermittelt. Alle Inhalte daraus werden in diesem Kurs benötigt. Die Kapitel dieses Buches bauen aufeinander auf; um einem späteren Kapitel folgen zu können, benötigen Sie den Stoff früherer Kapitel.

Sie benötigen R, eine GUI wie Positron oder RStudio und einige R-Pakete für diesen Kurs. Dieses Buch enthält „mittel“ viel R. Auf fortgeschrittene R-Techniken wurde aber komplett verzichtet. Dem einen Anfänger oder der anderen Anfängerin mag es

²<https://sebastiansauer.github.io/statistik1/>

1 Organisatorisches

dennoch als „viel Code“ erscheinen. Es wäre ja auch möglich gewesen, auf R zu verzichten und stattdessen eine „Klick-Software“ zu verwenden. JASP³ oder Jamovi⁴ sind Beispiele für tolle Software aus dieser Kategorie. Ich glaube aber, der Verzicht auf eine Skriptsprache (R) wäre ein schlechter Dienst an den Lernenden. Mit Blick auf eine „High-Tech-Zukunft“ sollte man zumindest mit etwas Computer-Code vertraut sein. Auf Computercode zu verzichten, erschiene mir daher fahrlässig für die „Zukunftsfestigkeit“ der Ausbildung.

1.2 Lernhilfen

Übungsaufgaben: Zum Ende aller Kapitel wird eine Auswahl an Übungsaufgaben aufgelistet. Für jede Aufgabe ist ein Name aufgeführt. Diese Aufgaben finden Sie auf der Seite <https://datenwerk.netlify.app>. Geben Sie dort jeweils den Namen der Aufgabe im Suchfeld ein, um die Aufgabe zu öffnen.



Schauen Sie sich mal den YouTube-Kanal *sebastiansauerstatistics* an und dann z. B. die Playlist „R“. Dort finden Sie *Videos zum Thema dieses Buches*.

1.3 Hinweise

Bei der Erstellung dieses Buches habe ich KI-Systeme (v. a. Claude von Anthropic) unterstützend eingesetzt, etwa zur sprachlichen Glättung, zur Ideenfindung für Beispiele und zur Fehlersuche in R-Code. Alle Inhalte wurden von mir konzipiert, geprüft und verantwortet. Die KI tritt nicht als Autorin auf.

Wurden Bilder anderer Autoren verwendet, so ist Autor, Fundort und Lizenz jeweils angegeben. Findet sich hingegen kein Autorenvermerk, so ist das Bild selber erstellt.

³<https://jasp-stats.org/>

⁴<https://www.jamovi.org/>

Teil I

Grundlagen

2 Die drei Zielarten der Statistik

2.1 Lernsteuerung

Abbildung 1.1 gibt einen Überblick zum aktuellen Standort im Modulverlauf. Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- die drei Zielarten der Statistik nennen und beschreiben können
- die Definition von Inferenzstatistik sowie Beispiele für inferenzstatistische Fragestellungen nennen
- zentrale Begriffe der Inferenzstatistik nennen und in Grundzügen erklären
- den Nutzen von Inferenzstatistik nennen
- erläutern, in welchem Zusammenhang Ungewissheit zur Inferenzstatistik steht
- anhand von Beispielen erklären, was ein statistisches Modell ist
- die Grundkonzepte der Regression angeben
- Unterschiede zwischen frequentistischer („klassischer“) und Bayes-Inferenz benennen
- Vor- und Nachteile der frequentistischen vs. Bayes-Inferenz diskutieren
- Die grundlegende Herangehensweise zur Berechnung des p-Werts informell erklären

Bei Gelman et al. (2021), Kap. 1 findet sich eine Darstellung ähnlich zu der in diesem Kapitel. Die Begleitliteratur ist nicht prüfungsrelevant; sie dient zur Vertiefung und als Grundlage einer ausführlicheren Erläuterung des Stoffes.

Bereiten Sie sich im Eigenstudium auf dieses Kapitel vor. Lesen Sie dazu folgende Themen:

- Statistik 1, Kap. „Rahmen“¹

¹<https://sebastiansauer.github.io/statistik1/010-rahmen>

2 Die drei Zielarten der Statistik

- Statistik 1², dort alle Inhalte aller Kapitel zum Thema „Modellieren“ bzw. „Regression“
- Statistik 1, Abschnitt zur Normalverteilung³

Diese Begleitvideos helfen Ihnen bei der Vor- und Nachbereitung dieses Kapitels:

- Video zur Inferenz, Teil 1
- Video zur Inferenz, Teil 2

Diese Frage haben Sie sich auch schon mal gestellt? Abb. Abbildung 2.1 gibt einen Überblick über die drei Zielarten der statistikbasierten wissenschaftlichen Forschung.⁴ Nach dieser Einteilung lassen sich drei Arten von Zielen unterscheiden: *Beschreiben*, *Vorhersagen* und *Erklären* (Shmueli, 2010).

2.2 Die drei Zielarten in der Statistik

Die drei Zielarten in der Statistik sind: Beschreiben, Vorhersagen, Erklären.

Beispiel 2.1 (Beispiele für die Zielarten statistischer Analysen).

- Beschreiben: “Wie groß ist der Gender-Paygap in der Branche X im Zeitraum Y?”
- Vorhersagen: Wenn eine Person, Mr. X, 100 Stunden auf die Statistiklausur lernt, welche Note kann diese Person dann erwarten?
- Erklären: Wie viel bringt (mir) das Lernen auf die Statistiklausur? □

Anhand der verwendeten statistischen Methode (z. B. Regressionsanalyse) kann man *nicht* feststellen, zu welchem Erkenntnisziel die Studie gehört. Um das Erkenntnisziel festzustellen, liest man sich die Forschungsfrage oder das Ziel der Studie durch. Bei wenig beackerten Wissenschaftsfeldern ist das *Beschreiben* ein sinnvoller erster Schritt. *Vorhersagen* ist mehr für die Praxis als für die Wissenschaft relevant.

²<https://sebastiansauer.github.io/statistik1/>

³<https://sebastiansauer.github.io/statistik1/040-verbildlichen#spezialfall-normalverteilung>

⁴Ziele existieren nicht „in echt“ in der Welt. Wir denken sie uns aus. Ziele haben also keine ontologische Wirklichkeit, sie sind epistemologische Dinge (existieren nur in unserem Kopf). Das heißt, dass man sich nach Belieben Ziele ausdenken kann. Allerdings hilft es, wenn man andere Menschen vom Nutzen der eigenen Ideen überzeugen kann.




Abbildung 2.1: Eine Einteilung zentraler Ziele von statistischen Analysen

2.3 Zielart *Beschreiben*


Wenn das Ziel die Beschreibung eines Datensatzes ist, so spricht man von *deskriptiver* Statistik.

Statistische Analysen mit dem Ziel zu beschreiben, fassen die Daten zusammen (zu möglichst aussagekräftigen Kennzahlen). Beschreibende Statistik nennt man auch *deskriptive Statistik*; Mittelwert, Korrelation und Regressionskoeffizienten sind typische Kennzahlen („Statistiken“); s. Abbildung 2.2.

Beispiel 2.2.

- Wie stark ist der (lineare) Zusammenhang r von Größe und Gewicht (bei Erwachsenen) in meiner Stichprobe?
- Wie stark ist der (lineare) Zusammenhang b von Lernzeit und Note (im Fach Statistik) in meinem Datensatz?
- Haben unsere Kunden bisher Webshop A oder B bevorzugt, laut unseren Daten? ☐

2 Die drei Zielarten der Statistik



(a) Die deskriptive Statistik fasst eine Spalte zu einer einzelnen Zahl zusammen.

(b) Zwei Spalten werden zu einer Zahl zusammengefasst

Abbildung 2.2: Beschreibende Statistik fasst eine oder mehr Variablen eines Datensatzes zu einer einzelnen Kennzahl zusammen.

Der beschreibenden Statistik geht es *nicht* darum, Erkenntnisse zu ziehen, die über die Daten hinaus gehen. So ist man in der beschreibenden Statistik nicht daran interessiert, Aussagen über die zugrundeliegende Population anzustellen.

Beispiel 2.3. In einem Hörsaal sitzen 100 Studis. Alle schreiben ihre Körpergröße auf einen Zettel. Die Dozentin sammelt die Zettel ein und rechnet dann den Mittelwert der Körpergröße der anwesenden Studierenden aus. Voilà: Deskriptive Statistik! □

Definition 2.1 (Deskriptivstatistik). *Deskriptivstatistik* fasst Merkmale aus einer Stichprobe zu Kennzahlen (Statistiken) zusammen.

2.4 Zielart Vorhersagen

Wenn das Ziel die Vorhersage bestimmter Ergebnisse ist, spricht man von *prädiktiven* bzw. *prognostischen* Analysen.

Beim Vorhersagen versucht man, auf Basis von Daten, gegeben bestimmter Werte der UV den Wert einer AV vorherzusagen, s. Abbildung 2.3.

Beispiel 2.4.

- Wie schwer ist wohl Herr X? Er ist ein deutscher erwachsener Mann der Größe 1,80 m; mehr wissen wir nicht.


- Welche Note kann man erwarten, wenn man nichts für die Klausur lernt?
- Wie viel wird ein Kunde ausgeben, wenn er sich in der Variante A des Webshops aufhält? □

Beispiel 2.5 (Ali lernt für die Klausur). Oh nein, die Klausur im Fach Statistik steht an. Ali lernt ziemlich viel. Wie viel Punkte (von 100 möglichen) wird er wohl erzielen? Ziehen wir ein einfaches statistisches Modell zur Rate, um eine Vorhersage für den „Klausurerfolg“ von Ali zu erhalten. Wir können vom Modell eine einzelne Zahl (83) als Punkt-Schätzwert bzw. Vorhersagewert erhalten oder einen Schätzbereich (62–104 Punkte). □

Hier ist das Regressionsmodell für Ali (`lm_ali`), s. Listing 2.1.

Listing 2.1 Regressionsmodell für Klausurerfolg als Funktion der Lernzeit (`lm_ali`)

```
noten2 <- read.csv("data/noten2.csv")
lm_ali <- lm(y ~ x, data = noten2)
```



(a) Regressionsgerade mit Punktvorhersage für Ali

(b) Regressionsgerade mit Vorhersagebereich (und herangezoomt) für Ali

Abbildung 2.3: Noten und Lernzeit: Rohdaten (a) und mit Modell (b). Mittelwerte sind mit gestrichelten Linien eingezeichnet. Die Vorhersage für Ali ist farbig markiert. Ali hat 42 Stunden gelernt für die Klausur; das Modell sagt ihm 83 Punkte (von 100) bzw. einen Bereich von 62 bis 104 Punkten voraus.

2.5 Zielart Erklären

Man spricht synonym von *schließender Statistik* oder *Inferenzstatistik*.

2 Die drei Zielarten der Statistik

Tabelle 2.1: Daten zur Studie A

Gruppe	Mit Medikament	Ohne Medikament
Männer	81/87 überlebt (93%)	234/270 überlebt (87%)
Frauen	192/263 überlebt (73%)	55/80 überlebt (69%)
Gesamt	273/350 überlebt (78%)	289/350 überlebt (83%)

2.5.1 Die zwei Arten von erklärenden Studien

„Erklären“ (Inferenz) hat hier zwei Bedeutungen (vgl. Gelman et al., 2021).

1. Populationsinferenz
2. Kausalinferenz

Beispiel 2.6.

- Wie stark ist der (lineare) Zusammenhang b von Lernzeit und Note (im Fach Statistik) in der Grundgesamtheit (nicht in der Stichprobe)?
- Bevorzugen unsere Kunden allgemein Webshop A oder B laut unseren Daten?
☐

Beispiel 2.7.

- Ist Größe eine Ursache von Gewicht (bei deutschen Männern)?
- Wenn ich 100 Stunden lerne, welche Note schreibe ich dann? ☐

2.5.2 Zielart Erklären – Kausalinferenz

Mittels Kausalinferenz können wir schließen, welche Variablen *Ursachen* und welche *Wirkung* sind – und welche Variablen Scheinkorrelation erzeugen. Das ist wichtig, denn nur wenn man die Ursache kennt, weiß man, was man tun muss, um eine Wirkung zu erzielen.

2.5.2.1 Studie A: Östrogen

Medikament einnehmen? Oder lieber nicht? Mit Blick auf Tabelle 13.1: Was raten Sie dem Arzt? Medikament einnehmen, ja oder nein?

Abbildung 2.4 zeigt die Daten aus Tabelle 13.1 in einem Balkendiagramm.

Überlebensrate nach Geschlecht, mit/ohne Medikament




Abbildung 2.4: Überlebensrate je Geschlecht, mit bzw. ohne Medikament

Die Daten stammen aus einer (fiktiven) klinischen Studie, $n = 700$, hoher Qualität (Beobachtungsstudie). Bei Männern scheint das Medikament zu helfen; bei Frauen auch. Aber *insgesamt* (Summe von Frauen und Männern) *nicht*?! Kann das sein? Was sollen wir den Arzt raten? Soll er das Medikament verschreiben? Vielleicht nur dann, wenn er das Geschlecht kennt (Pearl et al., 2016)?!

In Wahrheit sieht die kausale Struktur so aus: Das Geschlecht (Östrogen) hat einen positiven (+) Einfluss auf die Einnahme des Medikaments und negativen Einfluss (-) auf Heilung. Das Medikament hat einen positiven (+) Einfluss auf Heilung. Betrachtet man die Gesamt-Daten zur Heilung, so ist der Effekt von Geschlecht (Östrogen) und Medikament *vermengt* (konfundiert, confounded). Die kausale Struktur, also welche Variable beeinflusst bzw. nicht, ist in Abbildung 13.1 dargestellt.

2 Die drei Zielarten der Statistik




Abbildung 2.5: Zwei direkte Effekte (gender, drug) und ein indirekter Effekt (gender über drug) auf recovery

Betrachtung der Gesamtdaten zeigt in diesem Fall einen *konfundierten* Effekt: Geschlecht konfundiert den Zusammenhang von Medikament und Heilung.

! Wichtig

Aufteilen in Teilgruppen (Männer bzw. Frauen) ist also in diesem Fall der korrekte, richtige Weg. Achtung: Das Stratifizieren ist nicht immer und nicht automatisch die richtige Lösung. Stratifizieren bedeutet, den Gesamtdatensatz in Gruppen oder „Schichten“ („Strata“) aufzuteilen. Würde man die Gesamtzahl an Patienten mit vs. ohne Medikament vergleichen, käme man zu einem falschen Schluss.

2.5.2.2 Studie B: Blutdruck

Medikament einnehmen? Oder lieber nicht?

Mit Blick auf Tabelle 13.2: Was raten Sie dem Arzt? Medikament einnehmen, ja oder nein?

Tabelle 2.2: Daten zur Wirksamkeit eines Medikaments (Studie B)

Gruppe	Ohne Medikament	Mit Medikament
geringer Blutdruck	81/87 überlebt (93%)	234/270 überlebt (87%)

hoher Blutdruck	192/263 überlebt (73%)	55/80 überlebt (69%)
Gesamt	273/350 überlebt (78%)	289/350 überlebt (83%)

Die Daten stammen aus einer (fiktiven) klinischen Studie, $n = 700$, hoher Qualität (Beobachtungsstudie). Bei geringem Blutdruck scheint das Medikament zu schaden. Bei hohem Blutdruck scheint das Medikament auch zu schaden. Aber *insgesamt* (Summe über beide Gruppen) *nicht*, da scheint es zu nutzen?! Was sollen wir den Arzt raten? Soll er das Medikament verschreiben? Vielleicht nur dann, wenn er den Blutdruck nicht kennt (Pearl et al., 2016)?

2.5.2.3 Kausalmodell zur Studie B

Das Medikament hat einen (absenkenden) Einfluss auf den Blutdruck. Gleichzeitig hat das Medikament einen (toxischen) Effekt auf die Heilung. Verringerter Blutdruck hat einen positiven Einfluss auf die Heilung. Sucht man innerhalb der Leute mit gesenktem Blutdruck nach Effekten, findet man nur den toxischen Effekt: Gegeben diesen Blutdruck ist das Medikament schädlich aufgrund des toxischen Effekts. Der positive Effekt der Blutdruck-Senkung ist auf diese Art nicht zu sehen.

Das Kausalmodell von Studie B ist in Abbildung 13.2 dargestellt.




Abbildung 2.6: Drug hat keinen direkten, aber zwei indirekte Effekt auf recovery, einer davon ist heilsam, einer schädlich

Betrachtung der Teildaten zeigt nur den toxischen Effekt des Medikaments, nicht den nützlichen (Reduktion des Blutdrucks).

2 Die drei Zielarten der Statistik

! Wichtig

Betrachtung der Gesamtdaten zeigt in diesem Fall den wahren, kausalen Effekt. Stratifizieren wäre falsch, da dann nur der toxische Effekt, aber nicht der heilsame Effekt sichtbar wäre.

2.5.2.4 Studie A und B: Gleiche Daten, unterschiedliches Kausalmodell

Vergleichen Sie die DAGs Abbildung 13.1 und Abbildung 13.2, die die *Kausalmodelle* der Studien A und B darstellen: Sie sind *unterschiedlich*. Aber: Die *Daten* sind *identisch*.

Kausale Interpretation – und damit Entscheidungen für Handlungen – ist nur möglich, da das Kausalmodell bekannt ist. Die Daten alleine reichen nicht (bei Beobachtungsstudien).

2.5.2.5 Sorry, Statistik: Du allein schaffst es nicht

Datenanalyse alleine reicht nicht für Kausalschlüsse. 🧠 Kausalinferenz 📖 plus Datenanalyse 📊 erlaubt Kausalschlüsse. 📖 + 📊 = 😊

! Wichtig

Für Entscheidungen („Was soll ich tun?“) braucht man kausales Wissen. Kausales Wissen basiert auf einer Theorie (Kausalmodell) plus Daten.

2.5.3 Zielart Erklären – Populationsinferenz

Die zweite Bedeutung von „Erklären“ ist die Populationsinferenz: Von einer *Stichprobe* auf die *Grundgesamtheit* (Population) schließen.

Anders als bei der Kausalinferenz geht es hier nicht um die Frage, *welche* Variable Ursache und welche Wirkung ist, sondern darum, ob ein in der Stichprobe beobachteter Zusammenhang (oder Unterschied) auch in der Grundgesamtheit gilt – oder ob er nur zufällig in dieser Stichprobe aufgetreten ist.

Beispiele:

- Der Zusammenhang von Lernzeit und Note beträgt in der Stichprobe $b = 0.8$. Wie groß ist b vermutlich in der Grundgesamtheit aller Studierenden?
- Kunden bevorzugen in unserer Stichprobe Webshop A vor B. Gilt das auch für alle (zukünftigen) Kunden, oder könnte das Zufall sein?

Populationsinferenz beantwortet also Fragen wie „Wie sicher können wir sein?“ bzw. „Ist der gefundene Effekt echt (in der Population) oder nur Stichprobenrauschen?“. Dazu verwendet man Werkzeuge wie Konfidenzintervalle, Signifikanztests oder – in diesem Buch im Vordergrund – Bayes-Statistik.

! Wichtig

Populationsinferenz sagt nichts über Ursache und Wirkung aus. Ein statistisch gesicherter Zusammenhang in der Population kann trotzdem konfundiert sein.

Populationsinferenz ist Thema des nächsten Kapitels (Kapitel 3).

2.6 Modellieren

2.6.1 Modellieren als Grundraster des Erkennens

In der Wissenschaft – wie auch oft in der Technik, Wirtschaft oder im Alltag – betrachtet man einen Teil der Welt näher, meist mit dem Ziel, eine Entscheidung zu treffen, was man tun wird oder mit dem Ziel, etwas zu lernen. Nun ist die Welt ein weites Feld. Jedes Detail zu berücksichtigen ist nicht möglich. Wir müssen die Sache vereinfachen: Alle Informationen ausblenden, die nicht zwingend nötig sind. Aber gleichzeitig die Strukturelemente der wirklichen Welt, die für unsere Fragestellung zentral sind, beibehalten.

Dieses Tun nennt man *Modellieren*: Man erstellt sich ein Modell.

Definition 2.2 (Modell). Ein Modell ist ein vereinfachtes Abbild der Wirklichkeit. $\square$

Der Nutzen eines Modells ist, einen (übermäßig) komplexen Sachverhalt zu vereinfachen oder überhaupt erst handhabbar zu machen. Man versucht zu vereinfachen, ohne Wesentliches wegzulassen. Der Speck muss weg, sozusagen. Das Wesentliche bleibt. Auf die Statistik bezogen heißt das, dass man einen Datensatz dabei so zusammenfasst, damit man das Wesentliche erkennt.

2 Die drei Zielarten der Statistik

Was ist das „Wesentliche“? Oft interessiert man sich für die Ursachen eines Phänomens. Etwa: „Wie kommt es bloß, dass ich ohne zu lernen die Klausur so gut bestanden habe?“⁵ Noch allgemeiner ist man dabei häufig am Zusammenhang von X und Y interessiert, s. Abbildung 2.7, die ein Sinnbild von statistischen Modellen wiedergibt.




Abbildung 2.7: oben: Sinnbild eines einfachen statistischen Modells (eine UV, eine AV); unten: Sinnbild eines statistischen Modells, mit zwei UV

Man kann Abbildung 2.7 als ein Sinnbild einer (mathematischen) Funktion lesen.

Definition 2.3 (Funktion). Eine mathematische Funktion f setzt zwei Größen in Beziehung. $\square$

In Mathe-Sprech: $f : X \rightarrow Y$, lies: „ f bildet X auf Y ab.“

oder: $y = f(x)$, lies: „ Y ist eine Funktion von X “. $\square$

Die Größe des Zusammenhangs von X und Y in f bezeichnet man als *Effekt* von X auf Y .

⁵Das ist natürlich nur ein fiktives, komplett unrealistisches Beispiel, das auch unklaren Ursachen den Weg auf diese Seite gefunden hat.

Definition 2.4 (Effekt). Der Begriff Effekt im statistisch-wissenschaftlichen Sinn bezeichnet die Größe des statistischen Zusammenhangs (oder der Differenz) zwischen UV und AV in einem Modell, die über den zufälligen Erwartungswert hinausgeht. Effekt ist nicht unbedingt kausal zu verstehen. $\square$

Es hört sich zugespitzt an, aber eigentlich ist fast alles, was man tut, Modellieren: Wenn man den Anteil der R-Fans in einer Gruppe Studierender ausrechnet, macht man sich ein Modell: man vereinfacht diesen Ausschnitt der Wirklichkeit anhand einer statistischen Kennzahl, die das forschungsleitende Interesse zusammenfasst. Die Statistik kann man verstehen als ein Verfahren, das wissenschaftliche Modelle in statistische übersetzt und letztere dann einer empirischen Analyse unterzieht. Alle statistischen Ergebnisse beruhen auf Modellen und sind nur insoweit gültig, wie das zugrundeliegende Modell gültig ist.

2.6.2 Alle drei Zielarten modellieren, aber unterschiedlich

In allen drei Zielarten der Statistik wird modelliert.

- Beschreibende Studien nutzen Kennzahlen wie den Mittelwert, um „sich ein Bild zu machen“ von einer Verteilung.
- Vorhersagestudien nutzen Modelle als Werkzeug, um genaue Vorhersagen zu machen, ohne Anspruch, die Wirklichkeit zu erklären.
- Erklärende Studien nutzen Modelle, um die Wirklichkeit möglichst korrekt darzustellen.

Zur Umsetzung von Modellierung in eine konkrete statistische Analyse bietet sich die Regressionsanalyse an.

2.6.3 Regression zum Modellieren

Probieren Sie diese App aus, um Regressionskoeffizienten, Steigung (slope) und Achsenabschnitt (Intercept), optimal in den Punkteschwarm zu legen. Dabei meint „optimal“, die Abweichungen (Residuen, Residualfehler; die roten Balken in der App) zu minimieren.⁶ Probieren Sie diese App aus, die Ihnen gestattet, selber Hand an eine Regressionsgerade zu legen.⁷

⁶https://gallery.shinyapps.io/simple_regression/

⁷<https://shinyapps.org/showapp.php?app=https://shiny.psy.lmu.de/felix/lmfit&by=Felix%20Sch%C3%B6nbrodt&title=Find-a-fit!&shorttitle=Find-a-fit!>


2 Die drei Zielarten der Statistik

Die Regression ist eine Art Schweizer Taschenmesser der Statistik: Für vieles gut einsetzbar. Anstelle von vielen verschiedenen Verfahren des statistischen Modellierens kann man (fast) immer die Regression verwenden. Das ist nicht nur einfacher, sondern auch mathematisch schöner. Wir werden im Folgenden stets die Regression zum Modellieren verwenden. Dann wenden wir die Methoden der Inferenz auf die Kennzahlen der Regression an.


Alternativ zur Regression könnte man sich in den Wald der statistischen Verfahren begeben, wie hier von der Uni Münster als Ausschnitt (!) aufgeführt⁸. Auf dieser Basis kann man meditieren, welches statistischen Verfahren man für eine bestimmte Fragestellung verwenden sollte, s. Abbildung 2.8b. Muss man aber nicht – man kann stattdessen die Regression benutzen.

Hinweis

Es ist meist einfacher und nützlicher, die Regression zu verwenden, anstelle der Vielzahl von anderen Verfahren (die zumeist Spezialfälle der Regression sind). In diesem Kurs werden wir für alle Fragestellungen die Regression verwenden.⁹ $\square$



(a) Die eine Regression



(b) Wald von anderen Verfahren

Abbildung 2.8: Wähle die Regression. Oder die Wahl der Verfahren. Spoiler: Nimm lieber die Regression.

⁸https://web.archive.org/web/20091029162244/http://www.wiwi.uni-muenster.de/ioeb/en/organisation/pfaff/stat_overview_table.html

⁹Wie Jonas Kristoffer Lindeløv (<https://lindelov.github.io/tests-as-linear/>) uns erklärt, sind viele statistische Verfahren, wie der sog. t-Test Spezialfälle der Regression.

Beispiel 2.8. Typische *Spezialfälle* der Regression sind

- t-Test: UV: zweistufig nominal, AV: metrisch
- ANOVA: UV: mehrstufig nominal, AV: metrisch
- Korrelation: Wenn UV und AV z-standardisiert sind (d. h. Mittelwert von 0 und Standardabweichung von 1 haben), dann ist die Korrelation gleich dem Regressionskoeffizienten β_1 (bei einer einfachen Regression mit einer einzigen UV).

□

Abbildung 2.9 zeigt die Regressionsgleichung in voller Pracht. Links sieht man eine einfache Regression mit hp als UV (X, auch: Prädiktor) und mpg als AV (Y). Das rechte Teildiagramm zeigt eine multiple Regression mit den UVs hp und am.¹⁰ Im einfachsten Fall sind die vom Modell vorhergesagten (geschätzten) Werte, $\hat{y}$, durch eine einfache Gerade beschrieben, s. Abbildung 2.9, links. In allgemeiner Form schreibt man die Regressionsgleichung als lineare Gleichung, d. h. in Form einer Gerade, s. Theorem 2.1.

Theorem 2.1 (Lineares Modell (Regressionsgleichung)).


$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + \epsilon$$

Man nennt alle $\beta_0, \beta_1, \beta_2, \dots$ die Regressionsgewichte (Koeffizienten oder Parameter) des Modells (Gelman et al., 2021). Dabei ist β_0 der Achsenabschnitt (eng. *intercept*) und β_1 die Steigung der Regressionsgeraden. □


Anhand von Theorem 2.1 erkennt man auch, warum man von einem *linearen Modell* spricht: Y wird als gewichteter Mittelwert mehrerer Summanden berechnet. Eine Regressionsgerade ist durch zwei Parameter festgelegt: den Achsenabschnitt, β_0 und die Steigung, β_1 , s. Abbildung 2.9.

¹⁰Der Datensatz mtcars wird gerne als Studienobjekt verwendet, da er einfach ist und für viele Beispiele geeignet. Wenn Sie sich einen Sachverhalt an einem einfachen Datensatz vergegenwärtigen wollen, bietet sich auch der Datensatz mtcars an. Zudem ist er „fest in R eingebaut“; mit `data(mtcars)` können Sie ihn verfügbar machen.

2 Die drei Zielarten der Statistik



(a) Einfache Regression (eine UV: hp)



(b) Multiple Regression (zwei UV: hp und am)

Abbildung 2.9: Die Regressionsgerade in voller Pracht

Übungsaufgabe 2.1 (Peer Instruction: Regressionskoeffizienten). Eine Regressionsgerade wird durch zwei Koeffizienten festgelegt: ihren Achsenabschnitt, β_0 , sowie ihre Steigung, β_1 . Berechnet man also eine Regressionsgerade, so verfolgt man damit welche Zielart der Statistik?

- A) Beschreiben
- B) Vorhersagen
- C) Erklären – Kausal
- D) Erklären – Population
- E) Alle der oben genannten sind möglich
- F) Keine der oben genannten ☐

3 Populationsinferenz

3.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein. Sie können ...

- den Begriff der Populationsinferenz definieren und von der Deskriptivstatistik abgrenzen
- erläutern, warum inferenzstatistische Schlüsse notwendigerweise mit Ungewissheit behaftet sind
- zwischen Ungewissheit zu den Regressionskoeffizienten und Ungewissheit zur Vorhersagegenauigkeit (σ) unterscheiden
- den Begriff des Konfidenzintervalls (Schätzbereichs) erläutern und interpretieren
- frequentistische und Bayes-Inferenz einander gegenüberstellen
- den p-Wert informell definieren und typische Fehlinterpretationen benennen
- den Begriff der statistischen Signifikanz erläutern
- Null- und Alternativhypothese unterscheiden und anhand von Beispielen erläutern

Bei Gelman et al. (2021), Kap. 4, findet sich eine Darstellung, die sich mit den Inhalten dieses Kapitels überschneidet. Die Begleitliteratur ist nicht prüfungsrelevant; sie dient zur Vertiefung und als Grundlage einer ausführlicheren Erläuterung des Stoffes.

Bereiten Sie sich im Eigenstudium auf dieses Kapitel vor. Lesen Sie dazu folgende Themen:

- Statistik 1, Kap. „Rahmen“¹
- Statistik 1, Kap. „Punktmodelle 2“², insbesondere zu Regressionskoeffizienten

¹<https://sebastiansauer.github.io/statistik1/010-raahmen>

²<https://sebastiansauer.github.io/statistik1/070-zusammenhaenge>

3.2 Schließen von der Stichprobe auf die Grundgesamtheit

Populationsinferenz ist das Schließen von der Stichprobe auf die Grundgesamtheit.

Statistische Populationsinferenz – oft kurz als *Inferenz* bezeichnet – hat zum Ziel, vom Teil aufs Ganze zu schließen, bzw. vom Konkreten auf das Abstrakte. In der Datenanalyse heißt das: Was sagt mein Datensatz, der auf einer Stichprobe beruht, über die zugrundeliegende Grundgesamtheit aus?

Übungsaufgabe 3.1. Typischerweise untersuchen Sie im Rahmen einer statistischen Analyse eine *Stichprobe*, wie z. B. Ihr Freundeskreis, der leichtsinnig genug war, auf Ihre WhatsApp-Nachricht „Tolle Studie zum Geheimnis des Glücks!!!“ zu klicken. Ihr Freundeskreis ist ein *Teil* der Menschen (z. B. aus Deutschland), also eine Stichprobe. Schauen wir uns den Unterschied zwischen Stichprobe und Population näher an. □

Nehmen wir an, wir möchten herausfinden, wie groß der Anteil der R-Fans in der Grundgesamtheit (synonym: Population) aller Studierenden ist. Den Anteil der R-Fans bezeichnen wir der Einfachheit halber hier mit A^3 .

Das *Grundproblem der Inferenzstatistik* ist, dass wir an Aussagen zur Grundgesamtheit interessiert sind, aber nur eine Stichprobe, also einen Ausschnitt oder eine Teilmenge der Grundgesamtheit (synonym: Population) vorliegen haben. Wir müssen also den Anteil der R-Fans *in der Population* auf Basis des Anteils *in der Stichprobe* schließen: Wir verallgemeinern oder generalisieren von der Stichprobe auf die Grundgesamtheit, s. Abb. Abbildung 3.1.

³~~Meistens~~ Manchmal darf man bei der Statistik nicht nach einem tieferen Sinn suchen. Ist Statistik eine Art moderne Kunst?

3.2 Schließen von der Stichprobe auf die Grundgesamtheit




Abbildung 3.1: Population vs. Stichprobe. Die Stichprobe entnimmt einen Teil der Daten der Population. Autor: Karsten Lübke. Lizenz: OER.

Häufig ist das praktische Vorgehen recht simpel: Ah, in unserer Stichprobe sind 42 % R-Fans!⁴. Man schreibt: $p = 0.42$ (p wie proportion, engl. für „Anteil“). Die Stichprobe sei repräsentativ für die Grundgesamtheit aller Studierenden. Messerscharf schließen wir: In der Grundgesamtheit ist der Anteil der R-Fans auch 42 %, $\pi = 0.42$.

i Hinweis

Wir verwenden lateinische Buchstaben (p), um Kennzahlen einer Stichprobe zu benennen, und griechische (π) für Populationen. $\square$

Definition 3.1 ((Populations-)Inferenzstatistik). *Populations-Inferenzstatistik* – meist kurz als *Inferenzstatistik* bezeichnet – ist ein Verfahren zum Schließen von Statistiken (eine Kennzahl einer Stichprobe) auf *Parameter* (eine Kennzahl einer Grundgesamtheit). Inferenz bedeutet Schließen bzw. Schlussfolgern: auf Basis von vorliegendem Wissen wird neues Wissen generiert. Inferenzstatistik ist ein Verfahren, das mathematische Modelle (oft aus der Stochastik) verwendet, um

⁴Manch einer hätte mit mehr gerechnet; andere mit weniger...

3 Populationsinferenz

ausgehend von einer bestimmten Datenlage auf allgemeine Aussagen zu schließen.
□

Übungsaufgabe 3.2. Heute Nacht vor dem Schlafen wiederholen Sie die Definition.
Üben Sie jetzt schon mal. □

Für jede beliebige Statistik (Kennzahl von Stichprobendaten) kann man die Methoden der Populationsinferenz verwenden, um den zugehörigen Kennwert (Parameter) der Population zu bestimmen, s. Tabelle Tabelle 3.1. Da man die Parameter der Population so gut wie nie sicher kennt (schließlich hat man meist nur Auszüge, Teile der Population, also Stichproben), muss man sich mit *Schätzwerten* begnügen.

Tabelle 3.1: Bezeichnungen für Kennwerte

Kennwert	Stichprobe	Grundgesamtheit (Aussprache)	Schätzwert
Mittelwert	$\bar{X}$	μ (mü)	$\hat{\mu}$
Streuung	sd	σ (sigma)	$\hat{\sigma}$
Anteil	p	π (pi)	$\hat{\pi}$
Korrelation	r	ρ (rho)	$\hat{\rho}$
Regression	b	β (beta)	$\hat{\beta}$

Für Statistiken (Daten einer Stichprobe) verwendet man *lateinische* Buchstaben; für Parameter (Population) verwendet man *griechische* Buchstaben.

Übungsaufgabe 3.3. Geben Sie die griechischen Buchstaben für typische Statistiken an. Ohne auf die Tabelle zu schauen. 😊 □

Meist begnügt man sich beim Analysieren von Daten nicht mit Aussagen für eine Stichprobe, sondern will auf eine Grundgesamtheit verallgemeinern.

Leider sind die Parameter einer Grundgesamtheit zumeist unbekannt, daher muss man sich mit *Schätzungen* begnügen. Schätzwerte werden mit einem „Dach“ über dem Kennwert gekennzeichnet, s. letzte Spalte in Tabelle 3.1.

In der angewandten Forschung und im praktischen Leben interessieren häufig Fragen wie: „Welche Entscheidung ist (wahrscheinlich) besser?“. Da bekanntlich (fast) keine Aussagen sicher sind, spielt *Wahrscheinlichkeit* eine wichtige Rolle in den Forschungsfragen bzw. in deren Antworten.

i Hinweis

Wahrscheinlichkeit wird oft mit Pr oder p abgekürzt, für engl. *probability*. $\square$

Beispiel 3.1. Sie testen zwei Varianten Ihres Webshops (V1 und V2), die sich im Farbschema unterscheiden und ansonsten identisch sind: Hat das Farbschema einen Einfluss auf den Umsatz?

Dazu vergleichen Sie den mittleren Umsatz pro Tag von V1 vs. V2, $\bar{X}_{V1}$ und $\bar{X}_{V2}$. Die Mittelwerte unterscheiden sich etwas, $\bar{X}_{V1} > \bar{X}_{V2}$. Sind diese Unterschiede „zufällig“ oder „substanziell“? Gilt also $\mu_{V1} > \mu_{V2}$ oder gilt $\mu_{V1} \leq \mu_{V2}$? Wie groß ist die Wahrscheinlichkeit $Pr(\mu_{V1} > \mu_{V2})$?

3.3 Was ist Populationsinferenz?

Definition 3.2 (Populationsinferenz). *Populationsinferenz* (auch Inferenzstatistik oder schließende Statistik genannt) ist der Teilbereich der Statistik, der sich damit befasst, von den Daten einer begrenzten Stichprobe auf eine zugrundeliegende Grundgesamtheit (Population) zu verallgemeinern (zu schließen). $\square$

Deskriptivstatistik (Beschreiben) und Inferenzstatistik (Erklären) gehen Hand in Hand: Mit der Deskriptivstatistik berechnet man Statistiken zur Stichprobe. Dabei resultiert die Stichprobe durch eine zufällige Auswahl von Objekten aus der Grundgesamtheit. Mit der Inferenzstatistik verallgemeinert man von der Stichprobe auf die Grundgesamtheit, s. Abbildung 3.2.




Abbildung 3.2: Zusammenhang von Deskriptivstatistik und Inferenzstatistik

3 Populationsinferenz

3.3.1 Inferenz beinhaltet Ungewissheit

Inferenzstatistische Schlüsse sind mit *Ungewissheit* (Unsicherheit über die Zuverlässigkeit der Ergebnisse) behaftet: Schließlich kennt man nur einen Teil (die Stichprobe) eines Ganzen (die Population), möchte aber vom Teil auf das Ganze schließen. Aus diesem begrenzten Wissen resultiert notwendig Ungewissheit über die gesamte Population.

! Wichtig

Nichts Genaues weiß man nicht: Schließt man von einem Teil auf das Ganze, so geschieht das unter Unsicherheit. Man spricht von *Ungewissheit*, da man sich auf die *Unsicherheit des Wissens* über die Genauigkeit des Schließens bezieht.

Schließt man etwa, dass in einer Grundgesamtheit der Anteil der R-Fans bei 42 % liegt, so geschieht das unter Unsicherheit; es ist ungewiss. Man ist sich nicht sicher, dass es wirklich 42 % in der Population sind – und nicht etwa etwas mehr oder etwas weniger. Schließlich hat man *nicht* die ganze Population gesehen bzw. vermessen. *Sicher* ist man sich hingegen für die Stichprobe (Messfehler einmal ausgeblendet). Zur Bemessung der Unsicherheit (Ungewissheit) bedient man sich der Wahrscheinlichkeitsrechnung (wo immer möglich). Die Wahrscheinlichkeitstheorie bzw. -rechnung wird daher auch als die Mathematik des Zufalls bezeichnet.

Definition 3.3 (Zufälliges Ereignis). Unter einem zufälligen (engl. random) Ereignis verstehen wir ein Ereignis, das nicht (komplett) vorherzusehen ist, wie etwa die Augenzahl Ihres nächsten Würfelwurfs. Zufällig bedeutet nicht (zwangsläufig), dass das Ereignis keine Ursachen besitzt. So gehorchen die Bewegungen eines Würfels den Gesetzen der Physik, nur sind uns diese oder die genauen Randbedingungen nicht (ausreichend) bekannt. □

Übungsaufgabe 3.4. Welche physikalischen Randbedingungen wirken wohl auf einen Münzwurf ein? □

Beispiel 3.2 (Beispiele zur Quantifizierung von Ungewissheit). Aussagen mit Unsicherheit können unterschiedlich präzise formuliert sein.

- Morgen regnet's $\Leftrightarrow$ Morgen wird es hier mehr als 0 mm Niederschlag geben ($p = 97\%$).

3.3 Was ist Populationsinferenz?

- Methode A ist besser als Methode $B \Leftrightarrow$ Mit einer Wahrscheinlichkeit von 57 % ist der Mittelwert von Y für Methode A höher als für Methode B .
- Die Maschine fällt demnächst aus $\Leftrightarrow$ Mit einer Wahrscheinlichkeit von 97 % wird die Maschine in den nächsten 1-3 Tagen ausfallen, laut unserem Modell.
- Die Investition lohnt sich $\Leftrightarrow$ Die Investition hat einen Erwartungswert von 42 Euro; mit 90 % Wahrscheinlichkeit wird der Gewinn zwischen -10000 und 100 Euro.

Übungsaufgabe 3.5. Geben Sie weitere Beispiele an!

3.3.2 Zwei Arten von Ungewissheit

Im Modellieren im Allgemeinen und in Regressionsmodellen im Besonderen lassen sich (mindestens) zwei Arten von Ungewissheiten angeben:

1. Wie (un)gewiss ist man sich über die *Regressionsgewichte*?
2. Wie (un)gewiss ist man sich über die *Vorhersagegenauigkeit*?


3.3.2.1 Betas: Ungewissheit zur Regressionsgeraden

Wenn wir von den Daten der Stichproben auf die Grundgesamtheit schließen, können wir nicht sicher sein, ob die Regressionskoeffizienten (Achsenabschnitt, Steigung der Regressionsgeraden) exakt richtig sind, s. Abbildung 3.3. Wie man in Abbildung 3.4 sieht, können sich die Koeffizienten des Modells (β_0 , Achsenabschnitt und β_1 , Steigung) unterscheiden. Woran liegt das?


Listing 3.1 Regressionsmodell für Klausurerfolg als Funktion der Lernzeit (lm_toni)

```
noten2 <- read.csv("data/noten2.csv")
lm_toni <- lm(y ~ x, data = noten2)
```

3 Populationsinferenz




(a) Ungewissheit für den Achsenabschnitt: Die Gerade könnte ‚höher‘ oder ‚niedriger‘ aufgehängt sein.




(b) Ungewissheit für die Steigung der Regressionsgeraden: Die Gerade könnte mehr oder weniger steigen.

Abbildung 3.3: Wir könnten nicht sicher sein, dass der Achsenabschnitt und die Geradensteigung unseres Modells exakt richtig sind. Diese Werte könnten auch etwas größer oder kleiner sein.


Beispiel 3.3 (Stichproben der New Yorker Flüge). Nehmen wir an, wir ziehen ein paar Zufallsstichproben aus der Menge (Population) aller Flüge, die in New York im Jahre 2013 gestartet sind. In jeder Stichprobe berechnen wir eine Regression zwischen Flugzeit und Verspätung des Flugs am Ankunftsort. Sicherlich werden sich die Stichproben in ihren Kennwerten, z. B. in den Koeffizienten der genannten Regression, unterscheiden. $\square$



(a) Stichprobe 1



(b) Stichprobe 2



(c) Stichprobe 3

Abbildung 3.4: Regressionsanalysen mit verschiedenen Koeffizienten aufgrund der Zufälligkeit des Stichprobenziehens

Der Grund für die Schwankungen der Modellparameter zwischen den Stichproben ist die *Zufälligkeit* des Stichprobenziehens. Je nachdem, wie es der Zufall (oder sonst wer) will, landen bestimmte Fälle (Flüge in unserem Beispiel) in unserer Stichprobe. Zumeist unterscheiden sich die Stichproben; theoretisch könnten sie aber auch rein zufällig gleich sein.

! Wichtig

Stichproben-Kennwerte schwanken um den tatsächlichen Wert in der Population herum. $\square$


Um diese Ungewissheit, die sich in den Schwankungen der Stichproben-Regressionskoeffizienten ausdrückt, anzuzeigen, ist ein „grauer Schleier“ um die Regressionsgeraden in Abbildung 3.4 gekennzeichnet. Dieser graue Schleier gibt also eine Spannbreite anderer, plausibler Lagen der Regressionsgeraden an, die sich in einer anderen Stichprobe auch manifestieren könnten.

3.3.2.2 Sigma: Ungewissheit zur Genauigkeit der Vorhersage

Angenommen, wir sind uns *sicher* über die Werte der Modellparameter (β_0, β_1), also über die Lage der Regressionsgeraden, anschaulich gesprochen. Dann bliebe immer noch Ungewissheit, wie *genau* die Vorhersagen sind, wie groß also die Abstände zwischen vorhergesagten und tatsächlichen Werten. Wenn nicht die richtigen UVs im Modell sind (relevante fehlen oder auch irrelevante sind enthalten), dann liegen Vorhersagen und wirkliche Werte weiter auseinander: diese Streuung kann man als „Rauschen“ bezeichnen, s. Abbildung 3.5. Diese Art der Ungewissheit ist dann interessant, wenn man Vorhersagen macht und sich fragt, wie *präzise* diese Vorhersage ist. Die Präzision eines Modells kann man mit einem von zwei Kennwerten ausdrücken, die die gleiche Aussage machen. Diese zwei Kennwerte sind R^2 (R-Quadrat) und σ (sigma).

Definition 3.4 (Sigma als mittleren Vorhersagefehler). σ gibt (grob gesagt) den mittleren Vorhersagefehler des Modells an. Einfach gesprochen sagt σ wie weit eine Vorhersage im Durchschnitt vom wahren Wert entfernt ist. $\square$

3 Populationsinferenz



- (a) Geringer Vorhersagefehler (hohe Vorhersagegüte): Die vertikalen Balken sind kurz. (b) Hoher Vorhersagefehler: Die vertikalen Balken sind lang. (c) auch hoher Vorhersagefehler

Abbildung 3.5: Regressionsanalyse mit *gleicher* Regressionsgerade, aber *unterschiedlicher* Vorhersagegüte. Die Vorhersagefehler sind mit farbigen vertikalen Balken markiert. Je kürzer die Balken, desto besser (genauer) die Vorhersage.

3.3.3 Ich weiß, was ich nicht weiß: Ungewissheit angeben

Streng genommen ist eine Inferenz ohne Angabe der Ungewissheit (Genauigkeit der Schätzung) wertlos. Angenommen, jemand sagt, dass sie den Anteil der R-Fans (in der Population) auf 42 % schätzt, lässt aber offen wie *sicher* (präzise) die Schätzung (der Modellparameter) ist. Wir wissen also nicht, ob z. B. 2 % oder 82 % noch erwartbar sind. Oder ob man im Gegenteil mit hoher Sicherheit sagen kann, die Schätzung schließt sogar 41 % oder 43 % aus.

! Wichtig

Schließt man auf eine Population, schätzt also die Modellparameter, so sollte stets die (Un-)Genauigkeit der Schätzung, also die Ungewissheit des Modells, angegeben sein. □

Im Rahmen der Regressionsanalyse schlägt sich die Ungewissheit an zwei Stellen (und in drei Parametern) nieder:

1. zur Präzision der Regressionsgeraden β_0, β_1
2. zur Modellgüte (R^2) bzw. zum Vorhersagefehler, σ^5

⁵ σ , das griechische s für Streuung (um die Regressionsgerade herum), manchmal wird auch e wie *error* verwendet

3.3.4 Konfidenzintervall

Wir haben gesehen, dass wir die Werte der Parameter nur mit Ungewissheit angeben können (s. Abbildung 3.3 und Abbildung 3.5). Um dieser Ungewissheit Rechnung zu tragen, gibt man nicht nur einen einzelnen Wert an, einen *Punktschätzer*, sondern man gibt einen *Schätzbereich* auf Basis der Daten an, s. Tabelle 3.2.

Man spricht anstatt von Schätzbereich auch von einem *Konfidenzintervall*.⁶

```
model_parameters(lm_toni) |>
  select(1,2,5,6) |>
  print_md()
```

Tabelle 3.2: Punktschätzer und Schätzbereiche für die Modellkoeffizienten von `lm_toni`

Tabelle 3.2: Fixed Effects		
Parameter	Coefficient	CI
(Intercept)	46.19	(35.99, 56.39)
x	0.88	(0.68, 1.08)

Unser Modell gibt den 95 %-Schätzbereich für den Achsenabschnitt an, ca. von 36 bis 56 Klausurpunkten. Die Steigung wird geschätzt auf ca. 0.7 bis 1.1 Klausurpunkte pro Stunde Lernzeit.

Definition 3.5 (Konfidenzintervall). Ein Konfidenzintervall (confidence interval, CI) ist ein Oberbegriff für Schätzbereiche für Parameter wie Regressionskoeffizienten. Die Grenzen eines Konfidenzintervalls markieren die Grenzen eines Bereichs plausibler Werte für einen Parameter. □

Es gibt verschiedene Arten, Konfidenzintervalle zu berechnen; wir sprechen in späteren Kapiteln dazu ausführlicher. Ein Konfidenzintervall wird häufig mit 90 % oder 95 % Genauigkeit angegeben. Im Kontext der Bayes-Analyse – auf der dieser Kurs aufbaut – ist ein Konfidenzintervall einfach zu interpretieren. Sagen wir, wir finden, dass in einem Modell ein 95 %-Konfidenzintervall für den Anteil der R-Fans

⁶Tatsächlich gibt es mehrere Synonyme oder ähnliche Begriffe für Konfidenzintervall. Wir kommen später darauf detaillierter zu sprechen.

3 Populationsinferenz

angegeben wird, das sich von 40 bis 44 Prozent erstreckt. Dieser Befund lässt sich so interpretieren:

“Laut Modell liegt der gesuchte Anteil der R-Fans mit einer Wahrscheinlichkeit von 95 % im Bereich von 40 bis 44 Prozentpunkten.”

Übungsaufgabe 3.6. Geben Sie Beispiele für Konfidenzintervalle an.

Die Ungewissheit einer (Parameter-)schätzung aufzuzeigen (mit Hilfe eines Konfidenzintervalls), ist der wesentliche Nutzen der Populationsinferenz. Abbildung 3.6 stellt die Deskriptiv- der Populationsinferenzstatistik gegenüber.




Abbildung 3.6

3.4 Frequentistische Inferenz vs. Bayes-Inferenz

Es gibt zwei Hauptarten von Inferenzstatistik: Frequentistische Inferenz und Bayes-Inferenz.

Frequentismus: Klassische Inferenz

1. Ziel ist es, den Anteil von Fehlentscheidungen auf lange Sicht zu kontrollieren.
2. Keine Berücksichtigung von Vorwissen zum Sachgegenstand
3. Wahrscheinlichkeit wird über relative Häufigkeiten definiert.
4. Es ist *nicht* möglich, die Wahrscheinlichkeit einer Hypothese bzw. eines Werts in der Population (eines Parameters) anzugeben.

3.4 Frequentistische Inferenz vs. Bayes-Inferenz

5. Stattdessen wird angegeben, wie häufig eine vergleichbare Datenlage zu erwarten ist, wenn der Versuch sehr häufig (unendlich oft) wiederholt ist.
6. Ein Großteil der Forschung (in den Sozialwissenschaften) verwendet (aktuell) diesen Ansatz.

Bayesianische Inferenz

1. Ziel ist es, die Wahrscheinlichkeit einer Hypothese korrekt zu bemessen.
2. Vorwissen (Priori-Wissen) fließt explizit in die Analyse ein (zusammen mit den Daten).
3. Wenn das Vorwissen gut ist, wird die Vorhersage durch das Vorwissen genauer, ansonsten ungenauer.
4. Die Wahl des Vorwissens muss explizit (kritisierbar) sein.
5. In der Bayes-Inferenz sind Wahrscheinlichkeitsaussagen für Hypothesen möglich.
6. Die Bayes-Inferenz erfordert mitunter viel Rechenzeit und ist daher erst in den letzten Jahren (für gängige Computer) komfortabel geworden.

3.4.1 Frequentistische Inferenz und der p-Wert

Der zentrale Kennwert der frequentistischen Inferenz (synonym: Frequentismus) ist der p -Wert.

Der p -Wert ist so definiert, vgl. Wasserstein & Lazar (2016):

Wie hoch ist die Wahrscheinlichkeit eines empirischen Befunds (oder noch extremere Werte), vorausgesetzt die Nullhypothese H_0 gilt und man wiederholt den Versuch unendlich oft (mit gleichen Bedingungen, aber zufällig verschieden und auf Basis unseres Modells)?

Einfacher gesagt:

Der p -Wert ist die Wahrscheinlichkeit, ein Ergebnis zu erhalten, das mindestens so extrem ist wie das beobachtete, unter der Annahme, dass es keinen Effekt gibt.

Noch einfacher:

- Man nimmt an, dass es keinen Effekt gibt (z. B. kein Zusammenhang zwischen den untersuchten Variablen)

3 Populationsinferenz

- Dann fragt man: Wie überraschend wären meine Daten unter dieser Annahme?
- Der p-Wert gibt genau diese Überraschungs-Wahrscheinlichkeit an.

Übungsaufgabe 3.7. Recherchieren Sie eine Definition des p -Werts und lesen Sie sie einem Freund. Beobachten sie die Reaktionen auf Ihre Erklärung. □

Der p -Wert wird oft falsch verstanden (Badenes-Ribera et al., 2016). Aber er ist auch nicht leicht zu verstehen, meint Meister Yoda, s. Abbildung 3.7. Hier sind einige **FALSCH**E Interpretationen zum p -Wert laut der Autoren:

- Der p -Wert würde die Wahrscheinlichkeit der Nullhypothese oder der Forschungshypothese angeben. 🧐 **FALSCH!**
- Der p -Wert würde ein inhaltlich bedeutsames, praktisch signifikantes Ergebnis anzeigen. 🧐 **FALSCH!**



Abbildung 3.7: Der p -Wert ist wenig intuitiv, meint Meister Yoda

! Wichtig

Ein frequentistisches Konfidenzintervall macht keine Aussage zur Wahrscheinlichkeit eines Werts in der Population (eines Parameters). Stattdessen wird eine Aussage über das Ergebnis einer sehr häufig wiederholten Stichprobenziehung berichtet. Ob ein bestimmtes (unseres, Ihres) den wahren Wert enthält, bzw. mit welcher Wahrscheinlichkeit es den wahren Wert enthält, darüber macht das frequentistische Konfidenzintervall keine Aussagen. □

3.4.2 Bayes-Inferenz

Die zentrale Statistik der Bayes-Inferenz bzw. (synonym) Bayes-Statistik ist die *Posteriori-Verteilung*.

Die Posteriori-Verteilung beantwortet uns die Frage: „Wie wahrscheinlich ist die Forschungshypothese (oder Varianten von ihr), jetzt, nachdem wir die Daten kennen, auf Basis unseres Modells?“

In der Bayes-Statistik sind Aussagen folgender Art erlaubt:

Mit einer Wahrscheinlichkeit von 95 % ist der neue Webshop besser als der alte. Mit einer Wahrscheinlichkeit von 89 % liegt die Wirksamkeit des neuen Medikaments zwischen 0.1 und 0.4.

3.4.3 Statistische Signifikanz

Im *Frequentismus* spricht man von statistischer Signifikanz, wenn der p-Wert kleiner ist als 5 %: $p < .05$ (oder einen anderen Prozentwert als 5 %, aber meistens wird 5 % hergenommen). Man nimmt diesen Befund als Beleg, dass man einen Effekt gefunden hat, die Hypothese eines Nulleffekts (z.B. kein Zusammenhang von X und Y) also verwerfen kann. Faktisch verwirft man die Nullhypothese und wertet das Ergebnis als Unterstützung für die Forschungshypothese. Wichtig: „Verwerfen“ heißt nicht „beweisen“ – auch die Forschungshypothese gilt (wie jede wissenschaftliche Hypothese) nie als endgültig bewiesen, sondern bestenfalls als vorläufig nicht widerlegt.

3 Populationsinferenz

In der Bayes-Statistik ist der Begriff der Signifikanz nicht einheitlich definiert. Mit Bezug auf Gelman et al. (2021) (S. 57) wird in diesem Buch der Begriff wie folgt definiert – mit Gültigkeit sowohl für Bayes-Statistik als auch für Frequentistische Statistik.

Übungsaufgabe 3.8. Im Comic 1132 von xkcd⁷ wird sich über das Nicht-Berücksichtigen von Vorab-Informationen (Prior-Verteilung) lustig gemacht. Erklären Sie den Comic!

Definition 3.6 (Statistische Signifikanz im Frequentismus und im Bayesismus). Ist der Wert Null nicht im Schätzbereich enthalten, so liegt ein statistisch signifikantes Ergebnis vor. $\square$

Oft werden 95 %-Konfidenzintervalle verwendet, obwohl das nur eine Konvention ist. Die Signifikanzaussage bezieht sich immer auf einen Schätzbereich bestimmter Größe, z. B. 95 % (und des Modells inklusive Daten).

Liegt ein statistisch signifikantes Ergebnis vor, so *verwirft* man die *Nullhypothese* und akzeptiert die *Alternativhypothese* (synonym: Effekthypothese).

Definition 3.7 (Exakte Nullhypothese). Die exakte Nullhypothese (meist kurz nur als Nullhypothese bezeichnet), H_0 , besagt, dass *kein* (null) Effekt (keine Abweichung vom Referenzwert, kein Unterschied zwischen Gruppen, kein Zusammenhang zwischen UV und AV, Veränderung vor vs. nach der Intervention, ...) vorliegt. $\square$

Definition 3.8 (Alternativhypothese (Effekthypothese)). Eine Hypothese, die besagt, dass es einen (substanziellen) Effekt gibt. Das kann z. B. ein Unterschied zwischen den untersuchten Gruppen sein oder ein Zusammenhang zwischen den untersuchten Variablen. Logisch betrachtet ist die Alternativhypothese meist das Gegenteil der Nullhypothese. $\square$

Beispiel 3.4 (Beispiele für Effekthypothesen).

- Die Trefferquote der Münze ist $\pi = .7$ (Kopf), weicht also um 0.2 von 0.5, dem Wert laut Nullhypothese, ab.
- Der Unterschied im mittleren Gewicht zwischen den Gruppen beträgt ca. 500-600 g.
- Der Korrelationskoeffizient ρ liegt bei ca. .5 bis .7, ist also nicht Null.

⁷<https://xkcd.com/1132/>

3.4 Frequentistische Inferenz vs. Bayes-Inferenz

- Der standardisierte Regressionskoeffizient β liegt bei ca. .1 bis .2, ist also nicht Null.
- Der Unterschied in Gestimmtheit vor vs. nach der Induktion von Einsamkeit liegt bei $X_d = .3$, ist also nicht Null. $\square$

Beispiel 3.5 (Beispiele für Nullhypothesen).

- A) $H_0 : \mu = 100$ (Der Populationsmittelwert beträgt 100)
- B) $H_0 : \mu_1 = \mu_2$ (Es gibt keinen Unterschied zwischen den Mittelwerten zweier Gruppen)
- C) $H_0 : \rho = 0$ (Es besteht kein linearer Zusammenhang zwischen zwei Variablen)
- D) $H_0 : \pi = 0.5$ (Die Wahrscheinlichkeit für „Erfolg“ beträgt 50 %; die Münze ist „fair“)
- E) $H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4$ (Alle Gruppenmittelwerte sind gleich; bei ANOVA)
- F) $H_0 : \beta_1 = 0$ (Der Regressionskoeffizient ist null; kein Effekt des Prädiktors)
- G) $H_0 : \sigma_1^2 = \sigma_2^2$ (Die Varianzen zweier Populationen sind gleich) $\square$

Statistische Signifikanz im Frequentismus (nicht in der Bayes-Statistik) ist auch eine Funktion der Stichprobengröße: Wenn die Stichprobe groß genug ist, wird jeder Test signifikant (sofern der Effekt nicht exakt Null ist). Daher hat ein signifikantes Ergebnis zwei mögliche Ursachen: Der Effekt ist groß oder (auch) die Stichprobe ist groß, s. Abbildung 3.8.




Abbildung 3.8: Der p-Wert ist nicht nur eine Funktion der Effektgröße, sondern auch der Stichprobengröße. Große Stichproben werden zwangsläufig signifikant, sofern der Effekt nicht exakt Null ist.

Übrigens sollte man nicht nur von „Signifikanz“, sondern von „statistischer Signifikanz“ sprechen, um klar zu machen, dass man nicht ein Alltagsverständnis von

3 Populationsinferenz

Signifikanz („groß“, „bedeutsam“) meint, sondern einen wohl definierten statistischen Begriff. Das ist wichtig, weil es sonst leicht zu Fehlinterpretationen kommt.

Makowski et al. (2019) schlagen vor, welche Kennwerte der Bayes-Statistik analog zum p -Wert herangezogen werden können. Eine Möglichkeit dafür ist der Kennwert pd (*probability of direction*).

Übungsaufgabe 3.9 (Abhängigkeit vom Handy). Die Studie von Kabadayi (2024) untersucht den Zusammenhang von Smartphone-Abhängigkeit mit gesundheitlichen Problemen wie Depression, Stress, Einsamkeit und Schlafschwierigkeiten bei Heranwachsenden.

Lesen Sie den Abstract der Studie⁸ und Tabelle 2 (sowie alle Teile, die Sie benötigen, um Tabelle 2 zu verstehen).

1. Was ist der stärkste Zusammenhang bzgl. Smartphone-Abhängigkeit? Wie hoch ist er? Wie groß ist die erklärte Varianz des Zusammenhangs?
2. Zwischen welchen Variablen findet sich ein „statistisch signifikanter“ Zusammenhang?
3. Erklären Sie, was ein „statistisch signifikanter Zusammenhang“ hier bedeutet?

□

Übungsaufgabe 3.10 (Peer Instruction: p -Wert). Der p -Wert ist der zentrale Kennwert der frequentistischen Statistik. Aber er wird immer wieder missverstanden. Welche Aussage zum p -Wert ist korrekt?

- A) Ein p -Wert von 0,04 bedeutet, dass die Nullhypothese mit 96 % Wahrscheinlichkeit falsch ist.
- B) Ein p -Wert größer als 0,05 beweist, dass die Nullhypothese wahr ist.
- C) Ein kleiner p -Wert bedeutet, dass ein großer Effekt vorliegt.
- D) Ein p -Wert von 0,01 bedeutet, dass sich bei Wiederholung der Studie mit 99 % wieder ein signifikantes Ergebnis finden wird.
- E) Keine der oben genannten. □

3.5 Aufgaben

Schauen Sie sich die Aufgaben mit dem Tag *inference* auf dem Datenwerk⁹ an.

⁸<https://bmcp psychology.biomedcentral.com/articles/10.1186/s40359-024-02117-6>

⁹<https://datenwerk.netlify.app/#category=inference>

3.5.1 Paper-Pencil-Aufgaben

1. Griech-Buchstaben-Inferenz
2. inferenz-fuer-alle
3. ttest-als-regr
4. ttest-skalenniveau
5. pwert2
6. interpret-ci
7. interpret-ci2
8. gruppenvergleich-regression
9. Warum-Bayes
10. samples-nyc2
11. parameter-genau
12. punktschaetzer-reicht-nicht
13. aussagen-infstat

3.5.2 Aufgaben, für die man einen Computer braucht

1. korr-als-regr
2. ungewiss-arten-regr
3. inferenz-fuer-alle
4. adjustieren1a
5. adjustieren2a
6. lm-standardfehler
7. vorhersageintervall1

4 Hallo, Wahrscheinlichkeit

4.1 Lernsteuerung

Dieses Kapitel hat die Wahrscheinlichkeitstheorie (synonym: Wahrscheinlichkeitsrechnung) bzw. das Konzept der Wahrscheinlichkeit zum Thema.¹ Es geht sozusagen um die Mathematik des Zufalls.

Wozu brauchen Sie dieses Kapitel? Im wirklichen Leben sind Aussagen (Behauptungen) so gut wie nie sicher:

- „Weil sie so schlau ist, ist sie erfolgreich.“
- „In Elektroautos liegt die Zukunft.“
- „Das klappt sicher, meine Meinung.“
- „Der nächste Präsident wird XYZ.“

Hier lernen Sie, wie man mit Unsicherheiten umgehen und trotzdem Aussagen treffen kann.

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- die Grundbegriffe der Wahrscheinlichkeitstheorie erläuternd definieren
- die Definitionen von Wahrscheinlichkeit beschreiben
- typische Relationen (Operationen) von Ereignissen anhand von Beispielen veranschaulichen
- erläutern, was eine Zufallsvariable ist

Lesen Sie zur Begleitung dieses Kapitels Bourrier (2011), Kap. 2-4.

¹Die Wahrscheinlichkeitstheorie bildet zusammen mit der Statistik das Fachgebiet der Stochastik.

4.2 Grundbegriffe

4.2.1 Zufallsvorgang

Beispiel 4.1. Klassisches Beispiel für einen Zufallsvorgang ist das (einmalige oder mehrmalige) Werfen einer Münze. $\square$

Werfen Sie eine Münze! Diese hier zum Beispiel:



Bildquelle: By OpenClipartVectors, CC0

Wiederholen Sie den Versuch 10 Mal. Das reicht Ihnen nicht? Okay, wiederholen Sie den Versuch 100, nein 1000, nein: 10^6 Mal.² Notieren Sie als Ergebnis, wie oft die Seite mit der Zahl oben liegen kommt („Treffer“). $\square$

Oder probieren Sie die App der Brown University³, wenn Sie keine Sehnenscheidenentzündung bekommen wollen.

Definition 4.1 (Zufallsvorgang). Ein *Zufallsvorgang* oder *Zufallsexperiment* ist eine einigermaßen klar beschriebene Tätigkeit, deren Ergebnis nicht sicher ist. Allerdings ist die Menge möglicher Ergebnisse bekannt und die Wahrscheinlichkeit für alle Ergebnisse kann quantifiziert werden. $\square$

Beispiel 4.2 (Typische Zufallsvorgänge).

- **Würfeln:** Das Werfen eines fairen Würfels ist ein klassisches Beispiel. Der Ausgang (die Augenzahl) kann 1, 2, 3, 4, 5 oder 6 sein.
- **Münzwurf:** Beim Werfen einer Münze sind die möglichen Ausgänge „Kopf“ oder „Zahl“.
- **Lottoziehung:** Die Ziehung von 6 aus 49 Kugeln ist ein komplexeres Zufallsexperiment. Jeder Ausgang ist eine bestimmte Kombination von 6 Zahlen.
- **Kartenziehen:** Das Ziehen einer Karte aus einem gut gemischten Kartendeck ist ein weiteres Beispiel.

² $10^6 = 1000000$

³<https://seeing-theory.brown.edu/basic-probability/index.html#section1>

4 Hallo, Wahrscheinlichkeit

- **Glücksrad:** Das Drehen eines Glücksrads mit verschiedenen Feldern (z. B. Farben oder Zahlen). Welches Feld am Ende stehenbleibt, ist zufällig. $\square$

Übungsaufgabe 4.1. Nennen Sie Beispiele für Zufallsvorgänge! $\square$ ⁴

Vorsicht

Zufall heißt nicht, dass ein Vorgang keine Ursachen hätte. So gehorcht der Fall einer Münze komplett den Gesetzen der Gravitation. Würden wir diese Gesetze und die Ausgangsbedingungen (Luftdruck, Fallhöhe, Oberflächenbeschaffenheit, Gewichtsverteilungen, ...) exakt kennen, könnten wir theoretisch sehr genaue Vorhersagen machen. Der „Zufall“ würde aus dem Münzwurf verschwinden. Man sollte „Zufall“ also besser verstehen als „unbekannt“. $\square$

Übungsaufgabe 4.2. Mit dieser App⁵ können Sie Würfelwürfe simulieren und die Ausgänge dieses Zufallsexperiments beobachten. $\square$

4.2.2 Ergebnisraum

Definition 4.2 (Ergebnisraum). Die möglichen Ergebnisse eines Zufallsvorgangs fasst man als Menge mit dem Namen *Ergebnisraum* zusammen. Man verwendet den griechischen Buchstaben Ω für diese Menge. Die Elemente ω (kleines Omega) von Ω nennt man *Ergebnisse*. $\square$

Beispiel 4.3. Beobachtet man beim Würfelwurf (s. Abbildung 4.1) die oben liegende Augenzahl, so ist

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

ein natürlicher Grundraum (Henze, 2019). $\square$

Beispiel 4.4.

⁴Beispiele für Zufallsexperimente das Messen eines Umweltphänomens wie der Temperatur oder die Anzahl der Kunden, die einen Laden betreten. In jedem dieser Fälle sind die möglichen Ergebnisse nicht im Voraus bekannt und hängen von nicht komplett bekannten Faktoren ab.

⁵<https://www.geogebra.org/m/cbqee8h7>

- Münzwurf: $\Omega = \{\text{Kopf, Zahl}\}$
- Lotto: Bei der Ziehung von 6 aus 49 Kugeln ist der Grundraum die Menge aller möglichen Kombinationen von sechs Zahlen, das sind ca. 14 Millionen.
- Kartenziehen: Wenn eine einzelne Karte aus einem 52er-Kartendeck gezogen wird, ist der Grundraum die Menge aller 52 Karten.
- Glücksrad: Wenn das Glücksrad in vier gleich große, farbige Felder unterteilt ist (Rot, Grün, Blau, Gelb), dann ist der Grundraum die Menge der möglichen Farben: $\Omega = \{\text{Rot, Grün, Blau, Gelb}\}$ $\square$

Die Wahrscheinlichkeitsrechnung baut auf der Mengenlehre auf, daher wird die Notation der Mengenlehre hier verwendet.




Abbildung 4.1: Ein (sechseckiger) Würfel

4.2.3 Ereignis

Definition 4.3 (Ereignis). Jede Teilmenge⁶ von Ω heißt *Ereignis*; $A \subseteq \Omega$. $\square$

Beispiel 4.5. Beim Mensch-ärger-dich-nicht Spielen habe ich eine 6 geworfen.⁷ Das Nennen wir das Ereignis A : „Augenzahl 6 liegt oben“ und schreiben in Kurzform:

$$A = \{6\} \square$$

Beispiel 4.6. Sie werfen eine Münze (Sie haben keinen Grund, an ihrer Fairness zu zweifeln). „Soll ich jetzt lernen für die Klausur (Kopf) oder lieber zur Party gehen (Zahl)?“

⁶ A ist eine Teilmenge von B , wenn alle Elemente von A auch Teil von B sind.

⁷ Schon wieder.

4 Hallo, Wahrscheinlichkeit

Abbildung 4.2 zeigt die möglichen Ausgänge (T wie Treffer (Party) und N (Niete, Lernen)) dieses Zufallsexperiments.




Abbildung 4.2: Sie werfen eine Münze. Party oder Lernen???

Das Ereignis *Zahl* ist eingetreten! Treffer! Glück gehabt!⁸ □

4.2.4 Unmögliches und sicheres Ereignis

Definition 4.4 (Unmögliches und sicheres Ereignis). Die leere Menge $\emptyset$ heißt das *unmögliche*, der Grundraum Ω heißt das *sichere Ereignis*. □

Beispiel 4.7 (Unmögliches Ereignis). Alois behauptet, er habe mit seinem Würfel eine 7 geworfen. Schorsch ergänzt, sein Würfel liege auf einer Ecke, so dass keine Augenzahl oben liegt. Draco hat seinen Würfel runtergeschluckt. Diese Ereignisse sind *unmögliche Ereignisse*, zumindest nach unserer Vorstellung des Zufallsexperiments. □

Beispiel 4.8 (Sicheres Ereignis). Nachdem der Würfel geworfen wurde, liegt eine Augenzahl zwischen 1 und 6 oben. □

4.2.5 Elementarereignis

Definition 4.5 (Elementarereignis). Jede einelementige Teilmenge $\{\omega\}$ von Ω heißt *Elementarereignis* (häufig mit A bezeichnet).⁹ □

⁸?

⁹Ein *Ergebnis* ist ein Element von Ω . Elementarereignisse sind die einelementigen Teilmengen von Ω . Konzeptionell sind die beiden Begriffe sehr ähnlich, vgl. [https://de.wikipedia.org/wiki/Ergebnis_\(Stochastik\)](https://de.wikipedia.org/wiki/Ergebnis_(Stochastik)). Wir werden uns hier auf den Begriff *Elementarereignis* konzentrieren und den Begriff *Ergebnis* nicht weiter verwenden.

Beispiel 4.9.

- Sie spielen Mensch-ärger-dich-nicht. Und brauchen dringend eine 6. Sie würfeln. Das Ereignis $A = \{1\}$ tritt ein.¹⁰
- Sie schreiben eine Statistik-Klausur. Irgendwie haben Sie das Gefühl, das Ergebnis sei ein Zufallsexperiment... Jedenfalls können nach Adam Riese zwei Dinge passieren: $\Omega = \{\text{bestehen, nicht bestehen}\}$. Das erste der beiden Elementarereignisse tritt ein. Yeah!
- Sie führen eine Studie durch zur Wirksamkeit einer Lern-App. Es ist nicht klar, ob die App wirklich was bringt für den Lernerfolg. Vereinfacht gesprochen ist der Grundraum dieses Experiments: $\Omega = \{\text{schadet, bringt nichts, nützt}\}$. Die Daten sprechen für das Ereignis $A = \{\text{bringt nichts}\}$.

Übungsaufgabe 4.3. Welche Ereignisse beim Würfelwurf sind keine Elementarereignisse? $\square$

4.2.6 Vollständiges Ereignissystem

Definition 4.6 (Vollständiges Ereignissystem). Wird der Grundraum Ω vollständig in paarweise disjunkte Ereignisse zerlegt, so bilden diese Ereignisse ein vollständiges Ereignissystem, s. Abbildung 4.3. $\square$




Abbildung 4.3: Zerlegung des Grundraums in ein vollständiges Ereignissystem

Beispiel 4.10. Sei Ω der typische Ergebnisraum des Würfelwurfs. Wir zerlegen den Grundraum in zwei Ereignisse, A „gerade Zahlen“, und B „ungerade Zahlen“. Damit haben wir ein vollständiges Ereignissystem erstellt, s. Abbildung 4.4.

¹⁰Na toll.

$$A = \{2, 4, 6\} \quad \boxed{1 \boxed{2} 3 \boxed{4} 5 \boxed{6}} \quad (4.1)$$

$$B = \{1, 3, 5\} \quad \boxed{\boxed{1} 2 \boxed{3} 4 \boxed{5} 6} \quad (4.2)$$

$$(4.3)$$

$$\Omega = \{1, 2, 3, 4, 5, 6\} \quad \boxed{1 \ 2 \ 3 \ 4 \ 5 \ 6} \quad (4.4)$$

Abbildung 4.4

Ein Beispiel für ein vollständiges Ereignissystem

Beispiel 4.11. Sei Ω der typische Ergebnisraum des Würfelwurfs. Wir zerlegen den Grundraum in zwei Ereignisse, A „1,2,3“, und B „4,5,6“. Damit haben wir ein vollständiges Ereignissystem erstellt, s. Abbildung 4.4.

$$A = \{1, 2, 3\} \quad \boxed{\boxed{1 \ 2 \ 3} \ 4 \ 5 \ 6} \quad (4.5)$$

$$B = \{4, 5, 6\} \quad \boxed{1 \ 2 \ 3 \ \boxed{4 \ 5 \ 6}} \quad (4.6)$$

$$(4.7)$$

$$\Omega = \{1, 2, 3, 4, 5, 6\} \quad \boxed{1 \ 2 \ 3 \ 4 \ 5 \ 6} \quad (4.8)$$

Abbildung 4.5: Noch ein Beispiel für ein vollständiges Ereignissystem

4.2.7 Mächtigkeit

Definition 4.7 (Mächtigkeit). Die Anzahl der Elementarereignisse eines Ereignisraums nennt man die Mächtigkeit (des Ergebnisraums).¹¹ $\square$

Die Mächtigkeit von Ω bezeichnet man mit dem Symbol $|\Omega|$.

Beispiel 4.12. Beim Wurf eines Würfels mit $\Omega = \{1, 2, 3, 4, 5, 6\}$ gibt es 6 Elementarereignisse. Die Mächtigkeit ist also 6: $|\Omega| = 6$. $\square$

¹¹Die Menge aller Teilmengen einer Menge A nennt man die Potenzmenge $\mathcal{P}(A)$, vgl. https://de.wikipedia.org/wiki/Datei:Hasse_diagram_of_powerset_of_3.svg.

4.2.8 Disjunkte Ereignisse

Seien $A = \{1, 2, 3\}$; $B = \{4, 5, 6\}$ beide Teilmengen eines Grundraums Ω : $A \subseteq \Omega$, $B \subseteq \Omega$.

A und B sind disjunkt¹²: ihre Schnittmenge ist leer: $A \cap B = \emptyset$, s. Abbildung 4.6.




Abbildung 4.6: Zwei disjunkte Ereignisse, dargestellt durch überlappungsfreie Kreise

Beispiel 4.13. Das Ereignis A „Gerade Augenzahl beim Würfelwurf“, $A = \{2, 4, 6\}$ und das Ereignis B „Ungerade Augenzahl beim Würfelwurf“, $B = \{1, 3, 5\}$ sind disjunkt, s. Abbildung 4.7.

$$A = \{2, 4, 6\} \quad \boxed{2 \ 4 \ 6} \quad (4.9)$$

$$B = \{1, 3, 5\} \quad \boxed{1 \ 3 \ 5} \quad (4.10)$$

$$A \cap B = \emptyset \quad (4.11)$$

$$A \cap B = \emptyset \quad (4.12)$$

Abbildung 4.7: Beispiel für disjunkte Ereignisse

Beispiel 4.14. Die Ereignisse „normaler Wochentag“ und „Sonntag“ sind disjunkt. $\square$

Übungsaufgabe 4.4 (Peer Instruction: Elementarereignis). Welche der folgenden Ereignisse zeigt ein Elementarereignis des Würfelwurfs (wobei die Augenzahl 1, 2, ..., 6 die Ergebnisse sind)?

- A) Gerade Zahl gewürfelt
- B) Ungerade Zahl gewürfelt
- C) Keine 6 gewürfelt

¹²engl. disjoint

4 Hallo, Wahrscheinlichkeit

- D) 1 gewürfelt
- E) Keine der genannten $\square$

4.3 Was ist Wahrscheinlichkeit?

Die „klassische“ Logik der Wissenschaft beruht auf Schlüssen (Syllogismen) wie diesem: „Alle Schwäne sind weiß.“ $\rightarrow$ „Dies ist ein Schwan.“ $\rightarrow$ „Dieser Schwan ist weiß.“

Mit dem Konzept von Wahrscheinlichkeit können wir jetzt auch folgende Logik anwenden: „Die meisten Schwäne sind weiß.“ $\rightarrow$ „Dies ist ein Schwan.“ $\rightarrow$ „Dieser Schwan ist wahrscheinlich weiß.“ Das ist ein großer Fortschritt, der die Denkweise der Wissenschaft gut widerspiegelt und dafür eine logisch-mathematische Grundlage bereitstellt, s. Abbildung 4.8. Die Wahrscheinlichkeitsrechnung ist die typische Methode, um Ungewissheit zu präzisieren, d. h. zu quantifizieren.

4.3.1 Formallogische Definition

4.3.1.1 Wahrscheinlichkeit als Erweiterung der Logik

Die formallogische Konzeption von Wahrscheinlichkeit sieht Wahrscheinlichkeit als Erweiterung der formalen Logik (Jaynes & Bretthorst, 2003).¹³ In der formalen Logik ist ein Ereignis entweder *falsch* oder *wahr*. In der formallogischen Konzeption wird der Platz zwischen „falsch“ (0) und „richtig“ (1) als die Wahrscheinlichkeit $0 < p < 1$ gesehen (Briggs, 2016), s. Abbildung 4.8. Größere Werte stehen für größere Wahrscheinlichkeit und umgekehrt.

Definition 4.8 (Einfache Definition von Wahrscheinlichkeit). Die Wahrscheinlichkeit ist ein Maß für die Plausibilität einer Aussage A , gegeben gewisser Hintergrundinformationen (Daten, D): $Pr(A|D)$. Die Wahrscheinlichkeit eines Ereignisses wird (sofern berechenbar) als Zahl zwischen 0 und 1 angegeben, wobei 0 bedeutet, dass das Ereignis als unmöglich angesehen wird, und 1 bedeutet, dass das Ereignis als sicher betrachtet wird. Je näher die Wahrscheinlichkeit bei 1 (0) liegt, desto sicherer ist jemand, dass das Ereignis (nicht) der Fall ist. $\square$

¹³Manchmal wird diese Art der Wahrscheinlichkeit auch *epistemologische* Wahrscheinlichkeit genannt.




Abbildung 4.8: Wahrscheinlichkeit als Erweiterung der Logik

Nach dieser „Wahrscheinlichkeitslogik“ kann man ein Ereignis, von dessen Eintreten man „wenig überzeugt“ ist, z. B. mit 0.2 quantifizieren. Hingegen einem Ereignis, von man „recht sicher“ ist, mit 0.8 quantifizieren, s. Abbildung 4.9.



Abbildung 4.9: Ein Ereignis von dessen Eintreten man gering bzw. stark überzeugt ist

4.3.1.2 Wahrscheinlichkeit als Ungewissheit

Wahrscheinlichkeit existiert nicht in dem Sinne, wie ein Stein oder ein Mensch existiert. Wahrscheinlichkeit ist stattdessen eine Art von Wissen. Daher ist es (nach Jaynes & Bretthorst (2003)) falsch, zu sagen: „Die Wahrscheinlichkeit für Zahl bei dieser Münze ist 50 %.“ Richtig wäre für einen unbedarften Spieler: „Ich habe keinen Grund, nicht an der Fairness der Münze zu glauben, also gehe ich von 50 % Wahrscheinlichkeit für Zahl aus.“ Der Betrüger, der diese Münze in der Hand hat, geht allerdings von einer Wahrscheinlichkeit von 75 % für Zahl aus (er kennt die Münze besser als Sie).

Das Beispiel zeigt: Wahrscheinlichkeit ist kein Ding der Welt, sondern ein Wissenszustand.

Formaler ausgedrückt: Sei Pr die Wahrscheinlichkeit, die das Ereignis Z (Zahl) angibt, *gegeben* meiner Annahme, dass die Münze fair ist (F); sie hat also eine Wahrscheinlichkeit von 50 % ($1/2 = .5$) für Z . Dann kann man kurz schreiben:

$$Pr(Z|F) = 0.5$$

Gegeben des Wissens des Betrügers B wäre die Wahrscheinlichkeit für Z anders:

$$Pr(Z|B) = 0.75$$

In Worten: „Die Wahrscheinlichkeit von Zahl (Z) gegeben das Wissen des Betrügers über die Münze (B) liegt bei 75 %.“

4.3.1.3 Wahrscheinlichkeit ist bedingt auf ein Hintergrundwissen

Das Beispiel zeigt auch, dass die Wahrscheinlichkeit eines Ereignisses (wie Z) von Hintergrundinformationen (Annahmen, Daten, Evidenz, ...) abhängt. Ohne zu sagen, auf welche Hintergrundinformationen wir uns beziehen (die des unbedarften Spielers oder die des Betrügers), ist es sinnvoll, eine Wahrscheinlichkeit anzugeben. Daher ist $Pr(Z) = 0.5$ unvollständig. Allerdings wird die Hintergrundinformation oft weggelassen, wenn es klar ist, welche Hintergrundinformation vorliegt. So wird häufig vorausgesetzt, dass eine Münze fair ist.

Beispiel 4.15 (Morgen regnet's). Es ist daher unvollständig zu sagen: „Morgen wird es mit einer Wahrscheinlichkeit von 70 % regnen.“

Man müsste Hintergrundinformation (Evidenz, E) ergänzen, z. B. „gegeben meines Wissens zum Wettermodell X“.

Also: Anstelle von $Pr(\text{Regen}) = .7$ sollte man besser schreiben: $Pr(\text{Regen}|\text{Wettermodell X})$. $\square$

Beispiel 4.16 (Wahrscheinlichkeit für Krebs). Jemand beobachtet bei sich Symptome, die für eine Hautkrebserkrankung K typisch sind. Die Person sagt sich: „Ach, die Wahrscheinlichkeit für Hautkrebs liegt bei einem Promille. Kein Grund für Sorge.“ Formal: $Pr(K) = 0.001$. Aber wenn die Person relevante Symptome S hat, gilt: $Pr(K | S) \gg 0.001$. $\square$

Hinweis

Sagt jemand: „Die Wahrscheinlichkeit von A ist x %“, frag immer: „gegeben welcher Annahmen, welcher Evidenz?“

Definition 4.9 (Indifferenzprinzip). Das Indifferenzprinzip (synonym: Prinzip des unzureichenden Grundes) besagt, dass in Abwesenheit jeglicher Informationen, die bestimmte Ereignisse bevorzugen oder benachteiligen würden, alle möglichen Ereignisse als gleich wahrscheinlich angesehen werden sollten. $\square$

Vor uns liegt ein Würfel. Schlicht, ruhig, unbesonders. Wir haben keinen Grund anzunehmen, dass eine seiner $n = 6$ Seiten bevorzugt nach oben zu liegen kommt. Jedes der sechs Elementarereignisse ist uns gleich plausibel; der Würfel erscheint uns fair. In Ermangelung weiteres Wissens zu unserem Würfel gehen wir schlicht davon aus, dass jedes der n Elementarereignisse gleich wahrscheinlich ist. Es gibt keinerlei Notwendigkeit, den Würfel in die Hand zu nehmen, um zu einer Wahrscheinlichkeitsaussage auf diesem Weg zu kommen. Natürlich *könnten* wir unsere Auffassung eines fairen Würfels testen, aber auch ohne das Testen können wir eine stringente Aussage (basierend auf dem Indifferenzprinzip (s. Definition 4.9) der n Elementarereignisse) zur Wahrscheinlichkeit eines bestimmten (Elementar-)Ereignisses A kommen (Briggs, 2016), s. Theorem 4.1.

Theorem 4.1 (Indifferenzprinzip).

$$Pr(A) = \frac{1}{n} = \frac{1}{|\Omega|} \quad \square$$

Beispiel 4.17. Sei A = „Der Würfel wird beim nächsten Wurf eine 6 zeigen.“ Die Wahrscheinlichkeit für A ist $1/6$. $\square$

Beispiel 4.18 (Kann Sophia (Einhorn) fliegen?). Sei A : „Sophia ist ein Einhorn“. Und sei B : „Einhörner mit Flügeln können fliegen und die Hälfte aller Einhörner hat Flügel“. Dann ist $Pr(A|B) = 1/2$. $\square$

Beispiel 4.19 (Ich werfe Zahl beim nächsten Münzwurf). B „Ich habe keinen Grund an der Fairness der Münze zu zweifeln“. A : „Es wird Zahl geworfen beim nächsten Wurf dieser Münze“. Es gilt: $Pr(A|B) = 1/2$. $\square$

Definition 4.10 (Laplace-Experiment). Ein Zufallsexperiment, bei dem alle Elementarereignisse dieselbe Wahrscheinlichkeit haben, nennt man ein *Laplace-Experiment*, s. Theorem 4.2. $\square$

In Erweiterung von Theorem 4.1 können wir für ein Laplace-Experiment schreiben, s. Theorem 4.2.

Theorem 4.2 (Laplace-Experiment).

$$Pr(A) = \frac{\text{Anzahl Treffer}}{\text{Anzahl möglicher Ergebnisse}} \quad \square$$

4.3.2 Frequentistische Definition

In Ermangelung einer Theorie zum Verhalten eines (uns) unbekannten Zufallsvorgangs und unter der Vermutung, dass die Elementarereignisse nicht gleichwahrscheinlich sind, bleibt uns ein einfacher (aber aufwändiger und manchmal unmöglicher) Weg, um die Wahrscheinlichkeit eines Ereignisses zu bestimmen: Ausprobieren.

Angenommen, ein Statistik-Dozent, bekannt für seine Vorliebe zum Glücksspiel und mit scheinbar endlosen Glückssträhnen (er wirft andauernd eine 6), hat seinen Lieblingswürfel versehentlich liegen gelassen. Das ist *die* Gelegenheit! Sie greifen sich den Würfel, und ... Ja, was jetzt? Nach kurzer Überlegung kommen Sie zum Entschluss, den Würfel einem „Praxistest“ zu unterziehen: Sie werfen ihn 1000 Mal (Puh!) und zählen den Anteil der 6. Falls der Würfel fair ist, müsste gelten $Pr(A = 6) = 1/6 \approx .17$. Schauen wir mal!

Und hier der Anteil von 6 im Verlauf unserer Würfe, s. Abbildung 4.10.




Abbildung 4.10: Das Gesetz der großen Zahl am Beispiel der Stabilisierung des Trefferanteils beim wiederholten Würfelwurf

Hm, auf den ersten Blick ist kein (starkes) Anzeichen für Schummeln bzw. einen gezinkten Würfel zu finden.

4.3.3 Kolmogorovs Definition

Kolmogorov richtet eine Reihe von Forderungen an eine Definition von bzw. an das Rechnen mit Wahrscheinlichkeiten, die direkt plausibel erscheinen:

1. *Nichtnegativität*: Die Wahrscheinlichkeit eines Ereignisses kann nicht negativ sein.
2. *Normierung*: Das sichere Ereignis hat die Wahrscheinlichkeit 1 bzw. 100 %: $Pr(\Omega) = 1$; das unmögliche Ereignis hat die Wahrscheinlichkeit 0: $Pr(\emptyset) = 0$.
3. *Additivität*. Sind A und B disjunkt, dann ist die Wahrscheinlichkeit, dass mindestens eines der beiden Ereignisse eintritt ($A \cup B$) gleich der Summe der beiden Einzelwahrscheinlichkeiten von A und B .

Übungsaufgabe 4.5 (Peer Instruction: Ist der Schmockulator im Zustand alpha?). B : „Locuratoren und Schmockulatoren kommen in zwei Zuständen vor, alpha und beta“. Leider wissen wir nichts Weiteres über Locuratoren und Schmockulatoren. Vor Ihnen steht ein Schmockulator. Welche möglichst präzise Aussage können wir über den Zustand des Schmockulator treffen?

- A) Der Schmockulator ist sicher im Zustand alpha.
- B) Der Schmockulator ist in einem der beiden Zustände.
- C) Der Schmockulator ist vermutlich im Zustand alpha.
- D) Der Schmockulator ist möglicherweise im Zustand alpha.
- E) Der Schmockulator ist mit einer Wahrscheinlichkeit von 50 % im Zustand alpha.
- F) Keine der genannten. $\square$

4.4 Relationen von Ereignissen

Für das Rechnen mit Wahrscheinlichkeiten ist es hilfreich, ein paar Werkzeuge zu kennen, die wir uns im Folgenden anschauen.

Definition 4.11 (Relation). Eine Relation (zweier Ereignisse) bezeichnet die Beziehung, in der die beiden Ereignisse zueinander stehen. $\square$

Typische Relationen sind Gleichheit, Ungleichheit, Vereinigung, Schnitt.

4.4.1 Überblick

Wir gehen von Grundraum Ω aus, mit dem Ereignis A als echte Teilmenge von Ω : $A \subset \Omega$.

Da wir Ereignisse als Mengen auffassen, verwenden wir im Folgenden die beiden Begriffe synonym.

Dabei nutzen wir u.a. Venn-Diagramme. Venn-Diagramme eignen sich, um typische Operationen (Relationen) auf Mengen zu visualisieren. Die folgenden Venn-Diagramme stammen von Wikipedia¹⁴.

i Wozu sind die Venn-Diagramme gut? Warum soll ich die lernen?

Venn-Diagramme zeigen Kreise und ihre überlappenden Teile; daraus lassen sich Rückschlüsse auf Rechenregeln für Wahrscheinlichkeiten ableiten. Viele Menschen tun sich leichter, Rechenregeln visuell aufzufassen als mit Formeln und Zahlen alleine. Aber entscheiden Sie selbst! $\square$

Diese App versinnbildlicht das Rechnen mit Relationen von Ereignissen anhand von Venn-Diagrammen.¹⁵

4.4.2 Vereinigung von Ereignissen

Definition 4.12 (Vereinigung von Ereignissen). Vereinigt man zwei Ereignisse A und B , dann besteht das neue Ereignis C genau aus den Elementarereignissen der vereinigten Ereignisse. Man schreibt $C = A \cup B$, lies: „ C ist A vereinigt mit B “, oder „Menge A ODER Menge B “. $\square$

Abbildung 4.11 zeigt ein Venn-Diagramm zur Verdeutlichung der Vereinigung von Ereignissen.




Abbildung 4.11: $A \cup B$: Vereinigung zweier Mengen

¹⁴https://en.wikipedia.org/wiki/Venn_diagram

¹⁵<https://www.geogebra.org/m/QZvCMSDs>

Beispiel 4.20. Um einen (hohen!) Geldpreis zu gewinnen, muss bei Ihrem nächsten Wurf mindestens eines der beiden Ereignisse $A = \{1, 2\}$ oder $B = \{2, 3\}$ eintreten, s. Abbildung 4.12.

$$A = \{1, 2\} \quad \boxed{\boxed{1\ 2}\ 3\ 4\ 5\ 6} \quad (4.13)$$

$$B = \{2, 3\} \quad \boxed{1\ \boxed{2\ 3}\ 4\ 5\ 6} \quad (4.14)$$

$$A \cup B = \{1, 2, 3\} \quad \boxed{\boxed{1\ 2\ 3}\ 4\ 5\ 6} \quad (4.15)$$

Abbildung 4.12: Beispiel zur Vereinigung zweier Mengen

Zur besseren Verbildlichung betrachten Sie mal diese Animation zur Vereinigung von Mengen¹⁶; Quelle: Geogebra, J. Merschhemke.

In R heißt die Vereinigung von Mengen `union()`. Einfach mal ausprobieren.

```
A <- c(1, 2)
B <- c(2, 3)

union(A, B)
## [1] 1 2 3
```

4.4.3 (Durch-)Schnitt von Ereignissen

Definition 4.13 (Schnittmenge von Ereignissen). Die Schnittmenge zweier Ereignisse A und B umfasst genau die Elementarereignisse, die Teil beider Ereignisse sind. Man schreibt: $A \cap B$.¹⁷ Lies: „A geschnitten B“, oder „Menge A UND Menge B“. $\square$

Abbildung 4.13 zeigt ein Sinnbild zur Schnittmenge zweier Ereignisse.

¹⁶<https://www.geogebra.org/m/GEZV4xXc#material/cmXR8fHN>

¹⁷Synonym und kürzer: AB anstelle von $A \cap B$.




Abbildung 4.13: $A \cap B$: Schnitt zweier Mengen

Beispiel 4.21. Um einen (hohen!) Geldpreis zu gewinnen, muss bei ihrem nächsten Wurf sowohl das Ereignis A = „gerade Augenzahl“ als auch B = „Augenzahl größer 4“ eintreten, s. Abbildung 4.14.

$$A = \{2, 4, 6\} \quad \begin{array}{|c|c|c|c|c|c|} \hline 1 & 2 & 3 & 4 & 5 & 6 \\ \hline \end{array} \quad (4.17)$$

$$B = \{5, 6\} \quad \begin{array}{|c|c|c|c|c|c|} \hline 1 & 2 & 3 & 4 & 5 & 6 \\ \hline \end{array} \quad (4.18)$$

$$A \cap B = \{6\} \quad \begin{array}{|c|c|c|c|c|c|} \hline 1 & 2 & 3 & 4 & 5 & 6 \\ \hline \end{array} \quad (4.19)$$

$$A \cap B = \{6\} \quad \begin{array}{|c|c|c|c|c|c|} \hline 1 & 2 & 3 & 4 & 5 & 6 \\ \hline \end{array} \quad (4.20)$$

Abbildung 4.14: Beispiel zum Schnitt zweier Mengen

```
A <- c(2, 4, 6)
B <- c(5, 6)
intersect(A, B)
## [1] 6
```

i Eselsbrücke zur Vereinigungs- und Schnittmenge

Das Zeichen für eine Vereinigung zweier Mengen „ $\cup$ “ kann man leicht mit dem Zeichen für einen Schnitt zweier Mengen „ $\cap$ “ verwechseln; daher folgt hier eine Eselsbrücke, s. Abbildung 4.15.




Abbildung 4.15: Eselsbrücke für Vereinigungs- und Schnittmenge: In der „Tasche“ (Vereinigung) bleibt mehr hängen als in der „Käseglocke“.

4.4.4 Komplementärereignis

Definition 4.14 (Komplementärereignis). Ein Ereignis B ist genau dann ein Komplementärereignis zu A , wenn es genau die Elementarereignisse von Ω umfasst, die nicht Elementarereignis von A sind, s. Abbildung 4.17. $\square$

Man schreibt für das Komplementärereignis¹⁸ von A oft $\bar{A}$ oder $\neg A$ ¹⁹; lies „Nicht- A “ oder „A-quer“.

Beispiel 4.22. Beim normalen Würfelwurf sei A das Ereignis „gerade Augenzahl“, das Komplementärereignis²⁰ ist dann $\neg A$ „ungerade Augenzahl“, s. Abbildung 4.16.

$$A = \{2, 4, 6\} \quad \boxed{1 \quad \boxed{2} \quad 3 \quad \boxed{4} \quad 5 \quad \boxed{6}} \quad (4.21)$$

$$\underline{\hspace{10em}} \tag{4.22}$$

$$\neg A = \{1, 3, 5\} \quad \boxed{\boxed{1} \ 2 \ \boxed{3} \ 4 \ \boxed{5} \ 6} \quad (4.23)$$

(4.24)

Abbildung 4.16: Ein Beispiel für ein Komplement

¹⁸synonym: Komplement

¹⁹manchmal auch A^C ; C wie complementary event

²⁰ das „Komplement“, nicht zu verwechseln mit „Kompliment“




Abbildung 4.17: $\bar{A}$: Komplement von A

Beispiel 4.23 (Gezinkter Würfel). Ein gezinkter Würfel hat eine erhöhte Wahrscheinlichkeit für das Ereignis A = „6 liegt oben“, und zwar gelte $Pr(A) = 1/3$. Was ist die Wahrscheinlichkeit, *keine* 6 zu würfeln? $\square$ ²¹

4.4.5 Logische Differenz

Definition 4.15 (Logische Differenz). Die logische Differenz der Ereignisse A und B ist das Ereignis, das genau aus den Elementarereignissen von A besteht, die nicht zugleich Elementarereignis von B sind, s. Abbildung 4.18. $\square$

Die logische Differenz von A zu B schreibt man häufig so: $A \setminus B$; lies „A minus B“.




Abbildung 4.18: $A \setminus B$: Alle Elemente von A , die nicht in B sind.

Beispiel 4.24. Sei A die Menge „große Zahlen“ mit $A = \{4, 5, 6\}$. Sei B die Menge „gerade Zahlen“ mit $B = \{2, 4, 6\}$. Wir suchen die logische Differenz, $A \setminus B$, s. Abbildung 4.19.

²¹Die Wahrscheinlichkeit, keine 6 zu würfeln, liegt bei $2/3$.

$$A = \{4, 5, 6\} \quad \boxed{4 \ 5 \ 6} \quad (4.25)$$

$$B = \{2, 4, 6\} \quad \boxed{2 \ 4 \ 6} \quad (4.26)$$

$$A \setminus B \quad \boxed{5} \quad (4.27)$$

$$A \setminus B \quad \boxed{5} \quad (4.28)$$

Abbildung 4.19: Beispiel für die logische Differenz

In R gibt es die Funktion `setdiff()`, die eine Mengendifferenz ausgibt.

```
A <- c(4, 5, 6)
```

```
B <- c(2, 4, 6)
```

```
setdiff(A, B)
```

```
## [1] 5
```

🤖 Von der Menge A die Menge B abziehen, ist etwas anderes, als von B die Menge A abziehen.

🔥 Vorsicht

$$A \setminus B \neq B \setminus A.$$

```
setdiff(B, A)
```

```
## [1] 2
```

Übungsaufgabe 4.6 (B minus A ?). Berechnen Sie $B \setminus A$. $\square^{22}$

Übungsaufgabe 4.7 (Peer Instruction: Das Komplementärereignis von der Bestnote). Sie haben eine Statistiklausur bestanden. Mit Bestnote. Genauer gesagt, haben Sie 100 von 100 Punkten erzielt. Was ist das Komplementärereignis dazu?

A) 99 Punkte

B) 0 Punkte

4 Hallo, Wahrscheinlichkeit

- C) 0-99 Punkte
- D) 0-100 Punkte
- E) durchgefallen
- F) keines der genannten ☐

Nutzen Sie diese Animation zu Mengenoperationen²³ als weitere Veranschaulichung.

4.5 Zufallsvariable

4.5.1 Grundlagen

Beispiel 4.25. Schorsch sucht eine Betreuerin für seine Abschlussarbeit. An die ideale Betreuerin setzt er 4 Kriterien an: a) klare, schriftliche fixierte Rahmenbedingungen, b) viel Erfahrung, c) guten Ruf und d) interessante Forschungsinteressen. Je mehr dieser 4 Kriterien erfüllt sind, desto besser. Schorsch geht davon aus, dass die 4 Kriterien voneinander unabhängig sind (ob eines erfüllt ist oder nicht, ändert nichts an der Wahrscheinlichkeit, dass ein anderes Kriterium erfüllt ist). Schorsch interessiert sich also für die *Anzahl* der erfüllten Kriterien, also eine Zahl von 0 bis 4. Er schätzt die Wahrscheinlichkeit für einen „Treffer“ in jedem seiner 4 Kriterien auf 50 %. Viel Glück, Schorsch! Sein Zufallsexperiment hat 16 Ausgänge (Knoten 16 bis 31), s. Abbildung 4.20 und Tabelle 4.1. Ganz schön komplex. Eigentlich würden ihm ja eine Darstellung mit 5 Ergebnissen, also der „Gutachter-Score“ von 0 bis 4 ja reichen. Wie können wir die Sache übersichtlicher für Schorsch machen? Abbildung 4.20 ist ein Versuch. ☐

²³<https://seeing-theory.brown.edu/compound-probability/index.html>

Tabelle 4.1: Schorsch's Zufallsexperiment, Auszug der 16 Elementarereignisse (EE)

i	Elementarereignis	Pr(EE)	Trefferzahl
1	NNNN	1/16	0
2	NNNT	1/16	1
3	NNTN	1/16	1
4	NTNN	1/16	1
...	...	...	...




Abbildung 4.20: Ein Baumdiagramm mit 16 Ausgängen, analog zur 4 Münzwürfen. T: Treffer (Kriterium erfüllt). N: Niete (Kriterium nicht erfüllt). NNNT wäre zum Beispiel eine Gutachterin ohne klar fixierte Rahmenbedingungen, ohne viel Erfahrung, mit schlechtem Ruf aber mit interessanten Forschungsinteressen.

Schorsch braucht also eine übersichtlichere Darstellung; die Zahl der Treffer und ihre Wahrscheinlichkeit würde ihm ganz reichen. In vielen Situationen ist man an der Anzahl der Treffer interessiert. Die Wahrscheinlichkeit für eine bestimmte Trefferanzahl bekommt man einfach durch Addieren der Wahrscheinlichkeiten der zugehörigen Elementarereignisse, s. Tabelle 4.1. Hier kommt die Zufallsvariable ins Spiel. Wir nutzen sie, um die Anzahl der Treffer in einem Zufallsexperiment zu zählen.

Definition 4.16 (Zufallsvariable). Die Zuordnung der Elementarereignisse eines Zufallsexperiments zu genau einer Zahl $\in \mathbb{R}$ nennt man Zufallsvariable. $\square$

4 Hallo, Wahrscheinlichkeit

Die den Elementarereignissen zugewiesenen Zahlen nennt man *Realisationen* oder *Ausprägungen* der Zufallsvariablen.

Beispiel 4.26 (Lotto). Ein Lottospiel hat ca. 14 Millionen Elementarereignisse. Die Zufallsvariable „Anzahl der Treffer“ hat nur 7 Realisationen: 0, 1, ..., 6. $\square$

Es hat sich eingebürgert, Zufallszahlen mit X zu bezeichnen (oder anderen Buchstaben weit hinten aus dem Alphabet). Man schreibt für eine Zufallsvariable kurz: $X : \Omega \rightarrow \mathbb{R}$. „ X ist eine Zufallsvariable, die jedem Elementarereignis ω eine reelle Zahl zuordnet.“ Um die Vorschrift der Zuordnung genauer zu bestimmen, kann man folgende Kurzschreibweise nutzen:

$$X(\omega) = \begin{cases} 1, & \text{wenn } \omega = \text{Kopf,} \\ 0, & \text{wenn } \omega = \text{Zahl.} \end{cases}$$

Abbildung 4.21 stellt diese Abbildung dar.




Abbildung 4.21: Eine Zufallsvariable ist eine Zuordnung der Ereignisse zu einer reellen Zahl (nach einer bestimmten Regel)

Zufallsvariablen kann man in zwei Arten einteilen:

1. diskrete Zufallsvariablen
2. stetige Zufallsvariablen

4.5.2 Diskrete Zufallsvariable

4.5.2.1 Grundlagen

Eine diskrete Zufallsvariable ist dadurch gekennzeichnet, dass nur bestimmte Realisationen möglich sind, zumeist natürliche Zahlen, wie 0, 1, 2,..., . Abbildung 4.22 versinnbildlicht die Zufallsvariable des „Gutachter-Scores“, s. Beispiel 4.25.




Abbildung 4.22: Sinnbild einer diskreten Zufallsvariablen X für Schorschs Suche nach einer Betreuerin seiner Abschlussarbeit. X gibt den Score der Gutachterin wider.

Beispiel 4.27 (Diskrete Zufallsvariablen).

- Anzahl der Bewerbungen bis zum ersten Job-Interview
- Anzahl Anläufe bis zum Bestehen der Statistik-Klausur
- Anzahl der Absolventen an der HS Ansbach pro Jahr
- Anzahl Treffer beim Kauf von Losen
- Anzahl Betriebsunfälle
- Anzahl der Produkte in der Produktpalette $\square$

Beispiel 4.28 (Wahrscheinlichkeitsverteilung eines einfachen Würfelwurfs). Abbildung 4.23 zeigt die Wahrscheinlichkeitsverteilung eines einfachen Würfelwurfs. $\square$




Abbildung 4.23: Wahrscheinlichkeitsverteilung eines einfachen Würfelwurfs, Bildrechte: Olex Alexandrov, Wikipedia, PD

Beispiel 4.29. Der zweifache Würfelwurf ist ein typisches Lehrbuchbeispiel für eine diskrete Zufallsvariable.²⁴ Hier ist S ²⁵ die Augensumme des zweifachen Würfelwurfs und S ist eine Zahl zwischen 2 und 12. Für jede Realisation $X = x$ kann man die Wahrscheinlichkeit berechnen, Abbildung 4.24 versinnbildlicht die Wahrscheinlichkeit für jede Realisation von X . $\square$

²⁴da einfach und deutlich

²⁵S wie Summe

4 Hallo, Wahrscheinlichkeit




Abbildung 4.24: Augensumme des zweifachen Würfelwurfs; für jede Realisation von S ist die zugehörige Wahrscheinlichkeit dargestellt. Bildquelle: Tim Stellmach, Wikipedia, PD

Wahrscheinlichkeitsverteilungen dienen dazu, den Realisationen einer Zufallsvariablen eine Wahrscheinlichkeit zuzuordnen.

Definition 4.17 (Diskrete Wahrscheinlichkeitsverteilung). Eine diskrete Wahrscheinlichkeitsverteilung der (diskreten) Zufallsvariablen X ordnet jeder der k Ausprägungen $X = x$ eine Wahrscheinlichkeit p zu. $\square$

Beispiel 4.30 (Wahrscheinlichkeit des Geschlechts bei der Geburt). So hat die Variable *Geschlecht eines Babys* die beiden Ausprägungen *Mädchen* und *Junge* mit den Wahrscheinlichkeiten $p_M = 48.8\%$ bzw. $p_J = 51.2\%$, laut einer Studie (Gelman et al., 2021). $\square$

Zwischen der deskriptiven Statistik und der Wahrscheinlichkeitstheorie bestehen enge Parallelen, Tabelle 4.2 stellt einige zentrale Konzepte gegenüber. Bei einer guten Stichprobe kann man die Kennwerte der deskriptiven Statistik als Schätzwerte für die zugrundeliegende Wahrscheinlichkeit verwenden.

Tabelle 4.2: Gegenüberstellung von Wahrscheinlichkeitstheorie und deskriptiver Statistik

Wahrscheinlichkeitstheorie	Deskriptive Statistik
Zufallsvariable	Merkmal

Wahrscheinlichkeit	relative Häufigkeit, Anteil
Wahrscheinlichkeitsverteilung	einfache relative Häufigkeitsverteilung
Verteilungsfunktion	kumulierte relative Häufigkeitsverteilung
Erwartungswert	Mittelwert
Varianz	Varianz

Eine *Verteilung* zeigt, welche Ausprägungen eine Variable aufweist und wie häufig bzw. wahrscheinlich diese sind. Einfach gesprochen veranschaulicht ein Balken- oder Histogramm eine Verteilung. Man unterscheidet Häufigkeitsverteilungen (s. Abb. Abbildung 4.26) von Wahrscheinlichkeitsverteilungen (Abb. Abbildung 4.25).




Abbildung 4.25: Wahrscheinlichkeitsverteilung der Zufallsvariable „Augenzahl im zweifachen Würfelwurf“




Abbildung 4.26: (relative und absolute) Häufigkeiten des zweifachen Würfelwurfs, 1000 Mal wiederholt

Beispiel 4.31. Die Wahrscheinlichkeitsverteilung für X „Augensumme im zweifachen Würfelwurf“ ist in Abbildung 4.25 visualisiert. $\square$

4.5.2.2 Vertiefung: Verteilungsfunktion

Definition 4.18 (Verteilungsfunktion). Die Verteilungsfunktion F gibt die Wahrscheinlichkeit an, dass die diskrete Zufallsvariable X eine Realisation annimmt, die kleiner oder gleich x ist. $\square$

Die Berechnung von $F(x)$ erfolgt, indem die Wahrscheinlichkeiten aller möglichen Realisationen x_i , die kleiner oder gleich dem vorgegebenen Realisationswert x sind, addiert werden:

$$F(x) = \sum_{x_i \leq x} Pr(X = x_i).$$

Die Verteilungsfunktion ist das Pendant zur *kumulierten Häufigkeitsverteilung*, vgl. Abbildung 4.27 und Abbildung 4.28: Was die kumulierte Häufigkeitsverteilung für Häufigkeiten ist, ist die Verteilungsfunktion für Wahrscheinlichkeiten.




Abbildung 4.27: Verteilungsfunktion $F(X \leq x_i)$ für die Zufallsvariable „Augenzahl im zweifachen Würfelwurf“




Abbildung 4.28: Empirische Verteilungsfunktion (kumulierte Häufigkeitsverteilung) $F(X \leq x_i)$ von 1000 zweifachen Münzwürfen

4.5.3 Stetige Zufallsvariablen

4.5.3.1 Grundlagen

Abbildung 4.29 versinnbildlicht die stetige Zufallsvariable „Körpergröße“, die (theoretisch, in Annäherung) jeden beliebigen Wert zwischen 0 und (vielleicht) 2 Meter annehmen kann.




Abbildung 4.29: Sinnbild für eine stetige Zufallsvariable X „Körpergröße“

Definition 4.19 (Stetige Zufallsvariable). Eine stetige Zufallsvariable gleicht einer diskreten, nur dass alle Werte im Intervall erlaubt sind. $\square$

Beispiel 4.32.

- Spritverbrauch
- Körpergewicht von Professoren
- Schnabellängen von Pinguinen
- Geschwindigkeit beim Geblitztwerden $\square$

Übungsaufgabe 4.8 (Warten auf den Bus, 42 Sekunden). Sie stehen an der Bushaltestelle und warten auf den Bus. Langweilig. Da kommt Ihnen ein Gedanken in den Sinn: Wie hoch ist wohl die Wahrscheinlichkeit, dass Sie *exakt* 42 Sekunden auf den Bus warten müssen, s. Abbildung 4.31? Weiterhin überlegen Sie, dass davon auszugehen ist, dass jede Wartezeit zwischen 0 und 10 Minuten gleich wahrscheinlich ist. Spätestens nach 10 Minuten kommt der Bus, so ist die Taktung (extrem zuverlässig). Exakt heißt *exakt*, also nicht 42.1s, nicht 42.01s, nicht 42.001s, etc. bis zur x -ten Dezimale. $\square$

Nicht so einfach (?). Hingegen ist die Frage, wie hoch die Wahrscheinlichkeit ist, zwischen 0 und 5 Minuten auf den Bus zu warten ($0 < x < 5$), einfach: Sie beträgt 50 %, wie man in Abbildung 4.30 gut sehen kann.




Abbildung 4.30: Wie groß ist die Wahrscheinlichkeit, zwischen 0 und 5 Minuten auf den Bus zu warten? 50 Prozent!




Abbildung 4.31: Wie groß ist die Wahrscheinlichkeit, genau 42 Sekunden auf den Bus zu warten? Hm.

Vergleicht man Abbildung 4.31 und Abbildung 4.30 kommt man (vielleicht) zu dem Schluss, dass die Wahrscheinlichkeit exakt 42s auf den Bus zu warten, praktisch Null ist. Der Grund ist, dass die Fläche des Intervalls gegen Null geht, wenn das Intervall immer schmaler wird. Aus diesem Grund kann man bei stetigen Zufallszahlen nicht von einer Wahrscheinlichkeit eines bestimmten Punktes $X = x$ sprechen. Für einen bestimmten Punkt $X = x$ kann man aber die *Dichte* der Wahrscheinlich-

4 Hallo, Wahrscheinlichkeit

keit angeben.

Was gleich ist in beiden Situationen ($Pr(X = .42)$ und $Pr(0 < x < 0.5)$) ist die *Wahrscheinlichkeitsdichte*, f . In Abbildung 4.31 und Abbildung 4.30 ist die Wahrscheinlichkeitsdichte gleich, $f = 1/10 = 0.1$.

Definition 4.20 (Wahrscheinlichkeitsdichte). Die Wahrscheinlichkeitsdichte $f(x)$ gibt an, wie viel Wahrscheinlichkeitsmasse pro Einheit von X an der Stelle x ist. $\square$

Die Wahrscheinlichkeitsdichte zeigt an, an welchen Stellen x die Wahrscheinlichkeit besonders „geballt“ oder „dicht“ sind, s. Abbildung 4.32.




Abbildung 4.32: Die Wahrscheinlichkeit, dass eine Zufallsvariable einen Wert in einem bestimmten Intervall annimmt, entspricht dem Inhalt der Fläche unter dem Graphen der Wahrscheinlichkeitsdichtefunktion.

Bei *stetigen* Zufallsvariablen X geht man von unendlich vielen Ausprägungen aus; die Wahrscheinlichkeit einer bestimmten Ausprägung ist Null: $Pr(X = x_j) = 0$, $j = 1, \dots, +\infty$

Beispiel 4.33 (Wahrscheinlichkeitsverteilung für die Körpergröße). So ist die Wahrscheinlichkeit, dass eine Person exakt 166,66666666... cm groß ist, (praktisch) Null. Man gibt stattdessen die *Dichte* der Wahrscheinlichkeit an: Das ist die Wahrscheinlichkeit(smasse) pro Einheit von X . $\square$

Für praktische Fragen berechnet man zumeist die Wahrscheinlichkeit von Intervallen, s. Abbildung 4.32.

4.5.3.2 Vertiefung: Verteilungsfunktion

Definition 4.21 (Verteilungsfunktion). Die Verteilungsfunktion einer stetigen Zufallsvariablen gibt wie im diskreten Fall an, wie groß die Wahrscheinlichkeit für eine Realisation kleiner oder gleich einem vorgegebenen Realisationswert x ist. $\square$

Die Verteilungsfunktion $F(x)$ ist analog zur kumulierten Häufigkeitsverteilung zu verstehen, vgl. Abbildung 4.33. $\square$




Abbildung 4.33: Verteilungsfunktion F für X = „Wartezeit auf den Bus“

Übungsaufgabe 4.9 (Peer Instruction: Wieder auf den Bus warten). Sie warten wieder auf den Bus, s. Abbildung 4.30. Welche Aussage dazu ist falsch?

- A) Die Wahrscheinlichkeit, genau 5 Minuten zu warten, ist am höchsten.
- B) Die Wahrscheinlichkeit, genau 10 Minuten zu warten, ist Null.
- C) Mit 100 % Wahrscheinlichkeit beträgt die Wartezeit zwischen 0 und 10 Minuten.
- D) Die Wahrscheinlichkeit, höchstens 1 Minute zu warten, beträgt 10 %. $\square$

4.6 Aufgaben

Die Webseite datenwerk.netlify.app stellt eine Reihe von einschlägigen Übungsaufgaben bereit. Sie können die Suchfunktion der Webseite nutzen, um die Aufgaben mit den folgenden Namen zu suchen.

4.6.1 Paper-Pencil-Aufgaben

- prob-voll-esystem
- prob-disjunkt
- prob-disjunkt2
- prob-elementarereignis
- prob-vereinigung
- prob-ereignisraum
- prob-sicher-unmöglich
- indifferenz-p

4.6.2 Aufgaben, für die man einen Computer braucht

- penguins-relationen
- penguins-relationen2
- verteilungsfunktion-penguins

5 Rechnen mit Wahrscheinlichkeit

5.1 Lernsteuerung

Die Rechenregeln der Wahrscheinlichkeit erlauben es, für bestimmte Situationen eine Wahrscheinlichkeit zu berechnen. Das hört sich vielleicht wild an, ist aber oft ganz einfach. Dieses Kapitel stellt uns dafür einige grundlegende Rechengesetze für Wahrscheinlichkeiten vor: Zum Beispiel, wann man die Wahrscheinlichkeiten zweier Ereignisse addiert oder multipliziert. Außerdem lernen wir den Begriff der Unabhängigkeit kennen.

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- die Grundbegriffe der Wahrscheinlichkeitsrechnung erläuternd definieren
- typische Relationen (Operationen) von Ereignissen anhand von Beispielen veranschaulichen
- mit Wahrscheinlichkeiten rechnen

5.2 Additionssatz

Beispiel 5.1 (Wahrscheinlichkeit für eine gerade Zahl beim Würfelwurf). Ein (normaler) Würfel wird geworfen. Was ist die Wahrscheinlichkeit für eine gerade Zahl, also für das Ereignis $A = \{2, 4, 6\}$? Diese Wahrscheinlichkeit beträgt $Pr(\text{gerade Zahl}) = 1/6 + 1/6 + 1/6 = 3/6 = 1/2$. $\square$

Beispiel 5.2 (Gezinkter Würfel). Ein gezinkter Würfel hat eine erhöhte Wahrscheinlichkeit für das Ereignis $A = \text{„6 liegt oben“}$, und zwar gelte $Pr(A) = 1/3$. Was ist die Wahrscheinlichkeit, *keine* 6 zu würfeln? $\square^1$

¹Die Wahrscheinlichkeit, keine 6 zu würfeln, liegt bei $2/3$.

5.3 Vereinigung von Ereignissen: Additionssatz

Der Additionssatz wird verwendet, wenn wir an der Wahrscheinlichkeit bei der Vereinigung zweier Ereignisse interessiert sind. Also an der Wahrscheinlichkeit, dass *mindestens eines der Ereignisse* A und B eintritt. „Mindestens eines der Ereignisse A und B“ schreibt man $A \cup B$ und sagt „A vereinigt B“ oder auch „A oder B“.

5.3.1 Addition disjunkter Ereignisse

Gegeben sei $\Omega = \{1, 2, 3, 4, 5, 6\}$ beim normalen Würfelwurf. Als Sinnbild:

1	2	3	4	5	6
---	---	---	---	---	---

. Gesucht sei die Wahrscheinlichkeit des Ereignisses $A = \{1, 2\}$, das also eine 1 oder eine 2 geworfen wird, s. Abbildung 5.1. Man beachte, dass die beiden Ergebnisse disjunkt sind, s. Abbildung 4.6: Wenn man eine 1 wirft, hat man keine 2 geworfen.




Abbildung 5.1: 2 Ereignisse sind günstig; 4 sind nicht günstig.

Die Wahrscheinlichkeit für A ist die Summe der Wahrscheinlichkeiten der einzelnen Ereignisse (1 und 2):

$$Pr(1 \cup 2) = \frac{1}{6} + \frac{1}{6} = \frac{2}{6}$$

Visuell ausgedrückt:



Definition 5.1 (Additionssatz für disjunkte Ereignisse). Die Wahrscheinlichkeit, dass mindestens eines der beiden Ereignisse eintritt, ist die Summe der Einzelwahrscheinlichkeiten, s. Theorem 5.1.

Theorem 5.1 (Additionssatz für disjunkte Ereignisse).

$$Pr(A \cup B) = Pr(A) + Pr(B) \square$$

Beispiel 5.3. Was ist die Wahrscheinlichkeit, an einem Samstag oder Sonntag geboren zu sein? Unter der (vereinfachten) Annahme, dass alle Jahre zu gleichen Teilen aus allen Wochentagen bestehen und dass an allen Tagen gleich viele Babies geboren werden², ist die Antwort $Pr(A) = 1/7 + 1/7 = 2/7$. $\square$

5.3.2 Addition allgemeiner Ereignisse

Unter *allgemeinen* Ereignissen verstehen wir hier sowohl disjunkte als auch nicht disjunkte. Bei der Addition der Wahrscheinlichkeiten für A und B wird der Schnitt $A \cap B$ (der Überlappungsbereich) *doppelt* erfasst – sofern sie nicht disjunkt sind, aber wenn sie disjunkt sind, so ist der Schnitt gleich Null und wir machen auch dann nichts falsch. Der Überlappungsbereich muss daher noch abgezogen werden, s. Abbildung 5.2.

Definition 5.2 (Allgemeiner Additionssatz). Die Wahrscheinlichkeit, dass mindestens eines der beiden Ereignisse A und B eintritt, ist gleich der Summe ihrer Wahrscheinlichkeiten minus ihrer gemeinsamen Wahrscheinlichkeit, s. Theorem 5.2 und Abbildung 5.2. $\square$

Theorem 5.2 (Allgemeiner Additionssatz).

$$Pr(A \cup B) = P(A) + P(B) - P(A \cap B) \square$$




Abbildung 5.2: Der allgemeine Additionssatz gibt die Wahrscheinlichkeit, dass mindestens eines der beiden Ereignisse eintritt.

Beispiel 5.4 (Lernen und Klausur bestehen). In einem Psychologie-Studiengang sind die Studis verdonnert, zwei Statistik-Module ($S1, S2$) zu belegen. Die meisten bestehen (B), einige leider nicht (N), s. Tabelle 5.1.

²vermutlich gibt es noch mehr Annahmen, die wir uns explizit machen sollten.

5 Rechnen mit Wahrscheinlichkeit

Tabelle 5.1: Daten von 100 Studis; L: Lerner, B: Bestanden, N: Negation/Nicht

.	S1_B	S1_NB	Summe
S2_B	85	9	94
S2_NB	5	1	6
Summe	90	10	100

Ereignis $S_1 B$ sei „Klausur Statistik 1 bestanden“. Ereignis $S_2 B$ ist analog für „Klausur Statistik 2“.

Wir suchen die Wahrscheinlichkeit des Ereignisses A, d. h. mindestens eine der beiden Klausuren zu bestehen: $Pr(A) = Pr(S_1 B \cup S_2 B)$.

$$Pr(A) = Pr(S_1 B \cup S_2 B) \quad (5.1)$$

$$= Pr(S_1 B) + Pr(S_2 B) - Pr(S_1 B \cap S_2 B) \quad (5.2)$$

$$= (90 + 94 - 85)/100 = 99/100 \quad (5.3)$$

$$(5.4)$$

Die Wahrscheinlichkeit, mindestens eine der beiden Klausuren zu bestehen, liegt bei 99%.

Übungsaufgabe 5.1 (Peer Instruction: Keine Klausur bestanden). Wie hoch ist die Wahrscheinlichkeit, keine der beiden Klausuren zu bestehen?

- A) 1 %
- B) 5 %
- C) 6 %
- D) 9 %
- E) 10 %
- F) 16 % ☐

5.4 Bedingte Wahrscheinlichkeit


5.4.1 Illustration zur bedingten Wahrscheinlichkeit

Definition 5.3 (Bedingte Wahrscheinlichkeit). Die bedingte Wahrscheinlichkeit ist die Wahrscheinlichkeit, dass A eintritt, *gegeben dass* B schon eingetreten ist. $\square$


Man schreibt: $Pr(A|B)$. Lies: „A gegeben B“ oder „A wenn B“.

Übungsaufgabe 5.2. Schauen Sie sich mal diese Animation von Victor Powell an³ zu bedingten Wahrscheinlichkeiten an. Sehenswert. $\square$


Abbildung 5.3 illustriert *gemeinsame Wahrscheinlichkeit*, $Pr(A \cap B)$, und *bedingte Wahrscheinlichkeit*, $Pr(A|B)$.



(a) unbedingte Wahrscheinlichkeit für Ereignis B: 50%



(b) unbedingte Wahrscheinlichkeit für Ereignis A: 50%



(c) Wahrscheinlichkeit für Ereignis B gegeben A, $Pr(B|A)$: 50%

Abbildung 5.3: Illustration von gemeinsamer und bedingter Wahrscheinlichkeit

³<https://setosa.io/conditional/>

5 Rechnen mit Wahrscheinlichkeit

Beispiel 5.5 (Bedingte Wahrscheinlichkeit). Sei A „Schönes Wetter“ und B „Klausur steht an“. Dann meint $Pr(A|B)$ die Wahrscheinlichkeit, dass das Wetter schön ist, wenn gerade eine Klausur ansteht. $\square$

Beispiel 5.6 (Von Päpsten und Männern). Man(n) beachte, dass die Wahrscheinlichkeit, Papst P zu sein, wenn man Mann M ist *etwas anderes* ist, als die Wahrscheinlichkeit, Mann zu sein, wenn man Papst ist: $Pr(P|M) \neq Pr(M|P)$. Das hört sich erst verwirrend an, aber wenn man darüber nachdenkt, wird es plausibel. $\square$

Beispiel 5.7. Gustav Groß-Gütz verkauft eine Tinktur⁴, die schlau machen soll, „Gützis Gehirn Grütze“.⁵ Gustav trinkt die Grütze und sagt schlaue Dinge. Was schließen wir daraus? Sei H (wie Hypothese) „Gützis Grütze macht schlau“; sei D (wie Daten) die Beobachtung, dass Gustav schlaue Dinge gesagt hat. Ohne exakte Zahlen zu suchen, wie hoch ist wohl $Pr(D|H)$? In Worten: „Wie wahrscheinlich ist es, schlaue Dinge gesagt zu haben, wenn die Grütze wirklich schlau macht?“. Vermutlich ist diese Wahrscheinlichkeit sehr hoch. Aber wie hoch ist wohl $Pr(H|D)$? In Worten: „Wie wahrscheinlich ist es, dass die Grütze wirklich schlau macht, gegeben, dass wir gesehen haben, dass jemand etwas schlaues gesagt hat, nachdem er besagte Grütze getrunken hat?“ Skeptische Geister werden der Meinung sein, $Pr(H|D)$ ist gering. Das Beispiel zeigt u. a. $Pr(H|D) \neq Pr(D|H)$. $\square$

5.4.2 Bedingte Wahrscheinlichkeit als Filtern einer Tabelle

Beispiel 5.8.

Das Berechnen einer bedingten Wahrscheinlichkeit, $Pr(A|B)$, ist vergleichbar zum Filtern einer Tabelle, s. Tabelle 5.2.

Tabelle 5.2: Eine bedingte Wahrscheinlichkeit kann man als gefilterte Tabelle verstehen

id	kalt	Regen
1	0	0
2	0	1
3	1	0

⁴genauer besehen sieht sie eher aus wie eine Grütze oder ein Brei

⁵Sie schmeckt scheußlich.

Tabelle 5.2: Eine bedingte Wahrscheinlichkeit kann man als gefilterte Tabelle verstehen

id	kalt	Regen
4	1	1
SUMME	2	2

Es ergeben sich folgende Wahrscheinlichkeiten:

$$Pr(A) = 2/4; Pr(B) = 2/4;$$

$$Pr(A \cap B) = 1/4; Pr(A|B) = 1/2$$

Gleichung 5.5 versinnbildlicht die Berechnung von $Pr(A|B) = 1/2$ als Bruch: Das Verhältnis der Flächen von Zähler und Nenner ist 1 zu 2.

$$\frac{\text{Fläche von } A \cap B}{\text{Fläche von } B} = \frac{1}{2} \quad (5.5)$$

Die Wahrscheinlichkeit für A , wenn B schon eingetreten ist, berechnet sich so, s. Theorem 5.3 und Abbildung 5.4.




Abbildung 5.4: Wahrscheinlichkeit für Ereignis B gegeben A, $Pr(B|A) = 1/2$

Theorem 5.3 (Bedingte Wahrscheinlichkeit).

$$Pr(A|B) = \frac{Pr(A \cap B)}{Pr(B)}$$

5 Rechnen mit Wahrscheinlichkeit

Außerdem gilt analog

$$Pr(B|A) = \frac{Pr(B \cap A)}{Pr(A)} \quad \square$$

Beispiel 5.9 (Lernen und Klausur bestehen). Sie bereiten sich gerade auf die Klausur bei Prof. Süß vor. Das heißt: Sie überlegen, ob Sie sich auf die Klausur vorbereiten sollten. Vielleicht lohnt es sich ja gar nicht? Vielleicht ist die Wahrscheinlichkeit zu bestehen, wenn man nicht gelernt hat, sehr groß? Aber da Sie nun mal auf Fakten stehen, haben Sie sich nach einiger Recherche folgende Zahlen besorgen können, s. Tabelle 5.3. In der Tabelle sind die Daten von 100 Studis ausgewiesen. Ein Teil hat sich vorbereitet, ordentlich gelernt, nennen wir sie die „Lerner“. Ein anderer Teil hat nicht gelernt, NL bzw. $\neg L$. Ein Teil hat bestanden, B , ein Teil nicht NB oder $\neg B$.

Wir suchen die Wahrscheinlichkeit, zu bestehen, wenn man nicht gelernt hat: $Pr(B|\neg L)$.

Tabelle 5.3: Daten von 100 Studis; L: Lerner, B: Bestanden, N: Negation/Nicht

.	L	NL	Summe
B	80	1	81
NB	5	14	19
Summe	85	15	100

$$Pr(B|\neg L) = \frac{Pr(B \cap \neg L)}{Pr(\neg L)} \quad (5.6)$$

$$= \frac{1/100}{15/100} = 1/15 \quad (5.7)$$

$$(5.8)$$

Die Wahrscheinlichkeit, zu bestehen, wenn man nicht gelernt hat, liegt bei 1 von 15, also ca. 7%.⁶ $\square$

⁶ $Pr(L) = .85; Pr(\neg L) = .15; Pr(B) = .81; Pr(\neg B) = .19$

Beispiel 5.10 (Kalt wenn Regen). Die Wahrscheinlichkeit, dass es kalt ist, wenn es regnet (gegeben, dass es regnet), ist gleich der Wahrscheinlichkeit, dass es gleichzeitig kalt ist und regnet, geteilt durch die Wahrscheinlichkeit, dass es regnet. $\square$

5.5 Stochastische (Un-)Abhängigkeit

5.5.1 Warum ist das wichtig?

In der Forschung und im Alltag sind wir oft daran interessiert, ob zwei Ereignisse voneinander abhängig sind oder nicht: Lernen und Klausur bestehen, Rauchen und Lungenkrebs, Impfung und Infektion, Werbung und Verkaufserfolg, usw.

5.5.2 Unabhängigkeit

Beispiel 5.11 (Unabhängigkeit).

- Regentanz und Regen sind unabhängig.
- „Es regnet in Berlin“ und „In Tokio fällt eine Münze auf Kopf“
- „Ich habe 10 Mal hintereinander Kopf geworfen“ und „Beim nächsten Mal werfe ich Kopf“ (bei einer fairen Münze)
- Augenfarbe und Blutgruppe
- Es regnet und ich gewinne im Lotto $\square$

Stochastische Unabhängigkeit ist ein Spezialfall von Abhängigkeit: Es gibt sehr viele Ausprägungen für Abhängigkeit, aber nur eine für Unabhängigkeit. Können wir Unabhängigkeit nachweisen, haben wir also eine *starke* Aussage getätigt.

Definition 5.4 (Stochastische Unabhängigkeit). Zwei Ereignisse sind (stochastisch) unabhängig voneinander, wenn die Wahrscheinlichkeit von A nicht davon abhängt, ob B der Fall ist, s. Theorem 5.4. Anders gesagt:⁷

⁷Exakte Gleichheit ist in dieser Welt empirisch schwer zu finden. Daher kann man vereinbaren, dass Unabhängigkeit erfüllt ist, wenn die Gleichheit „einigermaßen“ oder „ziemlich“ gilt, die Gleichheit gewissermaßen „praktisch bedeutsam“ ist.

5 Rechnen mit Wahrscheinlichkeit

Theorem 5.4 (Stochastische Unabhängigkeit). $Pr(A) = Pr(A|B) = Pr(A|\neg B)$ $\square$

In Worten: Wenn die Wahrscheinlichkeit von A sich nicht ändert, wenn B eingetreten ist, so ist A von B (stochastisch) unabhängig.

Die Unabhängigkeit von A und B wird manchmal so in Kurzschreibweise ausgedrückt: $\perp\!\!\!\perp (A, B)\square$.

Theorem 5.5 (Stochastische Unabhängigkeit 2). Setzt man Theorem 5.3 in Theorem 5.4 (linke Seite) ein, so folgt⁸

$$Pr(A \cap B) = Pr(A) \cdot Pr(B). \quad \square$$

In Worten: Die Wahrscheinlichkeit, dass A und B beide der Fall sind, ist gleich dem Produkt ihrer jeweiligen Wahrscheinlichkeiten.

Beispiel 5.12 (Augenfarbe und Statistikliebe). Ich vermute, dass die Ereignisse A, „Augenfarbe ist blau“, und B, „Ich liebe Statistik“, voneinander unabhängig sind. $\square$ ⁹

Beispiel 5.13 (Überleben auf der Titanic). S. Abbildung 5.5, links: Überleben (Ü) auf der Titanic ist offenbar *abhängig* von der Passagierklasse (K_1, K_2, K_3). In Abbildung 5.5, links gilt also $Pr(|K_1) \neq Pr(|K_2) \neq Pr(|K_3) \neq Pr()$.


Auf der anderen Seite: Das Ereignis Überleben (Ü) auf der Titanic ist *unabhängig* vom Ereignis Alter ist eine Primzahl (P), s. Abbildung 5.5, rechts. Also: $Pr(|P) = Pr(|\neg P) = Pr()$, vgl. Tabelle 5.4.

⁸Vgl. Theorem 5.9

⁹Wer Daten dazu hat oder eine Theorie, der melde sich bitte bei mir.

Tabelle 5.4: Kontingenztafel (Häufigkeiten) für ‚Überleben auf der Titanic‘ und ‚Alter ist Primzahl‘. Wie man sieht, gibt es keine stochastische Abhängigkeit.

Age_prime	n	prop
0		
non-prime	96	0.17
prime	453	0.83
1		
non-prime	58	0.17
prime	282	0.83



(a) Überleben und Passagierklasse sind abhängig

(b) Überleben und ‚Geburtsdatum ist eine Primzahl‘ sind nicht abhängig

Abbildung 5.5: Abhängigkeit und Unabhängigkeit zweier Ereignisse

5.5.3 Stochastische Abhängigkeit

Liegt keine Unabhängigkeit vor, so spricht man von (stochastischer) *Abhängigkeit*, s. Theorem 5.6. In diesem Fall verändert sich unser Wissen über die Wahrscheinlichkeit von A , wenn wir wissen, dass B eingetroffen ist, s. Theorem 5.6.

Theorem 5.6 (Stochastische Abhängigkeit).

$$Pr(A|B) \neq Pr(A) \neq Pr(A|\neg B) \quad \square$$

5 Rechnen mit Wahrscheinlichkeit

In Worten: Ändert sich die Wahrscheinlichkeit von A, wenn B der Fall ist, so sind A und B voneinander (stochastisch) abhängig.


Theorem 5.6 gilt natürlich in dieser Form für alle anderen Variablen ebenso, s. z. B. Theorem 5.7. $\square$

Theorem 5.7 (Stochastische Abhängigkeit 2).

$$Pr(B|A) \neq Pr(B) \neq Pr(B|\neg A) \quad \square$$

Beispiel 5.14. Die Ereignisse „Lernen“ und „Klausur bestehen“ seien voneinander abhängig. Unsere Einschätzung zur Wahrscheinlichkeit von K ändert sich, wenn wir wissen, dass L vorliegt. Genauso wird sich unsere Einschätzung zur Wahrscheinlichkeit von K ändern, wenn wir wissen, dass L nicht vorliegt. $\square$

Beispiel 5.15 (Zusammenhang von Covidsterblichkeit und Impfquote). Sind die Ereignisse Tod durch Covid (T) bzw. Impfquote (I) und Land¹⁰ (B) voneinander abhängig (s. Abbildung 5.6)?



(a) Impfquote und Land sind voneinander abhängig

(b) Anteil Corona-Tote und Land sind voneinander abhängig

Abbildung 5.6: Impfquote und Sterblichkeit sind voneinander abhängig (bezogen auf Covid, auf Basis vorliegender Daten)

Ja, die beiden Ereignisse sind abhängig, da in beiden Diagrammen gilt: $Pr(A|B) \neq Pr(A) \neq Pr(A|\neg B)$. $\square^{11}$

¹⁰hier mit den zwei Ausprägungen DEU und USA

¹¹Daten von Our World in Data, <https://ourworldindata.org/covid-deaths>.

5.5.4 Unabhängigkeit ist symmetrisch

Stochastische Unabhängigkeit ist symmetrisch: Wenn A unabhängig zu B ist, ist auch B unabhängig zu A , s. Theorem 5.8.

Theorem 5.8 (Symmetrie der Unabhängigkeit).

$$Pr(A|B) = Pr(A) \leftrightarrow Pr(B|A) = Pr(B)$$

Man beachte, dass stochastische Unabhängigkeit und kausale Unabhängigkeit unterschiedliche Dinge sind (Henze, 2019): Stochastische Unabhängigkeit impliziert nicht kausale Unabhängigkeit. $\square$

Übungsaufgabe 5.3 (Peer Instruction: Welche Aussagen über stochastische Unabhängigkeit ist korrekt?).

1. Wenn X und Y unabhängig sind, dann hat X keinen Einfluss auf Y im Alltag.
2. Zwei Ereignisse A und B sind unabhängig, wenn sie sich nicht überschneiden.
3. Wenn X und Y unkorreliert sind, dann sind sie unabhängig.
4. Wenn X und Y abhängig sind, dann können sie nicht gleichzeitig positive Korrelation haben.
5. Wenn X und Y unabhängig sind, sind sie auch unkorreliert.

5.6 Wahrscheinlichkeit gemeinsamer Ereignisse: Multiplikationssatz

Gegeben seien die Ereignisse A und B . Der Multiplikationssatz wird verwendet, wenn wir an der Wahrscheinlichkeit interessiert sind, dass *beide Ereignisse* A und B der Fall sind; man spricht auch von der *gemeinsamen Wahrscheinlichkeit*. Abbildung 5.7 verdeutlicht dies für zwei unabhängige Ereignisse. Man schreibt „ A und B “ als $A \cap B$ (lies „ A geschnitten B “ oder „ A und B “) oder kurz AB , um anzuzeigen, dass sowohl A als auch B eingetreten sind.

5 Rechnen mit Wahrscheinlichkeit




Abbildung 5.7: Beide Ereignisse A und B sind eingetreten

Beispiel 5.16 (Wieder kalt und Regen). Es ist eine Sache, zu fragen, wie wahrscheinlich es ist, dass es kalt ist (bei Kälte), wenn es regnet (bei Regen): $Pr(K|R)$. Anders gesagt: „Wie groß ist die Wahrscheinlichkeit für Kälte, gegeben dass es regnet?“ Eine andere Sache ist es, nach der Wahrscheinlichkeit zu fragen, dass es gleichzeitig kalt ist und regnet, dass also beide Ereignisse (kalt und Regen) eintreten: $Pr(K \cap R), Pr(KR)$. $\square$

5.6.1 Gemeinsame Wahrscheinlichkeit unabhängiger Ereignisse

Beispiel 5.17. Wir führen das Zufallsexperiment „Wurf einer fairen Münze“ zwei Mal aus (Abbildung 5.8). Wie groß ist die Wahrscheinlichkeit, 2 Mal Kopf zu werfen? Dabei vereinbaren wir, dass „Kopf“ als „Treffer“ zählt (und „Zahl“ als „Niete“). $\square$




Abbildung 5.8: Wir werfen zwei faire Münzen: Zweifach wiederholtes Zufallsexperiment

5.6 Wahrscheinlichkeit gemeinsamer Ereignisse: Multiplikationssatz

Tabelle 5.5: Wahrscheinlichkeiten der Ereignisse im zweimaligen Münzwurf

Ereignis	Pr	Anzahl günstiger Pfade
OT	$1/2 * 1/2 = 1/4$	1
1T	$1/4 + 1/4 = 1/2$	2
2T	$1/2 * 1/2 = 1/4$	1

Abbildung 5.8 zeigt ein *Baumdiagramm*. Jeder Kasten (Knoten) zeigt ein *Ergebnis* des Zufallsexperiments. Die Pfeile (Kanten) symbolisieren die Abfolge des Experiments: Vom „Start“ (schwarzer Kreis) führen zwei mögliche Ergebnisse ab, jeweils mit Wahrscheinlichkeit $1/2$. Die untersten Knoten nennt man auch *Blätter* (Endknoten), sie zeigen das *Ergebnis* des (in diesem Fall) zweifachen Münzwurfs. Der Weg vom Start zu einem bestimmten Blatt nennt man *Pfad*. Die Anzahl der Pfade entspricht der Anzahl der Blätter. In diesem Diagramm gibt es vier Pfade (und Blätter).

Den Wurf der ersten Münze nennen wir in gewohnter Manier A ; den Wurf der zweiten Münze B .

Die Wahrscheinlichkeiten der resultierenden Ereignisse finden sich in Tabelle 5.5.

Sei K_1 das Ereignis, mit der 1. Münze Kopf zu werfen; sei K_2 das Ereignis, mit der 2. Münze Kopf zu werfen.

Wir suchen $Pr(K_1 \cap K_2)$. Aufgrund der stochastischen Unabhängigkeit der beiden Ereignisse gilt: $Pr(K_1 \cap K_2) = Pr(K_1) \cdot Pr(K_2)$.

```
Pr_K1K2 <- 1/2 * 1/2
Pr_K1K2
## [1] 0.25
```

Definition 5.5 (Multiplikationssatz der Wahrscheinlichkeit für unabhängige Ereignisse). Die Wahrscheinlichkeit, dass zwei (oder mehr) unabhängige Ereignisse A und B *gemeinsam* eintreten, ist gleich dem Produkt ihrer jeweiligen Wahrscheinlichkeiten, s. Theorem 5.9. $\square$

Theorem 5.9 (Multiplikationssatz für unabhängige Ereignisse).

$$Pr(A \cap B) = Pr(A) \cdot Pr(B)$$

5 Rechnen mit Wahrscheinlichkeit

Man beachte, dass es egal ist, ob A gemeinsam mit B oder B gemeinsam mit A eintreten: $Pr(A \cap B) = Pr(B \cap A)$. Man spricht in diesem Zusammenhang von der Symmetrie der Multiplikation. $\square$

Mit dieser App¹² können Sie das Baumdiagramm für den zweifachen Münzwurf näher erkunden.

Wir führen das Zufallsexperiment „Wurf einer fairen Münze“ drei Mal aus (Abbildung 5.9). Dabei vereinbaren wir wieder, dass „Kopf“ (K) als „Treffer“ gilt und „Zahl“ (Z) als „Niete“.




Abbildung 5.9: Wir werfen drei faire Münzen: Das dreifach wiederholte binäre Zufallsexperiment

Beim Wurf von „fairen“ Münzen gehen wir davon aus, dass Kenntnis des Ergebnisses des 1. Wurfes unsere Einschätzung des Ergebnisses des 2. Wurfes nicht verändert etc. Anders gesagt: Wir gehen von (stochastischer) Unabhängigkeit aus.

Für z. B. das Ereignis $A = \{ZZZ\}$ gilt: $Pr(A) = 1/2 \cdot 1/2 \cdot 1/2 = (1/2)^3$. Da jeder Endknoten (jedes Blatt) gleichwahrscheinlich ist, ist die Wahrscheinlichkeit jedes Endknotens gleich.

Allgemeiner gilt: Für ein Zufallsexperiment, das aus k Wiederholungen besteht und in jeder Wiederholung die Wahrscheinlichkeit $Pr(X) = p$ ist, so ist die Wahrscheinlichkeit für einen Endknoten $Pr(X^k) = p^k$.

Da die Endknoten disjunkte Elementarereignisse sind, kann man ihre Wahrscheinlichkeit addieren, um zu anderen (zusammengesetzten) Ereignissen zu kommen, vgl. Tabelle 5.6.

¹²<https://www.geogebra.org/m/gzxz57ak>

5.6 Wahrscheinlichkeit gemeinsamer Ereignisse: Multiplikationssatz

Tabelle 5.6: Ausgewählte Wahrscheinlichkeiten von Ereignissen im dreifachen Münzwurf

Ereignis	Pr	Anzahl günstiger Pfade
0T	$1/2 * 1/2 * 1/2 = 1/8$	1
1T	$1/8 + 1/8 + 1/8 = 3/8$	3
2T	$3 * 1/8 = 3/8$	3
3T	$1/2 * 1/2 * 1/2 = 1/8$	1

Abbildung 5.3 versinnbildlicht nicht nur die Bedingtheit zweier Ereignisse, sondern auch die (Un-)Abhängigkeit zweier Ereignisse, A und B . In diesem Fall ist die Wahrscheinlichkeit von A gleich B : $Pr(A) = Pr(B) = .5$. Man sieht, dass die Wahrscheinlichkeit von A bzw. von B jeweils die Hälfte der Fläche (der Gesamtfläche, d.h. von $Pr(\Omega) = 1$) ausmacht. Die Schnittmenge der Fläche von A und B entspricht einem Viertel der Fläche: $Pr(AB) = Pr(A) \cdot Pr(B) = 50\% \cdot 50\% = 25\%$. In diesem Fall sind A und B unabhängig. Abbildung 5.3 zeigt weiterhin, dass gilt: $Pr(A \cap B) = P(A) \cdot P(B) = P(B) \cdot P(A)$. Man beachte, dass diese Formel nur bei *Unabhängigkeit* (von A und B) gilt.

5.6.2 Gemeinsame Wahrscheinlichkeit allgemeiner Ereignisse

Ein Baumdiagramm bietet sich zur Visualisierung allgemeiner abhängiger Ereignisse an, s. Abbildung 5.10.

Beispiel 5.18. In einer Urne befinden sich fünf Kugeln, von denen vier rot sind und eine blau ist.

Hier ist unsere Urne:

R, R, R, R, B

Wie groß ist die Wahrscheinlichkeit, dass bei zwei Ziehungen ohne Zurücklegen (ZOZ) zwei rote Kugeln gezogen werden (Bourier, 2011, S. 47)? Ereignis A: „Kugel im 1. Zug hat die Farbe Rot“. Ereignis B: „Kugel im 2. Zug hat die Farbe Rot“.

Und jetzt ziehen wir. Hier ist das Baumdiagramm, s. Abbildung 5.10.

5 Rechnen mit Wahrscheinlichkeit




Abbildung 5.10: Baumdiagramm für ein zweistufiges Zufallsereignis, wobei der 2. Zug (Stufe) abhängig ist vom 1. Zug.

Wie man in Abbildung 5.10 nachrechnen kann, gilt also: $Pr(A \cap B) = P(A) \cdot P(B|A) = 4/5 \cdot 3/4 = 12/20 = 3/5$ $\square$

Definition 5.6 (Gemeinsame Wahrscheinlichkeit). Die Wahrscheinlichkeit, dass zwei abhängige Ereignisse A und B *gemeinsam* eintreten, ist gleich dem Produkt der Wahrscheinlichkeit von A und der bedingten Wahrscheinlichkeit von B gegeben A , s. Theorem 5.10. $\square$

Theorem 5.10 (Gemeinsame Wahrscheinlichkeit).

$$Pr(A \cap B) = Pr(A) \cdot Pr(B|A) \quad \square$$

Allgemein ist die Wahrscheinlichkeit, dass zwei Ereignisse A und B gemeinsam eintreten, gleich dem Produkt der Wahrscheinlichkeit von B und der bedingten Wahrscheinlichkeit von A gegeben B , s. Theorem 5.10. Im Fall von Unabhängigkeit vereinfacht sich die Formel zu der in Theorem 5.9.

Beispiel 5.19 (Nochmal kalt und Regen). Von McElreath (2020) stammt diese Verdeutlichung der gemeinsamen Wahrscheinlichkeit. Was ist die Wahrscheinlichkeit für das gemeinsame Auftreten von *kalt* ❄️ und *Regen* 🌧️? Die Wahrscheinlichkeit für kalt und Regen ist die Wahrscheinlichkeit von Regen 🌧️, wenn's kalt ❄️ ist mal die Wahrscheinlichkeit von Kälte ❄️.

Ebenfalls gilt: Die Wahrscheinlichkeit für kalt und Regen ist die Wahrscheinlichkeit von Kälte ❄️, wenn's regnet 🌧️ mal die Wahrscheinlichkeit von Regen 🌧️.

5.6 Wahrscheinlichkeit gemeinsamer Ereignisse: Multiplikationssatz

Das Gesagte als Emoji-Gleichung ist in Gleichung 5.9 dargestellt.

$$Pr(\text{❄️ und ☁️}) = P(\text{❄️}) \cdot P(\text{☁️}|\text{❄️}) = P(\text{❄️}) \cdot P(\text{❄️}|\text{☁️}) \quad (5.9)$$

Man kann die „Gleichung drehen“¹³, s. Gleichung 5.10.

$$Pr(\text{❄️ und ☁️}) = P(\text{☁️ und ❄️}) \quad (5.10)$$

□

Beispiel 5.20 (Bertie Botts Bohnen jeder Geschmacksrichtung).

Sei bloß vorsichtig mit denen. Wenn sie sagen jede Geschmacksrichtung, dann meinen sie es auch – Du kriegst zwar alle gewöhnlichen wie Schokolade und Pfefferminz und Erdbeere, aber auch Spinat und Leber und Kutteln. George meint, er habe mal eine mit Popelgeschmack gehabt.“

– Ron Weasley zu Harry Potter¹⁴

In einem Beutel liegen $n = 20$ Bertie Botts Bohnen jeder Geschmacksrichtung. Uns wurde verraten, dass fast alle gut schmecken, also z. B. nach Schokolade, Pfefferminz oder Marmelade. Leider gibt es aber auch $x = 2$ furchtbar scheußliche Bohnen (Ohrenschmalz-Geschmacksrichtung oder Schlimmeres). Sie haben sich nun bereit erklärt, $k = 2$ Bohnen zu ziehen. Und zu essen, und zwar direkt und sofort! Also, jetzt heißt es tapfer sein. Ziehen und runter damit!

Wie groß ist die Wahrscheinlichkeit, *genau eine* scheußliche Bohne zu erwischen?

Es gibt 2 Pfade für 1 Treffer bei 2 Wiederholungen (Züge aus dem Beutel), s. Abbildung 5.11: Man kann im ersten Zug eine scheußliche Bohne erwischen, aber nicht im zweiten Zug. Oder man kann im zweiten Zug Pech haben (aber nicht im ersten). Die Summe der Wahrscheinlichkeiten beider Pfade ist die Wahrscheinlichkeit für *genau eine* scheußliche Bohne, das sind 19 %.

¹³Der Multiplikationssatz ist symmetrisch

¹⁴Quelle: https://harrypotter.fandom.com/de/wiki/Bertie_Botts_Bohnen_jeder_Geschmacksrichtung

5 Rechnen mit Wahrscheinlichkeit




Abbildung 5.11: Baumdiagramm für ein ein zweistufiges Zufallsereignis: Bertie Botts Bohnen.

```
Pfad1 <- 2/20 * 18/19 # scheußliche Bohne im 1. Zug  
Pfad2 <- 18/20 * 2/19 # scheußliche Bohne im 2. Zug
```

```
Gesamt_Pr <- Pfad1 + Pfad2  
Gesamt_Pr  
## [1] 0.19
```

Nutzen Sie diese App¹⁵, um das auszuprobieren. Sie müssen in der App noch die Zahl der Bohnen (n) und die Zahl der scheußlichen Bohnen (x) einstellen. □

5.6.3 Kettenregel

Definition 5.7 (Kettenregel). Allgemein gesagt, spricht man von der *Kettenregel* der Wahrscheinlichkeitsrechnung, wenn man die gemeinsame Wahrscheinlichkeit auf die bedingte zurückführt, s. Theorem 5.11. □

Theorem 5.11 (Kettenregel).

$$Pr(A \cap B) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B) \square$$

In Worten: Die Wahrscheinlichkeit von A gegeben B ist gleich der Wahrscheinlichkeit von A mal der Wahrscheinlichkeit von B gegeben A .

¹⁵<https://www.geogebra.org/m/j545R3Fu>

Übungsaufgabe 5.4 (Baumdiagramm sucht Problem). Überlegen Sie sich eine Problemstellung (Aufgabenstellung), die mit dieser Baumdiagramm-App gelöst werden kann. □

Übungsaufgabe 5.5 (Peer Instruction: Dreifacher Münzwurf). Fünf Studierende unterhalten sich, wie man einen dreifachen Münzwurf mit dem Ergebnis von $X = 3$ Treffern verstehen kann. Welche Aussage ist richtig bzw. passt am besten? Gehen Sie von einer fairen Münze aus und Unabhängigkeit der Würfe.

- A) Wirft man die Münze drei Mal, so gibt es 4 verschiedene Ergebnisse (0 bis 3 Treffer), die alle gleich wahrscheinlich sind. Aber nur ein Ergebnis ist gesucht, nämlich 3 von 3 Treffern. Also ist die Wahrscheinlichkeit $1/4$, 25 %.
- B) Man kann einfach einen Computer fragen, z. B. R mit `dbinom(x = 3, size = 3, prob = 1/2)`, da kommt ungefähr 10 % raus.
- C) Wirft man die Münze drei Mal, so gibt es 8 Ergebnisse, die alle gleich wahrscheinlich sind. Aber nur ein Ergebnis ist gesucht, nämlich 3 von 3 Treffern. Also ist die Wahrscheinlichkeit $1/8$, ca. 12,5 %.
- D) Einfach die Zahlen in die Formel eintragen: $\left(\frac{1}{2}\right)^3 = \left(\frac{1}{2^3}\right) = \left(\frac{1}{8}\right)$
- E) Wirft man die Münze drei Mal, so sind die Würfe nicht wirklich unabhängig: Nach zwei Treffern in Folge wird ein dritter Treffer unwahrscheinlicher, weil sich die Serie „ausgleichen“ muss. Deshalb ist die Wahrscheinlichkeit für drei Treffer in Folge kleiner als $(1/2)^3$, nämlich nur ca. 6 %.

5.7 Totale Wahrscheinlichkeit

Beispiel 5.21 (Gesamter Ausschussanteil). Die folgende Aufgabe bezieht sich auf Bourier (2011), S. 56. Drei Maschinen (M_1, M_2, M_3) produzieren einen Artikel. Die Maschinen haben einen Anteil an der Produktion von 60, 10 bzw. 30 % und eine Ausschussquote von 5, 2 bzw. 4 %. Sei M das Ereignis, dass ein Artikel von Maschine M stammt, und S (Schrott) das Ereignis, dass ein Artikel Ausschuss (Schrott) ist. Gesucht ist der Ausschussanteil insgesamt (über alle drei Maschinen). Anders gesagt: Wie hoch ist die Wahrscheinlichkeit $Pr(S')$, dass ein zufällig gezogener Artikel Ausschuss ist? Abbildung 5.12 zeigt das Baumdiagramm für die Aufgabe. □

5 Rechnen mit Wahrscheinlichkeit




Abbildung 5.12: Totale Wahrscheinlichkeit

Die Anteile an der Produktion und vom Ausschluss sind in Abbildung 5.13 verdeutlicht.




Abbildung 5.13: Anteile von Produktion und Ausschuss

Dazu addieren wir die Wahrscheinlichkeiten der relevanten Äste. Jeder Ast stellt wiederum das gemeinsame Auftreten der Ereignisse M_i und S dar.

```
W_Ast1 <- 0.6 * 0.05 # Wahrscheinlichkeit für Ast 1
W_Ast2 <- 0.1 * 0.02 # ... Ast 2
W_Ast3 <- 0.3 * 0.04 # ... Ast 3
W_total <- W_Ast1 + W_Ast2 + W_Ast3 # totale W.
W_total
## [1] 0.044
```

Die *totale Wahrscheinlichkeit* (für Ausschuss) beträgt in diesem Beispiel also $Pr(B') = 0.044 = 4.4\%$.¹⁶

Definition 5.8 (Totale Wahrscheinlichkeit). Bilden die Ereignisse $M_1, M_2, \dots, M_n$ ein vollständiges Ereignissystem und ist S ein beliebiges Ereignis dann gilt Theorem 5.12. $\square$

¹⁶Einfacher als das Rechnen mit Wahrscheinlichkeiten ist es in solchen Fällen, wenn man anstelle von Wahrscheinlichkeiten absolute Häufigkeiten zum Rechnen verwendet.

5 Rechnen mit Wahrscheinlichkeit

Theorem 5.12 (Totale Wahrscheinlichkeit).

$$Pr(S') = \sum_{i=1}^n Pr(M_i) \cdot Pr(S|M_i). \square$$

In Worten: Die totale Wahrscheinlichkeit ist die Summe der gewichteten Teil-Wahrscheinlichkeiten.

Beispiel 5.22. In Abbildung 5.12 (Beispiel 5.21) gilt $Pr(S') = 0.6 \cdot 0.05 + 0.1 \cdot 0.02 + 0.3 \cdot 0.04 = 0.03 + 0.002 + 0.012 = 0.044$. $\square$

Übungsaufgabe 5.6 (Bertie Botts Bohnen jeder Geschmacksrichtung, Teil 2). Es ist die gleiche Aufgabe wie Beispiel 5.20, aber jetzt lautet die Frage: Wie groß ist die Wahrscheinlichkeit, *mindestens eine* scheußliche Bohne bei 3 Zügen zu erwischen?¹⁷ $\square$

5.7.1 Baumsammlung

Baumdiagramme sind ein hilfreiches Werkzeug für wiederholte Zufallsexperimente. Daher ist hier eine „Baumsammlung“¹⁸ zusammengestellt.

- Sie werfen 1 Münze, Abbildung 4.2.
- Sie werfen 2 Münzen, Abbildung 5.8.
- Sie werfen 3 Münzen, Abbildung 5.9.
- Sie werfen 4 Münzen, Abbildung 4.20.
- Sie werfen 9 Münzen, 🎲 Abbildung 7.7.

5.8 Vertiefung

Bei Henze (2019) findet sich eine anspruchsvollere Einführung in das Rechnen mit Wahrscheinlichkeit; dieses Kapitel behandelt einen Teil des Stoffes der Kapitel 2 und 3 von Henze (2019). Mit dieser App, die ein zweistufiges Baumdiagramm zeigt¹⁹,

¹⁷Die Wahrscheinlichkeit *keine* scheußliche Bohne zu ziehen ist $(17/20 \cdot 16/19 \cdot 15/18) \approx 0.6$. Daher ist die gesuchte Wahrscheinlichkeit (mindestens eine scheußliche Bohne) das Komplement davon: 0.4.

¹⁸Wald?

¹⁹<https://www.geogebra.org/m/n4xr4x5>

können Sie das Verhalten von verschiedenen Arten von Wahrscheinlichkeiten weiter untersuchen. Diese App lässt dich herausfinden, ob man wirklich krank ist, wenn der Arzt es behauptet.²⁰ Das Video zu Bayes von 3b1b verdeutlicht das Vorgehen der Bayes-Methode auf einfache und anschauliche Weise. Mittag & Schüller (2020) stellen in Kap. 11 die Grundlagen der Wahrscheinlichkeitstheorie vor. Ähnliche Darstellungen finden sich in einer großen Zahl an Lehrbüchern.

5.9 Aufgaben

Bearbeiten Sie die Aufgabe in der zu Beginn des Kapitels angegebenen Literatur.

Die Webseite datenwerk.netlify.app stellt eine Reihe von einschlägigen Übungsaufgaben bereit. Sie können die Suchfunktion der Webseite nutzen, um die Aufgaben mit den folgenden Namen zu suchen:

5.9.1 Paper-Pencil-Aufgaben

1. Additionssatz1
2. Nerd-gelockert
3. Urne1
4. Urne2
5. k-coins-k-hits
6. sicherheit
7. sicherheit2
8. Klausuren-bestehen
9. Gem-Wskt1
10. Gem-Wskt2
11. Gem-Wskt3
12. Gem-Wskt4
13. wuerfel05
14. wuerfel06
15. Bed-Wskt1
16. Bed-Wskt2
17. Bed-Wskt3
18. voll-normal
19. corona-blutgruppe

²⁰<https://www.geogebra.org/m/tkdfxa8f>

5 Rechnen mit Wahrscheinlichkeit

20. totale-Wskt1
21. wskt-quiz14
22. wskt-quiz09
23. prob-vereinigung
24. bestehen_ohne_lernen

5.9.2 Aufgaben, für die man einen Computer braucht

1. mtcars-abhaengig
2. mtcars-abhaengig-var2
3. mtcars-abhaengig_var3a
4. wskt-df-r

6 Verteilungen

6.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.
Sie können ...

- den Begriff der Zufallsvariablen erläutern
- die Begriffe von Wahrscheinlichkeitsdichte und Verteilungsfunktion erläutern
- den Begriff einer Gleichverteilung erläutern
- den Begriff einer Binomialverteilung erläutern
- den Begriff einer halben Normalverteilung erläutern
- den Begriff einer Exponentialverteilung erläutern
- zentrale Konzepte in R umsetzen

Der Stoff dieses Kapitels deckt sich (weitgehend) mit Bourier (2011), Kap. 6.1 und 6.3 sowie 7.1 und 7.2.

Dieses Kapitel setzt einige Grundbegriffe voraus, wie im Buch Statistik¹ vorgestellt, insbesondere im Kapitel „Rahmen“². Benötigt wird auch der Begriff der Normalverteilung³ sowie der Begriff der Quantile⁴. Lesen Sie diese Stellen, wenn Sie den Stoff noch nicht oder nicht mehr beherrschen.

Lesen Sie selbständig, zusätzlich zum Stoff dieses Kapitels, noch in Bourier (2011) folgende Abschnitte:

- Kap. 7.1.1 (Binomialverteilung)
- Kap. 7.2.1 (Gleichverteilung)
- Kap. 7.2.3 (Normalverteilung)

¹<https://sebastiansauer.github.io/statistik1/>

²<https://sebastiansauer.github.io/statistik1/010-rahmen#was-sind-daten>

³<https://sebastiansauer.github.io/statistik1/040-verbildlichen#spezialfall-normalverteilung>

⁴<https://sebastiansauer.github.io/statistik1/050-zusammenfassen.html#quantile>

6 Verteilungen

Lösen Sie auch die Übungsaufgaben dazu.

Weitere Übungsaufgaben finden Sie im dazugehörigen Übungsbuch, Bourier (2022).

Beachten Sie, dass neben den Inhalten des Kapitels auch stets der vorzubereitende Stoff prüfungsrelevant ist.

6.1.1 Benötigte R-Pakete

```
library(tidyverse)
library(ggpubr) # für Plots
```

6.1.2 Zentrale Begriffe

6.1.2.1 Eigenschaften von Zufallsvariablen

- Zufallsvariable (random variable)
- Diskret vs. stetig
- Wahrscheinlichkeitsdichte (Dichte, (probability) density, f)
- Wahrscheinlichkeitsfunktion (kumulierte Wahrscheinlichkeit, Wahrscheinlichkeitsmasse)

6.1.2.2 Verteilungen

- Gleichverteilung
- Normalverteilung
- Standardnormalverteilung

6.2 Wichtige Verteilungen


Im Folgenden sind einige wichtige Verteilungen aufgeführt, die in diesem Skript (und in der Statistik und Wahrscheinlichkeitstheorie) eine zentrale Rolle spielen.

6.3 Gleichverteilung

6.3.1 Indifferenz als Grundlage

Eine Gleichverteilung nimmt an, dass jede Ausprägung der zugehörigen Zufallsvariablen *gleichwahrscheinlich* ist. Wenn man keinen hinreichenden Grund hat, eine bestimmte Ausprägung einer Zufallsvariablen für plausibler als eine andere zu halten, ist eine Gleichverteilung eine passende Verteilung. Gleichverteilungen gibt es im diskreten und im stetigen Fall.

Abb. Abbildung 6.1 zeigt ein Beispiel für eine (stetige) Gleichverteilung.



- (a) Beispiel a: Gleichverteilung $\min=-1$, $\max=1$. Dichte: $1/2$
 (b) Beispiel b: Gleichverteilung $\min=0$, $\max=3$. Dichte: $1/3$

Abbildung 6.1: Stetige Gleichverteilung; man beachte jeweils die Y-Achse

Abbildung 6.1, (a): Bei $X = 0$ hat eine Einheit von X (z.B. von -1 bis 0) die Wahrscheinlichkeitsmasse von 50 %, da der Bereich $[-1, 0]$ die Hälfte (50 %) der Wahrscheinlichkeitsmasse der Verteilung beinhaltet. Bei jedem anderen Punkt x ist die Dichte identisch. Abbildung 6.1, (b): Bei $X = 0$ hat eine Einheit von X die Wahrscheinlichkeitsmasse von ca. 33 %, da der Bereich $[0, 1]$ ein Drittel der Wahrscheinlichkeitsmasse der Verteilung beinhaltet. Bei jedem anderen Punkt x ist die Dichte identisch. Definierendes Kennzeichen einer Gleichverteilung ist die *konstante Dichte*.

6.4 Binomialverteilung

6.4.1 Grundlagen

Definition 6.1 (Binomialverteilung). Die Binomialverteilung dient zur Darstellung der Wahrscheinlichkeit der Ergebnisse eines n -fach wiederholten binomialen Zu-

6 Verteilungen

fallsexperiments, eines Zufallsexperiments mit *zwei*⁵ Ergebnissen bzw. Elementarereignissen also. Dabei interessiert uns nur die *Anzahl* der k Treffer, aber nicht die Reihenfolge. Bei jeder Wiederholung liegt die Wahrscheinlichkeit eines Treffers bei p , und diese Wahrscheinlichkeit bleibt über alle Wiederholungen hinweg gleich: Die Münze verändert sich nicht durch die Würfe (*Ziehen mit Zurücklegen*, *ZmZ*). Außerdem hat ein bestimmtes Ergebnis im ersten Wurf keinen Einfluss auf die Wahrscheinlichkeit eines bestimmten Ergebnisses im zweiten Wurf, etc., sog. „iid“: *independent and identically distributed*.] $\square$

$$\begin{array}{ccc} \text{Unsere Zufallsvariable} & & \text{Binomialverteilung} \\ \hat{X} & \stackrel{\sim}{\sim} & \underbrace{\text{Bin}(n, p)} \\ \text{ist verteilt nach der} & & \text{mit den Parametern } n, p \end{array} \quad (6.1)$$

Für eine binomialverteilte Zufallsvariable X schreibt man kurz wie in Theorem 6.1 gezeigt.

Theorem 6.1 (Notation für eine binomialverteilte Zufallsvariable).

$$X \sim \text{Bin}(n, p) \quad \square$$

Beispiel 6.1. Anwendungsbeispiele: Wie viele defekte Teile sind in einer Stichprobe von produzierten Schrauben zu erwarten? Wie wahrscheinlich ist es, dass das neue Blutdruck-Medikament einer bestimmten Anzahl von Menschen hilft? Wie viele Personen stimmen in einer Umfrage der Frage „Ich halte die öffentlich-rechtlichen Sender für wichtig.“ zu? Was ist die Wahrscheinlichkeit, 6 mal hintereinander eine 6 zu würfeln bei einem fairen Würfel? Eine Münze, die in 7 von 10 Würfeln „Kopf“ zeigt – sollte sie als „unfair“ eingeschätzt werden? $\square$

Stellen wir uns ein Kistchen⁶ mit sehr vielen⁷ Losen vor, darunter $2/5$ Treffer (Gewinn) und $3/5$ Nieten, s. Abb. Abbildung 6.2. Der Versuch läuft so ab: Wir ziehen ein Los, schauen ob es ein Treffer ist oder nicht, legen es zurück und ziehen erneut. Da *sehr viele* Lose im Kästchen liegen, ist es praktisch egal, ob wir das Los wieder zurücklegen. Die Wahrscheinlichkeit für einen Treffer ändert sich (so gut wie) nicht. Jetzt ziehen wir z. B. drei Lose. Wie groß ist die Wahrscheinlichkeit, davon 2 Treffer zu erzielen (egal in welcher Reihenfolge)?

⁵von lat. *bis* „zweimal“

⁶In den Lehrbüchern häufig als Urne bezeichnet, was den bösen Spott von „Friedhofstatistik“ nach sich zog.

⁷praktisch unendlich vielen




Abbildung 6.2: Ein Kasten mit Losen, davon $2/5$ Treffer und $3/5$ Nieten

Praktischerweise ist die Binomialverteilung in R eingebaut, hier ist Pseudocode für Ihre Anwendung, s. Listing 6.1.

Listing 6.1 R-Pseudocode für die Binomialverteilung

```
dbinom(x = <Anzahl der Treffer>,
       size = <Anzahl der Würfe>,
       prob = <Wahrscheinlichkeit eines Treffers>)
```

6.4.2 Möglichkeiten zählen

Beispiel 6.2. Drei Lose gekauft, davon zwei Treffer?

Wie groß ist die Wahrscheinlichkeit p bei $n = 3$ Zügen $k = 2$ Treffer zu erzielen (und $n - k = 1$ Nieten)? (Nennen wir dieses gesuchte Ereignis der Kürze halber A'). Die Trefferwahrscheinlichkeit ist (bei jedem Zug) $p = 2/5$ und die Nietenwahrscheinlichkeit $1 - p = 3/5$ □, s. Abbildung 6.3. Abbildung 5.9 zeigt den entsprechenden Baum; Tabelle 6.1 zeigt die Ergebnisse dieses Zufallsexperiments.




Abbildung 6.3: Wie viele Möglichkeiten gibt es, 3 Lose zu sortieren, von denen 2 Treffer sind und 1 Niete?

6 Verteilungen

Tabelle 6.1: Alle acht Ergebnisse des Zufallsexperiment (binär, 3-fach wiederholt) mit ihren Wahrscheinlichkeiten im Überblick

Pfad (Ereignis)	Anzahl Treffer	Wahrscheinlichkeit
TTT	3	$p^3 = \left(\frac{2}{5}\right)^3 = \frac{8}{125} \approx 0.064$
TTN	2	$p^2q = \frac{4}{25} \cdot \frac{3}{5} = \frac{12}{125} \approx 0.096$
TNT	2	$p^2q = \frac{12}{125} \approx 0.096$
NTT	2	$p^2q = \frac{12}{125} \approx 0.096$
TNN	1	$pq^2 = \frac{2}{5} \cdot \frac{9}{25} = \frac{18}{125} \approx 0.144$
NTN	1	$pq^2 = \frac{18}{125} \approx 0.144$
NNT	1	$pq^2 = \frac{18}{125} \approx 0.144$
NNN	0	$q^3 = \left(\frac{3}{5}\right)^3 = \frac{27}{125} \approx 0.216$

Mit Blick auf Beispiel 6.2: Wir könnten jetzt ein Baumdiagramm zeichnen und pro Pfad die Wahrscheinlichkeit ausrechnen (Multiplikationssatz, Theorem 5.9), vgl. Abbildung 5.9. Die Summe der Wahrscheinlichkeiten der Pfade ist dann die gesuchte Wahrscheinlichkeit (Additionssatz, Theorem 5.1). Diagramme zeichnen ist einfach, dauert aber.

Beachtet man die *verschiedenen Reihenfolgen nicht*, so zählt man 3 günstige Pfade (T: Treffer; N: Niete), s. Abbildung 5.9:

1. TTN
2. TNT
3. NTT.

Wir haben also die Möglichkeiten (2 Treffer und 1 Niete zu erhalten)

- ohne Beachtung der Reihenfolge und
- ohne Zurücklegen (der Möglichkeiten)

gezählt.

Schneller geht es, wenn man rechnet. Wir könnten auch R auffordern, die Anzahl der günstigen Pfade zu berechnen, s. Theorem 6.3 mit `choose(3,2)`, was die Antwort 3 liefert.

6.4.3 Anzahl Pfade mal Pfad-Wahrscheinlichkeit

In diesem Fall ist die Wahrscheinlichkeit eines (günstigen) Pfades, A :

$$Pr(A) = Pr(T)^2 \cdot Pr(N)^1 = \left(\frac{2}{5}\right)^2 \cdot \left(\frac{3}{5}\right)^1 \approx 0.096.$$

```
p_a = (2/5)^2 * (3/5)^1
p_a
## [1] 0.096
```

Damit ist die Wahrscheinlichkeit des gesuchten Ereignisses A' (2 Treffer bei 3 Zügen) gleich der Anzahl der günstigen k Pfade (3) mal der Wahrscheinlichkeit eines Pfades (0.1):

$$Pr(A') = k \cdot Pr(A) = 3 \cdot 0.096 = 0.29.$$

```
p_a_strich = 3 * p_a
p_a_strich
## [1] 0.29
```

Die Wahrscheinlichkeit, bei 3 Zügen 2 Treffer zu erzielen, beträgt also ca. 29 %.

Dabei steht k für die Anzahl der günstigen Pfade und $Pr(A)$ für die Wahrscheinlichkeit eines günstigen Pfades (d. h. 2 Treffer und 1 Nieten) und alle Pfade haben die gleiche Wahrscheinlichkeit.

6.4.4 Formel der Binomialverteilung

Theorem 6.2 zeigt die mathematische Definition der Binomialverteilung. Dabei liegt immer ein Zufallsversuch mit n Durchgängen und k Treffern zugrunde. Jeder Durchgang hat die Trefferwahrscheinlichkeit p und jeder Durchgang ist unabhängig von allen anderen.

Theorem 6.2 (Binomialverteilung).

$$Pr(X = k|p, n) = \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} \quad \square$$

6 Verteilungen

$$\begin{aligned} \Pr(X = k|p, n) &= \text{Anzahl Pfade} \cdot \text{Pfad-Wskt} \\ &= \underbrace{\binom{n}{k}}_{\text{Anzahl Pfade}} \cdot \underbrace{p^k(1-p)^{n-k}}_{\text{Pfad-Wskt}} \end{aligned}$$

Theorem 6.2 kann man wie folgt auf Deutsch übersetzen:

Die Wahrscheinlichkeit für das Ereignis X gegeben p und n berechnet sich als Produkt von zwei Termen. Der erste Term gibt die Anzahl der (günstigen) Pfade, k (aus n möglichen Pfaden). Der zweite Term gibt die Wahrscheinlichkeit für einen günstigen Pfad (einen Treffer), $p = P(A)$, die „Pfad-Wskt“.

Die Anzahl der (günstigen) Pfade kann man mit dem *Binomialkoeffizient* ausrechnen, den man mit $\binom{n}{k}$ darstellt, s. Theorem 6.3.⁸

Definition 6.2 (Binomialkoeffizient). Der Binomialkoeffizient gibt an, auf wie vielen verschiedenen Arten man aus einer Menge von n verschiedenen Objekten k Objekte ziehen kann (ohne Zurücklegen und ohne Beachtung der Reihenfolge). $\square$

Theorem 6.3 (Binomialkoeffizient).

$$\binom{n}{k} = \frac{n!}{k! \cdot (n-k)!} \quad \square$$

Lies: „Wähle aus n möglichen Ereignissen (Pfade im Baum) k günstige Ereignisse (Pfade) oder kürzer „ k aus n “ bzw. „ n über k “. $\square$

Um den Binomialkoeffizient zu berechnen, muss man die Fakultät berechnen. Die Fakultät ist eine Rechenvorschrift für natürliche Zahlen. Man schreibt sie mit einem Ausrufezeichen hinter der Zahl, also zum Beispiel $3!$. Dabei multipliziert man alle natürlichen Zahlen von der gegebenen Zahl bis hinunter zur 1.

Beispiel 6.3.

$$\bullet \quad 1! = 1$$

⁸wobei gelten muss $n \geq k$

- $3! = 3 \cdot 2 \cdot 1$
- $4! = 4 \cdot 3 \cdot 2 \cdot 1$
- $0! = 1$ (per Definition) $\square$

Puh, Formeln sind vielleicht doch ganz praktisch, wenn man sich diese lange Übersetzung der Formel in Prosa durchliest. Noch praktischer ist es aber, dass es Rechenmaschinen gibt, die die Formel kennen und für uns ausrechnen.

Beispiel 6.4 (2 von 4 Freunden auswählen). Sie sind auf einer Party. Großartige Feier. Es wird spät, und langsam wird es Zeit, nach Hause zu fahren. Heute sind Sie der Fahrer. In Ihrem Auto haben Sie noch 2 freie Plätze. Aber 4 Ihrer Freunde möchten bei Ihnen mitfahren. Da stellt sich also die Frage: Wen wählen Sie aus?

1. Anton
2. Berta
3. Carla
4. Dario

Für den 1. freien Platz stehen alle 4 Freunde zur Auswahl. Für den 2. freien Platz stehen noch 3 Freunde zur Auswahl. Das sind 12 Möglichkeiten.

Abbildung 6.4 zeigt als Baumdiagramm Ihre Auswahl-Möglichkeiten. Das Diagramm zeigt auch, welche Möglichkeiten Sie hätten, wenn Sie alle 4 Freunde auswählen könnten.

6 Verteilungen




Abbildung 6.4: Sie wählen nacheinander 4 Freunde (A,B,C,D) aus. Wie viele Möglichkeiten gibt es dafür? Zuerst haben Sie 4 Möglichkeiten. Nachdem Sie den 1. Freund gewählt haben, haben Sie noch 3 weitere zur Auswahl. Dann noch 2 und schließlich bleibt der Letzte.

Würden Sie alle 4 Freunde wählen, wären das $4 \cdot 3 \cdot 2 \cdot 1 = 4! = 24$ Möglichkeiten. Zum Beispiel „ABCD“, „ABDC“, „ADBC“ etc. Wir wählen aber nur 2 von 4 Freunden. Daher haben wir nur $4 \cdot 3 \cdot \cancel{2 \cdot 1} = \frac{4!}{2!} = 12$ Möglichkeiten. Zum Beispiel „AB“, „BA“, „AC“. Allerdings ist es für die Frage, wer in Ihrem Auto mitfährt, egal, ob Sie „AB“ oder „BA“ auswählen – das läuft auf die gleichen Mitfahrer heraus. Also müssen wir diese Variationen noch von unseren Möglichkeiten abziehen. Wie viele Variationen für die Mitfahrer „A“ und „B“ gibt es? Das sind 2 Möglichkeiten: Für den 1. freien Sitz haben Sie die Wahl zwischen 2 Personen, für den 2. freien Sitz dann nur noch eine Wahl. Das macht also $2!$ Variationen – davon behalten wir nur eine. Wir „schneiden“

also jeden 2. Baumast ab, teilen also die Anzahl der Äste (Pfade) durch 2.

Insgesamt gibt es also 6 mögliche Mitfahrer-Kombinationen: „AB“, „AC“, „AD“, „BC“, „BD“, „CD“.

$$\binom{4}{2} = \frac{4!}{2! \cdot 2!} = \frac{4 \cdot 3 \cdot 2}{2 \cdot 2} = 3 \cdot 2 = 6$$

Gute Heimfahrt! □

Beispiel 6.5 (Klausur mit 20-Richtig-Falsch-Fragen). Eine Professorin stellt eine Klausur mit 20 Richtig-Falsch-Fragen. Wie groß ist die Wahrscheinlichkeit, durch bloßes Münzwürfen *genau* 15 Fragen richtig zu raten?⁹

```
# Wskt für genau 15 Treffer bei 20 Versuchen mit einer fairen Münze:
dbinom(x = 15, size = 20, prob = .5)
## [1] 0.015
```

Die Wahrscheinlichkeit liegt bei ca. 1 %.

Um *höchstens* 15 Treffer zu erzielen, müssten wir die Wahrscheinlichkeiten von 0 bis 15 Treffern aufsummieren.

Praktischerweise gibt es einen R-Befehl, der das Aufsummieren für uns übernimmt: `pbinom`.

```
pbinom(q = 15, size = 20, prob = .5)
## [1] 0.99
```

Die Wahrscheinlichkeit, höchstens 15 Treffer (d. h. 0, 1, 2, ... 15 Treffer) zu erzielen, liegt für `prob = .5` laut Binomialverteilung mit `pbinom` bei gut 99 %.

Beispiel 6.6 (3 Münzwürfe mit 3 Treffern). Was ist die Wahrscheinlichkeit bei 3 Münzwürfen (genau) 3 Treffer (Kopf) zu erzielen, s. Abbildung 6.5, links?

Das ist eine Frage an die Binomialverteilung; in R kann man das mit der Funktion `dbinom` beantworten.

⁹Hey, endlich mal was für das echte Leben!


6 Verteilungen

```
dbinom(x = 3, size = 3, prob = 1/2)
## [1] 0.12
```


Die Lösung lautet also $p = 1/8 = .125$. $\square$

Man kann sich auch vor Augen führen, dass es genau 1 günstigen Pfad gibt, nämlich TTT. Nach dem Multiplikationssatz gilt also: $Pr(X = 3) = 1 \cdot \left(\frac{1}{2}\right)^3 = \frac{1}{8} = .125$.

```
loesung <- (1/2)^3
loesung
## [1] 0.125
```



(a) $n=3, p=1/2$



(b) $n=9, p=.7$

Abbildung 6.5: Verschiedene Binomialverteilungen

Übungsaufgabe 6.1. Was fällt Ihnen bei der Binomialverteilung auf? Ist sie symmetrisch? Verändert sich die Wahrscheinlichkeit linear?

Übungsaufgabe 6.2. Was ist die Wahrscheinlichkeit für 0, 1, 2, ..., 9 Treffern bei 9 Würfeln, wenn die Trefferwahrscheinlichkeit 70 % beträgt? Abbildung 6.5, rechts, zeigt die Antwort.

6.4.5 Rechnen mit der Binomialverteilung

Die Binomialverteilung ist in R eingebaut; man kann sich leicht entsprechende Wahrscheinlichkeiten ausrechnen lassen: z. B. `dbinom(x = 2, size = 3, prob = 2/5)`. Das ist komfortabler als selber rechnen. Mit diesem Befehl rechnet R aus, wie hoch die Wahrscheinlichkeit ist, bei `size = 3` „Münzwürfen“, `x = 2` Treffer zu erzielen, wobei die Trefferwahrscheinlichkeit jeweils `prob = 2/5` beträgt.

Beispiel 6.7 (Lotto). Wie viele Zahlenkombinationen gibt es im Lotto für 6 Richtige? Der Binomialkoeffizient verrät es uns: $\binom{49}{6} = 13\,983\,816$ □ Anders gesagt: Der Binomialkoeffizient sagt uns, wie viele Möglichkeiten es gibt, aus z. B. 49 Bällen 6 zu ziehen (ohne Beachtung der Reihenfolge und ohne Zurücklegen). □

Beispiel 6.8. Wie viele Möglichkeiten gibt es, 2 Treffer bei 4 Zügen zu erzielen?

Das sind folgende Ergebnisse: 1. TTNN, 2. TNTN, 3. TNNT, 4. NTTN, 5. NTNT, 6. NNTT.

$$\binom{4}{2} = \frac{4!}{2! \cdot (4-2)!} \stackrel{\text{kürzen}}{=} \frac{2 \cdot 3}{1} = 6$$

Es sind also 6 Möglichkeiten.

In R kann man sich die Fakultät mit dem Befehl `factorial` ausrechnen lassen. Der R-Befehl `choose` berechnet den Binomialkoeffizienten.¹⁰

```
anzahl_pfade_2_aus_4 <-
  factorial(4) / (factorial(2) * factorial(4-2))
anzahl_pfade_2_aus_4
## [1] 6

choose(4, 2)
## [1] 6
```

□

Beispiel 6.9. Hier sind die 10 Kombinationen, um aus 5 Losen genau 2 Treffer und 3 Nieten zu ziehen:

TTNNN, TNTNN, TNNTN, TNNNT, NTTNN, NTNTN, NTNNT, NNTTN, NNTNT, NNNTT

```
choose(5, 2)
## [1] 10

anzahl_pfade_2_aus_5 <-
  factorial(5) / (factorial(2) * factorial(5-2))
anzahl_pfade_2_aus_5
## [1] 10
```

¹⁰Bei Taschenrechnern ist diese Funktion oft als „nCr“ zu finden.

6 Verteilungen

□

Beispiel 6.10 (Beförderung). Aus einem Team mit 25 Personen sollen 11 Personen befördert werden. Wie viele mögliche Kombinationen (von beförderten Personen) können gebildet werden?

$$\binom{25}{11} = \frac{25!}{11!(25-11)!} = 4\,457\,400$$

```
choose(n = 25, k = 11)
## [1] 4457400
```

Es gibt 4457400 Kombinationen von Teams; dabei ist die Reihenfolge der Ziehung nicht berücksichtigt. □

6.4.6 Pumpstation-Beispiel zur Binomialverteilung

In einer Pumpstation arbeiten 7 Motoren, die wir als identisch annehmen. Mit einer Wahrscheinlichkeit von 5 % fällt ein Motor aus und ist für den Rest des Tages nicht einsatzbereit. Der Betrieb kann aufrecht erhalten werden, solange mindestens 5 Motoren arbeiten. Wie groß ist die Wahrscheinlichkeit, dass die Pumpstation aus dem Betrieb fällt?

$Pr(X = k)$ (oder kurz: $Pr(k)$) gibt die Wahrscheinlichkeit (Wahrscheinlichkeitsfunktion) an für das Ereignis, dass k Motoren arbeiten.

Lassen wir R mal $Pr(X = 5)$ ausrechnen.

```
dbinom(x = 5, size = 7, prob = .95)
## [1] 0.041
```

Es gilt also $Pr(X = 5) \approx .04$. Die Wahrscheinlichkeit, dass (nur) 5 Motoren an einem beliebigen Tag laufen, ist demnach relativ gering – wobei „gering“ subjektiv ist, die Betreiberfirma findet diese Wahrscheinlichkeit, dass 2 Motoren ausfallen, wohl viel zu hoch. Die Wahrscheinlichkeit, dass $k = 0 \dots 7$ Motoren laufen, ist in Abbildung 6.6 dargestellt.

`dbinom()` steht für die Wahrscheinlichkeitsdichte (im diskreten Fall, wie hier, Wahrscheinlichkeitsfunktion genannt) und `binom` für die Binomialverteilung. `x` gibt die

Anzahl der Treffer an (das gesuchte Ereignis, hier 5 Motoren arbeiten); size gibt die Stichprobengröße an (hier 7 Motoren).

Damit gilt:

$$Pr(X \geq 5) = Pr(X = 5) + Pr(X = 6) + Pr(X = 7)$$

Berechnen wir zunächst die Wahrscheinlichkeit, dass 5,6 oder 7 Motoren laufen mit Hilfe der Binomialverteilung.

```
p_5 <- dbinom(x = 5, size = 7, prob = .95)
p_6 <- dbinom(x = 6, size = 7, prob = .95)
p_7 <- dbinom(x = 7, size = 7, prob = .95)

p_5
## [1] 0.041
p_6
## [1] 0.26
p_7
## [1] 0.7
```

Das sind 0.04, 0.26, 0.7. Die gesuchte Wahrscheinlichkeit, p_mind_5, ist die Summe der drei Einzelwahrscheinlichkeiten.

```
p_mind_5 <- p_5 + p_6 + p_7

p_mind_5
## [1] 1
```

Die Wahrscheinlichkeit, dass mind. 5 Motoren arbeiten, beträgt also 1. Das komplementäre Ereignis zu diesem Ereignis ist, dass *nicht* mind. 5 Motoren arbeiten, also *höchstens* 4 und es daher zu einem Ausfall kommt. Es gilt also $Pr(\bar{X}) = 1 - Pr(X)$.

```
p_weniger_als_4 <- 1 - p_mind_5
p_weniger_als_4
## [1] 0.0038
```

6 Verteilungen

Das sind also 0.38% Wahrscheinlichkeit, dass die Pumpstation ausfällt.




Abbildung 6.6: Wahrscheinlichkeit, dass genau $k = 0..7$ Motoren laufen

Alternativ kann man mit der Verteilungsfunktion `pbinom()` rechnen, die $Pr(X \leq 4)$ berechnet.

In R kann man die Funktion `pbinom()` nutzen (p für (kumulierte) Wahrscheinlichkeit), um die Verteilungsfunktion der Binomialverteilung zu berechnen.

```
pbinom(q = 4, size = 7, prob = .95)
## [1] 0.0038
```

$q = 4$ steht für $X \leq 4$, also für höchstens 4 Treffer (arbeitende Motoren); $size = 7$ meint die Stichprobengröße, hier 7 Motoren; $prob$ gibt die Trefferwahrscheinlichkeit an. $\square$

Übungsaufgabe 6.3 (Peer-Instruction: Qualitätskontrolle in einer Fabrik). Eine Fabrik produziert USB-Sticks. Die Wahrscheinlichkeit, dass ein USB-Stick defekt ist, beträgt 2 %. Aus der laufenden Produktion werden regelmäßig 10 USB-Sticks zufällig ausgewählt und getestet. Sei X die Anzahl defekter USB-Sticks in dieser Stichprobe.

Welche Aussage ist richtig bzw. passt am besten?

- A) Mit 98 % sind alle 10 USB-Sticks in Ordnung.
- B) Mit 82 % sind alle 10 USB-Sticks in Ordnung.
- C) Mit 2 % sind alle 10 USB-Sticks defekt.
- D) Es ist unmöglich, dass alle 10 USB-Sticks defekt sind.
- E) Es ist unmöglich, dass alle 10 USB-Sticks in Ordnung sind. $\square$

6.5 Die halbe Normalverteilung

Grundlagen über die Normalverteilung¹¹ können in Sauer (2025) nachgelesen werden.

Ein Spezialfall der Normalverteilung ist die *halbe* (oder halbseitige) Normalverteilung, s. Abbildung 6.7.




Abbildung 6.7: Die halbe Normalverteilung

Definition 6.3 (Halbe Normalverteilung). Wenn man die (negativen) Vorzeichen bei den Werten der Normalverteilung ignoriert, erhält man die halbe Normalverteilung. Man „spiegelt“ die negative Seite auf die positive. $\square$

¹¹<https://sebastiansauer.github.io/statistik1/040-verbildlichen#spezialfall-normalverteilung>

6 Verteilungen

Man kann sie verwenden, wenn man von normalverteilten Werten ausgeht, die größer als Null sein müssen. Sie hat nur einen Parameter, die Streuung (SD) der zugrundeliegenden Normalverteilung mit Mittelwert 0.

Beispiel 6.11 (Halbe Normalverteilungen).

- Die Entfernung Ihres Dart-Pfeiles zur Mitte der Zielscheibe
- Die Entfernung des vom Baum gefallenen Apfels zum Stamm
- Die Abweichung des Gewichts eines Produktionsgegenstands (z. B. einer Schraube) vom Soll-Gewicht
- Die Reaktionszeiten einer Versuchsperson in einer Reaktionszeitaufgabe □

6.6 Die Exponentialverteilung

6.6.1 Die Apfel-fällt-nicht-weit-vom-Stamm-Verteilung

Anstelle der halben Normalverteilung kann man auch die Exponentialverteilung verwenden. Die beiden Verteilungen haben einen ähnlichen Verlauf, nur dass bei Exponentialverteilung Extremwerte wahrscheinlicher sind. Das kann vorteilhaft sein, wenn man ein Phänomen darstellen will, dessen Skalierung man nicht genau kennt. Die Normalverteilung setzt der Streuung der Werte deutlich engere Grenzen als die Exponentialverteilung. Abbildung 6.8 stellt die beiden Verteilungen nebeneinander.




Abbildung 6.8: Exponentialverteilung (blau, Rate = 1) vs. halbe Normalverteilung (sd = 1)

Für eine exponentialverteilte Variable X schreibt man auch:

$$X \sim \text{Exp}(1)$$

Eine Verteilung dieser Form nennt man *Exponentialverteilung*. Sie hat einige nützliche Eigenschaften:

1. Eine Exponentialverteilung ist nur für positive Werte, $x > 0$, definiert.
2. Steigt X um eine *Einheit*, so ändert sich Y um einen *konstanten Faktor*.
3. Sie hat nur einen Parameter, genannt *Rate* oder λ („lambda“).
4. $\frac{1}{\lambda}$ gibt gleichzeitig Mittelwert und Streuung („Gestrecktheit“) der Verteilung an.
5. Je größer die Rate λ , desto schneller der „Verfall“ der Kurve und desto *kleiner* die Streuung und der Mittelwert der Verteilung (und umgekehrt: Je größer $1/\lambda$, desto *größer* die Streuung und der Mittelwert der Verteilung.)
6. Steigt X um 1 Einheit, sinkt (die Wahrscheinlichkeitsdichte von) Y um einen konstanten Faktor (der abhängig von λ) ist.


Ohne auf die mathematischen Eigenschaften im Detail einzugehen, halten wir fest, dass der Graph dieser Funktion gut zu unseren Plänen passt.

6.6.2 Visualisierung verschiedener Exponentialverteilungen

Schauen wir uns einige Beispiele von Exponentialverteilungen an. Unterschiede in Exponentialverteilungen sind rein auf Unterschiede in λ (lambda) zurückzuführen, s. Abbildung 6.9.


6 Verteilungen

Exp(2)




(a) lambda = 2

Exp(1)




(b) lambda = 1

Exp(0.5)




(c) lambda = 1/2

Exp(0.25)



(d) lambda = 1/4

Exp(0.125)



(e) lambda = 1/8

Abbildung 6.9: Exponentialverteilungen für verschiedene Werte von lambda. Die Zahlen an den vertikalen Linien geben die jeweiligen Quantile an (z.B. 0.95 = 95 %-Quantil).

i Hinweis

Eine „gut passende“ oder gar die „richtige“ Verteilung zu finden, ist nicht immer einfach, wenn nicht unmöglich. Gut beraten ist man mit der Regel, im Zweifel lieber eine liberale Verteilung zu wählen, die einen breiteren Raum an möglichen Werten zulässt. Allerdings sollte man nicht das Baby mit dem Wasser auskippen und extreme Werte, wie etwa mehrere Kilometer Körpergröße, besser verbieten.

Man kann sich den Median und andere Quantile der Exponentialverteilung mit `qexp` ausgeben lassen, wobei man mit `p` den Wert der Verteilungsfunktion angibt, für den man das Quantil haben möchte, z. B. `p = .5` für den Median (mit `pexp()` kann man sich analog die Verteilungsfunktion ausgeben lassen.) Mit `rate` wird λ (lambda) bezeichnet.¹²

Dieser Aufruf zum Beispiel, `qexp(p = .5, rate = 1/8)`, gibt uns das 50 %-Quantil einer Exponentialverteilung mit Rate (λ) $1/8$ zurück, ca. 5.5: Mit einer Wahrscheinlichkeit von 50 % wird ein Wert von 5.5 nicht überschritten bei dieser Verteilung.

Die Grenzen der inneren 95 % dieser Verteilung kann man sich auch ausgeben.

```
qexp(p = c(0.025, .975), rate = 1/8)
## [1] 0.2 29.5
```

Tabelle 6.2 zeigt ausgewählte Perzentile (50 %, 95 %) einiger Exponentialverteilungen, d. h. Exponentialverteilungen mit verschiedenen Werten für λ .

Tabelle 6.2: Median-Werte von Exponentialverteilungen mit verschiedenen Werten für λ (lambda). p50: 50%-Quantil (Median), p95: 95%-Quantil (Dieser Wert wird mit 95% Wahrscheinlichkeit nicht überschritten; er bietet sich als *Obere Grenze* der plausiblen Werte an.)

lambda	p50	p95
100.00	0.01	0.03
50.00	0.01	0.06
25.00	0.03	0.12
10.00	0.07	0.30

¹²Es gibt auch Online-Apps, die diese Werte ausgeben (<https://homepage.divms.uiowa.edu/~mbogdanar/applets/exp-like.html>)

6 Verteilungen

Tabelle 6.2: Median-Werte von Exponentialverteilungen mit verschiedenen Werten für λ (lambda). p50: 50%-Quantil (Median), p95: 95%-Quantil (Dieser Wert wird mit 95% Wahrscheinlichkeit nicht überschritten; er bietet sich als *Obere Grenze* der plausiblen Werte an.)

lambda	p50	p95
8.00	0.09	0.37
4.00	0.17	0.75
2.00	0.35	1.50
1.00	0.69	3.00
0.50	1.39	5.99
0.25	2.77	11.98
0.12	5.55	23.97
0.10	6.93	29.96
0.04	17.33	74.89
0.02	34.66	149.79
0.01	69.31	299.57

6.7 Vertiefung

Bourier (2011), Kap. 6.2 und 7.1 erläutert einige (grundlegende) theoretische Hintergründe zu diskreten Zufallsvariablen und Wahrscheinlichkeitsverteilungen. Wichtigstes Exemplar für den Stoff dieses Kapitels ist dabei die Binomialverteilung. Mittag & Schüller (2020) stellen in Kap. 12 und 13 Zufallsvariablen vor; zum Teil geht die Darstellung dort über die Lernziele bzw. Inhalte dieses Kurses hinaus.

6.8 Aufgaben

Zusätzlich zu den Aufgaben in der genannten Literatur sind folgende Aufgaben zu empfehlen.

6.8.1 Paper-Pencil-Aufgaben

- alphafehler-inflation3

- alphafehler-inflation4
- iq1a
- iq2a
- iq3a
- simu-uniform
- simu-unif2
- simu-unif3
- Quiz zum Thema Verteilungen
- Bsp-Binomial
- distros
- bfi10
- wskt-quiz10
- Schiefel
- exp-tab
- expl
- small-wide-normal
- likelihood-nv
- schmalstepost

6.8.2 Aufgaben, für die man einen Computer braucht

- alphafehler-inflation2
- Quiz (Aufgabensammlung) zu Verteilungen
- wuerfel01
- wuerfel02
- wuerfel03
- wuerfel04
- iq01
- iq02
- iq03
- iq04
- iq05
- iq06
- iq07
- iq08
- Bus1

Teil II

Bayes

7 Der Globus-Versuch

7.1 Lernsteuerung

In diesem Kapitel übersetzen wir eine Problemstellung (Forschungsfrage) in ein (mathematisches) Modell, das uns dann mithilfe der Bayes-Formel Antworten auf die Problemstellung gibt.

Nach Absolvieren dieses Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- Unterschiede zwischen Modellen und der Realität erläutern
- die Binomialverteilung heranziehen, um geeignete (einfache) Modelle zu erstellen (für binomial verteilte Zufallsvariablen)
- die weite Einsetzbarkeit anhand mehrerer Beispiele exemplifizieren
- das Bayes-Modell anhand bekannter Formeln herleiten
- Post-Wahrscheinlichkeiten anhand der Bayesbox berechnen

Der Stoff dieses Kapitels deckt einen Teil aus McElreath (2020), Kap. 2, ab. McElreath (2020) stellt das Globusmodell mit mehr Erläuterung und etwas mehr theoretischem Hintergrund vor, als es in diesem Kapitel der Fall ist.

Lesen Sie zur Vorbereitung in Statistik 1 (Sauer, 2025) das Kapitel „Daten Einlesen“¹.

Folgende R-Pakete werden in diesem Kapitel benötigt:

```
library(tidyverse)
library(ggpubr) # komfortable Visualisierung
```

¹<https://sebastiansauer.github.io/statistik1/020-r>

7.2 Von Welten und Golems

7.2.1 Kleine Welt, große Welt

Bekanntlich segelte Kolumbus 1492 los, und entdeckte Amerika². Das war aber ein glücklicher Zufall, denn auf seinem Globus existierte Amerika gar nicht. Vielleicht sah sein Globus so aus wie der von Behaim, s. Abb Abbildung 7.1.




Abbildung 7.1: Behaims Globus: Kein Amerika

Quelle: Ernst Ravenstein, Wikimedia, Public Domain³

Die kleine Welt des Modells entsprach hier nicht der großen Welt, der echten Erdkugel.

Das ist ein Beispiel, das zeigt, wie Modellieren schiefgehen kann. Es ist aber auch ein Beispiel für, sagen wir, die Komplexität wissenschaftlicher (und sonstiger) Erkenntnis. Einfach gesagt: Glück gehört halt auch dazu.

i Hinweis

Behaims Globus ist nicht gleich der Erde. Die kleine Welt von Behaims Globus ist nicht die große Welt, ist nicht die Erde.

Was in der kleinen Welt funktioniert, muss nicht in der großen Welt funktionieren. Modelle zeigen immer nur die kleine Welt: Vorsicht vor schnellen Schlüssen und vermeintlicher Gewissheit.

²wenn auch nicht als Erster

³<https://commons.wikimedia.org/wiki/File:RavensteinBehaim.jpg>

7 Der Globus-Versuch

Übungsaufgabe 7.1. Nennen Sie ein Beispiel, in dem ein Modell nicht (exakt) der Wirklichkeit entspricht! □

7.2.2 Der Golem von Prag



Abbildung 7.2: Der Golem von Prag

Bildquelle: Mikoláš Aleš, Wikimedia, Gemeinfrei⁴

Der Golem von Prag⁵, die Legende einer vom Menschen geschaffenen Kreatur mit gewaltiger Kraft, die Befehle wörtlich ausführt, s. Abbildung 7.2. Die Geschichte besagt, dass ein Rabbi mit Zauberkraften den Golem aus Lehm erschuf, um die jüdische Bevölkerung der Stadt zu schützen. Bei kluger Führung kann ein Golem Nützliches vollbringen. Bei unüberlegter Verwendung wird er jedoch großen Schaden anrichten.

⁴<https://de.wikipedia.org/wiki/Golem>

⁵<http://www.prague.net/golem>

7.2.3 Wissenschaftliche Modelle sind wie Golems




Abbildung 7.3: „Yeah, ich bin ein Golem!“ – Bildquelle: Klara Schaumann, abgebildet mit freundlicher Genehmigung der Autorin

Golem

Eigenschaften des *Golems*:

- Besteht aus Lehm
- Belebt durch „Wahrheit“
- Mächtig
- dumm
- Führt Befehle wörtlich aus
- Missbrauch leicht möglich
- Märchen

Modell

Eigenschaften eines *Modells*:

- Besteht aus ~~Lehm~~ Silikon
- Belebt durch Wahrheit (?)
- Manchmal mächtig
- simpler als die Realität
- Führt Befehle wörtlich aus
- Missbrauch leicht möglich
- Nicht einmal falsch

i Hinweis

Wir bauen Golems.

Abbildung 2.7 stellt ein Sinnbild von Modellen dar.

Vergleichen wir die kleine Welt unseres Modells (Tabelle 7.1), wie z. B. Behaims Globus, mit der Großen Welt, die Kolumbus und wir befahren.

Tabelle 7.1: Kleine Welt vs. große Welt

Kleine Welt	Große Welt
Die Welt, wie sie der Golem sieht	Die Welt, wie sie in Wirklichkeit ist
ist das Modell, aber nicht (zwangsläufig) die Wirklichkeit	entspricht nicht (zwangsläufig) dem Modell
Verwenden wir beim Modellieren	Ist das, was wir modellieren

Beispiel 7.1 (Die Bayes-Formel und Lernen). Bayes-Inferenz ähnelt dem Lernen von Menschen. Geben Sie ein Beispiel von Lernen bei Menschen, das oben dargestelltem Prozess ähnelt! □

Beispiel 7.2 (Ein Regressionsmodell stammt aus der kleinen Welt). Ein wissenschaftliches Modell, etwa auf Basis eines Regressionsmodells ist Teil der *kleinen* Welt. Man muss sich bei der Interpretation eines Regressionsmodells vor Augen halten: „Die Ergebnisse des Modells sind nur richtig unter der Annahme, dass sich der Zusammenhang X und Y durch eine Gerade beschreiben lassen und unter der Annahme, dass meine Daten repräsentativ sind.“ □

7.3 Ein erster Versuch: Wir werfen den Globus

7.3.1 Das Bayes-Update

Beispiel 7.3 (Wasseranteil auf der Erdoberfläche). Unsere Forschungsfrage lautet, mit welchem Anteil die Erde wohl mit Wasser bedeckt ist (Abbildung 7.4)? Um möglichst wenig schreiben zu müssen, schreiben wir für „angenommener Wasseranteil auf der Erdoberfläche“ kurz p oder π (p wie proportion, Anteil). □

7.3 Ein erster Versuch: Wir werfen den Globus



Abbildung 7.4: Die Erde. Schön! Und mit viel Wasser, ca. 70 % der Erdoberfläche sind mit Wasser bedeckt. Bildquelle: NASA „Blue Marble“ (Apollo 17, 1972) – gemeinfrei, kommerziell nutzbar ohne Attribution-Pflicht.

Analog können wir uns vorstellen, 11 Wissenschaftler haben jeweils eine andere Hypothese zum Wasseranteil, π , der Erde. Die erste Person hat die Hypothese $\pi_1 = 0$, die zweite Person geht von $\pi_2 = 0.1$ aus ... die 11. Person von $\pi_{11} = 1$.

Um die Forschungsfrage zu beantworten, werfen Sie einen Globus-Ball in die Luft und fangen ihn wieder auf. Sie notieren dann, ob die Stelle unter Ihrem Zeigefinger Wasser zeigt (W) oder Land (L). Den Versuch wiederholen Sie, bis Sie den Globusball insgesamt 9 Mal geworfen haben. (Warum gerade 9 Mal? Tja, dann hat das Handy geklingelt... Auch in wissenschaftlichen Versuchen ist (leider?) nicht immer alles genau geregelt.)

So sah *mein* Ergebnis aus (Ihr Ergebnis kann anders aussehen, schließlich ist es ja Zufall):

W L W W W L W L W

Also $W = 6$ (Wasser, d. h. „Treffer“) und $L = 3$ (Land, „Niete“) ($n = 9$ Versuche).

Übungsaufgabe 7.2 (Der Globusversuch). Besorgen Sie sich einen Globus (zur Not eine Münze) und stellen Sie den Versuch nach! $\square$

Beispiel 7.4 (Wir schießen Sonden ins Weltall). Eine alternative Geschichte für den Globusversuch: Es ist das Jahr 2345536. Sie arbeiten für eine Weltraumbehörde. Gestern haben Sie einen Planeten entdeckt, weit draußen im All. Jetzt geht es um die Frage, wie viel Wasser es auf der Oberfläche dieses Planeten gibt. Dazu schießen Sie (bzw. Ihre Behörde) eine Reihe von Sonden auf den Planeten. Wir gehen davon aus, dass die Landeplätze dieser Sonden voneinander unabhängig sind. Sagen wir, es werden $n = 9$ Sonden hochgeschossen, und davon landen $W = 6$ im Wasser. $\square$

7.3.2 Bayes-Updates

Der Bayes-Golem denkt eigentlich ganz vernünftig: Zuerst („Apriori“) hat er ein Vorwissen zum Wasseranteil, die dazugehörige Wahrscheinlichkeitsverteilung nennt man *Apriori-Verteilung* (s. Definition 7.1). In unserem Beispiel ist das Vorwissen recht bescheiden: Jeder Wasseranteil ist ihm gleich plausibel. Als nächstes beschaut sich der Golem die Daten und überlegt, wie wahrscheinlich die Daten sind, wenn man von einer bestimmten Hypothese ausgeht, z. B. dass der Wasseranteil 50 % beträgt. Die zugehörige Wahrscheinlichkeit der Daten unter Annahme einer Hypothese nennt man die⁶ *Likelihood*⁷, s. Definition 7.2. Als Letztes bildet sich der Golem eine abschließende Meinung zur Wahrscheinlichkeit jeder Hypothese. Diese Wahrscheinlichkeitsverteilung nennt man *Aposteriori-Verteilung*, s. Definition 7.3. Sie berechnet sich als Gewichtung des Vorwissens mit den neuen Daten, die durch die Likelihood repräsentiert werden. Anders gesagt: Das Vorwissen wird anhand der Erkenntnisse (der Daten) aktualisiert: das Bayes-Update, s. Abbildung 7.5.




Abbildung 7.5: Updating mit Bayes

Definition 7.1 (Apriori-Verteilung). Für jede Hypothese haben wir ein Vorab-Wissen, das die jeweilige Plausibilität der Hypothese angibt: *Apriori-Verteilung*⁸. □

Definition 7.2 (Likelihood). Für jede Hypothese (d. h. jeden *Parameterwert* π) möchten wir wissen, wie wahrscheinlich die Daten sind (unter der Annahme, dass die Hypothese richtig ist). Anders gesagt: Die *Likelihood* sagt uns, wie gut die Daten zu einer bestimmten Hypothese passen. □

Definition 7.3 (Aposteriori-Verteilung). Dann gewichten wir den Likelihood mit dem Vorabwissen, so dass wir die *Aposteriori-Verteilung*⁹ (kurz: „Post-Verteilung“) bekommen. Sie quantifiziert unser Wissen zu den Parameterwerten *nach* Kenntnis der Daten und aufbauend auf unserem Vorwissen. Man bezeichnet sie kurz mit $Pr(H|D)$, lies: „Die Wahrscheinlichkeit der Hypothese H gegeben der Daten D.“ □

⁶oder den?

⁷zu Deutsch etwa: „Mutmaßlichkeit“

⁸Anstatt von *Apriori-Verteilung* liest man auch *Priori-Verteilung* oder *Prior*.

⁹Anstatt von *Apriori* liest man auch *Prior* oder *Priori*; anstatt *Aposteriori* auch *Posterior*

Übungsaufgabe 7.3 (Wie gut passen die Daten zur Hypothese, dass die Erde komplett trocken ist?). Wir haben in unseren Versuch $W = 6$ und $L = 3$ erzielt. Diese Daten passen *überhaupt nicht* zur Hypothese, dass die Erdoberfläche komplett trocken ist. Die Likelihood, L für $\pi = 0$ ist also Null. Analog ist die Likelihood für $\pi = 1$ auch Null. $\square$

7.3.3 Berechnung der Likelihood im Globusversuch

Wie wahrscheinlich ist es, ein bestimmtes Ergebnis, z. B. $W = 6$ Treffer (bei 9 Würfeln), zu erhalten, wenn man eine bestimmte Hypothese (einen bestimmten Wasseranteil, z. B. 90 %) annimmt? Diese Wahrscheinlichkeit nennt man die *Likelihood*, $L = Pr(W = 6, n = 9 | \pi = .9)$.

Wenn wir eine Binomialverteilung für die Globuswürfe annehmen, dann gehen wir davon aus, dass die Daten unabhängig voneinander entstehen und sich der Parameterwert nicht zwischenzeitlich ändert.¹⁰ Der Wasseranteil der Erde bleibt während des Versuchs gleich (durchaus plausibel).

Berechnen wir also die Likelihood für verschiedene Hypothesen (Wasseranteile, π), für $\pi = 0, 0.1, 0.2, \dots, 1$, s. Listing 7.1. Wir halten also die Daten fest (6 Treffer bei 9 Würfeln) und berechnen die Wahrscheinlichkeit dieser Daten für verschiedene Hypothesen (Wasseranteile, π).

Abbildung 7.6 visualisiert die Likelihood-Funktion für unser Beispiel (6 Wasser bei 9 Würfeln) für verschiedene Hypothesen (Wasseranteile, π). Man sieht, dass die Likelihood um $\pi = 0.7$ herum am höchsten ist.

¹⁰Die sog. „iid-Annahme“, *independently and identically distributed*: Jeder Wurf des Globusballes ist eine Realisation der gleichen Zufallsvariablen. Jeder Wurf ist unabhängig von allen anderen: Das Ergebnis eines Wurfes hat keinen (stochastischen) Einfluss auf ein Ergebnis anderer Würfe. Die Wahrscheinlichkeitsverteilung ist bei jedem Wurf identisch.

7 Der Globus-Versuch

Listing 7.1 Likelihood-Funktion für $x=6$ Treffer, bei $n=9$ Würfeln, für eine binomialverteilte Zufallsvariable: Wir halten die Daten fest und variieren den Parameterwert.

```
dbinom(x = 6, size = 9, prob = .1)
dbinom(x = 6, size = 9, prob = .2)
dbinom(x = 6, size = 9, prob = .3)
dbinom(x = 6, size = 9, prob = .4)
dbinom(x = 6, size = 9, prob = .5)
dbinom(x = 6, size = 9, prob = .6)
dbinom(x = 6, size = 9, prob = .7)
dbinom(x = 6, size = 9, prob = .8)
dbinom(x = 6, size = 9, prob = .9)
## [1] 6.1e-05
## [1] 0.0028
## [1] 0.021
## [1] 0.074
## [1] 0.16
## [1] 0.25
## [1] 0.27
## [1] 0.18
## [1] 0.045
```

Likelihood-Funktion für Binomialverteilung




Abbildung 7.6: Die Likelihood-Funktion für $x=6$ Treffer, bei $n=9$ Würfeln, für eine binomialverteilte Zufallsvariable (mit 11 Parameterwerten: 0, 0.1, 0.2, ..., 1); Die Parameterwerte um 0.7 herum sind am plausibelsten.

Oder von Hand gerechnet für $\pi = 1/2$, s. Gleichung 7.1:

$$\begin{aligned}
 Pr(\pi = 1/2 | x = 6, n = 9) &= \\
 \binom{9}{6} \cdot (1/2)^6 \cdot (1/2)^3 &= \\
 \frac{9!}{6!3!} \cdot (1/2)^9 &= \\
 84 \cdot 1/512 &= 21/128 = 0.16
 \end{aligned} \tag{7.1}$$

Mithilfe von R als Taschenrechner gerechnet:

```

anz_pfade <- choose(9, 6)
wskt_pro_pfad <- (1/2)^6 * (1/2)^3
gesamt_wskt <- anz_pfade * wskt_pro_pfad
gesamt_wskt
## [1] 0.16
    
```

Für so viele Würfe ($n = 9$) würde ein Baumdiagramm unübersichtlich werden, s. Abbildung 7.7. Visualisierungen wie Baumdiagramme sind eine praktische Hilfe zum Verständnis, kommen aber bei größeren Daten schnell an ihre Grenze.




Abbildung 7.7: Wir werfen den Globus (oder eine Münze) 9 Mal, es resultieren 512 Endknoten. Nicht gerade übersichtlich.

Jetzt folgen einige Beispiele.

7 Der Globus-Versuch

Beispiel 7.5 (Likelihood für $W = 6, n = 9, \pi = .7$). Was ist die Likelihood von $W = 6$ bei $n = 9$ gegeben $\pi = .7$ bei unserem Globusversuch?

```
dbinom(x = 6, size = 9, prob = .7)
## [1] 0.27
```

Oder, synonym, wenn man einen Taschenrechner (oder R als Taschenrechner) benutzt:

```
choose(9, 6) * (.7)^6 * (.3)^3
## [1] 0.27
```

Noch „händischer“ gerechnet:

```
factorial(9)/(factorial(6)*factorial(3)) * (.7)^6 * (.3)^3
## [1] 0.27
```

Die Daten passen gut zur Hypothese $\pi = .7$. $\square$

Zur Erinnerung: Die Funktion `dbinom` gibt uns die Wahrscheinlichkeit von x Treffern, bei $size$ Versuchen zurück, wobei eine Binomialverteilung angenommen wird mit der Trefferwahrscheinlichkeit `prob`.

Beispiel 7.6 (Likelihood für $W = 6, n = 9, \pi = 1/3$). Was ist die Likelihood von $W = 6$ bei $n = 9$ gegeben $\pi = 1/3$ bei unserem Globusversuch?

```
dbinom(x = 6, size = 9, prob = 1/3)
## [1] 0.034
```

Offenbar ist $\pi = 1/3$ eine schlechte Hypothese, um die Daten zu erklären: Die Daten passen nicht gut zu ihr. $\square$

Beispiel 7.7 (Likelihood für $\pi = 0$). Was ist die Likelihood von $W = 6$ bei $n = 9$ gegeben $\pi = 0$ bei unserem Globusversuch?

7.3 Ein erster Versuch: Wir werfen den Globus

```
dbinom(x = 6, size = 9, prob = 0)
## [1] 0
```

$\pi = 0$ ist offenbar eine sehr schlechte Hypothese, um die Daten zu erklären: Die Daten sind unmöglich unter dieser Hypothese. $\square$

(Fast) von Hand gerechnet:

```
factorial(9)/(factorial(6)*factorial(3)) * (.7)^6 * (.3)^3
## [1] 0.27
```

Als Formel, s. Gleichung 7.2:

$$\begin{aligned} Pr(W = 6 | \pi = .7, n = 9) &= \\ \binom{9}{6} \cdot (.7)^6 \cdot (.3)^3 &= \\ \frac{9!}{6!3!} \cdot (.7)^6 \cdot (.3)^3 &= \\ 84 \cdot .003 &= .27. \end{aligned} \tag{7.2}$$

$\square$

Es gibt Taschenrechner(-Apps), die die Binomialverteilung oder den Binomialkoeffizienten berechnen können.¹¹

Übungsaufgabe 7.4 (Peer Instruction: Welcher Parameterwert ist am plausibelsten?). Wir führen wieder den Globusversuch durch (oder werfen eine Münze) und erhalten folgendes Ergebnis: 7 Mal Wasser und 2 Mal Land (also $W = 7$ und $L = 2$).

Welcher Wasseranteil, π ist am plausibelsten?

- A) 0 Wasser (0 %)
- B) 1/9 Wasser (ca. 11 %)
- C) 3/9 Wasser (ca. 33 %)
- D) 7/9 Wasser (ca. 78 %)
- E) 9 Wasser (100 %) $\square$

¹¹<https://www.geogebra.org/scientific?lang=de>

7.3.4 Unser Modell ist geboren

Ein Modell (in der Bayes-Statistik) besteht aus mind. drei Komponenten:

1. Die *Likelihood* (die Wahrscheinlichkeit der Daten unter Annahme der Hypothese), s. Gleichung 7.1
2. Die *Apriori-Verteilung(en)* (die Wahrscheinlichkeit der Hypothese vor den Daten), s. Gleichung 7.3
3. Die *Aposteriori-Verteilung* (die Wahrscheinlichkeit der Hypothese nach den Daten), s. Abbildung 7.11

7.3.5 Apriori-Verteilung

Unser Vorab- bzw. *Apriori*-Wissen zu π sei, dass uns alle Werte gleich („uniform“) plausibel erscheinen, s. Gleichung 7.3.

$$\pi \sim \text{Unif}(0, 1). \quad (7.3)$$

Lies: „ π ist gleich (uniform) verteilt mit der Untergrenze 0 und der Obergrenze 1“.

Man könnte auch sagen: Wir haben praktisch kein Vorwissen, wir sind erstmal (apriori) indifferent; jeder Parameterwert erscheint uns erstmal gleich wahrscheinlich, s. Abbildung 7.8.




Abbildung 7.8: Gleichverteilung mit Parametern min=0 und max=1

7.3.6 Aposteriori-Verteilung

Wie in Definition 7.3 eingeführt, quantifiziert die Aposteriori-Verteilung (kurz: „Post-Verteilung“) unser Wissen zu den Parameterwerten *nach* Kenntnis der Daten und aufbauend auf unserem Vorwissen (Apriori-Wissen). Sie ist das Ergebnis des Bayes-Updates; man bezeichnet sie kurz mit $Pr(H|D)$. Lies: „Die Wahrscheinlichkeit der Hypothese H gegeben der Daten D .“

Dabei nimmt man stillschweigend an, dass die Daten anhand eines gewissen Modells generiert wurden, z.B. der Binomialverteilung, sodass die Likelihood $Pr(D|H)$ berechnet werden kann. Abbildung 7.11 zeigt die Post-Verteilung für unser Globusbeispiel (6 Wasser bei 9 Würfeln).

7.4 Bayes' Theorem

7.4.1 Wozu wird Bayes in der Praxis genutzt?

In der Praxis nutzt man Bayes häufig, wenn man Daten D gesammelt hat, und wissen möchte, wie wahrscheinlich eine Hypothese H ist, im Lichte dieser gesammelten Daten, s. Theorem 7.1. Anders gesagt: Die Likelihood ist relativ einfach zu bestimmen, $Pr(D|H)$, aber nicht so interessant. Die Aposteriori-Wahrscheinlichkeit, $Pr(H|D)$, ist schwerer zu bestimmen, aber interessanter. Man könnte also sinnbildlich sagen, das Bayes-Theorem ist eine „Maschine“, die die Apriori-Wahrscheinlichkeit zusammen mit der Likelihood zur Aposteriori-Wahrscheinlichkeit „umbaut“.

$$Pr(H|D) = \frac{Pr(H) \cdot Pr(D|H)}{Pr(D)} \quad (7.4)$$

Theorem 7.1 (Bayes' Theorem).

$$Pr(H|D) = \frac{Pr(H) \cdot Pr(D|H)}{Pr(D)} = \frac{\text{Apriori} \cdot \text{Likelihood}}{\text{Evidenz}} \quad \square$$

Bayes' Theorem (Theorem 7.1) fragt nach $Pr(H|D)$:

Was ist die Wahrscheinlichkeit der Hypothese H , jetzt wo wir die Daten kennen?

7 Der Globus-Versuch

Und antwortet so (Gleichung 7.4):

Diese Wahrscheinlichkeit entspricht der Apriori-Wahrscheinlichkeit der Hypothese mal der Plausibilität (Likelihood) der Daten unter Annahme (gegeben) der Hypothese. Aus Standardisierungsgründen dividiert man noch die totale Wahrscheinlichkeit der Daten über alle Hypothesen (durch die sog. *Evidenz*).

Für unser Globusbeispiel:

Wie wahrscheinlich ist denn jetzt ein bestimmter Wasseranteil auf der Erde, π , (gegeben den Daten, $W = 6$ und $L = 3$) und wenn wir jede Hypothese apriori für gleich wahrscheinlich halten? Also, wie wahrscheinlich ist z. B. ein Wasseranteil von 70 % oder von 50 %?

7.4.2 Die Evidenz zur Standardisierung

Die Aufgabe der Evidenz ist nur dafür zu sorgen, dass der Wert von $Pr(H|D)$ insgesamt nur Werte zwischen 0 und 1 annehmen kann, also eine brave, normale Wahrscheinlichkeit ist. Würde man in Theorem 7.1 nicht durch die Evidenz teilen, so wäre die Aposteriori-Wahrscheinlichkeit nicht normiert, d. h. sie könnte Werte >1 annehmen, was ja nicht sein darf.

Definition 7.4 (Evidenz). $Pr(D)$ nennt man die *Evidenz*.

Die Evidenz berechnet sich als Summe der Likelihoods für alle Parameterwerte H_i , d. h. als die totale Wahrscheinlichkeit von D , s. Theorem 7.2, vgl. Definition 5.8. $\square$

Theorem 7.2 (Evidenz).

$$Pr(D) = \sum_{i=1}^n Pr(D|H_i) \cdot Pr(H_i) \quad \square$$

Die verschiedenen Parameterwerte kann man auch als die verschiedenen Hypothesen H_i auffassen. Falls es nur zwei Hypothesen bzw. Parameterwerte gibt, vereinfacht sich Theorem 7.2 zu Theorem 7.3.

Theorem 7.3 (Evidenz bei zwei Hypothesen).

$$Pr(D) = Pr(D|H_1) \cdot Pr(H_1) + Pr(D|H_2) \cdot Pr(H_2) \quad \square$$

Beispiel 7.8. In Beispiel 7.10 betrug der Wert der Evidenz $0.03 + 0.002 + 0.012 = 0.044$, also ca. 4 %. $\square$

Schauen wir uns die Bestandteile von Bayes' Theorem (Theorem 7.1) noch etwas näher an:

- (standardisierte) Aposteriori-Wahrscheinlichkeit: $Pr_{Post} := Pr(H|D)$
- Likelihood: $L := Pr(D|H)$
- Apriori-Wahrscheinlichkeit: $Pr_{Apriori} := Pr(H)$
- Evidenz: $E := Pr(D)$
- unstandardisierte Aposteriori-Wahrscheinlichkeit: $Pr_{unPost} = Pr_{Apriori} \cdot L$

Bayes' Theorem gibt die Pr_{Post} an, wenn man die Gleichung mit der $Pr_{Apriori}$ und dem L füttert. Bayes' Theorem wird verwendet, um die Pr_{Post} zu quantifizieren. Die Pr_{Post} ist proportional zu $Pr_{unPost} = L \times Pr_{Apriori}$.

7.4.3 Posteriori als Produkt von Priori und Likelihood

Die *unstandardisierte* Post-Wahrscheinlichkeit Pr_{unPost} ist einfach das Produkt von Likelihood und Priori, s. Gleichung 7.5.

$$Pr_{unPost} = L \times \text{Priori} \quad (7.5)$$

Abb. Abbildung 7.9 visualisiert, dass die Post-Verteilung eine Gewichtung von Apriori und Likelihood ist (das gilt sowohl für die unstandardisierte als auch für die standardisierte Post-Verteilung). Mathematisch gesprochen beruht diese Gewichtung auf einer einfachen Multiplikation der beiden genannten Terme.

7 Der Globus-Versuch




Abbildung 7.9: Prior mal Likelihood = Post

Standardisiert man die unstandardisierte Post-Verteilung, so erhält man die standardisierte Post-Verteilung. Das Standardisieren dient nur dazu, einen Wert zwischen 0 und 1 zu erhalten. Dies erreichen wir, indem wir durch die Summe aller Post-Wahrscheinlichkeiten dividieren. Die Summe der Post-Wahrscheinlichkeiten bezeichnet man (auch) als Evidenz, vgl. Gleichung Gleichung 7.6.

$$\text{Posteriori} = \frac{\text{Likelihood} \times \text{Priori}}{\text{Evidenz}} \quad (7.6)$$

7.4.4 Wissen updaten: Wir füttern Daten in das Modell

Golems können lernen?! Abbildung 7.10 zeigt die Post-Verteilung, nach $n = 1, 2, \dots, n = 9$ Datenpunkten, d. h. Würfeln mit dem Globusball. Man sieht: Am Anfang, apriori, also bevor wir die Daten kennen, vor dem ersten Wurf also, ist jeder Parameterwert gleich wahrscheinlich für den Golem (das Modell). Je nach Ergebnis des Wurfes verändert sich die Wahrscheinlichkeit der Parameterwerte, kurz gesagt, die Post-Verteilung verändert sich in Abhängigkeit von den Daten.

7.5 Die Post berechnen mit der Bayesbox




Abbildung 7.10: Unser Golem lernt

Insofern kann man sagen: Unser Golem (das Modell) lernt. Ob das Modell nützlich ist (präzise Vorhersagen liefert), steht auf einem anderen Blatt.

7.5 Die Post berechnen mit der Bayesbox

Wir erstellen uns eine kleine Tabelle, die man „Bayesbox“ nennen könnte.¹² Unser Ziel ist es, die Posteriori-Wahrscheinlichkeit für verschiedene Parameterwerte zu berechnen, also die Wahrscheinlichkeit, dass ein bestimmter Wasseranteil π vorliegt, gegeben die Daten (6 Wasser bei 9 Würfeln). Dazu gehen wir so vor:

7.5.1 Die Idee der Bayesbox

1. Teile den Wertebereich des Parameters in ein „Gitter“ auf, z. B. 0.1, 0.2, ..., 0.9, 1.
2. Wähle die Apriori-Wahrscheinlichkeit für jeden Parameterwert, z. B. 1/11 bei einer diskreten Gleichverteilung von 0 bis 1.
3. Berechne die Likelihood für jeden Parameterwert.
4. Berechne den unstandardisierten Aposteriori-Wert für jeden Parameterwert (Produkt von Apriori und Likelihood).

¹²Auch Gitter-Methode oder Grid-Methode genannt.

5. Standardisiere den Aposteriori-Wert durch Teilen anhand der Summe aller unstandardisierten Aposteriori-Wahrscheinlichkeiten.

Für jeden Parameterwert berechnen wir eine (Post-)Wahrscheinlichkeit.¹³ Häufig entspricht eine Hypothese einem Parameterwert, etwa wenn man sagt: „Ich glaube, die Münze ist fair“, was auf einen Parameterwert von 50 % herausläuft. Dazu geben wir an, für wie wahrscheinlich wir apriori¹⁴ – also bevor wir irgendwelche Daten erheben – jeden einzelnen Parameterwert halten. Wir machen es uns hier einfach und halten jeden Parameterwert für gleich wahrscheinlich.

Tatsächlich ist der konkrete Wert hier egal, solange wir allen Parameterwerten denselben Wert geben, wird sich die standardisierte Aposteriori-Wahrscheinlichkeit nicht ändern.

Entscheidend ist das Verhältnis der Apriori-Werte zueinander: Geben wir einem Parameterwerten den Wert 2, aber einem anderen den Wert 1, so halten wir Ersteren für (apriori) doppelt so plausibel wie Letztere. Die Post-Wahrscheinlichkeit für den Ersteren wird dann auch doppelt so groß sein wie die für Letztere (alles andere konstant gehalten).

Die „End-Wahrscheinlichkeit“, die unstandardisierte Post-Wahrscheinlichkeit, die „hinten rauskommt“ ist das Produkt von Apriori-Wert und Likelihood. Anschaulich gesprochen: Die Apriori-Werte werden mit den Likelihoodwerten gewichtet¹⁵. Da wir letztlich eine Wahrscheinlichkeitsverteilung bekommen möchten, teilen wir jeden Aposteriori-Wert durch die Summe aller Aposteriori-Werte. Dadurch ist garantiert, dass sich die Aposteriori-Werte zu eins aufaddieren. Damit haben wir dann die Ansprüche an eine Wahrscheinlichkeitsverteilung erfüllt (vgl. Kapitel 4.3.3).

7.5.2 Bayesbox in R berechnen

Legen wir uns ein Gitter mit Parameterwerten (π) an, um deren Aposteriori-Wahrscheinlichkeit zu berechnen. Konkret gesprochen: Wir listen jeden für uns interessanten Wasseranteil (π) auf, also $\pi = 0, 0.1, 0.2, \dots, 1$. Diese Parameterwerte sind die Hypothesen, die wir testen wollen, s. Listing 7.2.

Dann berechnen wir schon mal die Wahrscheinlichkeit der Daten (6 W bei 9 Würfen) gegeben jeweils eines Wasseranteils.

¹³Ein Parameterwert ist eine mögliche Ausprägung des Parameters.

¹⁴synonym: priori

¹⁵synonym: Die Likelihoodwerte werden mit den Apriori-Werten gewichtet.

Listing 7.2 Parameterwerte (Gitter) für Wasseranteile: 0, 0.1, 0.2, ..., 1

```
wasseranteile <- seq(from = 0, to = 1, by = 0.1) # Parameterwerte
wasseranteile
## [1] 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
```

```
Likelihood <- dbinom(6, size = 9, prob = wasseranteile)
Likelihood
## [1] 0.0e+00 6.1e-05 2.8e-03 2.1e-02 7.4e-02 1.6e-01 2.5e-01 2.7e-01 1.8e-01
## [10] 4.5e-02 0.0e+00
```

Schließlich packen wir das alles in eine Tabelle, die „Bayesbox“, s. Tabelle 7.2 und Listing 7.3.

Listing 7.3 Wir basteln uns eine Bayesbox

```
bayesbox_globusversuch <-
  tibble(
    # definiere die Hypothesen (die Parameterwerte, p):
    p = wasseranteile,
    # Lege den Apriori-Wert für alle Parameterwerte auf 1/11 fest:
    Apriori = 1/11) |>
  mutate(
    # berechne Likelihood für jeden Wasseranteil (Parameterwert):
    Likelihood = Likelihood,
    # berechne unstand. Aposteriori-Werte:
    unstd_Post = Likelihood * Apriori,
    # berechne Evidenz, d.i. die Summe aller unstand. Post-Werte:
    Evidenz = sum(unstd_Post),
    # berechne stand. Aposteriori-Werte (summiert zu 1):
    Post = unstd_Post / Evidenz)
```

Die Bayesbox (Tabelle 7.2) zeigt, wie sich die Post-Verteilung berechnet.

7 Der Globus-Versuch

Tabelle 7.2: Die Bayesbox für den Globusversuch, $k=6$ Treffer, $n=9$ Versuche, Apriori-Wahrscheinlichkeit $\Pr(H)=9\%$, und Wasseranteile p von 0 bis 1

id	p	Apriori	Likelihood	unstd_Post	Evidenz	Post
1	0.0	0.091	0.000	0.000	0.091	0.000
2	0.1	0.091	0.000	0.000	0.091	0.000
3	0.2	0.091	0.003	0.000	0.091	0.003
4	0.3	0.091	0.021	0.002	0.091	0.021
5	0.4	0.091	0.074	0.007	0.091	0.074
6	0.5	0.091	0.164	0.015	0.091	0.164
7	0.6	0.091	0.251	0.023	0.091	0.251
8	0.7	0.091	0.267	0.024	0.091	0.267
9	0.8	0.091	0.176	0.016	0.091	0.176
10	0.9	0.091	0.045	0.004	0.091	0.045
11	1.0	0.091	0.000	0.000	0.091	0.000

Für jede Hypothese (Spalte id) berechnen wir die *unstandardisierte* Aposteriori-Wahrscheinlichkeit als Produkt von Apriori und Likelihood.

Um zur *standardisierten* Aposteriori-Wahrscheinlichkeit zu gelangen, teilen wir in jeder Zeile der Bayesbox (also für jede Hypothese) die unstandardisierte Post-Wahrscheinlichkeit durch die Summe der unstandardisierten Post-Wahrscheinlichkeiten, s. Gleichung 7.7.

$$\text{Post} = \frac{\text{Post}_{\text{unstand}}}{\text{Evidenz}} = \frac{\Pr(H) \cdot \Pr(D|H)}{\Pr(D)} \quad (7.7)$$

Dabei haben wir die Apriori-Wahrscheinlichkeit für alle Parameterwerte als gleich angenommen, da wir keinerlei Vorwissen hatten, $\Pr(H_i) = 1/11$. Die Evidenz berechnet sich als Summe der unstandardisierten Post-Wahrscheinlichkeiten, $\Pr(D) = \sum \Pr_{\text{unstandPost}} = 0.09$.

Wenn die Apriori-Wahrscheinlichkeit für alle Hypothesen gleich ist, dann ist die standardisierte Aposteriori-Wahrscheinlichkeit identisch mit der Likelihood. Denn die Post-Wahrscheinlichkeit ist die um die Priori-Wahrscheinlichkeit gewichtete Likelihood. Sind die Apriori-Wahrscheinlichkeiten alle gleich, so ist die Gewichtung der Likelihood für alle Hypothesen gleich.

Beispiel 7.9 (Post-Wahrscheinlichkeit im Globusversuch für $p=.7$). In Beispiel 7.5 haben wir die Wahrscheinlichkeit für 6 Treffer bei 9 Würfeln gegeben einer Trefferwahrscheinlichkeit von $\pi = .7$ berechnet. Damit haben wir die Likelihood $L = Pr(D|H) = .27$ berechnet.

Auf dieser Basis können wir die Aposteriori-Wahrscheinlichkeit Pr_{Post} berechnen, zunächst die unstandardisierte. Dazu haben wir die Apriori-Wahrscheinlichkeit mit der Likelihood multipliziert, s. Gleichung 7.8:

$$Post_{unstand} = Pr(H) \cdot Pr(D|H) = 1/11 \cdot 0.2668 = 0.024 \quad (7.8)$$

Jetzt standardisieren wir die unstandardisierte Post-Wahrscheinlichkeit, indem wir durch die Evidenz dividieren, s. Gleichung 7.9.

$$Post = \frac{Post_{unstand}}{Evidenz} = \frac{0.024}{0.09} = 0.267 \quad (7.9)$$

Fazit: Nach dem Versuch, d. h. nachdem wir die Daten in Betracht gezogen haben, hat sich unsere Meinung über den Wasseranteil von $\pi = .7$ aktualisiert von 0.09 auf 0.27 – das ist eine Verdreifachung. Wir sind uns drei Mal so sicher wie vor dem Versuch, dass der Wasseranteil bei 70 % liegt. $\square$

Übungsaufgabe 7.5. Was wohl mit Post passiert, wenn wir Apriori ändern? $\square$

Abbildung 7.11 zeigt eine Visualisierung der Post-Verteilung mit Hilfe der Funktion `ggline(x, y)` aus dem Paket `ggpubr`. Wie man sieht, ist die Post-Wahrscheinlichkeit am höchsten bei $\pi = 0.7$. Wobei der Bereich von 0.6 bis 0.8 auch recht wahrscheinlich ist.

7 Der Globus-Versuch




Abbildung 7.11: Die Post-Verteilung visualisiert. Die Post-Wahrscheinlichkeit ist am höchsten bei $p=0.7$

7.5.3 Was sagt die Post?


Die Aposteriori-Verteilung (Kurz: „Post-Verteilung“, oder „Post“), Pr_{Post} , sagt, wie plausibel wir jeden Wert von p halten, jetzt, nachdem wir die Daten des Versuchs kennen. Die Post-Wahrscheinlichkeit updatet unser Apriori-Wissen mit dem Wissen, das wir durch die Daten erhalten haben.

Abbildung 7.12 zeigt die Post-Wahrscheinlichkeit für 5, 10 und 20 Parameterwerte. Das mittlere Teilbild mit 10 Parameterwerten entspricht unserer Tabelle oben. Man sieht: Je mehr Parameterwerte, desto „glatter“ wird die Verteilung.

Posterior-Verteilung bei unterschiedlicher Gitterfeinheit


6 Erfolge bei 9 Versuchen, uniforme Prior-Verteilung

Unendlich viele Parameterwerte




pi

10 Parameterwerte




pi

5 Parameterwerte



pi

20 Parameterwerte



pi

Abbildung 7.12: Die Post-Verteilung zunehmend mehr Parameterwerte in der Bayesbox. Je mehr Parameterwerte, desto ‚glatter‘ wird die Verteilung.

Die Post-Verteilung ist sowas wie das Ziel all Ihrer Träume (falls Sie es noch nicht gewusst haben): Aus der Post-Verteilung können Sie ablesen, wie wahrscheinlich Ihre Hypothese (Ihr Lieblings-Parameterwert) ist. Und noch einiges mehr, aber das ist Thema des nächsten Kapitels. □

Übungsaufgabe 7.6 (Peer Instruction: Schlüsse ziehen mit dem Bayes-Modell). Auf einer Party: Unterhalten sich fünf Studis über das Bayesmodell. Einer hat Unrecht, die anderen Recht. Aber wer?

- A) Wenn eine Hypothese A apriori doppelt so wahrscheinlich ist wie die anderen und die Likelihoods für alle Hypothesen gleich ist, dann ist A aposteriori auch doppelt so wahrscheinlich wie die anderen Hypothesen.
- B) Sind alle Hypothesen apriori gleich wahrscheinlich, dann hat die Hypothese mit dem höchsten Likelihood aposteriori auch die höchste Post-Wahrscheinlichkeit.

7 Der Globus-Versuch

- C) Hat eine Hypothese apriori die Wahrscheinlichkeit Null, so hat sie automatisch aposteriori auch die Wahrscheinlichkeit Null, unabhängig von ihrer Likelihood.
- D) Die unstandardisierte Aposteriori-Wahrscheinlichkeit ist gleich der standardisierten mal einen Faktor k .
- E) Hat eine Hypothese die höchste Likelihood, so hat sie automatisch auch die höchste Wahrscheinlichkeit aposteriori. $\square$

7.6 Abschluss

7.6.1 Zusammenfassung

- In unserem Modell haben wir Annahmen zu Pr_{Priori} und L getroffen.
- Auf dieser Basis hat der Golem sein Wissen geupdated zu Pr_{Post} .
- Mit der Bayesbox haben wir viele Hypothesen (Parameterwerte) untersucht und jeweils die Pr_{Post} berechnet.
- Unser Modell bildet die kleine Welt ab; ob es in der großen Welt nützlich ist, steht auf einem anderen Blatt.

Tipp

Wenn Sie auf einen Prozentwert für W tippen müssten, welchen würden Sie nehmen, laut dem Modell (und gegeben der Daten)? $\square$

7.6.2 Der Globusversuch als Modell für zweiwertige Zufallsversuche

Der Globusversuch ist kein prototypisches Beispiel für Statistik in der Praxis, zumindest nicht auf den ersten Blick. Er hat aber den Vorteil, dass es ein einfaches, gut greifbares Beispiel ist, und damit zum Lernen gut geeignet ist. Bei näherer Betrachtung ist der Globusversuch prototypisch für ganz viele Fragestellungen:

- Von einem neuen Produkt wurden von n Exemplaren k verkauft. Auf welchen Wert p kann die Akzeptanzrate dieses Produkts geschätzt werden?
- Ein Chat-Bot hat von n Fragen k richtig beantwortet. Wie hoch kann die Verständnisrate p dieses Programms geschätzt werden?

- Eine neue Krebstherapie hat von n „austherapierten“ Patientis k geheilt. Auf wie hoch kann die Erfolgsrate dieser Therapie geschätzt werden?

Kurz: Der Globusversuch ist ein Muster für zweiwertige Zufallsversuche. Und solche sind häufig im Leben, im Business und in der Wissenschaft.

7.7 Vertiefung

7.7.1 Bayes-Video von 3b1b

Das „Bayes-Paradox-Video“ von 3b1b präsentiert eine gut verständliche Darstellung des Bayes-Theorems aus einer zwar nicht gleichen, aber ähnlichen Darstellung wie in diesem Kapitel.

7.7.2 Bayes als Baum

Bayes' Theorem kann man sich als Baumdiagramm vor Augen führen, Abbildung 7.13. Gesucht sei $Pr(M_1|A)$, also: die Wahrscheinlichkeit, dass das Teil von Maschine 1 produziert wurde, gegeben, dass es Ausschuss ist. Gegeben sind die Wahrscheinlichkeiten, dass Maschine i das Teil produziert hat, $Pr(M_i)$. Außerdem sind die Wahrscheinlichkeiten, dass das Teil Ausschuss ist, $Pr(A|M_i)$, bekannt. Das Diagramm löst die Aufgabe für uns; es zeigt damit die Anwendung von Bayes' Theorem auf. Um $Pr(M_1|A)$ zu erhalten, setzt man die Wahrscheinlichkeit des *günstigen* Asts ins Verhältnis zur Wahrscheinlichkeit *aller relevanten* Äste, $Pr(A)$.

Beispiel 7.10 (Maschine produziert Ausschuss). Die drei Maschinen M_1, M_2, M_3 produzieren den gleichen Artikel. Ihr jeweiliger Anteil an der Produktion liegt bei 60 %, 10 % bzw. 30 %. Die jeweilige Ausschussquote liegt bei 5, 2, bzw. 4 %, s. Abbildung 7.13.

Aufgabe: Wie groß ist die Wahrscheinlichkeit, dass ein defektes Teil von Maschine 1 produziert wurde? Berechnen Sie diese Wahrscheinlichkeit. $\square$

Lösung: Der günstige (gesuchte) Ast, $Pr(M_1 \cap A)$, ist hier fett gedruckt, s. Abbildung 7.13. In Abbildung 7.13 zeigen die runden Kästchen am Ende der Pfade die Wahrscheinlichkeiten des jeweiligen Pfades an.

7 Der Globus-Versuch




Abbildung 7.13: Günstige Pfade

$$Pr(M1|A) = \frac{Pr(M1 \cap A)}{Pr(A)} = \frac{0.6 \cdot 0.05}{0.03 + 0.002 + 0.012} = \frac{0.03}{0.044} \approx 0.68$$

$Pr(M1|A)$ beträgt also ca. 68 %.

Zur Erinnerung: $Pr(A)$ ist die totale Wahrscheinlichkeit (dass ein produziertes Teil Ausschuss ist).

7.7.3 Bayes als bedingte Wahrscheinlichkeit

Bayes' Theorem wird verwendet, um die *Wahrscheinlichkeit einer Hypothese, gegeben einer bestimmten Datenlage* und basierend auf einer *Apriori-Wahrscheinlichkeit dieser Hypothese* zu berechnen. Man berechnet also $Pr(H|D)$. Bayes' Theorem ist nichts anderes als eine normale bedingte Wahrscheinlichkeit.

$Pr(H|D)$ kann man umformen (vgl. Theorem 5.3 und Definition 5.6), dann erhält man Bayes' Theorem, s. Theorem 7.4.

Theorem 7.4 (Bayes' Theorem als bedingte Wahrscheinlichkeit).

$$\begin{aligned}
 Pr(H|D) &= \frac{\overbrace{Pr(H \cap D)}^{\text{umformen}}}{Pr(D)} \\
 &= \frac{\underbrace{\overbrace{Pr(H)}^{\text{Apriori-Wahrscheinlichkeit}} \cdot \overbrace{Pr(D|H)}^{\text{Likelihood}}}_{\underbrace{Pr(D)}_{\text{Evidenz}}}}{Pr(D)} \quad \square
 \end{aligned}$$

7.7.4 Weitere Herleitung der Bayes-Formel

Man kann sich Bayes' Theorem auch wie folgt herleiten:

$$Pr(D \cap H) = Pr(H \cap D) = Pr(D) \cdot Pr(H|D) = Pr(H) \cdot Pr(D|H)$$

Dann lösen wir nach $Pr(H|D)$ auf, s. Gleichung 7.10.

$$Pr(H|D) = \frac{\underbrace{\overbrace{Pr(H)}^{\text{Apriori-Wahrscheinlichkeit}} \cdot \overbrace{Pr(D|H)}^{\text{Likelihood}}}_{\underbrace{Pr(D)}_{\text{Evidenz}}}}{Pr(D)} \quad (7.10)$$

7.7.5 Zusammengesetzte Hypothesen

Das ist vielleicht ein bisschen fancy, aber man kann Bayes' Theorem auch nutzen, um die Wahrscheinlichkeit einer *zusammengesetzten Hypothese* zu berechnen: $H = H_1 \cap H_2$. Ein Beispiel wäre: „Was ist die Wahrscheinlichkeit, dass es Regen (R) und Blitzeis (B) gibt, wenn es kalt (K) ist?“.

Das sieht dann so aus, Gleichung 7.11:

$$\begin{aligned}
 Pr(R \cap B|K) &= \frac{Pr(R \cap B) \cdot Pr(K|R \cap B)}{Pr(K)} \\
 &= \frac{Pr(R) \cdot Pr(B) \cdot Pr(K|R \cap B)}{Pr(K)} \quad (7.11)
 \end{aligned}$$

7 Der Globus-Versuch

Hier haben wir $Pr(R \cap B)$ aufgelöst in $Pr(R) \cdot Pr(B)$, das ist nur zulässig, wenn R und B unabhängig sind.

7.8 Aufgaben

Tipp

Einige der folgenden Aufgaben sind in englischer Sprache. Wenn Ihnen eine andere Sprache (z. B. Deutsch) lieber ist, nutzen Sie einfach die Übersetzungsfunktion Ihres Browsers. Das sind meist nur zwei Klicks. $\square$

7.8.1 Papier-und-Bleistift-Aufgaben

1. Verteilungen-Quiz-01
2. globus1
3. globus2
4. globus3
5. globus-bin
6. globus-bin2
7. Krebs1
8. kekse01
9. kekse03
10. bayes2
11. Bayes-Theorem1
12. bayes-ziel1
13. totale-wskt1
14. wskt-quiz13
15. wskt-quiz12
16. wskt-quiz15
17. qm2-quiz-globos

7.8.2 Aufgaben, für die man einen Computer braucht

2. Rethink2m1
3. Rethink2m2

4. Rethink2m3
5. kekse02
6. euro-bayes
7. bath42
8. Kaefer2
9. Lose-Nieten-Binomial-Grid

8 Die Post befragen

8.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.
Sie können ...

- die Post-Verteilung anhand einer Stichprobenverteilung auslesen
- Fragen nach Wahrscheinlichkeitsanteilen der Post-Verteilung anhand der Stichprobenverteilung beantworten
- Fragen nach Quantilen anhand der Stichprobenverteilung beantworten
- Die Post-Verteilung visualisieren mit R
- Schätzbereiche (Konfidenzintervalle) aus der Post-Verteilung bestimmen anhand von Perzentilintervallen und Highest Density Intervals (HDI)

Der Stoff dieses Kapitels orientiert sich an McElreath (2020), Kap. 3.1 und 3.2.

Lesen Sie folgende Kapitel zur Vorbereitung im Eigenstudium:

- Statistik1, Kap. „Daten umformen“¹
- Statistik1, Kap. „Daten zusammenfassen“²
- Statistik1, Kap. 6.4 „Quantile“³

Zusätzlich ist diese Playlist (bei YouTube) nützlich: Playlist QM2.

Folgende R-Pakete werden in diesem Kapitel benötigt:

```
library(tidyverse)
library(easystats)
library(ggpubr) # optional, Visualisierung
library(prada) # optional, bayesbox automatisiert
```

¹<https://sebastiansauer.github.io/statistik1/030-aufbereiten>

²<https://sebastiansauer.github.io/statistik1/050-zusammenfassen>

³<https://sebastiansauer.github.io/statistik1/050-zusammenfassen.html#quantile>

8.2 Zur Erinnerung: Bayesbox in R berechnen

Berechnen wir mit der Bayesbox („Gittermethode“) die Postverteilung für den Globusversuch. Die Bayesbox ist ein Weg, die Posteriori-Verteilung zu berechnen. Die Posteriori-Verteilung birgt viele nützliche Informationen. Sie ist das zentrale Ergebnis einer Bayes-Analyse.

Beispiel 8.1 (Bayesbox für $W = 6$ Wasser bei $N = 9$ Würfeln). Betrachten wir wieder das Globusmodell mit folgendem Ergebnis: $W = 6$ Wasser, $N = 9$ Würfeln, bei Apriori-Indifferenz gegenüber den Parameterwerten. Und, sagen wir, $g = 11$ Gitterwerten⁴ von 0 bis 1, in Schritten von 0.1, 0.1, 0.2, ..., 0.9, 1.0. $\square$

Übungsaufgabe 8.1 (Welcher Parameterwert hat die höchste Posteriori-Wahrscheinlichkeit?).

Lösung

Aufgrund der Apriori-Indifferenz entsprechen die Posteriori-Wahrscheinlichkeiten den Likelihoods. Die höchste Wahrscheinlichkeit (d. h. Likelihood) hat derjenige Parameterwert, zu dem die Daten am besten passen, und das ist $6/9 = 2/3$, s. Listing 8.1. $\square$

Listing 8.1 Bayesbox mit 6 Wasser bei 9 Versuchen ($g=11$ Gitterwerte)

```
n_success <- 6
n_trials <- 9
p_grid <- seq(from = 0, to = 1, by = .1) ①
L <- dbinom(n_success, size = n_trials, prob = p_grid) ②

bayesbox_6w_9v <- ③
  tibble(p_grid = p_grid, prior = 1) |>
  mutate(likelihood = L) |>
  mutate(unstand_post = (likelihood * prior),
         post = unstand_post / sum(unstand_post))
```

① Sequenz von 0 bis 1 mit Schritten der Größe 0.1.

⁴Die Anzahl g der Gitterwerte ist nicht Teil des Modells; die Anzahl der Gitterwerte entscheiden nur über die Genauigkeit der Post-Verteilung.

8 Die Post befragen

- ② Likelihood mit 6 Treffern bei 9 Würfeln und das Ganze jeweils für alle 11 Parameterwerte
- ③ Dann packen wir alles in eine Tabelle.

```
library(ggpubr)
ggline(bayesbox_6w_9v, x = "p_grid", y = "post")
```

Abb. Abbildung 8.1 zeigt die resultierende Bayesbox (s. Beispiel 8.1); vor allem ist die Post-Verteilung wichtig.




Abbildung 8.1: Die Postverteilung für $W=6$, $N=9$; der wahrscheinlichste Parameterwert ist farblich hervorgehoben

Voilà, die Post-Verteilung zu Beispiel 8.1 als Tabelle, die „Bayesbox“: s. Tabelle 8.1.

8.2.1 Bayesbox automatisiert

Übrigens kann man die Berechnung der Bayesbox auch automatisieren, s. Tabelle 8.2 und Listing 8.2. Entweder importiert („sourced“) man die Funktion bayesbox direkt von Github:

Tabelle 8.1: Postverteilung mit der Bayesbox berechnet

p_grid	prior	likelihood	unstand_post	post
0.0	1	0.00	0.00	0.00
0.1	1	0.00	0.00	0.00
0.2	1	0.00	0.00	0.00
0.3	1	0.02	0.02	0.02
0.4	1	0.07	0.07	0.07
0.5	1	0.16	0.16	0.16
0.6	1	0.25	0.25	0.25
0.7	1	0.27	0.27	0.27
0.8	1	0.18	0.18	0.18
0.9	1	0.04	0.04	0.04
1.0	1	0.00	0.00	0.00

```
url <- paste0(
  "https://raw.githubusercontent.com/sebastiansauer/prada/",
  "master/R/NAME_bayesbox.R")
bayesbox(hyps = p_grid, priors = 1, liks = L)
```

Mit `source` importiert man eine R-Skriptdatei. In diesem Fall steht dort der Code für die Funktion `bayesbox`.

Oder Sie starten das R-Paket `prada` (mit `library(prada)`), wo die Funktion wohnt:

Tabelle 8.2: Eine Bayesbox ‚automatisiert‘ erstellt, mit Hilfe der Funktion `bayesbox`

hyps	priors	liks	post_unstand	post_std
0.0	1	0.00	0.00	0.00
0.1	1	0.00	0.00	0.00
0.2	1	0.00	0.00	0.00
0.3	1	0.02	0.02	0.02
0.4	1	0.07	0.07	0.07
0.5	1	0.16	0.16	0.16
0.6	1	0.25	0.25	0.25
0.7	1	0.27	0.27	0.27
0.8	1	0.18	0.18	0.18

8 Die Post befragen

Tabelle 8.2: Eine Bayesbox ‚automatisiert‘ erstellt, mit Hilfe der Funktion `bayesbox`

hyps	priors	liks	post_unstand	post_std
0.9	1	0.04	0.04	0.04
1.0	1	0.00	0.00	0.00

Listing 8.2 Funktion `bayesbox`, auch im Paket `prada` erhältlich

```
library(prada)
bayesbox(hyps = p_grid, priors = 1, liks = L)
```

①
②

- ① Das Paket `prada` steht nicht im Standard-R-App-Store („CRAN“), sondern auf GitHub. Sie können es so installieren: `pak::pak("sebastiansauer/prada")`.
- ② Die Funktion verhält sich wie eine gewöhnliche Bayesbox: Bei `hyps` schreibt man die Hypothesen (bzw. Parameterwerte) auf. Bei `priors` die Priori-Werte und bei `liks` die Likelihoods der jeweiligen Hypothesen.

8.2.2 Bayesbox geht nur für einfache Modelle

Bisher, für einfache Fragestellungen, hat unsere Bayesbox gut funktioniert. Allerdings: Funktioniert sie auch bei komplexeren Modellen? Schließlich wollen wir ja auch irgendwann Regressionsmodelle berechnen. Angenommen, wir haben ein Regressionsmodell mit 1 Prädiktor, dann haben wir folgende drei Parameter zu schätzen: β_0, β_1, σ . Hört sich gar nicht so viel an. Aber Moment, wir müssten dann z. B. die Frage beantworten, wie wahrscheinlich die Daten aposteriori sind, wenn z. B. $\beta_0 = -3.14$ und $\beta_1 = 2.71$ und $\sigma = 0.70$. Wie viele Zeilen brauchen wir dann in der Bayesbox? Wenn wir für die drei Parameter jeweils 10 Ausprägungen annehmen, was wenig ist, kämen wir $10 \cdot 10 \cdot 10 = 1000 = 10^3$ Zeilen in der Bayesbox. Bei 100 Ausprägungen und 3 Parametern wären es schon $100^3 = 10^6$ Zeilen. Das wäre doch eine recht lange Tabelle.⁵ Bei einer multiplen Regression mit sagen wir 10 Parametern mit jeweils 100 Ausprägungen rechnet das arme R bis zum jüngsten Tag, denn das sind $100^{10} = 10^{20}$ Variationen, also Zeilen in der Bayesbox.



Bitte tue mir das nicht an!

⁵Vorsicht beim Ausdrucken.

 Schon gut, das können wir R nicht zumuten. Wir brauchen eine andere Lösung!

8.3 Mit Stichproben die Post-Verteilung zusammenfassen

8.3.1 Wir arbeiten jetzt mit Häufigkeit, nicht mit Wahrscheinlichkeit

Kurz gesagt: Komplexere Bayes-Modelle können nicht mehr „einfach mal eben“ ausgerechnet werden; die Mathematik wird zu rechenintensiv. Glücklicherweise gibt es einen Trick, der die Sache nicht nur rechnerisch, sondern auch konzeptionell viel einfacher macht. Dieser Trick lautet: Wir arbeiten nicht mehr mit Wahrscheinlichkeiten, sondern mit *Häufigkeiten*. Praktischerweise werden wir in Kürze einen R-Golem kennenlernen, der das für uns erledigt (er heißt *Stan* und kommt aus dem Paket *rstanarm*). Dieser Golem liefert uns *Stichproben* aus der Post-Verteilung zurück. Lernen wir jetzt also, wie man mit solchen Stichproben umgeht.

Die Bayesbox-Methode⁶ ist bei größeren Datensätzen (oder größeren Modellen) zu unpraktisch. In der Praxis werden daher andere, schnellere Verfahren verwendet, sog. Monte-Carlo-Markov-Ketten (MCMC). Wie diese Verfahren funktionieren sind aber nicht mehr Gegenstand dieses Kurses. Wir wenden Sie einfach an, freuen uns und lassen es damit gut sein.⁷

8.3.2 Häufigkeiten sind einfacher als Wahrscheinlichkeiten

Wie gesagt, typische R-Werkzeuge („R-Golems“, wie *Stan*) liefern uns die Post-Verteilung in Stichprobenform zurück. Bevor wir uns aber mit diesen R-Werkzeugen beschäftigen, sollten wir uns vertraut machen mit einer Post-Verteilung in Stichprobenform. Erstellen wir uns also eine Tabelle mit Stichprobendaten aus der Posteriori-Verteilung (s. Dataframe *bayesbox_6w_9v*), s. Listing 8.3.

Die Wahrscheinlichkeit, einen bestimmten Parameterwert (d.h. aus der Spalte *p_grid*) aus Tabelle *bayesbox_6w_9v* zu ziehen, ist proportional zur Posteriori-Wahrscheinlichkeit (*post*) dieses Werts. Ziehen mit Zurücklegen hält die Wahrscheinlichkeiten während des Ziehens konstant. Das Argument *weight_by* legt die

⁶auch Grid-Methode genannt

⁷Eine gute Einführung in die Hintergründe findet sich bei McElreath (2020).

8 Die Post befragen

Listing 8.3 Wir stellen eine Tabelle mit Stichproben aus der Post-Verteilung

```
samples_6w_9v <-  
  bayesbox_6w_9v |> # nimm die Tabelle mit Posteriori-Daten,  
  slice_sample( # Ziehe daraus eine Stichprobe,  
    n = 1e4, # mit insgesamt n=10000 Zeilen,  
    weight_by = post, # Gewichte nach Post-Wskt.,  
    replace = T) |> # Ziehe mit Zurücklegen  
  select(p_grid)
```

Wahrscheinlichkeit fest, mit der eine Zeile gezogen wird. Wir begnügen uns mit der Spalte mit den Wasseranteilswerten (Parameterwerten), `p_grid`, die anderen Spalten brauchen wir nicht.

Wenn Sie jetzt denken: „Warum machen wir das jetzt? Brauchen wir doch gar nicht!“ – Dann haben Sie Recht, für dieses Kapitel. Ab dem nächsten Kapitel werden wir aber, wenn wir mit komplexeren Modellen zu tun haben, nur noch mit Post-Verteilungen auf Stichprobenbasis arbeiten, weil wir Regressionsmodelle nicht mehr mit der Bayesbox berechnen können. Die Anzahl der Zeilen wäre einfach zu groß.

Hier erstmal die ersten 100 gesampelten Parameterwerte (`p_grid`) aus `samples_6w_9v`:

```
## [1] 0.4 0.9 0.6 0.5 0.8 0.8 0.5 0.7 0.8 0.5 0.6 0.5 0.9 0.7 0.6 0.9 0.3 0.7  
## [19] 0.6 0.8 0.4 0.7 0.3 0.9 0.7 0.6 0.6 0.4 0.6 0.5 0.5 0.5 0.6 0.8 0.7 0.5  
## [37] 0.7 0.7 0.4 0.8 0.6 0.6 0.7 0.9 0.6 0.9 0.4 0.8 0.9 0.8 0.6 0.6 0.6 0.5  
## [55] 0.7 0.5 0.8 0.7 0.7 0.6 0.8 0.3 0.5 0.8 0.5 0.7 0.6 0.5 0.8 0.7 0.7 0.7  
## [73] 0.7 0.6 0.7 0.5 0.7 0.6 0.6 0.7 0.8 0.7 0.6 0.8 0.5 0.8 0.7 0.7 0.7 0.6  
## [91] 0.8 0.7 0.7 0.9 0.4 0.5 0.6 0.6 0.5 0.8
```

So sieht unsere „Stichproben-Bayesbox“ als Balkendiagramm aus, s. Abbildung 8.2.

8.3.3 Syntax

```
samples_6w_9v |>  
  count(p_grid) |>  
  ggbarplot(x = "p_grid", y = "n") # aus ggpubr
```

8.3.4 Output




Abbildung 8.2: Stichprobenverteilung auf Basis von Stichproben

Aus Abbildung 8.2 können wir einfach auslesen, wie wahrscheinlich gewisse Parameterwerte sind. So sehen wir, dass das Modell Parameterwerte (Wasseranteil, π) zwischen ca. 50 % und 70 % am wahrscheinlichsten hält. Aber auch kleine Anteile wie 25 % sind nicht auszuschließen (auf Basis der Daten und der Modellannahmen).

Vergleichen Sie Abbildung 8.2 mit Abbildung 7.12: beide sind sehr ähnlich! Das Stichprobenziehen (Abbildung 8.2) nähert sich recht gut an die exakte Berechnung an (Abbildung 7.12).

Es ist hilfreich, sich die Stichproben-Posterior-Verteilung einmal anzuschauen, um ein Gefühl dafür zu bekommen, wie die Post-Verteilung aussieht.

8 Die Post befragen

8.3.5 Visualisierung der Stichprobendaten mit $g = 100$ Gitterwerten

$g = 10$ Gitterwerte ist ein grobes Raster. Drehen wir mal die Auflösung auf $g = 100$ Gitterwerte (Ausprägungen) nach oben.

```
g <- 100
n_success <- 6
n_trials <- 9

bayesbox_g100 <-
  tibble(p_grid = seq(from = 0,
                      to = 1,
                      length.out = g+1),
    prior = 1) |>
  mutate(likelihood = dbinom(n_success,
                             size = n_trials,
                             prob = p_grid)) |>
  mutate(unstand_post = (likelihood * prior),
    post = unstand_post / sum(unstand_post))
```

- ① $g = 100$ Gitterwerte
- ② $W = 6$ Treffer (Wasser)
- ③ $N = 9$ Versuche
- ④ Bayesbox anlegen mit 100 Zeilen, d. h. verschiedenen 100 Parameterwerten
- ⑤ Apriori indifferent: Alle Hypothesen haben die gleiche Apriori-Plausibilität
- ⑥ Die Likelihood ist binomialverteilt.
- ⑦ Post-Verteilung berechnen wie gewohnt

bayesbox_g100 ist eine Bayesbox mit $W = 6$, $N = 9$, $g = 101$; sie ist in Tabelle 8.3 dargestellt.

Tabelle 8.3: Bayesbox mit $g=101$ Gitterwerten für $W=6$ Wasser bei $N=9$ Würfeln (erste paar Zeilen)

p_grid	prior	likelihood	unstand_post	post
0.00	1	0	0	0
0.01	1	0	0	0
0.02	1	0	0	0
0.03	1	0	0	0

8.3 Mit Stichproben die Post-Verteilung zusammenfassen

Tabelle 8.3: Bayesbox mit $g=101$ Gitterwerten für $W=6$ Wasser bei $N=9$ Würfeln (erste paar Zeilen)

p_grid	prior	likelihood	unstand_post	post
0.04	1	0	0	0
0.05	1	0	0	0

Und daraus ziehen wir uns $n = 1000 = 10^3$ Stichproben:

```
samples_g100 <-  
  bayesbox_g100 |> # nimmt die Tabelle mit Posteriori-Daten,  
  slice_sample( # Ziehe daraus eine Stichprobe,  
    n = 1000, # mit insgesamt n=1000 Elementen,  
    weight_by = post, # Gewichte nach Spalte mit Post-Wskt.,  
    replace = T) # Ziehe mit Zurücklegen
```

Abbildung 8.3 zeigt sowohl die exakte Post-Verteilung (farbige, gepunktete Linie) als auch die Post-Verteilung auf Basis von Stichproben (Histogramm). In beiden Fällen erkennt man gut die zentrale Tendenz: ein Wasseranteil von ca. 70 % scheint der „typische“ Wert des Modells zu sein. Außerdem erkennt man, dass das Modell durchaus einige Streuung in der Schätzung des Wasseranteils bereithält. Das Modell ist sich nicht sehr sicher, könnte man sagen.

8 Die Post befragen




Abbildung 8.3: Post-Verteilung mit 100 Gitterwerten, exakt vs. auf Basis von Stichproben

Die Stichprobendaten nähern sich der „echten“ Posteriori-Verteilung an: Die Stichproben-Post-Verteilung ist ähnlich zur echten, exakten Post-Verteilung. Das Stichproben-Verfahren zur Berechnung der Post-Verteilung funktioniert also! Das ist gut, denn wir werden in Zukunft nur noch mit dem Stichproben-Verfahren (zur Erstellung der Post-Verteilung) arbeiten.

Hinweis

Mehr Stichproben und mehr Gitterwerte glätten die Stichproben-Post-Verteilung.

Jetzt die Post-Verteilung noch mal mit mehr Stichproben: $n = 10^6$ Stichproben bei $g = 101$ Gitterwerten aus der Posteriori-Verteilung, s. Abbildung 8.4.

8.4 Die Post-Verteilung befragen




Abbildung 8.4: Post-Verteilung mit einer Million Stichproben und 100 Parameterwerten (Gitterwerten): schön ‚glatt‘. Mittelwert (MW), Modus und Median (Md) liegen eng nebeneinander, da die Verteilung recht symmetrisch ist.

Übungsaufgabe 8.2 (Erstellen Sie Ihre eigene Stichproben-Post-Verteilung). Erstellen Sie eine Stichproben-Post-Verteilung auf Basis der Bayesbox `bayesbox_6w_9v`. Ziehen Sie $n = 100$ Stichproben. Tun Sie das *per Hand*: Übertragen Sie die Werte der Spalte `p_grid` auf kleine Zettel. Dabei soll der Anteil der Zettel pro Wert von `p_grid` der Posteriori-Wahrscheinlichkeit (post) entsprechen (gerundet auf zwei Dezimalstellen). Beispiel: Wenn der Parameterwert 0.7 eine Posteriori-Wahrscheinlichkeit von 0.27 hat, dann schreiben Sie 27 Zettel (von 100) mit dem Wert 0.7. □

8.4 Die Post-Verteilung befragen

So, jetzt befragen wir die Post-Verteilung.

! Wichtig

Die Post-Verteilung ist das zentrale Ergebnis einer Bayes-Analyse. Wir können viele nützliche Fragen an sie stellen.

8 Die Post befragen

Es gibt zwei Arten von Fragen:

A. nach Wahrscheinlichkeiten (p) B. nach Parameterwerten (Quantilen, q)

Beispiel 8.2 (Beispiele für Fragen an die Post-Verteilung). A. Fragen nach Wahrscheinlichkeiten (p):

- Mit welcher Wahrscheinlichkeit liegt der Parameter unter einem bestimmten Wert?
- Mit welcher Wahrscheinlichkeit liegt der Parameter über einem bestimmten Wert?
- Mit welcher Wahrscheinlichkeit liegt der Parameter zwischen zwei bestimmten Werten?


B. Fragen nach Parameterwerten (Quantilen, q):

- Welcher Wert wird mit 95 % Wahrscheinlichkeit nicht überschritten?
- Mit 5 % Wahrscheinlichkeit liegt der Parameterwert nicht unter welchem Wert?
- Welcher Parameterwert hat die höchste Wahrscheinlichkeit?
- Wie ungewiss ist das Modell über die Parameterwerte?

etc. □


Der Unterschied zwischen beiden Arten von Fragen ist in Abbildung 8.5 schematisch illustriert.

Welcher Wasseranteil wird mit 50% Wahrscheinlichkeit nicht



(a) Fragen nach Parameterwerten (q)

Was ist die Wahrscheinlichkeit eines Wasseranteils von höchstens



(b) Fragen nach Wahrscheinlichkeiten (p)

Abbildung 8.5: Unterschied zwischen Fragen nach Wahrscheinlichkeiten (p) und Fragen nach Parameterwerten (q)

Im *linken* Teildiagramm von Abbildung 8.5 fragen wir: „Welcher Wasseranteil wird mit einer gegebenen Wahrscheinlichkeit p nicht überschritten?“ – Wir suchen also einen Parameterwert (Quantil, q). Im *rechten* Teildiagramm fragen wir: „Wie wahrscheinlich ist ein Wasseranteil von höchstens q ?“ – Wir suchen also eine Wahrscheinlichkeit (p).

8.4.1 Fragen nach Wahrscheinlichkeiten (p)

Sagen wir, dass sei unsere Forschungsfrage: *Wie groß ist die Wahrscheinlichkeit, dass der Wasseranteil unter 50 % liegt?* Um diese Frage zu beantworten, zählen wir einfach, wie viele Stichproben die Bedingung erfüllen, und summieren die Wahrscheinlichkeiten dieser Stichproben. Wir zählen (*count*) also die Stichproben, die sich für einen Wasseranteil (*p_grid*) von weniger als 50 % aussprechen.

```
samples_6w_9v |>
  count(p_grid < .5)
```

Wenn wir insgesamt 10000 ($1e4$) Stichproben gezogen haben, können wir noch durch diese Zahl teilen, um einen Anteil zu bekommen. Dieser Anteil ist die Antwort auf die Forschungsfrage: Wie wahrscheinlich ist (laut Modell) ein Wasseranteil kleiner als 50 %? In unseren Daten ist die Wahrscheinlichkeit ca. 10 %.

Übungsaufgabe 8.3 (Was macht die Funktion *count*?). Zur Erinnerung: Der Befehl *count* macht Folgendes: Er gruppiert die Stichprobe nach dem Prüfkriterium (hier: *p_grid < .5*, d. h. Wasseranteil höchstens 50 %). Dann zählt er in jeder der beiden Teiltabellen die Zeilen und liefert diese zwei Zahlen dann zurück. □

Wir zählen, wie oft der Wasseranteil weniger als 50 % beträgt.

```
samples_6w_9v |>
  count(p_grid < .5)
```

<i>p_grid</i> < 0.5	n
FALSE	9047
TRUE	953

Natürlich gibt es verschiedene Wege, die gleiche Frage zu beantworten.

8 Die Post befragen

```
bayesbox_6w_9v |>
  filter(p_grid < .5) |>
  summarise(sum = sum(post))
```

sum
0.1

Beispiel 8.3 (Wasseranteil zwischen 50 und 75 %?). Noch eine Forschungsfrage: Mit welcher Wahrscheinlichkeit liegt der Parameter (Wasseranteil) zwischen 0.5 und 0.75?

Wir zählen die Stichproben, die diesen Kriterien entsprechen.

```
samples_6w_9v |>
  count(p_grid > .5 & p_grid < .75)
```

p_grid > 0.5 & p_grid < 0.75	n
FALSE	4844
TRUE	5156

 Ich würde empfehlen, die Anzahl noch in Anteile umzurechnen. Die kann man dann als Wahrscheinlichkeiten auffassen.

 Das wollte ich auch gerade sagen...

```
samples_6w_9v |>
  count(p_grid > .5 & p_grid < .75) |>
  mutate(Anteil = n / 1e4,
         Prozent = 100 * n / 1e4) # In Prozent
```

p_grid > 0.5 & p_grid < 0.75	n	Anteil	Prozent
FALSE	4844	0.48	48
TRUE	5156	0.52	52

Anstelle von count() könnte man, wenn man möchte, auch filter() verwenden.

```
samples_6w_9v |>
  filter(p_grid > .5 & p_grid < .75) |>
  summarise(sum = n() / 1e4,
    anteil = 100 * n() / 1e4) # In Prozent
```

sum	anteil
0.52	52

Fertig 😊 ☐

Beispiel 8.4 (Wasseranteil zwischen 90 % und 100 %?). Noch ein Beispiel für eine Forschungsfrage: Mit welcher Wahrscheinlichkeit liegt der Parameter zwischen 0.9 und 1?

8.4.2 Syntax

```
samples_6w_9v |>
  count(p_grid >= .9 & p_grid <= 1) |>
  mutate(prop = 100 * n / 1e4) # prop wie "proportion", Anteil
```

8.4.3 Output

p_grid >= 0.9 & p_grid <= 1	n	prop
FALSE	9538	95.4
TRUE	462	4.6

Laut unserem Modell ist es also sehr unwahrscheinlich, dass der Wasseranteil der Erde mind. 90 % beträgt. ☐

Übungsaufgabe 8.4 (Wasseranteil höchstens 50 %?).

🙄 Mit welcher Wahrscheinlichkeit ist der Planet höchstens zur Hälfte mit Wasser bedeckt?

8 Die Post befragen

Lösung

```
samples_6w_9v |> count(p_grid <= .5)
```

p_grid <= 0.5	n
FALSE	7376
TRUE	2624

Wir können auch fragen, welcher Parameterwert am wahrscheinlichsten ist; dieser Wert entspricht dem „Gipfel“ des Berges, s. Abbildung 8.4.

Für unsere Stichproben-Postverteilung, `samples_6w_9v`, s. Abbildung 8.2, lässt sich der Modus so berechnen:

```
map_estimate(samples_6w_9v$p_grid)
```

Parameter	MAP_Estimate
x	0.7

Dabei steht `map` für Maximum Aposteriori⁸, also das Maximum der Post-Verteilung.

Übungsaufgabe 8.5. Bei der Gelegenheit könnten wir folgende, ähnliche Fragen stellen:

- Was ist der mittlere Schätzwert (Mittelwert) zum Wasseranteil laut Post-Verteilung?
- Was ist der mediane Schätzwert (Median)?

Lösung

⁸https://easystats.github.io/bayestestR/reference/map_estimate.html

```
samples_6w_9v |>
  summarise(mean(p_grid),
            median(p_grid))
```

<u>mean(p_grid)</u>	<u>median(p_grid)</u>
0.64	0.6

8.4.4 Fragen nach Parameterwerten

! Wichtig

Schätzbereiche von Parameterwerten nennt man auch *Konfidenz- oder Vertrauensintervalle*⁹.

Welcher Parameterwert wird mit 90 % Wahrscheinlichkeit nicht überschritten, laut unserem Modell? (Gesucht sind also die unteren 90 % der Posteriori-Wahrscheinlichkeit.) Wir möchten also ziemlich sicher sein, was die Obergrenze an Wasser auf diesem Planeten ist. Diese Frage können wir mit dem Befehl `quantile` beantworten.

```
samples_6w_9v |>
  summarise(quantil90 = quantile(p_grid, p = .9))
```

<u>quantil90</u>
<u>0.8</u>

Laut unserem Modell können wir zu 90 % sicher sein, dass der Wasseranteil kleiner ist als ca. 78 %.

Es hilft vielleicht, sich die Post-Verteilung noch einmal vor Augen zu führen, s. Abbildung 8.4.

⁹Tatsächlich gibt es eine Vielzahl an Begriffen, die in der Literatur nicht immer konsistent verwendet werden, etwa Kompatibilitätsintervall, Ungewissheitsintervall, Passungsbereich.

8 Die Post befragen

Was ist das *mittlere* Intervall, das mit 90 % Wahrscheinlichkeit den Parameterwert enthält, laut dem Modell?

Dafür „schneiden“ wir links und rechts die 5 % der Stichproben mit den extremsten Werten ab und schauen, bei welchen Parameterwerten wir als Grenzwerte landen:

```
samples_6w_9v |>
summarise(
  quant_05 = quantile(p_grid, 0.05),
  quant_95 = quantile(p_grid, 0.95))
```

quant_05	quant_95
0.4	0.8

Solche Fragen lassen sich also mit Hilfe von *Quantilen* beantworten.

Übungsaufgabe 8.6 (Welcher Parameterwert ist der wahrscheinlich größte?). Übersetzen wir „wahrscheinlich“ größte in „mit einer Wahrscheinlichkeit von 99 % gibt es keinen größeren“.

Lösung

```
samples_6w_9v |>
summarise(quant99 = quantile(p_grid, p = .99))
```

quant99
0.9

Mit einer Wahrscheinlichkeit von 99 % ist der höchste zu erwartende Wasseranteil 0.9.

Übungsaufgabe 8.7 (Welcher Parameterwert ist der wahrscheinlich kleinste?). Übersetzen wir „wahrscheinlich“ kleinste in „mit einer Wahrscheinlichkeit von 99 % gibt es keinen kleineren“.

Lösung

```
samples_6w_9v |>
  summarise(wahrscheinlich_kleinste =
    quantile(p_grid, p = .01))
```

<u>wahrscheinlich_kleinste</u>
0.3

Mit einer Wahrscheinlichkeit von 99 % ist der kleinste zu erwartende Wasseranteil 0.3 – immer auf Basis unserer beobachteten Daten und der Vorannahmen.

Übungsaufgabe 8.8 (Welcher Parameterwert ist der „vermutlich“ kleinste?). In der „wirklichen“ Welt sind Aussagen nicht immer präzise. Sagen wir, die Chefin der Weltraumbehörde hat in einem Presse-Statement von der „vermutlichen Untergrenze“ hinsichtlich des Wasseranteils gesprochen.

Übersetzen wir „vermutlich“ kleinste in „mit einer Wahrscheinlichkeit von 90 % gibt es keinen kleineren“.

Lösung

```
samples_6w_9v |>
  summarise(wahrscheinlich_kleinste =
    quantile(p_grid, p = .1))
```

<u>wahrscheinlich_kleinste</u>
0.5

Mit einer Wahrscheinlichkeit von 90 % ist der kleinste zu erwartende Wasseranteil 0.5 – immer auf Basis unserer beobachteten Daten und der Vorannahmen.

8.5 Visualisierung der Verteilungen

8.5.1 Perzentilintervalle

Definition 8.1 (Perzentilintervall (PI)). Intervalle (Bereiche), die die „abzuschneidende“ Wahrscheinlichkeitsmasse hälftig auf die beiden Ränder aufteilen, nennen wir *Perzentilintervalle* (PI) oder (synonym) *Equal-Tails-Intervalle* (ETI), s. Abb. Abbildung 8.6.¹⁰ □

80%–ETI: Die mittleren 80% der Wahrscheinlichkeit liegen zwischen 0.45 und 0.81




Abbildung 8.6: Perzentilintervalle: Das Intervall umfasst die mittleren 80% der Wahrscheinlichkeit

Die 10 %-, 20 %-, ..., 100 %-Quantile¹¹ (auf Basis von `bayesbox_g100_samples`) sind in Abbildung 8.7 illustriert.

¹⁰Hier auf Basis der Post-Verteilung `samples_6w_9v`.

¹¹d. h. die Dezile

p_grid	prior	likelihood	unstand_post
0.86	1	0.64	0.64
0.88	1	0.68	0.68
0.62	1	0.24	0.24
0.96	1	0.88	0.88
0.84	1	0.59	0.59
0.88	1	0.68	0.68




Abbildung 8.7: Quantile in 10%-Schritten durch die Verteilung von bayesbox_g100-samples

8.5.2 Schiefe Posteriori-Verteilungen sind möglich

Beispiel 8.5 (Globusversuch: 3 Würfe, 3 Treffer). Noch einmal zum Globusversuch: Gehen wir von 3 Würfeln mit 3 Mal Wasser (Treffer) aus; auf welche Wasseranteile (Parameterwerte) werden wir jetzt schließen? □

Erstellen wir uns dazu mal eine Post-Verteilung (3 Treffer, 3 Würfe), s. Listing 8.4 mit dem Objekt bayesbox_3w_3v.

So sehen die ersten paar Zeilen der Post-Verteilung, samples_3w_3v, aus.


Mit dieser „schiefen“ Post-Verteilung können wir gut die Auswirkungen auf das Perzentil- und das Höchste-Dichte-Intervall vergleichen.

Hier z. B. ein 50 %-Perzentilintervall, s. Abb. Abbildung 8.8, (a).


8 Die Post befragen

Listing 8.4 Schiefe Post-Verteilung in einer Bayesbox

```
bayesbox_3w_3v <-  
  tibble(p_grid = seq(0,1, by = .01),  
    prior = 1) |>  
  mutate(likelihood = dbinom(3, size = 3, prob = p_grid)) |>  
  mutate(unstand_post = likelihood * prior) |>  
  mutate(post_33 = unstand_post / sum(unstand_post))  
  
samples_3w_3v <-  
  bayesbox_3w_3v |>  
  slice_sample(n = 1e6,  
    weight_by = post_33,  
    replace = T)
```



(a) Perzentilintervall (PI)



(b) Höchste-Dichte-Intervall (HDI)

Abbildung 8.8: Schiefe Intervalle: Das PI enthält den wahrscheinlichsten Parameterwert nicht, das HDI schon.

Ein *Perzentilintervall* kann bei schiefen Verteilungen den wahrscheinlichsten Parameterwert nicht enthalten, diesen plausiblen Wert also zurückweisen. Das macht keinen Sinn.

Ein *Highest-Density-Intervall* (HDI¹²) ist schmaler als das Perzentilintervall und enthält immer den wahrscheinlichsten Parameterwert.

Die Grenzwerte dieses ETI (oder jedes beliebig breiten) kann man sich z. B. mit dem Befehl `eti` ausgeben lassen.

¹²Auch als *Highest Density Posterior Interval* (HDPI) bezeichnet.

```
samples_3w_3v |>
  select(p_grid) |>
  eti(ci = .5) # Paket `easystats`
```

Parameter	CI	CI_low	CI_high
p_grid	0.5	0.71	0.94

Der wahrscheinlichste Parameterwert (1) ist *nicht* im Intervall enthalten. Das ist ein Nachteil der ETI.

8.5.3 Intervalle höchster Dichte

Definition 8.2 (Intervalle höchster Dichte (Highest Density Intervals)). Intervalle höchster Dichte (Highest Density Intervals, HDI oder HDPI) sind definiert als das *schmälste* Intervall, das den gesuchten Parameter enthält (in Bezug auf ein gegebenes Modell). □

Der wahrscheinlichste Parameterwert (1) *ist* im Intervall enthalten, was Sinn macht, s. Abbildung 8.8. Bei einem HDI sind die abgeschnittenen Ränder nicht mehr gleich groß, im Sinne davon, dass sie nicht (zwangsläufig) die gleiche Wahrscheinlichkeitsmasse enthalten. Beim PI ist die Wahrscheinlichkeitsmasse in diesen Rändern hingegen gleich groß.

Je unsymmetrischer die Verteilung, desto weiter liegen die Punktschätzer auseinander (und umgekehrt), s. Abb. Abbildung 8.9.

8 Die Post befragen




Abbildung 8.9: Visualisierung der Punktschätzer bei einer schiefen Post-Verteilung (auf Basis von samples_3w_3v)

Mit dem Befehl `hdi` kann man sich die Grenzwerte eines HDI, z. B. eines 50 %-HDI, ausgeben lassen, s. Tabelle 8.4.

```
samples_6w_9v |>
  select(p_grid) |>
  hdi(ci = .5) # aus dem Paket `{easystats}`
```

Tabelle 8.4: 50%-HDI für unser Globusmodell (samples_6w_9v)

Parameter	CI	CI_low	CI_high
p_grid	0.5	0.6	0.7

Das Modell ist sich also zu 50 % sicher, dass der gesuchte Parameter (der Wasseranteil der Erdoberfläche) sich im Bereich von ca. .67 bis .78 befindet (auf Basis eines HDI).

8.6 Fazit

- Bei symmetrischer Posteriori-Verteilung sind beide Intervalle ähnlich oder identisch

- Perzentilintervalle sind verbreiteter
- *Intervalle höchster Dichte* (Highest Density Interval, HDI) sind bei schiefen Post-Verteilungen zu bevorzugen
- Intervalle höchster Dichte sind die *schmalsten* Intervalle für eine gegebene Wahrscheinlichkeitsmasse

Fassen wir zentrale Punkte an einem Beispiel zusammen.

Wir greifen dazu wieder auf den Globusversuch zurück, Datensatz `samples_6w_9v`, s. Listing 8.3. Sagen wir, wir haben 6 Treffer bei 9 Würfeln erzielt.

Lageparameter: Welchen mittleren Wasseranteil kann man erwarten?

```
samples_6w_9v |>
  summarise(
    mean = mean(p_grid),
    median = median(p_grid))
```

mean	median
0.64	0.6

Streuungsparameter: Wie unsicher sind wir in der Schätzung des Wasseranteils?

```
samples_6w_9v |>
  summarise(
    p_sd = sd(p_grid),
    p_iqr = IQR(p_grid),
    p_mad = mad(p_grid)) # Mean Absolute Deviation, Mittlerer Absolutfehler
```

p_sd	p_iqr	p_mad
0.14	0.2	0.15

Anstelle von Streuungsparametern ist es aber üblicher, ein HDI oder PI für den gesuchten Parameter anzugeben.

! Wichtig

Alles Wasser oder was? Im Beispiel dieses Kapitels haben wir uns gefragt, was wohl der Wasseranteil auf dem Planeten Erde ist. Halten Sie sich klar vor Augen: Der Wasseranteil ist ein Beispiel für einen *Parameter*, einer unbekannten Größe eines Modells.

8.7 Aufgaben

8.7.1 Papier-und-Bleistift-Aufgaben

1. kekse03
2. bfi10
3. Kaefer2
4. mtcars-post2a
5. rethink3e1-7-paper
6. mtcars-post3a
7. mtcars-post3a
8. mtcars-post_paper
9. fattails1
10. fattails2
11. eti-hdi

8.7.2 Aufgaben, bei denen man einen Computer benötigt

1. iq01
2. iq02
3. iq03
4. iq04
5. iq05
6. iq06
7. iq07
8. iq08
9. iq10
10. ReThink3e1-7
11. Weinhaendler

12. groesse2
13. groesse1
14. Anteil-Apple
15. Kung-height
16. zwielichter-dozent-bayes

Teil III

Lineare Modelle

9 Gauss-Modelle

9.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.
Sie können ...

- ein Gaußmodell spezifizieren und in R berechnen
- an Beispielen verdeutlichen, wie sich eine vage bzw. eine informationsreiche Priori-Verteilung auf die Posteriori-Verteilung auswirkt

Der Stoff dieses Kapitels orientiert sich an McElreath (2020), Kap. 4.1 bis 4.3.

Lesen Sie zur Vorbereitung folgende Kapitel im Eigenstudium:

- Statistik1, Kap. „Modellgüte“¹
- Statistik1, Kap. „Punktmodelle 2“²
- Statistik1, Abschnitt „Normalverteilung“³

In diesem Kapitel werden die folgenden R-Pakete benötigt.

Hinweis

Software, und das sind R-Pakete, müssen Sie nur einmalig installieren. Aber bei jedem Start von R bzw. Ihrer GUI wie Positron oder RStudio müssen Sie die (benötigten!) Pakete starten.

¹<https://sebastiansauer.github.io/statistik1/060-modellguete>

²<https://sebastiansauer.github.io/statistik1/070-zusammenhaenge>

³<https://sebastiansauer.github.io/statistik1/040-verbildlichen#normalverteilung>

```
library(tidyverse) # Datenjudo
library(rstanarm) # Bayes-Modelle berechnen
library(easystats) # Statistik-Komfort
library(DataExplorer) # Daten verbildlichen
library(ggpubr) # Daten verbildlichen
library(hexbin) # stat_bin_hex ggplot2
```

! Wichtig

Ab diesem Kapitel benötigen Sie *Stan*, das ist das R-Paket *rstanarm*. □

Wir benötigen den Datensatz *!Kung* aus der Datei *Howell1a.csv*. Quelle der Daten ist McElreath (2020) mit Bezug auf Howell.

```
Kung_path <- paste0(
  "https://raw.githubusercontent.com/sebastiansauer/Lehre/",
  "main/data/Howell1a.csv")

kung <- read.csv(Kung_path)

head(kung, n = 5)
```

height	weight	age	male
152	48	63	1
140	36	63	0
137	32	65	0
157	53	41	1
145	41	51	0

Datenquelle⁴

9.2 Einstieg

Beispiel 9.1 (Was war noch mal eine Normalverteilung?). In diesem Kapitel benötigen Sie ein gutes Verständnis der Normalverteilung (die auch als Gauss-Verteilung

⁴<https://raw.githubusercontent.com/sebastiansauer/2021-wise/main/Data/Howell1a.csv>

bezeichnet wird). Fassen Sie daher die wesentlichen Aspekte der Normalverteilung (soweit im Unterricht behandelt) zusammen! □

Beispiel 9.2 (Was war noch mal eine Posteriori-Verteilung?). In diesem Kapitel befragen wir die Post-Verteilung für eine normalverteilte Zufallsvariable, nämlich die Körpergröße der !Kung San. Was war noch mal eine Post-Verteilung und wozu ist sie gut? □

9.3 Wie groß sind die !Kung San?

Dieser Abschnitt basiert auf McElreath (2020), Kap. 4.3.

9.3.1 !Kung San

In diesem Abschnitt untersuchen wir eine Forschungsfrage in Zusammenhang mit dem Volk der !Kung.

The ǀKung are one of the San peoples who live mostly on the western edge of the Kalahari desert, Ovamboland (northern Namibia and southern Angola), and Botswana. The names ǀKung (ǀXun) and Ju are variant words for 'people', preferred by different ǀKung groups. This band level society used traditional methods of hunting and gathering for subsistence up until the 1970s. Today, the great majority of ǀKung people live in the villages of Bantu pastoralists and European ranchers.

Quelle⁵

Wir interessieren uns für die Größe der erwachsenen !Kung, also filtern wir die Daten entsprechend und speichern die neue Tabelle als `kung_erwachsen`.

```
kung_erwachsen <- kung |>
  filter(age >= 18)

nrow(kung_erwachsen)
## [1] 352
```

⁵https://en.wikipedia.org/wiki/%C7%83Kung_people

Tabelle 9.1: Statistiken der metrischen Variablen im Kung-Datensatz

Variable	Mean	SD	Skewness	Kurtosis	n	n_Missing
height	154.60	7.74	0.15	-0.48	352.00	0
weight	44.99	6.46	0.13	-0.51	352.00	0
age	41.14	15.97	0.67	-0.21	352.00	0
male	0.47	0.50	0.13	-2.00	352.00	0

$N = 352$.

Lassen wir uns einige typische deskriptive Statistiken zum Datensatz ausgeben. `{easystats}` macht das tatsächlich recht easy, s. Tabelle 9.1.

```
describe_distribution(kung_erwachsen)
```

Die Verteilungen lassen sich mit `plot_density` (aus dem R-Paket `{DataExplorer}`) erstellen, s. Abbildung 9.1.

```
plot_density(kung_erwachsen)
```




Abbildung 9.1: Verteilungen der Variablen im Kung-Datensatz. Größe und Gewicht sind recht symmetrisch bzw. normalverteilt; Alter ist rechtsschief.

9.3.2 Wir gehen apriori von normalverteilter Größe der !Kung aus

Forschungsfrage: Wie groß sind die erwachsenen !Kung im Durchschnitt?

Wir interessieren uns also für den Mittelwert der Körpergröße einer erwachsenen !Kung-Person, μ . Der Einfachheit halber gehen wir davon aus, dass Frauen und Männer im Schnitt gleich groß sind.



Abbildung 9.2: Mensch; Bildquelle: Wikimedia, Own alterations and File:SVG_Human_With_All_Organs.svg by Madhero88, CC BY-SA, 3.0

9.4 Unser Gauss-Modell der !Kung

9.4.1 Normalverteilung als Grundlage des Modells

Hier gehen wir von einer Normalverteilung (synonym: „Gauss-Verteilung“) des Populationsmittelwert, μ , sowie der tatsächlichen Körpergrößen der einzelnen Personen, h_i (h wie *height*) aus.

Zur Erinnerung: Die (unstandardisierte) Post-Verteilung ist das Produkt von Apriori und Likelihood, s. Abbildung 9.3. Im Folgenden gehen wir diese Bestimmungsstücke der Reihe nach durch, in gewohnter Manier.



Abbildung 9.3: Apriori mal Likelihood ist gleich der unstandardisierten Post-Verteilung

Nur dass wir dieses Mal die Bayesbox nicht von Hand berechnen, sondern Stan die Arbeit überlassen. Stan liefert uns brav eine Stichproben-Post-Verteilung zurück.

 Ich berechne dir die Stichproben-Postverteilung, ganz ohne Bayesbox!

 Toll, dann hab ich ja nix zu tun!

9.4.2 Apriori-Verteilungen

Wir haben zwei Apriori-Größen (Parameter):

1. Den *Mittelwert* der Körpergrößen in der Population, μ . Dieser Parameter beantwortet die Frage: „Wie groß sind die erwachsenen !Kung im Durchschnitt?“
2. Die *Streuung* der tatsächlichen Körpergrößen um den Mittelwert der Population herum, σ . Dieser Parameter beantwortet die Frage: „Wie unterschiedlich groß sind die erwachsenen !Kung?“

Apriori-Verteilung für μ : Der Mittelwert der Körpergröße, μ , sei *normalverteilt* mit $\mu = 178$ und $\sigma = 20$:

$$\mu \sim \mathcal{N}(178, 20) \quad \text{Prior}$$

Apriori-Verteilung für σ : Die Streuung der Größen, σ , sei *exponentialverteilt* (da notwendig positiv) mit $\lambda = 1/8$.


$$\sigma \sim \mathcal{E}(1/8) \quad \text{Prior}$$

Warum gerade $\lambda = 1/8$? Das ist einfach ein grobes Abschätzen mit Blick auf Abbildung 6.9: Bei $\lambda = 1/8$ liegt der Median bei ca. 5 cm. Eine Streuung von ca. 5 cm um den Mittelwert herum erscheint nicht ganz falsch. Dann kann man folgern: $95\%KI(\mu) : 178 \pm 40$. In Worten: Wir halten es apriori zu 95 % für plausibel, dass die *durchschnittliche* Körpergröße der erwachsenen !Kung zwischen 138 cm und 218 cm liegt – laut unserem Modell (unserer Apriori-Verteilung). Das ist eine Aussage über den unbekannten Mittelwert μ , nicht über die Körpergröße einzelner Personen (dafür ist σ zuständig). Das ist ein ausreichend großer Bereich, um Überraschungen zuzulassen, aber eng genug, um biologisch unmögliche Werte auszuschließen.

In Abbildung 9.4 sind unsere Priori-Verteilungen visualisiert.

9 Gauss-Modelle


$\mu \sim \text{dnorm}(178, 20)$



Mittelwert der Körpergröße, μ

(a) Priori der mittleren Körpergröße

$\sigma \sim \text{dexp}(0.1)$



Streuung der Körpergrößen, σ

(b) Priori der Schätzungenauigkeit

Abbildung 9.4: Prioris unseres (ersten) Kung-Modells (m_{kung})

i Hinweis

Dieses Modell hat zwei Parameter, μ und σ . $\square$

Warum 178 cm? Kein besonderer Grund. Hier wollen wir den Effekt verschiedener Priori-Werte untersuchen.⁶ In einer echten Untersuchung sollte man einen inhaltlichen Grund für einen Priori-Wert haben. Oder man wählt „schwach informative“ Prioris, wie das `{rstanarm}` im Standard tut: Damit lässt man kaum Vorabinformation in das Modell einfließen, aber man verhindert extreme Prioris, die meistens unsinnig sind (so wie eine SD von 100 Metern bei der Körpergröße).

⁶Der Autor des zugrundeliegenden Lehrbuchs, Richard McElreath, gibt 178 cm als seine Körpergröße an.

i Hinweis

Wir haben zwar vorab nicht viel Wissen, aber auch nicht gar keines: Eine Gleichverteilung der Körpergrößen kommt nicht in Frage und ein vages Wissen zum Mittelwert haben wir auch. Darüber hinaus ist eine Normalverteilung für Körpergröße biologisch nicht unplausibel und spiegelt sich in den Daten wider, s. Abbildung 9.1.

9.4.3 Likelihood

Für viele Ausprägungen von μ und σ müssen wir (bzw. Stan) die jeweilige Likelihood berechnen. Z. B. ist zu fragen, wie groß die Wahrscheinlichkeit ist, dass wir einen !Kung finden mit Körpergröße 190 bis 191 cm ($h_i = [190, 191]$), gegeben der Hypothesen (Parameterwerte), dass der Populationsmittelwert $\mu = 170$ cm und der Streuung der Körpergrößen $\sigma = 10$ cm beträgt. Nehmen wir an, dass die Körpergrößen, h_i normalverteilt sind, dann können wir die Likelihood anhand der Quantile der Normalverteilung berechnen. Etwa so:

$$L = Pr(h_i = [190; 191] \mid \mu = 180, \sigma = 10)$$

Aber da wir das Rechnen an Stan geben, begnügen wir uns mit einer Kurz-Schreibweise

$$h_i \sim \mathcal{N}(\mu, \sigma) \quad \text{Likelihood}$$

Lies: „Die Körpergröße ist normalverteilt mit Mittelwert μ und Streuung σ .“ Stan weiß dann, was er zu tun hat. Für die Post-Verteilung muss Stan für alle plausiblen Kombinationen von μ und σ die Likelihoods berechnen, s. Abbildung 9.5.

9 Gauss-Modelle




Abbildung 9.5: Die Verteilung der Körpergrößen, h_i setzt sich aus zwei Verteilungen zusammen: Dem Mittelwert μ und der exponentialverteilten Streuung σ

Jetzt haben wir unser Modell (`m_kung`) definiert!

Weil es so schön ist, schreiben/zeichnen wir es hier noch einmal auf, Gleichung 9.1.

$$\begin{array}{ll} \mu \sim \mathcal{N}(M = 178, S = 20) & \text{Prior} \\ \sigma \sim \mathcal{E}(1/8) & \text{Prior} \\ h_i \sim \mathcal{N}(\mu, \sigma) & \text{Likelihood} \end{array} \quad (9.1)$$

9.4.4 Post-Verteilung berechnen mit Stan

Zur Berechnung von `m_kung` nutzen wir jetzt dieses Mal aber *nicht* die Bayesbox, sondern lassen Stan (in R) die Arbeit verrichten.

Okay, Stan, du Golem unseres Vertrauens! An die Arbeit! Berechne uns das Kung-Modell!

```
# library(rstanarm) # nicht vergessen, das Paket zu starten
m_kung <-
  stan_glm(height ~ 1,
```

①

```

prior_intercept = normal(178, 20),           ②
prior_aux = exponential(1/8),               ③
refresh = 0,                                ④
data = kung_erwachsen)

m_kung_post <- as_tibble(m_kung)             ⑤
names(m_kung_post) <- c("mu", "sigma")      ⑥

```

- ① Stan berechnet die Post-Verteilung für die Körpergrößen, h_i , hier height genannt
- ② Apriori für μ
- ③ Apriori für σ
- ④ Stan soll nicht so geschwätzig sein und alle seine Stichproben am Bildschirm zeigen, sondern nur das Wichtigste zurückmelden.
- ⑤ Modellergebnis in Tabelle umwandeln
- ⑥ Schönerer Namen für die Spalten geben

Mit `stan_glm` rufen wir Stan zur Arbeit. `stan_glm`⁷ ist eine Funktion, mit der man Regressionsmodelle berechnen kann. Nun haben wir in diesem Fall kein „richtiges“ Regressionsmodell. Man könnte sagen, wir haben eine AV (Körpergröße), aber keine UV (keine Prädiktoren). Glücklicherweise können wir auch solche „armen“ Regressionsmodelle formulieren: $av \sim 1$ bzw. in unserem Beispiel $height \sim 1$ bedeutet, dass man nur die Verteilung der AV berechnen möchte, aber keine Prädiktoren hat (das soll die 1 symbolisieren).

Betrachten wir die Post-Verteilungen von μ und von σ , s. Abbildung 9.6.

⁷ aus dem R-Paket `rstanarm`, das zuvor installiert und gestartet sein muss, bevor Sie den Befehl nutzen können.




Abbildung 9.6: Die beiden Randverteilungen der Post-Verteilungen, d.h. die Verteilungen für μ und für σ

Plotten wir mal die *gemeinsame* Post-Verteilung von `m_kung`, s. Abbildung 9.7, also die Kombinationen, die „Pärchen“ der Werte von Mittelwert und Streuung.

9.4.5 Fliesendiagramm

Gemeinsame Post-Verteilung von Mittelwert, μ und Streuung, σ

```
m_kung_post |>
  ggplot() +
  aes(x = mu, y = sigma) |>
  geom_hex() +
  scale_fill_viridis_c()
```




Abbildung 9.7: Die gemeinsame Post-Verteilung von Mittelwert und Streuung von `m_kung_neue_prioris`

9.4.6 Streudiagramm




Abbildung 9.8: Die Postverteilung in unterschiedlicher Darstellung

9.4.7 Histogramm

Und hier kommt die Post-Verteilung nur des Mittelwerts.

Natürlich können wir auch nur von einem einzelnen Parameter (z. B. Mittelwert) die Verteilung untersuchen, s. Abbildung 9.9.




Abbildung 9.9: Die Post-Verteilung von μ in `m_kung_neue_prioris`; ein Balkendiagramm bietet sich an.

Da das Modell *zwei* Parameter hat, können wir auch beide gleichzeitig plotten. Wie man sieht, sind die beiden Parameter unkorreliert. In anderen Modellen können die Parameter korreliert sein. Abbildung 9.7 erlaubt uns, für *jede Kombination von Mittelwert und Streuung* zu fragen, wie wahrscheinlich diese bestimmte Kombination ist.

Fassen wir die Ergebnisse dieses Modells zusammen:

- Wir bekommen eine Wahrscheinlichkeitsverteilung für μ und eine für σ (bzw. eine zweidimensionale Verteilung, für die μ, σ -Paare).
- Trotz des eher vagen Priors ist die Streuung der Posteriori-Werte für μ und σ klein: Die große Stichprobe hat die Priori-Werte überstimmt.
- Ziehen wir Stichproben aus der Posteriori-Verteilung, so können wir interessante Fragen stellen.

9.5 Hallo, Posteriori-Verteilung

... wir hätten da mal ein paar Fragen an Sie. 🧐

1. Mit welcher Wahrscheinlichkeit ist die *mittlere* !Kung-Person größer als 1,55 m?
2. Welche mittlere Körpergröße wird mit 95 % Wahrscheinlichkeit nicht überschritten, laut dem Modell?
3. In welchem 90 %-PI liegt μ vermutlich?
4. Mit welcher Unsicherheit ist die Schätzung der mittleren Körpergröße behaftet?
5. Was ist der mediane Schätzwert der mittleren Körpergröße, sozusagen der „Best Guess“?

Antworten folgen etwas weiter unten.

9.5.1 Posteriori-Stichproben von `stan_glm()` berechnen lassen

Mit `stan_glm()` können wir komfortabel die Posteriori-Verteilung berechnen. Die Gittermethode wird nicht verwendet, aber die Ergebnisse sind – für unsere Fälle – ähnlich. Es werden aber auch viele Stichproben simuliert (sog. MCMC-Methode).

Grob gesagt berechnen wir die Post-Verteilung mit `stan_glm` so: `stan_glm(AV ~ UV, data = meine_daten)`.

Wir können, wie wir es oben getan haben, uns die Stichproben der Post-Verteilung ausgeben lassen, und diese z. B. plotten.

Wir können es aber auch komfortabler haben ... Mit dem Befehl `parameters` kann man sich die geschätzten Parameterwerte einfach ausgeben lassen (s. Abbildung 9.7).

```
parameters(m_kung) # aus Paket `easystats`
```

Parameter	Median	95% CI	pd	Rhat	ESS (tail)	Prior
(Intercept)	154.60	(153.81, 155.43)	100%	1.001	2342	Normal (178 +- 20)

Das Wesentliche: Unser Golem schätzt den Größenmittelwert der Kung auf ca. 155cm bzw. auf einen Bereich von etwa 153.81 bis 155.43 (95 %-ETI in der Voreinstellung⁸). Informativ ist vielleicht noch, dass wir den Prior erfahren, der im Modell verwendet wurde. Dazu später mehr.

Hinweis

In dieser Ausgabe sind ein paar Angaben, die wir nicht verstehen, wie `pd`, `Rhat` und `ESS`. Kein Problem: Einfach ignorieren 🤪 Wer Näheres wissen will, findet hier einen Anfang.⁹ Außerdem sei an McElreath (2020) und Gelman et al. (2021) verwiesen. □

9.6 Wie tickt `stan_glm()`?

Hier ein paar Kerninfos zu `stan_glm`:



(a) Hallo Leute,
hier ist Stan!

- `Stan`^a ist eine Software zur Berechnung von Bayesmodellen; das Paket `rstanarm` stellt Stan für uns bereit.
- `stan_glm()` ist für die Berechnung von Regressionsmodellen ausgelegt.
- Will man nur die Verteilung einer einzelnen Variablen (wie `heights`) schätzen, so hat man ... eine Regression ohne Prädiktor.
- Eine Regression ohne Prädiktor schreibt man auf Errisch so: `y ~ 1`. Die 1 steht also für die nicht vorhandene UV; `y` meint die AV (`height`).
- (Intercept) (Achsenabschnitt) gibt den Mittelwert an.

^a<https://mc-stan.org/>

Mehr findet sich in der Dokumentation von `RstanArm`¹⁰.

⁸https://easystats.github.io/parameters/reference/model_parameters.brmsfit.html

⁹<https://easystats.github.io/easystats/>

¹⁰<https://mc-stan.org/rstanarm/>

9.6.1 Schätzwerte zu den Modellparameter

Die Parameter eines Modells sind die Größen, für die wir eine Priori-Verteilung annehmen. Außerdem wählen wir die Normalverteilung als Likelihood-Verteilung, so dass wir die Likelihood berechnen können. Auf dieser Basis schätzen wir dann die Post-Verteilung. Ich sage *schätzen*, um hervorzuheben, dass wir die wahren Werte nicht kennen, sondern nur eine Vermutung haben, unsere Ungewissheit vorab also (wie immer) in der Priori-Verteilung festnageln und unsere Ungewissheit nach Kenntnis der Daten in der Posteriori-Verteilung quantifizieren. Wie gerade gesehen, lassen sich die Modellparameter (bzw. genauer gesagt deren Schätzungen) einfach mit `parameters(modellname)` auslesen.

9.6.2 Stichproben aus der Posteriori-Verteilung ziehen

Wie wir es vom Globusversuch gewohnt sind, können wir aber auch Stichproben aus der Post-Verteilung ziehen.

Hier die ersten paar Zeilen von `m_kung_post`:

```
head(m_kung_post)
```

mu	sigma
154	7.5
155	7.8
155	7.7
154	7.7
154	7.9
155	7.8

In einer Regression ohne Prädiktoren entspricht der Achsenabschnitt dem Mittelwert der AV, daher gibt uns die Spalte (Intercept) Aufschluss über unsere Schätzwerte zu μ (der Körpergröße).

Übungsaufgabe 9.1 (Mit welcher Wahrscheinlichkeit ist $\mu > 155$?).

9 Gauss-Modelle

Lösung

```
names(m_kung_post) <-  
  c("mu", "sigma") # den Namen "(Intercept)" durch "mu" ersetzen, ist prägnanter  
  
m_kung_post |>  
  count(mu > 155) |>  
  mutate(prop = n/sum(n))
```

mu > 155	n	prop
FALSE	3277	0.82
TRUE	723	0.18

Die Wahrscheinlichkeit ist nicht hoch, aber nicht auszuschließen, dass die Kung im Schnitt größer als 155 cm sind. Wahrscheinlicher ist jedoch, dass sie kleiner als 155 cm sind. □

Übungsaufgabe 9.2 (Mit welcher Wahrscheinlichkeit ist $\mu > 165$?).

Lösung

```
names(m_kung_post) <-  
  c("mu", "sigma") # den Namen "(Intercept)" durch "mu" ersetzen, ist prägnanter  
  
m_kung_post |>  
  count(mu > 165) |>  
  mutate(prop = n/sum(n))
```

mu > 165	n	prop
FALSE	4000	1

Oh, diese Hypothese können wir mit an Sicherheit grenzender Wahrscheinlichkeit ausschließen. Aber Achtung: Das war eine Kleine-Welt-Aussage! Die Wahrscheinlichkeit, die Hypothese $\mu > 165$ auszuschließen, ist *nur* dann hoch, wenn das Modell gilt! Wenn also der Golem keinen Mist gebaut hat. Und sind wir mal ehrlich, der Golem tut, was sein:e Herr:in und Meister:in ihm befiehlt. Letztlich liegt es an uns, den Golem auf Spur zu kriegen.

Beispiel 9.3 (Welche mittlere Körpergröße wird mit 95 % Wahrscheinlichkeit nicht überschritten, laut dem Modell `m_kung`?).

Lösung

```
m_kung_post |>
  summarise(q95 = quantile(mu, .95))
```

q95
155

Übungsaufgabe 9.3 (In welchem 90 %-PI liegt μ vermutlich?).

Lösung

```
m_kung_post |>
  eti()
```

Parameter	CI	CI_low	CI_high
mu	0.95	153.8	155.4
sigma	0.95	7.2	8.3

Ein ETI ist synonym zu PI.

Übungsaufgabe 9.4 (Mit welcher Unsicherheit ist die Schätzung der mittleren Körpergröße behaftet?).

Lösung

```
m_kung |>
parameters()
```

Tabelle 9.2: Fixed Effects

Parameter	Median
(Intercept)	154.60

Seeing is believing, s. Abbildung 9.11.

```
m_kung |>
parameters() |>
plot(show_intercept = TRUE)
```

The plot displays the estimated coefficient for the intercept. The x-axis, labeled 'Coefficient', has major tick marks at 0, 50, 100, and 150. The y-axis is labeled '(Intercept)'. A single blue dot is positioned at approximately 154.6 on the x-axis. A vertical dotted line is drawn at x=0.

Abbildung 9.11: Parameter von m_kung, nur einer: der Intercept

Das Modell ist sich recht sicher: die Ungewissheit der mittleren Körpergröße liegt bei nicht viel mehr als einem Zentimeter (95 %-CI).

Übungsaufgabe 9.5 (Was ist der mediane Schätzwert der mittleren Körpergröße, sozusagen der „Best Guess“?).

Lösung

`parameters(m_kung)` hat uns die Antwort schon gegeben: Ca. 155 cm.

Ähnliche Fragen bleiben als Übung für die Lesis. 🤪

9.6.3 Standard-Prioriwerte bei `stan_glm()`

Man kann `stan_glm()` auch ohne Priori-Werte aufrufen. In dem Fall bestimmt Stan die Priori-Werte selber. Welche das sind, kann man sich so anzeigen lassen:

```
prior_summary(m_kung)
## Priors for model 'm_kung'
## -----
## Intercept (after predictors centered)
## ~ normal(location = 178, scale = 20)
##
## Auxiliary (sigma)
## ~ exponential(rate = 0.12)
## -----
## See help('prior_summary.stanreg') for more details
```

Aber welche Priori-Werte verwendet Stan? Ganz einfach: Stan zieht die Stichproben-Daten als Prioris heran. Strenggenommen ist das nicht „pures Bayes“, weil die Priori-Werte ja *vorab*, also vor Kenntnis der Daten bestimmt werden sollen.

Man sollte diese Standardwerte als (komfortablen) Minimalvorschlag sehen. Kennt man sich im Sachgebiet aus, kann man meist bessere Prioris finden. Die Voreinstellung ist nicht zwingend; andere Werte wären auch denkbar.

Standardwerte von `stan_glm`

- Intercept: μ , der Mittelwert der Verteilung Y
 - $\mu \sim \mathcal{N}(\bar{Y}, sd(Y) \cdot 2.5)$

- als Streuung von μ wird die 2.5-fache Streuung der Stichprobe (für Y) angenommen.
- Auxiliary (sigma): σ , die Streuung der Verteilung Y
 - $\sigma \sim \mathcal{E}(\lambda = 1/sd(Y))$
 - als „Streuung“, d. h. λ von h_i wird $\frac{1}{sd(Y)}$ angenommen. $\square$

Eine sinnvolle Strategie ist, einen Prior so zu wählen, dass man nicht übergewiss ist, also nicht zu sicher Dinge behauptet, die dann vielleicht doch passieren (also die Ungewissheit zu gering spezifiziert), andererseits sollte man extreme, unplausible Werte ausschließen.

! Wichtig

Bei der Wahl der Prioris gibt es nicht die eine, richtige Wahl. Die beste Entscheidung ist auf transparente Art den Stand der Forschung einfließen zu lassen und eigene Entscheidungen zu begründen. Häufig sind mehrere Entscheidungen möglich. Möchte man lieber vorsichtig sein, weil man wenig über den Gegenstand weiß, dann könnte man z. B. auf die Voreinstellung von `rstanarm` vertrauen, die „schwachinformativ“ ist, also nur wenig Priori-Information in das Modell einfließen lässt.

9.6.4 Wenn es schnell gehen muss

`stan_glm()` ist deutlich langsamer als z. B. der befreundete Golem `lm()`. Der Grund für Stans Langsamkeit ist, dass er viele Stichproben zieht, also viel zu zählen hat. Außerdem wiederholt er das Stichprobenziehen (im Standard) 4 Mal, damit sein Meister prüfen kann, ob er (Stan) die Arbeit auch immer richtig gemacht hat. Die Idee dabei ist: Wenn alle vier Durchführungen (auch „Ketten“, engl. „chains“, genannt) zum etwa gleichen Ergebnis kommen, dann wird schon alles mit rechten Dingen zugegangen sein. Weichen die Ergebnisse der 4 Ketten voneinander ab, so ist Stan ein Fehler unterlaufen, oder irgendetwas ist „dumm gelaufen“. An dieser Stelle schauen wir uns die Ketten nicht näher an, aber es sei notiert, dass man die Anzahl der Ketten mit dem Argument `chains` steuern kann. Möchte man, dass Stan sich beeilt, so kann man `chains = 1` setzen, das spart Zeit, s. `m_kung_1kette`.


```
m_kung_1kette <- stan_glm(height ~ 1,
  data = kung_erwachsen,
  chains = 1, # nur 1 Kette, anstelle von 4, spart Zeit
  refresh = 0)

parameters(m_kung_1kette)
```

9.7 Modell `m_kung_neue_priors`: Standard-Priori-Werte

Im Modell `m_kung` haben wir unsere eigenen Priori-Werte einfließen lassen. Jetzt vertrauen wir die Wahl der Priors Stan an. Betrachten Sie dazu unser zweites Kung-Modell, `m_kung_neue_priors`.

```
m_kung_neue_priors <-
  stan_glm(height ~ 1,
    refresh = FALSE, # bitte nicht so viel Ausgabe drucken
    data = kung_erwachsen)
parameters(m_kung_neue_priors)
```

Tabelle 9.3: Parameter von `m_kung_neue_priors` mit Standard-Prioriwerten

Parameter	Median	95% CI	pd	Rhat	ESS (tail)	Prior
(Intercept)	154.60	(153.78, 155.42)	100%	1.001	2239	Normal (154.60 +- 19.36)

Wir haben noch nicht alle Informationen kennengelernt, die in Tabelle 9.3 ausgegeben werden. Im Zweifel: Einfach ignorieren. Wichtige Fähigkeit im Studium. 😊

! Wichtig

Vergleichen Sie die Parameterwerte von `m_kung` und `m_kung_neue_priors`! Was fällt Ihnen auf? Nichts? Gut! Tatsächlich liefern beide Modelle sehr ähnliche Parameterwerte. Die Prioriwerte waren nicht so wichtig, weil wir genug Daten haben. Hat man einigermaßen viele Daten, so fallen Prioriwerte nicht mehr ins

Gewicht, zumindest wenn sie moderat gewählt waren.

9.7.1 Posteriori-Verteilung und Parameter plotten

Leider liefert der Stan-Golem keinen braven Tibble (Tabelle) zurück.

🧑 Stan, streng dich mal ein bisschen an!

🤖 Mach's halt selber, wenn du es besser kannst!

Daher müssen wir die Ausgabe des Stan-Golems erst in eine schöne Tabelle umwandeln:

```
m_kung_neue_prioris_tibble <-  
  as_tibble(m_kung_neue_prioris)  
  
head(m_kung_neue_prioris_tibble)
```


(Intercept)	sigma
155	7.7
154	7.8
155	8.0
155	7.8
155	8.2
155	7.8

Außerdem ist der Name der ersten Spalte eigentlich unzulässig, da Spaltennamen in R nicht mit Sonderzeichen anfangen dürfen (sondern mit Buchstaben). Daher müssen wir den Namen mit „Samthandschuhen“ anpacken. Auf Errisch sind das die Backticks, die wir um den Namen rumwickeln müssen, s. die folgende Syntax.

9.7.2 Mit {ggpubr}


```
m_kung_neue_prioris_tibble |>  
  gghistogram(x = "`(Intercept)`") # Aus dem Paket "ggpubr"
```

9.7 Modell *m_kung_neue_prioris*: Standard-Priori-Werte



9.7.3 Mit {ggplot}

```
m_kung_neue_prioris_tibble |>  
  ggplot(aes(x = `(Intercept)`)) + # Aus dem Paket `ggplot2`  
  geom_histogram()
```



Als Ausblick: Ein Vergleich mehrerer Priori-Werte wäre auch nützlich, um ein skeptisches Publikum von der Wahl (bzw. der Indifferenz) der gewählten Priori-Werte zu überzeugen.

9.7.4 Welche Körpergrößen erwartet unser Modell

Bisher haben wir untersucht, wie die Verteilung der *mittleren* Körpergrößen, μ , laut unserem Modell aussehen könnte; wir haben uns also mit der Post-Verteilung von μ beschäftigt. Wir könnten aber auch an der Frage der Verteilung der *tatsächlichen* Körpergrößen, h_i , laut Modell, interessiert sein: Wie groß sind sie denn, die !Kung, laut unserem Modell?

Wie wir wissen, liefert unser Stan-Golem eine *Stichproben-Postverteilung*. Wenn wir das Ergebnisobjekt unserer Analyse, `m_kung`, in eine Tabelle (Tibble) umwandeln und (die ersten paar Zeilen) betrachten, sehen wir diese Stichproben:


```
m_kung |> as_tibble() |> head()
```

(Intercept)	sigma
154	7.5
155	7.8
155	7.7
154	7.7
154	7.9
155	7.8

Laut unserem Modell sind die Körpergrößen, h_i , normalverteilt mit μ und σ . μ wird von Stan, der in Begriffen der Regressionsanalyse denkt, schnöde als (Intercept) bezeichnet. Wir könnten jetzt also für jede Zeile eine Normalverteilung berechnen. Und daraus zufällig eine Zahl ziehen. Damit hätten wir dann unsere Verteilung von Körpergrößen laut Modell. Diese Verteilung nennt man auch *Posterior-Prädiktiv-Verteilung*. Prädiktiv daher, weil sie die Werte der Körpergrößen „vorhersagt“.

Wir können uns diese Verteilung auch komfortabel von R ausgeben lassen, s. Abbildung 9.12.

```
pp_check(m_kung)
pp_check(m_kung, "stat")
```



- (a) Die dunkle, dicke Dichtekurve zeigt die tatsächliche Verteilung der Körpergrößen im Datensatz. Die hellen, leichten Dichtekurven zeigen die Verteilungen laut der Post-Verteilung unseres Modells.
- (b) Der wahre Wert einer Test-Statistik (T), hier der Mittelwert der Körpergrößen, wird mit der Verteilung der Körpergrößen in Bezug gesetzt.

Abbildung 9.12: Die Posterior-Prädiktiv-Verteilung: Die Verteilung der tatsächlichen Körpergrößen auf Basis der Post-Verteilung. Unser Modell stellt die tatsächliche Verteilung ganz gut nach.

9.8 Fazit

9.8.1 Zusammenfassung

Wir haben die Posteriori-Verteilung für ein Gauss-Modell berechnet. Dabei hatten wir ein einfaches Modell mit metrischer Zielvariablen, ohne Prädiktoren, betrachtet. Die Zielvariable, Körpergröße (height), haben wir als normalverteilt mit den Parametern μ und σ angenommen. Für μ und σ haben wir jeweils keinen einzelnen (fixen) Wert angenommen, sondern eine Wahrscheinlichkeitsverteilung, der mit der Priori-Verteilung für μ bzw. σ festgelegt ist.

! Wichtig

Kontinuierliches Lernen ist der Schlüssel zum Erfolg.

9.9 Aufgaben

9.9.1 Papier-und-Bleistift-Aufgaben

1. exp-tab
2. exp-tab2
3. norms-sd
4. small-wide-normal
5. exp1
6. distros
7. mtcars-post_paper
8. groesse03
9. pupil-size2
10. groesse04
11. Priorwahl1

9.9.2 Aufgaben, für die man einen Computer benötigt

1. stan_glm01
2. ReThink4e1
3. ReThink4e3
4. Kung-height
5. Pupil-size
6. IQ-Studentis
7. Priori-Streuung

10 Einfache lineare Modelle

10.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.
Sie können ...

- Das Zusammenspiel von Apriori-Verteilungen und linearem Modell zur Berechnung der Likelihood erläutern
- die Post-Verteilung für einfache lineare Modelle in R berechnen
- zentrale Informationen zu Modellparametern des Regressionsmodells – wie Lage- oder Streuungsmaße und auch Schätzintervalle – aus der Post-Verteilung herauslesen

Der Stoff dieses Kapitels orientiert sich an McElreath (2020), Kap. 4.4.

Lesen Sie zur Vorbereitung folgende Kapitel im Eigenstudium:

- Statistik1, Kap. „Geradenmodelle 1“¹
- Statistik1, Abschnitt „z-Transformation“²

In diesem Kapitel benötigen Sie folgende R-Pakete:

```
library(tidyverse)
library(easystats)
library(rstanarm) # Bayes-Golem
library(ggpubr) # Datenvisualisierung
```

¹<https://sebastiansauer.github.io/statistik1/080-regression1>

²<https://sebastiansauer.github.io/statistik1/060-modellguete.html#die-z-transformation>

10 Einfache lineare Modelle

Da wir in diesem Kapitel immer mal wieder eine Funktion aus dem R-Paket {easystats} verwenden: Hier finden Sie eine Übersicht aller Funktionen des Pakets.³

In diesem Kapitel benötigen wir den Datensatz zu den !Kung-Leuten, aus der Datei Howell1a.csv, McElreath (2020).

```
kung_path <- paste0(
  "https://raw.githubusercontent.com/sebastiansauer/",
  "Lehre/main/data/Howell1a.csv") ①

kung <- read.csv(kung_path) ②

kung_erwachsen <- kung |> filter(age > 18) ③
```

- ① Pfad zum Datensatz; Sie müssen online sein, um die Daten herunterzuladen.
- ② Daten einlesen
- ③ Auf Erwachsene Personen begrenzen (d. h. Alter > 18)

10.2 Einstieg

Übungsaufgabe 10.1 (Grundkonzepte der linearen Regression). Fassen Sie die Grundkonzepte der linearen Regression kurz zusammen! □

Übungsaufgabe 10.2 (Was ist eine Post-Verteilung und wozu ist sie gut?). Erklären Sie kurz, was eine Post-Verteilung ist – insbesondere im Zusammenhang mit den Koeffizienten einer einfachen Regression – und wozu sie gut ist. □

Dieses Kapitel stellt ein einfaches Regressionsmodell vor, bei dem die Körpergröße auf das Gewicht zurückgeführt wird; also ein sehr eingängiges Modell. Neu (im Vergleich zu einer Frequentistischen Regression mit `lm`) ist dabei lediglich, dass die drei Parameter des Modells – β_0 , β_1 , σ – jetzt über eine Post-Verteilung verfügen. Die Post-Verteilung ist der Zusatznutzen der Bayes-Statistik. Die „normale“ Regression hat uns nur einzelne Werte für die Modellparameter geliefert („Punktschätzer“). Mit Bayes haben wir eine ganze Verteilung pro Parameter; das ist informationsreicher als mit der Frequentistischen Regressionsanalyse.

³https://easystats.github.io/easystats/articles/list_of_functions.html

⁴Da es viele Funktionen sind, bietet es sich an mit `Strg-F` auf der Webseite nach Ihrem Lieblingsbe-
fehl zu suchen.

10.3 Den Datensatz verstehen

10.3.1 Statistiken zum !Kung-Datensatz

Tabelle 10.1 zeigt die zentralen deskriptiven Statistiken zum !Kung-Datensatz.

```
Kung_path <- "data/Howell1a.csv"
kung <- read_csv(Kung_path)

kung_erwachsen <- kung |> filter(age > 18)

describe_distribution(kung_erwachsen)
```

Tabelle 10.1: Verteilung der (metrischen) Variablen im !Kung-Datensatz

Variable	Mean	SD	Min	Max	n
height	154.64	7.8	137	179	346
weight	45.05	6.5	32	63	346
age	41.54	15.8	19	88	346
male	0.47	0.5	0	1	346

Wie aus Tabelle 10.1 abzulesen ist, liegt das mittlere Körpergewicht (weight) bei ca. 45 kg (SD ca. 7 kg).

Wir brauchen explorative Datenanalyse (EDA) nicht wirklich, um einfache Bayes-Regressionen zu verstehen. Aber EDA hilft, die Daten zu verstehen, was essenziell ist, wenn man Erkenntnisse aus den Daten gewinnen will. Das Paket DataExplorer hat ein paar nette Hilfen zur explorativen Datenanalyse.

```
library(DataExplorer)
```

Was man im Rahmen einer EDA stets prüfen sollte, sind fehlende Werte. Gibt es in diesem Datensatz fehlende Werte? Nein, s. Abbildung 10.1.

```
kung_erwachsen |> plot_missing()
```

10 Einfache lineare Modelle




Abbildung 10.1: Fehlende Werte – fehlen.

Betrachten wir als Nächstes die Verteilung der *numerischen* Variablen des Datensatzes, s. Abbildung 10.2.

```
kung_erwachsen |> plot_histogram()
```




Abbildung 10.2: Verteilung (als Histogramme dargestellt) der numerischen Variablen des Datensatzes

Wie man in Abbildung 10.2 sieht, ist Alter (*age*) rechtsschief verteilt, wohingegen Größe (*height*) und Gewicht (*weight*) deutlich symmetrischer oder sogar normalverteilt sind. *height* ist bimodal (zweigipflig), vermutlich auf Grund der Vermischung der Verteilung der beiden Geschlechter.

Betrachten wir nun die Verteilung der *kategorialen* Variablen des Datensatzes: Es gibt etwas mehr Männer als Frauen im Datensatz.

```
kung_erwachsen |>
  count(male) |>
  mutate(Anteil_maenner = n / sum(n))
```

male	n	Anteil_maenner
0	182	0.53
1	164	0.47

Korrelationen sind, ähnlich wie Regressionen, eine Methode, um Zusammenhänge zwischen Variablen darzustellen. Allerdings sind Korrelationen nur zwischen

10 Einfache lineare Modelle

zwei Variablen definiert; Regressionsanalysen können komfortabel mehrere Variablen berücksichtigen. Die Korrelationen der (numerischen) Variablen sind in Abbildung 10.3 dargestellt.

```
kung_erwachsen |> plot_correlation()
```




Abbildung 10.3: Korrelationsmatrix

Starke Zusammenhänge finden sich (wenig überraschend) zwischen Größe und Gewicht sowie zwischen Geschlecht und Größe/Gewicht.

Übungsaufgabe 10.3 (Vertiefung: EDA-Bericht). Probieren Sie mal die folgende Funktion aus, die Ihnen einen Bericht zur EDA erstellt: `create_report(kung_erwachsen)`. □

10.3.2 Der Zusammenhang von Gewicht und Größe

Die (einfache) Regression prüft, inwieweit zwei Variablen, Y und X linear zusammenhängen. Je mehr sie zusammenhängen, desto besser kann man X nutzen, um Y vorherzusagen (und umgekehrt). Hängen X und Y zusammen, heißt das nicht (unbedingt), dass es einen *kausalen* Zusammenhang zwischen X und Y gibt. *Linear* ist ein Zusammenhang, wenn der Zuwachs in Y relativ zu X konstant ist: wenn

X um eine Einheit steigt, steigt Y immer um b Einheiten (nicht kausal, sondern deskriptiv gemeint).⁵

Laden wir die !Kung-Daten und visualisieren wir uns den Zusammenhang zwischen Gewicht (X , UV) und Größe (Y , AV), Abbildung 10.4.




Abbildung 10.4: Der Zusammenhang zwischen Gewicht (X) und Größe (Y)

Wie man sieht in Abbildung 10.4, gibt es einen deutlichen linearen Zusammenhang zwischen Gewicht und Größe: Je schwerer (je höher das Gewicht einer Person), desto größer (desto höher ihr Wert in der Körpergröße).

10.3.3 Prädiktor zentrieren

i Hinweis

Wenn Sie mit der z -Transformation nicht vertraut sind, macht es Sinn, das Thema (jetzt) zu lernen, s. hier.⁶ □

⁵Datenquelle (<https://raw.githubusercontent.com/sebastiansauer/Lehre/main/data/Ho-wella.csv>), McElreath (2020).

⁶<https://sebastiansauer.github.io/statistik1/060-modellguete.html#die-z-transformation>

Tabelle 10.2: Gewicht (weight) und zentriertes Gewicht (weight_c): Zentrierte Gewichtswerte zeigen, wie viele Kilogramm eine Person vom Mittelwert entfernt ist. So ist die Person mit der ID 1 drei Kilogramm schwerer als der Mittelwert von 45 kg.

id	weight	weight_c	height	age	male
1	48	3	152	63	1
2	36	-9	140	63	0
3	32	-13	137	65	0

Zieht man von jedem Gewichtswert den Mittelwert ab, so bekommt man die Abweichung des Gewichts vom Mittelwert; der Prädiktor ist dann *zentriert* (engl. to center). Wenn man den Prädiktor *Gewicht* (weight) zentriert hat, ist der Achsenabschnitt, β_0 , einfacher zu verstehen: In einem Modell mit zentriertem Prädiktor (weight) gibt der Achsenabschnitt die Größe einer Person mit durchschnittlichem Gewicht an. Würde man weight nicht zentrieren, gibt der Achsenabschnitt die Größe einer Person mit weight=0 an, was nicht wirklich sinnvoll zu interpretieren ist; vgl. Gelman et al. (2021), Kap. 10.4, 12.2. Man zentriert eine Variable X , indem man von x_i den Mittelwert $\bar{x}$ abzieht: $x_i - \bar{x}$. Im Folgenden zentrieren wir *Gewicht* (weight); die resultierende Variable nennen wir weight_c (c wie „centered“).

```
kung_zentriert <-
  kung_erwachsen |>
  mutate(weight_c = weight - mean(weight))
```

Mit Hilfe der Funktion center() aus {easystats} kann man sich das Zentrieren erleichtern.

```
kung_zentriert <-
  kung_erwachsen |>
  mutate(weight_c = as.numeric(center(weight)))
```

Wie man sieht, wird die Verteilung von weight durch die Zentrierung „zur Seite geschoben“. Der Mittelwert von weight_c (das zentrierte Gewicht) liegt jetzt bei 0, s. Abbildung 10.5.

10.4 Modell `m_kung_gewicht_c`: zentrierter Prädiktor




Abbildung 10.5: Das Zentrieren ändert die Verteilungsform nicht, sondern „schiebt“ die Verteilung nur zur Seite. Der resultierende Mittelwert ist dann Null. Die zentrierten Werte zeigen, wie weit ein Messwert vom Mittelwert entfernt ist (hier in der Einheit kg).

Das Schwierigste ist dabei nur, nicht zu vergessen, dass `kung_zentriert` die Tabelle mit zentriertem Prädiktor ist, nicht `kung_erwachsen`.

10.4 Modell `m_kung_gewicht_c`: zentrierter Prädiktor

Erstellen wir nun ein Regressionsmodell mit dem zentrierten Prädiktor, Gewicht. Die Forschungsfrage lautet: „Wie stark ist der lineare Zusammenhang von Größe und Gewicht?“. Anders formuliert: „Um wie viele Zentimeter Körpergröße unterscheiden sich zwei erwachsene Kung, wobei die eine Person um 1 kg leichter ist als die andere?“.

Einige Regressionskoeffizienten, wie der Achsenabschnitt (engl. intercept) sind schwer zu interpretieren: Bei einem (erwachsenen) Menschen mit `Gewicht 0`, was wäre wohl die Körpergröße? Hm, Philosophie steht heute nicht auf der Tagesordnung. Da wäre es schön, wenn wir die Daten so umformen könnten, dass der Achsenabschnitt eine sinnvolle Aussage macht. Zum Glück geht das leicht: Wir zentrieren den Prädiktor (Gewicht)!

! Wichtig

Durch Zentrieren kann man die Ergebnisse einer Regression einfacher interpretieren.

10 Einfache lineare Modelle

Zuerst stellen wir die Modelldefinition von `m_kung_gewicht_c` auf.

Für jede Ausprägung des Prädiktors *Gewicht zentriert* (`weight_centered`), wc_i , wird eine Post-Verteilung für die abhängige Variable *Größe* (`height`, h_i) berechnet. Der Mittelwert μ für jede Post-Verteilung ergibt sich aus dem linearen Modell (unserer Regressionsformel). Die Post-Verteilung berechnet sich auf Basis der Priori-Werte und des Likelihoods (Bayes-Formel). Wir brauchen Priori-Werte für die Steigung β_1 und den Achsenabschnitt β_0 der Regressionsgeraden. Außerdem brauchen wir einen Priori-Wert, der die Streuung σ der Größe (`height`) angibt; dieser Wert wird als exponentialverteilt angenommen. Der Likelihood gibt an, wie wahrscheinlich ein bestimmter Wert `height` ist, gegeben μ und σ . Theorem 10.1 stellt die Modelldefinition dar. Abbildung 10.6 zeigt, wie die drei Parameter zusammen die Likelihood definieren.




Abbildung 10.6

Theorem 10.1 stellt Abbildung 10.6 als Modellgleichung dar. Abbildung 10.7 zeigt anhand der Regressionsgerade, wie die vorhergesagten Körpergrößen zustande kommen.

10.4 Modell `m_kung_gewicht_c`: zentrierter Prädiktor

men: μ (vorhergesagte Körpergröße) beruht auf dem jeweiligen X -Wert (d. h. Gewicht, UV); zusammen mit der Streuung der Körpergrößen um den Mittelwert (σ) ergibt sich dann die Normalverteilung der Körpergrößen, y_i (AV).




Abbildung 10.7: Die Körpergrößen, Y (AV) sind abhängig vom Wert des Körpergewichts, X , (UV)

Theorem 10.1 (Modelldefinition `m_kung_gewicht_c`).

$height_i \sim \text{Normal}(\mu_i, \sigma)$	Likelihood
$\mu_i = \beta_0 + \beta_1 \cdot \text{weightcentered}_i$	Lineares Modell, Regressionsformel
$\beta_0 \sim \text{Normal}(178, 20)$	Priori
$\beta_1 \sim \text{Normal}(0, 10)$	Priori
$\sigma \sim \text{Exp}(0.1)$	Priori

□

$$height_i \sim \text{Normal}(\mu_i, \sigma) \quad \text{Likelihood}$$

Der Likelihood von `m_kung_gewicht_c` ist ähnlich zu den vorherigen Modellen (`m_kung`). Nur gibt es jetzt ein kleines „Index-i“ am μ und am h (h wie heights). Es gibt

10 Einfache lineare Modelle

jetzt nicht mehr nur einen Mittelwert μ , wie in `m_kung`, sondern für jede Beobachtung (Zeile) einen Mittelwert μ_i . Lies etwa so:

„Die Wahrscheinlichkeit, eine bestimmte Größe h bei Person i zu beobachten, gegeben μ und σ ist normalverteilt (mit Mittelwert μ und Streuung σ)“.

Betrachten wir als nächstes die Regressionsformel, `m_kung_gewicht_c`:

$$\mu_i = \beta_0 + \beta_1 \cdot \text{weightcentered}_i \quad \text{Lineares Modell}$$

μ ist jetzt *nicht* mehr ein Parameter, der (stochastisch) geschätzt werden muss (wie in `m_kung`). μ wird jetzt (deterministisch) *berechnet*. Gegeben β_0 und β_1 ist μ also ohne Ungewissheit bekannt. weightcentered_i ist der zentrierte Gewichtswert (`weight_c`) der i ten Beobachtung, also einer !Kung-Person (Zeile i im Datensatz). Lies etwa so:

„Der vorhergesagte mittlere Wert der Körpergröße, μ_i , der i ten Person berechnet sich als Summe von β_0 und β_1 mal weightcentered_i “.

μ_i ist eine lineare Funktion von `weight_c`. β_1 gibt den Unterschied in `height` zweier Beobachtung an, die sich um eine Einheit in `weight_c` (also auch in `weight`) unterscheiden (Steigung der Regressionsgeraden). β_0 gibt an, wie groß μ ist, wenn `weight_c` Null ist, d.h. beim Durchschnittsgewicht (Achsenabschnitt, engl. `intercept`).

Was sind unsere Priori-Verteilung des Modells `m_kung_gewicht_c`? Sie gleichen denen von `m_kung`, allerdings haben wir jetzt zusätzlich β_1 . Dieser Parameter gibt die Steigung der Regressionsgeraden an (auch als „Regressionsgewicht“ bezeichnet). Damit wird die Stärke des (linearen) Zusammenhangs zwischen UV (X) und AV (Y) festgelegt. Hier definieren wir den Zusammenhang als normalverteilt mit Mittelwert 0 und Streuung 10 cm. Damit liegt der Bereich plausibler Werte für den Zusammenhang von Gewicht und Größe zwischen -20 cm bis +20 cm Unterschied in der Körpergröße pro Kilogramm Unterschied im Körpergewicht. Das ist ein recht informationsarmer Wert: Viele Werte sind möglich, auch unerwartete. Man kann argumentieren, dass diese Apriori-Verteilung biologisch nicht realistisch ist. Dazu später mehr.

10.4 Modell `m_kung_gewicht_c`: zentrierter Prädiktor

$\beta_0 \sim \text{Normal}(178, 20)$

Priori Achsenabschnitt

$\beta_1 \sim \text{Normal}(0, 10)$

Priori Regressionsgewicht

$\sigma \sim \text{Exp}(0.1)$

Priori Sigma

Parameter sind hypothetische Kreaturen: Man kann sie nicht beobachten, sie existieren nicht wirklich. Ihre Verteilungen nennt man Priori-Verteilungen. β_0 wurde in `m_kung` als μ bezeichnet, da wir dort eine „Regression ohne Prädiktoren“ berechnet haben. σ ist uns schon als Parameter bekannt und behält seine Bedeutung aus dem letzten Kapitel. Da `height` nicht zentriert ist, liegt der Mittelwert von β_0 bei 178 und nicht bei 0. β_1 fasst unser Vorwissen, ob und wie sehr der Zusammenhang zwischen Gewicht und Größe positiv (gleichsinnig) ist. β_1 ist hier schwach informativ: Im Schnitt behauptet diese Apriori-Verteilung, sei der Zusammenhang gleich Null. Aber die Apriori-Verteilung akzeptiert auch recht starke positive und negative (!) Werte. Diese Wahl an Apriori-Werten ist nicht unbedingt ideal. Wir sollten uns künftig noch andere (bessere) Parameter für die Apriori-Verteilung von β_1 überlegen. Die Anzahl der Prioris entspricht übrigens der Anzahl der Parameter des Modells.

Jetzt sind wir bereit, das Modell bzw. die Post-Verteilung zu berechnen. Erinnern wir uns: „Prioris plus Daten gleich Post“. Los, Stan, an die Arbeit! Berechne uns die Post-Verteilung. Nennen wir das Modell `m_kung_gewicht_c`.

```
m_kung_gewicht_c <-  
  stan_glm(  
    height ~ weight_c, # Regressionsformel  
    prior = normal(0, 10), # Regressionsgewicht (beta 1)  
    prior_intercept = normal(178, 20), # beta 0  
    prior_aux = exponential(0.1), # sigma  
    refresh = 0, # zeig mir keine Details  
    data = kung_zentriert)  
  
parameters(m_kung_gewicht_c)
```

```
parameters(m_kung_gewicht_c) |>  
  select(1,2,4,5) |>  
  print_md()
```

Tabelle 10.3: Parameter von m_kung_gewicht_c

Tabelle 10.3: Fixed Effects		
Parameter	Median	CI
(Intercept)	154.65	(154.10, 155.20)
weight_c	0.91	(0.82, 0.99)

Wie man in Tabelle 10.3 sieht, wird der Zusammenhang von Gewicht und Größe, d. h. β_1 , die Steigung der Regressionsgeraden, auf einen Wert zwischen ca. 0.8 bis 1.0 kg Unterschied in der Körpergröße geschätzt (wenn sich die Personen um 1 kg Körpergewicht unterscheiden). Es gibt also einen Zusammenhang zwischen Gewicht und Größe (laut unserem Modell). Danke, Stan!

Übungsaufgabe 10.4 (Peer-Instruction: Wie leitet sich der Wert der Körpergrößen h_i her?). Welche Aussage zur Herleitung der Körpergrößen, h_i , ist korrekt?

- Die Körpergrößen sind gleich mit dem um das Regressionsgewicht gewichteten Wert des jeweiligen Körpergewichts (d. h. $h_i = \beta_1 \cdot wc_i$).
- Die Körpergrößen sind apriori normalverteilt mit dem Mittelwert 178 cm (in diesem Modell).
- Die Körpergrößen sind apriori normalverteilt mit dem Mittelwert, der sich aus dem Regressionsmodell ergibt für jede Beobachtung i .
- Die Körpergrößen sind das Resultat zweier Parameter: Der mittleren Körpergröße, μ , sowie der Streuung in der Population, σ . $\square$

10.5 Die Post-Verteilung befragen

10.5.1 m_kung_starkes_beta1

Mit der Apriori-Verteilung von β_1 in m_kung_gewicht_c sind wir nicht zufrieden. Sagen wir stattdessen, auf Basis gut geprüfter Evidenz haben wir folgendes Modell festgelegt: height ~ weight_c, s. Gleichung 10.1. Dabei haben wir folgende Apriori-Verteilungen gewählt:

$$\beta_1 \sim N(5, 3); \beta_0 \sim N(178, 20); \sigma \sim E(0.1) \tag{10.1}$$

Dieses Mal haben wir für β_1 durchaus „meinungsstarke“ Werte ausgewählt. Im Schnitt gehen wir von einem Zusammenhang aus, so dass es einen Unterschied von 5 cm in der AV (Größe) gibt, wenn sich die UV (Gewicht) um 1 Einheit (1 kg) unterscheidet zwischen zwei Personen. Wir nennen das Modell `m_kung_starkes_beta1`⁷, s. Listing 10.1.

Listing 10.1 Modelldefinition von `m_kung_starkes_beta1` in R

```
m_kung_starkes_beta1 <-
  stan_glm(
    height ~ weight_c, # Regressionsformel
    prior = normal(5, 3), # Regressionsgewicht (beta 1)
    prior_intercept = normal(178, 20), # beta 0
    prior_aux = exponential(0.1), # sigma
    refresh = 0, # zeig mir keine Details
    data = kung_zentriert)
```

Hinweis

Mit `seed` kann man die Zufallszahlen fixieren, so dass jedes Mal die gleichen Werte resultieren. So ist die Nachprüfbarkeit der Ergebnisse („Reproduzierbarkeit“) sichergestellt⁸. Welche Wert für `seed` man verwendet, ist egal, solange alle den gleichen verwenden. Der Autor verwendet z. B. oft den Wert 42. Zur Erinnerung: Der Golem zieht Zufallszahlen, damit erstellt er Stichproben, die die Postverteilung schätzen. Das Argument `seed` ist nur relevant, wenn man die Ergebnisse von Stan zwischen zwei Durchläufen vergleichen möchte. Ansonsten hat es keine Bedeutung.

10.5.2 Mittelwerte von β_0 und β_1 aus der Post-Verteilung

Betrachten wir die ersten paar Zeilen aus der Post-Verteilung, s. Tabelle 10.4. Dazu wandeln wir das Ergebnis-Objekt von `stan_glm`, d. h. `m_kung_starkes_beta1` in eine Tabelle (einen „Tibble“) um.

⁷Wer ist hier für die Namensgebung zuständig? Besoffen oder was?

⁸oder zumindest besser sichergestellt

Listing 10.2 Die Post-Verteilung bekommen wir, indem wir das Ergebnisobjekt von `stan_glm` in einen Tibble (Dataframe) umwandeln.

```
m_kung_starkes_beta1_post <-  
m_kung_starkes_beta1 |>  
  as_tibble() |>  
  head()
```

Tabelle 10.4: Die ersten paar Zeilen der Post-Verteilung von `m_kung_starkes_beta1`

id	(Intercept)	weight_c	sigma
1	155.1	0.9	5.0
2	155.5	0.8	5.1
3	155.5	0.9	5.1

Tabelle 10.5 zeigt die Zusammenfassung der Stichproben aus der Post-Verteilung; `komfortabel` zu erhalten mit dem Befehl `parameters(m_kung_starkes_beta1)`.

Tabelle 10.5: Parameter von `m_kung_starkes_beta1`

Tabelle 10.5: Fixed Effects			
Parameter	Median	CI	pd
(Intercept)	154.65	(154.14, 155.19)	100%
weight_c	0.91	(0.82, 0.99)	100%

Definition 10.1 (Effektwahrscheinlichkeit). Die Kennzahl `pd` (propability of direction) gibt die *Effektwahrscheinlichkeit* an: Die Wahrscheinlichkeit, dass der Effekt positiv (also größer als Null) oder negativ ist (je nachdem ob der Median des Effekts positiv oder negativ ist). `pd` gibt aber nicht an, wie stark der Effekt ist, nur ob er klar auf einer Seite der Null liegt. Damit ist er so etwas (grob!) Ähnliches wie der `p`-Wert in der Frequentistischen Statistik (Makowski et al., 2019). □

Am besten das Diagramm zur Effektwahrscheinlichkeit (`pd`) anschauen, s. Abbildung 10.8. `Rhat` und `ESS` sind Kennzahlen, die untersuchen, ob mit der Stichprobenziehung im Bayes-Modell alles gut funktioniert hat. Bei einfachen Modellen (die wir

hier berechnen) sollte da in der Regel alles in Ordnung sein. Rhat sollte nicht (viel) größer als 1 oder 1,01 sein. ESS (effective sample size) gibt die Anzahl der effektiv nutzbaren Stichproben an (im Standard werden 4000 berechnet). Die Zahl sollte nicht deutlich geringer sein. Wir werden uns aber mit diesen beiden Kennwerten nicht weiter beschäftigen in diesem Kurs.

```
plot(p_direction(m_kung_starkes_beta1))
```




Abbildung 10.8: Diagramm zur Probability of Direction, Modell `m_kung_starkes_beta1`

10.5.3 Visualisieren der „mittleren“ Regressionsgeraden

Zur Erinnerung: Die Bayes-Analyse liefert uns viele Stichproben zu den gesuchten Parametern, hier β_0 , β_1 und σ . Überzeugen wir uns mit einem Blick in die Post-Verteilung von `m_kung_starkes_beta1`, s. Tabelle 10.4. Wir können z. B. ein Lagemaß wie den Median hernehmen, um die „mittlere“ Regressionsgerade zu betrachten, s. Abbildung 10.9.

```
kung_zentriert |>
  ggplot() +
  aes(x = weight_c, y = height) +
```

10 Einfache lineare Modelle

```
geom_point() +  
geom_abline(  
  slope = 0.9, # Median beta 1  
  intercept = 154, # Median beta 0  
  color = beta1col)
```




Abbildung 10.9: Die mittlere Regressionsgerade, unser ‚Best-Guess‘ zum Zusammenhang von Gewicht und Größe

10.5.4 Zentrale Statistiken zu den Parametern

In diesem Modell gibt es drei Parameter: β_0, β_1, σ .⁹ Hier folgen einige Beispiele an Fragen, die wir an unser Modell bzw. die Post-Verteilung stellen können.

10.5.4.1 Lagemaße zu den Parametern

- Was ist die mittlere Größe der erwachsenen Kung? (Das war die Forschungsfrage des letzten Kapitels; β_0)
- Was ist der Schätzwert für den Zusammenhang von Gewicht und Größe? (β_1)

⁹In manchen Lehrbüchern wird β_0 auch als α bezeichnet.

- Was ist der Schätzwert für Ungewissheit in der Schätzung der Größe? (σ)
- Was ist der wahrscheinlichste und der mediane Wert für β_1 ?

Eine nützliche Zusammenfassung der Post-Verteilung bekommt man mit `parameters(modell)`, s. Tabelle 10.5. Wandelt man das Ausgabe-Objekt der Bayes-Regression, d.h. `m_kung_starkes_beta1`, mit `as_tibble()` in eine Tabelle um, so bekommt man eine Tabelle mit den Stichproben der Post-Verteilung, s. Tabelle 10.4.

Wie wir gesehen haben, nutzen wir diese Tabelle der Post-Verteilung immer wieder. Daher haben wir sie uns als ein Objekt abgespeichert, `m_kung_starkes_beta1_post`, s. Listing 10.2. Jetzt haben wir wieder eine schöne Tabelle mit Stichproben aus der Post-Verteilung, die wir wie gewohnt befragen können. Oder man erstellt selber ein Diagramm mit `ggplot` oder `ggpubr`, s. Abbildung 10.10, um einen Überblick über Lage- und Streuungsmaße der Post-Verteilung zu bekommen.

```
m_kung_starkes_beta1_post |>
  ggplot(aes(x = weight_c)) +
  geom_density(fill = beta1col)
```




Abbildung 10.10: Die Postverteilung für den Parameter Gewicht (zentriert); die plausiblen Werte liegen zwischen 0.8 und 1.0 cm pro Kilogramm Gewicht

10 Einfache lineare Modelle

Abbildung 10.10 zeigt, dass Mittelwert, Median und Modus eng zusammenliegen. Zur Erinnerung: Der Modus gibt den häufigsten, d.h. hier also den wahrscheinlichsten, Wert an. Der Modus wird hier auch *Maximum a Posteriori* (MAP) genannt, daher:

```
m_kung_starkes_beta1_post |>  
  summarise(map_b1 = map_estimate(weight_c))
```

Hier ist die Verteilung von σ visualisiert, s. Abbildung 10.11. Interessanterweise ist die Post-Verteilung von σ *normalverteilt* und *nicht* mehr *exponentialverteilt*, wie in der Apriori-Verteilung: Die Daten haben die Apriori-Verteilung „überstimmt“.

```
m_kung_starkes_beta1_post |>  
  ggplot(aes(x = sigma)) +  
  geom_density(fill = errorcol)
```





Abbildung 10.11: Die Post-Verteilung für den Parameter sigma, m_kung_starkes_beta1; die plausiblen Werte liegen zwischen 4.7 cm und 5.5 cm.

Alternativ kann man sich die Verteilung eines Parameters auch so ausgeben lassen, gleich mit Intervallgrenzen, z. B. 95 %, s. Abbildung 10.12.

```
m_kung_starkes_beta1_hdi <-
  m_kung_starkes_beta1_post |>
  select(weight_c) |> # analog für `select(sigma)`
  hdi() # analog mit eti()

plot(m_kung_starkes_beta1_hdi, data = m_kung_starkes_beta1_post)
```

Highest Density Interval (HDI)

Abbildung 10.12: Die Parameter Gewicht (zentriert) Modells `m_kung_starkes_beta1`

Ergänzt man bei `plot()` noch `show_intercept = TRUE` wird auch der Achsenabschnitt angezeigt. Den Parameter der Vorhersage-Genauigkeit, σ bekommt man mit `get_sigma`:

```
get_sigma(m_kung_starkes_beta1)
## [1] 5.1
## attr("class")
## [1] "insight_aux" "numeric"
```

10.5.5 Streuungsmaße zu den Parametern

- Wie unsicher sind wir uns in den Schätzungen der Parameter?

10 Einfache lineare Modelle

Diese Frage wird durch die Ungewissheitsintervalle in der Ausgabe beantwortet.

i Hinweis

An einigen Stellen wird empfohlen, anstelle eines (gebräuchlichen) 95 %-Intervalls auf ein 90 %- oder 89 %-Intervall auszuweichen, aufgrund der besseren numerischen Stabilität.

10.5.6 Ungewissheit von β_0 und β_1 aus der Post-Verteilung visualisiert


Abbildung 10.13 stellt die Ungewissheit der Post-Verteilung dar, in dem einige Stichproben aus der Post-Verteilung visualisiert werden.

```
kung_zentriert |>
  ggplot(aes(x = weight_c, y = height)) +
  geom_point() +
  geom_abline(
    data = m_kung_starkes_beta1_post |> slice_head(n = 10),
    aes(slope = weight_c, intercept = `(Intercept)`),
    alpha = .3)


kung_zentriert |>
  ggplot(aes(x = weight_c, y = height)) +
  geom_point() +
  geom_abline(
    data = m_kung_starkes_beta1_post |> slice_head(n = 100),
    aes(slope = weight_c, intercept = `(Intercept)`),
    alpha = .1)

kung_zentriert |>
  ggplot(aes(x = weight_c, y = height)) +
  geom_point() +
  geom_abline(
    data = m_kung_starkes_beta1_post |> slice_head(n = 1e3),
    aes(slope = weight_c, intercept = `(Intercept)`),
    alpha = .01)
```


10.5 Die Post-Verteilung befragen



(a) 10 Stichproben



(b) 100 Stichproben



(c) 1000 Stichproben

Abbildung 10.13: Ungewissheit der Post-Verteilung, dargestellt anhand von Stichproben aus der Post-Verteilung

Einfacher ist die Visualisierung mit `estimate_expectation`, s. Abbildung 10.14.

```
estimate_expectation(m_kung_starkes_beta1, by = "weight_c") |> # Regressionsgerade  
plot() +  
geom_point(data = kung_zentriert, aes(x = weight_c, y = height)) # Punkte
```




Abbildung 10.14: Schätzbereich für die bedingten mittleren Körpergröße, also die Regressionsgerade mit Unsicherheitsintervall

10.5.7 Fragen zu Quantilen des Achsenabschnitts

i Hinweis

Zur Erinnerung: Bei einem zentrierten Prädiktor misst der Achsenabschnitt die mittlere Größe¹⁰.

- Welche mittlere Größe wird mit einer Wahrscheinlichkeit von 50 %, 90 % bzw. 95 % Wahrscheinlichkeit nicht überschritten?
- Welche mittlere Größe wird mit einer Wahrscheinlichkeit von 95 % nicht unterschritten?
- Von wo bis wo reicht der innere 50 %-Schätzbereich (ETI) der mittleren Körpergröße?

Quantile:

```
m_kung_starkes_beta1_post |>  
  summarise(  
    quantile = quantile(m_kung_starkes_beta1_post$beta1, probs = c(0.5, 0.9, 0.95))  
  )
```

¹⁰ μ

```
q_50 = quantile(`(Intercept)`, prob = .5),
q_90 = quantile(`(Intercept)`, prob = .9),
q_05 = quantile(`(Intercept)`, prob = .95))
```

q_50	q_90	q_05
155	155	155

50 %-ETI:

```
m_kung_starkes_beta1 |>
  eti(ci = .5)
```

Parameter	CI	CI_low	CI_high	Effects	Component
(Intercept)	0.5	154.46	154.84	fixed	conditional
weight_c	0.5	0.88	0.94	fixed	conditional

10.5.8 Fragen zu Wahrscheinlichkeitsmassen des Achsenabschnitts

Wie wahrscheinlich ist es, dass die mittlere Größe bei mind. 155 cm liegt?

```
m_kung_starkes_beta1_post |>
  count(gross = `(Intercept)` >= 155) |>
  mutate(prop = n / sum(n))
```

gross	n	prop
FALSE	3593	0.9
TRUE	407	0.1

Die Wahrscheinlichkeit beträgt 0.1.

Wie wahrscheinlich ist es, dass die mittlere Größe höchstens 154.5 cm beträgt?

10 Einfache lineare Modelle

```
m_kung_starkes_beta1_post |>  
  count(klein = `(Intercept)` <= 154.5) |>  
  mutate(prop = n / sum(n))
```

klein	n	prop
FALSE	2833	0.71
TRUE	1167	0.29

Die Wahrscheinlichkeit beträgt 0.29.

10.6 Post-Verteilung bedingt auf einen Prädiktorwert

10.6.1 Bei jedem Prädiktorwert eine Post-Verteilung für μ

Komfort pur: Unser Modell erlaubt uns für jeden beliebigen Wert des Prädiktors eine Post-Verteilung (von μ) zu berechnen. Hier am Beispiel von `m_kung_post`, s. Abbildung 10.15.

10.6 Post-Verteilung bedingt auf einen Prädiktorwert





Abbildung 10.15: Für jeden beliebigen Prädiktorwert kann man eine Post-Verteilung bekommen. A: Regressionsmodell mit einigen ausgewählten Gewichtswerten. Es ist jeweils die Wahrscheinlichkeitsverteilung für den vorhergesagten Y-Wert dargestellt (hier sind die Verteilungen zu groß dargestellt zur besseren Sichtbarkeit). B: Für jeden beliebigen Gewichtswert (Y) bekommt man eine (auf den jeweiligen X-Wert bedingten) Post-Verteilung.

10.6.2 Visualisierung

Was ist wohl die Wahrscheinlichkeit der Körpergröße bei einem bestimmten Gewicht? Angenommen wir wissen, dass das Gewicht bei, sagen wir 45 kg liegt. Welche Körpergröße ist (im Schnitt) zu erwarten? Wie unsicher sind wir uns über diesen Mittelwert? Etwas formaler ausgedrückt: $\mu | \text{weight} = 45$

45 kg entspricht genau dem Mittelwert von weight. Geht man von zentrierten Prädiktorwerten aus, gilt in dem Fall $\text{weight}_c = 0$. Erstellen wir uns dazu eine Tabelle und plotten diese, s. Abbildung 10.16.

```
mu45 <-  
  m_kung_gewicht_c_post |>  
  mutate(mu45 = `(Intercept)`)  
  
mu45 |>  
  ggplot(aes(x = mu45)) +  
  geom_density()
```



10.6 Post-Verteilung bedingt auf einen Prädiktorwert




Abbildung 10.16: Post-Verteilung der Größe (laut unserem Modell) bei einem Gewicht von 45kg

Analog können wir fragen, wie groß wohl eine Person mit 50 kg im Mittelwert sein wird und wie (un)gewiss wir uns über diesen Mittelwert sind. 50 kg, das sind 5 über dem Mittelwert, in zentrierten Einheiten ausgedrückt also `weight_c = 5`. Auch dazu erstellen wir uns eine Tabelle, s. Tabelle 10.6. Die Verteilung der mittleren Größe bei einem Gewicht von 50 kg ist weiter „rechts“ (Richtung höhere Größe) lokalisiert, s. Abbildung 10.17. Dazu addieren wir zum Wert des Achsenabschnitts (`intercept`) das Fünffache des Regressionsgewichts, β_1 (`weight_c`): $\text{mu50} = (\text{Intercept}) + 5 * \text{weight_c}$. Das Diagramm erhält man mit `ggplot(mu50, aes(x = mu50)) + geom_density()`.

```
mu50 <-
  mu45 |>
  mutate(mu50 = `(Intercept)` + 5 * weight_c)

head(mu50)
```

Tabelle 10.6: Die Verteilung von `mu` bedingt auf ein Gewicht von 50kg.

(Intercept)	weight_c	sigma	mu45	mu40	mu50	mu55
154	0.92	5.3	154	150	159	163

Tabelle 10.6: Die Verteilung von μ bedingt auf ein Gewicht von 50kg.

(Intercept)	weight_c	sigma	mu45	mu40	mu50	mu55
155	0.85	5.0	155	151	159	164
155	0.97	5.0	155	150	160	165
155	0.86	4.8	155	151	159	163
155	0.92	5.2	155	150	160	164
155	0.91	5.1	155	150	159	164




Abbildung 10.17: Post-Verteilung der mittleren Größe (laut unserem Modell) bedingt auf ein Gewicht von 50 kg

10.6.3 Lagemaße und Streuungen

Befragen wir die *bedingte* Post-Verteilung. Eine erste Frage zielt nach den typischen deskriptiven Statistiken, also nach Lage und Streuung der Verteilung der Körpergröße.

Was ist das 90 % ETI für $\mu|w = 50$? Man erhält es mit dem Befehl `mu50 |> eti(ci = .9)`

```
#|echo: false
mu50 |>
eti(ci = .9)
```

Parameter	CI	CI_low	CI_high
(Intercept)	0.9	154.20	155.09
weight_c	0.9	0.84	0.97
sigma	0.9	4.83	5.48
mu45	0.9	154.20	155.09
mu40	0.9	149.55	150.69
mu50	0.9	158.60	159.74
mu55	0.9	162.87	164.52

Die mittlere Größe – gegeben $w = 50$ – liegt mit 90 % Wahrscheinlichkeit zwischen den beiden Werten (ca.) 159 cm und 160 cm.

Welche mittlere Größe wird mit 95 % Wahrscheinlichkeit nicht überschritten, wenn die Person 45 kg wiegt? Dazu berechnen wir das gefragte Quantil (also bei 95 %).

```
mu45 |>
summarise(q_95 = quantile(mu45, prob = .95))
```

<u>q_95</u>
155

10.7 Fazit

10.7.1 Ausstieg

Beispiel 10.1 (Fassen Sie das Wesentliche zusammen!). Schreiben Sie 5-10 Sätze zum Wesentlichen Stoff dieses Kapitels und reichen Sie bei der von Lehrkraft vorgegebenen Stelle ein! □

10.7.2 Vertiefung

McElreath (2020) bietet eine tiefere Darstellung von linearen Modellen auf Basis der Bayes-Statistik, insbesondere Kapitel 4 daraus vertieft die Themen dieses Kapitels. Kurz (2021) greift die R-Inhalte von McElreath (2020) auf und setzt sie mit Tidyverse-Methoden um; ein interessanter Blickwinkel, wenn man tiefer in die R-Umsetzung einsteigen möchte. Gelman et al. (2021) bieten ebenfalls viele erhellende Einblicke in das Thema Regressionsanalyse, sowohl aus einer frequentistischen als auch aus einer Bayes-Perspektive.

10.8 Aufgaben

10.8.1 Papier-und-Bleistift-Aufgaben

1. Bayes-Ziel1
2. Bayesmod-bestimmen01
3. mtcars-post2a
4. Bed-Post-Wskt1
5. mtcars-post3a
6. regression1a
7. regression1b
8. Regression2
9. Priorwahl1
10. Bayesmod-bestimmen02
11. Likelihood-identifizieren
12. Priorwahl2
13. Likelihood2
14. interpret-koeff
15. bed-post-wskt1

10.8.2 Computer-Aufgaben

1. Post-befragen1
2. penguins-stan-01

11 Schätzen vs. Testen

11.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein. Sie können...

- den Unterschied zwischen dem *Schätzen* von Modellparametern und dem *Testen* von Hypothesen erläutern
- Vor- und Nachteile des Schätzens und Testens diskutieren
- Das ROPE-Konzept erläutern und anwenden
- Die Güte von Regressionsmodellen einschätzen und berechnen

Der Stoff dieses Kapitels orientiert sich an (Kruschke, 2018).

Lesen Sie zur Vorbereitung folgende Literatur:

- Statistik1, Kap. „Geradenmodelle 2“¹

In diesem Kapitel werden folgende R-Pakete benötigt:

```
library(rstanarm) # Bayes-Modelle
library(tidyverse)
library(easystats)
library(palmerpenguins) # Datensatz "penguins"
```

Wir benötigen den Datensatz `palmerpenguins`.

¹<https://sebastiansauer.github.io/statistik1/090-regression2>




Abbildung 11.1: Possierlich: Die Pinguine (Horst, 2024)

Übungsaufgabe 11.1 (Machen Sie sich mit den Pinguinen vertraut). Machen Sie sich zunächst mit dem Pinguin-Datensatz vertraut. Sie finden den Datensatz `penguins` im R-Paket `palmerpenguins`, das Sie auf gewohnte Art installieren können. Im Internet findet man den Datensatz auch als CSV-Datei; s. unten. Importieren Sie den Datensatz und verschaffen Sie sich einen Überblick über die Verteilungen jeder Variablen des Datensatzes.

Sie können den Datensatz `penguins` entweder über den Pfad importieren:

```
penguins_url <- paste0(
  "https://vincentarelbundock.github.io/Rdatasets/",
  "csv/palmerpenguins/penguins.csv")

penguins <- read.csv(penguins_url)
```

Oder über das zugehörige R-Paket:

```
data("penguins", package = "palmerpenguins")
```

Beide Möglichkeiten des Datenimports sind okay. □

11.2 Einstieg

Betrachten Sie die zwei folgenden Aussagen, die jeweils ein Forschungsziel angeben:

1. „Lernen für die Klausur bringt etwas!“
2. „Wie viel bringt Lernen für die Klausur?“

Beispiel 11.1. Diskutieren Sie die epistemologische Ausrichtung sowie mögliches Für und Wider der beiden Ausrichtungen! Einmal Behauptung, einmal Frage – was macht das für einen Unterschied? □

11.3 Was ist Testen? Was ist Schätzen?

Forschungsfragen kann man, allgemein gesprochen, auf zwei Arten beantworten:

1. *Hypothesen testen*: „Die Daten widerlegen die Hypothese (nicht)“
2. *Parameter schätzen*: „Der Effekt von X auf Y liegt zwischen A und B“.

11.3.1 Hypothesen testen

Hypothesen testende Analysen kommen zu einer Ja-Nein-Entscheidung bzgl. einer Hypothese. Genauer muss man sagen: Im besten Fall kommen sie zu einer Ja-Nein-Aussage. Es kann natürlich sein, dass die Datenlage so nebelig oder das Problem so knifflig ist, dass man ehrlicherweise zugeben muss, dass man sich nicht sicher ist oder sogar komplett im Dunkeln tappt.

Beispiel 11.2 („Lernen erhöht den Prüfungserfolg!“). Die Hypothese *Lernen erhöht den Prüfungserfolg* kann durch eine Studie und eine entsprechende Analyse grundsätzlich folgende drei Ergebnisse finden. 1) Die Daten widersprechen der Hypothese: Lernen bringt offenbar doch nichts für den Klausurerfolg. 2) Die Daten unterstützen die Hypothese: Lernen erhöht den Prüfungserfolg. 3) Die Daten sind uneindeutig, es ist keine Aussage zum Einfluss von Lernen auf den Prüfungserfolg möglich. □

Das Testen einer Hypothese kann zu drei Arten von Ergebnissen führen. Die ersten beiden sind informationsreich, die dritte ist informationsarm.

1.  Die Daten *widersprechen* der Hypothese: Auf Basis der Daten (und des Modells) muss man die Hypothese ablehnen (verwerfen, sagt man), also als falsch (falsifiziert) betrachten oder zumindest hat die Glaubwürdigkeit der Hypothese gelitten.

11 Schätzen vs. Testen

2. ● Die Daten *unterstützen* die Hypothese: Auf Basis der Daten (und des Modells) muss man die Hypothese annehmen (oder kann die Gegenthese zumindest nicht verwerfen). Oder zumindest hat die Hypothese an Glaubwürdigkeit gewonnen.
3. ? Die Datenlage ist *unklar*; zum Teil unterstützen die Daten die Hypothese, zum Teil widersprechen sie ihr. Man kann keine oder kaum Schlüsse aus den Daten ziehen. In diesem Fall gibt es keinen (nennenswerten) Erkenntnisgewinn.

Hypothesen prüfen ist *binär* in dem Sinne, dass sie zu „Schwarz-Weiß-Ergebnissen“ führen (sofern die Datenlage stark genug ist).

! Wichtig

Eine gängige Variante des Hypothesentestens² ist das Testen der Hypothese „Es liegt kein (null) Effekt vor“ (Null Effekt). Man geht also davon aus, dass es keinen Zusammenhang zwischen UV und AV gibt und spricht vom *Nullhypothesen testen*, H_0 . □

11.3.2 Beispiele für Nullhypothesen

- „Lernen bringt nichts“
- „Frauen und Männer parken gleich schnell ein“
- „Es gibt keinen Zusammenhang von Babies und Störchen“
- „Früher war es auch nicht besser (sondern gleich gut)“
- „Bei Frauen ist der Anteil, derer, die Statistik mögen gleich hoch wie bei Männern“ (Null Unterschied zwischen den Geschlechtern) □

Vorteil des Hypothesen testen ist das klare, einfache Ergebnis – die Hypothese ist abgelehnt, angenommen, oder die Datenlage ist unklar. Das unterstützt die Entscheidungsfindung, da es die Komplexität reduziert.

i Man kann Hypothesen nicht bestätigen

Karl Poppers These, dass man Hypothesen nicht bestätigen (verifizieren) kann, hatte großen Einfluss auf die Wissenschaftstheorie (und Epistemologie all-

²vor allem in der Frequentistischen Statistik

gemein) ausgeübt (Popper, 2013). Schlagend ist das Beispiel zur Hypothese H „Alle Schwäne sind weiß“. Auch eine große Stichprobe an weißen Schwänen kann die Wahrheit der Hypothese nicht beweisen. Schließlich ist es möglich, dass wir den schwarzen Schwan einfach noch nicht gefunden haben.³ Umgekehrt reicht die (zuverlässige) Beobachtung eines einzelnen schwarzen Schwans, um die Hypothese H zu widerlegen (falsifizieren). □

i Wirklich nicht?

In der Wissenschaftspraxis werden die meisten Hypothesen probabilistisch untersucht. Komplett sichere Belege, wie in Poppers Beispiel mit dem schwarzen Schwan, gibt es nicht. Das bedeutet, dass Evidenz im bestätigenden wie im widerlegenden Sinne tendenziell (d. h. probabilistisch) zu betrachten ist. Auf dieser Basis und der Basis zuverlässiger, repräsentativer Daten erscheint plausibel, dass Hypothesen sowohl bestätigt als auch widerlegt werden können (Kruschke, 2018; Morey & Rouder, 2011). □

11.3.3 Parameter schätzen

Beim Schätzen von Parametern untersucht man, *wie groß* ein Effekt ist, etwa der Zusammenhang zwischen X und Y. Es geht also um eine Skalierung, um ein *wieviel* und nicht um ein „ja/nein“, was beim Hypothesen testen der Fall ist.

Beim Parameter schätzen gibt es zwei Varianten:

- a) *Punktschätzung*: Das Schätzen eines einzelnen Parameterwerts, sozusagen ein „Best Guess“
- b) *Bereichsschätzung*: Das Schätzen eines Bereichs plausibler oder wahrscheinlicher Parameterwerte

Allerdings kann man das Parameter schätzen auch wie einen Hypothesentest nutzen: Ist ein bestimmter Wert, etwa die Null, nicht im Schätzbereich enthalten, so kann man die Hypothese verwerfen, dass der Parameter gleich diesem Wert (etwa Null) ist. Das Hypothesen testen ist daher (implizit) im Parameter schätzen enthalten.

³Tatsächlich gibt es schwarze Schwäne, aber nicht in Europa: https://en.wikipedia.org/wiki/Black_swan

11 Schätzen vs. Testen

Beispiel 11.3. Wie groß ist der Schätzbereich für den Effekt des Parameters „Geschlecht“ auf das mittlere Gewicht von Pinguinen? Hat die UV *Geschlecht* einen großen Einfluss auf das mittlere Gewicht dieser Tiere? Anders gefragt: Um welchen Wert sind männliche Tiere im Schnitt schwerer als weibliche Tiere? Tabelle 11.1 gibt uns die Antwort.

```
data(penguins, package = "palmerpenguins")
penguins_nona <-
  penguins |> drop_na(sex, body_mass_g) # keine fehlenden Werte

m_penguins_sex <-
  stan_glm(body_mass_g ~ sex, data = penguins_nona)
```

Tabelle 11.1: Parameterschätzung des Modells `m_penguins`; der Gewichtsunterschied zwischen den Mittelwerten der Geschlechter beträgt etwa 700 g.

Tabelle 11.1: Fixed Effects			
Parameter	Median	CI	pd
(Intercept)	3863.18	(3754.31, 3971.56)	100%
sexmale	681.11	(528.74, 843.76)	100%

Grob gesagt sind männliche Tiere ca. 500 g bis 800 g schwerer als weibliche Tiere im Schnitt (95 %-ETI), laut unserem Modell; der Punktschätzer liegt bei einem Gewichtsunterschied von ca. 681 g. □

Beispiel 11.4 (Parameterschätzen als gerichteter Hypothesentest).

Forschungsfrage: Sind männliche Pinguine im Schnitt schwerer als weibliche Tiere?

Gleichung 11.1 formalisiert diese Forschungsfrage als statistische Hypothese H .

$$H : \mu_M \geq \mu_F \rightarrow d = \mu_M - \mu_F \geq 0 \quad (11.1)$$

Anders als beim Testen einer Nullhypothese (ist ein Parameter bzw. eine Differenz gleich Null?) prüfen wir hier eine *gerichtete* Hypothese: Ist die Differenz d größer oder gleich Null?

Theorem 11.1 (Gerichteter Hypothesentest).

$$H : \mu_M \geq \mu_F \leftrightarrow d = \mu_M - \mu_F \geq 0 \quad \square$$

Der Unterschied zwischen zwei Mittelwerten, d , ist genau dann Null, wenn $\beta_1 = 0$ in unserem Regressionsmodell m1, s. Theorem 11.1. Entsprechend gilt $d \neq 0$ wenn $\beta_1 \neq 0$.

Um die Forschungsfrage zu beantworten, zählen wir wie gewohnt den Anteil der Stichproben in der Post-Verteilung für die UV sexmale, die einen Wert größer Null aufweisen:

```
m_penguins_sex_post <-  
  m_penguins_sex |>  
  as_tibble()  
  
m_penguins_sex_post |>  
  count(sexmale > 0)
```

sexmale > 0	n
TRUE	4000

100 % (4000 von 4000) Stichproben finden einen Wert größer Null für sexmale; das heißt, weibliche Tiere sind leichter bzw. männliche Tiere schwerer (im Durchschnitt). Entsprechend finden 0 % der Stichproben einen Wert, der für das Gegenteil spricht (das weibliche Tiere schwerer wären). Damit resümieren wir, dass unser Modell 100 % Wahrscheinlichkeit für die Hypothese einräumt: $p_H = 1$. Achtung: Die 100 %-ige Sicherheit für die Hypothese stammt aus der kleinen Welt, nicht unbedingt aus der großen Welt.

Einfacher zeigt uns `parameters(m_penguins_sex)`, wie groß die Wahrscheinlichkeit für $\beta_1 > 0$ ist, nämlich anhand des Koeffizienten `pd`, s. Tabelle 11.1.

Aber das Auslesen der Post-Verteilung erlaubt uns auch, andere Hypothesen zu prüfen, etwa die Wahrscheinlichkeit der Hypothese, dass der Gewichtsunterschied zwischen den Geschlechtern mehr als 500 g beträgt.

Vorteil der Parameterschätzung (gegenüber dem Testen von Hypothesen) ist die Nuanciertheit des Ergebnisses, die der Komplexität echter Systeme besser Rechnung trägt.

11 Schätzen vs. Testen

Übungsaufgabe 11.2 (Interpretation beim Hypothesen testen). Ein Forschungsteam untersucht die Hypothese, dass hohe Bildschirmzeit mit verringerter Intelligenz bei Kindern einhergeht. Dazu vergleichen Sie Kinder, die sehr viel Zeit am Tag am Bildschirm verbringen, mit Kindern, die sehr wenig Zeit am Tag am Bildschirm verbringen (und die im übrigen vergleichbar sind). Sie finden in ihrer Studie einen Effekt von 95% $KI[-4; -2]$ IQ-Punkten, zuungunsten der Kinder mit hoher Bildschirmzeit.

Welche Aussage dazu ist korrekt bzw. passt am besten?

- A) Die H_0 ist als sicher falsch zu verwerfen.
- B) Die H_0 ist als sicher richtig anzunehmen.
- C) Die H_0 ist mit 95 % Wahrscheinlichkeit richtig.
- D) Die H_0 ist mit 95 % Wahrscheinlichkeit falsch.
- E) Die Datenlage ist unklar, es ist keine Entscheidung möglich. $\square$

11.4 ROPE: Bereich von „praktisch Null“

Nullhypothesen sind fast immer falsch, s. Abbildung 11.2.



Abbildung 11.2: Du testest EXAKTE Nullhypothesen?

Quelle: Imgflip Meme Generator⁴

We do not generally use null hypothesis significance testing in our own work. In the fields in which we work, we do not generally think null hypotheses can be true: in social science and public health, just about every treatment one might consider will have *some* effect, and no comparison or regression coefficient of interest will be exactly zero. We do not find it particularly helpful to formulate and test null hypotheses that we know ahead of time cannot be true. (Gelman et al., 2021)

⁴<https://imgflip.com/i/5v5531>

11.4.1 Alternativen zu Nullhypothesen

Nullhypothesen, H_0 , sind z. B.: $\rho = 0$, $\rho_1 = \rho_2$, $\mu_1 = \mu_2$, $\mu = 0$, $\beta_1 = 0$. Nullhypothesen zu testen, ist sehr verbreitet. Ein Grund ist, dass in der Frequentistischen Statistik keine andere Art von Hypothesentest (einfach) möglich ist.⁵ Ein anderer Grund ist vermutlich, ... wir haben es schon immer so gemacht. Alternativen zum Testen von Nullhypothesen sind:

- Posteriori-Intervalle (ETI oder HDI) berichten
- Rope-Konzept (Kruschke, 2018)
- Wahrscheinlichkeit von inhaltlich bedeutsamen Hypothesen quantifizieren (z. B. dass $\beta_1 > 0.42$)
- Wahrscheinlichkeit quantifizieren, dass der Effekt ein positives bzw. ein negatives Vorzeichen hat (*probability of direction*, *pd*)

11.4.2 „Praktisch kein Unterschied“: Das Rope-Konzept

Beispiel 11.5 (Beispiele für ROPE).

- Sagen wir, wenn sich zwei Preismittelwerte um höchstens $d = 100\text{€}$ unterscheiden, gilt dieser Unterschied für einen Marketingmanager als „praktisch gleich“, „praktisch kein Unterschied“, „nicht substanziell“, „unbedeutend“ bzw. „vernachlässigbar gering“
- Bei Pinguinarten definiert eine Biologin nach umfangreichem Studium der Literatur, dass ein Unterschied von max. 100 g Körpergewicht „vernachlässigbar wenig“ ist.
- Eine findige Geschäftsfrau entscheidet für ihre Firma, dass ein Umsatzunterschied von 100k Euro „praktisch irrelevant“ sei. $\square$

Definition 11.1 (ROPE). ROPE (Region of Practical Equivalence) ist ein Bereich um den Nullwert, der als praktisch äquivalent zu Null angesehen wird. $\square$

Wie legt man den Grenzwert d fest, bis zu dem ein Unterschied (Differenz) gerade noch bzw. gerade nicht mehr unbedeutend ist? Die Wahl von d ist *subjektiv* in dem Sinne als sie von inhaltlichen Überlegungen geleitet sein sollte. Diesen Bereich

⁵Mittlerweile gibt es neue Frequentistische Ansätze für ein Verfahren ähnlich dem ROPE-Ansatz, der weiter unten vorgestellt wird.

bezeichnen wir den *Indifferenzbereich* (Äquivalenzzone, Bereich eines vernachlässigbaren Unterschieds oder *Region of practical equivalence*, Rope).

Jetzt prüfen wir, ob ein „Großteil“ der Posteriori-Stichproben im Rope liegt. Unter „Großteil“ wird häufig das 95 %-HDI verstanden (das ist auch der Standard der R-Funktion `rope()`, die wir hier nutzen).

Entscheidungsregel nach Kruschke (2018):

- Großteil der Post-Verteilung liegt *innerhalb* von Rope $\rightarrow$ *Annahme* der ROPE-Nullhypothese „praktisch kein Effekt“, H_0
- Großteil der Post-Verteilung liegt *außerhalb* von Rope $\rightarrow$ *Ablehnung* der ROPE-Nullhypothese „praktisch kein Effekt“, H_0
- Ansonsten $\rightarrow$ keine Entscheidung – die Datenlage ist uneindeutig

Mit „Großteil“ meinen wir (per Default) das 95 %-KI (der Posteriori-Verteilung).

11.4.3 Vernachlässigbarer Regressionseffekt

Kruschke (2018) schlägt vor, einen Regressionskoeffizienten unter folgenden Umständen als „praktisch Null“ zu bezeichnen:

Wenn eine Veränderung über „praktisch den ganzen Wertebereich“ von X (UV) nur einen vernachlässigbaren Effekt auf Y (AV) hat. Ein vernachlässigbarer Effekt ist dabei $\hat{\gamma} = \pm 0.1 sd_y$. Das impliziert Rope-Grenzen von $\beta_x = \pm 0.1$ für z-standardisierte UV und AV. Einfach gesprochen: Eine vernünftige Voreinstellung für die Rope-Grenzen bei Regressionskoeffizienten sind $\pm 10\%$ der SD der AV.

ROPE-Defaults

Im der Voreinstellung umfasst die Größe des ROPE $\pm 10\%$ der SD der AV. $\square$

11.4.4 HDI-Rope-Entscheidungsregel visualisiert




Abbildung 11.3: Die Entscheidungsregeln zum ROPE illustriert (Kruschke, 2018); A: Verwerfen der ROPE-Hypothese; B und C: Akzeptieren; D-F: Unklare Datenlage, keine Entscheidung zur ROPE-Hypothese

Abbildung 11.3 illustriert die Entscheidungsregel zum ROPE für die drei Situationen *Verwerfen der ROPE-Hypothese*, *Beibehalten* und *unklare Datenlage* (Kruschke, 2018, Abb. 1, S. 272).

11.4.5 Rope berechnen

Hier ist das Modell, das Gewicht als Funktion der Pinguinart erklärt (m_penguins_species).

```
m_penguins_species <- stan_glm(body_mass_g ~ species,
  data = penguins,
  refresh = 0, # unterdrückt Ausgabe der Posteriori-Stichproben
  seed = 42 # zur Reproduzierbarkeit
)
```

Den Rope berechnet man mit `rope(model)`, s. Tabelle 11.2.

Tabelle 11.2: Der Rope-Bereich für die Stufen der UV (Arten von Pinguinen)

Parameter	ROPE_low	ROPE_high	ROPE_Percentage
(Intercept)	-80.20	80.20	0.00
speciesChinstrap	-80.20	80.20	0.75
speciesGentoo	-80.20	80.20	0.00

Die Faktorstufe Chinstrap der UV species hat doch einen beträchtlichen Teil ihrer Wahrscheinlichkeitsmasse der Posteriori-Verteilung im ROPE. Wir können daher für diese Gruppe das ROPE *nicht* verwerfen. Die Datenlage ist *unklar*. Es ist keine abschließende Entscheidung über die Hypothese möglich.

Aber: Gentoo liegt zu 0 % im Rope. Für die Gruppe Gentoo können wir die ROPE-Hypothese *verwerfen*. Der Effekt von Gentoo ist größer als vernachlässigbar. Anders gesagt: Tiere der Art Gentoo sind im Schnitt substantiell schwerer als Tiere der Referenzgruppe (*Adelie*). Der ROPE-Grenzwert wurde hier per Voreinstellung auf 80 g Unterschied festgelegt (10 % der SD der AV).

Hinweis


Die angegebenen Prozentwerte beziehen sich nicht auf die 100 % der Post-Verteilung, sondern (in der Voreinstellung) auf das 95 %-ETI. Dabei werden 10 % der Streuung der AV als Intervallgrenzen des ROPE angenommen, s. `help(rope)`.

Das hört sich abstrakt an? Dann lassen Sie uns das lieber visualisieren.

11 Schätzen vs. Testen

11.4.6 Visualisierung unserer Rope-Werte, `m_penguins_species`

Ein Großteil der Posteriori-Masse von `m_penguins_species` liegt *nicht* innerhalb des Rope. Aber können wir umgekehrt sagen, dass ein Großteil außerhalb liegt? Das erkennt man optisch ganz gut, s. Abbildung 11.4.



(a) Diagramm mit `rope(m_penguins_species) |> plot()`

(b) Diagramm mit `parameters(m_penguins_species) |> plot()`

Abbildung 11.4: Rope und HDI überlappen bei Chinstrap, aber nicht bei Gentoo. Im ersten Fall nehmen wir die Rope-Null-Hypothese an, im zweiten Fall verwerfen wir sie.

Das ROPE durchkreuzt die „Berge“ der Posteriori-Verteilung für *Chinstrap* deutlich. Aber: Das 95 %-HDI liegt nicht komplett innerhalb des Rope. Wir können das Null-hypothese für Chinstrap *nicht verwerfen*, aber auch *nicht bestätigen* – eine unklare Datenlage.

Gentoo hingegen wird vom Rope nicht durchkreuzt, es ist weit entfernt vom „blauen vertikalen Band“ des Rope: *Gentoo* liegt außerhalb des Rope. Es gibt einen „substanziellen“ Unterschied zwischen dem Mittelwert der AV in Gruppe *Gentoo* und in der Referenzgruppe *Adelie*.

Wir verwerfen die ROPE-Hypothese, die „Praktisch-Null-Hypothese“, in diesem Fall.

11.4.7 Finetuning des Rope

Wir können festlegen, was wir unter „praktischer Äquivalenz“ verstehen, also die Grenzen des Ropes verändern. Sagen wir, 200 Gramm sind unsere Grenze für einen vernachlässigbaren Effekt, s. Abbildung 11.5.

```
plot(rope(m_penguins_species, range = c(-200, 200))) +
# order = c(5, 4): Blau/Amber statt Orange/Hellblau, da Letztere im
# Graustufendruck fast identisch hell sind (schlechter S/W-Kontrast)
scale_fill_okabeito(order = c(5, 4))
```

Region of Practical Equivalence (ROPE)




Abbildung 11.5: ROPE mit selber eingestellter Grenze von ± 200 (Gramm)

In der Voreinstellung werden 95 %-ETI berichtet, das kann man wie folgt ändern, wenn man möchte: `rope(m_penguins_species, range = c(-500,500), ci = .89, ci_method = "HDI")`. Die ROPE-Grenzen sind in Tabelle 11.3 zu sehen.

Tabelle 11.3: ROPE-Grenzen für das Modell `m_penguins_species` mit ROPE-Grenzen von 500 g.

Parameter	ROPE_low	ROPE_high	ROPE_Percentage
(Intercept)	-500	500	0
speciesChinstrap	-500	500	1
speciesGentoo	-500	500	0

Jetzt wird berichtet, welcher Teil eines 89 %-CI⁶ sich im Rope befindet.

⁶89 ist die nächst kleinste Primzahl unter 95; und 95 wird gemeinhin als Grenzwert für Schätzberei-

11 Schätzen vs. Testen

Übungsaufgabe 11.3 (Peer-Instruction: Interpretation des ROPE-Anteils). In einer Hochschule wird der Effekt eines „Robo-Professors“ auf die Lernleistung der Studierenden untersucht, im Fach Statistik. Der „Robo-Professor“ ist ein Computerprogramm auf Basis künstlicher Intelligenz, das den Studierenden den Stoff vermittelt. Dazu wird eine Gruppe von Studierenden von einem menschlichen Dozenten unterrichtet, die andere Gruppe von einem „Robo-Professor“. Nach dem Kurs wird die Lernleistung der Studierenden in einer Prüfung gemessen. Das Regressionsmodell `m_robo` liefert einen RoPE-Anteil von 10 % für den Koeffizienten `robo_professor`. Welche Aussage dazu ist korrekt?

- A) Der Robo-Professor hat einen Einfluss von 10 % auf die Lernleistung der Studierenden.
- B) Der Einfluss des Robo-Professors auf die Lernleistung der Studierenden ist substanziell.
- C) Es gibt keinen Einfluss des Robo-Professors auf die Lernleistung der Studierenden.
- D) Es ist nicht auszuschließen, dass der Robo-Professor keinen substanziellen Einfluss auf die Lernleistung der Studierenden hat.
- E) Der Einfluss des Robo-Professors auf die Lernleistung der Studierenden ist vernachlässigbar. ☐

11.4.8 Beantwortung der Forschungsfrage

Für die Spezies *Gentoo* wurde ein substanzieller Gewichtsunterschied zur Referenzgruppe, *Adelie*, vom Modell entdeckt. Für *Chinstrap* hingegen ist keine klare inferenzstatistische Aussage hinsichtlich eines Indifferenzbereichs möglich: Es ist plausibel, laut dem Modell, dass es einen praktisch bedeutsamen Unterschied gibt, aber es ist auch plausibel, dass es keinen praktisch bedeutsamen Unterschied gibt.

che verwendet. Damit ist 95 hier eine „magic number“, ein Defacto-Standard ohne hinreichende Begründung. Um darauf hinzuweisen, benutzen einige Forscherinnen und Forscher mit – ähem – subtilem Humor lieber die 89 als die 95. 🙋♂

11.5 Modellgüte

11.5.1 Wozu Modellgüte?

Hat man ein Modell aufgestellt und geprüft und Ergebnisse erhalten, möchte man wissen, wie belastbar diese Ergebnisse sind. Eine Abschätzung zur Belastbarkeit der Modellergebnisse liefern Kennwerte der Modellgüte. Diese Kennwerte zielen z. B. darauf ab, wie *präzise* die Aussagen des Modells sind. Je präziser die Aussagen eines Modells, desto nützlicher ist es natürlich. Bei einer Parameterschätzung erhält man auch Informationen zur Präzision der Schätzung: Ist der Schätzbereich schmal, so ist die Schätzung präzise (und vice versa). Allerdings könnte ein Modell aus mehreren Parameterschätzungen bestehen, die unterschiedlich präzise sind. Da kann es helfen, eine zusammenfassende Beurteilung zur Präzision, oder allgemeiner zur Güte des Modells, zu erhalten. Im Folgenden wird eine von mehreren gebräuchlichen und sinnvollen Kennzahlen vorgestellt, R^2 .

11.5.2 Modellgüte mit R^2 bestimmen

R^2 gibt den Anteil der Gesamtvarianz (der AV) an, den das Modell erklärt. - Höhere Werte von R^2 bedeuten, dass das Modell die Daten besser erklärt. R^2 wird normalerweise auf Basis eines Punktschätzers definiert. Solch eine Definition lässt aber viel Information – über die Ungewissheit der Schätzung – außen vor. Daher ist es wünschenswert, diese Information in R^2 einfließen zu lassen: *Bayes-R-Quadrat*.

Die Post-Verteilung von R^2 kann man sich wie folgt ausgeben lassen, s. Abbildung 11.6.

```
m_penguins_species_r2 <-
  m_penguins_species |>
  r2_posterior() |>
  as_tibble()

hdi(m_penguins_species_r2) |> # Intervallgrenzen der Post-Verteilung von R2
plot() # visualisieren
```

Highest Density Interval (HDI)




Abbildung 11.6: Die Verteilung von R-Quadrat im Modell `m_penguins_species`

R^2 und σ sind negativ assoziiert: In einem Datensatz mit hohem R^2 ist σ gering und umgekehrt. Beide Koeffizienten berechnen sich auf Basis von σ und haben den gleichen Zweck: die Abschätzung der Güte eines Modells. Im Unterschied zum Frequentistischen R-Quadrat erhält man in der Bayes-Statistik nicht nur einen Punktschätzer für R^2 , sondern wie auch sonst eine Post-Verteilung, so dass man z. B. einen Schätzbereich angeben kann.

Schneller bekommt man den Punkt- und den Intervallschätzer für R^2 mit `r2(m_penguins_species)`.

```
## # Bayesian R2 with Compatibility Interval
##
## Conditional R2: 0.667 (95% CI [0.620, 0.711])
```

11.6 Fazit

Obwohl das Testen von Hypothesen im Moment verbreiteter ist, spricht einiges zugunsten der Vorzüge der Parameterschätzung. Möchte man aber, um sich bestimmter bestehender Forschung anzunähern, einen Hypothesentest, speziell den Test einer Nullhypothese verwenden, so bietet sich das ROPE-Verfahren an.

Übungsaufgabe 11.4 (Zeit für einen Rückblick: Welche Fragen haben Sie im Moment?). Mittlerweile haben wir einen Großteil des Stoffs absolviert. Welche Punkte sind Ihnen offen geblieben? Wo haben Sie noch Fragen?

Die Lehrkraft stellt Ihnen eine (anonyme) Plattform für Ihre Fragen bereit, so dass Sie in Ruhe Ihre offenen Fragen und diejenigen Ihrer Kommilitoninnen und Kommilitonen überdenken können. □

11.7 Aufgaben

1. Wskt-Schluckspecht
2. wskt-mtcars-1l
3. rope-regr
4. rope1
5. rope2
6. rope3
7. rope2a
8. penguins-rope

12 Fallbeispiele

12.1 Lernsteuerung

Abbildung 1.1 gibt einen Überblick zum aktuellen Standort im Modulverlauf.

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können...

- typische, deskriptive Forschungsfragen spezifizieren als Regression
- Forschungsfragen in Regressionsterme übersetzen
- typische Forschungsfragen auswerten

Der Stoff dieses Kapitels orientiert sich an McElreath (2020), Kap. 4.4 sowie Gelman et al. (2021), Kap. 7 und 10.

Frischen Sie Ihr Wissen in den Grundlagen der einfachen und multiplen Regression (inkl. Interaktionseffekte) auf. Dazu sind z. B. folgende Literaturstellen geeignet.

- Statistik1, Kap. „Geradenmodelle 1“¹
- Statistik1, Kap. „Geradenmodelle 2“²

In diesem Kapitel werden die üblichen R-Pakete benötigt.

```
library(rstanarm) # Bayes-Modelle  
library(tidyverse) # Datenjudo  
library(easystats) # Statistik-Komfort
```

Wir benötigen in diesem Kapitel folgende Datensätze: kidiq, penguins. Den Datensatz kidiq importieren Sie am einfachsten aus dem R-Paket rstanarm, das Sie schon installiert haben. Alternativ können Sie die Daten hier herunterladen.³

¹<https://sebastiansauer.github.io/statistik1/080-regression1>

²<https://sebastiansauer.github.io/statistik1/090-regression2>

³<https://raw.githubusercontent.com/sebastiansauer/Lehre/main/data/kidiq.csv>

```
data("kidiq", package = "rstanarm")
```

Außerdem benötigen wir den Datensatz `penguins`. Sie können den Datensatz `penguins` entweder über den Pfad importieren oder über das zugehörige R-Paket. Beide Möglichkeiten sind okay.

```
penguins_url <- paste0(
  "https://vincentarelbundock.github.io/Rdatasets/",
  "csv/palmerpenguins/penguins.csv")

penguins <- read.csv(penguins_url)
```

```
data("penguins", package = "palmerpenguins")
```

Beispiel 12.1 (Was waren noch mal die Skalenniveaus?). Um Forschungsfragen zu klassifizieren, müssen Sie wissen, was die Skalenniveaus der beteiligten AV und der UV(s) sind.⁴ □

Beispiel 12.2 (Was war noch einmal die Interaktion?). Erklären Sie die Grundkonzepte der Interaktion (hier synonym: Moderation) im Rahmen einer Regressionsanalyse!⁵ □

Wenn Sie die Skalenniveaus kennen, können Sie die Forschungsfrage korrekt auswerten, also das korrekte (Regressions-)Modell spezifizieren. Wir werden hier viele der typischen Forschungsfragen (aus psychologischen und ähnlichen Fragestellungen) mit Hilfe von Regressionsmodellen beantworten. Das hat den Vorteil, dass sie nicht viele verschiedene Auswertungsmethoden (t-Test, Varianzanalyse, ...) lernen müssen. Außerdem ist die Regressionsanalyse (für viele Situationen) die beste Herangehensweise, da sie viele Möglichkeiten für Erweiterungen bietet. Entsprechend ist das Thema dieses Kapitels, gängige Forschungsfragen mit Hilfe der Regressionsanalyse zu untersuchen. Wenn Sie die Grundkonzepte der Regression schon kennen, wird Ihnen vieles sehr bekannt vorkommen. Natürlich würzen wir das Ganze mit einer ordentlichen Portion Post-Verteilungen aus der Bayes-Küche. Allerdings kommt auch dabei nichts Wesentliches mehr hinzu, abgesehen von ein paar Erweiterungen.

⁴Hier ist eine kurze Erklärung dazu: <https://sebastiansauer.github.io/statistik1/010-rahmen#sec-arten-variablen>

⁵Hier finden Sie eine kurze Erklärung zur Interaktion: <https://sebastiansauer.github.io/statistik1/090-regression2#interaktion>

12.2 Taxonomie von Forschungsfragen

Wir konzentrieren uns im Folgenden auf Forschungsfragen auf Basis von Regressionsmodellen mit *metrischer* AV. Andere Skalenniveaus bei der AV klammern wir aus. Im Folgenden sind für die UV(s) nominale sowie metrische Skalenniveaus erlaubt. Modelle mit mehreren UV (und mehreren Stufen an UV) sind ebenfalls erlaubt.

Wir untersuchen in diesem Kapitel häufig verwendete Arten von Forschungsfragen mittels Regressionsanalysen. Für jede Variante ist zumeist ein Beispiel, die Modellformel, der Kausalgraph⁶, die Forschungsfrage sowie die Grundlagen der Auswertung dargestellt.

Dabei wird folgende Nomenklatur verwendet, um die Skalenniveaus der beteiligten Variablen einer Forschungsfrage zu benennen:

- y: metrische AV
- g: Gruppierungsvariable; nominal skalierte UV (querschnittlich)
- b: binäre UV
- x: metrische UV
- u: ungemessene (unbekannte) Variable

Übungsaufgabe 12.1 (Einstieg: Was ist Ihre Lieblingsforschungsfrage?). Welche Forschungsfrage würden Sie selber gerne untersuchen – etwa im Kontext eines entsprechenden Moduls in einem Folgesemester? Auch in Ihrer Abschlussarbeit haben Sie Gelegenheit zu eigener Forschung.

Überlegen Sie sich (in Kleingruppen) eine oder mehrere Forschungsfragen, die Sie interessieren würden! Posten Sie Ihre Antwort in das von der Lehrkraft bereitgestellte Forum. □

12.3 $y \sim b$

Hintergrund:

Eine Psychologin, die im öffentlichen Dienst als Schulpsychologin arbeitet, versucht herauszufinden, warum einige Kinder intelligenter sind als andere. Dazu wurden in einer aufwändigen Studie die Intelligenz vieler Kinder gemessen. Zusätzliche

⁶auch DAG genannt, s. Kapitel 13

wurden verschiedene Korrelate der Intelligenz erhoben, in der Hoffnung, „Risikofaktoren“ für geringere Intelligenz zu entdecken.

Forschungsfrage:

Ist der mittlere IQ-Wert (*kid_score*) von Kindern, deren jeweilige Mutter über einen Schulabschluss (*mom_hs*, $x = 1$) verfügt, höher als bei Kindern, deren jeweilige Mutter nicht über einen Schulabschluss verfügt ($x = 0$)? (*ceteris paribus*)⁷.

Die Modellformel zur Forschungsfrage lautet allgemein $y \sim b$ bzw. konkret für den vorliegenden Fall $\text{kid_iq} \sim \text{mom_hs}$.

Theorem 12.1 drückt die Forschungsfrage formaler und als Hypothese (Behauptung) aus.

Theorem 12.1 (Hypothese für ungleiche Mittelwerte).

$$H_A : \mu_{x=1} > \mu_{x=0} \quad \square$$

In Worten: „Der mittlere IQ-Wert für Kinder, deren Mütter über einen Schulabschluss verfügen ist höher als in der Gruppe von Kindern, deren Mütter über keinen Schulabschluss verfügen“. Zu beachten ist, dass sich eine Hypothese immer auf Parameterwerte bezieht, also auf die Population, nicht auf die Statistiken der Stichprobe.

Die zugehörige Nullhypothese, H_0 lautet:

$$H_0 : \mu_{x=1} = \mu_{x=0} \quad \square$$

Für die Praktisch-Null-Hypothese (ROPE-Hypothese) wählen wir 5 IQ-Punkte als Grenzwert für gerade noch unbedeutend.

$$H_{ROPE} : \mu_{x=1} > \mu_{x=0} + 5 \quad \square$$

Die Regressionsformel zur Forschungsfrage lautet: $y \sim b$ bzw. $\text{kid_iq} \sim \text{mom_hs}$.

Der Kausalgraph zur Modellformel ist in Abbildung 12.1 dargestellt. Y hat, laut unserem Modell, zwei Ursachen:

⁷Häufig erlaubt uns unser Vorwissen eine gerichtete Hypothese – „größer als/kleiner als“ – zu formulieren, anstelle der „empirisch ärmeren“ einfachen, ungerichteten Ungleichheit

12 Fallbeispiele

1. mom_hs (b)
2. u, das steht für „unbekannt“⁸




Abbildung 12.1: DAG für $\text{kid_iq} \sim \text{mom_hs}$

Auf dieser Basis berechnen wir unser Regressionsmodell mit Stan: `stan_glm(kid_score ~ mom_hs, data = kidiq)`

```
m10.1 <- stan_glm(  
  kid_score ~ mom_hs,  
  data = kidiq)
```

Der Einfachheit halber übernehmen wir die Prioriwerte von Stan, s. Listing 12.1.

Die komplette Modellspezifikation ist in Gleichung 12.1 aufgeführt. Wie man sieht, sind die Priori-Verteilungen sehr breit – zu breit vielleicht. Das sollten wir beim nächsten Mal verbessern.

$\text{kid score}_i \sim \text{Normal}(\mu_i, \sigma)$	Likelihood	
$\mu_i = \beta_0 + \beta_1 \cdot \text{mom hs}_i$	Lineares Modell	
$\beta_0 \sim \text{Normal}(87, 51)$	Prior Achsenabschnitt	(12.1)
$\beta_1 \sim \text{Normal}(0, 124)$	Prior Regressionsgewicht	
$\sigma \sim \text{Exp}(0.049)$	Prior Vorhersagegüte	

⁸unknown, sozusagen der unbekannte Gott, also für alle sonstigen Einflüsse; man kann das „u“ ohne Schaden weglassen, da wir es sowieso nicht modellieren. Hier ist es nur aufgeführt, um zu verdeutlichen, dass wir nicht so verwegen sind, zu behaupten, es gäbe keine anderen Einflüsse als mom_hs auf die IQ des Kindes.

Listing 12.1 Standard-Prioriwerte für m10.1, von Stan vergeben

```
prior_summary(m10.1)
## Priors for model 'm10.1'
## -----
## Intercept (after predictors centered)
## Specified prior:
## ~ normal(location = 87, scale = 2.5)
## Adjusted prior:
## ~ normal(location = 87, scale = 51)
##
## Coefficients
## Specified prior:
## ~ normal(location = 0, scale = 2.5)
## Adjusted prior:
## ~ normal(location = 0, scale = 124)
##
## Auxiliary (sigma)
## Specified prior:
## ~ exponential(rate = 1)
## Adjusted prior:
## ~ exponential(rate = 0.049)
## -----
## See help('prior_summary.stanreg') for more details
```

Mit `parameters(m10.1)` bekommt man die Parameter des Modells, s. Tabelle 12.1.

Tabelle 12.1: Parameter des Modells m10.1 (sigma ist nicht dargestellt, da meistens nicht von hohem Interesse)

Tabelle 12.1: Fixed Effects		
Parameter	Median	CI
(Intercept)	77.56	(73.40, 81.67)
mom_hs	11.75	(7.28, 16.37)

m10.1: $\text{kid_score} = 78 + 12 \cdot \text{mom_hs} + \text{error}$

12 Fallbeispiele

Der **Achsenabschnitt** (intercept, β_0 oder auch mit α bezeichnet) ist der mittlere vorhergesagte IQ-Wert von Kindern, deren Mütter über *keinen* Schulabschluss (mom_hs = 0) verfügen:

$$\text{kid_score} = 78 + 0 \cdot 12 + \text{error}$$

Das **Regressionsgewicht** (slope, β_1 , β) ist der Unterschied im IQ-Wert von Kindern mit Müttern mit Schulabschluss (im Vergleich zum IQ-Wert von Kindern mit Müttern ohne Schulabschluss). Dieser Unterschied entspricht der Steigung der Regressionsgeraden.

$$\text{kid_score} = 78 + 1 \cdot 12 + \text{error} = 90 + \text{error}$$

Der Wert von error (e) zeigt, wie genau die Schätzung (Vorhersage) ist bzw. wie stark UV und AV zusammenhängen. error entspricht dem Vorhersagefehler, also dem Unterschied vom tatsächlichen IQ-Wert des Kindes (y) zum vom Modell vorhergesagten Wert ($\hat{y}$).

Ein lineares Modell der Art $y \sim g$ kann man als Berechnung des Unterschieds im Mittelwert von y zwischen beiden Gruppen (g0 vs. g1) verstehen.

👤 Hey Stan! Nimm den Datensatz kidiq, gruppierere nach mom_hs und fasse zusammen anhand des Mittelwerts. Die resultierende Zahl soll heißen kid_score_avg. An die Arbeit!

🤖 Schon mal was von „bitte“ gehört?

12.3.1 R-Code

```
kidiq |>
  group_by(mom_hs) |>
  summarise(kid_score_avg =
    mean(kid_score))
```

12.3.2 Ausgabe

mom_hs	kid_score_avg
0	77.55
1	89.32

mom_hs	kid_score_avg
--------	---------------

Der mittlere (average, avg) IQ-Wert unterscheidet sich um ca. 12 Punkte (89.4-77.6), zugunsten der Kinder von Müttern mit Abschluss.

In Abbildung 12.2 ist der Unterschied im IQ der Kinder als Funktion des Schulabschlusses der Mutter dargestellt, auf Basis des Datensatzes kidiq.

```
estimate_relation(m10.1) |> plot()
```




Abbildung 12.2: Kinder, deren Mütter über einen Schulabschluss verfügen ($\text{mom_hs}=1$), haben im Mittel einen höheren Intelligenztestwert (als Kinder, deren Mütter keinen Schulabschluss haben, $\text{mom_hs}=0$), laut dem vorliegenden Modell. Die Regressionsgerade ist als durchgezogene Linie dargestellt. Die Mittelwerte pro Gruppe als Punkte und als gestrichelte, horizontale Linie.


Prüfen wir mit `rope(m10.1)`, ob der Effekt der UV (Unterschied zwischen den Gruppen) „praktisch Null“ ist; dazu nutzen wir das ROPE-Verfahren.

12 Fallbeispiele

```
rope(m10.1, range = c(-5, 5))
```

Das Ergebnis zeigt uns, dass es 0 % Überlappung vom Rope und dem 95 %-HDI (der Posterior-Verteilung) gibt.

Fazit: Wir verwerfen die Praktisch-Null-Hypothese. Adios! Abbildung 12.3 visualisiert die Erstreckung der Posteriori-Verteilung (und des 95 %-HDI) sowie des Rope.



(a) Diagramm mit `rope(m10.1) |> plot()`

(b) Diagramm mit `parameters(m10.1) |> plot()`

Abbildung 12.3: Der Bereich plausibler Werte (der Post-Verteilung von m10.1) liegt komplett außerhalb des Bereichs zu vernachlässigend kleiner Werte (ROPE-Bereich). Wir verwerfen die Praktisch-Null-Hypothese (ROPE-Hypothese).

In der *frequentistischen* Statistik (die mehrheitlich unterrichtet wird) untersucht man diese Datensituation – Mittelwertsdifferenz zwischen zwei Gruppen – mit einem sog. *t-Test*. Der *t-Test* (für zwei Gruppen) ist ein inferenzstatistisches Verfahren, das prüft, ob die Mittelwertsdifferenz zwischen zwei Gruppen (in der Population) μ_d Null ist: $\mu_d = 0$.⁹ In der Bayes-Statistik betrachtet man dazu stattdessen die Posteriori-Verteilung (z. B. mit 95%PI).

Alternativ zum *t-Test* kann man – unabhängig, ob man Frequentistisch oder Bayesianisch unterwegs ist – mit einer Regression vom Typ $y \sim b$ das in etwa gleiche Ergebnis erreichen.¹⁰

⁹Genauer gesagt wird geprüft, wie wahrscheinlich es auf Basis des Modells ist, noch extremere Ergebnisse zu beobachten unter der Annahme, dass die (exakte) Nullhypothese wahr ist. Es ist etwas kompliziert.

¹⁰Genauer gesagt, erlaubt der *t-Test* in der Form des Welch-Tests auch Abweichungen von der Varianzhomogenität der getesteten Gruppen. Die Regression geht hingegen von Varianzhomogenität

Tabelle 12.2: m10.1, Stichprobe aus der Post-Verteilung, ersten paar Zeilen

Achsenabschnitt	momhs	sigma
80.5	9.5	19.7
77.9	12.5	19.7
75.9	12.9	20.0
77.8	9.5	20.7
78.7	11.9	20.0

Zur Beantwortung der Forschungsfrage betrachten wir die Ergebnisse von m10.1.

12.3.3 R-Code

```
m10.1_post <-
  m10.1 |>
  as_tibble()

names(m10.1_post) <- c("Achsenabschnitt", "momhs", "sigma") # schönere Namen
```

12.3.4 Ausgabe

Hier sind die ersten paar Zeilen, s. Tabelle 12.2.

Berechnen wir zur Übung ein 95%-PI von Hand; komfortabler geht es mit `eti(m10.1)`, s. Tabelle 12.1.

```
pi_mom_hs <-
  m10.1_post |>
  reframe(pi_95 = quantile(momhs, c(.025, .975)))

pi_mom_hs
```

(Homoskedastizität) aus. Allerdings ist diese Annahme nicht von besonderer Bedeutung, wenn es um die Regressionskoeffizienten geht.

$$\overline{\pi_{.95}} \\ \begin{array}{c} 7.3 \\ 16.4 \end{array}$$

Mit 95 % Wahrscheinlichkeit liegt der Unterschied im mittleren IQ-Wert zwischen Kindern von Müttern mit bzw. ohne Schulabschluss im Bereich von 7 bis 16 IQ-Punkten, laut unserem Modell: 95%*PI* : [7, 16]. Die Hypothese, dass es keinen Unterschied oder einen Unterschied in die andere Richtung geben sollte, ist vor diesem Hintergrund als unwahrscheinlich abzulehnen. Mit `plot(eti(m10.1))` kann man das 95 %-ETI der Post-Verteilung visualisieren.

! Wichtig

Zur Erinnerung: Korrelation ungleich Kausation. Von einem „Effekt“ zu sprechen, lässt in den meisten Köpfen wohl die Assoziation zu einem *kausalen* Effekt entstehen. Ein Kausaleffekt ist eine starke (und sehr interessante und wichtige) Behauptung, die mehr Fundierung bedarf als eine einfache Korrelation bzw. ein einfacher Zusammenhang. Für eine Kausalaussage braucht man ein Argument, etwa einen Verweis auf bestehende Studien oder eine Theorie.



12.4 Vertiefung: Toleranzbereich

🔥 VERTIEFUNG, nicht prüfungsrelevant 🔥

Berechnet man ein Regressionsmodell mit `stan_glm` (🤖 😊), dann zieht man dabei Zufallszahlen 🎲. Der Hintergrund ist, dass Stan eine Stichproben-Post-Verteilung erstellt, und das Ziehen der Stichproben erfolgt zufällig. Das erklärt, warum Ihre Ergebnisse einer Regressionsanalyse mittels `stan_glm` von denen in diesem Buch abweichen können.

Um zu prüfen, ob Ihre Ergebnisse „ähnlich genug“ oder „innerhalb eines Toleranzbereichs“ sind, kann man die Funktion `is_in_tolerance()` aus dem R-Paket `prada` nutzen.

Größe des Toleranzbereichs

Die Größe des *relativen Toleranzbereichs* ist in `is_in_tolerance()` auf 5 % festgelegt. Das heißt, ein Unterschied von 5 % zwischen einem Referenzwert (dem „wahren“ Wert) und Ihrem Wert ist *okay*, also im Toleranzbereich. Außerdem gibt es noch einen *absoluten Toleranzbereich*, der auf 10 % der SD der AV festgelegt ist (bei Regressionsmodellen). Der *größere* der beiden Werte gilt. □

Wenn Sie diese Funktion nutzen wollen, müssen Sie zunächst das Paket installieren (von Github, nicht vom Standard-R-App-Store CRAN) und dann wie gewohnt starten.

```
pak::pak("sebastiansauer/prada") # `pak` können Sie mit `install.packages("pak")`
  ↪ installieren
library(prada)
```

Dann testen Sie, ob Ihr Modellparameter, z. B. β_1 innerhalb eines Toleranzbereichs liegt.

Sagen wir der „richtige“ oder „wahre“ Wert (oder schlicht der Wert einer Musterlösung) für β_0 ist 77. Unser Wert sei 77.56. Liegt dieser Wert noch innerhalb eines Toleranzbereichs?

```
is_in_tolerance(asis = 77.56, # Ihr Wert
  tobe = 77, # Referenzwert
  tol_rel = .05, # relative Toleranz
  tol_abs = .10 * sd(kidiq$kid_score) # absolute Toleranz
)
## [1] TRUE
```

Ja, unser Wert ist *innerhalb* des Toleranzbereichs. 

Übungsaufgabe 12.2 (Peer-Instruction: Wählen Sie plausible Priori-Verteilungen für Modell m10.1!). Die Apriori-Verteilungen, die Stan als Voreinstellung gewählt hat, sind recht weit. Das ist nicht unbedingt falsch, aber z. B. weniger Streuung in den Verteilungen wäre wohl plausibler.

Bearbeiten Sie dazu folgende Aufgaben in Kleingruppen:

- Welche Parameter gibt es in m10.1?

12 Fallbeispiele

- b) Geben Sie passende Parameter für diese Apriori-Verteilungen an in mathematischer Notation.
- c) Geben Sie den passenden R-Befehl für diese Apriori-Werte an.

Bereiten Sie Ihre Lösungen schriftlich elektronisch vor. Die Lehrkraft wird Sie ggf. bitten, Ihre Aufgaben im Plenum zu präsentieren. □

12.5 $y \sim x + b$

Forschungsfrage:

Wie stark ist der statistische Effekt von jeweils dem Schulabschluss der Mutter (`mom_hs`) und dem IQ der Mutter (`mom_iq`) auf den IQ des Kindes (`kid_score`)?

Die Modellformel zur Forschungsfrage lautet: $y \sim x + b$ bzw. $\text{kid_score} \sim \text{mom_iq} + \text{mom_hs}$.


Die Hypothesen lauten:

1. Der Schulabschluss der Mutter hat einen positiven Effekt auf den IQ des Kindes: $\beta_{\text{momhs}} > 0$.
2. Der IQ der Mutter hat einen positiven Effekt auf den IQ des Kindes: $\beta_{\text{momiq}} > 0$.

Der Kausalgraph¹¹ zur Modellformel ist in Abbildung 12.4 dargestellt. Laut unserem Modell ist y also eine Funktion zweier (kausaler) Einflüsse, b und u , wobei u für „unbekannt“ steht, also für alle sonstigen Einflüsse.¹²

¹¹DAG, s. Kapitel 13

¹²Dabei nehmen wir an, dass x und u nicht voneinander abhängen, was man daran erkennt, dass es keine Pfeile zwischen den beiden Variablen gibt.

Abbildung 12.4: DAG für $y \sim b$

Deskriptive Statistiken zum Datensatz sind in Tabelle 12.3 dargestellt.

```
describe_distribution(kidiq)
```

Tabelle 12.3: Variablen und ihre Verteilung im Datensatz kidiq

Variable	Mean	SD	IQR	Min	Max	n
kid_score	86.80	20.41	28	20	144	434
mom_hs	0.79	0.41	0	0	1	434
mom_iq	100.00	15.00	22	71	139	434
mom_age	22.79	2.70	4	17	29	434

Berechnen wir als Erstes folgendes einfaches Modell mit nur einer UV: $\text{kid_score} \sim \text{mom_iq}$ (m10.2), s. Tab. Tabelle 12.4.

```

m10.2 <-
  stan_glm(kid_score ~ mom_iq, data = kidiq)

m10.2 |>
  parameters()
  
```

Tabelle 12.4: Parameter des Modells m10.2

Tabelle 12.4: Fixed Effects		
Parameter	Median	CI
(Intercept)	25.95	(13.99, 37.70)
mom_iq	0.61	(0.49, 0.72)

Setzt man die (Punktschätzer der) Parameter in die allgemeine Regressionsgleichung von m10.2 ein, so erhält man: $\text{kid_score} = 26 + 0.6 * \text{mom_iq} + \text{error}$. Visualisieren wir uns noch das Modell m10.2, s. Abbildung 12.5.

12.5.1 mit ggplot2

```
kidiq |>
  ggplot(aes(x = mom_iq, y = kid_score)) +
  geom_point(alpha = .7) +
  geom_abline(slope = coef(m10.2)[2],
             intercept = coef(m10.2)[1],
             color = beta1col)
```





Abbildung 12.5: Die Intelligenz eines Kindes als Funktion der Intelligenz der Mutter (m10.2)

12.5.2 Mit easystats

Alternativ kann man sich das Modell (m10.2) mit `plot(estimate_relation)` visualisieren, mit Hilfe des R-Pakets `easystats`, s. Abbildung 12.6.

```
plot(estimate_relation(m10.2)) +  
  geom_point(data = kidiq, aes(x = mom_iq, y = kid_score))
```




Abbildung 12.6: Die geschätzten Erwartungswerte von m10.2 visualisiert

Die Linie zeigt die vorhergesagten IQ-Werte der Kinder für verschiedene IQ-Werte der Mütter. Vergleicht man Teilpopulationen von Müttern mit einem mittleren Unterschied von einem IQ-Punkt, so findet man 0.6 IQ-Punkte Unterschied bei ihren Kindern *im Durchschnitt*, laut dem Modell m10.2. Der Achsenabschnitt hilft uns nicht weiter, da es keine Menschen mit einem IQ von 0 gibt.

Berechnen wir als nächstes ein Modell mit beiden Prädiktoren: `kid_score ~ mom_hs + mom_iq`, s. Tabelle 12.5; Modell m10.3.

```
m10.3 <-
stan_glm(
  kid_score ~ mom_iq + mom_hs,
  refresh = 0,
  data = kidiq)
```

Tabelle 12.5: Parameter des Modells m10.3 (ohne sigma; ETI-Intervalle)

Tabelle 12.5: Fixed Effects		
Parameter	Median	CI
(Intercept)	25.86	(14.14, 37.04)

Parameter	Median	CI
mom_iq	0.56	(0.44, 0.69)
mom_hs	5.97	(1.72, 10.32)

Will man nur schnell die Koeffizienten des Modells (d. h. Punktschätzer der Modellparameter, in diesem Fall den Median) wissen, so kann man anstelle von `parameters(mein_modell)` auch `coef(mein_modell)` schreiben. Aber natürlich ist es möglich (und einfacher) anstelle von `coef` den Befehl `parameters` zu verwenden.

```
coef(m10.3)
## (Intercept)  mom_iq  mom_hs
##      25.86    0.56    5.97
```

`m10.3: kid_score = 26 + 0.6*mom_iq + 6*mom_hs + error`

Möchte man nur z. B. den 3. Wert aus diesem Vektor, so kann man schreiben:

```
coef(m10.3)[3]
## mom_hs
##      6
```

Abbildung 12.7 visualisiert das Modell `m10.3`.

```
kidiq2 <-
  kidiq |>
  mutate(mom_hs = as.factor(mom_hs))

m10.3a <-
  stan_glm(
    kid_score ~ mom_iq + mom_hs,
    refresh = 0,
    data = kidiq2)

pred <- estimate_relation(m10.3a)

plot(pred) +
  geom_point(data = kidiq2, aes(x = mom_iq, y = kid_score, color = mom_hs)) +
```

12 Fallbeispiele

```
# order = c(5, 4): Blau/Amber statt Orange/Hellblau, da Letztere im  
# Graustufendruck fast identisch hell sind (schlechter S/W-Kontrast)  
scale_color_okabeito(order = c(5, 4))
```




Abbildung 12.7: Der Effekt von sowohl mütterlicher Intelligenz als auch mütterlichem Schulabschluss.

- *Achsenabschnitt*: Hat das Kind eine Mutter mit einem IQ von 0 und ohne Schulabschluss, dann schätzt das Modell den IQ-Wert des Kindes auf 26.
- *Koeffizient zum mütterlichen Schulabschluss*: Vergleicht man Kinder von Müttern gleicher Intelligenz, aber mit Unterschied im Schulabschluss, so sagt das Modell einen Unterschied von 6 Punkten im IQ voraus.
- *Koeffizient zum mütterlichen IQ*: Vergleicht man Kinder von Müttern mit gleichem Wert im Schulabschluss, aber mit 1 IQ-Punkt Unterschied, so sagt das Modell einen Unterschied von 0.6 IQ-Punkten bei den Kindern voraus.

Mit 95 % Wahrscheinlichkeit liegt der Unterschied im mittleren IQ-Wert zwischen Kindern von Müttern mit bzw. ohne Schulabschluss im Bereich von 1.6 bis 10.1 IQ-Punkten, laut unserem Modell. Der Effekt des mütterlichen IQs wird auf 0.5 bis 0.7 geschätzt (95 %-ETI). Da für beide UV die Null nicht im Intervall plausibler Werte liegt, kann ein Null-Effekt (die exakte Nullhypothese) abgelehnt werden.

12.6 $y \sim x + b + x:b$

Forschungsfrage:

Gibt es einen Interaktionseffekt zwischen mütterlichem Schulabschluss und mütterlichem IQ (auf den IQ-Wert des Kindes)?

Außerdem ist man vermutlich auch an den Effekten der beiden UV auf die AV interessiert; diese Fragen haben wir im letzten Abschnitt untersucht (und greifen sie daher nicht noch mal ausführlich auf).

Die Modellformel zur Forschungsfrage lautet: $y \sim x + b + x:b$. Der Einfachheit halber übernehmen wir wieder die Prioris wie vom R-Paket `rstanarm` bereitgestellt.

Der DAG zur Modellformel ist in Abbildung 12.8 dargestellt (`momiqmom_hs` bezeichnet den Interaktionseffekt der Intelligenz der Mutter mit ihrem Schulabschluss auf die Intelligenz des Kindes).




Abbildung 12.8: DAG für $y \sim x + b + x:b$

In m10.3 hat das Modell die Regressionsgeraden gezwungen, parallel zu sein. Betrachtet man das Streudiagramm, so sieht man, dass nicht-parallele Geraden besser passen. Sind die Regressionsgeraden nicht parallel, so spricht man von einer *Interaktion* (synonym: Interaktionseffekt, Moderation). Fügen wir also im nächsten Modell, m10.4 einen Interaktionseffekt hinzu.

!

Wichtig

Liegt eine Interaktion vor, so unterscheidet sich die Steigung der Geraden in den Gruppen. Liegt keine Interaktion vor, so sind die Geraden parallel. □

Wir berechnen mit m10.4 das Modell mit folgender Modellformel: `kid_score ~ mom_hs + mom_iq + mom_hs:mom_iq`, s. Listing 12.2, Abbildung 12.9 und Tabelle 12.6.

Listing 12.2 Die Modelldefinition von m10.4 mit `stanglm`

```
m10.4 <-  
  stan_glm(kid_score ~ mom_iq + mom_hs + mom_hs:mom_iq,  
    data = kidiq,  
    refresh = 0)
```

In der Regressionsformel sieht man, dass ein zusätzlicher Parameter, eben der Interaktionseffekt, in das Modell aufgenommen wurde.

Tabelle 12.6: Parameter von m10.4

Tabelle 12.6: Fixed Effects		
Parameter	Median	CI
(Intercept)	-9.98	(-35.42, 16.94)
mom_iq	0.95	(0.67, 1.23)
mom_hs	49.12	(20.41, 78.60)
mom_iq:mom_hs	-0.46	(-0.77, -0.15)

Mit `estimate_relation(m10.4) |> plot()` kann man sich das Modell visualisieren, s. Abbildung 12.9.




Abbildung 12.9: m10.4: Wie m10.3, aber mit Interaktionseffekt. Es ist gut zu erkennen, dass der Achsenabschnitt für diese Daten kaum zu interpretieren ist.

Der *Achsenabschnitt* gibt die IQ-Schätzwerte für Kinder mit Müttern ohne Abschluss und mit einem IQ von 0 an. Kaum zu interpretieren. *mom_hs*: Dieser Koeffizient zeigt den Unterschied der IQ-Schätzwerte zwischen Kindern mit Mutter ohne bzw. mit Schulabschluss und jeweils mit einem IQ von 0. Puh. *mom_iq*: Unterschied der IQ-Schätzwerte zwischen Kindern mit Müttern, die sich um einen IQ-Punkt unterscheiden, aber jeweils ohne Schulabschluss. *Interaktion (mom_hs:mom_iq)*: Der Unterschied in den Steigungen der Regressionsgeraden, also der Unterschied des Koeffizienten für *mom_iq* zwischen Müttern mit bzw. ohne Schulabschluss. Für beide Gruppen, *mom_hs*=0 und *mom_hs*=1, gilt folgende Regressionsformel, s. Gleichung 12.2.

$$\text{kid score} = \beta_0 + \beta_1 \cdot \text{mom hs} + \beta_2 \cdot \text{mom iq} + \beta_3 \cdot \text{mom hs} \cdot \text{mom iq} \quad (12.2)$$

β_3 gibt die Stärke des Interaktionseffekts an.

Auf Errisch schreibt man Gleichung 12.2 so (s. Listing 12.2):

`kid_score ~ mom_iq + mom_hs + mom_hs:mom_iq.`

Der Doppelpunkt zwischen *mom_hs* und *mom_iq* steht für den Interaktionseffekt der beiden Variablen.

Trägt man die Punkteschätzer der Koeffizienten ($\beta_0, \beta_1, \beta_2, \beta_3$) ein, so erhält man Gleichung 12.3.

12 Fallbeispiele

$$\text{kid score} = -10 + 49.1 \cdot \text{mom hs} + 1 \cdot \text{mom iq} + -0.5 \cdot \text{mom hs} \cdot \text{mom iq} \quad (12.3)$$

Teilen wir die Regressionsformel einmal auf die beiden Gruppen (mom_hs=0 bzw. mom_hs=1) auf:

mom_hs=0:

$$\begin{aligned} \text{kid_score} &= -10 + 49.1 \cdot 0 + 1 \cdot \text{mom_iq} + -0.5 \cdot 0 \cdot \text{mom_iq} \\ &= -10 + 1 \cdot \text{mom_iq} \end{aligned}$$

mom_hs=1:

$$\begin{aligned} \text{kid_score} &= -10 + 49.1 \cdot \text{mom_hs} + 1 \cdot \text{mom_iq} + -0.5 \cdot \text{mom_hs} \cdot \text{mom_iq} \\ &= 39.1 + 0.5 \cdot \text{mom_iq} \end{aligned}$$

Wie in Tabelle 12.6 ersichtlich, kann für alle drei Effekte (mütterliche IQ, mütterlicher Schulabschluss und Interaktion von mütterlichem IQ mit mütterlichem Schulabschluss) ein Nulleffekt ausgeschlossen werden. Ob die Effekte stärker als „praktisch Null“ sind, kann mittels des ROPE-Verfahren untersucht werden.

12.7 $y \sim x_c + b + x_c:b$

Unter *Zentrieren* (to center) versteht man das Bilden der Differenz eines Messwerts zu seinem Mittelwert.¹³ Zentrierte Werte geben also an, wie weit ein Messwert vom mittleren (typischen) Messwert entfernt ist. Mit zentrierten Werten ist eine Regression einfacher zu interpretieren. Hier zentrieren wir (nur) mom_iq; die zentrierte Variable kennzeichnen wir durch den Suffix _c, also mom_iq_c. Man könnte auch mom_hs zentrieren, aber für eine einfache Interpretation ist es meist nützlich, nur metrische Prädiktoren zu zentrieren.

¹³Vgl. Abschnitt „UV zentrieren“ (<https://sebastiansauer.github.io/statistik1/090-regression2.html#uv-zentrieren>) im Kursbuch Statistik1 (<https://sebastiansauer.github.io/statistik1/>).


```

kidiq <-
  kidiq |>
  mutate(mom_iq_c = mom_iq - mean(mom_iq))

m10.5 <- stan_glm(kid_score ~ mom_hs + mom_iq_c + mom_hs:mom_iq_c,
  data = kidiq,
  refresh = 0)

coef(m10.5) # nur die Punktschätzer für die Koeffizienten ausgeben

```

Tabelle 12.7 zeigt die Punktschätzer der Koeffizienten von m10.5.

Tabelle 12.7: Punktschätzer von m10.5 (zentrierte UV)

Tabelle 12.7: Fixed Effects		
Parameter	Median	CI
(Intercept)	85.32	(81.07, 89.47)
mom_hs	2.92	(-1.83, 7.52)
mom_iq_c	0.96	(0.69, 1.24)
mom_hs:mom_iq_c	-0.48	(-0.79, -0.17)

Zur Interpretation von m10.5:

- Der *Achsenabschnitt (Intercept)* gibt den geschätzten mittleren IQ des Kindes an, wenn man eine Mutter *mittlerer* Intelligenz und *ohne* Schulabschluss betrachtet.
- mom_hs gibt den Unterschied im geschätzten mittleren IQ des Kindes an, wenn man Mütter mittlerer Intelligenz aber mit bzw. ohne Schulabschluss vergleicht.
- mom_iq_c gibt den Unterschied im geschätzten mittleren IQ des Kindes an, wenn man Mütter ohne Schulabschluss aber mit einem IQ-Punkt Unterschied vergleicht.
- mom_hs:mom_iq_c gibt den mittleren Unterschied in den Koeffizienten für mom_iq_c an zwischen den beiden Gruppen von mom_hs.

Mit `estimate_relation(m10.5) |> plot()` kann man sich das Modell visualisieren, s. Abbildung 12.10.

12 Fallbeispiele




Abbildung 12.10: m10.5: Mit zentrierten Prädiktoren gibt der Achsenabschnitt den Y-Wert für eine Beobachtung mit mittleren X-Wert an; daher ist der Achsenabschnitt besser zu interpretieren als ohne Zentrierung.

Zentrieren ändert nichts an den Vorhersagen. Betrachten wir die Vorhersagen von m10.4. Mit predict kann man sich die Vorhersagen eines Modells ausgeben lassen.

```
new <- tibble(mom_hs = 0, mom_iq = mean(kidiq$mom_iq))
pred_new <- predict(m10.4, newdata = new)
mean(pred_new)
## [1] 85
```

Und vergleichen wir Vorhersagen von m10.4 mit denen von m10.5: Wir sehen, die Vorhersagen sind (bis auf Rundungsfehler) identisch.

```
new <- tibble(mom_hs = 0, mom_iq_c = 0)
pred_new <- predict(m10.5, newdata = new)
mean(pred_new)
## [1] 85
```

Auch die Streuungen der vorhergesagten Werte unterscheiden sich nicht (wirklich): $\sigma_{m10.4} = 18$; $\sigma_{m10.5} = 18$.

Das Zentrieren ändert auch *nicht* die Regressionskoeffizienten, da die Streuungen dieser Variablen nicht verändert wurden durch das Zentrieren.

Tabelle 12.8 zeigt die Punktschätzer der Parameter für m10.5 sowie ihre ETI. Nutzen Sie dafür `parameters(m10.5)`, s. Tabelle 12.8. Highest Density (Posterior) Intervalle (HDI oder HDPI) kann man sich komfortabel ausgeben lassen mit `hdi(m10.5)` oder mit `parameters(m10.5, ci_method = "hdi")`, s. Tabelle 12.9. Im Falle symmetrischer Posteriori-Verteilungen (wie hier) kommen beide Arten von Intervallen zu gleichen Ergebnissen.

Tabelle 12.8: Parameter von m10.5 und ETIs

Tabelle 12.8: Fixed Effects		
Parameter	Median	CI
(Intercept)	85.32	(81.07, 89.47)
mom_hs	2.92	(-1.83, 7.52)
mom_iq_c	0.96	(0.69, 1.24)
mom_hs:mom_iq_c	-0.48	(-0.79, -0.17)

```
parameters(m10.5, ci_method = "hdi") |>
  select(1,2,4,5) |>
  print_md()
```

Tabelle 12.9: Parameter von m10.5 und HDIs

Tabelle 12.9: Fixed Effects		
Parameter	Median	CI
(Intercept)	85.32	(81.16, 89.53)
mom_hs	2.92	(-1.49, 7.79)
mom_iq_c	0.96	(0.68, 1.24)
mom_hs:mom_iq_c	-0.48	(-0.79, -0.17)

Das Model zeigt keine Belege, dass sich die mittlere Intelligenz von Kindern bei Müttern mit bzw. ohne Schulabschluss unterscheidet (95%PI: [-2.0, 7.8]); die Befundlage ist unklar. Hingegen fand sich ein Effekt der mütterlichen Intelligenz; pro Punkt Unterschied in mütterlichem IQ fand sich ein Unterschied von 0.7 bis 1.3 IQ-Punkte beim Kind (95%PI). Außerdem fand sich ein Beleg, dass der Zusammenhang des IQ zwischen Mutter und Kind durch den Schulabschluss moderiert wird: Bei Mütter

12 Fallbeispiele

mit Schulabschluss war der Regressionskoeffizient zwischen Mutter-IQ und Kind-IQ geringer (95%PI: [-0.80, -0.17]).

! Wichtig

Das Modell hat mittels Abbildung 12.11 mutig Kausalaussagen postuliert. Das ist zwar schön, bedarf aber einer Begründung mit Rückgriff auf die Literatur (was hier nicht getan wurde). Ohne eine Begründung ist die Behauptung der Kausalaussage nicht zu verteidigen.

12.8 $y \sim g$

Hier untersuchen wir ein Modell mit einer nominalen UV mit mehreren Stufen.


Nach Ihrem Studium wurden Sie reich als Unternehmensberaterin; Ihre Kompetenz als Wirtschaftspsychologin war heiß begehrt. Von Statistik wollte niemand etwas wissen... Doch nach einiger Zeit kamen Sie in eine Sinnkrise. Sie warfen Ihren Job hin und beschlossen, in die Wissenschaft zu gehen. Kurz entschlossen bewarben Sie sich auf das erste Stellenangebot als Nachwuchswissenschaftler:in. Ihr Forschungsprojekt führte Sie in die Antarktis... Nun, das war zumindest ein Gegenentwurf zu Ihrem bisherigen Jet-Set-Leben. Ihre Aufgabe bestand nun darin, Pinguine zu untersuchen. Genauer gesagt ging es um Größenunterschiede zwischen drei Pinguinarten. Ja, stimmt, an so ein Forschungsprojekt hatten Sie vorher nie auch nur im Traum gedacht.

Forschungsfrage:

Unterscheiden sich die mittleren Körpergewichte der drei Pinguinarten?

Die allgemeine Modellformel zur Forschungsfrage lautet: $y \sim g$.

Der DAG zur Modellformel ist in Abbildung 12.11 dargestellt.

Abbildung 12.11: DAG für $y \sim g$

Prüfen wir die Nullhypothese, H_0 , dass alle Mittelwerte gleich sind, exakt gleich (?)

Formal: $\mu_1 = \mu_2 = \dots = \mu_k$ mit k verschiedenen Gruppen von Pinguinarten. Hypothesen, die keinen (Null) Unterschied zwischen Gruppen oder keinen Zusammenhang zwischen Variablen postulieren, kann man als *Nullhypothesen* bezeichnen. Moment. Dass sich *alle* Mittelwerte um 0,00000000 unterscheiden, ist wohl nicht zu vermuten. Daher ist die bessere Forschungsfrage:

Wie *sehr* unterscheiden sich mittlere Körpergewichte in Abhängigkeit von der Pinguinart?

Alternativ können wir die Hypothese prüfen, ob die Mittelwerte „praktisch“ gleich sind, also sich „kaum“ unterscheiden. Der Grenzwert für „praktisch gleich“ bzw. „kaum unterschiedlich“ ist subjektiv. Dazu in Kapitel 11.4 mehr.

Werfen wir einen Blick in den Datensatz `penguins`. Hier ist die Verteilung des Gewichts jeder Spezies im Datensatz, Tabelle 12.10.



Abbildung 12.12: Palmer Penguins

Datenquelle¹⁴, Beschreibung des Datensatzes¹⁵

```
penguins |>
  select(body_mass_g, species) |>
  group_by(species) |>
  describe_distribution(range = FALSE, iqr = FALSE)
```

Tabelle 12.10: Die Verteilung des Körpergewichts pro Spezies der Pinguine

species	Mean	SD	IQR	Min	Max	n
Adelie	3701	459	650	2850	4775	151
Chinstrap	3733	384	488	2700	4800	68
Gentoo	5076	504	800	3950	6300	123

Was fällt Ihnen auf? Visualisieren wir als Nächstes die Verteilung der AV, um den Datensatz genauer zu verstehen. Hier kommen die Pinguine! Wie schwer sind die Tiere in unserer Stichprobe, s. Abbildung 12.13?

¹⁴<https://vincentarelbundock.github.io/Rdatasets/csv/palmerpenguins/penguins.csv>

¹⁵<https://vincentarelbundock.github.io/Rdatasets/doc/palmerpenguins/penguins.html>




Abbildung 12.13: Verteilung des Körpergewichts dreier Arten von Pinguinen – Geom Violine

Berechnen wir nun das mittlere Gewicht pro Spezies (Gruppe) der Pinguine, s. m10.6 und Tabelle 12.11. Die Modellformel für m10.6 lautet also `body_mass_g ~ species`.

```
options(mc.cores = parallel::detectCores()) # Turbo einschalten

m10.6 <- stan_glm(body_mass_g ~ species,
                  data = penguins,
                  refresh = 0, # unterdrückt Ausgabe der Posteriori-Stichproben
                  )

m10.6 |> parameters()
```

12 Fallbeispiele

Tabelle 12.11: Parameter des Modells m10.6; neben dem Achsenabschnitt sind die Effekte der Gruppe Adelie und Chinstrap ausgewiesen

Tabelle 12.11: Fixed Effects		
Parameter	Median	CI
(Intercept)	3702.05	(3628.80, 3774.84)
speciesChinstrap	33.38	(-105.46, 170.16)
speciesGentoo	1375.11	(1263.06, 1483.22)

Zur Interpretation von m10.6:

Die UV hat drei verschiedene Stufen (Werte, Ausprägungen; hier: Spezies), aber es werden in Tabelle 12.11 nur zwei Stufen angezeigt (also eine weniger) zusätzlich zum Achsenabschnitt. Die fehlende Stufe (Adelie, nicht ausgegeben) ist die *Vergleichs- oder Referenzkategorie* (baseline) und ist im Achsenabschnitt ausgedrückt (Intercept). Die Koeffizienten für species geben jeweils den (vorhergesagten) Unterschied zur Vergleichskategorie wieder. Pinguine der Spezies Adelie haben laut Modell ein mittleres Gewicht von ca. 3700 g. Pinguine der Spezies Gentoo sind laut Modell im Mittel gut 1300 g schwerer als Pinguine der Spezies Adelie, etc.

Der Unterschied im mittleren Gewicht von den Gruppen Chinstrap und Gentoo zur Referenzgruppe (Adelie) ist in Abbildung 12.14 verdeutlicht.

```
plot(hdi(m10.6)) +  
  # order = c(5, 4): Blau/Amber statt Orange/Hellblau, da Letztere im  
  # Graustufendruck fast identisch hell sind (schlechter S/W-Kontrast)  
  scale_fill_okabeito(order = c(5, 4))
```


Highest Density Interval (HDI)




Abbildung 12.14: Effekt der UV: Unterschiede zur Referenzgruppe (95%-HDI)

Das Farbschema nach Okabe und Ito¹⁶ ist gut geeignet, um nominal skalierte Farben zu kodieren (s. Details hier).

Glauben wir jetzt an Gruppeneffekte?

Glauben wir jetzt, auf Basis der Modellparameter, an Unterschiede (hinsichtlich der AV) zwischen den Gruppen (UV)?

Es scheinen sich nicht alle Gruppen voneinander zu unterscheiden. So ist der Mittelwert der Gruppe Gentoo deutlich höher als der der beiden anderen Gruppen. Umgekehrt sind sich die Pinguinarten Adelie und Chinstrap in ihren Mittelwerten ziemlich ähnlich. Wie in Abbildung 12.14 ersichtlich, überlappt sich der Schätzbereich für den Parameter von Gentoo *nicht* mit der Null; hingegen überlappt sich der Schätzbereich des Parameters für Chinstrap deutlich mit der Nulllinie. Auf Basis unseres Modells verwerfen wir also (mit hoher Sicherheit) die Hypothese, dass *alle* Mittelwerte *exakt* identisch sind. Ehrlicherweise ist sowieso zweifelhaft, dass die *exakte Nullhypothese* $\mu_1 = \mu_2 = \dots = \mu_k$ bis in die letzte Dezimale gilt. Anders gesagt: Die Wahrscheinlichkeit eines bestimmten Wertes einer stetigen Zufallsvariable ist praktisch Null. Aber: Viele Forscherinnen und Forscher prüfen gerne die Nullhypothese, daher diskutieren wir hier den Begriff der (exakten) Nullhypothese. Das Verfahren der Frequentistischen Statistik, um die Nullhypothese $\mu_1 = \mu_2 = \dots = \mu_k$ zu testen, nennt man *Varianzanalyse* (analysis of variance, kurz ANOVA). In der

¹⁶<https://jfly.uni-koeln.de/color/>

12 Fallbeispiele

Bayes-Statistik nutzt man – wie immer – primär die Post-Verteilung, um Fragen der Inferenz (z. B. Gruppenunterschiede dieser Art) zu beurteilen.

Unser Modell m10.6 verwendet schwach informierte (weakly informative) Priors. Für Achsenabschnitt und die Regressionskoeffizienten trifft unser Golem Stan folgende Annahmen in der Voreinstellung:

- Achsenabschnitt und Regressionsgewichte werden als normalverteilt angenommen
- mit Mittelwert entsprechend den Stichprobendaten
- und einer Streuung des Mittelwerts, die der 2.5-fachen der Streuung in der Stichprobe entspricht
- für Sigma wird eine Exponentialverteilung mit Rate $\lambda = 1$ angenommen, skaliert mit der Streuung der AV.

Mehr Infos kann man sich mit `prior_summary(modell)` ausgeben lassen.

```
prior_summary(m10.6)
## Priors for model 'm10.6'
## -----
## Intercept (after predictors centered)
## Specified prior:
## ~ normal(location = 4202, scale = 2.5)
## Adjusted prior:
## ~ normal(location = 4202, scale = 2005)
##
## Coefficients
## Specified prior:
## ~ normal(location = [0,0], scale = [2.5,2.5])
## Adjusted prior:
## ~ normal(location = [0,0], scale = [5015.92,4171.63])
##
## Auxiliary (sigma)
## Specified prior:
## ~ exponential(rate = 1)
## Adjusted prior:
## ~ exponential(rate = 0.0012)
## -----
## See help('prior_summary.stanreg') for more details
```

Wenn man über mehr inhaltliches Wissen verfügt, wird man die Prioris anpassen wollen. So könnte man z. B. auf Basis von Fachwissen über das Gewicht von Pinguinen postulieren, dass Adelie-Pinguine im Mittel 3000 g wiegen. Und dass die anderen zwei Pinguin-Arten im Mittel sich nicht unterscheiden vom Mittelwert der Adelie-Pinguine.

```
m10.6b <- stan_glm(
  body_mass_g ~ species,
  data = penguins,
  refresh = 0,
  prior = normal(location = c(0, 0), # betas, Mittelwert
                  scale = c(500, 500)), # betas, Streuung
  prior_intercept = normal(3000, 500), # Achsenabschnitt, Mittelwert und Streuung
  prior_aux = exponential(0.001)
)
coef(m10.6b)
##      (Intercept) speciesChinstrap speciesGentoo
##           3707           24           1356
```

Anstelle von Rohwerten (hier Angabe von Gramm Gewicht) kann man die Streuung auch in z-Werten eingeben, das macht es etwas einfacher, s. m10.6c. Dazu gibt man bei dem oder den entsprechenden Parametern den Zusatz `autoscale = TRUE` an.

```
m10.6c <- stan_glm(
  body_mass_g ~ species,
  data = penguins,
  refresh = 0,
  prior = normal(location = c(0, 0), # betas, Mittelwert
                  scale = c(2.5, 2.5), # betas, Streuung
                  autoscale = TRUE), # in z-Einheiten
  prior_intercept = normal(3000, 2.5, # Achsenabschnitt, Mittelwert und Streuung
                           autoscale = TRUE),
  prior_aux = exponential(1, autoscale = TRUE)
)
coef(m10.6c)
##      (Intercept) speciesChinstrap speciesGentoo
##           3701           32           1374
```

Den Parameter für die Streuung des Modells, σ , kann man sich mit `sigma(modell)` ausgeben lassen.

```
sigma(m10.6b)
## [1] 463
```

Implizit bekommt man die Informationen zu σ mitgeteilt durch die Größe der Konfidenzintervalle.

Übrigens macht es meistens keinen Sinn, *extrem* weite Prioris zu definieren.¹⁷

12.9 Vertiefung: Wechsel der Referenzkategorie

species ist eine nominale Variable, da passt in R der Typ factor (Faktor) am besten. Aktuell ist der Typ noch character (Text):

```
penguins <- penguins |>
  mutate(species = factor(species))
```

Im Standard sortiert R die Faktorstufen alphabetisch, aber man kann die Reihenfolge ändern.

```
levels(penguins$species)
## [1] "Adelie" "Chinstrap" "Gentoo"
```

Setzen wir Gentoo als Referenzkategorie und lassen die restliche Reihenfolge, wie sie ist:

```
library(forcats)
penguins <- penguins |>
  mutate(species = factor(species),
         species = fct_relevel(species, "Gentoo"))
```

Beachten Sie, dass dazu das Paket forcats verfügbar sein muss.

Jetzt haben wir die Referenzkategorie geändert:

¹⁷s. Details unter <https://mc-stan.org/rstanarm/articles/priors.html#how-to-specify-flat-priors-and-why-you-typically-shouldnt>.

```
levels(penguins$species)
## [1] "Gentoo" "Adelie" "Chinstrap"
```

Der Wechsel der Referenzkategorie ändert nichts Wesentliches am Modell, s. Tabelle 12.12.

```
m10.6a <- stan_glm(body_mass_g ~ species, data = penguins, refresh = 0)
hdi(m10.6a)
```

Tabelle 12.12: m10.6a mit geänderter Referenzkategorie; die Effekte der UVs bleiben gleich.

Tabelle 12.12: Highest Density Interval

Parameter	95% HDI
(Intercept)	[4995.54, 5160.03]
speciesAdelie	[-1481.34, -1266.61]
speciesChinstrap	[-1479.09, -1207.72]

12.10 $y \sim x1 + x2$

Hier untersuchen wir Forschungsfragen mit zwei metrischen UV (und einer metrischen AV).

Forschungsfrage:

Stehen sowohl der IQ der Mutter als auch, unabhängig davon, das Alter der Mutter im Zusammenhang mit dem IQ des Kindes?

Das ist eine *deskriptive* Forschungsfrage. Keine Kausalwirkung (etwa „IQ der Mutter ist die Ursache zum IQ des Kindes“) wird impliziert. Es geht in dieser Forschungsfrage rein darum, Zusammenhänge in den Daten – bzw. in der Population – aufzuzeigen. Viele Forschungsfragen gehen allerdings weiter und haben explizit Kausalwirkungen im Fokus. Für solche Fragen ist ein Kausalmodell nötig: Fachlich fundierte Annahmen über Kausalzusammenhänge zwischen UV und AV.

Was heißt, X hängt mit Y zusammen?

12 Fallbeispiele

Der Begriff „Zusammenhang“ ist nicht exakt. Häufig wird er (für metrische Variablen) verstanden als lineare Korrelation ρ bzw. r oder als lineare Regression β bzw. b .

Der Regressionskoeffizient misst die *Steigung* der Regressionsgerade und zeigt, wie groß der vorhergesagte Unterschied in Y ist, wenn man zwei Personen (Beobachtungseinheiten) vergleicht, die sich um eine Einheit in X unterscheiden. Der Regressionskoeffizient wird manchmal mit dem „Effekt von X auf Y“ übersetzt. Vorsicht: „Effekt“ klingt nach Kausalzusammenhang. Eine Regression ist keine hinreichende Begründung für einen Kausalzusammenhang.

Der Korrelationskoeffizient misst eine Art der Stärke des linearen Zusammenhangs. Er zeigt, wie klein die Vorhersagefehler der zugehörigen Regression im Schnitt sind. Korrelation ist nicht (automatisch) Kausation.¹⁸

Es ist hilfreich, sich die Korrelationen zwischen den (metrischen) Variablen zu betrachten, bevor man ein (Regressions-)Modell aufstellt, s. Tabelle 12.13.

```
kidiq |>
correlation(bayesian = TRUE)
```

Tabelle 12.13: Korrelation der Variablen im Datensatz kidiq (95 %-KI)

Parameter1	Parameter2	rho	CI
kid_score	mom_hs	0.23	(0.14, 0.32)
kid_score	mom_iq	0.44	(0.37, 0.52)
kid_score	mom_age	0.09	(-4.59e-03, 0.18)
kid_score	mom_iq_c	0.44	(0.36, 0.51)
mom_hs	mom_iq	0.28	(0.19, 0.37)
mom_hs	mom_age	0.21	(0.13, 0.30)
mom_hs	mom_iq_c	0.28	(0.19, 0.37)
mom_iq	mom_age	0.09	(-2.50e-03, 0.18)
mom_iq	mom_iq_c	1.00	(1.00, 1.00)
mom_age	mom_iq_c	0.09	(-7.19e-03, 0.18)

Tabelle 12.14 zeigt die Korrelationsmatrix.

¹⁸<https://xkcd.com/552/>

```
kidiq |>
correlation(bayesian = TRUE) |>
summary()
```

Tabelle 12.14: Die Korrelationen zwischen den Variablen der Tabelle kidiq. Die Sterne geben einen Bereich des p-Werts an (wir ignorieren die Sterne hier).

Parameter	mom_iq_c	mom_age	mom_iq	mom_hs
kid_score	0.45***	0.09	0.45***	0.24***
mom_hs	0.28***	0.21***	0.28***	
mom_iq	1.00***	0.09		
mom_age	0.09			

p-value adjustment method: Holm (1979)

Nützlich ist auch die Visualisierung der Korrelationstabelle als Heatmap, Abbildung 12.15.

```
kidiq |>
correlation() |>
summary() |>
plot()
```

Correlation Matrix




Abbildung 12.15: Visualisierung der Korrelationsmatrix als Heatmap

Wir berechnen zunächst jeweils eine univariate Regression, pro Prädiktor, also eine für mom_iq und eine für mom_age.

```
m10.7 <- stan_glm(kid_score ~ mom_iq, data = kidiq, refresh = 0)
m10.8 <- stan_glm(kid_score ~ mom_age, data = kidiq, refresh = 0)
```

Tabelle 12.15 zeigt die Ergebnisse für mom_iq.

Tabelle 12.15: Parameter für m10.7

Tabelle 12.15: Fixed Effects		
Parameter	Median	CI
(Intercept)	25.68	(14.29, 37.97)
mom_iq	0.61	(0.49, 0.72)

Tabelle 12.16 zeigt die Ergebnisse für mom_age.

Tabelle 12.16: Parameter für m10.8

Tabelle 12.16: Fixed Effects		
Parameter	Median	CI
(Intercept)	71.08	(54.69, 87.33)
mom_age	0.69	(-0.03, 1.40)

Visualisieren wir nun die univariaten Regressionen. In Abbildung 12.16 ist die univariate Regression mit jeweils einem der beiden Prädiktoren dargestellt.

m10.7: Die Steigung beträgt 0.6. m10.8: Die Steigung beträgt 0.7.

m10.7: Die univariate Regression mit dem Alter der Mutter al




Abbildung 12.16: Zwei univariate Regressionen

Berechnen wir im Folgenden das multiple Modell (beide Prädiktoren), m10.9. m10.9 stellt das multiple Regressionsmodell dar; *multipel* bedeutet in diesem Fall, dass mehr als ein Prädiktor im Modell aufgenommen ist, s. Tabelle 12.17.

```
m10.9 <- stan_glm(kid_score ~ mom_iq + mom_age,
  data = kidiq,
  refresh = 0)
parameters(m10.9)
```

Tabelle 12.17: Parameter für m10.9

Tabelle 12.17: Fixed Effects		
Parameter	Median	CI
(Intercept)	17.46	(2.06e-03, 34.54)
mom_iq	0.60	(0.49, 0.72)
mom_age	0.40	(-0.26, 1.05)

! Wichtig

Die Regressionsgewichte unterscheiden sich (potenziell) von denen der jeweiligen univariaten Regressionen.

Bei einer multiplen Regression ist ein Regressionsgewicht jeweils „bereinigt“ vom Zusammenhang mit dem (oder den) anderen Regressionsgewicht(en). Das bedeutet anschaulich, man betrachtet den Zusammenhang einer UV mit der AV, wobei man gleichzeitig den anderen Prädiktor konstant hält.

Abbildung 12.17 zeigt eine Visualisierung von m10.9, in der die 3. Dimension durch eine Farbschattierung ersetzt ist.




Abbildung 12.17: Modell m10.9; die Farbverläufe zeigen der Wert der abhängigen Variablen

Auf der Achse von mom_iq erkennt man deutlich (anhand der Farbänderung) die

Veränderung für die AV (kid_score). Auf der Achse für mom_age sieht man, dass sich die AV kaum ändert, wenn sich mom_age ändert.

Abbildung 12.18 visualisiert den Zusammenhang von 10 Variablen untereinander.



Abbildung 12.18: So sieht der Zusammenhang im 10-dimensionalen Raum aus

Leider macht mein Hirn hier nicht mit. Unsere Schwäche, eine große Zahl an Dimensionen zu visualisieren, ist der Grund, warum wir mathematische Modelle brauchen. Daher kann man ein Modell verstehen als eine Zusammenfassung eines (ggf. hochdimensionalen) Variablenraums.

12.11 $y \sim x1_z + x2_z$

In diesem Abschnitt untersuchen wir ein Modell mit zwei z-standardisierten, metrischen Prädiktoren (und einer metrischen, *nicht*-standardisierten AV).

Zur Relevanz der Prädiktoren: Woher weiß man, welche UV am stärksten mit der AV zusammenhängt? Man könnte auch sagen: Welcher Prädiktor (welche UV) am „wichtigsten“ ist oder den „stärksten Einfluss“ auf die AV ausübt? Bei solchen kausal konnotierten Ausdrücken muss man vorsichtig sein: Die Regressionsanalyse als solche ist keine Kausalanalyse. Die Regressionsanalyse – wie jede statistische Methode – kann für sich *nur Muster in den Daten*, also Zusammenhänge bzw. Unterschiede, entdecken. Möchte man die Relevanz von Prädiktoren vergleichen, so ist ein Kausalmodell empfehlenswert.

Welcher Prädiktor ist nun „wichtiger“ oder „stärker“ in Bezug auf den Zusammenhang mit der AV, mom_iq oder mom_age (Modell m10.9)? Die Antwort hängt auch

12 Fallbeispiele

von der Streuung bzw. Skalierung der Variablen ab. `mom_iq` hat den größeren Koeffizienten und viel Streuung; `mom_age` hat weniger Streuung.

Um die Relevanz der Prädiktoren vergleichen zu können, müsste man vielleicht die Veränderung von `kid_score` betrachten, wenn man vom kleinsten zum größten Prädiktorwert geht. Allerdings sind Extremwerte meist instabil (da sie von einer einzigen Beobachtung bestimmt werden). Sinnvoller ist es daher, die Veränderung in der AV zu betrachten, wenn man den Prädiktor von „unterdurchschnittlich“ auf „überdurchschnittlich“ ändert. Das kann man mit *z-Standardisierung* erreichen.

```
kidiq2 <-  
  kidiq |>  
  mutate(mom_iq_z = ((mom_iq - mean(mom_iq)) / sd(mom_iq))) |> # z-Transformation  
  select(mom_iq, mom_iq_z)  
  
kidiq2 |>  
  head()
```

mom_iq	mom_iq_z
121	1.41
89	-0.71
115	1.03
99	-0.04
93	-0.48
108	0.53

Der Nutzen von Standardisieren (dieser Art) ist die *bessere Vergleichbarkeit* der Effekte von UV, die (zuvor) verschiedene Mittelwerte und Streuungen hatten¹⁹. Die Standardisierung ist ähnlich zur Vergabe von Prozenträngen: „Dieser Messwert gehört zu den Top-3-Prozent“. Diese Aussage ist bedeutsam für Variablen mit verschiedenem Mittelwert und Streuung. So werden vergleichende Aussagen für verschiedene Verteilungen möglich.

Zu den Statistiken zu den z-transformierten Variablen: Tabelle 12.3 zeigt die Verteilung der (metrischen) Variablen im Datensatz `kidiq`.

Metrische Variablen in z-Werte zu transformieren, hat verschiedene Vorteile:

¹⁹am nützlichsten ist diese Standardisierung bei normal verteilten Variablen.

- der Achsenabschnitt ist einfacher zu interpretieren (da er sich dann auf ein Objekt mit mittlerer Ausprägung bezieht)
- Interaktionen sind einfacher zu interpretieren (aus dem gleichen Grund)
- Prioriwerte sind einfacher zu definieren (wieder aus dem gleichen Grund)
- die Effekte verschiedener Prädiktoren sind einfacher in ihrer Größe zu vergleichen, da sie dann die gleiche Skalierung/Streuung aufweisen
- kleine und ähnlich große Wertebereiche erleichtern dem Golem die Rechenarbeit

Man kann die z-Transformation („Standardisierung“) mit `standardize` (aus `easystats`) durchführen, s. Tabelle 12.18.

```
kidiq_z <-  
  standardize(kidiq, append = TRUE) # z-transformiert alle numerischen Werte
```

Tabelle 12.18: z-transformierte Variablen im Datensatz `kidiq` (erste paar Zeilen und Spalten)

kid_score	mom_hs	mom_iq	mom_age
65	1	121.12	27
98	1	89.36	25
85	1	115.44	27
83	1	99.45	25
115	1	92.75	27
98	0	107.90	18

Der Schalter `append = TRUE` sorgt dafür, dass die ursprünglichen Variablen beim z-Standardisieren nicht überschrieben werden, sondern angehängt werden (mit einem Suffix `_z`).

Man kann auch nur einzelne Variablen mit `standardize` standardisieren, indem man das Argument `select` nutzt.

```
kidiq |>  
  standardize(select = c("mom_iq", "mom_age", "kid_score"))
```

Man kann das Standardisieren auch von Hand machen, ohne ein Extra-Paket, s. Tabelle 12.19. Dazu verwendet man den Befehl `scale()`.

12 Fallbeispiele

```
kidiq |>
  mutate(mom_iq_z2 = scale(mom_iq),
         mom_age_z2 = scale(mom_age),
         kid_score_z2 = scale(kid_score))
```

Tabelle 12.19: Z-Standardisierung ohne Extrapaket; ersten paar Spalten und Zeilen

mom_iq	mom_iq_z2
121	1.408
89	-0.709
115	1.030
99	-0.037
93	-0.484
108	0.527

Berechnen wir das Modell m10.10: $y \sim x1_z + x2_z$.

```
m10.10 <- stan_glm(kid_score ~ mom_iq_z + mom_age_z,
  data = kidiq_z,
  refresh = 0)
parameters(m10.10)
```

Tabelle 12.20: Parameter von m10.12

Tabelle 12.20: Fixed Effects		
Parameter	Median	CI
(Intercept)	86.80	(85.11, 88.50)
mom_iq_z	9.06	(7.41, 10.75)
mom_age_z	1.05	(-0.68, 2.79)

12.12 $y_z \sim x1_z + x2_z$

In diesem Abschnitt berechnen wir ein Modell (Modell m10.12), in dem sowohl die Prädiktoren z-transformiert sind (standardisiert) *als auch* die AV. Das

z-Standardisieren der AV, `kid_score`, ist zwar *nicht* nötig, um den Effekt der Prädiktoren (UV) auf die AV zu untersuchen. Standardisiert man aber die AV, so liefern die Regressionskoeffizienten (Betas) eine Aussage darüber, um wie viele SD-Einheiten sich die AV verändert, wenn sich ein Prädiktor um eine SD-Einheit verändert. Das kann auch eine interessante(re) Aussage sein.

Berechnen wir das Modell m10.12: $y_z \sim x1_z + x2_z$.

```
m10.12 <- stan_glm(kid_score_z ~ mom_iq_z + mom_age_z,
  data = kidiq_z,
  refresh = 0)
coef(m10.12)
## (Intercept)  mom_iq_z  mom_age_z
##  0.00056    0.44320    0.05211
```

- Der *Achsenabschnitt* gibt den Mittelwert der AV (`kid_score`) an, da `kid_score_z = 0` identisch ist zum Mittelwert von `kid_score`.
- Der Koeffizient für `mom_iq_z` gibt an, um wie viele SD-Einheiten sich `kid_score` (die AV) ändert, wenn sich `mom_iq` um eine SD-Einheit ändert.
- Der Koeffizient für `mom_age_z` gibt an, um wie viele SD-Einheiten sich `kid_score` (die AV) ändert, wenn sich `mom_age` um eine SD-Einheit ändert.

Jetzt sind die Prädiktoren in ihrer Relevanz (Zusammenhang mit der AV) vergleichbar. Man sieht, dass die Intelligenz der Mutter *deutlich wichtiger* ist als das Alter der Mutter (im Hinblick auf die Vorhersage bzw. den Zusammenhang mit der AV).

Mit `parameters` können wir uns ein PI für m10.12 ausgeben lassen, s. Abbildung 12.19; im Standard wird ein 95 %-ETI berichtet²⁰.

```
parameters(m10.12)
```

Tabelle 12.21: Fixed Effects

Parameter	Median	CI
(Intercept)	5.64e-04	(-0.08, 0.08)
mom_iq_z	0.44	(0.36, 0.52)
mom_age_z	0.05	(-0.04, 0.14)

²⁰Zumindest zur Zeit als ich diese Zeilen schreibe. Achtung: Voreinstellungen können sich ändern. Am besten in der Dokumentation nachlesen: `?parameters`.

12 Fallbeispiele

Parameter	Median	CI
-----------	--------	----

```
plot(eti(m10.12)) +
# order = c(5, 4): Blau/Amber statt Orange/Hellblau, da Letztere im
# Graustufendruck fast identisch hell sind (schlechter S/W-Kontrast)
scale_fill_okabeito(order = c(5, 4))
```




Abbildung 12.19: Im Standard wird ein 95%-Intervall gezeigt bzw. berechnet; hier das ETI für m10.12

Wie ist es um die Modellgüte in m10.12 bestellt? Berechnen wir R^2 .

```
r2(m10.12)
## # Bayesian R2 with Compatibility Interval
##
## Conditional R2: 0.204 (95% CI [0.145, 0.266])
```

Ist dieser Wert von R^2 „gut“? Diese Frage ist ähnlich zur Frage „Ist das viel Geld?“; man kann die Frage nur im Kontext beantworten.

Eine einfache Lösung ist immer, Modelle zu vergleichen. Dann kann man angeben, welches Modell die Daten am besten erklärt, z. B. auf Basis von R^2 .

Zu beachten ist, dass das Modell theoretisch fundiert sein sollte. Vergleicht man viele Modelle aufs Geratewohl, so muss man von zufällig hohen Werten der Modellgüte im Einzelfall ausgehen.

Wenn Sie aber unbedingt eine „objektive“ Antwort auf die Frage „wie viel ist viel?“ haben wollen, ziehen wir Herrn Cohen zu Rate, der eine Antwort auf die Frage „Wie viel ist viel?“ gegeben hat (Cohen, 1992):

```
interpret_r2(0.2) # aus `easystats`
## [1] "moderate"
## (Rules: cohen1988)
```

Danke, Herr Cohen! Die Prioris für m10.12 kann man sich mit `prior_summary(m10.12)` ausgeben lassen. Danke, Stan!

```
prior_summary(m10.12) # aus rstanarm
## Priors for model 'm10.12'
## -----
## Intercept (after predictors centered)
## ~ normal(location = -2.8e-16, scale = 2.5)
##
## Coefficients
## ~ normal(location = [0,0], scale = [2.5,2.5])
##
## Auxiliary (sigma)
## ~ exponential(rate = 1)
## -----
## See help('prior_summary.stanreg') for more details
```



Nix zu danken!

Wie gesagt, Stan nimmt dafür einfach die empirischen Mittelwerte und Streuungen her.²¹

Stans Ausgabe kann man in Mathe-Sprech so darstellen, s. Gleichung 12.4.

²¹Nicht unbedingt die feine bayesianische Art, denn die Prioris sollten ja eigentlich apriori, also vor Kenntnis der Daten, bestimmt werden. Auf der anderen Seite behauptet Stan, von uns zur Rede gestellt, dass die empirischen Mittelwerte ja doch gute Schätzer der echten Parameter sein müssten, wenn die Stichprobe, die wir ihm angeschleppt hätten, tatsächlich gut ist...

$$\begin{aligned}
\text{kidscore}_i^z &\sim \mathcal{N}(\mu_i, \sigma) \\
\mu_i &= \beta_0 + \beta_1 \text{momi}q_i^z + \beta_2 \text{momage}_i^z \\
\beta_0 &\sim \mathcal{N}(0, 2.5) \\
\beta_1 &\sim \mathcal{N}(0, 2.5) \\
\beta_2 &\sim \mathcal{N}(0, 2.5) \\
\sigma &\sim \mathcal{E}(1)
\end{aligned} \tag{12.4}$$

Man beachte, dass der Achsenabschnitt zur Intelligenz der Kinder auf Null festgelegt wird: Bei *mittlerer* Intelligenz und *mittlerem* Alter der Mutter wird *mittlere* Intelligenz des Kindes erwartet in m10.12. Dadurch, dass nicht nur UV, sondern auch AV z-standardisiert (d. h. zentriert und in der Streuung auf 1 standardisiert) sind, ist der Mittelwert der AV Null. Schreibt man einen Bericht, so bietet es sich an, die Modelldefinition zumindest im Anhang aufzuführen.

Übungsaufgabe 12.3 (Anzahl der Modellparameter). Wie viele Modellparameter hat m10.12?²²

Unsere Antwort auf die Forschungsfrage:

Das Modell spricht sich klar für einen statistischen, linearen Effekt von Intelligenz der Mutter auf die Intelligenz des Kindes aus, wenn das Alter der Mutter statistisch kontrolliert wird (95%PI: [0.38, 0.51]). Pro Einheit Standardabweichung in der UV (Intelligenz der Mutter) ändert sich die AV um ca. 0.44 Standardabweichungseinheiten. Hingegen zeigt das Modell, dass das Alter der Mutter statistisch eher keine Rolle spielt (95%PI: [-0.02, 0.12]). Alle Variablen wurden z-transformiert. Insgesamt erklärt das Modell im Median einen Anteil von ca. 0.2 an der Varianz der Kinderintelligenz. Das Modell griff auf die Standard-Priori-Werte aus dem R-Paket rstanarm (Goodrich et al., 2020) zurück (s. Anhang für Details).

! Wichtig

Hier wird von einem „statistischen Effekt“ gesprochen, um klar zu machen, dass es sich lediglich um assoziative Zusammenhänge, und nicht um kausale Zusammenhänge, handelt. Kausale Zusammenhänge dürfen wir nur verkünden, wenn wir sie a) explizit untersuchen und b) sich in der Literatur Belege

²²4: $\beta_0, \beta_1, \beta_2, \sigma$

dafür finden oder c) wir ein Experiment fachgerecht durchgeführt haben.

12.13 Vertiefung

Sind X und Y z-standardisiert, so sind Korrelation und Regression identisch, s. Theorem 12.2.

Theorem 12.2. *Man kann die Regression als Korrelation verstehen:*

$$b = r \frac{sd_y}{sd_x} \quad \square$$

Berechnen wir dazu ein einfaches Modell mit z-standardisierten Variablen und betrachten die Punktschätzer für die Regressionskoeffizienten, s. m10.12.

```
m10.12 <-
  stan_glm(kid_score_z ~ mom_iq_z, data = kidiq_z, refresh = 0)
coef(m10.12)
## (Intercept)  mom_iq_z
##      0.001      0.446
```

Vergleichen Sie diese Werte mit der Korrelation, s. Tabelle 12.22.²³

```
kidiq_z |>
  select(kid_score, mom_iq, kid_score_z, mom_iq_z) |>
  correlation() |>
  display()
```

²³Ignorieren Sie die Zeile mit dem Befehl `display()`. Dieser Befehl dient nur dazu, die Ausgabe zu verschönern in Markdown-Dokumenten, wie im Quelltext dieses Kapitels.

Tabelle 12.22: Correlation Matrix (pearson-method)

Parameter1	Parameter2	r	95% CI	t(432)	p
kid_score	mom_iq	0.45	(0.37, 0.52)	10.42	< .001***
kid_score	kid_score_z	1.00	(1.00, 1.00)	Inf	< .001***
kid_score	mom_iq_z	0.45	(0.37, 0.52)	10.42	< .001***
mom_iq	kid_score_z	0.45	(0.37, 0.52)	10.42	< .001***
mom_iq	mom_iq_z	1.00	(1.00, 1.00)	Inf	< .001***
kid_score_z	mom_iq_z	0.45	(0.37, 0.52)	10.42	< .001***

p-value adjustment method: Holm (1979) Observations: 434

Korrelationen der z-transformierten Variablen im Datensatz kidiq

Zentrale Annahme eines linearen Modells: Die AV ist eine *lineare* Funktion der einzelnen Prädiktoren, $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots$, vgl. Theorem 2.1.

Hingegen ist es weniger wichtig, dass die AV (y) normalverteilt ist. Zwar nimmt die Regression häufig normalverteilte Residuen an²⁴, aber diese Annahme ist nicht wichtig, wenn es nur darum geht, die Regressionskoeffizienten zu schätzen (Gelman et al., 2021).

Ist die Linearitätsannahme erfüllt, so sollte der Residualplot nur *zufällige* Streuung um $y = 0$ herum zeigen, s. Abbildung 12.20.

Ein Residuum e ist der Vorhersagefehler, also die Differenz zwischen vorhergesagtem und tatsächlichem Wert: $e_i = y_i - \hat{y}_i$

```
kidiq <-  
kidiq |>  
mutate(m10.12_pred = predict(m10.12), # vorhergesagten Werte  
       m10.12_resid = resid(m10.12)) # Residuen
```

```
kidiq |>  
ggplot(aes(x = m10.12_pred, y = m10.12_resid)) +  
geom_hline(color="white", yintercept = 0, size = 2) +  
geom_hline(color = "grey40",  
           yintercept = c(-1,1),
```

²⁴was auf normal verteilte AV hinauslaufen kann aber nicht muss

```
size = 1,  
linetype = "dashed") +  
geom_point(alpha = .7) +  
geom_smooth()
```





Abbildung 12.20: Die Verteilung der Fehler scheint keinem starken Trend (in Abhängigkeit zum vorhergesagten Wert) zu folgen, was ein gutes Zeichen ist.

Hier erkennt man keine größeren Auffälligkeiten.

Mit der PPV kann man die Güte des Modells prüfen.

```
pp_check(m10.12)
```



12 Fallbeispiele

Unser Modell – bzw. die Stichproben unserer Posteriori-Verteilung, y_{rep} – verfehlt den Mittelwert von y leider recht häufig.

Visualisieren wir noch die bereinigten Regressionskoeffizienten, s. Abbildung 12.21.




Abbildung 12.21: Bereinigte Regressionskoeffizienten

Abbildung 12.21 zeigt in der oberen Reihe die Regression eines Prädiktors auf den anderen Prädiktor. Untere Reihe: Regression der Residuen der oberen Reihe auf die AV, kid_score_z . Unten links (C): Die Residuen von mom_iq_c sind kaum mit der AV assoziiert. Das heißt, nutzt man den Teil von mom_age_z , der nicht mit mom_iq_z zusammenhängt, um kid_score vorherzusagen, findet man keinen (*kaum*) Zusammenhang. Unten rechts (D): Die Residuen von mom_age_c sind *stark* mit der AV assoziiert. Das heißt, nutzt man den Teil von mom_iq_z , der nicht mit mom_age_z zusammenhängt, um kid_score vorherzusagen, findet man einen starken Zusammenhang.

Eine multiple Regression liefert die gleichen Regressionskoeffizienten wie die Modelle aus Teildiagrammen (C) und (D).

Was ist eigentlich der numerische Unterschied zwischen Bayesianischen und Frequentistischen Modellen? Schauen wir es uns an.

Wie man sieht liefern `stan_glm()` und `lm` ähnliche Ergebnisse (bei schwach informativen Prioriwerten):

```
stan_glm(mpg ~ hp + cyl, data = mtcars, refresh = 0) |> coef()
## (Intercept)      hp      cyl
##    36.901    -0.019   -2.255

lm(mpg ~ hp + cyl, data = mtcars) |> coef()
## (Intercept)      hp      cyl
##    36.908    -0.019   -2.265
```

! Wichtig

Wenn auch die Ergebnisse eines frequentistischen und eines Bayes-Modells numerisch ähnlich sein können, so ist doch die Interpretation grundverschieden. Bayesmodelle erlauben Wahrscheinlichkeitsaussagen zu den Parametern, Frequentistische Modelle nicht.

12.14 Fazit

Übungsaufgabe 12.4 (Ausstieg: Was haben Sie heute (nicht) verstanden?). Schreiben Sie zum Abschluss zwei Zettel:

- Zettel 1: Schreiben Sie eine Sache, die Sie gut verstanden haben.
- Zettel 2: Schreiben Sie eine Sache, die Sie NICHT gut verstanden haben.

Legen Sie beim Verlassen des Raumes Ihre Zettel vorne bei der Lehrkraft ab (anonym). □

Eine Kurzdarstellung des Bayes-Inferenz findet sich in diesem Post und in diesem.

Ausblick: Binäre AV. Man kann eine Regression auch verwenden, wenn die AV *binär* ist.

Forschungsfrage: Kann man anhand des Spritverbrauchs vorhersagen, ob ein Auto eine Automatik- bzw. ein manuelle Schaltung hat? Anders gesagt: Hängen Spritverbrauch und Getriebeart? (Datensatz mtcars)

Dazu nutzen wir den Datensatz mtcars, wobei wir die Variablen z-standardisieren.

12 Fallbeispiele


```
data(mtcars)
mtcars2 <-
  mtcars |>
  standardize(append = TRUE)
```

Dann berechnen wir mit Hilfe von Stan ein Regressionsmodell: m14: $am \sim mpg_z$:

```
m14 <-
  stan_glm(am ~ mpg_z,
    data = mtcars2,
    refresh = 0)
coef(m14)
## (Intercept)    mpg_z
##      0.41      0.30
```

Ab $mpg_z = 0.32$ sagt das Modell $am=1$ (manuell) vorher. Ganz ok.

```
mtcars2 |>
  ggplot(aes(x = mpg_z, y = am)) +
  geom_hline(yintercept = 0.5, color = "white", size = 2) +
  geom_point() +
  geom_abline(intercept = coef(m14)[1],
    slope = coef(m14)[2],
    color = beta1col)
```

```
neg_am <- predict(m14, newdata = tibble(mpg_z = -1.3))
```

Für kleine Werte von `mpg_z` (< -1.3) sagt unser Modell *negative* Werte für `am` voraus. Das macht keinen Sinn: Es gibt keine negativen Werte von `am`, nur 0 und 1. Müssen wir mal bei Gelegenheit besser machen.

! Wichtig

Kontinuierliches Lernen ist der Schlüssel zum Erfolg.

Weitere Hinweise zu den Themen dieses Kapitels finden sich bei Gelman et al. (2021), Kap. 10, insbesondere 10.3.

Gelman et al. (2021) bieten einen Zugang mittleren Anspruchs zur Regressionsmodellierung. Das Buch ist von einem weltweit führenden Statistiker geschrieben und vermittelt tiefe Einblicke bei gleichzeitig überschaubarem mathematischen Aufwand.

Für das vorliegende Kapitel sind insbesondere daraus die Kapitel 6, 7, und 10 relevant.

12.15 Aufgaben

12.15.1 Papier-und-Bleistift-Aufgaben

1. anz-params
2. fofrage-regrformel2
3. modelldef-regrformel
4. finde-prior
5. Nullhyp-Beispiel
6. Griech-Buchstaben-Inferenz
7. Interaktionseffekt1
8. Regression2
9. Regression3
10. diamonds-nullhyp-mws
11. zwert-berechnen
12. stan_glm_parameterzahl
13. kausale-verben
14. zuordnung_regr_formel

12.15.2 Aufgaben, für die man einen Computer benötigt

1. Regr-Bayes-interpret
2. Regr-Bayes-interpret03
3. Regr-Bayes-interpret02
4. rope4

12.15.3 Vertiefende Aufgaben

1. Anova-skalenniveau
2. ttest-skalenniveau
3. stan_glm_prioriwerte

Teil IV

Kausalität

13 Konfundierung

13.1 Lernsteuerung

Für dieses Kapitel benötigen Sie folgende R-Pakete:

```
library(dagitty) # DAGs zeichnen  
library(tidyverse)  
library(rstanarm)  
library(easystats)
```

13.2 Datensatz

In diesem Kapitel nutzen wir den Datensatz Saratoga County¹; s. Tabelle 13.3. Hier gibt es eine Beschreibung des Datensatzes².

Sie können ihn entweder über die Webseite herunterladen:

```
SaratogaHouses_path <- paste0(  
  "https://vincentarelbundock.github.io/Rdatasets/",  
  "csv/mosaicData/SaratogaHouses.csv")  
  
d <- read.csv(SaratogaHouses_path)
```

Oder aber über das Paket mosaic importieren:

```
data("SaratogaHouses", package = "mosaicData")  
d <- SaratogaHouses # kürzerer Name, das ist leichter zu tippen
```

¹<https://vincentarelbundock.github.io/Rdatasets/csv/mosaicData/SaratogaHouses.csv>

²<https://vincentarelbundock.github.io/Rdatasets/doc/mosaicData/SaratogaHouses.html>

13 Konfundierung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- erklären, was eine Konfundierung ist
- DAGs lesen und zeichnen
- Konfundierung in einem DAG erkennen

Dieses Kapitel vermittelt die Grundlagen der Kausalinferenz mittels graphischer Modelle. Ähnliche Darstellungen wie in diesem Kapitel finden sich bei Rohrer (2018).

13.3 Einstieg

In diesem Kapitel steigen wir ein in das Themengebiet *Kausalanalyse* (oder synonym Kausalinferenz). Wir beschäftigen uns also mit der für die Wissenschaft (und den Rest des Universums) zentralen Frage, was die Ursache eines Phänomens ist. In diesem ersten Kapitel zu dem Thema geht es um einen häufigen Fall von „Scheinkorrelation“, also eines Zusammenhangs zwischen UV und AV, der aber gar kein echter kausaler ist, sondern nur Schein. Bei diesem Scheinzusammenhang handelt es sich um die Konfundierung. Im nächsten Kapitel schauen wir uns die verbleibenden Grundbausteine der Kausalinferenz an.

13.3.1 Von Störchen und Babies

Kennen Sie die Geschichte von Störchen und Babies? Ich meine nicht die aus dem Biologieunterricht in der fünften Klasse, sondern in einem statistischen Zusammenhang. Was war da noch mal die Moral von der Geschichte?³ □

13.3.2 Erlaubt eine Regressionsanalyse Kausalschlüsse?

Findet man in einer Regressionsanalyse einen „Effekt“, also ein Regressionsgewicht ungleich Null, heißt das dann, dass die UV die Ursache der AV ist?⁴ Erklären Sie diesen Sachverhalt genauer. □

³Nur weil die Variablen `Anzahl_Stoerche` und `Anzahl_Babies` korreliert sind, heißt das nicht, dass das eine die Ursache des anderen sein muss.

⁴Nein

Tabelle 13.1: Daten zur Studie A

Gruppe	Mit Medikament	Ohne Medikament
Männer	81/87 überlebt (93%)	234/270 überlebt (87%)
Frauen	192/263 überlebt (73%)	55/80 überlebt (69%)
Gesamt	273/350 überlebt (78%)	289/350 überlebt (83%)

13.4 Statistik, was soll ich tun?

13.4.1 Studie A: Östrogen

13.4.1.1 Medikament einnehmen?

Mit Blick auf Tabelle 13.1: Was raten Sie dem Arzt? Medikament einnehmen, ja oder nein?

Die Daten stammen aus einer (fiktiven) klinischen Studie, $n = 700$, hoher Qualität (Beobachtungsstudie). Bei Männern scheint das Medikament zu helfen; bei Frauen auch. Aber *insgesamt* (Summe von Frauen und Männern) *nicht*?! Was sollen wir den Arzt raten? Soll er das Medikament verschreiben? Vielleicht nur dann, wenn er das Geschlecht kennt (Pearl et al., 2016)?

13.4.1.2 Kausalmodell zur Studie A

In Wahrheit sieht die kausale Struktur so aus: Das Geschlecht (Östrogen) hat einen Einfluss (+) auf Einnahme des Medikaments und auf Heilung (-). Das Medikament hat einen Einfluss (+) auf Heilung. Betrachtet man die Gesamt-Daten zur Heilung, so ist der Effekt von Geschlecht (Östrogen) und Medikament *vermengt* (konfundiert, confounded). Die kausale Struktur, also welche Variable beeinflusst bzw. nicht, ist in Abbildung 13.1 dargestellt.

13 Konfundierung




Abbildung 13.1: Zwei direkte Effekte (gender, drug) und ein indirekter Effekt (gender über drug) auf recovery

Betrachtung der Gesamtdaten zeigt in diesem Fall einen *konfundierten* Effekt: Geschlecht konfundiert den Zusammenhang von Medikament und Heilung.

! Wichtig

Betrachtung der Teildaten (d. h. stratifiziert pro Gruppe) zeigt in diesem Fall den wahren, kausalen Effekt. Stratifizieren ist also in diesem Fall der korrekte, richtige Weg. Achtung: Das Stratifizieren ist nicht immer und nicht automatisch die richtige Lösung. Stratifizieren bedeutet, den Gesamtdatensatz in Gruppen oder „Schichten“ („Strata“).

13.4.2 Studie B: Blutdruck

13.4.2.1 Medikament einnehmen?

Mit Blick auf Tabelle 13.2: Was raten Sie dem Arzt? Medikament einnehmen, ja oder nein?

Tabelle 13.2: Daten zur Wirksamkeit eines Medikaments (Studie B)

Gruppe	Ohne Medikament	Mit Medikament
geringer Blutdruck	81/87 überlebt (93%)	234/270 überlebt (87%)

hoher Blutdruck	192/263 überlebt (73%)	55/80 überlebt (69%)
Gesamt	273/350 überlebt (78%)	289/350 überlebt (83%)

Die Daten stammen aus einer (fiktiven) klinischen Studie, $n = 700$, hoher Qualität (Beobachtungsstudie). Bei geringem Blutdruck scheint das Medikament zu schaden. Bei hohem Blutdruck scheint das Medikament auch zu schaden. Aber *insgesamt* (Summe über beide Gruppen) *nicht*, da scheint es zu nutzen?! Was sollen wir den Arzt raten? Soll er das Medikament verschreiben? Vielleicht nur dann, wenn er den Blutdruck nicht kennt (Pearl et al., 2016)?

13.4.2.2 Kausalmodell zur Studie B

Das Medikament hat einen (absenkenden) Einfluss auf den Blutdruck. Gleichzeitig hat das Medikament einen (toxischen) Effekt auf die Heilung. Verringerter Blutdruck hat einen positiven Einfluss auf die Heilung. Sucht man innerhalb der Leute mit gesenktem Blutdruck nach Effekten, findet man nur den toxischen Effekt: Gegeben diesen Blutdruck ist das Medikament schädlich aufgrund des toxischen Effekts. Der positive Effekt der Blutdruck-Senkung ist auf diese Art nicht zu sehen.

Das Kausalmodell von Studie B ist in Abbildung 13.2 dargestellt.




Abbildung 13.2: Drug hat keinen direkten, aber zwei indirekte Effekt auf recovery, einer davon ist heilsam, einer schädlich

Betrachtung der Teildaten zeigt nur den toxischen Effekt des Medikaments, nicht den nützlichen (Reduktion des Blutdrucks).

13 Konfundierung

! Wichtig

Betrachtung der Gesamtdaten zeigt in diesem Fall den wahren, kausalen Effekt. Stratifizieren wäre falsch, da dann nur der toxische Effekt, aber nicht der heilsame Effekt sichtbar wäre.

13.4.3 Studie A und B: Gleiche Daten, unterschiedliches Kausalmodell

Vergleichen Sie die DAGs Abbildung 13.1 und Abbildung 13.2, die die *Kausalmodelle* der Studien A und B darstellen: Sie sind *unterschiedlich*. Aber: Die *Daten* sind *identisch*.

Kausale Interpretation – und damit Entscheidungen für Handlungen – ist nur möglich, da das Kausalmodell bekannt ist. Die Daten alleine reichen nicht. Gut merken.

13.4.4 Sorry, Statistik: Du allein schaffst es nicht

Datenanalyse alleine reicht nicht für Kausalschlüsse. 🤖

Datenanalyse plus Kausalinferenz erlaubt Kausalschlüsse. 📚 + 📊 = 😊

! Wichtig

Für Entscheidungen („Was soll ich tun?“) braucht man kausales Wissen. Kausales Wissen basiert auf einer Theorie (Kausalmodell) plus Daten.

13.4.5 Vertiefung⁵

13.4.5.1 Studie C: Nierensteine

Nehmen wir an, es gibt zwei Behandlungsvarianten bei Nierensteinen, Behandlung A und B. Ärzte tendieren zu Behandlung A bei großen Steinen (die einen schwereren Verlauf haben); bei kleineren Steinen tendieren die Ärzte zu Behandlung B.

⁵Dieser Abschnitt ist prüfungsrelevant, birgt aber nichts Neues.

Sollte ein Patient, der nicht weiß, ob sein Nierenstein groß oder klein ist, die Wirksamkeit in der Gesamtpopulation (Gesamtdaten) oder in den stratifizierten Daten (Teildaten nach Steingröße) betrachten, um zu entscheiden, welche Behandlungsvariante er (oder sie) wählt?

Die Größe der Nierensteine hat einen Einfluss auf die Behandlungsmethode. Die Behandlung hat einen Einfluss auf die Heilung. Damit gibt es eine Mediation („Kette“) von Größe $\rightarrow$ Behandlung $\rightarrow$ Heilung. Darüber hinaus gibt es noch einen Einfluss von Größe der Nierensteine auf die Heilung.

Das Kausalmodell ist in Abbildung 13.3 dargestellt; Abbildung 13.4 visualisiert alternativ. Beide Varianten zeigen das Gleiche. Sie können sich einen aussuchen. Hier sind beide Varianten gezeigt, damit Sie wissen, dass verschiedene Darstellungsformen möglich sind.

Sollte man hier size kontrollieren, wenn man den Kausaleffekt von treatment schätzen möchte? Oder lieber nicht kontrollieren?

13.4.6 DAG links-rechts




Abbildung 13.3: DAG zur Nierenstein-Studie

13 Konfundierung

13.4.7 DAG oben-unten




Abbildung 13.4: DAG zur Nierenstein-Studie in zweiter Darstellungsform

Ja: In diesem Fall sollte man *size* kontrollieren, denn man ist am Effekt des *treatments* interessiert. Würde man nicht *size* kontrollieren, bekäme man den „vermengten“ Effekt von *size* und *treatment*, also keine (belastbare) Aussage über den Effekt der Behandlung.

13.4.7.1 Mehr Beispiele

Beispiel 13.1. Studien zeigen, dass Einkommen und Heiraten (bzw. verheiratet sein) hoch korrelieren. Daher wird sich dein Einkommen erhöhen, wenn du heiratest. □

Beispiel 13.2. Studien zeigen, dass Leute, die sich beeilen, zu spät zu ihrer Besprechung kommen. Daher lieber nicht beeilen, oder du kommst zu spät zu deiner Besprechung. □

13.4.8 Zwischenfazit

Bei *Beobachtungsstudien* ist aus den Daten alleine nicht herauszulesen, ob eine Intervention wirksam ist, ob es also einen kausalen Effekt von der Intervention (angenommen Ursache) auf eine AV (Wirkung) gibt. Damit ist auch nicht zu erkennen, welche Entscheidung zu treffen ist. Nur Kenntnis des Kausalmodells zusätzlich zu den Daten erlaubt, eine Entscheidung sinnvoll zu treffen.

Bei *experimentellen Daten* ist die Kenntnis des Kausalmodells nicht nötig (wenn das Experiment handwerklich gut gestaltet ist): Das Randomisieren der Versuchspersonen zu Gruppen und das Kontrollieren der Versuchsbedingungen sorgen dafür, dass es keine Konfundierung gibt.

13.5 Konfundierung

13.5.1 Die Geschichte von Angie und Don



Don, Immobilienmogul, Auftraggeber



Angie, Data Scientistin.



Wolfie, Post-Nerd, kommt in dieser Geschichte aber nicht vor

13.5.2 Datensatz ‚Hauspreise im Saratoga County‘

Importieren Sie den Datensatz SaratogaHouses, s. Kapitel 13.2 und Tabelle 13.3.

Tabelle 13.3: Saratoga-County-Datensatz

price	livingArea	bedrooms	waterfront
132500	906	2	No
181115	1953	3	No
109000	1944	4	No
155000	1944	3	No
86060	840	2	No

13 Konfundierung

13.5.3 Immobilienpreise in einer schicken Wohngegend vorhersagen

Don 🧑: „Finden Sie den Wert meiner Immobilie heraus! Die Immobilie muss viel wert sein!“

Angie 🧑: „Das finde ich heraus. Ich mach das wissenschaftlich.“

13.5.4 Modell 1: Preis als Funktion der Anzahl der Zimmer

Angie 🧑: „Hey Don! Mehr Zimmer, mehr Kohle!“

Modell 1 (m1) modelliert den Hauspreis als Funktion der Zimmerzahl, s. Abbildung 13.5.




Abbildung 13.5: Modell m1

Angie 🧑: „Jedes Zimmer mehr ist knapp 50 Tausend wert. Dein Haus hat einen Wert von etwa 150 Tausend Dollar, Don.“

Don 🧑: Zu wenig! 🤔

Berechnen wir das Modell m1; der Punktschätzer des Parameters bedroom steht in Tabelle 13.4.

```
m1 <- stan_glm(price ~ bedrooms,
  refresh = 0,
  seed = 42,
  data = d)

point_estimate(m1)
```

Tabelle 13.4: Parameter für m1

Parameter	Median	Mean	MAP	Effects	Component
(Intercept)	59763	59853	58701	fixed	conditional
bedrooms	48258	48238	47954	fixed	conditional

`point_estimates(modell)` gibt die Punktschätzer der Parameter eines Modells zurück, aber nicht die Schätzbereiche. Möchten Sie beides, können Sie die Funktion `parameters(modell)` nutzen.⁶

Mit `estimate_predictions` können wir Vorhersagen berechnen (bzw. schätzen; die Vorhersagen sind ja mit Ungewissheit verbunden, daher ist „schätzen“ vielleicht das treffendere Wort). Tabelle 13.5 zeigt den laut `m1` vorhergesagten Hauspreis für ein Haus mit 2 Zimmern.

```
dons_house <- tibble(bedrooms = 2)
estimate_prediction(m1, data = dons_house)
```

Tabelle 13.5: Vorhersage des Hauspreises für ein Haus mit 2 Zimmern

Tabelle 13.5: Model-based Predictions			
bedrooms	Predicted	SE	95% CI
2	1.55e+05	91197.19	(-17709.68, 3.33e+05)

Variable predicted: price

⁶In aller Regel macht es mehr Sinn, die Schätzbereiche der Punktschätzer auch zu betrachten. Nur die Punktschätzer zu betrachten vernachlässigt wesentliche Information.

13.5.5 Don hat eine Idee

Don 🧑: „Ich bau eine Mauer! Genial! An die Arbeit, Angie!“

Don hofft, durch Verdopplung der Zimmerzahl den doppelten Verkaufspreis zu erzielen. Ob das klappt?

Angie 🧑: „Das ist keine gute Idee, Don.“

Berechnen wir die Vorhersagen für Dons neues Haus (mit den durch Mauern halbierten Zimmern), s. Tabelle 13.6.⁷

```
dons_new_house <- tibble.bedrooms = 4)
estimate_prediction(m1, dons_new_house)
predict(m1, newdata = dons_new_house)
```

Tabelle 13.6: Vorhergesagter Hauspreis laut m1 für ein Haus mit 4 Zimmern

Tabelle 13.6: Model-based Predictions			
bedrooms	Predicted	SE	95% CI
4	2.53e+05	92475.66	(74347.84, 4.36e+05)

Variable predicted: price

Mit 4 statt 2 Schlafzimmer steigt der Wert auf 250k, laut m1, s. Abbildung 13.5.

Don 🧑: „Volltreffer! Jetzt verdiene ich 100 Tausend mehr! Ich bin der Größte!“

i Hinweis

Zur Erinnerung: „4e+05“ ist die Kurzform der wissenschaftlichen Schreibweise und bedeutet: $4 \cdot 100000 = 4 \cdot 10^5 = 400000$

⁷Anstelle von estimate_relation() kann man auch (einfacher vielleicht) predict() verwenden: predict(m1, newdata = dons_new_house). Allerdings gibt predict() nur den vorhergesagten Wert aus. estimate_prediction() gibt noch zusätzlich das Vorhersageintervall aus, berücksichtigt also die (doppelte) Ungewissheit der Vorhersage. Mit anderen Worten: estimate_prediction gibt die PPV aus.

13.5.6 R-Funktionen, um Beobachtungen vorhersagen

`predict(m1, dons_new_house)` oder `point_estimate(m1, dons_new_house)` sagt einen *einzelnen Wert* vorher (den sog. Punktschätzer der Vorhersage).⁸ Ein Intervall wird *nicht* ausgegeben.

`estimate_prediction(m1, dons_new_house)` erstellt *Vorhersageintervalle*, berücksichtigt also *zwei Quellen* von Ungewissheit:

- Ungewissheiten in den Parametern (Modellkoeffizienten, $\beta_0, \beta_1, \dots$)
- Ungewissheit im „Strukturmodell“: Wenn also z. B. in unserem Modell ein wichtiger Prädiktor fehlt, so können die Vorhersagen nicht präzise sein. Fehler im Strukturmodell schlagen sich in breiten Schätzintervallen (bedingt durch ein großes σ) nieder.

`estimate_expectation(m1, dons_new_house)` erstellt *Konfidenzintervalle* und berücksichtigt also nur *eine Quelle* von Ungewissheit:

- Ungewissheiten in den Parametern (Modellkoeffizienten)

Die Schätzbereiche sind in dem Fall deutlich kleiner, s. Tabelle 13.7.

```
estimate_expectation(m1, dons_new_house)
```

Tabelle 13.7: Ungewissheit für die Parameter, also die Regressionsgerade, nicht die Beobachtungen

Tabelle 13.7: Model-based Predictions			
bedrooms	Predicted	SE	95% CI
4	2.53e+05	3168.87	(2.47e+05, 2.59e+05)

Variable predicted: price

⁸Bei `predict` ist dieser Wert der Median der Post-Verteilung; bei `point_estimate` kann man sich aus-
suchen, ob der Median, der Mittelwert oder der wahrscheinlichste Wert der Post-Verteilung als
Schätzwert verwendet wird.

13.5.7 Modell 2

Berechnen wir das Modell m2: price ~ bedrooms + livingArea. Tabelle 13.8 gibt den Punktschätzer für die Koeffizienten wider.

```
m2 <- stan_glm(price ~ bedrooms + livingArea,
  data = d,
  seed = 42,
  refresh = 0)

point_estimate(m2, centrality = "median")
```

Tabelle 13.8: Parameter (Punktschätzer, keine Schätzung der Ungewissheit) von m2

Tabelle 13.8: Point Estimate

Parameter	Median
(Intercept)	36533.15
bedrooms	-14138.79
livingArea	125.35

Was sind die Vorhersagen des Modells? Tabelle 13.9 gibt Aufschluss für den laut m2 vorhersagten Kaufpreis eines Hauses mit 4 Zimmern und 1200 Quadratfuß Wohnfläche; Tabelle 13.10 gibt die Schätzung (laut m2) für den Preis eines Hauses mit 2 Zimmern (und der gleichen Wohnfläche). Die Vorhersage erhält man mit dem Befehl predict():

```
predict(m2, newdata = data.frame(bedrooms = 4, livingArea = 1200))
##      1
## 130464
```

Tabelle 13.9: Vorhersage von m2 für ein Haus mit 4 Zimmern und 1200 Einheiten Wohnfläche

bedrooms	livingArea	Predicted	SE	CI_low	CI_high
4	1200	133523	69471	-4335	270053

Tabelle 13.10: Vorhersage von m2 für ein Haus mit 2 Zimmern und 1200 Einheiten Wohnfläche

bedrooms	livingArea	Predicted	SE	CI_low	CI_high
2	1200	160902	68298	31823	3e+05

Andere, aber ähnliche Frage: Wie viel kostet ein Haus mit sagen wir 4 Zimmern *gemittelt* über die verschiedenen Größen von livingArea? Stellen Sie sich alle Häuser mit 4 Zimmern vor (also mit verschiedenen Wohnflächen). Wir möchten nur wissen, was so ein Haus „im Mittel“ kostet. Wir möchten also die Mittelwerte pro bedroom schätzen, gemittelt für jeden Wert von bedroom über livingArea. Die Ergebnisse stehen in Tabelle 13.11 und sind in Abbildung 13.6 visualisiert.

```
estimate_means(m2, by = "bedrooms", length = 7)
```

Tabelle 13.11: Vorhersagen des Preises von Häusern mit verschiedener Zimmerzahl gemittelt über die verschiedenen Werte der Wohnfläche; basierend auf m2.

bed-rooms	RO-PE_CI	Median	CI_low	CI_high	pd	RO-PE_low	ROPE_high	ROPE_Percentage
1	0.95	242467	231206	254351	1	-0.1	0.1	0
2	0.95	228301	221698	235313	1	-0.1	0.1	0
3	0.95	214230	210920	217555	1	-0.1	0.1	0
4	0.95	200113	194511	205656	1	-0.1	0.1	0
5	0.95	185978	175623	196017	1	-0.1	0.1	0
6	0.95	171845	156449	186696	1	-0.1	0.1	0
7	0.95	157605	136951	177554	1	-0.1	0.1	0

13 Konfundierung




Abbildung 13.6: Hauspreis als Funktion der Zimmerzahl, laut m2


Angie 🧑: „Die Zimmer zu halbieren, hat den Wert des Hauses *verringert*, Don!“

Don 🧑: „Verringert!? Weniger Geld?! Oh nein!“

13.5.8 Die Zimmerzahl ist negativ mit dem Preis korreliert

... wenn man die Wohnfläche (Quadratmeter) kontrolliert, s. Abbildung 13.7.

Angie 🧑: „Ne-Ga-Tiv!“



Facetten zeigen Quartile der Variable 'Wohnfläche'

Abbildung 13.7: Hauspreis stratifizieren

Basierend auf diesem Quellcode⁹

Hinweis

Aussagen, gleich ob sie statistischer, wissenschaftlicher oder sonstiger Couleur sind, können immer nur dann richtig sein, wenn ihre Annahmen richtig sind. Behauptet etwa ein Modell, dass der Wert einer Immobilie steigt, wenn man mehr Zimmer hat, so ist das kein Naturgesetz, sondern eine Aussage, die nur richtig sein kann, wenn das zugrundeliegende Modell richtig ist. □

13.5.9 Kontrollieren von Variablen

 Durch das Aufnehmen von Prädiktoren in die multiple Regression werden die Prädiktoren *kontrolliert* (adjustiert, konditioniert):

Die Koeffizienten einer multiplen Regression zeigen den Zusammenhang β des einen Prädiktors mit y , wenn man den (oder die) anderen Prädiktoren statistisch *konstant* hält.

Man nennt die Koeffizienten einer multiplen Regression daher auch *parziale Regressionskoeffizienten*. Manchmal spricht man, eher umgangssprachlich, auch vom „Netto-Effekt“ eines Prädiktors, oder davon, dass ein Prädiktor „bereinigt“ wurde vom (linearen) Einfluss der anderen Prädiktoren auf y .

Damit kann man die Regressionskoeffizienten so interpretieren, dass Sie den Effekt des Prädiktors x_1 auf y anzeigen *unabhängig* vom Effekt der anderen Prädiktoren, $x_2, x_3, \dots$ auf y .

Man kann sich dieses Konstanthalten vorstellen als eine Aufteilung in Gruppen: Der Effekt eines Prädiktors x_1 wird für jede Ausprägung (Gruppe) des Prädiktors x_2 berechnet.

Wichtig

Das Hinzufügen von Prädiktoren kann die Gewichte der übrigen Prädiktoren ändern. □

⁹<https://github.com/sebastiansauer/QM2-Folien/blob/main/Themen/children/Hauspreis-stratifizieren.Rmd>

13 Konfundierung

Don 🙄: „Aber welche und wie viele Prädiktoren soll ich denn jetzt in mein Modell aufnehmen?! Und welches Modell ist jetzt richtig?!“

Angie 🙄: „Leider kann die Statistik keine Antwort darauf geben.“

Don 🙄: „Wozu ist sie dann gut?!“

! Wichtig

In Beobachtungsstudien hilft nur ein (korrektes) Kausalmodell. Ohne Kausalmodell ist es *nutzlos*, die Regressionskoeffizienten (oder eine andere Statistik) zur Erklärung der Ursachen heranzuziehen: Die Regressionskoeffizienten können sich wild ändern, wenn man Prädiktoren hinzufügt oder weglässt. Es können sich sogar die *Vorzeichen der Regressionsgewichte ändern*; in dem Fall spricht man von einem Simpson-Paradox.

13.5.10 Welches Modell richtig ist, kann die Statistik nicht sagen

Often people want statistical modeling to do things that statistical modeling cannot do. For example, we'd like to know whether an effect is „real“ or rather spurious. Unfortunately, modeling merely quantifies uncertainty in the precise way that the model understands the problem. Usually answers to large world questions about truth and causation depend upon information not included in the model. For example, any observed correlation between an outcome and predictor could be eliminated or reversed once another predictor is added to the model. But if we cannot think of the right variable, we might never notice. Therefore all statistical models are vulnerable to and demand critique, regardless of the precision of their estimates and apparent accuracy of their predictions. Rounds of model criticism and revision embody the real tests of scientific hypotheses. A true hypothesis will pass and fail many statistical „tests“ on its way to acceptance.

– McElreath (2020), S. 139

13.5.11 Kausalmodell für Konfundierung, km1

Das Kausalmodell km1 ist in Abbildung 13.8 dargestellt; vgl. Abbildung 13.7.




Abbildung 13.8: Kausalmodell km1 – Eine Erklärung (von mehreren) für m1 bzw. die Daten, die m1 zugrunde liegen

Wenn dieses Kausalmodell stimmt, findet man eine *Scheinkorrelation* zwischen price und bedrooms. Eine Scheinkorrelation ist ein Zusammenhang, der *nicht* auf einem kausalen Einfluss beruht. d_connected heißt, dass die betreffenden Variablen „verbunden“ sind durch einen gerichteten (d wie directed) Pfad, durch den die Assoziation (Korrelation) wie durch einen Fluss fließt 🌊. d_separated heißt, dass sie *nicht* d_connected sind.

13.5.12 m2 kontrolliert die Konfundierungsvariable livingArea

Beispiel 13.3. In Abbildung 13.8 ist living area eine Konfundierungsvariable für den Zusammenhang von bedrooms und price. □

Definition 13.1 (Konfundierungsvariable). Eine Konfundierungsvariable (Konfundierer) ist eine Variable, die den Zusammenhang zwischen UV und AV verzerrt, wenn sie nicht kontrolliert wird (VanderWeele & Shpitser, 2013). □

Wenn das Kausalmodell stimmt, dann zeigt m2 den kausalen Effekt von livingArea.

Don 🧑: Was tun wir jetzt bloß?! Oh jeh!

Angie 🧑: Wir müssen die Konfundierungsvariable kontrollieren.

Abbildung 13.9 zeigt, dass bedrooms und price *unkorreliert* werden (d_separated), wenn man living area kontrolliert.

13 Konfundierung




Abbildung 13.9: Durch Kontrolle von living area wird die Assoziation von price und bedrooms aufgehoben.


Durch das Kontrollieren („adjustieren“), sind bedrooms und price nicht mehr korreliert, nicht mehr d_connected, sondern jetzt d_separated.

Definition 13.2 (Blockieren). Das Kontrollieren eines Konfundierers (wie living_area) „blockt“ den betreffenden Pfad, führt also dazu, dass über diesen Pfad keine Assoziation (z. B. Korrelation) zwischen UV (bedrooms) und AV (price) mehr vorhanden ist. UV und AV sind dann d_separated („getrennt“). □

13.5.13 Konfundierer kontrollieren

Gehen wir in diesem Abschnitt davon aus, dass km1 richtig ist.

Ohne Kontrollieren der Konfundierungsvariablen: Regressionsmodell $y \sim x$, Abbildung 13.10, links: Es wird (fälschlich) eine Korrelation zwischen x und y angezeigt: Scheinkorrelation. Mit Kontrollieren der Konfundierungsvariablen: Regressionsmodell $y \sim x + \text{group}$, Abbildung 13.10, rechts.



(a) Ohne Kontrolle der Konfundierungsvariablen: Konfundierung tritt auf.

(b) Mit Kontrolle der Konfundierungsvariablen: Konfundierung tritt nicht auf.

Abbildung 13.10: Konfundierung von y und x!

Abbildung 13.10, rechts, zeigt korrekt, dass es keine Korrelation zwischen x und y gibt, wenn group kontrolliert wird. Außerdem sieht man im rechten Teildiagramm, dass es ein Kontrollieren der Variable group durch Aufnahme als Prädiktor in die Regressionsgleichung einem Stratifizieren entspricht (getrennte Berechnung der Regressionsgerade pro Gruppe).

! Wichtig

Kontrollieren Sie Konfundierer. ☐

13.5.14 m1 und m2 passen nicht zu den Daten, wenn km1 stimmt

Laut km1 dürfte es keine Assoziation (Korrelation) zwischen bedrooms und price geben, wenn man livingArea kontrolliert, wie in Abbildung 13.8 dargestellt. Es gibt aber noch eine Assoziation zwischen bedrooms und price, wenn man livingArea kontrolliert. Daher sind sowohl m1 als auch m2 nicht mit dem Kausalmodell km1 vereinbar.

13.5.15 Kausalmodell 2, km2

Unser Modell m2 sagt uns, dass beide Prädiktoren jeweils einen eigenen Beitrag zur Erklärung der AV haben.

Daher könnte das folgende Kausalmodell, km2, besser passen.

In diesem Modell gibt es eine Wirkkette: $a \rightarrow b \rightarrow p$.

13 Konfundierung

Insgesamt gibt es zwei Kausaleinflüsse von a auf p: - $a \rightarrow p$ - $a \rightarrow b \rightarrow p$

Man nennt die mittlere Variable einer Wirkkette auch einen *Mediator* und den Pfad von der UV (a) über den Mediator (b) zur AV (p) auch *Mediation*, s. Abbildung 13.11.




Abbildung 13.11: Der Effekt von livingArea wird über den Mediator bedrooms auf price vermittelt.

13.5.16 Dons Kausalmodell, km3

So sieht Dons Kausalmodell aus, s. Abbildung 13.12.




Abbildung 13.12: Dons Kausalmodell

Don 🧑: „Ich glaube aber an mein Kausalmodell. Mein Kausalmodell ist das größte! Alle anderen Kausalmodelle sind ein Disaster!“

Angie 🙄: “Don, nach deinem Kausalmodell müssten bedrooms und livingArea unkorreliert sein. Sind sie aber nicht. Rechne doch selber die Korrelation aus, Don:

Don 🙄: „Äh, wie ging das nochmal?“

So könntest du das rechnen, Don: `correlation(d, select = c("bedrooms", "livingArea"))`. Oder z. B. so:

```
dons_r <- d |>
  summarise(cor(bedrooms, livingArea))
```

Die Korrelation liegt also bei 0.66

Angie 🙄: „Bitte, gerne hab ich dir geholfen, Don.“

13.5.17 Unabhängigkeiten laut der Kausalmodelle

km1: b: bedrooms, p: price, a area (living area), s. Abbildung 13.8.

Das Kausalmodell km1 behauptet: $b \perp\!\!\!\perp p \mid a$: bedrooms sind unabhängig von price, wenn man livingArea kontrolliert.

Kontrollieren einer Variable Z erreicht man auf einfache Art, indem man sie zusätzlich zur vermuteten Ursache X in die Regressionsgleichung mit aufnimmt, also $y \sim x + z$.

Aber diese behauptete Unabhängigkeit findet sich *nicht* in den Daten wieder, s. Tabelle 13.8. Also: 🌩️ Passt nicht zu den Daten!

km2 b: bedrooms, p: price, a area (living area), s. Abbildung 13.11.

Das Kausalmodell km2 postuliert *keine* Unabhängigkeiten: Laut km2 sind alle Variablen des Modells miteinander assoziiert (korreliert).

i Hinweis

Ein Modell, in dem alle Variablen miteinander korreliert sind, nennt man auch *saturiert* oder *saturiertes Modell*. So ein Modell ist empirisch *schwach*. Denn: Behauptet ein Modell, dass die Korrelation zwischen zwei Variablen irgendeinen Wert zwischen -1 und +1 beträgt (nur nicht exakt Null), so ist das eine sehr schwache Aussage (und kaum zu falsifizieren). So ein Modell ist wissenschaftlich wenig wert. Das ist so ähnlich wie ein Modell, das voraussagt, dass

13 Konfundierung

es morgen irgendeine Temperatur hat zwischen -30 und +30 Grad (nur nicht exakt Null). Trifft diese Temperaturvorhersage ein, so werden wir nicht gerade beeindruckt sein.

Fazit: km2 passt zu den Daten, aber wir sind nicht gerade beeindruckt vom Modell.

km3: b: bedrooms, p: price, a area (living area), s. Abbildung 13.12.

$b \perp\!\!\!\perp a$: bedrooms sind unabhängig von livingArea (a)

 km3 passt nicht zu den Daten/zum Modell!

13.6 DAGs: Directed Acyclic Graphs

Was sind DAGs? Wir haben in diesem Kapitel schon viele Beispiele gesehen, z. B. Abbildung 13.12.

Definition 13.3 (DAG). DAGs sind eine bestimmte Art von Graphen zur Analyse von Kausalstrukturen. Ein *Graph* besteht aus Knoten (Variablen) und Kanten (Linien), die die Knoten verbinden. DAGs sind *gerichtet*; die Pfeile zeigen immer in eine Richtung (und zwar von Ursache zu Wirkung). DAGs sind *azyklisch*; die Wirkung eines Knoten darf nicht wieder auf ihn zurückführen. $\square$

Definition 13.4 (Pfad). Ein *Pfad* ist ein Weg durch den DAG, von Knoten zu Knoten über die Kanten, unabhängig von der Pfeilrichtung. $\square$

Der DAG von km1 ist in Abbildung 13.8 zu sehen.

13.6.1 Leider passen potenziell viele DAGs zu einer Datenlage

Auf Basis der in Dons Modell dargestellten (Un-)Abhängigkeiten der Variablen sind noch weitere Kausalmodelle möglich.

In Abbildung 13.13 sind diese weiteren, möglichen Kausalmodelle für Dons Modell dargestellt. Dabei sind folgende Abkürzungen verwendet: b: bedrooms, p: price, a area (living area).

Ja, der Job der Wissenschaft ist kein Zuckerschlecken. Aber wenn es einfach wäre, die Kausalstruktur der Phänomene zu entdecken, wären sie längst erkannt, und alle Probleme der Menschheit gelöst.




Abbildung 13.13: Kausalmodelle, die potenziell geeignet sind für Dons Fragestellung

Alle diese DAGs in Abbildung 13.13 haben die *gleichen* Implikationen hinsichtlich der (Un-)Abhängigkeiten zwischen den Variablen. Wir können also leider empirisch nicht bestimmen, welcher der DAGs der richtige ist. Um den richtigen DAG zu identifizieren, bräuchten wir z. B. einen reichhaltigeren DAG, also mit mehr Variablen.

13.6.2 Was ist eigentlich eine Ursache?

Etwas verursachen kann man auch (hochtrabend) als „Kausation“ bezeichnen.

i Hinweis

Weiß man, was die Wirkung W einer Handlung H (Intervention) ist, so hat man H als Ursache von W erkannt (McElreath, 2020). $\square$

Definition 13.5 (Kausale Abhängigkeit). Ist X die Ursache von Y , so hängt Y von X ab: Y ist (kausal) *abhängig* von X . $\square$

Viele Menschen denken – fälschlich – dass Korrelation Kausation bedeuten müsse. Schauen Sie sich dazu einmal das comic 552 von xkcd an.¹⁰

¹⁰<https://xkcd.com/552/> und die Erklärung dazu: https://www.explainxkcd.com/wiki/index.php/552:_Correlation

13 Konfundierung

Beispiel 13.4 (Der Schoki-Dag). Der „Schoki-DAG“ in Abbildung 13.14 zeigt den DAG für das Schokoladen-Nobelpreis-Modell. □




Abbildung 13.14: Macht Schokolade Nobelpreise?

13.7 Fazit

13.7.1 Zusammenfassung

Sind zwei Variablen korreliert (abhängig, assoziiert), so kann es dafür zwei Gründe geben:

1. Kausaler („echter“) Zusammenhang
2. Nichtkausaler Zusammenhang („Scheinkorrelation“)

Man ist daran interessiert, echten (also kausalen) Zusammenhang aufzudecken¹¹ und Scheinkorrelation auszuschließen.

Eine von zwei möglichen Ursachen einer Scheinkorrelation ist Konfundierung.¹²

Konfundierung kann man aufdecken, indem man die angenommene Konfundierungsvariable kontrolliert (adjustiert), z. B. indem man sie als Prädiktor in eine Regression aufnimmt.

¹¹zu „identifizieren“

¹²Die andere Ursache ist die Kollisionsverzerrung, s. Kapitel 13.

Ist die Annahme einer Konfundierung korrekt, so löst sich der Scheinzusammenhang nach dem Adjustieren auf.

Löst sich der Scheinzusammenhang nicht auf, sondern drehen sich die Vorzeichen der Zusammenhänge nach Adjustieren um, so spricht man von einem *Simpson-Paradox*.

Die *Daten alleine* können *nie* sagen, welches Kausalmodell der Fall ist in einer Beobachtungsstudie. Fachwissen (inhaltliches wissenschaftliches Wissen) ist nötig, um DAGs auszuschließen.

13.7.2 Ausstieg

Beispiel 13.5 (Schoki macht Nobelpreis!?). Eine Studie fand eine starke Korrelation, $r = 0.79$ zwischen der Höhe des Schokoladenkonsums eines Landes und der Anzahl der Nobelpreise eines Landes (Messerli, 2012), s. Abbildung 13.15.




Abbildung 13.15: Je mehr Schoki, desto mehr Nobelpreise

! Wichtig

Korrelation ungleich Kausation! Korrelation *kann* bedeuten, dass eine Kausation vorliegt, aber es muss auch nicht sein, dass Kausation vorliegt. Liegt Korrelation ohne Kausation vor, so spricht man von einer *Scheinkorrelation*. Um Scheinkorrelation von echter Assoziation (auf Basis von Kausation) abzugrenzen

13 Konfundierung

zen, muss man die Kausalmodelle überprüfen, so wie wir das hier tun.

13.7.3 Vertiefung

Es gibt viel Literatur zu dem Thema Kausalinferenz. Ein Artikel, der einen vertieften Einblick in das Thema Konfundierung liefert z. B. Tennant et al. (2020) oder Suttorp et al. (2015). Allerdings sollte man neben Konfundierung noch die drei anderen „Atome“ der Kausalinferenz – Kollision, Mediation (und Nachfahre) – kennen, um gängige Fragen der Kausalinferenz bearbeiten zu können.

13.8 Aufgaben

- Sammlung „kausal“

13.8.1 Papier-und-Bleistift-Aufgaben

1. confounder-example
2. adjustieren1a

13.8.2 Computer-Aufgaben

1. saratoga-cor1

14 Die Atome der Kausalität

14.1 Lernsteuerung

Für dieses Kapitel benötigen Sie folgende R-Pakete:

```
library(tidyverse)
library(rstanarm)
library(easystats)
```

Wir nutzen wieder den Datensatz Saratoga County¹; s. Tabelle 13.3. Hier gibt es eine Beschreibung des Datensatzes².

Sie können ihn entweder über die Webseite herunterladen:

```
SaratogaHouses_path <- paste0(
  "https://vincentarelbundock.github.io/Rdatasets/",
  "csv/mosaicData/SaratogaHouses.csv")

d <- read.csv(SaratogaHouses_path)
```

Oder aber über das Paket mosaic importieren:

```
data("SaratogaHouses", package = "mosaicData")
d <- SaratogaHouses # kürzerer Name, das ist leichter zu tippen
```

Alternativ können Sie ihn hier herunterladen:

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

¹<https://vincentarelbundock.github.io/Rdatasets/csv/mosaicData/SaratogaHouses.csv>

²<https://vincentarelbundock.github.io/Rdatasets/doc/mosaicData/SaratogaHouses.html>

14 Die Atome der Kausalität

- erklären, wann eine Kausalaussage gegeben eines DAGs berechtigt ist
- erklären, warum ein statistisches Modell ohne Kausalmodell zumeist keine Kausalaussagen treffen kann
- die “Atome” der Kausalität eines DAGs benennen
- “kausale Hintertüren” schließen

Dieses Kapitel vermittelt die Grundlagen der Kausalinferenz mittels graphischer Modelle. Ähnliche Darstellungen wie in diesem Kapitel finden sich bei Rohrer (2018).

14.2 Kollision

14.2.1 Kein Zusammenhang von Intelligenz und Schönheit (?)

Gott ist gerecht (?)³ Zumindest findet sich in folgenden Daten kein Zusammenhang von Intelligenz (talent) und Schönheit (looks), wie Abbildung 14.1 illustriert. Für geringe Intelligenzwerte gibt es ein breites Spektrum von Schönheitswerten und für hohe Intelligenzwerte sieht es genauso aus.




Abbildung 14.1: Kein Zusammenhang von Schlauheit und Schönheit in den Daten

14.2.2 Aber Ihre Dates sind entweder schlau oder schön

Seltsamerweise beobachten Sie, dass die Menschen, die Sie daten (Ihre Dates), entweder schön sind oder schlau – aber selten beides gleichzeitig (schade), s. Abbil-

³<https://twitter.com/TheTweetOfGod/status/1462594155176026123>

dung 14.2.




Abbildung 14.2: Ihre Datingpartner sind komischerweise entweder schlau oder schön (aber nicht beides), zumindest in der Tendenz.

Wie kann das sein?

14.2.3 DAG zur Rettung

Der DAG in Abbildung 14.3 bietet eine rettende Erklärung.




Abbildung 14.3: Date als gemeinsame Wirkung von Schönheit und Intelligenz. Stratifiziert man die gemeinsame Wirkung (dates), so kommt es zu einer Scheinkorrelation zwischen Schönheit und Intelligenz.

Eine ähnliche Visualisierung des gleichen Sachverhalts zeigt Abbildung 14.4.




Abbildung 14.4: Durch Kontrolle der gemeinsamen Wirkung entsteht eine Scheinkorrelation zwischen den Ursachen

14.2.4 Was ist eine Kollision?

Definition 14.1 (Kollision). Als *Kollision* (Kollisionsverzerrung, Auswahlverzerrung, engl. collider) bezeichnet man einen DAG, bei dem eine Wirkung zwei Ursachen hat (eine gemeinsame Wirkung zweier Ursachen) (Pearl et al., 2016, p. 40). □

Kontrolliert man die *Wirkung* m , so entsteht eine *Scheinkorrelation* zwischen den Ursachen x und y . Kontrolliert man die *Wirkung nicht*, so entsteht *keine Scheinkorrelation* zwischen den Ursachen, s. Abbildung 14.3, vgl. Rohrer (2018).

! Wichtig

Man kann also zu viele oder falsche Prädiktoren einer Regression hinzufügen, so dass die Koeffizienten nicht die kausalen Effekte zeigen, sondern durch Scheinkorrelation verzerrte Werte.

💡 Tipp

👤 Kontrollieren Sie keine Kollisionsvariablen. ☐

14.2.5 Einfaches Beispiel zur Kollision

In der Zeitung *Glitzer* werden nur folgende Menschen gezeigt: a) schöne Menschen und b) reiche Menschen.

Gehen wir davon aus, dass Schönheit und Reichtum unabhängig voneinander sind.

Übungsaufgabe 14.1. Wenn ich Ihnen sage, dass Don nicht schön ist, aber in der *Glitzer* häufig auftaucht, was lernen wir dann über seine finanzielle Situation?⁴ ☐

„Ich bin schön, unglaublich schön, und groß, großartig, tolle Gene!!!“ 🧑

14.2.6 Noch ein einfaches Beispiel zur Kollision

„So langsam check ich's!“ 🧑⁵

Sei $Z = X + Y$, wobei X und Y unabhängig sind.

Wenn ich Ihnen sage, $X = 3$, lernen Sie nichts über Y , da die beiden Variablen unabhängig sind. Aber: Wenn ich Ihnen zuerst sage, $Z = 10$, und dann sage, $X = 3$, wissen Sie sofort, was Y ist ($Y = 7$).

Also: X und Y sind abhängig, gegeben Z : $X \not\perp Y \mid Z$.⁶

⁴Don muss reich sein.

⁵Super, Don!

⁶Der horizontale Balken „|“ bedeutet „gegeben, dass“. Ein Beispiel lautet $Pr(A|B)$: „Die Wahrscheinlichkeit von A, gegeben dass B der Fall ist.“

14.2.7 Durch Kontrollieren entsteht eine Verzerrung bei der Kollision

Abbildung 14.3 zeigt: Durch Kontrollieren entsteht eine Kollision, eine Scheinkorrelation zwischen den Ursachen.

Kontrollieren kann z. B. bedeuten:

- *Stratifizieren*: Aufteilen von *date* in zwei Gruppen und dann Analyse des Zusammenhangs von *talent* und *looks* in jeder Teilgruppe von *date*
- *Kontrollieren mit Regression*: Durch Aufnahme von *date* als Prädiktor in eine Regression zusätzlich zu *looks* mit *talent* als Prädiktor

Ohne Kontrolle von *date* entsteht *keine* Scheinkorrelation zwischen *Looks* und *Talent*. Der Pfad („Fluss“) von *Looks* über *date* nach *Talent* ist blockiert.

Kontrolliert man *date*, so *öffnet* sich der Pfad *Looks* -> *date* -> *talent* und die Scheinkorrelation entsteht: Der Pfad ist nicht mehr „blockiert“, die Korrelation kann „fließen“ – was sie hier nicht soll, denn es handelt sich um Scheinkorrelation.

Das Kontrollieren von *date* erfolgt zumeist durch das Bilden einer Teilgruppe (Auswahl).

14.2.8 IQ, Fleiss und Eignung fürs Studium

Sagen wir, über die *Eignung* für ein Studium würden nur (die individuellen Ausprägungen) von Intelligenz (IQ) und Fleiss entscheiden, s. den DAG in Abbildung 14.5.




Abbildung 14.5: Kollisionsstruktur im Dag zur Studiumseignung

Bei positiver eignung wird ein Studium aufgenommen (studium = 1), ansonsten nicht (studium = 0).

Quelle

eignung (fürs Studium) sei definiert als die Summe von iq und fleiss, plus etwas Glück, s. Listing 14.1.

Laut unserem Modell setzt sich Eignung zur Hälfte aus Intelligenz und zur Hälfte aus Fleiss zusammen, plus etwas Glück.

14.2.9 Schlagzeile „Fleiß macht blöd!“

Eine Studie untersucht den Zusammenhang von Intelligenz (iq) und Fleiß (f) bei Studentis (s). Ergebnis: Ein *negativer* Zusammenhang!?

Berechnen wir das „Eignungsmodell“, aber nur mit Studis (studium == 1, also ohne Nicht-Studis), s. Tabelle 14.1.

```

m_eignung <-
  stan_glm(iq ~ fleiss, data = d_eignung |> filter(studium == 1), refresh = 0)

hdi(m_eignung)
  
```

Listing 14.1 Eignung ist die Summe von Fleiss und Intelligenz, plus ein Quentchen Glück

```
set.seed(42) # Reproduzierbarkeit
N <- 1e03

d_eignung <-
tibble(
  iq = rnorm(N), # normalverteilt mit MW=0, sd=1
  fleiss = rnorm(N),
  glueck = rnorm(N, mean = 0, sd = .1),
  eignung = 1/2 * iq + 1/2 * fleiss + glueck,
  # nur wer geeignet ist, studiert (in unserem Modell):
  studium = ifelse(eignung > 0, 1, 0)
)
```

Tabelle 14.1: Zum Zusammenhang von Fleiss und Talent

Tabelle 14.1: Highest Density Interval

Parameter	95% HDI
(Intercept)	[0.70, 0.86]
fleiss	[-0.53, -0.36]

Abbildung 14.6 zeigt das Modell und die Daten.

Negativer Zusammenhang von Fleiss und IQ bei Studentis




Abbildung 14.6: Der Zusammenhang von Fleiss und IQ

IQ ist *nicht* unabhängig von Fleiß in unseren Daten, sondern abhängig. Nichtwissenschaftliche Berichte, etwa in einigen Medien, greifen gerne Befunde über Zusammenhänge auf und interpretieren die Zusammenhänge – oft vorschnell – als kausal. (Ehrlicherweise muss man zugeben, dass auch wissenschaftliche Berichte Daten über Zusammenhänge gerne kausal interpretieren, oft vorschnell.)

14.2.10 Kollisionsverzerrung nur bei Stratifizierung

Definition 14.2 (Stratifizieren). Durch Stratifizieren wird eine Stichprobe in (homogene) Untergruppen unterteilt (sog. *Strata*). □

Nur durch das Stratifizieren (Aufteilen in Subgruppen, Kontrollieren, Adjustieren) tritt die Scheinkorrelation auf, s. Abbildung 14.7.

i Hinweis

Ohne Stratifizierung tritt *keine* Scheinkorrelation auf. Mit Stratifizierung tritt Scheinkorrelation auf.

Kein Stratifizierung, keine Scheinkorrelation




Abbildung 14.7: Stratifizierung und Scheinkorrelation. A: Keine Stratifizierung und keine Scheinkorrelation. B: Stratifizierung und Scheinkorrelation

Wildes Kontrollieren einer Variablen – Aufnehmen in die Regression – kann genauso gut schaden wie nützen.

Nur Kenntnis des DAGs verrät die richtige Entscheidung: ob man eine Variable kontrollieren muss oder es nicht darf.

i Hinweis

Nimmt man eine Variable als zweiten Prädiktor auf, so „kontrolliert“ man diese Variable. Das Regressionsgewicht des ersten Prädiktors wird „bereinigt“ um den Einfluss des zweiten Prädiktors; insofern ist der zweite Prädiktor dann „kontrolliert“.

14.2.11 Einfluss von Großeltern und Eltern auf Kinder


Wir wollen hier den (kausalen) Einfluss der Eltern E und Großeltern G auf den Bildungserfolg der Kinder K untersuchen.

Wir nehmen folgende Effekte an:

- indirekter Effekt von G auf K: $G \rightarrow E \rightarrow K$

- direkter Effekt von E auf K: $E \rightarrow K$
- direkter Effekt von G auf K: $G \rightarrow K$

Wir sind v. a. interessiert an $G \rightarrow K$, dem *direkten kausalen* Effekt von Großeltern auf ihre Enkel, s. Abbildung 14.8.



Abbildungung 14.8: Der kausale Effekt von Großeltern auf Enkel. Ein verlorener Fall, zumindest was den DAG betrifft

Aber was ist, wenn wir vielleicht eine unbekannte Variable übersehen haben? (S. nächster Abschnitt).

14.2.12 Der Gespenster-DAG

Es gibt „unheilbare“ DAGs, nennen wir sie „Gespenster-DAGs“, in denen es nicht möglich ist, einen (unverzerrten) Kausaleffekt zu bestimmen, s. Abbildung 14.9. Letztlich sagt uns der DAG bzw. unsere Analyse zum DAG: „Deine Theorie ist nicht gut, zurück an den Schreibtisch und denk noch mal gut nach. Oder sammle mehr Daten.“




Abbildung 14.9: Der Gespenster-DAG: Eine Identifikation der Kausaleffekt ist nicht (vollständig) möglich.

U könnte ein ungemessener Einfluss sein, der auf E und K wirkt, etwa *Nachbarschaft*. Die Großeltern wohnen woanders (in Spanien), daher wirkt die Nachbarschaft der Eltern und Kinder nicht auf sie. E ist sowohl für G als auch für U eine Wirkung, also eine Kollisionsvariable auf diesem Pfad. Wenn wir E kontrollieren, wird es den Pfad $G \rightarrow K$ verzerren, auch wenn wir niemals U messen.

Die Sache ist in diesem Fall chancenlos. Wir müssen diesen DAG verloren geben, McElreath (2020), S. 180; ein Gespenster-DAG. 🙈

14.3 Die Hintertür schließen

Definition 14.3 (Hintertür). Eine „Hintertür“ ist ein nicht-kausaler Pfad zwischen einer UV und einer AV. Ein Hintertürpfad entsteht, wenn es eine alternative Route über eine oder mehrere Variable gibt, die UV mit der AV verbindet. Dieser Pfad verzerrt die Schätzwerte des kausalen Einflusses, wenn er nicht kontrolliert wird.

□

14.3.1 Zur Erinnerung: Konfundierung

Forschungsfrage: Wie groß ist der (kausale) Einfluss der Schlafzimmerzahl auf den Verkaufspreis des Hauses?

a: livingArea, b: bedrooms, p: price

UV: b, AV: p

Das Kausalmodell ist in Abbildung 14.10 dargestellt.




Abbildung 14.10: Der Preis wird sowohl von der Zimmerzahl als auch der Wohnfläche beeinflusst

Im Regressionsmodell $p \sim b$ wird der kausale Effekt durch die Konfundierung mit a verzerrt sein. Der Grund für die Konfundierung sind die zwei Pfade zwischen b und p :

1. $b \rightarrow p$
2. $b \leftarrow a \rightarrow p$

Beide Pfade erzeugen (statistische) Assoziation zwischen b und p . Aber nur der erste Pfad ist kausal; der zweite ist nichtkausal. Gäbe es nur den zweiten Pfad und wir würden b ändern, so würde sich p *nicht* ändern.

14.3.2 Gute Experimente zeigen den echten kausalen Effekt

Abbildung 14.11 zeigt eine erfreuliche Situation: Die „Hintertür“ zu unserer UV (Zimmerzahl) ist geschlossen!

Ist die Hintertür geschlossen – führen also keine Pfeile in unserer UV – so kann eine Konfundierung ausgeschlossen werden.




Abbildung 14.11: Unverzerrte Schätzung des kausalen Effekts unserer UV (Zimmerzahl). Das Regressionsgewicht ist hier der unverzerrte Kausaleffekt. Es spielt keine Rolle, ob der andere Prädiktor im Modell enthalten ist. Da die beiden Prädiktoren unkorreliert sind, hat die Aufnahme des einen Prädiktors keinen Einfluss auf das Regressionsgewicht des anderen.

Die „Hintertür“ der UV (b) ist jetzt zu! Der einzig verbleibende, erste Pfad ist der kausale Pfad und die Assoziation zwischen b und p ist jetzt komplett kausal.

Eine berühmte Lösung, den kausalen Pfad zu isolieren, ist ein (randomisiertes, kontrolliertes⁷) Experiment. Wenn wir den Häusern zufällig (randomisiert) eine Anzahl von Schlafzimmern (b) zuweisen könnten (unabhängig von ihrer Quadratmeterzahl, a), würde sich der Graph so ändern. Das Experiment *entfernt* den Einfluss von a auf b. Wenn wir selber die Werte von b einstellen im Rahmen des Experiments, so kann a keine Wirkung auf b haben. Damit wird der zweite Pfad, $b \leftarrow a \rightarrow p$ geschlossen („blockiert“).

! Wichtig

Die Stärke von (gut gemachten) Experimente ist, dass sie kausale Hintertüren schließen. Damit erlauben sie (korrekte) Kausalaussagen. □

⁷engl. randomized, controlled trial, RCT

14.3.3 Hintertür schließen auch ohne Experimente

Konfundierende Pfade zu blockieren zwischen der UV und der AV nennt man auch *die Hintertür schließen* (backdoor criterion). Wir wollen die Hintertüre schließen, da wir sonst nicht den wahren, kausalen Effekt bestimmen können.

Zum Glück gibt es neben Experimenten noch andere Wege, die Hintertür zu schließen, wie die Konfundierungsvariable a in eine Regression mit aufzunehmen.

Tipp

Kontrollieren Sie Konfundierer, um kausale Hintertüren zu schließen. $\square$

Warum blockt das Kontrollieren von a den Pfad $b \leftarrow a \rightarrow p$? Stellen Sie sich den Pfad als eigenen Modell vor. Sobald Sie a kennen, bringt Ihnen Kenntnis über b kein zusätzliches Wissen über p . Wissen Sie hingegen nichts über a , lernen Sie bei Kenntnis von b auch etwas über p . Konditionieren ist wie „gegeben, dass Sie a schon kennen...“.

$$b \perp\!\!\!\perp p \mid a$$

14.4 Die vier Atome der Kausalanalyse

Abbildung 14.12 stellt die vier „Atome“ der Kausalinferenz dar. Mehr gibt es nicht! Kennen Sie diese vier Grundbausteine, so können Sie jedes beliebige Kausalsystem (DAG) entschlüsseln.




Abbildung 14.12: Die vier Atome der Kausalinferenz

14.4.1 Mediation

Definition 14.4 (Mediator). Einen Pfad mit drei Knoten (Variablen), die über insgesamt zwei Kanten verbunden sind, wobei die Pfeile von UV zu Mediator und von Mediator zur AV zeigen, nennt man *Mediation*. Der *Mediator* ist die Variable zwischen UV und AV (Pearl et al., 2016, p. 38). □

Die *Mediation* (synonym: Wirkkette, Rohr, Kette, chain) beschreibt Pfade, in der die Kanten (eines Pfades) die gleiche Wirkrichtung haben: $x \rightarrow m \rightarrow y$. Anders gesagt: Eine Mediation ist eine Kausalabfolge der Art $x \rightarrow m \rightarrow y$, s. Abbildung 14.13. Die Variable in der Mitte m der Kette wird auch *Mediator* genannt, weil sie die Wirkung von X auf Y „vermittelt“ oder überträgt. Die Erforschung von Mediation spielt eine recht wichtige Rolle in einigen Wissenschaften, wie der Psychologie.

Die Mediation




Abbildung 14.13: Das Kausalmodell der Mediation mit x als UV, m als Mediator und Y als AV.

Beispiel 14.1 (Mediator kontrollieren?). Sollte man den Mediator m in Abbildung 14.13 kontrollieren, wenn man den Kausaleffekt von x auf y schätzen möchte?⁸ □

⁸Nein, durch das Kontrollieren von m wird der Kausalpfad von x zu y geschlossen. Es kann keine kausale Assoziation von x auf y mehr „fließen“.

Ohne Kontrollieren ist der Pfad offen: Die Assoziation „fließt“ den Pfad entlang (in beide Richtungen). Kontrollieren blockt (schließt) die Kette (genau wie bei der Gabel).

Tipp

Kontrollieren Sie den Mediator *nicht*. Der Pfad über den Mediator ist ein „echter“ Kausalpfad, keine Scheinkorrelation. $\square$

Wichtig

Das Kontrollieren eines Mediators ist ein Fehler, wenn man am gesamten (totalen) Kausaleffekt von UV zu AV interessiert ist. $\square$

Es kann auch angenommen werden, dass der Mediator nicht der einzige Weg von X zu Y ist, s. Abbildung 14.14. In Abbildung 14.14 gibt es zwei kausale Pfade von X zu Y: $x \rightarrow m \rightarrow y$ und $x \rightarrow y$.

Definition 14.5 (Kausaleffekt). Gibt es eine (von (praktisch) Null verschiedene) kausale Assoziation der UV auf die AV, so hängt die AV von der UV (kausal) ab. Man spricht von einem Kausaleffekt (der UV auf die AV). $\square$

Definition 14.6 (Totaler Effekt). Die Summe der Effekte aller (kausalen) Pfade von UV zu AV nennt man den *totalen (kausalen) Effekt*. $\square$

Definition 14.7 (Indirekter Effekt). Den (kausalen) Effekt über den Mediatorpfad (von X über M zu Y) nennt man den *indirekten (kausalen) Effekt*. $\square$

Definition 14.8 (Direkter Effekt). Ein Effekt, der nur aus dem Pfad $x \rightarrow y$ besteht, also ohne Zwischenglieder, nennt man in Abgrenzung zum indirekten Effekt, *direkten (kausalen) Effekt*. $\square$




Abbildung 14.14: Partielle Mediation: Es gibt einen direkten Effekt ($X \rightarrow Y$) und einen indirekten Effekt ($X \rightarrow M \rightarrow Y$).

14.4.2 Der Nachfahre

Definition 14.9 (Nachfahre). Ein *Nachfahre* (engl. *descendent*) ist eine Variable, die von einer anderen Variable beeinflusst⁹ wird, s. Abbildung 14.15. $\square$

Kontrolliert man einen Nachfahren d , so kontrolliert man damit zum Teil den Vorfahren (die Ursache), m . Der Grund ist, dass d Information beinhaltet über m . Hier wird das Kontrollieren von d den Pfad von x nach y teilweise öffnen, da m eine Kollisionsvariable ist.

⁹beeinflussen ist grundsätzlich kausal zu verstehen

14.5 Schließen Sie die Hintertür (wenn möglich)!




Abbildung 14.15: Ein Nachfahre verhält sich ähnlich wie sein Vorfahre...

14.4.3 Kochrezept zur Analyse von DAGs 🧑🔍

Wie kompliziert ein DAG auch aussehen mag, er ist immer aus diesen vier Atomen aufgebaut.

Hier ist ein Rezept, das Ihnen zeigt, welche Variablen Sie kontrollieren sollten und welche nicht: 📄

1. Listen Sie alle Pfade von UV (X) zu AV (Y) auf.
2. Beurteilen Sie jeden Pfad, ob er gerade geschlossen oder geöffnet ist.
3. Beurteilen Sie für jeden Pfad, ob er ein Hintertürpfad ist (Hintertürpfade haben einen Pfeil, der zur UV führt).
4. Wenn es geöffnete Hintertürpfade gibt, prüfen Sie, welche Variablen man kontrollieren muss, um den Pfad zu schließen (falls möglich).

14.5 Schließen Sie die Hintertür (wenn möglich)!

14.5.1 Hintertür: ja oder nein?

14.5.1.1 Fall 1: $x \rightarrow$

$$\boxed{X \rightarrow}$$

Alle Pfade, die von der UV (X) *wegführen*, sind entweder „gute“ Kausalpfade oder automatisch geblockte Nicht-Kausal-Pfade. In diesem Fall müssen wir nichts tun.

14 Die Atome der Kausalität

Denken Sie daran, dass Sie keine Nachkommen der UV kontrollieren dürfen, da das den Kausalfad von der UV zur AV blockieren könnte.

14.5.1.2 Fall 2: $\rightarrow X$

$$\rightarrow X$$

Alle Pfade, die zur UV *hinführen*, sind immer Nicht-Kausal-Pfade, *Hintertüren*. Diese Pfade können offen sein, dann müssen wir sie schließen. Sie können auch geschlossen sein, dann müssen wir nichts tun.

💡 Tipp

Schließen Sie immer offene Hintertüren, um Verzerrungen der Kausaleffekte zu verhindern. $\square$

14.5.2 bsp1

UV: X , AV: Y , drei Kovariaten (A , B , C) und ein ungemessene Variable, U




Abbildung 14.16: Puh, ein schon recht komplizierter DAG

Es gibt zwei Hintertürpfade in Abbildung 14.16:

1. $X \leftarrow U \leftarrow A \rightarrow C \rightarrow Y$, offen
2. $X \leftarrow U \rightarrow B \leftarrow C \rightarrow Y$, geschlossen

14.5 Schließen Sie die Hintertür (wenn möglich)!

Kontrollieren von A oder (auch) C schließt die offene Hintertür.

McElreath (2020), Kurz (2021), s. S. 186.

14.5.3 Schließen Sie die Hintertür (wenn möglich)!, bsp2

S. DAG in Abbildung 14.17: UV: W , AV: D




Abbildung 14.17: Welche Variablen muss man kontrollieren, um den Effekt von W auf D zu bestimmen?

Kontrollieren Sie diese Variablen, um die offenen Hintertüren zu schließen:

- entweder A und M
- oder S

Mehr Infos¹⁰

Details finden sich bei McElreath (2020) oder Kurz (2021), S. 188.

¹⁰<https://bookdown.org/content/4857/the-haunted-dag-the-causal-terror.html#backdoor-waffles>

14.5.4 Implizierte bedingte Unabhängigkeiten von bsp2

Auch wenn die Daten nicht sagen können, welcher DAG der richtige ist, können wir zumindest lernen, welcher DAG falsch ist. Die vom Modell implizierten bedingten Unabhängigkeiten geben uns Möglichkeiten, zu prüfen, ob wir einen DAG verwerfen (ausschließen) können. Bedingte Unabhängigkeit zwischen zwei Variablen sind Variablen, die nicht assoziiert (also stochastisch unabhängig) sind, wenn wir eine bestimmte Menge an Drittvariablen kontrollieren.

bsp2 impliziert folgende bedingte Unabhängigkeiten:

```
## A _||_ W | S  
## D _||_ S | A, M, W  
## M _||_ W | S
```

14.6 Fazit

14.6.1 Ausstieg

Beispiel 14.2 (PMI zum heutigen Stoff). Der Kreativitätsforscher Edward de Bono hat verschiedene „Denkmethoden“ vorgestellt, die helfen sollen, Probleme besser zu lösen. Eine Methode ist die „PMI-Methode“. PMI steht für *Plus*, *Minus*, *Interessant*. Bei Plus und Minus soll man eine Bewertung von Positiven bzw. Negativen bzgl. eines Sachverhaltes anführen. Bei *Interessant* verzichtet man aber explizit auf eine Bewertung (im Sinne von „gut“ oder „schlecht“) und fokussiert sich auf Interessantes, Überraschendes, Bemerkenswertes.

Führen Sie die PMI-Methode zum heutigen Stoff durch!

1. *Plus*: Was fanden Sie am heutigen Stoff gut, sinnvoll, nützlich? Warum?
2. *Minus*: Was finden Sie am heutigen Stoff nicht gut, sinnvoll, nützlich? Warum?
3. *Interessant*: Was finden Sie am heutigen Stoff bemerkenswert, interessant, nachdenkenswert? Warum?

Reichen Sie die Antworten an der von der Lehrkraft angezeigten Stelle ein! □

14.6.2 Zusammenfassung

Wie (und sogar ob) Sie statistische Ergebnisse (z. B. eines Regressionsmodells) interpretieren können, hängt von der *epistemologischen Zielrichtung* der Forschungsfrage ab:

- Bei *deskriptiven* Forschungsfragen können die Ergebnisse (z. B. Regressionskoeffizienten) direkt interpretiert werden. Z. B. „Der Unterschied zwischen beiden Gruppen beträgt etwa ...“. Allerdings ist eine kausale Interpretation nicht zulässig.
- Bei *prognostischen* Fragestellungen (Vorhersagen) spielen die Modellkoeffizienten keine Rolle, stattdessen geht es um vorhergesagten Werte, $\hat{y}_i$, z. B. auf Basis der PPV. Kausalaussagen sind zwar nicht möglich, aber auch nicht von Interesse.
- Bei *kausalen* Forschungsfragen dürfen die Modellkoeffizienten nur auf Basis eines Kausalmodells (DAG) oder eines (gut gemachten) Experiments interpretiert werden.

Modellkoeffizienten ändern sich (oft), wenn man Prädiktoren zum Modell hinzufügt oder wegnimmt. Entgegen der verbreiteten Annahme ist es falsch, möglichst viele Prädiktoren in das Modell aufzunehmen, wenn das Ziel eine Kausalaussage ist. Kenntnis der „kausalen Atome“ ist Voraussetzung zur Ableitung von Kausalschlüssen in Beobachtungsstudien.

14.6.3 Vertiefung

An weiterführender Literatur sei z. B. Cummiskey et al. (2020), Lübke et al. (2020), Pearl et al. (2016) und Dablander (2020) empfohlen. Ein gutes Lehrbuch, das auf Kausalinferenz eingeht, ist Huntington-Klein (2022). Praktischerweise ist es öffentlich lesbar¹¹. Das Web-Buch Causal Inference for the Brave and True¹² sieht auch vielversprechend aus. Es gibt viel Literatur zu dem Thema; relevante Suchterme sind z. B. „DAG“, „causal“ oder „causal inference“.

¹¹<https://theeffectbook.net/ch-CausalPaths.html>

¹²<https://matheusfacure.github.io/python-causality-handbook/landing-page.html>

14.7 Aufgaben

- Sammlung „kausal“

14.7.1 Papier-und-Bleistift-Aufgaben

1. kollision-eignung
2. hintertuer
3. tutorium-kausal

Literaturverzeichnis

- Badenes-Ribera, L., Frias-Navarro, D., Iotti, B., Bonilla-Campos, A., & Longobardi, C. (2016). Misconceptions of the P-Value among Chilean and Italian Academic Psychologists. *Frontiers in Psychology*, 7. <https://www.frontiersin.org/article/10.3389/fpsyg.2016.01247>
- Bourier, G. (2011). *Wahrscheinlichkeitsrechnung und schließende Statistik: praxisorientierte Einführung mit Aufgaben und Lösungen* (7., aktualisierte Aufl). Gabler.
- Bourier, G. (2022). *Statistik-Übungen: Beschreibende Statistik – Wahrscheinlichkeitsrechnung – Schließende Statistik* (7. Auflage). Springer Gabler.
- Briggs, W. M. (2016). *Uncertainty: The Soul of Modeling, Probability & Statistics*. Springer.
- Cohen, J. (1992). A Power Primer. *Psychological Bulletin*, 112(1), 155–159.
- Cummiskey, K., Adams, B., Pleuss, J., Turner, D., Clark, N., & Watts, K. (2020). Causal Inference in Introductory Statistics Courses. *Journal of Statistics Education*, 28(1), 2–8. <https://doi.org/10.1080/10691898.2020.1713936>
- Dablander, F. (2020). *An Introduction to Causal Inference* [Preprint]. PsyArXiv. <https://doi.org/10.31234/osf.io/b3fkx>
- Forum, W. E. (2020). *The Future of Jobs Report 2020*. World Economic Forum. https://www3.weforum.org/docs/WEF_Future_of_Jobs_2020.pdf
- Gelman, A., Hill, J., & Vehtari, A. (2021). *Regression and Other Stories*. Cambridge University Press.
- Goodrich, B., Gabry, J., Ali, I., & Brilleman, S. (2020). *Rstanarm: Bayesian Applied Regression Modeling via Stan*. <https://mc-stan.org/rstanarm>
- Henze, N. (2019). *Stochastik: Eine Einführung mit Grundzügen der Maßtheorie: Inkl. zahlreicher Erklärvideos*. Springer Berlin Heidelberg. <https://doi.org/10.1007/978-3-662-59563-3>
- Horst, A. (2024). *Statistics Artwork* [Artwork]. <https://allisonhorst.com/>
- Huntington-Klein, N. (2022). *The Effect: An Introduction to Research Design and Causality*. CRC Press, Taylor & Francis Group. <https://theeffectbook.net/>
- Jaynes, E. T., & Bretthorst, G. L. (2003). *Probability Theory: The Logic of Science*. Cambridge University Press.
- Kabadayi, F. (2024). Smartphone Addiction, Depression, Distress, Eustress, Loneliness, and Sleep Deprivation in Adolescents: A Latent Profile and Network Analy-

- sis Approach. *BMC Psychology*, 12(1), 608. <https://doi.org/10.1186/s40359-024-02117-6>
- Kruschke, J. K. (2018). Rejecting or Accepting Parameter Values in Bayesian Estimation. *Advances in Methods and Practices in Psychological Science*, 1(2), 270–280. <https://doi.org/10.1177/2515245918771304>
- Kurz, S. (2021). *Statistical Rethinking with Brms, Ggplot2, and the Tidyverse: Second Edition*. <https://bookdown.org/content/4857/>
- Lübke, K., Gehrke, M., Horst, J., & Szepannek, G. (2020). Why We Should Teach Causal Inference: Examples in Linear Regression with Simulated Data. *Journal of Statistics Education*, 1–17. <https://doi.org/10.1080/10691898.2020.1752859>
- Makowski, D., Ben-Shachar, M. S., Chen, S. H. A., & Lüdtke, D. (2019). Indices of Effect Existence and Significance in the Bayesian Framework. *Frontiers in Psychology*, 10. <https://www.frontiersin.org/article/10.3389/fpsyg.2019.02767>
- McElreath, R. (2020). *Statistical Rethinking: A Bayesian Course with Examples in R and Stan* (2. Aufl.). Taylor and Francis, CRC Press.
- Messerli, F. H. (2012). Chocolate Consumption, Cognitive Function, and Nobel Laureates. *New England Journal of Medicine*, 367(16), 1562–1564. <https://doi.org/10.1056/NEJMon1211064>
- Mittag, H.-J., & Schüller, K. (2020). *Statistik: Eine Einführung mit interaktiven Elementen*. Springer Berlin Heidelberg. <https://doi.org/10.1007/978-3-662-61912-4>
- Morey, R. D., & Rouder, J. N. (2011). Bayes Factor Approaches for Testing Interval Null Hypotheses. *Psychological Methods*, 16(4), 406–419. <https://doi.org/10.1037/a0024377>
- Pearl, J., Glymour, M., & Jewell, N. P. (2016). *Causal Inference in Statistics: A Primer*. Wiley.
- Popper, K. (2013). *Logik Der Forschung* (H. Keuth, Hrsg.). Akademie Verlag. <https://doi.org/10.1524/9783050063782>
- Rohrer, J. M. (2018). Thinking Clearly About Correlations and Causation: Graphical Causal Models for Observational Data. *Advances in Methods and Practices in Psychological Science*, 1(1), 27–42. <https://doi.org/10.1177/2515245917745629>
- Sauer, S. (2025). *Statistik1*. Independently published via Amazon. <https://www.amazon.de/Statistik1-Einf%C3%BChrung-Statistik-Schwerpunkt-Prognose-Modellierung/dp/B0F673WGG5>
- Shmueli, G. (2010). To Explain or to Predict? *Statistical Science*, 25(3), 289–310. <https://doi.org/10.1214/10-STS330>
- Suttorp, M. M., Siegerink, B., Jager, K. J., Zoccali, C., & Dekker, F. W. (2015). Graphical Presentation of Confounding in Directed Acyclic Graphs. *Nephrology Dialysis Transplantation*, 30(9), 1418–1423. <https://doi.org/10.1093/ndt/gfu325>
- Tennant, P. W. G., Murray, E. J., Arnold, K. F., Berrie, L., Fox, M. P., Gadd, S. C., Harri-

- son, W. J., Keeble, C., Ranker, L. R., Textor, J., Tomova, G. D., Gilthorpe, M. S., & Ellison, G. T. H. (2020). Use of Directed Acyclic Graphs (DAGs) to Identify Confounders in Applied Health Research: Review and Recommendations. *International Journal of Epidemiology*, 50(2), 620–632. <https://doi.org/10.1093/ije/dyaa213>
- van Kampen, D. (2014). The SSQ Model of Schizophrenic Prodromal Unfolding Revised: An Analysis of Its Causal Chains Based on the Language of Directed Graphs. *European Psychiatry*, 29(7), 437–448. <https://doi.org/10.1016/j.eurpsy.2013.11.001>
- VanderWeele, T. J., & Shpitser, I. (2013). On the Definition of a Confounder. *Annals of statistics*, 41(1), 196–220. <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4276366/>
- Wasserstein, R. L., & Lazar, N. A. (2016). The ASA’s Statement on p-Values: Context, Process, and Purpose. *The American Statistician*, 70(2), 129–133. <https://doi.org/10.1080/00031305.2016.1154108>

Teil V

Anhang

15 Abschluss

15.1 Lernsteuerung

Nach Absolvieren des jeweiligen Kapitels sollen folgende Lernziele erreicht sein.

Sie können ...

- erläutern, wie Sie eine typische, sozialwissenschaftliche Forschungsfrage (quantitativ) untersuchen
- typische “Lieblingsfehler” benennen und Wege aufzeigen, um die Fehler zu umgehen
- zwischen den Grundkonzepten der Frequentistischen Statistik und der Bayes-Statistik übersetzen
- die Grundideen der Bayes-Statistik in einen Gesamtzusammenhang einordnen

In diesem Kapitel benötigen Sie folgende R-Pakete.

```
library(tidyverse)
library(easystats)
library(rstanarm)
```

Nutzen Sie nach Bedarf folgende Begleitvideos:

- Fragestunde QM2
- Playlist QM2
- Lieblingsfehler

15.2 Lieblingsfehler

Lieblingsfehler im Überblick:

1. Quantile und Verteilungsfunktion verwechseln
2. Prädiktoren nicht zentrieren, wenn es einen Interaktionsterm gibt
3. Interaktion falsch interpretieren
4. Regressionskoeffizienten kausal interpretieren, wenn es keine kausale Fundierung gibt

15.2.1 Vertiefung: Post-Präd-Verteilung (PPV) und Post-Verteilung verwechseln

Berechnen wir unser Standard-mtcars-Modell: `mpg ~ hp`.

```
m1 <- stan_glm(mpg ~ hp, data = mtcars, refresh = 0)
```

Die *Post-Verteilung* zeigt Stichproben zu den Parameterwerten, s. Tabelle 15.1.

```
post_verteilung <- m1 |>
  as_tibble()
head(post_verteilung)
```

Tabelle 15.1: Postverteilung in Stichprobenform (m1)

	(Intercept)	hp	sigma
	25	-0.04	4.6
	29	-0.06	3.6
	31	-0.08	5.0
	30	-0.07	4.2
	30	-0.08	3.9
	34	-0.08	4.3

Diese Tabelle kann man hernehmen, um Fragen zu Post-Verteilung zu beantworten. Häufig ist es aber bequemer, z. B. mit `parameters(m1)` Post-Intervalle und Punktschätzer auszulesen.

Die *Posterior-Prädiktiv-Verteilung* (PPV) zeigt die Vorhersagen, also keine Parameterwerte, sondern Beobachtungen.

name	value
Mazda RX4	22
Mazda RX4 Wag	17
Datsun 710	18
Hornet 4 Drive	16
Hornet Sportabout	17

15.2.2 Quantile und Verteilungsfunktion verwechseln

15.2.2.1 Quantil für p

Ein p -Quantil teilt eine Verteilung in zwei Teile, und zwar so, dass mind. p kleiner oder gleich dem p -Quantil sind. s. Abbildung 15.1.




Abbildung 15.1: 50%-Quantil

Das 50 %-Quantil (.5-Quantil) beträgt $x = 0$. Mind ein Anteil $1 - p$ ist größer oder gleich dem p -Quantil.

15.2.2.2 Verteilungsfunktion F

$F(x)$ gibt die Wahrscheinlichkeit an der Stelle x an, dass X einen Wert kleiner oder gleich x annimmt, s. Abbildung 15.2.




Abbildung 15.2: Verteilungsfunktion $F(x=0)=1/2$

$F(0) = 1/2$, die Wahrscheinlichkeit beträgt hier 50 %, dass x nicht größer ist als 0.

15.2.3 Interaktion falsch interpretieren

Berechnen wir ein einfaches Interaktionsmodell: $\text{mpg} \sim \text{hp} * \text{vs}$.

i Hinweis

Zur Erinnerung: $\text{mpg} \sim \text{hp} * \text{vs}$ ist synonym zu (aber kürzer als) $\text{mpg} \sim \text{hp} + \text{vs} + \text{hp}:\text{vs}$.

```
m2 <- stan_glm(mpg ~ hp*vs, data = mtcars) # mit Interaktionseffekt
```

Modellkoeffizienten, s. Tabelle 15.2.

```
parameters(m2)
```

Tabelle 15.2: Parameter von m2

Tabelle 15.2: Fixed Effects		
Parameter	Median	CI
(Intercept)	24.58	(19.07, 29.94)
hp	-0.04	(-0.07, -0.01)
vs	14.22	(5.76, 23.58)
hp:vs	-0.11	(-0.20, -0.03)

Tabelle 15.2 zeigt die Visualisierung der Parameter von m2.

```
plot(parameters(m2))
```




Abbildung 15.3: Parameter von m2 visualisiert

Falsch 🐱 Der Unterschied im Verbrauch zwischen den beiden Gruppen vs=0 und vs=1 beträgt ca. 14.3.

Richtig 🤖 Der Unterschied im Verbrauch zwischen den beiden Gruppen $vs=0$ und $vs=1$ beträgt ca. 14.3 – wenn $hp=0$.

Da $hp=0$ kein realistischer Wert ist, ist das Modell schwer zu interpretieren. Zentrierte Prädiktoren wären hier eine sinnvolle Lösung.

Gelman et al. (2021), Kap. 10, McElreath (2020), Kap. 8

15.3 Kochrezepte

15.3.1 Kochrezept: Forschungsfrage untersuchen

Theoretische Phase 1. Staunen über ein Phänomen, y , Kausalfrage finden 2. Literatur wälzen, um mögliche Ursachen x von y zu lernen 3. Forschungsfrage, Hypothese präzisieren 4. Modell präzisieren (DAG(s), Prioris)

Empirische Phase

5. Versuch planen
6. Daten erheben

Analytische Phase

7. Daten aufbereiten
8. Modell berechnen anhand eines oder mehrerer DAGs
9. Modell prüfen/kritisieren
10. Forschungsfrage beantworten

Yeah! Fertig.

15.3.2 Parameter schätzen vs. Hypothesen prüfen

Quantitative Studien haben oft einen von zwei (formalen) Zielen: Hypothesen testen oder Parameter schätzen. Beispiel Hypothesenprüfung: „Frauen parken im Durchschnitt schneller ein als Männer“. Beispiel Parameterschätzung: „Wie groß ist der mittlere Unterschied in der Ausparkzeit zwischen Frauen und Männern?“

Je ausgereifter ein Forschungsfeld, desto *kühnere* Hypothesen lassen sich formulieren: – stark ausgereift: – Die nächste totale Sonnenfinsternis in Deutschland wird

15 Abschluss

am 27.7.2082 um 14.47h stattfinden, Quelle¹ - gering ausgereift: - Die nächste Sonnenfinsternis wird in den nächsten 100 Jahren stattfinden. - Lernen bringt mehr als Nicht-Lernen für den Klausurerfolg. Kühne Hypothesen sind wünschenswert



15.3.3 Formalisierung von Forschungsfragen

Der Mittelwert in Gruppe A ist höher als in Gruppe B (der Unterschied, d , im Mittelwert ist größer als Null):

$$\mu_1 > \mu_2 \Leftrightarrow \mu_1 - \mu_2 > 0 \Leftrightarrow \mu_d > 0$$

15.4 Kerngedanken Bayes

15.4.1 Zentraler Kennwert der Bayes-Statistik: Post-Verteilung

Berechnen wir wieder ein einfaches² Modell: $\text{mpg} \sim \text{hp}$.

```
m3 <- stan_glm(mpg ~ hp, data = mtcars)
```

Und schauen wir uns die Post-Verteilung an, mit eingezeichnetem HDI, s. Abbildung 15.4.

¹<https://www.solar-eclipse.info/de/eclipse/country/DE/>

²langweiliges

Highest Density Interval (HDI)




Abbildung 15.4: Post-Verteilung (HDI) von m3

Ein Zusammenfassen der Posterior-Verteilung (z. B. zu einem 95 %-PI) ist möglich und oft sinnvoll. Verschiedene Arten des Zusammenfassens der Post-Verteilung sind möglich, z. B. zu Mittelwert oder SD oder einem HD-Intervall. Allerdings übermittelt nur die gesamte Post-Verteilung alle Informationen. Daher empfiehlt es sich (oft), die Post-Verteilung zu visualisieren.

15.4.2 Posteriori als Produkt von Priori und Likelihood

$$\text{Posteriori} = \frac{\text{Likelihood} \times \text{Priori}}{\text{Evidenz}}$$

15.5 Beispiele für Prüfungsaufgaben

15.5.1 Geben Sie den korrekten Begriff an!

🧠🚗👤 Hans 👤 Anna 👤 Lise

Puh, wie erstelle ich für alle Studis ein anderes Rätsel³?

³Fahr-Hier-Hans-Anna-Lise: Varianzanalyse

15.5.2 DAG mit doppelter Konfundierung

Puh, jetzt kommt ein wilder DAG, s. Abbildung 15.5.




Abbildung 15.5: Ein DAG mit doppelter Konfundierung. Ist hier noch zu helfen?

Definition 15.1 (Minimale Adjustierungsmenge). Die Minimale Adjustierungsmenge für x und y gibt eine kleinstmögliche Menge an Knoten eines DAGs an, die zu adjustieren sind, um den kausalen Effekt von x auf y zu bestimmen (zu „identifizieren“).

□

? Geben Sie die minimale Adjustierungsmenge (minimal adjustment set) an, um den totalen (gesamten) Effekt von E auf D zu bestimmen!

! Entweder ist die Menge $\{A, Z\}$ zu adjustieren oder die Menge $\{B, Z\}$.

Ja, dem DAG ist zu helfen.

15.5.3 DAG mit vielen Variablen

Je nach dem wie komplex Ihre Theorie ist, ist Ihr DAG auch komplex, s. Abbildung 15.6.




Abbildung 15.6: Ein DAG mit vielen Variablen

Minimale Adjustierungsmenge, um den Effekt von E auf D zu identifizieren: {7}, {8}.

Trotz der vielen Variablen, ist der kausale Effekt von E auf D recht gut zu identifizieren.

15.5.4 Ein Kausalmodell der Schizophrenie, van Kampen (2014)

The SSQ model of schizophrenic prodromal unfolding revised:

An analysis of its causal chains based on the language of directed graphs

D. van Kampen

Lesen Sie hier den Abstract⁴.

Folgende Symptome der Schizophrenie wurden gemessen:

Social Anxiety (SAN), Active Isolation (AIS), Affective Flattening (AFF), Suspiciousness (SUS), Egocentrism (EGC), Living in a Fantasy World (FTW), Alienation (ALN), Apathy (APA), Hostility (HOS), Cognitive Derailment (CDR), Perceptual Aberrations (PER), and Delusional Thinking (DET)

van Kampen (2014)

⁴<https://www.cambridge.org/core/journals/european-psychiatry/article/abs/ssq-model-of-schizophrenic-prodromal-unfolding-revised-an-analysis-of-its-causal-chains-based-on-the-language-of-directed-graphs/F2E7BBFC1B392616DB894AFBFABE7818>

15 Abschluss

UV: SUS, AV: EGC

Berechnen Sie die minimale Adjustierungsmenge, um den kausalen Effekt der UV auf die AV zu identifizieren!

Abbildung 15.7 zeigt den DAG von van Kampen (2014) zu den Symptomen der Schizophrenie.




Abbildung 15.7: Ein DAG zu den Symptomen der Schizophrenie

Minimales Adjustment-Set für den totalen Kausaleffekt: {AIS, ALN}

15.5.5 Modelle berechnen

Stellen Sie sich auf Aufgaben ein, in denen Sie Modellparameter berechnen sollen. Orientieren Sie sich an den Aufgaben und Inhalten des Unterrichts.

Prüfungsfragen zu Modellen könnten z. B. sein:

- Geben Sie den Punktschätzer (Median) für den Prädiktor X im Modell Y an!
- Geben Sie ein 89 %-HDI für den Parameter X im Modell Y an!
- Geben Sie R-Quadrat an.
- Formulieren Sie ein Interaktionsmodell!
- Welches Modell ist korrekt, um den kausalen Effekt zu modellieren?
- Formulieren Sie ein Modell mit folgenden Prioris ...
- Liegt der Effekt X noch im ROPE ?
- Unterscheidet sich die Breite des CI von der Breite des HDI für den Prädiktor X im Modell Y?

- Was verändert sich an den Parametern, wenn Sie die Prädiktoren zentrieren/z-standardisieren?
- ...

15.6 Aufgabensammlungen

Folgende Tags auf dem Datenwerk beinhalten relevante Aufgaben⁵:

- bayes
- bayes-grid
- dag
- qm2
- probability
- post
- rope

Besondere „Prüfungsnähe“ könnten diese Sammlungen haben:

- qm2-pruefung
- exam-22
- quiz1-qm2-ws23
- Verteilungen-Quiz

⁵das ist keine vollständige Liste, sondern eine Anregung. Andere Tags könnten auch relevant sein

16 Probeklausur

Diese Liste ist im Aufbau. Bitte konsultieren Sie für weitere Aufgaben selbständig alle relevanten Aufgaben, die in den Kapiteln vorgestellt wurden.

16.1 2025

Hier finden Sie Aufgaben zu einer Probeklausur aus dem Jahr 2025. Die interaktiven Single-Choice-Aufgaben stehen nur in der HTML-Version des Buches zur Verfügung; hier folgt stattdessen eine Liste mit Links zu den entsprechenden Aufgaben im Datenwerk.

1. [anova-skalenniveau](#)
2. [anz-params](#)
3. [aussagen-infstat](#)
4. [exp1](#)
5. [def-statistik01](#)
6. [interpret-ci2](#)
7. [exp2](#)
8. [exp-tab](#)
9. [gem-wskt1](#)
10. [gem-wskt2](#)
11. [gem-wskt4](#)
12. [genial](#)
13. [globus2](#)
14. [griech-buchstaben](#)
15. [fofrage-regrformel](#)
16. [fofrage-regrformel2](#)
17. [gruppenvergleich-regression](#)
18. [interpret-ci](#)
19. [interpret-koeff](#)
20. [kaefer1](#)

21. kekse01
22. klausuren-bestehen
23. bayes-theorem1

16.2 2024

1. ttest-als-regr
2. Additionssatz1
3. Nerd-gelockert
4. Urne1
5. corona-blutgruppe
6. voll-normal
7. alphafehler-inflation3
8. verteilungen-quiz-05
9. verteilungen-quiz-03
10. verteilungen-quiz-04
11. Kekse03
12. globus-bin2
13. globus2
14. iq01a
15. gem-wskt4
16. Rethink2m3
17. mtcars-post2a
18. groesse03
19. bath42
20. klausur-raten
21. bed-post-wskt1
22. mtcars-post3a
23. exp-tab
24. norms-sd
25. mtcars-post_paper
26. bfi10
27. rope-luecke
28. wskt-schluckspecht2a
29. penguins-stan-06

16.3 2023

Dieser Tag auf dem Datenwerk stellt Fragen einer Probeprüfung (Version 2023) zusammen.

16.4 2022

Dieser Tag auf dem Datenwerk stellt Fragen einer Probeprüfung (Version 2022) zusammen.

17 Definitionen

1. Kausale Abhängigkeit: Definition 13.5
2. Additionssatz für disjunkte Ereignisse: Definition 5.1
3. Allgemeiner Additionssatz: Definition 5.2
4. Alternativhypothese (Effekthypothese): Definition 3.8
5. Binomialkoeffizient: Definition 6.2
6. Binomialverteilung: Definition 6.1
7. Blockieren: Definition 13.2
8. Kollision: Definition 14.1
9. Konfundierungsvariable: Definition 13.1
10. DAG: Definition 13.3
11. Elementarereignis: Definition 4.5
12. Deskriptivstatistik: Definition 2.1
13. Direkter Effekt: Definition 14.8
14. Effekt: Definition 2.4
15. Ereignis: Definition 4.3
16. Ergebnisraum: Definition 4.2
17. Perzentilintervall (PI): Definition 8.1
18. Evidenz: Definition 7.4
19. Funktion: Definition 2.3
20. Gemeinsame Wahrscheinlichkeit: Definition 5.6
21. Halbe Normalverteilung: Definition 6.3

17 Definitionen

- 22. Intervalle höchster Dichte (Highest Density Intervals): Definition 8.2
- 23. Hintertür: Definition 14.3
- 24. Indirekter Effekt: Definition 14.7
- 25. Stochastische Unabhängigkeit: Definition 5.4
- 26. Indifferenzprinzip: Definition 4.9
- 27. (Populations-)Inferenzstatistik: Definition 3.1
- 28. Kausaleffekt: Definition 14.5
- 29. Kettenregel: Definition 5.7
- 30. Konfidenzintervall: Definition 3.5
- 31. Likelihood: Definition 7.2
- 32. Laplace-Experiment: Definition 4.10
- 33. Mächtigkeit: Definition 4.7
- 34. Mediator: Definition 14.4
- 35. Komplementärereignis: Definition 4.14
- 36. Logische Differenz: Definition 4.15
- 37. Schnittmenge von Ereignissen: Definition 4.13
- 38. Vereinigung von Ereignissen: Definition 4.12
- 39. Minimale Adjustierungsmenge : Definition 15.1
- 40. Modell: Definition 2.2
- 41. Multiplikationssatz der Wahrscheinlichkeit für unabhängige Ereignisse: Definition 5.5
- 42. Nachfahre: Definition 14.9
- 43. Exakte Nullhypothese: Definition 3.7
- 44. Effektwahrscheinlichkeit: Definition 10.1
- 45. Pfad: Definition 13.4
- 46. Populationsinferenz: Definition 3.2
- 47. Aposteriori-Verteilung: Definition 7.3

- 48. Bedingte Wahrscheinlichkeit: Definition 5.3
- 49. Apriori-Verteilung: Definition 7.1
- 50. Relation: Definition 4.11
- 51. ROPE: Definition 11.1
- 52. Sigma als mittleren Vorhersagefehler: Definition 3.4
- 53. Statistische Signifikanz im Frequentismus und im Bayesismus: Definition 3.6
- 54. Stratifizieren: Definition 14.2
- 55. Totaler Effekt: Definition 14.6
- 56. Totale Wahrscheinlichkeit: Definition 5.8
- 57. Unmögliches und sicheres Ereignis: Definition 4.4
- 58. Verteilungsfunktion: Definition 4.18
- 59. Verteilungsfunktion: Definition 4.21
- 60. Vollständiges Ereignissystem: Definition 4.6
- 61. Wahrscheinlichkeitsdichte: Definition 4.20
- 62. Einfache Definition von Wahrscheinlichkeit: Definition 4.8
- 63. Diskrete Wahrscheinlichkeitsverteilung: Definition 4.17
- 64. Zufälliges Ereignis: Definition 3.3
- 65. Zufallsvariable: Definition 4.16
- 66. Zufallsvorgang: Definition 4.1
- 67. Stetige Zufallsvariable: Definition 4.19

18 Theoreme

1. Stochastische Abhängigkeit: Theorem 5.6
2. Stochastische Abhängigkeit 2: Theorem 5.7
3. Allgemeiner Additionssatz: Theorem 5.2
4. Additionssatz für disjunkte Ereignisse: Theorem 5.1
5. Bayes' Theorem: Theorem 7.1
6. Bayes' Theorem als bedingte Wahrscheinlichkeit: Theorem 7.4
7. Binomialkoeffizient: Theorem 6.3
8. Binomialverteilung: Theorem 6.2
9. Notation für eine binomialverteilte Zufallsvariable: Theorem 6.1
10. Man kann die Regression als Korrelation verstehen.: Theorem 12.2
11. Indifferenzprinzip: Theorem 4.1
12. Evidenz: Theorem 7.2
13. Evidenz bei zwei Hypothesen: Theorem 7.3
14. Hypothese für ungleiche Mittelwerte: Theorem 12.1
15. Gemeinsame Wahrscheinlichkeit: Theorem 5.10
16. Stochastische Unabhängigkeit: Theorem 5.4
17. Symmetrie der Unabhängigkeit: Theorem 5.8
18. Stochastische Unabhängigkeit 2: Theorem 5.5
19. Kettenregel: Theorem 5.11
20. Laplace-Experiment: Theorem 4.2
21. Lineares Modell (Regressionsgleichung): Theorem 2.1

- 22. Modelldefinition $m_{\text{kung_gewicht_c}}$: Theorem 10.1
- 23. Gerichteter Hypothesentest: Theorem 11.1
- 24. Multiplikationssatz für unabhängige Ereignisse: Theorem 5.9
- 25. Bedingte Wahrscheinlichkeit: Theorem 5.3
- 26. Totale Wahrscheinlichkeit: Theorem 5.12